



**UNIVERSIDAD DE CHILE
FACULTAD DE ECONOMÍA Y NEGOCIOS
ESCUELA DE POSTGRADO**

Retención de talento con People Analytics: Un enfoque basado en Machine Learning y Uplift Modeling

**ACTIVIDAD FORMATIVA EQUIVALENTE
PARA OPTAR AL GRADO DE MAGISTER EN ANALÍTICA DE NEGOCIOS**

Nicolás Cañete Ponce
Profesor Guía: Jaime Miranda

Santiago, Chile

2025

Tabla de contenido

1. Resumen ejecutivo.....	4
2. Introducción.....	5
3. Planteamiento y formulación del problema.....	7
4. Hipótesis	9
5. Objetivos	10
5.1 Objetivo general	10
5.1 Objetivos específicos.....	10
6. Metodología.....	11
6.1 Selección de datos	12
6.2 Preprocesamiento de datos.....	12
6.3 Transformación de datos.....	12
6.4 Minería de datos.....	12
6.5 Evaluación e interpretación	17
6.6 Despliegue/Utilización del conocimiento.....	20
7. Marco teórico	21
7.1 La fuga de talento: Evolución conceptual, causas y consecuencias	21
7.2 People Analytics y modelos de machine learning en la retención de talento ..	22
7.3 Uplift modeling como herramienta de inferencia causal.....	23
7.4 Investigaciones recientes	24
8. Desarrollo.....	25
8.1 Selección de datos	25
8.2 Pre-procesamiento de datos.....	28
8.3 Transformación de datos (Feature engineering).....	35
8.4 Minería de datos.....	36
8.4.1 Modelado predictivo	36
8.4.2 Modelado con Uplift modeling	42
9. Conclusiones.....	44
10. Trabajos futuros.....	45
Bibliografía.....	46

Índice de ilustraciones y cuadros

Figura 1: Proceso KDD.....	11
Figura 2: Espacio ROC con ejemplos de clasificadores-----	17
Figura 3: Ejemplo de histograma con resultados uplift por profesional.....	19
Tabla 1: Base de datos final.....	26
Gráfico 1: Distribución de Edad por Renuncia o No Renuncia.....	29
Gráfico 2: Distribución de Antigüedad por Renuncia o No Renuncia.....	30
Gráfico 3: Distribución de Nota Desempeño por Renuncia o No Renuncia.....	31
Gráfico 4: Distribución de Incremento por Renuncia o No Renuncia.....	31
Gráfico 5: Distribución de Saldo Vacaciones por Renuncia o No Renuncia.....	32
Tabla 2: Observaciones y Tasa renunciaciones de Puesto.....	32
Tabla 3: Observaciones y Tasa renunciaciones de Subgerencia.....	33
Gráfico 6: Proporción de renunciaciones por Estamento.....	34
Gráfico 7: Proporción de renunciaciones por Sindicato.....	34
Tabla 5: Resultados de modelos de Machine Learning.....	37
Gráfico 9: Curvas ROC por Modelo (Validación Cruzada).....	38
Gráfico 10: Importancia de Variables, LightGBM.....	39
Gráfico 11: Importancia de Variables, Gradient Boosting.....	39
Gráfico 12: Importancia de Variables, XGBoost.....	40
Gráfico 13: Importancia de Variables, Random Forest.....	40
Gráfico 14: Importancia de Variables, Catboost.....	41
Tabla 6: Resultados de Uplift Modeling	42
Gráfico 15: Distribución de Uplift scores.....	43

1. Resumen Ejecutivo

En el escenario empresarial actual, la retención del talento se ha convertido en uno de los más relevantes desafíos estratégicos en materia de gestión de personas para las organizaciones. La pérdida de profesionales calificados no sólo impacta en costos directos para los procesos de reclutamiento, selección y capacitación, sino que también en la pérdida de conocimiento institucional, capital intelectual y redes de comunicación. Estudios muestran que el costo de reemplazo de un profesional altamente calificado puede alcanzar hasta el 200% de su salario anual, evidenciando la magnitud del problema.

La gestión de retención de talento ha estado principalmente enfocada en el diseño de estrategias genéricas, sin diferenciar entre trabajadores con distintos niveles de riesgo o sensibilidad a las intervenciones. Esto lleva a una utilización ineficiente de los recursos, abriendo la posibilidad a la realización de intervenciones de retención en personas que no se presenten como sensibles a estas, abandonando, aun siendo retenidos, la empresa. De esta manera, surge la necesidad de acciones proactivas y predictivas, que permitan distinguir a las personas a intervenir donde se maximice la probabilidad de retención, optimizando esfuerzos y recursos de la organización.

Este trabajo aborda un enfoque basado en la metodología *KDD*¹. Con información histórica de trabajadores de una empresa de transporte, se entrenan y testean modelos de *Machine Learning* para la construcción de modelos predictivos de clasificación de renuncia y se implementa *Uplift Modeling* para estimar el efecto causal de una intervención de retención.

Los resultados del modelado predictivo confirman la superioridad de técnicas de *Gradient Boosting*, con *LightGBM* obteniendo los mayores resultados de *F1-score* (0.4763). El análisis de *Uplift Modeling* identificó a 74 trabajadores persuasibles², permitiendo enfocar estrategias de retención de talento y desde ahí eficientizar el uso de recursos. Esto demuestra que la analítica avanzada puede transformar la gestión de recursos humanos hacia un enfoque basado en evidencia. Es relevante mencionar que una limitación del estudio es el reducido tamaño del grupo de tratamiento de retención (N=28), lo que plantea la necesidad de futuras investigaciones con mayor cantidad de datos.

Este documento abarca desde el planteamiento del problema, las hipótesis, los objetivos a alcanzar de este trabajo, la metodología en detalle utilizada, el marco teórico que envuelve la investigación, el desarrollo de los modelos, para finalizar con las conclusiones obtenidas y futuros trabajos.

Esta AFE concluye que la combinación de técnicas de *Machine Learning* y *Uplift Modeling*, aplicados a los conceptos de *People Analytics*, pueden ser un aliado estratégico clave en la retención proactiva del talento, impactando así a la sostenibilidad, eficiencia y productividad de las organizaciones.

¹ *Knowledge Discovery in Databases*

² Trabajadores que son susceptibles a cambiar su decisión de renuncia producto de una acción de retención.

2. Introducción

En el competitivo escenario empresarial del Siglo XXI, la gestión del talento se ha levantado como un pilar fundamental para la sostenibilidad de las organizaciones. El entorno globalizado en el que se desenvuelven las empresas se caracteriza por presentar una constante evolución tecnológica, con una creciente demanda por habilidades cada vez más especializadas. La capacidad de las organizaciones para atraer, desarrollar y retener a sus trabajadores de alto desempeño se ha convertido en un elemento de atención para las organizaciones, quienes comprenden que la pérdida de talento valioso trae consigo costos de reclutamiento, capacitación, pérdida de productividad, y otros intangibles como motivación, moral, clima.

Las organizaciones enfrentan de manera persistente el desafío de la fuga de talento, también llamada rotación de personas o *employee turnover*. Esto implica la renuncia de trabajadores de una empresa, traducándose como una pérdida de capital intelectual, del *know how*, experiencia y relaciones estratégicas que son insustituibles en el corto plazo (Dess & Shaw, 2001). En el contexto de un mercado laboral altamente competitivo desde el capital humano, la pérdida de trabajadores clave puede traer consigo repercusiones no sólo al entorno directo de quien renuncia, sino que también al resto de la estructura organizacional.

La creciente relevancia de la analítica de datos en el ámbito de Recursos Humanos (*People Analytics*) y la necesidad apremiante de transformar la gestión del talento de una práctica reactiva a una proactiva, predictiva y prescriptiva, se levantan como el móvil de este trabajo. La posibilidad de mitigar los costos de la fuga de talento, mejorar la eficiencia de las inversiones en capital humano y, en última instancia, fortalecer la resiliencia organizacional, constituye un campo de investigación de inmenso valor práctico y académico. El avance exponencial en *Machine Learning* y la disponibilidad de grandes volúmenes de datos organizacionales ofrecen una oportunidad sin precedentes para abordar este desafío con mayor precisión y efectividad.

Los fundamentos que sustentan este trabajo se asientan en la intersección de la teoría de la gestión del capital humano, la inferencia causal y la ciencia de datos. Se reconoce que la decisión de un trabajador de permanecer o irse está influenciada por una interacción de factores individuales, organizacionales y contextuales. La hipótesis central es que los modelos predictivos de *Machine Learning*, al ser entrenados con datos históricos, pueden identificar patrones asociados a la fuga de talento con una precisión superior a los métodos tradicionales.

Junto a esto, se postula que a través de la utilización de técnicas de *Uplift Modeling*, es posible que las organizaciones puedan identificar qué intervenciones de retención específicas son más efectivas para segmentos particulares de empleados en riesgo de fuga. *Uplift Modeling* se aproxima como una técnica de analítica predictiva que estima el efecto causal de una intervención en diferentes individuos, siendo de esta manera una herramienta que permite identificar qué intervenidos podrían tener una mayor probabilidad de éxito del tratamiento (Olaya et al., 2020). Sus principales aplicaciones se observan en la

búsqueda de la maximización de la efectividad en campañas de *marketing*, tratamientos personalizados en medicina, y optimización de precios (Olaya et al., 2020), sin embargo, no se observa mayor investigación de la aplicación de esta técnica en gestión de talento a través del uso de la analítica predictiva del impacto esperado en una campaña de retención.

El enfoque de este trabajo se aparta de las estrategias de retención genéricas e investigaciones únicamente enfocadas en predecir quiénes dejarán la organización, complementándose con la utilización de herramientas que permitan definir qué individuos, con alto riesgo de renuncia, son mejores candidatos a una intervención de retención de talento.

Dentro de este marco, el objetivo general de este AFE es desarrollar y validar un marco metodológico que integre modelos predictivos de *Machine Learning* y *Uplift Modeling* para optimizar las estrategias de retención de talento en organizaciones.

La hipótesis principal de este trabajo es que la aplicación combinada de modelos predictivos de *Machine Learning* y *Uplift Modeling* permitirá a las organizaciones asignar sus recursos de retención de manera más eficiente y efectiva, al identificar y dirigir intervenciones personalizadas a los empleados que son persuasibles, maximizando los esfuerzos de retención y reduciendo los costos asociados a la fuga de talento.

La metodología utilizada en este estudio se basa en la estructura de Descubrimiento de Conocimiento en Bases de Datos (*KDD*) (Fayyad et al., 1996). Este proceso busca garantizar la rigurosidad metodológica desde la selección de la información hasta el despliegue de las soluciones. Este proceso comprende las etapas de Selección de datos, donde se identifican las fuentes de información a utilizar; Preprocesamiento, etapa en la que se asegura la limpieza de los datos para su estructura óptima para las técnicas posteriores; Transformación, donde toma lugar la ingeniería de atributos para transformar las variables de acuerdo a las necesidades de los modelos que se utilizan, Minería de datos, etapa de desarrollo de los modelos de *Machine Learning* para la construcción de los modelos predictivos a través de técnicas como *Random Forest*, *XGBoost*, *LightGBM* y posteriormente *Uplift Modeling*; y finalmente, las etapas de Evaluación e Interpretación de los resultados para analizar la validación de los resultados obtenidos y guiar la toma de decisiones en la implementación de estrategias de retención de talento.

La estructura de este documento abarca el planteamiento y formulación de las hipótesis que dan origen a la investigación, los objetivos de esta, la metodología utilizada para la comprobación de estas hipótesis, el marco teórico en el que sustentan las técnicas utilizadas, el desarrollo investigativo siguiendo la metodología *KDD*, y finalmente las conclusiones recogidas de la fase de desarrollo, contrastando los resultados con las hipótesis planteadas, sugiriendo nuevos campos de acción.

3. Planteamiento y formulación del problema

La fuga de talento es una de las disrupciones más costosas y complejas que enfrentan las organizaciones en el panorama empresarial actual. Las empresas invierten recursos significativos en la atracción, desarrollo y retención de sus empleados, reconociéndolos como un activo determinante para su sostenibilidad. Sin embargo, cuando un empleado clave decide abandonar la organización, esta inversión se ve comprometida, generando una serie de costos directos e indirectos que impactan negativamente en la productividad, la moral del equipo y, en última instancia, en la rentabilidad y la capacidad de innovación. Estos costos incluyen gastos de reclutamiento y capacitación, la pérdida de conocimiento institucional y la interrupción de proyectos. El verdadero problema de negocio aquí no es solo la existencia de la fuga, sino la ineficacia de los enfoques tradicionales para gestionarla.

Actualmente, muchas organizaciones adoptan estrategias de retención, lanzando iniciativas generales sin una comprensión profunda de las razones subyacentes de la fuga o de qué intervenciones son más efectivas para segmentos específicos de su fuerza laboral. Esta falta de precisión resulta en una asignación subóptima de recursos, donde se invierte en empleados que quizás no necesitaban la intervención o en aquellos que, a pesar de la intervención, igualmente se irán. Esto se traduce en un desperdicio de capital financiero y humano, ya que las inversiones en retención no producen el impacto deseado y el talento valioso sigue abandonando la empresa. La decisión de intervenir y cómo hacerlo se convierte en un dilema crítico para la administración, pues una intervención errónea puede no solo ser ineficaz sino incluso contraproducente, erosionando la confianza y el compromiso.

Aquí es donde radica la relevancia crucial en el contexto de la Analítica de Negocios. El problema de la fuga de talento es, fundamentalmente, un problema de toma de decisiones bajo incertidumbre. Las organizaciones necesitan transformar la pregunta "¿Quién se irá?" en la pregunta más poderosa y accionable "¿A quién debemos intervenir para maximizar nuestra probabilidad de retenerlo, optimizando nuestros recursos?" La analítica predictiva ofrece la capacidad de pronosticar la probabilidad de fuga basándose en patrones de datos históricos, moviendo a la organización de una postura reactiva a una proactiva. Sin embargo, el verdadero valor estratégico se alcanza con la analítica prescriptiva, específicamente a través del *Uplift Modeling*. Esta técnica permite estimar el efecto causal incremental de una intervención de retención particular en la probabilidad de que un empleado permanezca. Al hacerlo, el *Uplift Modeling* no solo identifica a los empleados en riesgo, sino que también a los persuasibles: aquellos individuos cuya decisión de quedarse será directamente influenciada por una acción específica. Esto transforma la toma de decisiones de retención, permitiendo a los líderes de Recursos Humanos focalizar sus esfuerzos y presupuestos, aumentando la eficacia de las campañas de retención y alimentando el retorno de la inversión en la gestión del talento.

Considerando el alcance de este trabajo, se establecen como limitación del estudio, la disponibilidad de la información, la investigación está sujeta a la disponibilidad de datos históricos de empleados de una empresa de transportes, donde el acceso a la información relevante para entender los patrones que conducen a una renuncia, están limitados por el acceso que la organización ha conferido de la información de sus trabajadores, como también de la existencia de bases de datos relacionadas a las variables relevantes. Adicionalmente, la proporción de observaciones a predecir es también un limitante, la cantidad de casos de renuncia y la cantidad de intervenciones de retención, sobre el total de observaciones, representan una baja proporción dentro del total de trabajadores de la muestra, lo que lleva a un tratamiento dedicado de estas variables para balancear las clases. De manera que este trabajo se centra exclusivamente en la fuga de talento voluntaria, excluyendo la rotación involuntaria (despidos, jubilaciones), las conclusiones están únicamente orientadas a la toma de acción sobre un tipo de egreso, las renunciaciones, ya que las causas y las estrategias de intervención difieren sustancialmente, no permitiendo generalizar los resultados hacia otras casuísticas de pérdida de fuerza laboral. Finalmente, junto con esto, aunque los modelos y la metodología propuesta se basan en aplicaciones validadas, la aplicabilidad directa de los hallazgos específicos de esta investigación, como los factores que impulsan la decisión de renuncia, requieren del análisis particular de otras organizaciones, dadas las singularidades de cada cultura y contexto empresarial.

4. Hipótesis

La presente investigación busca responder a una serie de interrogantes fundamentales en el ámbito de la gestión del talento y la analítica de negocios, con el fin de transformar las estrategias de retención de una perspectiva reactiva a una proactiva y prescriptiva. Las preguntas que guían este estudio y que se intentará responder a través del desarrollo y aplicación de la metodología propuesta son las siguientes:

- ¿Pueden los modelos predictivos de *Machine Learning* identificar a los empleados con alto riesgo de fuga de manera más precisa y confiable que la intuición gerencial, utilizando datos históricos disponibles en las organizaciones? Esta pregunta busca validar la capacidad de estas herramientas para ofrecer una alerta temprana efectiva sobre la potencial rotación de personal.
- ¿Es posible, mediante el uso de *Uplift Modeling*, determinar qué grupos de empleados en riesgo de fuga son más propensos a ser influenciados positivamente por una intervención de retención específica, optimizando así la asignación de recursos y esfuerzos? Esta pregunta profundiza en la capacidad de la analítica prescriptiva para ir más allá de la predicción, enfocándose en la causalidad y la efectividad de las intervenciones en retención de talento.
- ¿Qué factores son los más relevantes en la probabilidad de fuga de un empleado, y cómo estos factores interactúan para definir la propensión de un individuo a responder a determinadas estrategias de retención? Esta pregunta busca dar respuesta a las causas de la rotación y la sensibilidad a las intervenciones, proporcionando *insights* accionables para la definición de las acciones de Recursos Humanos.

A partir de estas preguntas de investigación, se plantea la siguiente hipótesis central:

La aplicación combinada de modelos predictivos de *Machine Learning* para la detección temprana de la fuga de talento y la implementación de *Uplift Modeling* para la identificación de individuos persuasibles, permitirá a la organización encontrar los patrones que permitan identificar qué trabajadores presenten un alto riesgo de renuncia, al mismo tiempo de detectar la mejor estrategia para evitar el desenlace de ese escenario.

Esta hipótesis no sólo establece que existe un conjunto de atributos que permiten definir patrones que impulsan la decisión de renuncia de un trabajador, sino que también apunta a potenciar la eficacia de las acciones de retención a través de la personalización y la focalización de los esfuerzos.

5. Objetivos

5.1 Objetivo general

El objetivo general de esta AFE es desarrollar e implementar un enfoque analítico integral para la predicción y optimización de la retención de talento, utilizando técnicas de *People Analytics*, *Machine Learning* y *Uplift Modeling*, con el fin de mejorar la toma de decisiones estratégicas en la gestión del talento.

5.2 Objetivos específicos

Para alcanzar el objetivo general de manera estructurada, la investigación se basa en la definición de un marco teórico dentro del cual se fundamenta la investigación sobre fuga de talento y modelos predictivos de *Machine Learning* y *Uplift Modeling*. Se realiza una revisión exhaustiva de la literatura relevante para contextualizar el problema de la fuga de talento, sus causas y consecuencias. Además, profundizar en los fundamentos de la analítica de negocios aplicables a la predicción de la rotación de personal, sentando las bases conceptuales y técnicas necesarias para la investigación.

Se define también como un objetivo específico, diseñar y aplicar una Metodología de Descubrimiento de Conocimiento en Bases de Datos (*KDD*) para la predicción de la fuga de talento. Se busca definir un proceso estructurado y argumentado para la recolección, preprocesamiento y transformación de datos de talento. El objetivo de esto es implementar diferentes técnicas de *Machine Learning* para construir modelos predictivos de fuga, evaluando su rendimiento con métricas de rendimiento. Con esto, se pretende establecer qué trabajadores están en riesgo de renuncia.

Finalmente, se define también como objetivo, descubrir qué profesionales, con alta probabilidad de abandono de la empresa en estudio, presentan una mayor propensión a ser persuadidos mediante acciones de retención. Desde los resultados del modelo predictivo, se aplican técnicas de *Uplift Modeling* para estimar el efecto causal de una intervención de retención y descubrir quienes son aquellos trabajadores a los que debiesen estar dirigidas las retenciones.

6. Metodología

La presente investigación adoptará un enfoque de investigación cuantitativa, estructurado en torno al proceso de Descubrimiento de Conocimiento en Bases de Datos (*KDD*). Este marco proporciona una secuencia lógica para la extracción de patrones a partir de grandes volúmenes de datos. La aplicación del *KDD* garantizará un proceso riguroso desde la selección de los datos hasta la interpretación de los resultados y su despliegue, permitiendo la construcción y validación de modelos predictivos de fuga de talento y la implementación del *Uplift Modeling*.

Las etapas del proceso *KDD*, adaptadas a este estudio, son las siguientes:




Figura 1: Proceso KDD. Adaptado al español de Fayyad, U. M., Piatetsky-Shapiro, G., & Smyth, P. (1996). *From data mining to knowledge discovery in databases*. *AI Magazine*, 17(3), 37–54. <https://doi.org/10.1609/aimag.v17i3.1230>.

1. Selección de datos: Identificación de las fuentes de datos relevantes para la investigación.
2. Preprocesamiento de datos: Limpieza, integración y transformación de los datos para asegurar su calidad y formato adecuado para la utilización de técnicas posteriores.
3. Transformación de datos: Reducción de la dimensionalidad y transformación de atributos (*Feature Engineering*).
4. Minería de datos: Aplicación de algoritmos de *Machine Learning* para construir los modelos predictivos y de *uplift*.
5. Evaluación e interpretación: Análisis y validación de los resultados de los modelos construidos.

6. Despliegue del conocimiento: Implementación de las estrategias de retención basadas en los *insights* obtenidos.

A continuación, se detalla cada una de estas etapas en el contexto de esta investigación:

6.1 Selección de datos

Esta fase inicial se centra en la identificación y recopilación de todas las fuentes de datos y variables que puedan influir en la decisión de un empleado de permanecer o abandonar la organización. Como fuentes de información, se recopilan datos históricos y actuales de distintas fuentes internas de la organización.

La variable por predecir es la fuga voluntaria de talento. Se define como una variable binaria: 1 si el empleado abandonó voluntariamente la organización dentro de un periodo de observación definido y 0 si permaneció.

6.2 Preprocesamiento de datos

Respecto a la limpieza de datos y manejo de valores faltantes, se identifican datos ausentes y se aplican estrategias de imputación (media, mediana, moda, regresión), eliminación de registros o variables, según la naturaleza de los datos y el porcentaje de valores faltantes. Además, en esta etapa se ajustan los tipos de datos (numéricos, categóricos, fechas) para que sean compatibles con los algoritmos de *Machine Learning*.

6.3 Transformación de datos

En esta fase, se refinan los datos para que sean compatibles con los algoritmos de minería de datos. Incluye la reducción de la dimensionalidad y el *feature engineering*.

- *Feature selection*: Identificación de las variables más relevantes para la predicción de la fuga de talento, eliminando aquellas que son redundantes, irrelevantes o que pueden introducir ruido en el modelo.
- *Feature engineering*: Creación de nuevas variables a partir de las existentes que puedan capturar patrones relevantes y manipulación de atributos para mejorar el rendimiento de los modelos posteriores.

6.4 Minería de datos

Etapas central de *KDD* donde se aplican los algoritmos de *machine learning* para construir los modelos predictivos y de *uplift*.

Antes de la implementación de los modelos para predecir renunciaciones, se realizan la Validación cruzada, técnicas de balanceo de clases, tratamiento de variables categóricas.

Una vez que se ha obtenido el conjunto de entrenamiento se utiliza una estrategia de validación cruzada estratificada de 5 *folds* para el entrenamiento de los modelos. Es relevante destacar que todos los pasos de preprocesamiento dependientes de los datos se realizarán dentro de cada iteración de la validación cruzada para prevenir el *data leakage*. De esta manera, en cada iteración de la validación cruzada, el conjunto de entrenamiento se subdivide en $k-1$ *folds* que actúan como el subconjunto de entrenamiento temporal para esa iteración, y 1 *fold* que servirá como el subconjunto de validación temporal.

En cada subconjunto de entrenamiento temporal se realiza la aplicación de *SMOTE* (Chawla et al., 2002), dado el desbalance de la clase de renuncia, se aplica esta técnica exclusivamente al subconjunto de entrenamiento temporal de la iteración actual. Esto asegura que las muestras sintéticas se generen solo a partir de los datos disponibles para el entrenamiento en ese *fold*, evitando la filtración de información.

Se procede con el *One-Hot Encoding* para las variables categóricas, generando nuevas columnas binarias para cada clase de cada una de estas variables. Esta transformación se realiza dentro de cada *fold*, considerando las clases presentes en el *subset* de entrenamiento, y creando las mismas en los sets de prueba, de cada *fold*. De esta manera se evita la filtración de datos.

Finalmente, se entrenan los modelos y se promedian los rendimientos de cada uno en cada uno de los *folds*.

Implementación de modelos de *Machine Learning* para predicción:

Logistic Regression

La regresión logística es un modelo de clasificación supervisada que permite estimar la probabilidad de ocurrencia de un evento binario ($Y=1$ o $Y=0$) en función de un conjunto de variables independientes X (Hosmer, Lemeshow, & Sturdivant, 2013). La relación entre la variable dependiente y las covariables se modela a partir del logaritmo de las razones de probabilidad (logit):

$$\log \left(\frac{P(Y = 1 | X)}{1 - P(Y = 1 | X)} \right) = X\beta$$

La función logística transforma la combinación lineal de los predictores en una probabilidad acotada entre 0 y 1:

$$P(Y = 1 | X) = \frac{1}{1 + e^{-X\beta}}$$

Los coeficientes β indican el efecto de cada variable sobre la probabilidad de ocurrencia del evento de interés y suelen estimarse por máxima verosimilitud. El modelo se utiliza para

clasificación binaria destacándose por su robustez, interpretación y garantías teóricas. (Hosmer, Lemeshow, & Sturdivant, 2013).

Decision Trees

Un árbol de decisión es un algoritmo supervisado que utiliza una estructura tipo árbol para segmentar el espacio de las variables predictoras en regiones homogéneas y tomar decisiones sucesivas a partir de los valores de los atributos (Breiman et al., 1984). Cada nodo representa una prueba sobre una variable, cada rama una secuencia de decisiones y cada hoja una predicción o resultado (Breiman et al., 1984). El proceso de construcción busca maximizar la homogeneidad en cada segmento respecto a la variable objetivo, empleando criterios como la reducción de la impureza de Gini o la ganancia de información (Breiman et al., 1984). Los árboles de decisión pueden utilizarse tanto para clasificación como para regresión, permitiendo visualizar reglas explícitas y son especialmente útiles cuando se busca interpretabilidad (Breiman et al., 1984).

Random Forest

Random Forest es una técnica de ensamblado que construye múltiples árboles de decisión entrenados en subconjuntos aleatorios de datos y variables predictoras (Breiman, 2001). Cada árbol se entrena con una muestra *bootstrap* del conjunto original y un subconjunto aleatorio de variables en cada división (Breiman, 2001). La predicción final se obtiene por votación mayoritaria o promedio de los árboles individuales, lo que mejora la precisión y reduce el sobreajuste (Breiman, 2001). Esta técnica es robusta frente al ruido, variables irrelevantes y es ampliamente utilizada en ciencia de datos para conjuntos de datos grandes y heterógeneos (Breiman, 2001).

Gradient Boosting

Es un ensamblado secuencial donde cada modelo débil corrige los errores del modelo anterior, optimizando una función de pérdida L (Friedman, 2001). Formalmente, el modelo se actualiza iterativamente según:

$$F_m(x) = F_{m-1}(x) + \alpha h_m(x)$$

Donde F_m es el modelo de iteración m , h_m el modelo débil, y α la tasa de aprendizaje (Friedman, 2001). Esto le permite lograr alta precisión y flexibilidad, aunque requiere ajustes finos para evitar sobreajuste (Friedman, 2001).

XGBoost

XGBoost es una implementación avanzada y escalable de *Gradient Boosting* diseñada para ofrecer alta eficiencia computacional, precisión y facilidad de uso en problemas de *Machine Learning* a gran escala (Chen & Guestrin, 2016). Fue desarrollado para resolver limitaciones presentes en implementaciones clásicas de *boosting* integrando una diversidad de técnicas de mejora de rendimiento y aplicabilidad. Se expresa como la suma de M árboles de decisión, cada uno representando una función $h_m(x)$.

$$F_m(x) = \sum_{m=1}^M h_m(x)$$

donde cada h_m contribuye con una predicción parcial para mejorar la aproximación al valor objetivo (Chen & Guestrin, 2016).

LightGBM

Light Gradient Boosting Machine es un algoritmo de *boosting* basado en árboles de decisión que se distingue por su eficiencia y rapidez, especialmente en grandes conjuntos de datos (Ke et al., 2017). Su diseño incluye la presencia de histogramas para discretizar las variables, agrupando los valores de las características en intervalos discretos, en vez de analizar cada valor continuo individualmente. Además, expande sólo la hoja que proporciona la mayor reducción en la función de pérdida, permitiendo el crecimiento de árboles más profundos y enfocados en las áreas más prometedoras del espacio de características, mejorando la precisión del modelo. Con esto, esta técnica permite la capacidad de construir modelos con alto rendimiento en clasificación y regresión, a gran escala y con un consumo reducido de recursos.

CatBoost

Categorical Boosting es un algoritmo de *boosting* desarrollado con especial énfasis en el manejo eficiente de variables categóricas, aspecto crítico en muchos conjuntos de datos reales donde las variables no numéricas son dominantes (Prokhorenkova et al., 2018). Comprende la codificación automática de variables categóricas, empleando técnicas internas para transformar variables categóricas sin necesidad de preprocesamiento externo como *one-hot encoding*, evitando así el crecimiento explosivo de la dimensionalidad y el costo computacional. Utiliza una técnica llamada *Ordered Boosting*, la cual reduce el sesgo que aparece en métodos tradicionales de *boosting* causado por el uso de la misma información para construir y evaluar el modelo en cada iteración. Así, se crean permutaciones aleatorias de los datos para entrenar a cada árbol, asegurando que la predicción de cada muestra se base en modelos que no le han visto previamente, lo que mejora la capacidad de generalización y reduce el sobreajuste.

Implementación de *Uplift Modeling* para estrategias de retención:

T-Learner

Este es un enfoque de inferencia causal que permite estimar el Efecto Condicional Promedio del Tratamiento (*CATE*), el cual mide el efecto esperado de una intervención condicionada en las características individuales X de las unidades observadas (Künzel et al., 2019; Facure, 2018). Este método consiste en la construcción de dos modelos separados e independientes para predecir el resultado bajo tratamiento y control.

El modelo del grupo de tratamiento se entrena exclusivamente con los datos del grupo que recibió la intervención (en el caso de este trabajo, trabajadores retenidos), para estimar la respuesta bajo tratamiento.

$$\mu_1(x) = E[Y(1) \mid X = x]$$

Mientras que el grupo de control se entrena sólo con las observaciones del grupo no tratado, para estimar la respuesta en condiciones sin intervención.

$$\mu_0(x) = E[Y(0) \mid X = x]$$

Posteriormente, para cada individuo con características x , el *CATE* es estimado como la diferencia entre las predicciones de ambos modelos:

$$\hat{T}(x) = \hat{\mu}_1(x) - \hat{\mu}_0(x)$$

Estos modelos pueden ser entrenados utilizando algoritmos de *Machine Learning* que brinden un rendimiento confiable como regresión, árboles de decisión o redes neuronales (Künzel et al., 2019, Facure, 2018). *T-Learner*, modelar de manera individual las funciones de respuesta bajo tratamiento y control, permite capturar las diferencias específicas entre ambos grupos (Nie & Wager, 2001), sin embargo, si las muestras del grupo tratado o de control son pequeñas o desbalanceadas, los modelos pueden sufrir de sobreajuste o producir estimaciones inestables (Künzel et al., 2019).

6.5 Evaluación e Interpretación

En esta fase, se evalúan los modelos con diferentes técnicas y métricas de rendimiento.

Modelo de *Machine Learning* para predicción:

AUC (Area under the curve) y curva ROC

La curva *ROC (Receiver Operating Characteristic)* es una representación gráfica que muestra el desempeño de un clasificador binario en distintos umbrales de decisión. En el eje X se presenta la Tasa de falsos positivos (FPR) y en el eje Y la Tasa de verdaderos positivos (TPR).

$$TPR = \frac{TP}{TP + FN} , \quad FPR = \frac{FP}{FP + TN}$$

Donde TP representa los verdaderos positivos, es decir, la cantidad de casos en los que el modelo predice la clase positiva y la observación es positiva; FN los falsos negativos, cantidad de casos en los que el modelo predice la clase negativa y la observación pertenece a la clase negativa; FP los falsos positivos, cantidad de casos en los que el modelo predice la clase positiva pero la observación pertenece a la clase negativa; y FN los falsos negativos, casos en los que el modelo predice la clase negativa pero la observación pertenece a la clase positiva.

El *AUC* corresponde al área bajo la curva *ROC*. Mide la capacidad del modelo para distinguir entre empleados que, en el caso de este trabajo, renuncian y los que no. Un modelo con buen desempeño tendrá una curva que se acerca a la esquina superior izquierda, con un área bajo la curva cercana a 1.




Figura 2: Espacio ROC con ejemplos de clasificadores.

Tomado de Wikipedia: Curva ROC

Precision

Mide el porcentaje de instancias predichas como positivas que realmente son positivas. Indica qué tan confiable es el modelo cuando califica algo como positivo.

$$Precision = \frac{TP}{TP + FP}$$

Recall

Mide la proporción de casos positivos que fueron correctamente identificados por el modelo. Indica la capacidad del modelo para encontrar todos los elementos positivos.

$$Recall = \frac{TP}{TP + FN}$$

F1-Score

Es el promedio armónico entre *Precision* y *Recall*, lo que equilibra ambas métricas en un solo valor. Cobra mayor relevancia cuando se necesita un balance entre *Precision* y *Recall*, especialmente en contextos con clases desbalanceadas.

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

Importancia de Características

La importancia de las variables o características es una medida que indica cuánto contribuye cada variable de entrada a las predicciones del modelo. Es una métrica de interpretación de los modelos, permitiendo observar cuáles características tienen mayor peso en la determinación del resultado.

En modelos basados en árboles, se calcula a partir de la reducción promedio de la impureza (Gini, entropía) o de la ganancia de información que produce una variable en los nodos de decisión. Una variable con alta importancia indica que es clave para diferencia entre clases o explicar la variabilidad de la predicción.

Análisis de *Uplift score* para estimar el *CATE*

El *Uplift score* mide la diferencia en la probabilidad de un resultado (por ejemplo, renuncia vs permanencia) condicionada a recibir una intervención frente a no recibirla. Se aproxima al *CATE*, que es el efecto del tratamiento para un subgrupo de profesionales con características específicas, consistiendo el análisis en calcular, para cada individuo, la ganancia o pérdida esperada de aplicar la intervención.

Análisis de distribución

Los resultados de *Uplift score* se visualizan en su distribución a través de un histograma para obtener una referencia visual de la concentración de resultados en ciertos rangos o si existe variabilidad significativa. Esto representa una ayuda para identificar la proporción de profesionales para los cuales la intervención es beneficiosa, nula, o incluso contraproducente.




Figura 3: Ejemplo de histograma con resultados de Uplift por profesional.

La gráfica de ejemplo muestra una concentración de resultados en torno a cero, lo que indicaría que el efecto de las intervenciones es mayoritariamente neutro. Concentraciones cercanas 1 darían cuenta que el efecto de la intervención es principalmente negativo, considerando que la búsqueda es la reducción de la probabilidad de renuncia, mientras que sería mayoritariamente positiva si se observase una mayor concentración cerca del -1 .

Identificación de segmentos

Desde los resultados de *Uplift*, los profesionales pueden clasificarse en cuatro categorías interpretativas:

- Persuasibles: Casos con *Uplift* positivo y significativo, siendo aquellos que probablemente cambien su comportamiento gracias a la intervención.
- *Sure Things*: Casos en que se obtendría un resultado positivo incluso sin intervención. La intervención no genera valor adicional, siendo representados por valores de *Uplift* positivos pero cercanos a cero.
- Neutros: El resultado no cambia con o sin la intervención, en términos de *Uplift* no aporta beneficio, con un *score* de cero.
- Detractores: Resultados negativos en *Uplift score*. La intervención Odría tener un efecto adverso, aumentando la probabilidad de resultados no deseados si son objeto de tratamiento.

6.6 Despliegue/Utilización del Conocimiento

La etapa final del *KDD* se enfoca en la implementación práctica del conocimiento descubierto.

1. Sistema de alerta temprana: Implementación de un sistema que utilice el modelo predictivo de fuga para identificar continuamente a los empleados en riesgo y generar alertas para Recursos Humanos y los tomadores de decisiones.
2. Personalización de intervenciones: Desarrollo de un marco para recomendar intervenciones de retención específicas basadas en los resultados del *Uplift Modeling* para cada empleado en riesgo, dirigiendo los recursos de manera estratégica y eficiente.
3. Monitoreo y reentrenamiento: Establecimiento de un proceso de monitoreo continuo del rendimiento de los modelos y planes para su reentrenamiento periódico con nuevos datos para asegurar su relevancia y precisión a lo largo del tiempo.

7. Marco Teórico

La comprensión profunda del problema de la fuga de talento y el desarrollo de soluciones analíticas avanzadas requieren de una sólida base teórica. Este capítulo establece el marco conceptual y contextual, construyéndose desde la definición de la fuga de talento y su evolución en la literatura, hacia el auge de *People Analytics*, los modelos predictivos de *Machine Learning* en la gestión de personas, y finalmente, la introducción del *Uplift Modeling* como una solución en la optimización de las intervenciones. Se analizarán las investigaciones previas, destacando cómo se ha abordado históricamente este desafío y cómo las innovaciones metodológicas han permitido avances significativos, conduciendo a la propuesta de solución de esta investigación.

7.1 La Fuga de Talento: Evolución conceptual, causas y consecuencias

El estudio de la fuga de talento, también conocida como rotación de personal o *employee turnover*, ha sido un pilar en la investigación de la gestión organizacional y el comportamiento humano en el trabajo durante décadas. Si bien el fenómeno no es nuevo, su conceptualización y la complejidad han evolucionado significativamente con el tiempo.

Los primeros modelos de rotación se centraron predominantemente en factores individuales y psicológicos. Mobley (1977) propuso un modelo que conceptualizaba la rotación como un proceso secuencial de decisión, iniciando con la insatisfacción laboral y culminando en la búsqueda de empleo y la intención de irse. Este modelo resaltaba la importancia de la satisfacción laboral como un predictor clave (Mobley et al., 1979). En esta época, la investigación se apoyaba en gran medida en encuestas, entrevistas y análisis de regresión logística o lineal para identificar correlaciones entre variables como el compromiso organizacional y la satisfacción, y la intención de renuncia. La resolución del problema práctico se basaba en la identificación de factores de descontento para implementar mejoras generales en las condiciones de trabajo.

La investigación amplió su alcance para incluir una nueva gama de factores organizacionales y contextuales. Hom y Griffeth (1991) integraron lazos con la organización y oportunidades de empleo externas en sus modelos, reconociendo que la decisión de irse no solo dependía de factores internos, sino también de la atractividad del mercado laboral. Se comenzó a hablar de la "guerra por el talento" (Michaels et al., 2001), enfatizando la creciente competencia entre empresas por la escasez de habilidades y personal calificado. Los análisis estadísticos multivariantes se volvieron más comunes para comprender la interacción de múltiples variables. Las soluciones prácticas implicaban la implementación de programas de desarrollo, mejora de la cultura organizacional y paquetes de compensación más competitivos. La comprensión de los costos asociados a la fuga de talento (reclutamiento, capacitación, pérdida de productividad) comenzó a ganar terreno como argumento de negocio (Abbasi & Hollman, 2000).

La proliferación de datos digitales dentro de las empresas y los avances en la capacidad computacional dieron origen a la disciplina de *People Analytics* (también conocida como *HR Analytics*, *Talent Analytics* o *Workforce Analytics*). Esta nueva aproximación transformó la forma de abordar el problema de la fuga de talento, pasando de análisis descriptivos y diagnósticos *post-mortem*, a la predicción y la prescripción. Las organizaciones comenzaron a entender que no sólo necesitaban saber cuántos empleados se iban, sino que ahora quiénes, por qué y cómo podían ser retenidos de manera efectiva.

Los costos asociados a la fuga de talento, que tradicionalmente se subestimaban, han sido cuantificados con mayor precisión en esta etapa, considerando que los costos directos, como reclutamiento, selección, *onboarding* y capacitación del reemplazo pueden oscilar entre el 50% y el 60% del salario anual de un empleado, mientras que al totalizar estos, considerando también los costos indirectos, este impacto puede alcanzar hasta un 200% del salario anual de un trabajador altamente calificado (SHRM, 2017). Dentro de este último tipo de costos, se encuentran la pérdida del capital humano y social, reducción de la productividad y calidad, tiempos muertos por retrasos en proyectos, deterioro de la moral del equipo, pérdida de conocimiento institucional y de redes de contactos. Estos últimos, aunque complejos de monetizar, pueden tener un impacto considerable a largo plazo (Dess & Shaw, 2001).

7.2 People Analytics y modelos predictivos de *Machine Learning* en la retención de talento

People Analytics (PA) es la aplicación de métodos estadísticos y analíticos a los datos de personas para comprender y mejorar los resultados de negocio relacionados con los trabajadores. Su objetivo es transformar la toma de decisiones en Recursos Humanos, desde una base intuitiva, a una basada en datos y evidencia (Larsson & Edwards, 2001). Dentro de *PA*, la predicción de la fuga de talento ha sido uno de los casos de uso más estudiados y de mayor relevancia.

A partir de la década de 2010, con la madurez de los algoritmos de *Machine Learning* y la disponibilidad de herramientas computacionales, se observa una explosión de investigaciones y aplicaciones prácticas para la predicción de la rotación. Es aquí, donde empresas tecnológicas como *Google* y *LinkedIn* fueron pioneras en la aplicación de modelos predictivos para identificar a empleados en riesgo. Utilizaban variables como el desempeño, la antigüedad, las compensaciones, el historial de promociones e incluso datos no estructurados de comunicaciones. Sus primeros modelos solían ser Regresión Logística o Árboles de Decisión, valorados por su interpretabilidad.

Paulatinamente, la investigación académica y la práctica empresarial comenzaron a explorar algoritmos más complejos y potentes. *Random Forest* se popularizó por su robustez, su capacidad para manejar interacciones no lineales y menor sensibilidad al sobreajuste, siendo utilizado en estudios que combinaban datos de desempeño, salario y datos demográficos para predecir la fuga.

En la última década, la adopción de técnicas de *Gradient Boosting* como *XGBoost* se ha vuelto estándar en la predicción de fuga de talento debido a su alta precisión y eficiencia computacional. Numerosos estudios han demostrado que estos modelos superan consistentemente a los algoritmos tradicionales en la identificación de patrones complejos de rotación en diversos contextos organizacionales.

Sin embargo, a pesar de la capacidad predictiva de estos modelos, un desafío persiste: saber quién se irá no es lo mismo que saber cómo evitar que se vaya. La predicción por sí sola no garantiza que una intervención será efectiva, ni que los recursos se asignen de manera óptima. Este es el punto donde la investigación tradicional de *Machine Learning* para la fuga de talento alcanza su techo, abriendo la ventana a modelos de inferencia causal.

7.3 Uplift Modeling como herramienta de inferencia causal

Mientras que los modelos predictivos convencionales estiman la probabilidad de un evento, como la probabilidad de fuga, no informan sobre la probabilidad de que un individuo cambie su comportamiento gracias a una intervención específica. Aquí es donde el *Uplift Modeling* emerge como una técnica fundamental. Su objetivo es estimar el efecto causal incremental de una intervención en el comportamiento de un individuo. En el contexto de la retención de talento, el *Uplift Modeling* busca identificar a los persuasibles, es decir, aquellos trabajadores que se quedarían en caso de recibir una intervención específica.

El *Uplift Modeling* tiene sus raíces en el estudio de efectos de tratamientos médicos y ha sido ampliamente adoptado en el *marketing* y la optimización de campañas de clientes, por ejemplo, en la banca, telecomunicaciones o *retail* para identificar clientes persuasibles a comprar un producto o a no darse de baja.

A inicios de milenio, Hansotia y Rukstales (2002) fueron pioneros en formalizar este enfoque en el ámbito del *marketing* relacional, desarrollando modelos que maximizan el valor esperado al identificar a los clientes que responden porque se les ofreció una promoción, y no simplemente quienes habrían respondido de todas formas. Más adelante, Rzepakowski y Jaroszewicz (2012) introdujeron algoritmos específicos de árboles de decisión para modelar *Uplift*, adaptando los criterios de división para reflejar diferencias entre grupos tratados y no tratados. Los experimentos realizados por Rzepakowski y Jaroszewicz mostraron que sus árboles de decisión para *Uplift* superan significativamente a los métodos tradicionales y a otros enfoques previos en la identificación de segmentos de población que responden de manera diferencial a una intervención. Esto permite a las organizaciones optimizar la asignación de recursos, focalizando sus acciones en los individuos donde el impacto es realmente incremental.

A nivel de *Machine Learning*, Guelman, Guillén y Pérez-Marín (2015) desarrollaron los *Uplift Random Forests*, mejorando la capacidad predictiva en escenarios con múltiples variables y efectos heterogéneos.

La aplicación del *Uplift Modeling* en *People Analytics* es un campo relativamente más reciente. Mientras que la literatura de *ML* en RRHH se ha centrado en la predicción, la necesidad de optimizar las inversiones en retención ha impulsado la exploración de causalidad.

7.4 Investigaciones recientes

Estudios recientes han contribuido a la investigación de la multiplicidad de factores que pueden impulsar la decisión de un profesional de abandonar su organización, encontrándose entre estos el equilibrio entre vida laboral y personal: Investigaciones post-pandemia muestran que la flexibilidad, la modalidad de trabajo (presencial, híbrido o remoto), y el apoyo a la salud mental son determinantes en la decisión de fuga, de acuerdo a investigaciones de Microsoft (2021) sobre tendencias laborales. Otras investigaciones han revelado que un factor relevante en la decisión de renuncia es la cultura organizacional y liderazgo: Un entorno laboral negativo, donde gobierne la percepción de injusticia y equidad, una comunicación deficiente y un liderazgo ineficaz son detectados como razones clave para la renuncia de trabajadores (Harter et al., 2020). Además de esto, aparecen la necesidad de conexión y búsqueda de un propósito, especialmente en la fuerza laboral más joven, la búsqueda de un propósito en el trabajo y la alineación con los valores de la empresa juegan un papel importante. Una desconexión con la misión de la organización puede acelerar la búsqueda de nuevas oportunidades (Grant, 2017).

Respecto a las investigaciones y aplicaciones de soluciones de *Uplift Modeling* más recientes, destacan los trabajos de Gutierrez y Gérardy (2017), quienes presentaron una revisión exhaustiva de los enfoques de meta-aprendizaje como los *T-Learners* y *X-Learners*, integrando el marco del *Conditional Average Treatment Effect* dentro de técnicas de aprendizaje automático supervisado. Estos avances han permitido expandir el uso del *Uplift Modeling* más allá del marketing, aplicándolo hoy en áreas como la retención de talento, salud personalizada y prevención del abandono escolar. Ejemplo de esto es la aplicación de esta herramienta en investigaciones de retención estudiantil, destacando cómo el *Uplift* permite estimar el efecto incremental de una intervención individual, diferenciándose de los modelos predictivos tradicionales al identificar a aquellos estudiantes que son más propensos a responder de manera positiva ante una intervención (Olaya et al., 2020).

En los últimos años, el *Uplift Modeling* ha avanzado significativamente. Nyberg y Klami (2023) mostraron cómo corrigiendo el desequilibrio de clases mejora notablemente el desempeño de modelos de *Uplift Random Forests*. Por su parte, Ibragimov y Vakhrushev (2024) adaptaron algoritmos de *Gradient Boosting* para estimar efectos causales en aplicaciones de *Uplift*.

8 Desarrollo

8.1 Selección de datos

Para esta investigación se obtienen datos de diferentes subsistemas de Recursos Humanos. Las bases de origen utilizadas para dar origen *dataset* final se describen a continuación:

- **Dotación histórica:** Base de datos que contiene a todos los trabajadores que han formado parte de la empresa entre enero 2022 y diciembre 2024. Contiene registros únicos de 5.636 trabajadores con 14 variables: Mes (último mes-año en que el trabajador estuvo vigente antes de salir de la empresa. En el caso de trabajadores que continúan estando vigentes, se define como valor diciembre 2024), Rut, ID, Renuncia (binaria que indica si el trabajador renunció), Egreso (binaria que indica si el trabajador salió de la empresa por motivos diferentes a renuncia), Nombre, Apellido Paterno, Apellido Materno, Edad, Antigüedad, Gerencia, Puesto, Estamento, Subgerencia, Sindicato, Hijos.
- **Evaluaciones de Desempeño:** Base de datos con las evaluaciones de desempeño de todos los trabajadores desde 2021 a 2024, un registro por trabajador por año. La base cuenta con 14.987 registros con las variables Rut, Año de evaluación, Nota.
- **Ausentismos:** Base de datos que contiene las ausencias producidas por vacaciones y licencias médicas por enfermedad común y accidente. Esta base presenta un tratamiento previo que registra de manera mensual la cantidad de días de ausencia durante los últimos 12 meses, por trabajador. De esta manera, esta base contiene los registros desde enero 2021 hasta diciembre 2024, para cada trabajador en cada uno de esos meses, de su comportamiento de ausentismo durante los últimos 12 meses. Son 31.657 registros con las variables Año, Mes, Rut, Días de Licencia, Días de Vacaciones, Saldos de Vacaciones.
- **Compensaciones:** Base de datos con el registro de los trabajadores que han recibido incrementos de renta durante un mes en particular. Contiene todos los incrementos de renta desde el año 2.000. Contiene 24.268 registros no únicos, con las variables ID, Rut, Fecha del evento, Puesto, Porcentaje de incremento, Retenciones de renta (desde 2022).

La tabla 1 muestra el resumen de las variables de la base de datos final.

Variable	Descripción	% nulos	Promedio	Desviación estándar	Mínimo	Máximo
Mes	Último mes de vigencia de por trabajador	0%	-	-	-	-
ID	Identificador del trabajador	0%	-	-	-	-
Edad	Años de vida del trabajador	0%	42,9	11,1	19,07	80,1
Antigüedad	Años de antigüedad del trabajador en la empresa	0%	11,1	10,3	0,0	52,9
Gerencia	Gerencia a la que pertenece el trabajador en 'Mes'	0%	-	-	-	-
Puesto	Cargo al que pertenece el trabajador en 'Mes'	0%	-	-	-	-
Estamento	Estamento al que pertenece el trabajador en 'Mes'	0%	-	-	-	-
Subgerencia	Subgerencia a la que pertenece el trabajador en 'Mes'	0%	-	-	-	-
Dias_vac_ult_12m	Cantidad de días de vacaciones utilizados por el trabajador en los últimos 12 meses, desde 'Mes'	0%				

Variable	Descripción	% nulos	Promedio	Desviación estándar	Mínimo	Máximo
Evaluación de Desempeño	Nota de última evaluación de desempeño	1%	105,1	6.0	50	125
Incremento_u lt_3_años	Porcentaje de incremento de renta acumulado en últimos 3 años. No considera IPC.	0%	7,8%	21%	0%	404%
Hijos	Variable binaria que refleja si un trabajador tiene hijos	0%	0,45	0,49	0	1
Saldo vacaciones	Cantidad de días de vacaciones que cada trabajador tiene en su banco en 'Mes'	0%	20,6	17,1	-10,2	142,5
Sindicato	Sindicato al que pertenece cada trabajador en 'Mes'	0%	-	-	-	-
Renuncia	Variable binaria que indica la renuncia (1) o vigencia (0) de un trabajador	0%	0,06	0.24	0	1
Retención	Variable binaria que indica si un trabajador fue intervenido con una acción de retención	0%	0,02	0,16	0	1

Tabla 1: Base de datos final

8.2 Pre-procesamiento de datos

Posterior a la selección y recolección de datos, se procede al preparamiento previo a la etapa de minería. Para esto, se trata la información de las variables con valores nulos. Para el caso de la variable “Evaluación de Desempeño”, única con valores faltantes, se corrigen estos nulos con la mediana, dado que es una variable numérica. De esta manera, se presenta una solución a los valores faltantes, con una medida robusta frente a valores extremos (*outliers*).

A continuación, se eliminan de la base de datos las variables que no entregarán aporte al modelado de técnicas de *Machine learning*, como aquellas identificadoras de cada trabajador. De esta manera, se prescinde de las columnas Mes y ID.

Dado que la investigación se centra en la decisión de renuncia de los trabajadores, es que se eliminan de la base a analizar a trabajadores que hayan egresado de la empresa por motivos diferentes a una renuncia, como desvinculaciones. De este modo se modela con los trabajadores vigentes, y con aquellos que hayan renunciado, sin considerar a quienes fueron desvinculados.

Además, dado que las tasas de egresos son mayores en cargos profesionales y jefaturas, es que se prescinde de los trabajadores con estamentos distintos a estos, modelándose posteriormente únicamente con trabajadores que para la fecha de referencia (columna Mes), hayan formado, o formen parte para el caso de los vigentes, de los estamentos Profesionales o Jefes. Esto no sólo tiene argumento en enfocar los esfuerzos en los puestos donde la fuga de talento es una problemática mayormente presente, sino que también funciona como estrategia para entregar una primera solución, estructural, al problema de desbalanceo de clases. En el *dataset* completo, la proporción de renuncias sobre el total es de únicamente un 6%, mientras que al definir el foco en Profesionales y Jefes, la proporción de renuncias sobre el total alcanza un 13%. Esto es un empuje esencial para la factibilidad del entrenamiento de los modelos, los que con una proporción de renuncias tan baja como la original, y aun utilizando técnicas de balanceo como SMOTE, no son capaces de encontrar los patrones para luego predecir. Con esto, se obtiene una base final de 1.056 observaciones.

Habiendo definido estos alcances para la base de datos, continúa el *Exploratory Data Analysis (EDA)* como base metodológica previa al proceso de *feature engineering*, y herramienta de entendimiento del comportamiento de las variables.

Análisis exploratorio de datos

Primero, se procede al análisis exploratorio de datos de las variables numéricas, graficando su distribución respecto a la variable dependiente Renuncias:

1. Edad: Se observan diferencias en edad entre quienes renuncian y quienes no, aquellos que abandonaron la empresa tienden a ser más jóvenes que aquellos que continúan vigentes en la dotación. Las personas dentro de la base de datos que han renunciado tienen una mediana cercana a los 35 años, mientras que aquellos que se han mantenido en la organización sitúan su mediana cerca de los 40 años.

Para el caso de quienes renunciaron, el 25% de los trabajadores tienen un mínimo de 40 años. Se observa también que el profesional de mayor edad habiendo renunciado, no supera los 60 años, a diferencia de la agrupación que se mantiene en la dotación, que alcanza valores máximos por encima de los 75.




Gráfico 1: Distribución de Edad por Renuncia o No Renuncia

2. Antigüedad: Se observa que las personas que renuncian tienden a tener menor antigüedad que aquellos que no, de manera similar a como ocurre con edad. Existe una menor dispersión de años de antigüedad en el caso de renuncia, distribuyéndose principalmente entre valores cercanos a 0 y los 10 años.

Se observa una acumulación de *outliers* en el caso de quienes no han renunciado, hacia valores altos de años de antigüedad, arrastrando así la media por encima de la mediana. Siendo la media de antigüedad 11 años, la mediana se sitúa cerca de los 7 años de antigüedad en la empresa. No existen profesionales del grupo renunciante que sobrepasen los 30 años de permanencia en la organización.




Gráfico 2: Distribución de Antigüedad por Renuncia o No Renuncia

3. Nota_Desempeño: La distribución de los resultados de las evaluaciones de desempeño entre las agrupaciones de la variable a predecir, se observa que quienes han renunciado presentan una menor dispersión en sus resultados, pero con mayor presencia de valores extremos. El 25% de los valores del grupo renunciante presenta valores que oscilan entre el 107 y el 111, sin embargo, para quienes no han renunciado, el 25% de las evaluaciones de desempeño están agrupadas entre el 109 y el 118. Ambas agrupaciones presentan notas sobre 120 (el máximo es 125).

El valor mínimo es 50 para quienes no han renunciado, mientras que el valor mínimo es 80 para quienes sí renunciaron.




Gráfico 3: Distribución de Nota Desempeño por Renuncia o No Renuncia

4. Incrementos últimos 3 años: Se observa preliminarmente una tendencia hacia menores porcentajes de incremento durante los últimos 3 años para el grupo que ha renunciado. El mayor valor de incremento está sobre el 400% para quienes se mantienen en la dotación de la empresa, mientras que para quienes renunciaron, el mayor incremento acumulado de los últimos 3 años alcanza el 280%. La distribución muestra también que existe una mayor acumulación en valores cercanos a 0%.




Gráfico 4: Distribución de Incremento por Renuncia o No Renuncia

- 4. Saldos de Vacaciones:** En términos de medianas, el grupo que renuncia presenta una leve mayor acumulación de saldos de vacaciones que el grupo vigente, con el 50% de sus observaciones bordeando los 20 días de saldo. Ninguna de las personas que renunció dejó la organización con saldo negativo, a diferencia del grupo vigente donde si se observan valores de saldo menores a cero. El profesional que renunció a la organización con mayor acumulación de días lo hizo con 60 días de saldo, a diferencia de la mayor acumulación de quienes se mantienen en la organización, donde el saldo máximo sobrepasa los 140 días de vacaciones. Se observa una cantidad relevante de casos sobre los 60 días de saldo para el caso de trabajadores vigentes.




Gráfico 5: Distribución de Saldo Vacaciones por Renuncia o No Renuncia

6. Puesto: Esta variable cuenta con 365 valores diferentes. Se cuenta además con 28 puestos distintos con un 100% de renunciaciones, los que representan a 36 trabajadores, 21 puestos con un porcentaje de renunciaciones entre el 33% y 57%, sobre un total de 82 trabajadores, 26 puestos con porcentaje de renunciaciones entre 6% y 25%, sobre un total de 379 trabajadores, y finalmente 290 puestos con 0% de renunciaciones, sobre un total de 559 trabajadores.

% de Renuncias	Q Puestos	Q trabajadores
100%	28	36
33% - 57%	21	82
6% - 25%	26	379
0%	290	559

Tabla 2: Observaciones y Tasa renunciaciones de Puesto

7. Subgerencia: Esta variable categórica cuenta con 64 valores diferentes. Realizando el mismo ejercicio que con Puesto, se obtiene lo siguiente de la concentración de renunciaciones:

% de Renunciaciones	Q Subgerencias	Q trabajadores
100%	15	37
10% - 45%	14	471
3% - 9%	12	252
0%	23	296

Tabla 3: Observaciones y Tasa renunciaciones de Subgerencia

Se observa que la mayor concentración está en la agrupación de 14 subgerencias con una tasa de renuncia que se encuentra en el rango entre 10% a 45%, la cual reúne a 571 profesionales. Existen otras 15 subgerencias, que representan sólo a 37 profesionales, las cuales presentan un 100% de tasa de renuncia, esta es la agrupación de menor volumen. Estos equipos, al presentar un menor volumen de trabajadores, reciben un mayor impacto en términos de tasa ante la renuncia de sus trabajadores. Un total de 23 subgerencias, representando a 296 profesionales, no presentan registros de renuncia en sus equipos.

8. Gerencia: Esta variable cuenta con 24 valores distintos, relativos a las diferentes Gerencias de los trabajadores de la muestra. Cuatro Gerencias presentan tasas de renuncia sobre el 50%, representando sólo a 20 observaciones totales (Tabla 4).

9. Estamento: Dado el foco en estamentos Profesionales y Jefes, la concentración de renunciaciones se observa únicamente en estas dos agrupaciones estamentales. Para el caso de Jefes, la proporción de renunciaciones alcanza el 12,5%, representando un total de 279 trabajadores; mientras que para el caso de los Profesionales la proporción de renunciaciones es de 13,8%, sobre un total de 777 observaciones.

Estas tasas se interpretan desde el porcentaje de fuga, por motivos de renuncia, sobre la dotación promedio de cada uno de estos estamentos. De esta manera, cerca de un 13% de las personas que han conformado a estas agrupaciones durante el último año, han abandonado la organización. Representan el foco de la gestión de retención del talento en la empresa.




Gráfico 6: Proporción de renuncias por Estamento

10. Sindicato: Se observa que las categorías Cuota Sindicato 1 y Cuota Sindicato 2 tienen un 100% de renuncias, esto se explica desde la baja cantidad de observaciones en estos sindicatos, debido a etiquetas que se definieron durante un mes particular para específicamente referirse a quienes egresaron de la empresa en ese momento. Esto será luego tratado en la etapa de *feature engineering*.




Gráfico 7: Proporción de renuncias por Sindicato

Para finalizar la etapa exploratoria de datos, se realiza un análisis de multicolinealidad entre las variables, a través de un mapa de calor de correlaciones (Gráfico 8) a modo de comprender las relaciones de las variables independientes entre ellas y con la dependiente (renuncia). De esto se desprende que las variables Edad, Antigüedad, y Saldo de Vacaciones están fuertemente correlacionadas, sin embargo, como los modelos a ser entrenados son ensambles y árboles, no es necesario entrar en ingeniería de atributos con estas variables.

8.3 Transformación de datos (*feature engineering*)

Debido a la presencia de variables categóricas con diferentes niveles de cardinalidad, se procede a aplicar estrategias de ingeniería de atributos distintas para cada caso. El proceso principal que se realizó a estas variables fue una reducción de la cardinalidad mediante diferentes técnicas, considerando que esto es un ejercicio que permite mejorar el rendimiento de los modelos con técnicas posteriores como *one-hot encoding*.

Las variables categóricas relevantes para la transformación son Gerencia, Sindicato, Puesto, Estamento, Subgerencia.

- **Reducción de la cardinalidad mediante agrupación semántica:** Las variables Gerencia y Sindicato presentan una cardinalidad relativamente baja, con múltiples categorías que, si bien informativas, podían agruparse para simplificar el modelo y consolidar la información. El proceso considera el diseño y aplicación de categorizaciones fijas de grupos más amplios. Estas transformaciones se realizan sobre el *dataset* original.
 - Gerencia: Se agrupan las diferentes categorías de esta variable en torno a las unidades de negocio y conocimiento experto del funcionamiento organizacional. Las 20 diferentes Gerencias se agrupan en las categorías *Staff* (430 observaciones), Operaciones y Mantenimiento (305 observaciones), Proyectos e Ingeniería (270 observaciones), Negocios (51 observaciones).
 - Sindicato: Se agrupan las diferentes categorías en 3 grandes clasificaciones de sindicatos. Esta clasificación se define desde el conocimiento experto del contexto organizacional, normalizándose criterios de nombre de los sindicatos, y asignando una categoría Otros para agrupaciones de baja cardinalidad. Con esto, se generan las categorías S_2 (617 observaciones), S_Metro (378 observaciones), Otros (61 observaciones).
- **Reducción de la cardinalidad basada en Tasa de Renuncia:** Las variables originales Puesto y Subgerencia presentan la mayor cardinalidad entre las variables categóricas, con 365 y 63 valores diferentes, respectivamente.

Este escenario, presenta un desafío mayor en la implementación de técnicas posteriores como *one-hot encoding*, debido al crítico aumento en la dimensionalidad que traería consigo la creación de esas cantidades de nuevas columnas, aumentando el riesgo de sobreajuste. Dado este escenario, se desarrolló una agrupación con base en la tasa de renuncia de los diferentes puestos y subgerencias, con rangos y categorizaciones preddefinidas. De esta manera, Se clasifican los puestos y subgerencias en 6 categorías cada una, dependiendo de su comportamiento histórico en la proporción de trabajadores de cada

categoría que ha renunciado. Las nuevas categorías son “TR 0%”, “TR Muy baja”, “TR baja”, “TR media”, “TR Alta”, “TR Muy alta”. Finalmente, con este ejercicio se reduce fuertemente la cardinalidad, convirtiendo cientos de categorías en un número reducido y manejable para técnicas posteriores. A diferencia de las variables Gerencia y Sindicato, cuya transformación se basa en agrupaciones fijas y sobre el *dataset* completo, el trabajo de ingeniería de atributos para las variables Puesto y Subgerencia exigen una aproximación diferente. Dada la alta cardinalidad y naturaleza de la agrupación de estas, utilizando la variable a predecir como herramienta de agrupación, la incorporación de esto de manera directa a la base trae consigo riesgo de *data leakage*. Para mitigar esto, la transformación de estos atributos se realiza sobre cada *fold* resultante del proceso de validación cruzada y únicamente en el *set* de entrenamiento.

Con aquella definición, se realiza la división en 5 *folds* para iniciar la validación cruzada. Con esto, se realiza SMOTE para balancear las clases de la variable renuncia, debido a su presencia de únicamente un 13% sobre el total de la muestra. Una vez agrupadas las variables categóricas, se aplica esta técnica de codificación para convertir cada una de las categorías de estas variables agrupadas en una binaria, además de la variable Estamento. Con esto, la dimensionalidad se mantiene dentro de márgenes estables, aumentando el dataset de 18 a 31 columnas, eliminándose las variables originales para evitar duplicación. Dada la utilización posterior de *Uplift Modeling*, la creación de nuevas columnas se mantuvo en un volumen constante para que los modelos de tratamiento y control recibieran un número idéntico de características. Se forzó a que el *one hot encoder* generara siempre el mismo número fijo de columnas, independiente de la presencia o ausencia de las categorías en un *subset* específico.

8.4 Minería de datos

8.4.1 Modelado Predictivo

Entrenamiento y testeo

Para el proceso de entrenamiento y testeo de minería de datos, se aplicaron modelos de *Machine Learning* para la detección de patrones y construcción de modelos predictivos como línea base, además del desarrollo de *Uplift Modeling* para la inferencia causal.

Construcción de modelo predictivo

Para el entrenamiento de los modelos, se aplicó una estrategia de validación cruzada, dividiendo el *dataset* en 5 *folds*, entrenando los modelos en un subconjunto de estos, de esta manera se evita el sobreajuste. Las variables cuya cardinalidad fue reducida con base en las agrupaciones por tasa de renuncia, fueron transformadas en cada uno de los subconjuntos de entrenamiento de cada *fold*, para evitar *data leakage*.

Resultados

Las métricas seleccionadas para estimar el rendimiento de los modelos fueron los promedios de *F-1 score*, *AUC*, *Precision* y *Recall*, de los modelos *LightGBM*, *Gradient Boosting*, *XGBoost*, *Random Forest*, *CatBoost*, *Logistic Regression* y *Decision Tree*, de los distintos *folds* de la validación cruzada.

A continuación, se muestran los resultados de los promedios de las métricas para cada modelo.

Modelo	<i>F-1 score</i>	<i>AUC</i>	<i>Precision</i>	<i>Recall</i>
<i>LightGBM</i>	0.476	0.771	0.422	0.547
<i>Gradient Boosting</i>	0.474	0.772	0.412	0.562
<i>XGBoost</i>	0.472	0.796	0.412	0.554
<i>Random Forest</i>	0.458	0.762	0.379	0.583
<i>CatBoost</i>	0.450	0.785	0.368	0.583
<i>Logistic Regression</i>	0.381	0.755	0.284	0.583
<i>Decision Tree</i>	0.366	0.693	0.252	0.669

Tabla 5: Resultados de modelos de Machine Learning

Se observa que el modelo con mejor *F-1 score* y *Precision* es *LightGBM*, mientras que aquel con mayor *AUC* es *XGBoost*. De manera general, se observa que los modelos basados en técnicas de gradientes tienen un rendimiento superior al resto de modelos.

Adicionalmente se muestran de manera gráfica los resultados de los promedios de *AUC* de los *folds* para los distintos modelos. Se observa también los resultados de cada *fold*, los que en su conjunto conducen al promedio de *AUC* de cada modelo.




Gráfico 9: Curvas ROC por Modelo (Validación Cruzada)

Importancia de las variables

A continuación, se presenta la importancia de las variables de los modelos entrenados con mejor rendimiento.

LightGBM




Gráfico 10: Importancia de Variables, LightGBM

Gradient Boosting




Gráfico 11: Importancia de Variables, Gradient Boosting

XGBoost




Gráfico 12: Importancia de Variables, XGBoost

Random Forest




Gráfico 13: Importancia de Variables, Random Forest

CatBoost




Gráfico 14: Importancia de Variables, CatBoost

Se observa, desde las gráficas de importancia de variables, que *LightGBM* atribuye la mayor ganancia a variables como Antigüedad, Edad, Nota de desempeño y Saldo de vacaciones. El resto de los modelos con mejor rendimiento, muestran una amplia importancia a 'Puesto_TR 0%'.

A la luz de los resultados de rendimiento de cada modelo en las distintas métricas de desempeño y los resultados de la importancia de las variables, se selecciona a *LightGBM* como el modelo que ofrece el equilibrio óptimo. Esto se fundamenta en su liderazgo en *F1-score*, la cual es una métrica crucial en la búsqueda de un equilibrio entre *Precision* (evitar intervenciones innecesarias) y *Recall* (identificar la mayor cantidad de renunciante reales), encontrando el mejor balance entre falsos positivos y falsos negativos en un problema de clasificación con clases desbalanceadas. Además de esto, *LightGBM* presenta una mejor explicabilidad en la importancia de sus variables, entregando una perspectiva de atributos asociados a los trabajadores por sobre una relevancia a variables estructurales de la organización.

Habiendo seleccionado el modelo de *Machine Learning* óptimo, se procede al enfoque causal de *Uplift Modeling*.

8.4.2 Modelado causal con *Uplift Modeling*

A través de la estimación del *CATE*, se obtiene la diferencia en la probabilidad de renuncia entre sujetos que recibieron el tratamiento y aquellos que no.

A través de la implementación de *T-Learner* se entrenan dos modelos predictivos con *LightGBM*, de manera independiente, uno sobre el grupo de trabajadores que recibieron una retención y otro sobre el grupo de control, trabajadores que no recibieron el tratamiento. Las predicciones de ambos modelos se combinan para estimar el *Uplift*.

El *dataset* original de 1.056 registros se divide en un grupo de tratamiento con 28 trabajadores que recibieron acciones de retención y otro con 1.028 trabajadores que no. Se realizaron las mismas técnicas de *feature engineering* y balanceo de clases utilizadas para el entrenamiento de los modelos predictivos, en cada *subset* de datos.

Resultados

El análisis descriptivo de los *Uplift scores* muestra lo siguiente:

Métrica	Valor
Media	0.312516
Desviación estándar	0.581218
Mínimo	-0.999962
Máximo	0.999964
Mediana	0.000034

Tabla 6: Resultados de *Uplift Modeling*

Desde estos valores se observa una gran variabilidad en la respuesta a la intervención. El valor positivo de la media muestra que, en promedio, la acción de retención no está logrando reducir la probabilidad de renuncia de manera generalizada. La mediana cercana a cero refuerza el concepto de que para la mayoría de los trabajadores el efecto de la retención es mínimo. Además, la amplitud de rango entre el valor mínimo y el máximo, junto a la desviación estándar, dan cuenta de la existencia de individuos con gran diferenciación de respuestas al tratamiento.

Para comprender la distribución de los *Uplift scores*, se grafica el histograma con la probabilidad de todos los individuos.




Gráfico 15: Distribución de Uplift scores

Se observa a la luz del histograma una distribución multimodal, reforzando la amplia heterogeneidad en la respuesta de los trabajadores a la intervención de retención. Las concentraciones de resultados de *Uplift* se agrupan en tres principales clasificaciones:

Persuasibles: Moda alrededor de -1.0. Esta agrupación representa a los individuos para quienes la intervención se presenta como altamente efectiva en reducir su probabilidad de renuncia. Se identificaron 74 trabajadores en este segmento. Estos individuos muestran un alto valor estratégico en la toma de decisiones debido a que muestran una alta probabilidad de cambiar su decisión de renuncia si reciben la retención, permitiendo diseñar intervenciones dirigidas y eficientes. Se consideran para esta agrupación a todos aquellos con *Uplift score* < -0.05

Neutros: Moda alrededor de 0.0. Para estos trabajadores la intervención de retención tiene un efecto mínimo o nulo en su probabilidad de renuncia. Este segmento contiene a 584 individuos, para quienes la intervención no produce un efecto significativo. Se consideran para esta agrupación a todos aquellos con $-0.05 \leq \text{Uplift score} \leq 0.05$.

Detractores/Sure things: Moda alrededor de 1.0. Trabajadores que muestran una respuesta negativa ante la intervención, o al menos ineficaz. Esta categoría comprende a 398 sujetos, para quienes la retención no se recomienda. Se consideran para esta agrupación a todos aquellos con *Uplift score* > 0.05.

9. Conclusiones

El presente estudio abordó el desafío crítico de la retención de talento en la organización mediante la aplicación de la metodología *Knowledge Discovery in Databases (KDD)*, un marco que permitió transformar eficientemente los datos brutos de recursos humanos en conocimiento accionable. Esta aproximación sistemática, desde la preparación de los datos, incluyendo la exclusión de variables irrelevantes como “Mes Dotación” e “ID Sap” y la aplicación de ingeniería de características, aseguró la calidad de la información para el modelado, validando la eficacia del *KDD* en la analítica de personas. Durante este proceso, se identificaron factores predictivos cruciales en la renuncia de empleados, revelados por el análisis de importancia de variables en los modelos, destacándose la antigüedad, la edad, la nota de desempeño y el incremento salarial en los últimos tres años. Particularmente notable fue la prominente relevancia de la variable *Puesto_TR 0%*, la cual emergió como un predictor extremadamente fuerte de la no renuncia en la mayoría de los modelos de *boosting*. Sin embargo, en *LightGBM*, la jerarquía de importancia se mostró ligeramente diferente, priorizando otras variables continuas como la antigüedad y la edad para alcanzar su rendimiento óptimo, una observación que subraya cómo las particularidades de cada modelo influyen en la interpretación de la importancia de las variables.

La evaluación comparativa de diversos algoritmos de *Machine Learning* confirmó de manera contundente la superioridad de los modelos basados en la técnica de *Gradient Boosting* para el problema de clasificación de renuncia, caracterizado por un significativo desbalance de clases. Estos modelos, incluyendo *LightGBM*, *XGBoost*, *Gradient Boosting* y *CatBoost*, ocuparon consistentemente los primeros puestos en métricas cruciales como el *F1-score* y el *AUC*, superando a otros enfoques como *Random Forest*, la Regresión Logística y los Árboles de Decisión.

Producto de su rendimiento en esta investigación, *LightGBM* fue seleccionado como el clasificador óptimo para el desarrollo del *Uplift Modeling* y la construcción de la estrategia de intervención. Esta decisión se fundamentó principalmente en su liderazgo en *F1-score* medio (0.476305), que representa el equilibrio más deseable entre *Precision* (0.422967) y *Recall* (0.547354) en un problema de clasificación desbalanceada. Además de su rendimiento, la explicabilidad que proporcionan las importancias de variables en *LightGBM*, derivadas de la ganancia de información, facilita la comprensión de los factores que impulsan la renuncia, lo que permite a la organización diseñar estrategias de intervención más informadas y efectivas.

Finalmente, el desarrollo del *Uplift Modeling* reveló una heterogeneidad fundamental en la respuesta de los empleados a la intervención de retención. La distribución multimodal de los *Uplift Scores*, con concentraciones alrededor de -1.0, 0.0 y 1.0, demostró la existencia de “Persuasibles”, “Neutros” y “Detractores/Sure Things”. Esta segmentación es un pilar para una estrategia de retención eficiente, ya que permite dirigir recursos exclusivamente a los 74 individuos clasificados como “Persuasibles”, evitando gastos innecesarios en los “Neutros” y los “Detractores/Sure Things”. No obstante, es imperativo reconocer una

limitación crítica del estudio: la baja cantidad de sujetos en el grupo de tratamiento (N=28). Esta escasez de datos en el grupo intervenido es un factor altamente probable de haber contribuido a la inestabilidad en la estimación de las probabilidades de tratamiento y a la aparición de *uplift scores* contraintuitivos, lo que subraya la necesidad de recopilar más datos bajo condiciones experimentales controladas para futuras investigaciones que busquen validar y refinar las estimaciones de causalidad.

10. Trabajos futuros

La obtención de resultados de esta AFE abre líneas de futuros trabajos que pueden fortalecer las aplicaciones de los modelos propuestos.

Desde una perspectiva metodológica, la aplicación de pruebas controladas como testeos A/B con un mayor número de profesionales siendo sujetos de tratamiento, pudiese traer consigo una mayor interpretabilidad del impacto de las medidas de retención, junto con una mejor observación de su relación con la decisión de renuncias de las personas. Esto requiere del entendimiento organizacional del potencial de este tipo de investigaciones, y la movilización de decisiones de gestión de talento, diseñadas desde una cultura que promueva la toma de decisiones con evidencia.

Junto con esto, y con el objetivo de implementar estas soluciones en un contexto real de la empresa de transporte en estudio, es que pueden potenciarse los resultados desde la inclusión de nuevas variables que la revisión bibliográfica arroja como potenciales predictores de las renuncias: Distancia desde el hogar hasta la oficina, resultados de encuestas de clima e intención de permanencia o satisfacción laboral, salario recibido, niveles de renta, utilización de beneficios, años en el mismo puesto, o historial de promociones. Todas estas variables se asoman como potenciales predictores, sin embargo, no estuvieron disponibles para este trabajo. Es crucial que los entornos de Recursos Humanos potencien el avance de una cultura *data-driven* para gobernar el registro de esta información y permitir el desarrollo de aplicaciones de *People Analytics* en todo su potencial.

Finalmente, se recomienda la integración de este enfoque en la reportabilidad continua de esta organización. Esto permitiría el seguimiento constante de los riesgos de renuncia y la identificación de los segmentos persuasibles. De esta manera, podrían simularse escenarios de intervención como aumentos salariales, programas de desarrollo, medidas de flexibilidad laboral, retroalimentando los modelos con los resultados de dichas acciones, en un ciclo de mejora continua.

Bibliografía

- Abbasi, S. M., & Hollman, K. W. (2000). Turnover: The real bottom line. *Public Personnel Management*, 29(3), 333–342. <https://doi.org/10.1177/009102600002900303>
- Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (1984). *Classification and Regression Trees*. Wadsworth
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. <https://doi.org/10.1145/2939672.2939785>
- Dess, G. G., & Shaw, J. D. (2001). Voluntary turnover, social capital, and organizational performance. *Academy of Management Review*, 26(3), 446–456. <https://doi.org/10.5465/amr.2001.4845830>
- Facure, M. (2018). 21 - *Meta Learners. Causal Inference for the Brave and True*. Recuperado de <https://matheusfacure.github.io/python-causality-handbook/21-Meta-Learners.html>
- Fayyad, U. M., Piatetsky-Shapiro, G., & Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI Magazine*, 17(3), 37–54. <https://doi.org/10.1609/aimag.v17i3.1230>
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232. <https://doi.org/10.1214/aos/1013203451>
- Grant, A. (2017). *Originals: How non-conformists move the world*. Penguin Books.
- Guelman, L., Guillén, M., & Pérez-Marín, A. M. (2015). Uplift random forests. *Cybernetics and Systems*, 46(3–4), 230–248. <https://doi.org/10.1080/01969722.2015.1012892>
- Gutierrez, P., & Gérardy, J.-Y. (2017). Causal inference and uplift modelling: A review of the literature. In *Proceedings of the 3rd International Conference on Predictive Applications and APIs* (Vol. 67, pp. 1–13). PMLR. <https://proceedings.mlr.press/v67/gutierrez17a.html>
- Hansotia, B., & Rukstales, B. (2002). Incremental value modeling. *Journal of Interactive Marketing*, 16(3), 35–46. <https://doi.org/10.1002/dir.10035>
- Harter, J., Schmidt, F., Agrawal, S., & Plowman, S. (2020). The relationship between engagement at work and organizational outcomes. *Gallup*.
- Hom, P. W., & Griffeth, R. W. (1991). *Employee turnover*. South-Western Publishing.
- Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression* (3rd ed.). Wiley.

- Ibragimov, B., & Vakhrushev, A. (2024). *Uplift modelling via gradient boosting*. *Proceedings of the ACM on programming languages*, 35, 1177–1187. <https://doi.org/10.1145/3637528.3672019>
- Kasdorf, R. L., & Kayaalp, A. (2022). Employee career development and turnover: a moderated mediation model. *International Journal of Organizational Analysis*, 30(2), 324–339. <https://doi.org/10.1108/IJOA-09-2020-2416>
- Ke, G., Meng, Q., Finley, T., et al. (2017). LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, 30.
- Künzel, S. R., Sekhon, J. S., Bickel, P. J., & Yu, B. (2019). *Metalearners for estimating heterogeneous treatment effects using machine learning*. *Proceedings of the National Academy of Sciences*, 116(10), 4156–4165. <https://doi.org/10.1073/pnas.1804597116>
- Larsson, A.-S., & Edwards, M. (2021). Insider econometrics meets people analytics and strategic human resource management. *The International Journal of Human Resource Management*, 33(12), 2373–2419. <https://doi.org/10.1080/09585192.2020.1847166>
- Michaels, E., Handfield-Jones, H., & Axelrod, B. (2001). *The War for Talent*. *Harvard Business Press*.
- Microsoft. (2021). The Next Great Disruption Is Hybrid Work—Are We Ready? *Work Trend Index Annual Report*. <https://www.microsoft.com/en-us/worklab/work-trend-index/hybrid-work>
- Mobley, W. H. (1977). Intermediate linkages in the relationship between job satisfaction and employee turnover. *Journal of Applied Psychology*, 62(2), 237–240. <https://doi.org/10.1037/0021-9010.62.2.237>
- Mobley, W. H., Horner, S. O., & Hollingsworth, A. T. (1979). An evaluation of precursors of hospital employee turnover. *Journal of Applied Psychology*, 63(4), 408–414. <https://doi.org/10.1037/0021-9010.63.4.408>
- Nie, X., & Wager, S. (2021). Quasi-oracle estimation of heterogeneous treatment effects. *Biometrika*, 108(2), 299–319. <https://doi.org/10.1093/biomet/asz055>
- Nyberg, O., & Klami, A. (2023). Exploring uplift modeling with high class imbalance. *Data Mining and Knowledge Discovery*, 37, 736–766. <https://doi.org/10.1007/s10618-023-00917-9>
- Olaya, D., Vásquez, J., Maldonado, S., Miranda, J., & Verbeke, W. (2020). Uplift modeling for preventing student dropout in higher education. *Decision Support Systems*, 134, Article 113320, 1–11. <https://doi.org/10.1016/j.dss.2020.113320>
- Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems*, 31.

Radcliffe, N. J., & Surry, P. D. (1999). Differential response analysis: Modeling true response by isolating the effect of a single action. *Credit Scoring and Credit Control IV*.

Rzepakowski, P., & Jaroszewicz, S. (2012). Decision trees for uplift modeling with single and multiple treatments. *Knowledge and Information Systems*, 32(2), 303–327. <https://doi.org/10.1007/s10115-011-0434-0>

Society for Human Resource Management. (2017). *Human Capital Benchmarking Report. SHRM*.


Wikipedia. (s.f.). Curva ROC. En Wikipedia, la enciclopedia libre, https://es.wikipedia.org/wiki/Curva_ROC

Anexos

Tabla 4

Gerencia	Cantidad de Renuncias	Total de dotación	% de Renuncias
Gerencia Corporativa Clientes y Sostenibilidad	3	3	100,0%
Gerencia Corporativa Planificación y Desarrollo	9	9	100,0%
Gerencia Extensiones	4	4	100,0%
Compliance	2	4	50,0%
Gerencia Auditoria Interna	3	12	25,0%
Gerencia Corporativa Asuntos Legales	5	25	20,0%
Gerencia Corporativa Ingeniería	16	87	18,4%
Gerencia Abastecimiento y Contratos	10	59	16,9%
Gerencia División Proyectos	15	99	15,2%
Gerencia Ingeniería, Obras Civiles y Arquitectura	8	56	14,3%
Gerencia Corporativa Planificación y Clientes	8	57	14,0%
Gerencia Seguridad	2	15	13,3%
Gerencia Corporativa de Personas	17	133	12,8%
Gerencia Corporativa Administración y Finanzas	4	41	9,8%
Gerencia Mantenimiento	7	77	9,1%
Gerencia Ingeniería Operaciones y Mantenimiento	12	134	9,0%
Gerencia División Negocios	4	46	8,7%
Gerencia División Transporte de Pasajeros	1	14	7,1%
Gerencia Proyectos Operacionales	3	46	6,5%
Gerencia Operaciones y Servicios	1	19	5,3%
Gerencia Seguridad de la Información y Tecnología	2	39	5,1%
Gerencia Corporativa Comunicaciones y Sostenibilidad	2	48	4,2%
Gerencia de Construcción	1	24	4,2%
Gerencia Comercial Grandes Cuentas	0	5	0,0%

Gráfico 8



Conceptos Clave para el Lector:

- *Machine Learning (ML)*: Un subcampo de la IA que permite a los sistemas aprender de los datos, identificar patrones y tomar decisiones con una mínima intervención humana.
- Algoritmo de Clasificación: Tipo de algoritmo de *ML* que predice una categoría o clase (en este caso, si un empleado se fuga o no).
- Variables Predictoras (*Features*): Las características o atributos de los datos utilizados para entrenar el modelo.
- Variable Objetivo (*Target*): La variable que el modelo intenta predecir, en este caso la renuncia de un trabajador.
- Sobreajuste (*Overfitting*): Cuando un modelo aprende demasiado bien los datos de entrenamiento, capturando el ruido, lo que le impide generalizar a datos nuevos.
- Validación cruzada: Técnica para evaluar el rendimiento de un modelo de *ML*, estimándolo en datos no vistos durante el entrenamiento. Consiste en la división de un *dataset* en *folds* (subdivisiones), entrenando el modelo en algunos y evaluándolo en los restantes, repitiendo el proceso una cantidad definida de veces.
- SMOTE: *Synthetic Minority Oversampling Technique*, técnica de *Machine Learning* utilizada para el tratamiento de desbalanceo de clases, cuando la clase de una variable a predecir es menos frecuente que otra. Como en un caso de predicción de fuga, la proporción de renuncias efectivas suele ser mucho menor que los casos de “no renuncia”.
- Curva ROC: *Receiver Operating Characteristics*, gráfica que evalúa el desempeño de un modelo de clasificación binaria, mostrando la relación entre la tasa de verdaderos positivos y la tasa de falsos positivos, en distintos umbrales.
- AUC: *Area Under the Curve*, es el área bajo la curva ROC, mide la capacidad del modelo para distinguir entre clases, siendo un buen indicador para problemas con clases desequilibradas. Un AUC de 1 representa una clasificación perfecta, uno de 0.5 representa un modelo sin capacidad predictiva, mientras que un AUC menor a 0.5 representa un modelo que tiene un rendimiento peor que el azar.
- *Precision*: Métrica de evaluación de rendimiento de modelos de clasificación, que indica la proporción de las predicciones positivas que fueron correctas. En esta aplicación, mide cuántas de los casos en que el modelo clasificó como renuncia, efectivamente lo fueron.
- *Recall*: Métrica de sensibilidad, que refleja cuántos de los casos positivos fueron correctamente identificados por el modelo. En esta aplicación, mide del total de renuncias efectivas, cuántas fueron clasificadas como renuncia.

- *F1-Score*: Métrica de evaluación para modelos de clasificación binaria que combina *Precision* y *Recall*. Es la media armónica entre ambas métricas. Su valor va de 0 a 1, donde 1 indica un rendimiento perfecto. Un F1 alto indica que el modelo hace buenas predicciones positivas y captura la mayoría de los positivos reales.
- Inferencia Causal: El proceso de determinar si una relación entre dos variables es de causa y efecto. Crucial para ir más allá de la correlación.
- Intervención/Tratamiento: La acción específica que se aplica a un grupo de individuos. En esta investigación, es la acción de retención a un trabajador para evitar su renuncia.
- Grupo de Tratamiento: El grupo de individuos que recibe la intervención.
- Grupo de Control: El grupo de individuos que no recibe la intervención, utilizado para establecer una línea base de comparación.
- *Uplift Modeling*: Técnica de modelado que busca estimar el impacto de una intervención sobre un individuo específico. Estima el cambio de una probabilidad de un evento, producto de una acción. En este caso, el cambio en la probabilidad de renuncia de un trabajador al recibir una retención.
- *CATE: Conditional Average Treatment Effect*, es el efecto promedio que tiene un tratamiento condicionado a un grupo con características específicas. Es la diferencia esperada entre el resultado con y sin tratamiento.
- *T-Learner: Two-Model Learner*, es una técnica de *Uplift Modeling* que entrena dos modelos por separado. Uno para los individuos que recibieron el tratamiento (grupo de tratamiento) y otro para quienes no los recibieron (grupo de control).