



CerveclA: Una cerveza obtenida utilizando técnicas analíticas.

Taller AFE – Entrega Informe 3

Escuela de Economía y Negocios – Universidad de Chile

Autor: Nicolás Ceroni

Profesor Guía: Richard Weber

Fecha: 18-03-2025

Santiago, Chile



UNIVERSIDAD DE CHILE
FACULTAD DE ECONOMÍA Y NEGOCIOS
ESCUELA DE POSTGRADO

CerveclA: Una cerveza obtenida utilizando técnicas analíticas.

ACTIVIDAD FORMATIVA EQUIVALENTE
PARA OPTAR AL GRADO DE MAGISTER EN ANALÍTICA DE NEGOCIOS

NICOLÁS CERONI PERISIC

RICHARD WEBER

Santiago, Chile

2025

Resumen Ejecutivo

ESPAÑOL

El proyecto "CerveclA" se centra en el desarrollo de un modelo analítico para agilizar el diseño de recetas de cerveza artesanal, con el objetivo de reducir pérdidas de recursos y tiempos asociados al proceso tradicional de prueba y error. Utilizando datos de plataformas especializadas, se implementaron técnicas avanzadas de Machine Learning para predecir puntuaciones de recetas basadas en combinaciones de ingredientes clave (principalmente maltas y lúpulos) así como también variables de proceso.

El trabajo incluyó la recopilación de datos mediante web scraping, el análisis y transformación de datos, y el desarrollo de modelos predictivos para identificar recetas óptimas en términos de calidad (puntuación). Este enfoque innovador busca mejorar la eficiencia del proceso de creación de recetas, y obtener en menor tiempo y con menos recursos, una mejor cerveza.

La metodología aplicada contempla desde la recolección de datos hasta la validación práctica de la receta, integrando herramientas como Python, PyCaret, Shap Values y SQLite para la obtención y modelado de datos. Los resultados incluyen un modelo automatizado que, a partir de un estilo de cerveza en particular, permita obtener de manera más rápida una mejora en la calidad de las cervezas producidas, basada en las evaluaciones realizadas por otros maestros cerveceros.

ENGLISH

The "CerveclA" project focuses on developing an analytical model to streamline the design of craft beer recipes, aiming to reduce resource waste and time associated with the traditional trial-and-error process. Using data from specialized platforms, advanced Machine Learning techniques were implemented to predict recipe scores based on combinations of key ingredients (mainly malts and hops) as well as process variables.

The work included data collection through web scraping, data analysis and transformation, and the development of predictive models to identify optimal recipes in terms of quality (score). This innovative approach seeks to improve the efficiency of the recipe creation process, producing better beer in less time and with fewer resources.

The applied methodology encompasses everything from data collection to the practical validation of the recipe, integrating tools such as Python, PyCaret, Shap Values, and SQLite for data acquisition and modeling. The expected outcomes include an automated model that, starting from a particular beer style, allows for faster improvement in the quality of the beers produced, based on evaluations made by other master brewers.

Tabla de contenido

Resumen Ejecutivo.....	3
1. Introducción.....	6
2. Planteamiento y formulación del problema.....	7
3. Hipótesis.....	8
4. Objetivos.....	8
5. Metodología Propuesta.....	8
6. Marco Teórico.....	9
6.1. Proceso de Elaboración de Recetas.....	9
6.2. Herramientas Utilizadas.....	11
6.3. Avances en DATA, IA y ML en la Industria Cervecera.....	15
7. Descripción del enfoque de solución.....	16
7.1. Scraping, Crawler y Base de Datos.....	16
7.2. Análisis Exploratorio de los Datos.....	17
7.3. Cálculo de indicador de score para cada cerveza.....	18
7.4. Pre-Procesamiento y Transformación de datos.....	21
7.5. Modelado Analítico con Machine Learning y Evaluación de resultados.....	24
7.6. Hallazgos y conclusiones para armado de recetas.....	30
8. Resultados.....	34
8.1. Resultados generales y cumplimiento de objetivos.....	34
8.2. Resultados para más de un estilo.....	35
8.3. Resultado de Arquitectura Modular.....	36
8.4. Otros resultados y análisis.....	37
9. Conclusiones.....	39
Referencias.....	41
Anexos.....	43

TABLA DE GRÁFICOS

GRÁFICO 1 - DISPERSIÓN ENTRE BREWS Y SCORE.....	19
GRÁFICO 2 - BALANCEO DE SCORE.....	19
GRÁFICO 3 - DISTRIBUCIÓN DE SCORE POST BALANCE.....	20
GRÁFICO 4 - HISTOGRAMA DEL SCORE APLICADO A TODO EL DATASET.....	21
GRÁFICO 5 - BALANCEO DE SCORE DE AMERICAN PALE ALE.....	27
GRÁFICO 6 - DISTRIBUCIÓN AMERICAN PALE ALE BALANCEADA.....	27
GRÁFICO 7 - ANÁLISIS DE SHAP VALUES AMERICAN PALE ALE.....	29
GRÁFICO 8 - R CUADRADO Y MAPE MÚLTIPLES RECETAS.....	36

TABLA DE ILUSTRACIONES

ILUSTRACIÓN 1 - BASE DE DATOS.....	17
ILUSTRACIÓN 2 - FLUJO DE ANÁLISIS.....	24
ILUSTRACIÓN 3 - DIAGRAMA DE ARQUITECTURA DE SOLUCIÓN.....	37

1.Introducción

El mercado de la cerveza artesanal ha experimentado un notable crecimiento a nivel global. En 2023, el valor del mercado mundial de cerveza fue de aproximadamente 674 mil millones de dólares (Statista, 2024), de los cuales 109,22 mil millones de dólares correspondieron a la cerveza artesanal (EMR Claight, 2024). Este segmento, impulsado por la demanda de productos personalizados y de alta calidad, se estima que siga creciendo a una tasa compuesta anual de 8,9% entre 2024 y 2032 (EMR Claight, 2024), lo que refleja el interés de los consumidores por productos únicos y locales.

En Chile, el mercado de la cerveza artesanal también avanza a pasos agigantados. Actualmente, el país cuenta con más de 300 cervecerías artesanales, con un crecimiento anual en torno al 30% y 40%, y la participación de la cerveza artesanal en el mercado total chileno ya alcanza el 3% (Agencia Argentina de inversiones y comercio internacional, 2023). Este crecimiento ha sido particularmente notorio en regiones como Los Lagos, Valparaíso y La Araucanía, donde la producción local ha generado un fuerte vínculo entre la cerveza artesanal y la identidad regional.

Un paso crítico en el proceso de elaboración de cervezas artesanales es la creación de recetas, ya que estas implican una combinación compleja de ingredientes. Entre ellos se encuentran la modificación del agua mediante sales, el uso de maltas tanto base como especiales, la selección de lúpulos de diversas clases, y la adición de alguna levadura específica. Estas decisiones generan la amplia gama de colores, perfiles de sabor, aromas y texturas que definen cada receta. A esto se le suma la complejidad de decidir a qué temperatura hacer cada parte del proceso, como la maceración y la fermentación, y otros tipos de decisiones.

No obstante, en la industria de la cerveza artesanal, es común que se produzcan lotes pequeños para probar nuevas recetas. Estas pruebas a menudo resultan en productos que no cumplen las expectativas, lo que puede generar una merma significativa. Según conversaciones con cerveceros artesanales, se estima que entre el 5% y el 10% de la producción total se pierde debido a pruebas fallidas, y en la generación de una receta nueva, uno puede realizar la receta en promedio entre 6 a 10 veces, lo que implica la pérdida de materias primas, tiempo, energía y recursos hídricos. En particular, los lotes de prueba suelen oscilar entre 100 y 400 litros, y no es raro que se desperdicien completamente si no cumplen con los estándares de calidad esperados. Además, cada litro de cerveza producido requiere entre 8 y 10 litros de agua, lo que agrava el impacto de estos desperdicios (UNC Environmental Finance Center, 2024). Estos procesos también contribuyen a emisiones de CO₂ y generan costos adicionales asociados al tratamiento de residuos (Salazar Tijerino, San Martin-Gonzalez, Velasquez Domingo, & Huang, 2023).

Este trabajo se enfoca en la creación de un modelo analítico para mejorar el proceso de creación de recetas de cerveza, utilizando métricas de popularidad y calificaciones extraídas de sitios especializadas en cervezas (Brewer's Friends, 2024). Al implementar técnicas analíticas avanzadas, se busca llegar antes a una buena receta de cerveza (combinatoria de ingredientes), ahorrando de esta forma pérdidas económicas, tiempos de proceso, y materias primas asociadas al ensayo y la prueba y error en el proceso de diseño de recetas de cerveza.

2.Planteamiento y formulación del problema

Para elaborar una receta de cerveza en la actualidad, se requieren 4 ingredientes básicos (agua, malta, lúpulos y levadura). La combinación de estos ingredientes, más algunas variables de proceso, es la que otorga las características a la cerveza, tal como el aroma, el color, el sabor, el alcohol, el amargor, entre otros.

Existen diversos estilos de cerveza, que se caracterizan por tener ciertos atributos específicos que tienen que cumplir. Por ejemplo, una cerveza estilo “American IPA” debe tener un amargor específico como también aromas frutales otorgados por el lúpulo. En cambio, una cerveza estilo “Barley Wine”, tiene que ser una cerveza maltosa, con cuerpo, y con un gran contenido alcohólico.

Es en el proceso de diseño de recetas donde un maestro cervecero define qué ingredientes usar, en qué cantidades, y en qué parte del proceso, teniendo infinitas posibilidades. Se puede partir con una guía base de cómo hacer un estilo en particular, y después ir probando con distintas combinaciones de malta, lúpulo, perfiles de agua (añadiendo distintas sales) y levaduras, hasta llegar a la cerveza deseada, la que luego tiene que ser evaluada para proyectar su éxito comercial.

Es en este proceso de formulación de recetas, donde existe la oportunidad de usar analítica avanzada para poder obtener conclusiones de combinaciones de ingredientes que permitan obtener una mejor cerveza basada en un puntaje dado.

Por ende, el problema que se plantea en este trabajo es encontrar una función o modelo que permita obtener y predecir el puntaje o score (de 1 a 5) que tendría una cerveza basado en diferentes combinaciones de maltas (M), lúpulos (H) y variables de proceso (P), de la siguiente forma:

$$Score = f(M_i, H_j, P)$$

Para esto, y por cada estilo de cerveza en particular, se genera de forma automática un modelo analítico que permite estimar el puntaje (Score) que tendría una cerveza dada una combinación específica de ingredientes. Posteriormente, se puede determinar cómo cada variable impacta en el puntaje predicho, y con esto obtener conclusiones que permitan decidir qué ingredientes utilizar en la elaboración de una cerveza con buen puntaje.

Finalmente, el resultado que se espera es una herramienta que permita apoyar la toma de decisiones de un maestro cervecero a la hora de elegir ingredientes para una receta.

3. Hipótesis

Este trabajo se centra en la hipótesis que, para algún estilo en particular, existen combinaciones de ingredientes que pueden generar una mejor cerveza, basada en puntuaciones y popularidad evaluada por varios maestros cerveceros.

Adicionalmente se puede determinar, a partir de un análisis avanzado, cómo cada uno de los ingredientes impacta positiva o negativamente en el resultado de puntaje de esta cerveza, y utilizar estos descubrimientos para diseñar la receta y elaborar la cerveza.

4. Objetivos

El objetivo general de este trabajo es desarrollar una herramienta que emplee analítica avanzada para apoyar el proceso de creación de recetas, con el fin de obtener una cerveza excepcional en menos tiempo y utilizando menos recursos de lo que se requeriría con un proceso tradicional y manual de generación de recetas.

Los objetivos específicos de este trabajo son:

1. Obtener y Analizar datos de recetas de cerveza para obtener conclusiones relevantes sobre el diseño de estas.
2. Generar una métrica de Score que nos permita identificar y obtener un puntaje para cada una de las recetas de los datos.
3. Realizar un modelo de Machine Learning que permita predecir el Score de la cerveza a partir de la combinación de sus ingredientes.
4. Analizar los resultados del modelo, para rescatar conclusiones que permitan diseñar una receta.
5. Hacer la cerveza para probar los resultados directamente en un proceso real.

5. Metodología Propuesta

Se propone realizar un trabajo que consta de 4 fases:

1. **Obtención de la data:** Realizar técnicas de *Web Crawler* y *Web Scraping* sobre un sitio donde existen recetas, y evaluaciones realizadas por maestros cerveceros de todo el mundo.
2. **Transformación de Datos:** Hacer un análisis descriptivo y exploratorio de los datos, para poder convertirlos a un formato trabajable por un modelo analítico.
3. **Generación de Modelos de Predicción:** Utilizar herramientas de Machine Learning, para poder estimar el score de cada receta.
4. **Obtención de hallazgos y conclusiones:** Analizar el modelo obtenido para poder revisar como cada variable utilizada (maltas, lúpulos, proceso, etc..), impactan en los resultados, y con esto obtener los hallazgos y conclusiones para desarrollar una receta de cerveza.

Todo este proceso se realizará teniendo en cuenta practicas comunes y restricciones que tiene todo proceso de diseño de recetas como cantidades máximas de maltas, lúpulos, ratios estándar de alcohol, entre otras.

6.Marco Teórico

El marco teórico de este trabajo se divide en tres partes. La primera parte, se describe en breve el proceso de elaboración de recetas con los aspectos más relevantes del mismo para la construcción del modelo. En la segunda parte, se resumen las técnicas y herramientas utilizadas para elaborar los modelos analíticos utilizados en este trabajo. Finalmente, en la tercera parte, se busca mostrar avances respecto al uso de analítica avanzada, machine learning e Inteligencia artificial en la industria de la cerveza, buscando trabajos relacionados con este hasta la fecha.

6.1. Proceso de Elaboración de Recetas

La elaboración de cerveza es un proceso complejo que comienza con el diseño de la receta y pasa por múltiples etapas técnicas que involucran la selección de ingredientes, el manejo preciso de las temperaturas y tiempos, y la fermentación controlada. A continuación, y basado en distintos libros de elaboración de cerveza (Palmer, 2017) (Mosher, 2017), se detallan los pasos clave en la producción de una cerveza:

1. Diseño de la Receta

El diseño de la receta es el primer paso en el proceso de elaboración y define las características finales de la cerveza. Una receta contiene información clave como:

- **Estilo de la cerveza** (por ejemplo, IPA, Stout, Lager).
- **Tamaño del lote**, que se refiere a la cantidad de cerveza a producir.
- **Densidades del proceso** como la densidad inicial y final, que es una medición que permite saber las azúcares que están dentro del mosto, y permiten finalmente calcular el contenido alcohólico de la cerveza.
- **Alcohol por volumen (ABV)**, que es la medida de cuán alcohólica será la cerveza.
- **IBU (Unidades Internacionales de Amargor)**, que indican el nivel de amargor, y este dado por los lúpulos usados en el proceso.
- **Indicador de color (SRM)**, que mide la tonalidad de la cerveza.
- **Eficiencia de la receta**, la cual refleja el rendimiento de la malta utilizada.

2. Maceración (Mash)

Una vez que se define la receta, el siguiente paso es la **maceración**. Aquí, la malta molida se mezcla con agua caliente para convertir los almidones de los granos en azúcares fermentables. Este proceso se realiza a una temperatura controlada, generalmente entre 63°C y 72°C, y puede durar de 60 a 90 minutos. Dependiendo de la receta, se pueden añadir diferentes tipos de maltas para influir en el color y el sabor.

Durante la maceración, es crucial controlar:

- **Temperatura del macerado**, que afecta los tipos de azúcares generados.
- **Relación agua-grano**, que impacta la densidad y eficiencia.
- **Perfil del agua**, que puede ajustarse con sales para influir en la dureza del agua y en los sabores finales.

3. Lavado del Grano (Sparging)

Después de la maceración, los azúcares deben extraerse de la mezcla de granos. Esto se hace en el proceso llamado lavado del grano o *sparging*. Se añade agua caliente sobre los granos macerados

para enjuagar los azúcares restantes. El líquido resultante, llamado mosto, es lo que se utilizará en las etapas posteriores para crear la cerveza. Aquí es importante no extraer demasiados taninos del grano, lo que puede dar un sabor astringente indeseado.

4. Hervor del Mosto (Boiling)

El mosto obtenido del lavado se lleva a ebullición, generalmente durante 60 a 90 minutos. El hervor tiene múltiples propósitos:

- Esteriliza el mosto eliminando posibles contaminantes.
- Se añaden los lúpulos en diferentes momentos del hervor para añadir amargor, sabor y aroma.
- Se evaporan compuestos no deseados, como el dimetil sulfuro (DMS), que puede generar sabores y aromas indeseados en la cerveza.

La cantidad de lúpulo y el momento en que se añaden durante el hervor influirán en el perfil de sabor final. Lúpulos añadidos al inicio del hervor aportan amargor, mientras que los que se añaden hacia el final contribuyen más al aroma.

5. Enfriado del Mosto (Cooling)

Tras el hervor, el mosto debe enfriarse rápidamente para prepararlo para la fermentación. Esto se hace mediante intercambiadores de calor o utilizando un enfriador de inmersión, bajando la temperatura del mosto a niveles seguros para la levadura (generalmente por debajo de los 25°C). En esta etapa, es fundamental evitar la contaminación por bacterias o levaduras salvajes.

6. Fermentación

Una vez que el mosto se ha enfriado, se transfiere a un fermentador y se añade la levadura seleccionada. La levadura es responsable de convertir los azúcares fermentables en alcohol y CO₂, lo que define el contenido alcohólico de la cerveza y su nivel de carbonatación. La fermentación puede durar entre una y dos semanas, dependiendo del estilo de cerveza y de la levadura utilizada.

La temperatura de fermentación debe controlarse cuidadosamente para garantizar que la levadura funcione de manera óptima:

- Temperaturas bajas suelen producir cervezas más limpias y ligeras (como las Lagers).
- Temperaturas más altas pueden generar más ésteres y fenoles, lo que aporta sabores frutales y especiados (común en las Ales).

7. Maduración y Carbonatación

Después de la fermentación primaria, muchas cervezas pasan por una etapa de maduración o fermentación secundaria, donde los sabores se redondean y se eliminan los sabores indeseados generados en la fermentación primaria. Esto puede durar desde unas pocas semanas hasta varios meses.

En esta etapa también puede realizarse la carbonatación, que puede lograrse de manera natural añadiendo más azúcares para que la levadura genere CO₂ o mediante la carbonatación forzada en un barril.

8. Embotellado o Enlatado

Finalmente, la cerveza se embotella o se enlata para su distribución. En muchos casos, se añaden azúcares adicionales antes del embotellado para permitir una fermentación secundaria en la botella, lo que genera carbonatación natural.

Este trabajo impacta de manera directa en decisiones que se toman en las etapas 1, 2 y 4 de las revisadas anteriormente, por lo que son la base del set de datos a analizar y optimizar.

6.2. Herramientas Utilizadas

En este trabajo, se han empleado diversas herramientas tecnológicas que permiten obtener, transformar, analizar y almacenar información de manera eficiente. Estas herramientas se dividen en dos grandes etapas: la obtención y almacenamiento de datos, y la transformación y análisis de la información. A continuación, se detalla las herramientas utilizadas como también algunas definiciones relevantes en el desarrollo de este trabajo.

1. Obtención y Almacenamiento de Datos

El acceso y recopilación de datos desde fuentes externas se ha realizado mediante técnicas de *web crawler* y *web scraping*.

El web scraping es una técnica utilizada para extraer datos de páginas web de forma automatizada. Consiste en navegar por sitios web, recopilar información específica y estructurarla en un formato útil para su análisis, como tablas o bases de datos. Esta técnica permite acceder a grandes volúmenes de datos publicados en internet de manera más eficiente que la recopilación manual.

Componentes del Web Scraping

Para entender cómo funciona el web scraping, es importante considerar los siguientes elementos principales:

- **Solicitudes HTTP:** El proceso inicia con una solicitud HTTP al servidor que aloja el sitio web. Estas solicitudes son generalmente del tipo GET, que permite acceder al contenido de una página. Ejemplo: Librerías como requests en Python permiten realizar estas solicitudes.
- **HTML y Estructura de las Páginas Web:** El contenido de una página web se encuentra en documentos HTML que estructuran el texto, imágenes y otros elementos. El scraper debe analizar este contenido para identificar y extraer los datos de interés.
- **Parsing de Datos:** Se utiliza un *parser*, como el proporcionado por la librería BeautifulSoup en Python, para interpretar el HTML y localizar los elementos específicos que contienen la información deseada, como etiquetas <div>, <table>, , etc.
- **Almacenamiento de Datos:** Los datos extraídos se estructuran y almacenan en un formato adecuado para su posterior análisis, como un archivo CSV o una base de datos como SQLite.

El proceso de web scraping se realiza en varias etapas:

- **Acceso a la página web:** Se realiza una solicitud HTTP para descargar el contenido de la página.
- **Extracción del código fuente:** El código HTML descargado se analiza para identificar las secciones relevantes.
- **Selección de datos específicos:** Se usan selectores como clases (class) o identificadores (id) para localizar los elementos que contienen los datos necesarios.

- **Estructuración de la información:** Los datos extraídos se organizan en estructuras como listas, diccionarios o tablas.

Para ello, se han utilizado las siguientes herramientas y tecnologías:

- **Python:** Python es un lenguaje de programación versátil y ampliamente utilizado en análisis de datos, machine learning y desarrollo de aplicaciones. Su facilidad para integrarse con librerías especializadas lo convierte en una elección ideal para tareas de web scraping y manipulación de datos.
- **Requests:** Esta librería facilita la interacción con sitios web mediante la realización de solicitudes HTTP (GET, POST, etc.). Permite extraer contenido HTML de páginas web de forma eficiente y es fundamental para acceder a los datos de interés.
- **Beautiful Soup:** Librería utilizada para analizar y extraer datos de documentos HTML y XML. Con BeautifulSoup es posible navegar y estructurar información no estructurada en formatos más manejables, como listas o diccionarios.
- **SQLite:** Como sistema de gestión de bases de datos relacional ligero, SQLite se ha utilizado para almacenar los datos obtenidos. Es especialmente útil en proyectos de análisis de datos por su simplicidad y su integración nativa con Python mediante la librería sqlite3. Este sistema permite gestionar grandes volúmenes de datos de manera local y eficiente.

La combinación de estas herramientas permitió la recopilación estructurada de datos relevantes para la modelación analítica, asegurando que la información esté almacenada de manera consistente para su posterior análisis.

2. Transformación y Análisis de la Información

Una vez recopilados y almacenados los datos, se procedió a la etapa de transformación y análisis, para lo cual se emplearon diversas librerías de Python, enfocadas en manipulación de datos y aprendizaje automático. Las principales herramientas utilizadas son:

- **Pandas:** Librería esencial para la manipulación y análisis de datos. Permite trabajar con estructuras de datos como DataFrames, realizar transformaciones complejas, limpiar datos y preparar la información para el modelado analítico.
- **Scikit-learn (sklearn):** Biblioteca clave en machine learning que incluye una amplia variedad de algoritmos para clasificación, regresión y clustering. Además, proporciona herramientas para el preprocesamiento de datos, selección de características y evaluación de modelos.
- **PyCaret:** Framework de aprendizaje automático que simplifica el proceso de experimentación y comparación de modelos. PyCaret permite entrenar, evaluar y seleccionar modelos de machine learning con pocas líneas de código, agilizando la fase de experimentación en el proyecto.
- **Shap Values (SHapley Additive exPlanations):** son una técnica explicativa basada en teoría de juegos que mide el impacto de cada característica en la predicción de un modelo, asignando de forma justa la contribución de cada variable en el resultado.
- **Matplotlib y Seaborn:** Librerías utilizadas para la visualización de datos. Permiten generar gráficos e identificar patrones, tendencias o correlaciones en la información, lo cual es esencial en la etapa exploratoria y de interpretación de resultados.
- **NumPy:** Herramienta fundamental para cálculos numéricos y operaciones con matrices, que sirve como base para muchas de las librerías mencionadas. Se utiliza para realizar cálculos matemáticos avanzados requeridos en la preparación y análisis de datos.

La integración de estas herramientas en un flujo de trabajo cohesivo permitió transformar datos en bruto en información procesable, desarrollar modelos predictivos y obtener los hallazgos y conclusiones necesarios para elaborar una receta a partir de estos modelos.

Dos herramientas centrales para este trabajo fue Pycaret y Shap Values. A continuación, se define de forma más detallada, y se da un estado del arte de ambas herramientas para mejorar la comprensión de estas:

PyCaret

En los últimos años, el auge de las herramientas de aprendizaje automático (machine learning, ML) ha permitido a los investigadores y profesionales del análisis de datos realizar tareas complejas con mayor facilidad. Estas herramientas automatizan flujos de trabajo que tradicionalmente requerían habilidades técnicas avanzadas, permitiendo que usuarios con distintos niveles de experiencia aprovechen las capacidades del aprendizaje automático. PyCaret es un ejemplo destacado en este contexto, perteneciente a la categoría de herramientas de Machine Learning Automatizado (AutoML), diseñada para simplificar y acelerar el desarrollo de modelos predictivos.

Definición y Principales Características

PyCaret es una biblioteca de Python de código abierto que proporciona una solución integral para el aprendizaje automático supervisado y no supervisado. Diseñada para reducir la complejidad del proceso de creación de modelos, PyCaret permite a los usuarios realizar tareas que incluyen preprocesamiento de datos, selección de modelos, optimización de hiperparámetros y evaluación de desempeño, todo dentro de un marco cohesivo y estandarizado.

PyCaret se distingue por su interfaz intuitiva y su integración con otras bibliotecas populares como *Scikit-learn*, *XGBoost*, *LightGBM* y *CatBoost*, lo que permite realizar comparaciones entre múltiples algoritmos de manera eficiente. Además, incluye soporte para visualización y despliegue de modelos, haciendo que el flujo de trabajo de machine learning sea accesible desde la exploración inicial de datos hasta la implementación del modelo en producción (Ali, 2020).

Beneficios y Limitaciones de PyCaret

Entre los principales beneficios de PyCaret se destacan:

- **Automatización del Proceso de Modelado:** PyCaret automatiza tareas repetitivas como la imputación de valores faltantes, la codificación de variables categóricas y la selección de características relevantes.
- **Facilidad de Uso:** La simplicidad de su sintaxis reduce la curva de aprendizaje para usuarios no técnicos, fomentando la adopción de herramientas analíticas en distintos sectores.
- **Comparación de Modelos:** Su función `compare_models()` permite evaluar múltiples algoritmos de manera simultánea, ordenándolos según métricas de desempeño clave como precisión, AUC o F1-score.

No obstante, PyCaret presenta ciertas limitaciones. Por ejemplo, su enfoque de caja negra puede dificultar la personalización avanzada de modelos. Además, la biblioteca depende en gran medida de otros frameworks subyacentes, lo que puede generar desafíos de compatibilidad y rendimiento en proyectos a gran escala (Vadar, Moharekar, & Pol, 2024).

Estado del Arte: PyCaret y su Comparación con Otras Herramientas

El desarrollo de PyCaret se enmarca en una tendencia creciente hacia las plataformas de AutoML. Herramientas como H2O.ai, *Auto-sklearn* y Google AutoML comparten objetivos similares de automatización. Sin embargo, PyCaret se destaca por su facilidad de uso y rapidez de implementación, combinando funcionalidades avanzadas con una interfaz amigable (Vadar, Moharekar, & Pol, 2024).

SHAP Values

La interpretabilidad de los modelos de aprendizaje automático es un área de investigación clave, especialmente en aplicaciones donde las decisiones automatizadas deben ser comprendidas y justificadas. En este contexto, los valores SHAP (SHapley Additive exPlanations) han emergido como una metodología robusta para explicar los resultados de modelos complejos. Basados en la teoría de juegos, los valores SHAP cuantifican la contribución de cada característica al resultado predicho, proporcionando explicaciones consistentes y matemáticamente fundadas (Lundberg & Lee, A Unified Approach to Interpreting Model Predictions, 2017).

Definición y Principios Fundamentales

SHAP es un marco interpretativo que calcula la contribución marginal de cada característica en un modelo predictivo utilizando los conceptos de la teoría de juegos de Shapley. Los valores SHAP asignan un "peso" o importancia a cada característica en función de su impacto en la predicción del modelo. Esto se logra mediante la combinación de todas las posibles permutaciones de características, asegurando que las contribuciones sean justas y equitativas (Molnar, 2020).

Los valores SHAP son especialmente valiosos debido a las siguientes propiedades:

- Consistencia: Si una característica aumenta su contribución marginal, su valor SHAP también aumenta.
- Eficiencia: La suma de los valores SHAP es igual al resultado del modelo, garantizando que todas las contribuciones estén correctamente asignadas.

Algoritmo y Aplicación

El cálculo de valores SHAP se basa en el promedio ponderado de las diferencias en las predicciones del modelo al incluir o excluir una característica específica. Aunque el cálculo exacto puede ser computacionalmente costoso, implementaciones prácticas como SHAP en Python utilizan aproximaciones como el método *Kernel SHAP* para reducir la complejidad computacional (Lundberg, SHAP Documentation, 2018).

El framework SHAP incluye herramientas visuales como gráficos de dependencia, gráficos de resumen y gráficos de fuerza, que facilitan la comprensión de las interacciones entre características y predicciones.

Estado del Arte: SHAP en el Contexto de la Interpretabilidad

El uso de SHAP se ha ampliado en diversos dominios, incluyendo finanzas, salud y marketing, debido a su capacidad para proporcionar explicaciones claras y coherentes en modelos de caja negra como *XGBoost*, *Random Forests* y redes neuronales profundas. Estudios recientes han demostrado que SHAP supera a otras técnicas interpretativas como LIME (*Local Interpretable Model-agnostic Explanations*) al garantizar coherencia y estabilidad en las explicaciones (Hasan, 2023).

En comparación con métodos alternativos, SHAP ofrece ventajas significativas:

- Generalización: Puede aplicarse a cualquier modelo predictivo.
- Granularidad: Permite analizar tanto predicciones individuales como patrones globales del modelo.
- Visualizaciones: Facilita la interpretación de los resultados a través de gráficos intuitivos.

Sin embargo, SHAP también presenta limitaciones, como su alta demanda computacional, particularmente en conjuntos de datos con muchas características, y la dificultad para interpretar gráficos complejos en modelos con interacciones no lineales (Molnar, 2020).

6.3. Avances en DATA, IA y ML en la Industria Cervecera

La aplicación de técnicas de Inteligencia Artificial (IA) y Machine Learning (ML) en la industria de la cerveza está recién comenzando, existen pocos ejemplos conocidos y públicos acerca del uso de data en diferentes procesos. Aun así, con estos pocos ejemplos, se ve que su aplicación tiene oportunidades relevantes en el desarrollo de productos innovadores y mejorar la eficiencia en la producción de cerveza. A continuación, se ven alguno de los ejemplos y estudios más relevantes en este ámbito.

Uno de los ejemplos en esta área es IntelligentX, una compañía que intentó revolucionar el proceso de creación de recetas de cerveza mediante algoritmos de ML. Utilizando el feedback de los consumidores, IntelligentX ajusta las recetas de manera continua a través de un algoritmo de aprendizaje automático, mejorando la cerveza en función de las preferencias de sabores del cliente (Harvard, 2019). Este enfoque iterativo le permitió a IntelligentX, generar suscripción y mejora continua a sus recetas. Esta iniciativa nació como un proyecto, pero ya no sigue vigente.

Otro ejemplo sobre el uso de técnicas analíticas en la industria de cerveza es el estudio publicado en Nature sobre la predicción y mejora de sabores complejos en la cerveza (Schreurs, y otros, 2024). En este estudio, se analiza cómo las propiedades químicas y componentes de sabor pueden ser modelados para predecir el score que le otorgarían los consumidores, basado en reviews realizados en Ratebeer (Rate Beer, 2024). Los investigadores lograron establecer relaciones clave entre la composición química de las cervezas y las puntuaciones otorgadas por los evaluadores, abriendo la puerta a la creación de cervezas más atractivas para segmentos específicos del mercado y para saber que componentes son los más deseados por los consumidores para lograr crear mejores recetas.

Un caso más es el de la cervecería Species X, que utiliza modelos analíticos para perfeccionar recetas con base en la retroalimentación de los clientes (Buchanan, 2024). Esta cervecería ha implementado un enfoque basado en datos para ajustar constantemente sus recetas, similar a IntelligentX, pero con un enfoque local en los mercados y preferencias de la comunidad.

Este tipo de iniciativas demuestran que la IA puede ser una herramienta valiosa no solo para mejorar la calidad del producto, sino también para fidelizar a los consumidores mediante la personalización de las recetas.

La novedad en este trabajo es realizar combinaciones de ingredientes a partir de la evaluación de maestros cerveceros de distintas recetas de internet.

7.Descripción del enfoque de solución

Para el desarrollo de este trabajo, se realizaron varios pasos que se describen a continuación:

1. *Scraping*, *Crawler* y Base de Datos.
2. Análisis Inicial de los datos obtenidos.
3. Cálculo de indicador de Score para cada cerveza.
4. Pre-Procesamiento y Transformación de datos para el análisis.
5. Modelado Analítico con Machine Learning y Evaluación de resultados
6. Conclusiones para armado de recetas.

7.1. Scraping, Crawler y Base de Datos

El primer paso para el trabajo fue conseguir los datos. Esto se logró gracias a un programa hecho en Python que consulta el sitio BrewerFriends y almacenaba las recetas en una base de datos.

Lo primero dentro de este punto, es la construcción de una base de datos que permita almacenar toda la información de una receta de cervezas. Tras conocer el funcionamiento y composición de una receta de cerveza, además del análisis del sitio web mencionado anteriormente, los puntos considerados para la construcción de esta base de datos son los siguientes:

- Una receta tiene información clave como el estilo, el tamaño del lote, las densidades del proceso, el alcohol, los IBU, indicador de color, la eficiencia de la receta (cual fue el rendimiento de la malta), entre otros.
- Adicionalmente, la Receta tiene indicadores del comportamiento en el sitio, como las visitas, la cantidad de veces que fue elaborada (Brews), un Score y cuantos reviews tiene.
- Luego, una receta puede tener una o más maltas de distinto tipo y en distintas cantidades, uno o más lúpulos en diferentes cantidades y añadidos en distintos momentos, un perfil de agua en específico y variables de proceso como temperaturas de macerado o tiempos de hervor.

La base de datos quedó compuesta de 8 tablas que contiene la información necesaria para poder realizar los análisis que se requieren en este trabajo. Un resumen de las tablas y sus relaciones se pueden observar en la ilustración 1. Una visión más completa con todos los atributos de cada tabla se encuentra el anexo 1.




ILUSTRACIÓN 1 - BASE DE DATOS

Posteriormente, se realiza el *Web Crawler* y *Scraping* hacia el sitio BrewerFriends, que contiene las recetas y su información. Para esto, primero se visita la página de recetas (Anexo 2), para guardar todas las recetas y sus links en un arreglo. Luego se recorre cada uno de los links para acceder a cada página de recetas (Anexo 3 y 4), para extraer la información de estas, y almacenarlas en las bases de datos con su relación específica. Además, también se visita la página de cada ingrediente para igual almacenarlo (Anexo 5).

El script en Python logró correr hasta acumular un total de 10.360 recetas. Con esto tenemos una base de datos disponible para comenzar el trabajo.

7.2. Análisis Exploratorio de los Datos.

Se realiza un análisis exploratorio de la base de datos para ver con qué información contamos de recetas.

El dataset contiene 10.360 recetas de cervezas. Dentro de estas recetas, se tienen 185 estilos distintos, en las que se utilizan 693 maltas distintas y 273 lúpulos. Cada receta tiene su combinación única de estos atributos, con diferentes cantidades.

De las 10.360 recetas, hay 8.934 sin una evaluación que se traduce en un **puntaje o score**, pero todas tienen información de visualizaciones (views) y cantidad de veces elaboradas (brews), estos

atributos son los que serán de utilidad para poder estimar el puntaje o score para todas las recetas, que finalmente se utilizará para el modelo predictivo.

Cuando revisamos las 693 maltas distintas, podemos distinguir que existen varias del mismo tipo como por ejemplo “American Pale-Ale” o “German Pale Ale” y hasta incluso otras Pale Ale de marcas distintas. Adicionalmente, hay otras maltas que, si bien pueden diferir en cuanto a especificaciones, para el caso de elaboración de receta, se pueden comportar de un modo similar. Esta definición es clave para poder disminuir la dimensionalidad del problema, y poder agrupar ingredientes similares en alguna categoría más reducida que sirva para el análisis.

Similar a las maltas, con el lúpulo se tiene el mismo comportamiento. Se tiene en la base de datos lúpulos iguales de diferentes marcas, pero que en promedio producen el mismo efecto en la cerveza. Adicionalmente, se tienen lúpulos escritos de forma distinta, los que también se pueden normalizar para generar una reducción de dimensionalidad.

En términos de variables de proceso, como cantidades de maltas, o lúpulos, o hasta incluso tiempo de proceso, tenemos medidas diferentes. Por ejemplo, en cantidad de lúpulo a añadir, existe medidas que están en grms, otras en onzas, y otras en kg. Adicionalmente, existen recetas de distintos tamaños de Lote, desde los 5 Litros hasta aproximadamente 7000 litros.

Este análisis exploratorio inicial, deja en evidencia algunas de las transformaciones de datos a realizar, que se detallaran en la sección 4 de este capítulo.

7.3. Cálculo de indicador de score para cada cerveza.

Al analizar el set de datos, de las 10.360 recetas, encontramos 8.934 sin datos de puntaje o score, por lo tanto, se genera la hipótesis de que este puntaje se puede predecir a partir de la cantidad de visitas (Views) y cantidad de veces que se elaboró la receta (Brews). Al revisar el set de datos se confirma que todas las recetas contienen estos atributos sin nulos, por lo que se plantea el desarrollo de un modelo analítico, que logre estimar el puntaje (Score) a partir de la cantidad de “Views” y “Brews”. La idea es entrenar este modelo con aquellas recetas que si tengan Score.

Para validar la hipótesis anterior, se analiza gráficamente la relación que existe entre *Brews* y Score, notando una relación entre ambas variables. Esto podría ayudar a generar una predicción con un modelo analítico del Score a partir de esta variable (*Brews*). En el gráfico 1, podemos visualizar cómo se da esta relación. Como era de esperar, mientras más “*Brews*” (Cantidad de elaboraciones que tiene una receta), mayor Score tiene la misma entre los usuarios y cerveceros. Esta relación se repite de forma similar cuando se relaciona con la cantidad de Views (Anexo 6).

Adicionalmente, se analiza la distribución de score de las recetas que si poseen esta variable. En el gráfico 2, se puede ver cómo el score está distribuido con mayor frecuencia a las recetas con puntaje 4 o 5. Cuando se trata generar algún modelo con el set de datos como está, el hecho de que no exista un balance del score (la misma cantidad de recetas en cada puntaje) hace que el modelo quede sesgado hacia los valores altos (4 y 5), obteniendo predicciones solo de alto puntaje, y obteniendo R cuadrados muy cercanos a 0. La utilización del set de datos como está, no sirve para generar un indicador de score para todas las recetas. Por esta razón se busca balancear los datos para hacer un modelo que permita una mejor estimación de dicho puntaje o score.

GRÁFICO 1 - DISPERSIÓN ENTRE BREWS Y SCORE






GRÁFICO 2 - BALANCEO DE SCORE



Luego de este análisis y utilizando técnicas de balanceo (replicando aleatoriamente recetas de bajo score e incluyéndolas nuevamente en el dataset) se logró obtener un set de datos

homogéneo, para posteriormente hacer el modelo analítico sobre datos balanceados. El resultado de la distribución del balanceo se puede observar en la Gráfico 3.

GRÁFICO 3 - DISTRIBUCIÓN DE SCORE POST BALANCE




En la imagen anterior, podemos ver cómo los puntajes de las recetas o score, están más equitativos entre cada uno.

Con los datos ya balanceados, es momento de generar una estimación de score para las otras casi de 8900 recetas que no tienen score. Para lo anterior, se corrió un conjunto de modelos de regresión en Pycaret, para seleccionar y aplicar el mejor modelo de la lista. Los resultados de este modelamiento se muestran en el Anexo 7.

En la tabla del Anexo 7 se puede ver que con el modelo de Extra Trees Regressor se obtienen los mejores resultados. Este modelo obtiene un R cuadrado de 0.92294 y un error porcentual medio absoluto de 2.82% lo que se considera un buen predictor para obtener el score de cada receta. Adicionalmente, se valida el modelo con un gráfico de valores reales versus predichos, para confirmar el uso del modelo. Este grafico se puede observar en el Anexo 18. Dado lo anterior, este modelo se aplicará sobre toda la base de recetas, para obtener el score de todos los registros del set de datos, y con esto realizar los análisis posteriores.

Después de aplicar el modelo a las recetas, guardamos las predicciones por id de receta en nuestra base de datos para poder utilizarlo en los pasos posteriores. La distribución del set de datos resultante, se puede observar en el gráfico 4. Se verifica con esto que las distribuciones son muy parecidas al set de datos original (con la mayor cantidad de recetas entre el 4 y el 5), y, por lo tanto, tiene el mismo comportamiento de la distribución observada en los scores que venían por defecto.

GRÁFICO 4 - HISTOGRAMA DEL SCORE APLICADO A TODO EL DATASET



7.4. Pre-Procesamiento y Transformación de datos.

En esta etapa del trabajo, se requiere transformar y preparar el set de datos para ser procesado por técnicas de Machine Learning. Según lo visto en el análisis exploratorio, se puede ver que existen variables en distintas escalas y formatos, y, por lo tanto, se tiene que dejar el set de datos en un lenguaje en común para ser procesado por los algoritmos de ML.

Recordemos que tenemos múltiples tablas dentro del base de datos, por lo tanto, se tiene que realizar ingeniería de atributos sobre cada una de ellas. Las transformaciones realizadas se detallan a continuación:

Tabla de Recetas:

1. **Normalizar unidades de lote a Litros:** Se mencionó anteriormente que existían distintas unidades de lote como Litros y Galones. La idea es que todas las recetas queden en Litros, por lo tanto, esta es la primera transformación realizada en Python.
2. **Selección de columnas:** se descartan columnas con muchos Nulls o que no sirven para el análisis basado en juicio experto, se analizaron la cantidad de Nulos y N/A de la tabla de recetas, obteniendo variables como PreBoilGravity, Source, MashPH, Cost y Reviews con gran cantidad de Nulos. Estas se eliminan del dataset, ya que no aportan valor para el análisis. Cabe destacar que, si obtendremos costo de recetas, pero este será calculado a

posterior, utilizando directamente el costo de los insumos con respecto a valores en Chile. Adicionalmente se descartar otras columnas como Nombre de la receta, PreBoil Size (ya se tiene el *BatchSize*), Eficiencia (ya que esta variable depende de los equipos), el Method (ya que se considera para la elaboración el método todo grano), PreBoil Gravity (ya que se utiliza la gravedad final de la receta), las calorías y carbohidratos ya que son datos estimados y no de análisis de laboratorio. Finalmente se descartaron los Views y Brews ya que se utilizaron para realizar el ranking.

3. **Transformación de variables a numéricas:** Las variables que quedaron en el dataset son en su mayoría numérica, pero están como textos (algunas tienen información o caracteres adicionales, como por ejemplo el BoilTime tiene la palabra “min” de minutos, y el ABV de alcohol, tiene el “%”. Por lo tanto, limpiamos estas palabras y transformamos en números. Adicionalmente, para la densidad específica, había ciertos datos en Grados Plato, y la transformamos en unidad de densidad específica tradicional (como el resto del dataset) y de forma numérica.
4. **Descartar datos anómalos:** Se hizo un análisis exploratorio para la distribución de estas variables numéricas, y se filtraron algunas recetas con datos anómalos, como por ejemplo recetas con Densidad final mayor a 1.6 (las densidades finales están en torno a los 1.001 hacia los 1.020 normalmente, puede existir mayor, pero no es común, y menos llegar a 1.6). Adicionalmente se descartó algunas recetas que tenían IBU mayor a 2000 (cuando el rango promedio es entre los 30 y 60), y una receta que aparecía con ABV (Grados alcohólicos) mayor a 200. Solo se descartaron 3 recetas que cumplían con estas características anómalas.

Finalmente, en este set de datos, se dejaron las siguientes variables:

- Id_receta: Sirve para hacer la relación posterior con los ingredientes.
- Style: Sirve para poder filtrar por estilo en la parte de análisis y hacer modelo por algún estilo en particular.
- BoilTime: Tiempo de hervor de la receta, en minutos.
- BatchSize_Liters: Lote en Litros, esto nos servirá para normalizar los valores de los ingredientes (para dejar kg por litro en el caso de las maltas, y grms por litro en el caso de los lúpulos).
- FinalGravity: Corresponde a la densidad específica final en la receta. Corresponde al nivel de azúcar residual en la receta.
- ABV: Corresponde al % de alcohol en la receta.
- IBU: Corresponde al nivel de amargor aparente en la cerveza. Es el resultado de los Alfa-ácidos isomerizados en el proceso de hervor.
- SRM: Corresponde a la medida de color en la cerveza, mientras más alto el número, más oscura la cerveza.
- Prediccion_Rating: Es el score o puntaje obtenido en el paso anterior, es decir, el predicho en nuestro modelo a partir de los Views y Brews.

Tabla de maltas y lúpulos.

1. **Reducción de dimensionalidad de maltas y lúpulos:** Se agruparon las maltas y lúpulos según reglas de negocio, es decir, las maltas se agruparon en categorías similares,

reduciendo estas en 18 Macro-Categorías. De igual forma, se realizó esto sobre los lúpulos, agrupando por nombre, marcas, y también lúpulos similares. Para estimar los costos se dejaron lúpulos que se pueden obtener en Chile, los que no se podían obtener se buscó su símil tomando como referencia una tabla de lúpulos (cervezodromo, 2024).

2. **Transformación de Unidades:** Para las maltas, las unidades diferían entre recetas, existiendo en el dataset recetas en lb, g, oz y kg. Dejamos todos estos valores en Kg, para tener una unidad en común entre recetas. Algo similar se realizó con el lúpulo, ya que existían lúpulos en g, lb, kg y ml (este último referente a los aceites esenciales, donde 1ml puede equivaler a aproximadamente 7.5gms de lúpulo (Alemania Patente n° EP 1 414 937 B1, 2004). Los lúpulos se dejaron todos en grms.
3. **Transformación de tiempos de proceso:** Los lúpulos se utilizan en diferentes partes y tiempos del proceso, como Coccion, Whirpool, Standhop, Dryhop, por lo tanto, se normalizaron los tiempos contenidos en estas variables, para obtener informacion de los procesos de lupulado de cada receta.
4. **Normalización nombres de Proceso:** Se procesaron los nombres de los procesos, ya que algunos tenían nombres escritos de forma diferente, y otros incluían mayor informacion (como por ejemplo el Whirpool, salía informacion con respecto a la temperatura, que la vamos a omitir para nuestro análisis).
5. **Conformación de datasets:** Se dejaron establecido 3 datasets para luego generar el cruce con la tabla de Recetas, por un lado, dejamos una tabla con las maltas y sus cantidades en kilo. Luego se dejó una tabla con los lúpulos y su gramaje. Y finalmente una tabla con los lúpulos y sus procesos y los tiempos asociados en cada proceso. Estas son las tablas que se requieren cruzar con la tabla principal para generar el Tablón final.

Transformaciones Finales de Tablón:

1. **Trasponer tablas de ingredientes y enlazar a tabla principal:** La primera tarea para generar el tablón final, fue trasponer los ingredientes, para que quedaran cada receta como fila, y como columna los ingredientes, y como dato las cantidades (y en el caso de los procesos los tiempos). Luego se realizó un merge entre la tabla de recetas principal, y estas tres tablas para que quedara el tablón.
2. **Dejar todos los datos de recetas en Unidades por Litro:** Con la variable de Tamaño de Lote (BatchSize_Liters), se hizo una división de cada ingrediente por los litros correspondiente de cada receta, así nos aseguramos que todas tengan la misma escala para entrenar los modelos.
3. **Descartar variables auxiliares:** Para los análisis se descartan variables auxiliares utilizadas en el proceso, como id_receta, los litros del lote (utilizado solo para la transformación), el estilo (que es solo utilizado como filtro) y algunas variables de proceso repetidas como tiempo de Coccion (*Boil*).

Con estos pasos, dejamos un Tablón listo para ser procesado por los algoritmos de Machine Learning y obtener una receta a partir de los datos.


7.5. Modelado Analítico con Machine Learning y Evaluación de resultados

En esta parte del proceso, se requiere llegar a un modelo que permita generar conclusiones sobre algún estilo en particular, por lo que se tomó la decisión de generar una función en Python que a partir del Dataset, el estilo a analizar y otros parámetros (para filtrar columnas de forma dinámica), se lograra hacer todo el flujo de análisis de forma automática.

Este flujo de análisis se puede observar en la ilustración 2, y consta de los siguientes pasos:

1. Filtrar Estilo
2. Drop Columnas Iniciales
3. Drop Columnas Dinámicas por Parámetros
4. Balanceo
5. Pycaret + Best Model
6. Shap Values
7. Gráficos y análisis

ILUSTRACIÓN 2 - FLUJO DE ANÁLISIS



Cada una de las etapas del flujo se detallan a continuación:

Filtrar Estilo y Drop Columnas Iniciales

Los dos primeros pasos son los más básicos. La función al recibir el estilo (ej: "American Pale Ale"), filtra el dataset con solo recetas de este estilo, con esto, todo el resto del análisis y el modelo analítico se realizará sobre este estilo en particular.

Luego de generar este filtrado, se realiza la eliminación de algunas columnas de forma inicial, que no deberían entrar al modelo analítico por definición, estas columnas son el id_receta, el estilo (ya lo utilizamos previamente para filtrar), el index, el Batchsize_Liters (que son la cantidad de litros que tiene el lote, y no debería impactar en el score o rating de la cerveza).

Drop Columna Dinámicas por parámetro

Luego de varias iteraciones entrenando modelo y analizando resultados, se determinó que se podrían obtener distintos resultados y usos, entrenando los modelos con distintas columnas, adicionalmente, hay columnas que no tienen un sentido funcional para algunos estilos (por ejemplo, no todos los estilos tienen Dryhop, o algún proceso de lúpulo complejo, por lo que considerar estas columnas en el modelo, podrían significar ruido).

Es por esta razón que se decide realizar tres parámetros para manipular de forma dinámica las columnas del dataset a procesar y de esta forma evaluar diferentes resultados:

1. DB: Este parámetro sirve para botar columnas “básicas” o “de resultado” de una receta. Estas columnas son: Final Gravity, IBU, SRM y ABV. Estas columnas se pueden obviar en el modelo ya que son resultantes del proceso en sí y de los ingredientes a elegir, es decir, el Final Gravity depende del proceso de fermentación y la cantidad de maltas utilizada, o el IBU que depende de los lúpulos empleados. Por lo tanto, si se quisiera generar un modelo completo considerando estos parámetros, se podrían incluir, en cambio sí se quiere conseguir solo hallazgos y conclusiones de ingredientes a utilizar, estas columnas se podrían no considerar en el modelo.
2. DC y Umb: Este parámetro tiene como objetivo eliminar columnas de ingredientes o proceso que no se utilicen en una gran proporción dentro de una receta. Esta proporción se define con un umbral especificado, que permite decidir la tolerancia de registros en 0 de una columna en particular. Por ejemplo, si analizamos un estilo, donde queremos considerar solo ingredientes que estén presentes como mínimo en un 5% de las recetas, dejamos un umbral de 95, es decir, se tolera que el 95% de las recetas tenga ese ingrediente en 0. Si el umbral es 100, quiere decir que todas las columnas serán consideradas. Con este parámetro podemos ir ajustando manualmente un nivel de “significancia” de los ingredientes a considerar en el modelo. Si bien hay modelos que eligen automáticamente las columnas a considerar, con esto se puede añadir una capa de control adicional en el análisis.
3. DLP: Finalmente, tenemos la decisión si considerar o no las variables/columnas del proceso del lúpulo, esto es, los tiempos de Dryhop o FirstWort, hopback, entre otros. No muchas recetas tienen estas técnicas, por lo que muchas de estas variables podrían ser eliminadas con el parámetro anterior, pero puede ser que por diseño se requiera no considerarlas dentro del análisis de forma manual, por alguna otra razón de diseño de recetas, (por ejemplo, si el proceso en si no se puede hacer realidad por limitante de equipamiento).

Balanceo

Filtrando el set de datos por variados estilos, podemos encontrar la misma distribución de score o puntaje que el set de datos completo, es decir, un sesgo hacia variables con score 4 y 5. Esto es por la naturaleza de los datos. Por lo tanto, para realizar los análisis se requiere balancear la muestra, y para esto aumentar la cantidad de 3, 4 y 5. Por lo tanto se utiliza una función similar a la utilizada anteriormente, que permite dejar el dataset balanceado a partir de submuestras aleatorias de recetas de bajo score para dejar la distribución de una forma más pareja.

Pycaret + Best Model

Con el dataset ya balanceado y con las columnas preparadas, se genera un procesamiento de regresión con Pycaret. Para esto se considera siempre dividir el dataset en un 80% de entrenamiento y un 20% de testing.

Luego se utiliza la función *Best_model* para imprimir el resultado de cada uno de los modelos entrenados para ver cuál utilizar. El mejor modelo se guarda en una variable, que finalmente es el retorno de todo el flujo de análisis.

Hasta este punto, se podría haber retornado el modelo, para luego hacer los análisis correspondientes, pero los análisis de Shap Values y los gráficos que se realizan son transversales para todos los estilos de cerveza, por lo que también están dentro de la función para su posterior análisis.

Shap Values Gráficos y análisis.

Esta es la última fase de la función, en esta sección de la función se realiza el análisis de los Shap Values de cada receta para ver los atributos más relevantes como también cuantificar su impacto positivo o negativo en el score. Con esto se imprimen distintos gráficos que la librería de Shap Values, tiene disponible para analizar los resultados.

Adicionalmente, y para lograr determinar recomendaciones y conocimiento para elaborar una receta, se realiza un filtro de las variables más relevantes (dadas por el Shap Values), y se entrena un árbol de decisión con estas, para determinar algunas reglas que permitan guiar el proceso de elaboración de recetas.

Finalmente, con ayuda de los gráficos, el análisis de impacto de los Shap Values, y las reglas del árbol de decisión, se pueden obtener hallazgos y conclusiones para el diseño de una receta de cerveza y su posterior elaboración.


Con el proceso claro de análisis se realizan pruebas con diferentes estilos de recetas que se detallan a continuación:

Análisis para “American Pale Ale”:

Se realizó la prueba para el estilo “American Pale Ale”, para esto, se incluyó todos los filtros de columnas, y un umbral de 95 (eliminar columnas donde el ingrediente este presente en menos del 5% de las recetas).


El número de recetas de este estilo dentro del dataset es de 747 y la distribución inicial de score se muestra en el gráfico 5, post balanceo, se llega a la distribución que se muestra en el gráfico 6, lo que nos señala que ya se puede procesar.

GRÁFICO 5 - BALANCEO DE SCORE DE AMERICAN PALE ALE



Llegando a la siguiente distribución postbalance

GRÁFICO 6 - DISTRIBUCIÓN AMERICAN PALE ALE BALANCEADA



Posterior al balanceo, se obtienen los resultados de los modelos Pycaret, siendo el Extra Trees Regressor, el que tiene las mejores métricas considerando R cuadrado de 0.92 aproximadamente y MAPE de 4%, esto se puede observar claramente en la tabla 1.


TABLA 1 - RESULTADOS PYCARET AMERICAN PALE ALE

	Model	MAE	MSE	RMSE	R2	RMSLE	MAPE	TT (Sec)
et	Extra Trees Regressor	0.1867	0.1424	0.3757	0.9179	0.0709	0.0404	0.0240
rf	Random Forest Regressor	0.2282	0.1777	0.4188	0.8972	0.0801	0.0504	0.0380
lightgbm	Light Gradient Boosting Machine	0.2729	0.2126	0.4588	0.8782	0.0903	0.0677	0.0730
dt	Decision Tree Regressor	0.2193	0.2916	0.5347	0.8316	0.1135	0.0481	0.0060
gbr	Gradient Boosting Regressor	0.5070	0.4258	0.6512	0.7573	0.1485	0.1695	0.0180
knn	K Neighbors Regressor	0.3664	0.4378	0.6578	0.7476	0.1397	0.0851	0.0050
ada	AdaBoost Regressor	0.9156	1.2094	1.0983	0.3065	0.2717	0.3469	0.0060
lr	Linear Regression	1.0246	1.4554	1.2058	0.1680	0.3118	0.4158	0.0050
lar	Least Angle Regression	1.0247	1.4625	1.2086	0.1641	0.3123	0.4155	0.0050
ridge	Ridge Regression	1.0855	1.5181	1.2315	0.1319	0.3161	0.4413	0.0050
br	Bayesian Ridge	1.1066	1.5513	1.2449	0.1130	0.3190	0.4517	0.0050
huber	Huber Regressor	1.0993	1.5908	1.2600	0.0889	0.3139	0.4344	0.0080
omp	Orthogonal Matching Pursuit	1.1839	1.7417	1.3188	0.0057	0.3399	0.4971	0.0070
en	Elastic Net	1.1874	1.7454	1.3202	0.0039	0.3407	0.5007	0.0050
lasso	Lasso Regression	1.1890	1.7505	1.3222	0.0010	0.3413	0.5022	0.0050
llar	Lasso Least Angle Regression	1.1890	1.7505	1.3222	0.0010	0.3413	0.5022	0.0050
dummy	Dummy Regressor	1.1915	1.7650	1.3277	-0.0074	0.3429	0.5047	0.0050
par	Passive Aggressive Regressor	1.5296	3.5864	1.8657	-1.0648	0.4447	0.6174	0.0050

Adicionalmente, se valida el modelo con un gráfico donde están los valores de la predicción con los valores reales, el que se puede observar en el anexo 19. Con esto, podemos determinar que este modelo puede ser utilizado para obtener recomendaciones e ideas para la elaboración de recetas.

A continuación, se realiza el análisis de los Shap Values para las variables más importantes según el modelo, este análisis se detalla en el gráfico 7.

GRÁFICO 7 - ANÁLISIS DE SHAP VALUES AMERICAN PALE ALE



Gracias a los Shap Values, con este gráfico ya podemos observar conclusiones importantes acerca del diseño de recetas de una american Pale Ale. Estos hallazgos serán discutidos en la siguiente sección para elaborar una receta.

Ahora que se puede obtener a partir de este análisis cuales ingredientes utilizar, se debe seleccionar la cantidad, y para esto se generan gráficos de los atributos más relevantes dados por

el modelo, como también se utiliza entrena un árbol de decisión para revisar algunas reglas de cantidades que puedan ser útiles de una forma visual. Algunos ejemplos de estos gráficos, como también una muestra del árbol de decisión, se puede observar desde los anexos 8 al 16.

Con todos estos resultados y gráficos, podemos comenzar un análisis más funcional (o de negocio), para poder elaborar una receta y poder realizar su elaboración.

7.6. Hallazgos y conclusiones para armado de recetas

Se trabajará sobre los resultados de análisis de la American Pale Ale para analizar y obtener los hallazgos y conclusiones para la elaboración de este estilo.

Los hallazgos y conclusiones que salen a primera vista, son los entregados por el gráfico de Shap Values. Con este gráfico se pueden visualizar cuales son los ingredientes relevantes al momento de realizar una cerveza American Pale Ale, tanto para bien, como para mal.

El resultado obtenido de Shap Values (gráfico 7), se lee de la siguiente forma:

- Cada línea del “eje y” es un ingrediente.
- Los colores indican el valor de cada ingrediente, los rojos para los valores más altos, y los azules para los más bajos.
- El eje X indica el impacto que tiene cada valor de un ingrediente en el resultado del score de la receta final.

Con esta lectura, podemos analizar por ejemplo el impacto de la malta Pale Base Ale / Pale, un ingrediente básico para cualquier receta de cerveza, donde en este caso nos indica que valores muy altos de esta malta (valores que están en rojo), pueden ser perjudicial para el puntaje de la receta, pero valores medios a medios altos de esta malta, impactan positivamente en el resultado de la cerveza. Si analizamos este hallazgo con conocimiento experto, podemos decir que se debe a que utilizar solo el 100% de malta base para una receta como esta, puede no ser beneficioso, o a la vez utilizar valores muy alto, puede generar cervezas más maltosas o más alcohólicas que se pueden escapar del estilo. En cambio, utilizar valores medios a medios altos, permiten generar cervezas más balanceadas, que es lo que se busca en este estilo para tener una buena evaluación.

Adicionalmente, se pueden ver hallazgos mucho más claros, como por ejemplo el uso del lúpulo Magnum. En el gráfico podemos ver que hay una tendencia mayoritaria, a que el uso del lúpulo magnum en pequeñas cantidades, puede generar un impacto positivo en la receta, pero si se llegan a valores altos, esto puede ser perjudicial. Por lo tanto, juntando este hallazgo con conocimiento experto, se podría definir hacer la prueba con lúpulo Magnum para el Amargor, en pequeñas cantidades.

Por lo tanto, analizando este gráfico, ya tenemos dos conclusiones para la receta de una American Pale Ale: Malta base Pale Ale en combinación con otras maltas, y lúpulo Magnum en bajas cantidades para el amargor.

Siguiendo la misma lógica, se puede comenzar a analizar por tipo de ingrediente, comenzando con las maltas. En el gráfico 7, se puede ver que la malta Caramelo (de 10 a 30L en niveles de caramelo) y la malta Munich impactan positivamente en bajas cantidades, por lo que son ingredientes a considerar dentro de nuestra receta. Luego más abajo, se ve que la avena (malta Oats), y las maltas

especiales (por ejemplo, Carapils), en bajas cantidades también impactan positivamente. En este caso, Carapils y Avena en este estilo, son para otorgar mayor retención de espuma en la cerveza, pero la avena podría aumentar la turbidez, como en este se quiere conseguir una cerveza clara, se opta por usar malta Especial Carapils en vez de Avena.

Por lo tanto, mezclando hallazgos del modelo, como también conocimiento experto, se puede llegar a cuáles maltas utilizar. En resumen, serían las siguientes:

- Malta base Pale Ale.
- Malta Caramelo de 10 a 30L
- Malta Munich.
- Malta Especial Carapils.

Ahora, se sigue con la definición de los lúpulos. Ya tenemos Magnum en pequeñas cantidades para el Amargor, por lo tanto, queda definir los lúpulos de Sabor y Aroma. Para esto, vamos a revisar los lúpulos más significativos en cuanto a su impacto positivo en el gráfico. Estos son, Amarillo, Citra, Cascade y Galaxy. En este caso, la utilización de Cascade no sorprende, ya que es parte de muchas pale ale (en nuestras recetas se utiliza un 43.5% de las veces, ver anexo 8), de hecho, se ve que su leve uso impacta positivamente (más que negativamente), pero si se usa en mayores cantidades, el impacto es claramente positivo (aunque con menor soporte). En cambio, el lúpulo Galaxy solo lo vemos presente en un 10% de las recetas, y en este análisis, se ve que puede impactar positivamente, por lo que puede ser una oportunidad para elaborar una receta diferenciada de la mayoría con este lúpulo. En otro caso, el lúpulo citra podría ser esperable, siendo utilizado en el 30% de las recetas de american pale ale, y el amarillo un 22%. En este caso la combinación de lúpulos quedaría de la siguiente forma:

- Magnum
- Cascade
- Amarillo
- Citra
- Galaxy

Finalmente, otro hallazgo de este gráfico es la variable de proceso BoilTime que tiene relación con el tiempo de cocción de la receta. En este caso, dice que valores inclinados hacia los más altos impactan positivamente, por lo tanto, optamos por un tiempo mayor a 60 minutos de cocción, y en este caso lo dejaremos en 75 minutos. Esto puede ayudar a reducir algunos defectos en la cerveza final.

Después de este análisis, nos falta definir las cantidades de ingredientes. El primer acercamiento, es tomar los rangos en los que se mueven las recetas analizadas, y su relación con el target, de manera grafica. Estos análisis se hicieron utilizando los gráficos de los anexos 8 al 15, en donde cada variable tiene su comportamiento. Con solo observación obtenemos estos rangos para cada ingrediente:

Maltas:

- Malta base Pale Ale: Se puede ver una concentración de 0.15 a 0.20 kg/litro por lo tanto un rango indicado deberían estar entre estos números. Por conocimiento experto, esta malta debiese representar el 80% de la malta total.

- Malta Caramelo de 10 a 30L: Alta concentración entre los valores 0.01 a 0.02 kg x Litro. Se ve una relación positiva a medida que va aumentando, llegando hasta los 0.04 a 0.05 kg x litro.
- Malta Munich: Rangos disponibles de los 0.01 a 0.05. Fuera de esos rangos hay muy pocos datos como para considerar algo más alto.
- Malta Especial Carapils: Rangos desde los 0.01 a 0.1 tenemos disponible en los datos.

Lúpulos:

- Magnum: se observan tramos entre los 0.1 a 1.3 gramos por litro.
- Cascade: se observa una concentración de 0 a 5 gramos por litro, pero buenos resultados sobre 5 grms por litro (en gráfico).
- Amarillo: Se observa de 2 a 8 gramos por litro.
- Citra: Se observa de 1 a 12 gramos por litro, pero buenos resultados entre los 2 y 4 grms por litro.
- Galaxy: Se observa de 3 a 6 gramos por litro.

Con ayuda de los gráficos, se pudo determinar todos los rangos posibles, y ahora, ya se puede decidir sobre las cantidades exactas. Para esto se utilizó acotar estos rangos con las reglas de un árbol de decisión (ver Anexo 16), además de juicio experto.

Por ejemplo, en el árbol del Anexo 16, se propone un uso de Magnun menor a 0.565 grms x litro, además de usar una malta base Munich menor a 0.044 kg x litro, y malta caramelo menor a 0.011 kgs x litro. Con estas tres reglas tengo uno de los mejores valores obtenidos del árbol, con la mayor cantidad de recetas que caen en esa hoja (por ende, mayor validez).

Siguiendo la misma lógica, más algo de conocimiento experto, respetando ciertas ratios encontrados en la literatura (Daniels, 1998) y en guías de estándar cervecero (BJCP, 2021), se seleccionaron todas las variables para la receta, dejando el siguiente resultado para un lote de 23 litros.

TABLA 2 - RECETA RESULTANTE

Ingrediente	Cantidad Unitaria	Cantidad Total	Uso
Malta base Pale Ale	0.17 kg x Litro	4 Kg.	Macerado
Malta Munich	0.034 kg x Litro	0.8 Kg.	Macerado
Malta Cara 20	0.013 kg x Litro	0.3 Kg	Macerado
Malta Especial Carapils	0.013 kg x litro	0.3 Kg	Macerado
Magnum	0.55 grms x litro	12.65 grms	Amargor
Cascade	5 grms x litro	115 grms	Sabor y Aroma
Amarillo	2 grms x litro	46 grms	Aroma y Dryhop
Citra	2 grms x Litro	46 grms	Aroma y Dryhop
Galaxy	3 grms x Litro	69 grms	Aroma y Dryhop

Los modelos realizados, no incluyeron algunas variables como los perfiles de agua y uso de levadura, ya que en muchos casos las recetas no poseían esta información, por lo que, para el diseño de esta

receta, se optó por utilizar el perfil básico (buscado de internet) de un agua para una American Pale Ale, y un tipo de levadura clásico (US-05) para su elaboración.

Con esto ya tenemos una receta lista para su elaboración y posterior prueba.

Con este ejemplo, podemos extrapolar esta técnica a cualquier receta y verificar la hipótesis de poder obtener descubrimientos para la elaboración de recetas a partir de modelos de Machine Learning.

Para demostrar lo anterior, y cumplir de una forma más consistente los objetivos de este trabajo, es que se ejecutó la función para más estilos de receta, tomando en cuenta estilos que poseen un buen número de recetas para hacer analizadas. Para esta selección se utilizó la tabla 3, que se presenta a continuación.

TABLA 3 - ESTILOS DE CERVEZA Y CANTIDAD DE RECETAS

Style	Cantidad
American IPA	1547
American Pale Ale	747
Saison	280
American Amber Ale	247
Imperial IPA	234
Blonde Ale	222
Witbier	195
American Stout	173
Cream Ale	165
Sweet Stout	164
American Brown Ale	162
Specialty IPA: New England IPA	160
Russian Imperial Stout	151
Robust Porter	150

En concreto, se realizó el ejercicio para las primeras 10:

- American IPA
- American Pale Ale
- Saison
- American Amber Ale
- Imperial IPA
- Blonde Ale
- Witbier
- American Stout
- Cream Ale
- Sweet Stout

Los resultados de la aplicación sistemática de este modelo en varios estilos, como también los resultados generales del procedimiento y modelos generales, se discuten en el próximo capítulo de Resultados.

8. Resultados

En esta sección se presentan los principales resultados obtenidos, destacando su relevancia en relación con los objetivos planteados inicialmente. Se analiza, además, la replicabilidad del modelo en otras recetas de cerveza mediante la aplicación de la función descrita en la sección anterior, revisando los resultados clave de dicha implementación. Por último, se expone una arquitectura general resultante del proyecto, junto con los análisis complementarios realizados durante el desarrollo del trabajo que contribuyeron a la solución final. La estructura de esta sección es la siguiente:

1. Resultados generales y cumplimiento de objetivos.
2. Resultados para más de un estilo.
3. Resultado de arquitectura modular.
4. Otros análisis y resultados.

8.1. Resultados generales y cumplimiento de objetivos.

El objetivo general de este trabajo se basa en la aplicación de analítica avanzada en el proceso de generación de recetas, y en este sentido el proyecto logró implementar un modelo analítico basado en técnicas de Machine Learning, lo que permitió obtener hallazgos para una receta particular de una Cerveza estilo American Pale Ale utilizando herramientas avanzadas como PyCaret y Shap Values.

Dentro del contexto de los objetivos específicos, se puede decir que se logró cada uno de los puntos:

1. Se recopiló un conjunto de datos de 10,360 recetas a través de técnicas de web scraping y *crawling* en el sitio *Brewer's Friend*. El análisis exploratorio identificó patrones clave, como la relación entre ingredientes y métricas de calidad (por ejemplo, el impacto de ciertos lúpulos en el puntaje final). Además, se realizó una transformación de los datos para normalizar las unidades y reducir la dimensionalidad, lo que facilitó la extracción de hallazgos.
2. Se desarrolló un modelo predictivo para estimar el *score* de recetas sin evaluación previa, utilizando variables como el número de visualizaciones (*views*) y elaboraciones (*brews*). El modelo alcanzó un coeficiente R cuadrado de 0.92294, asegurando una estimación precisa del puntaje.
3. Se implementó un modelo de Machine Learning utilizando PyCaret. El algoritmo *Extra Trees Regressor* fue identificado como el más adecuado para predecir el puntaje de una receta en función de los ingredientes y parámetros del proceso, para una receta en particular, logrando resultados confiables y con sentido de negocio, adicionalmente se obtuvo un R cuadrado de 0.917, y un bajo error de solo un 4%, lo que se traduce en un modelo utilizable para los fines planteados en este trabajo. Finalmente, se realizó un procedimiento, el que sistemáticamente se puede aplicar a diferentes estilos de cerveza.
4. Los valores SHAP permitieron identificar los ingredientes y parámetros del proceso más relevantes en el diseño de recetas. Por ejemplo, se determinó el impacto positivo del lúpulo *Magnum* en pequeñas cantidades y de la malta *Pale Ale* en combinaciones

moderadas con otras maltas. Estos hallazgos y conclusiones se utilizaron para diseñar una receta.

5. Se diseñó una receta de una cerveza estilo “American Pale Ale” desde sus inicios utilizando los descubrimientos obtenidos para elaborar un lote de 23 litros y probar sus resultados de forma real.

8.2. Resultados para más de un estilo.

Con este resumen de resultados podemos determinar que los objetivos del trabajo se cumplieron particularmente para una receta, pero la pregunta clave es: ¿Son escalables? ¿Se puede aplicar a cualquier receta? Para responder esto, es que corrimos el modelo para los diez estilos que tenían una mayor cantidad de recetas para analizar. Los resultados de este análisis se muestran a continuación:

TABLA 4 - RESULTADOS MÚLTIPLES RECETAS


Receta	Cantidad	Modelo	R cuadrado	MAPE
American IPA	1547	Extra Trees Regressor	0.93	3.8%
American Pale Ale	747	Extra Trees Regressor	0.92	4.0%
Saison	280	Extra Trees Regressor	0.82	4.8%
American Amber Ale	247	Extra Trees Regressor	0.83	4.8%
Imperial IPA	234	Extra Trees Regressor	0.90	4.0%
Blonde Ale	222	Extra Trees Regressor	0.88	4.5%
Witbier	195	Extra Trees Regressor	0.77	6.2%
American Stout	173	Extra Trees Regressor	0.96	2.6%
Cream Ale	165	Extra Trees Regressor	0.93	3.0%
Sweet Stout	164	Extra Trees Regressor	0.88	7.4%

Con esta tabla, una de las primeras cosas que nos llama la atención, que, si bien Pycaret corrió para todos los estilos desde 0, para cada uno de ellos fue el Extra Trees Regressor, el que obtuvo los mejores resultados consistentemente. Esto nos indica, que es un modelo consistente para este tipo de ejercicios.

Lo segundo que llama la atención, es que se obtuvieron R cuadrados significativos para cada uno de los modelos, todos sobre el 0.82, llegando hasta 0.96 en el mejor de los casos. Adicionalmente, los errores estuvieron todos bajo el 8%, considerando que la escala es una evaluación de 1 a 5. De hecho, solo dos errores están por sobre el 5%, siendo la Witbier y la Sweet Stout los que lideran esta lista. Una cosa que, si se puede notar, es que a medida que tenemos menor cantidad de recetas, el error aumenta sutilmente. Esto lo podemos observar en el gráfico 8.

En general, podemos validar que este procedimiento nos sirve para obtener recomendaciones, ideas y conocimiento para apoyar el proceso de diseño de recetas de múltiples estilos de cerveza.

GRÁFICO 8 - R CUADRADO Y MAPE MÚLTIPLES RECETAS




8.3. Resultado de Arquitectura Modular

En cuanto a la arquitectura resultante de este proyecto, tenemos varios programas que nos permitieron llegar a los resultados presentados. Esta arquitectura está compuesta de lo siguiente:

1. *Scraping Brewer's Friend*: Código en Python que permite extraer información de recetas desde Brewer and Friends. Este código, valida que la receta no exista en la base de datos, y luego extrae solo los datos de recetas que no existan actualmente.
2. *BD Recipes*: Base de datos que contiene información sobre recetas, incluyendo todos los atributos ya mencionados anteriormente.
3. *Cálculo de Scoring*: Notebook de Python que permite calcular un score a partir de un modelo de Machine Learning, a partir de los Views y los Brews.
4. *Preparación de Datos y Machine Learning*: Notebook de Python que permite transformar los datos, y generar la función de análisis.
5. *Función de análisis*: En el mismo Notebook anterior, se encuentra como resultado final, una función de análisis, que, a partir de un estilo, puede generar los hallazgos y conclusiones necesarias para elaborar una receta.

Un diagrama de este esquema completo se puede revisar en la ilustración 3.

ILUSTRACIÓN 3 - DIAGRAMA DE ARQUITECTURA DE SOLUCIÓN



Uno de los beneficios de tener esta arquitectura, es el hecho de que, al ser modular, se puede evolucionar de forma independiente para continuar con cualquier trabajo sobre este en el futuro. Por ejemplo, obtener más recetas con el *Scrapping*, cambiar la forma de predecir los Score, incluir otras variables, mejorar la función de análisis, entre otros.

El otro beneficio de los resultados de este proceso es que ahora se tiene una base de datos de recetas, que puede ser utilizada para otros análisis dentro de la industria Cervecera.

8.4. Otros resultados y análisis.

En el proceso de desarrollo y análisis de este proyecto, se cuestionó el hecho de realizar un modelo de regresión o uno de clasificación. En este sentido luego de varios análisis extras, se decidió seguir con un modelo de regresión por varios motivos que se exponen a continuación:

1. Decisión de Umbral de clasificación: Al tener un target numérico, se hicieron distintas pruebas para transformar este en un target de clasificación (0 o 1, por ejemplo). Esto se realizó con un umbral que decide si la receta estaba evaluada con mayor de cierta nota, se transformaba en uno, en caso contrario 0. Encontrar este umbral no es un trabajo trivial, y con diferentes pruebas que se generaban, se encontraban resultados distintos, comparando métricas de los distintos modelos que se elaboraban. Para esto se utilizaron métricas como *accuracy* o curvas ROC. Adicionalmente, se analizaron matrices de confusión.
2. Funcionamiento de Pycaret y Shap Values: Al generar los distintos modelos en Pycaret, al intentar aplicar la metodología para obtener los Shap Values, no se encontraban las conclusiones directamente, si no que solo resultaban unas pocas variables las relevantes, dependiente del umbral utilizado. Esto genero un problema adicional con respecto a los resultados obtenidos por un modelo de regresión.
3. Prueba de Modelos sin Pycaret: Se probaron distintos modelos sin utilizar Pycaret (utilizando directamente distintos modelos de sklearn), haciendo grillas con distintos parámetros, pero ninguno de estos dio mejor resultado que los modelos de regresión descritos anteriormente. El mejor modelo con este approach fue un *Support Vector Machine*, con un 0.79 de *Accuracy*, pero tan solo un 0.57 de curva ROC. En el Anexo 17 se

muestra el resultado de los modelos de clasificación entrenados, como también sus resultados.

Finalmente, otro análisis paralelo, fue de utilizar variables de ingredientes como binarias, es decir, si utiliza cierto ingrediente, clasificarlo como uno, y si no como cero, independiente de la cantidad de ingrediente utilizado. Con este análisis, se obtuvieron resultados no tan distintos al modelo principal planteado, pero era más difícil obtener hallazgos y conclusiones para ver cantidades y elaborar la receta final.

9. Conclusiones

El presente trabajo ha demostrado que es posible aplicar analítica avanzada y tecnología en el diseño de recetas de cerveza artesanal, logrando obtener una receta de cerveza en menor tiempo tal vez que los que se requieren con algunos métodos tradicionales basados en prueba y error. A través de la implementación de modelos de Machine Learning, se alcanzaron resultados contundentes que no solo validan la hipótesis planteada, sino que también muestran la escalabilidad y aplicabilidad del enfoque. Si bien hay que probar el resultado final de la cerveza, y la misma evaluarla en un panel de expertos, queda demostrado, que, a partir de técnicas de analítica avanzada, si se puede construir una receta de cerveza.

El desarrollo de este proyecto, desde la extracción de datos mediante técnicas de web scraping hasta la obtención de resultados tangibles en el diseño de una receta, refuerza su carácter integral. La receta diseñada, estilo *American Pale Ale*, fue elaborada como un producto real, validando así la utilidad práctica de los modelos analíticos y confirmando que los hallazgos obtenidos pueden traducirse en un producto final de alta calidad.

El análisis de datos desempeñó un rol fundamental en este trabajo, evidenciando su potencial para apoyar la toma de decisiones estratégicas. En este caso particular, permitió identificar combinaciones óptimas de ingredientes y procesos, mostrando cómo las herramientas de analítica pueden ser un puente efectivo entre el conocimiento técnico y las decisiones basadas en datos.

En cuanto a los resultados obtenidos, el modelo predictivo basado en *Extra Trees Regressor* mostró un desempeño destacado, con un R cuadrado de 0.92 y un error porcentual medio absoluto (MAPE) de 4%. Estos indicadores no solo validan la calidad del modelo, sino que también destacan su capacidad para generalizar y adaptarse a diferentes estilos de cerveza, como se demostró al aplicar el modelo a múltiples estilos con resultados consistentes.

Además, la creación de funciones específicas para este tipo de análisis demostró ser una estrategia clave, ya que otorgó dinamismo, extensibilidad y flexibilidad al proyecto. Estas funciones permiten iterar sobre diferentes estilos y escenarios de diseño, mejorando así el alcance y las posibilidades del modelo analítico.

Próximos Pasos

El trabajo realizado abre múltiples oportunidades para futuras investigaciones y aplicaciones prácticas, entre las cuales se destacan:

1. **Ampliación de la base de datos:** Realizar *scraping* de más recetas para mejorar aún más los resultados del modelo y reducir la necesidad de un balanceo drástico de datos.
2. **Modelo avanzado de lúpulos:** Considerar las cantidades específicas de cada lúpulo en las diferentes etapas del proceso (amargor, sabor y aroma) para un análisis más granular. Con esto, podemos facilitar el diseño de estrategias de lupulado en la cerveza, y encontrar patrones que permitan sobresalir en este ámbito.
3. **Agrupación de ingredientes:** Clasificar lúpulos según sus características más relevantes, como perfiles de sabor, aroma y alfa-ácidos, y con esto, obtener mayor información, o estar más cubierto frente al reemplazo de ingredientes, por ejemplo, si no se cuenta con un lúpulo

en particular, se puede llegar a utilizar alguno que tenga las mismas características de forma más dinámica.

4. **Función evaluativa:** A partir de la función de análisis elaborada en este trabajo, se puede llegar a diseñar una función que permita evaluar recetas ya realizadas, la cual pueda ejecutarse desde una API e integrarse en otros sistemas. Con esto, se puede evaluar cada receta que se requiera realizar, para ver que puntaje podría obtener, y además, recomendar posibles cambios que podría tener la receta para mejorar su puntuación.
5. **Optimización basada en costos:** Se podría ampliar los horizontes de este trabajo desarrollando analítica prescriptiva con un modelo que encuentre recetas óptimas a nivel de score, incluyendo restricciones presupuestarias con los costos asociados a los ingredientes involucrados. Con esto se podría obtener recetas optimas en cuanto a calidad y costos.
6. **Análisis de otros ingredientes:** Extender el análisis a perfiles de agua y tipos de levadura, elementos que no fueron considerados en esta tesis debido a la falta de datos específicos, pero que son clave en el diseño integral de una receta.
7. **Extensión a otras fuentes de informacion:** Al validar la hipótesis y concluir con los objetivos detrás de este proyecto, se pueden llegar a realizar ejercicios similares, como por ejemplo conseguir feedback de cliente en forma de score para evaluar las recetas elaboradas, o generar *focus group* con algunas cervezas para obtener a partir de estos resultados otra forma de generar un score de cerveza, y con esto, poder optimizar la cerveza elaborada.

Este proyecto ha sentado las bases para un uso más amplio de la analítica en la industria cervecera, mostrando su potencial para apoyar procesos tradicionales con estrategias y analíticas basadas en datos. La integración de estas técnicas representa un avance significativo en la búsqueda de cervezas excepcionales de manera eficiente y sostenible.

Referencias

- Adam, H. D. (2004). *Alemania Patente n° EP 1 414 937 B1*.
- Agencia Argentina de inversiones y comercio internacional. (2023). *Investigacion de Mercado Chile de Cerveza Artesanal*. Argentina.
- Ali, M. (April de 2020). *Pycaret*. Obtenido de PyCaret: An open source, low-code machine learning library in Python: <https://pycaret.org/>
- BJCP. (2021). 2021 BEER STYLE GUIDELINES.
- Brewer's Friends. (Septiembre de 2024). *Brewer's Friends Homebrew Beer Recipes*. Obtenido de <https://www.brewersfriend.com/>
- Buchanan, T. (Febrero de 2024). *Species X brews beer with AI-generated recipes*. Obtenido de Species X brews beer with AI-generated recipes: <https://www.axios.com/local/columbus/2024/02/13/species-x-brewery-ai-beer-recipes-columbus-ohio>
- cervezodromo. (2024). *Tabla de Lupulos Sustitutos*. Obtenido de Tabla de Lupulos Sustitutos: <https://cervezodromo.es/lupulo/sustitutos/>
- Daniels, R. (1998). *Designing Great Beers: The Ultimate Guide to Brewing Classic Beer Styles*. Brewers Publications.
- EMR Claight. (2024). *Mercado Global de Cerveza Artesanal*. Obtenido de Informes de Expertos: <https://www.informesdeexpertos.com/informes/mercado-de-cerveza-artesanal>
- Harvard. (Noviembre de 2019). *IntelligentX: Changing the world, one beer at time*. Obtenido de Harvard Digital Innovation and Transformation: <https://d3.harvard.edu/platform-digit/submission/intelligentx-changing-the-world-one-beer-at-a-time/>
- Hasan, M. (2023). Understanding Model Predictions: A Comparative Analysis of SHAP and LIME on Various ML Algorithms. *Journal of Scientific and Technological Research*, 17-26.
- Lundberg, S. (2018). *SHAP Documentation*. Obtenido de https://shap.readthedocs.io/en/latest/generated/shap.KernelExplainer.html?utm_source=chatgpt.com
- Lundberg, S., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *Conference on Neural Information Processing Systems*. doi:10.48550/arXiv.1705.07874
- Lundberg, S., Erion, G., & Lee, S.-I. (2019). Consistent Individualized Feature Attribution for Tree Ensembles. *ICML Workshop on Human Interpretability in Machine Learning (WHI 2017)*.
- Molnar, C. (2020). *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*. Leanpub.
- Mosher, R. (2017). *Tasting Beer: An Insider's Guide to the World's Greatest Drink*. Storey Publishing.

Palmer, J. (2017). *How to Brew*. Brewers Publications.

Rate Beer. (2024). *RATE BEER*. Obtenido de RATE BEER: <https://www.ratebeer.com/ratebeerbest/>

Salazar Tijerino, M. B., San Martin-Gonzalez, M., Velasquez Domingo, J. A., & Huang, J.-Y. (2023). Life Cycle Assessment of Craft Beer Brewing at Different Scales on a Unit Operation Basis. *Sustainability* 15, no 14: 11416. doi:<https://doi.org/10.3390/su151411416>

Schreurs, M., Piampongsant, S., Roncoroni, M., Cool, L., Herrera-Malaver, B., & Vanderaa, C. (2024). Predicting and improving complex beer flavor through machine learning. *Nat Commun*, 15(2368). doi:<https://doi.org/10.1038/s41467-024-46346-0>


Statista. (30 de Julio de 2024). *La industria cervecera global - Datos Estadísticos*. Obtenido de La industria cervecera global - Datos Estadísticos: <https://es.statista.com/temas/11242/la-industria-de-la-cerveza-en-el-mundo/#:~:text=El%20tama%C3%B1o%20del%20mercado%20cervecero,los%20797.000%20millones%20en%202032.>

UNC Environmental Finance Center. (Junio de 2024). *Brewing a Greener Future: Craft Beer's Enviromental Revolution*. Obtenido de <https://efc.sog.unc.edu/brewing-a-greener-future-craft-beers-environmental-revolution/>

Vadar, D., Moharekar, D., & Pol, D. (2024). COMPARATIVE ANALYSIS OF AUTOMATED MACHINE LEARNING LIBRARIES: PYCARET, H2O, TPOT, AUTO-SKLEARN, AND FLAML. *International Journal of Scientific Research in Engineering and Management (IJSREM)*, 08(11), 1-8. doi:10.55041/IJSREM39119

Anexos

Anexo 1 – Base de datos construida a partir de *Scraping*.



Anexo 2 – Página principal de Recetas de Brewer Friends.

← → ↻ ↺ brewersfriend.com/homebrew-recipes/ 🔍 ☆ 📄 📌 📁 📂 📅 📆 📇 📈 📉 📊 📋 📌 📍 📎 📏 📐 📑 📒 📓 📔 📕 📖 📗 📙 📚 📛 📜 📝 📞 📟 📠 📡 📢 📣 📤 📥 📦 📧 📨 📩 📪 📫 📬 📭 📮 📯 📰 📱 📲 📳 📴 📵 📶 📷 📸 📹 📺 📻 📼 📽 📾 📿 📰 📱 📲 📳 📴 📵 📶 📷 📸 📹 📺 📻 📼 📽 📾 📿

Nueva pestaña teoría - Music Theor... teoría - Espacio ded... SEM SEO y Posicion... IBM - Coremetrics (s... Web site, online ana... CAPACITACIÓN Y F... Analisis Web | Le tea... Google Analytics Portalinmobiliario.c... Music Production, A...

Brew your best beer EVER. Save 10% on Brewer's Friend Premium today. Use code TAKE10. [SIGN UP](#)

Welcome Guest! [LOGIN](#) [SIGN UP](#)

COMMUNITY • TOOLS • SEARCH • BROWSE • MY BREWING • LEARN • NEW BEER RECIPE • SHOP

10% BREWER'S FRIEND OFF PREMIUM [USE CODE TAKE10](#) [SIGN UP](#)

Home » Homebrew Beer Recipes

Homebrew Beer Recipes

Browse our growing list of 300,000+ homebrew beer recipes. Sort by beer style, batch size, ABV and more for all-grain, extract or partial mash brewing.

Browse All Recipes or explore by brewing method: All-grain | Extract | BIAB | Partial Mash

Title	Style	Size	OG	FG	ABV	IBU	Color	Views	Brewed	Rating
📄 Avg. Perfect Northeast IPA (NEIPA)	Specialty IPA, New England IPA	5.75 Gallons	1.062	1.013	6.5	59.25	5.2 🍷	594K	693	★★★★★
📄 Sierra Nevada Pale Ale Clone	American Pale Ale	6.5 Gallons	1.055	1.013	5.88	39.79	5 🍷	533.2K	961	★★★★★
📄 Vanilla Cream Ale	Cream Ale	5.75 Gallons	1.055	1.013	5.48	19.44	4.83 🍷	448.1K	211	★★★★★
📄 Zombie Dust Clone - ALL GRAIN	American IPA	6 Gallons	1.061	1.016	5.94	42.42	5.5 🍷	362.7K	343	★★★★★
📄 Russian River Pilsy The Elder (original)	Imperial IPA	6 Gallons	1.072	1.018	7.09	232.89	4.89 🍷	332.1K	89	★★★★★
📄 Spotted Cow (New Giarus Spotted Cow Clone)	Cream Ale	5.5 Gallons	1.054	1.014	5.36	21.27	5.94 🍷	327.8K	81	★★★★★
📄 Chocolate Vanilla Porter	Robust Porter	6 Gallons	1.06	1.016	5.77	31.36	34.76 🍷	316.3K	70	★★★★★
📄 Southern Tier Punking Clone	Holiday/Winter Special Spiced Beer	5.5 Gallons	1.083	1.021	6.16	50.22	15.64 🍷	303.9K	113	★★★★★
📄 Zombie Dust Clone - EXTRACT	American IPA	5 Gallons	1.063	1.016	6.16	70.18	8.98 🍷	286.8K	191	★★★★★
📄 Mango Habanero IPA	Imperial IPA	5.5 Gallons	1.088	1.018	8.88	98.09	8.55 🍷	297.4K	92	★★★★★
📄 Belle Brugg Belgisk Blond 50 L	Belgian Blond Ale	50 Litres	1.062	1.012	6.52	18.54	4.35 🍷	279.6K	36	★★★★★
📄 Tank 7 Clone	Session	5.5 Gallons	1.073	1.019	7.65	41.11	6.25 🍷	271.8K	44	★★★★★
📄 White IPA	American IPA	10 Gallons	1.064	1.017	6.2	55.96	3.91 🍷	268K	54	★★★★★
📄 Pilsner Unquell BYO Clone	Bohemian Pilsener	11 Gallons	1.051	1.013	4.92	36.45	3.61 🍷	265.4K	37	★★★★★
📄 Bella Two Hearted Clone	American IPA	5.5 Gallons	1.073	1.018	7.14	63.62	8.1 🍷	263.8K	84	★★★★★

Anexo 3 – Parte principal de la receta

Brew your best beer EVER. Save 10% on Brewer's Friend Premium today. Use code TAKE10. [SIGN UP](#)



Brewer's Friend Brewing With Total Confidence

COMMUNITY TOOLS SEARCH BROWSE MY BREWING LEARN NEW BEER RECIPE SHOP

Welcome Guest!
[LOGIN](#) [SIGN UP](#)

View Recipe

RECIPE TOOLS EXPORT PRINT

Avg. Perfect Northeast IPA (NEIPA)





kcq101

Beer Stats

Method: All Grain
Style: **Specialty IPA: New England IPA**
Boil Time: 60 min
Batch Size: 5.75 gallons (fermentor volume)
Pre Boil Size: 7.5 gallons
Pre Boil Gravity: 1.048 (recipe based estimate)
Post Boil Gravity: 1.062 (recipe based estimate)
Efficiency: 70% (brew house)
Source: Kevin Quinn - (Beer Advocate Crowd-Source)

Rating: ★★★★★ 4.76 (38 Reviews)
Hop Utilization: 88%
Calories: 197.1 (Per 12oz)
Carbs: 18.3 g (Per 12oz)

Created: Tuesday May 31st 2016

Similar Recipes

 **NEIPA #11: Voss Kveik**
by bradyt88
OG: 1.063 FG: 1.011 ABV: 6.8%
IBU: 53

 **Golden Haze IPA**
by Nebula Brewing
OG: 1.054 FG: 1.009 ABV: 6.0%
IBU: 59

 **NE Pale Ale**
by pietrok22
OG: 1.078 FG: 1.021 ABV: 7.6%
IBU: 56

Original Gravity: 1.062	Final Gravity: 1.013	ABV (standard): 6.5%	IBU (tinseth): 59.3	SRM (morey): 5.2 	Mash pH: n/a	Cost \$: n/a
-------------------------	----------------------	----------------------	---------------------	--	--------------	--------------



10% OFF BREWER'S FRIEND PREMIUM
Unlimited Recipes & Brews, Tilt/Data Streaming, No ads!

USE CODE **TAKE10**
[SIGN UP](#)

Anexo 4 – Sección de Ingredientes dentro de página de recetas.

Fermentables

Amount	Fermentable	Cost	PPG	°L	Bill %
10.75 lb	US - Pale 2-Row		37	1.8	77%
1.40 lb	American - Wheat		38	1.8	10%
1.40 lb	Flaked Oats		33	2.2	10%
0.42 lb	Honey Malt		37	25	3%
13.97 lbs / \$ 0.00					

Hops

Amount	Variety	Cost	Type	AA	Use	Time	IBU	Bill %
1 oz	Citra		Pellet	12.6	Boil	10 min	13.55	7.3%
1 oz	Galaxy		Pellet	15.6	Boil	10 min	16.77	7.3%
1.50 oz	Citra		Pellet	12.6	Whirlpool at 170 °F	15 min	9.23	10.9%
1.50 oz	Galaxy		Pellet	15.6	Whirlpool at 170 °F	15 min	11.43	10.9%
1.50 oz	Mosaic		Pellet	11.3	Whirlpool at 170 °F	15 min	8.28	10.9%
1 oz	Citra		Pellet	12.6	Dry Hop	7 days		7.3%
1.50 oz	Galaxy		Pellet	15.6	Dry Hop	7 days		10.9%
1 oz	Mosaic		Pellet	11.3	Dry Hop	7 days		7.3%
1.25 oz	Citra		Pellet	12.6	Dry Hop	3 days		9.1%
1.50 oz	Galaxy		Pellet	15.6	Dry Hop	3 days		10.9%
1 oz	Mosaic		Pellet	11.3	Dry Hop	3 days		7.3%
13.75 oz / \$ 0.00								

☐ Show Summary View

Mash Guidelines

Amount	Description	Type	Start Temp	Target Temp	Time
		Infusion	--	152 °F	60 min
Starting Mash Thickness: 1.25 qt/lb					

Anexo 5 – Web para ingredientes

Brew your best beer EVER. Save 10% on Brewer's Friend!



Brewer's Friend Brewing With Total Confidence

COMMUNITY • TOOLS • SEARCH • BROWSE • MY BREWING • LEARN




Home » Fermentables » US - Pale 2-Row

US - Pale 2-Row

Country:	Category:	Type:	PPG:	Color:	Recipes:
United States	Grain	Base malt	37	1.8 °L	55,262



Anexo 6 – Relación de Views vs score.





Anexo 7 – Tabla resultado de Pycaret para Elaboracion de Score.

	Model	MAE	MSE	RMSE	R2	RMSLE	MAPE	TT (Sec)
et	Extra Trees Regressor	0.1254	0.1512	0.3858	0.9294	0.0808	0.0282	0.0180
rf	Random Forest Regressor	0.1741	0.2040	0.4486	0.9045	0.0997	0.0391	0.0260
dt	Decision Tree Regressor	0.1280	0.2133	0.4589	0.9004	0.1056	0.0288	0.0040
knn	K Neighbors Regressor	0.2760	0.3655	0.6040	0.8297	0.1342	0.0611	0.0060
lightgbm	Light Gradient Boosting Machine	0.4064	0.3764	0.6114	0.8247	0.1402	0.1330	0.0560
gbr	Gradient Boosting Regressor	0.7040	0.7481	0.8643	0.6518	0.2287	0.3161	0.0150
ada	AdaBoost Regressor	1.0934	1.6846	1.2975	0.2178	0.3693	0.5870	0.0080
huber	Huber Regressor	1.2372	2.0948	1.4469	0.0273	0.4084	0.6751	0.0060
br	Bayesian Ridge	1.2365	2.0963	1.4474	0.0266	0.4085	0.6742	0.0050
ridge	Ridge Regression	1.2370	2.0963	1.4474	0.0266	0.4084	0.6743	0.0050
lar	Least Angle Regression	1.2370	2.0963	1.4474	0.0266	0.4084	0.6743	0.0050
lr	Linear Regression	1.2370	2.0963	1.4474	0.0266	0.4084	0.6743	0.0050
en	Elastic Net	1.2345	2.1053	1.4505	0.0224	0.4094	0.6749	0.0050
lasso	Lasso Regression	1.2472	2.1319	1.4597	0.0099	0.4113	0.6798	0.0050
llar	Lasso Least Angle Regression	1.2472	2.1319	1.4597	0.0099	0.4113	0.6798	0.0050
omp	Orthogonal Matching Pursuit	1.2523	2.1433	1.4637	0.0046	0.4121	0.6818	0.0040
dummy	Dummy Regressor	1.2583	2.1617	1.4699	-0.0039	0.4142	0.6875	0.0040
par	Passive Aggressive Regressor	4.7810	347.2371	14.1603	-158.9733	0.9147	1.7487	0.0050



Anexo 8 – Gráfico de uso de lúpulo Cascade y su relación con Score




Anexo 9 – Gráfico de uso de lúpulo Magnum y su relación con Score




Anexo 10 – Gráfico de uso de lúpulo Citra y su relación con Score




Anexo 11 – Gráfico de uso de lúpulo Galaxy y su relación con Score





Anexo 12 – Gráfico de uso de Malta base Pale y su relación con Score





Anexo 13 – Gráfico de uso de Malta Munich y su relación con Score




Anexo 14 – Gráfico de uso de Malta Caramelo 10-30L y su relación con Score



Anexo 15 – Gráfico de uso de Malta Especial y su relación con Score



Anexo 16 – Muestra de Árbol de decisión




Anexo 17 – Resultados de ejercicio para un Modelo de Clasificación.


Tabla Resumen

	Model	Accuracy	ROC AUC
0	Logistic Regression	0.575893	0.482892
1	Arbol	0.575893	0.482892
2	KNN	0.687500	0.465015
3	Random Forest	0.816964	0.401238
4	Red Neuronal	0.754464	0.477322
5	Support Vector Machine	0.794643	0.560062


Resultados de KNN para diferentes parámetros.




Resultados para Random Forest para diferentes parámetros




Resultados de redes neuronales para diferentes parámetros



Resultados de Support Vector Machine para diferentes parámetros



Anexo 18 – Grafico de predicción versus valores reales de score a partir de Views and Brews.



Anexo 19 – Grafico de predicción versus valores reales de score en el análisis de la American Pale Ale.

