



UNIVERSIDAD
DE CHILE

Universidad de Chile
Facultad de Economía y Negocios
Escuela de Postgrado

**Modelamiento Predictivo de Aportes y Rescates de Fondos
Mutuos de Renta Fija Local**

Actividad Formativa Equivalente
Para Optar al Grado de Magíster de Analítica de Negocios

Juan Francisco Gajardo

Profesor Guía
Sebastian Maldonado

Santiago, Chile

2025

Indice

Resumen Ejecutivo	5
Executive Summary	6
1. Introducción	8
2. Planteamiento y Formulación del Problema	10
3. Hipótesis.....	11
4. Objetivos	12
4.1 Objetivo General	12
4.2 Objetivos Específicos	12
5. Marco Teórico	13
5.1 Mercados Financieros y Fondos Mutuos de Renta Fija	13
5.2 Flujo de Aporte y Rescates en Fondos Mutuos de Renta Fija	18
5.3 Riesgos Asociados a Fondos de Renta Fija	18
5.4 Predicción y Modelos de Series Temporales Asociado a Finanzas:	20
Estacionariedad	21
Ruido blanco	21
Tendencia, estacionalidad y ciclos	21
ACF y PACF	22
5.5 Modelos ARIMA, SARIMA y SARIMAX.....	22
5.6 Aplicación de modelos de series temporales en finanzas	24
5.7 Limitaciones de los modelos tradicionales.....	24
5.8 Modelos de Machine Learning Utilizados	25
Decision Tree	26
Random Forest	27
XGBoost (Extreme Gradient Boosting).....	27
Support Vector Machine (SVM).....	28
LSTM (Long Short-Term Memory).....	29
GRU (Gated Recurrent Unit)	30
6. Descripción del enfoque de solución	32
6.1 Carga y Preprocesamiento de Datos.....	33

6.2 Limpieza de Datos y Filtrado por Categorías	33
6.3 Análisis Descriptivo	34
6.4 Generación de Gráficos de Análisis Exploratorio	34
6.5 Pruebas de Normalidad.....	34
6.6 Descomposición de Series Temporales	35
6.7 Modelado Predictivo con ARIMA y SARIMAX.....	36
6.8 Evaluación y Comparación de Modelos.....	36
6.9 Preprocesamiento de Datos para Modelos de Machine Learning	37
6.10 Escalado de Datos y Creación de Secuencias Temporales	37
6.11 Entrenamiento de Modelos GRU y LSTM	37
6.12 Entrenamiento de Modelos Tradicionales de Machine Learning	38
6.13 Evaluación de Modelos con Métricas de Rendimiento.....	38
6.14 Generación de Resultados y Discusiones	38
7. Resultados	40
7.1 %Aporte/Rescates y Distribución de Rentabilidades	40
7.2 Evaluación de Normalidad, Estacionariedad y Estructura Temporal de la Variable Objetivo.....	44
7.3 Autocorrelación	45
7.4 Análisis de la Descomposición de Series de Tiempo por Categoría de Fondo....	46
7.5 Conclusiones generales de Estacionaridad	51
7.6 Discusión de Modelos ARIMA y SARIMAX.....	51
7.7 Análisis con variables Exógenas:	55
7.8 Conclusiones de Variables Exógenas.....	57
7.9 Resultados de Modelos de Machine Learning	58
Modelo GRU:	58
Modelo SVM:.....	59
Modelo Decision Tree:.....	59
Modelo Random Forest:.....	60
Modelo XGB:.....	61
Modelo LSTM:.....	61
7.10 Discusión modelo de Machine Learning	63
8. Conclusión	64

9. Referencias Bibliográficas	66
10. Anexos	68
Estadística Descriptiva	68
Gráficos Boxplot.....	69

Resumen Ejecutivo

El mercado de renta fija en Chile juega un papel fundamental en el sistema financiero, ofreciendo a los inversionistas acceso a una amplia variedad de instrumentos de deuda. Comprender y anticipar los flujos de aportes y rescates en fondos mutuos de renta fija es clave para mejorar la gestión de activos, la planificación de emisiones de deuda y oportunidades de inversión. Este trabajo desarrolla y evalúa un modelo predictivo que busca anticipar estos flujos a partir de datos históricos de aportes y rescates y sus respectivas rentabilidades pasadas.

El estudio aplicó un enfoque mixto, combinando modelos estadísticos (ARIMA y SARIMAX) y técnicas de *machine learning* (GRU, LSTM, Decision Tree, Random Forest, SVM y XGBoost), evaluando el desempeño predictivo para distintos horizontes temporales y categorías de fondos.

Los resultados de los modelos ARIMA mostraron que, en general, estos capturan bien la media histórica de los flujos, tuvieron limitaciones para anticipar cambios estructurales, especialmente en fondos de corto plazo (<365 días), caracterizados por alta volatilidad y bandas de confianza amplias. En contraste, los fondos de mayor duración (>365 días), denominados en UF o en pesos, exhibieron menor dispersión histórica, permitiendo predicciones más estables y con menor incertidumbre.

El modelo SARIMAX superó consistentemente a ARIMA en casi todas las categorías, al incorporar variables exógenas como las rentabilidades pasadas. Por ejemplo, en fondos de duración corta, el RMSE se redujo de 0.059 (ARIMA) a 0.0014 (SARIMAX) para el horizonte de 1 día, mostrando un ajuste significativamente más preciso. En categorías con horizontes largos en UF (>3 años), SARIMAX logró representar mejor las tendencias de mediano plazo y moderar la incertidumbre, validando su superioridad donde las variables externas influyen más marcadamente.

En la evaluación de modelos de *machine learning*, XGBoost destacó como la herramienta más robusta para la predicción multihorizonte de flujos. Mostró bajo error promedio y alta estabilidad en fondos de deuda de mediano y largo plazo, con rentabilidades promedio proyectadas entre 0.43 y 0.50 para fondos <365 días en pesos, y cerca de 0.49 en fondos >365 días en pesos. Modelos como Random Forest y Decision Tree también ofrecieron un desempeño sólido y consistente, especialmente en fondos con baja volatilidad. Redes neuronales como GRU y LSTM demostraron buena capacidad en series más largas y estables, aunque con desempeño más variable en series altamente volátiles. SVM, por su parte, fue más efectivo en fondos de corto plazo y categorías con menor complejidad estructural.

En conjunto, los resultados confirman que la elección del modelo predictivo debe ser sensible al perfil del fondo. Mientras ARIMA puede servir como línea base para capturar inercia histórica, SARIMAX mejora la capacidad predictiva al incluir factores de rentabilidad. Para fines operacionales y estratégicos, se recomienda el uso de modelos

de *machine learning* como XGBoost, dada su capacidad de adaptarse a diferentes estructuras de fondos y de reducir de manera consistente el error de predicción.

Este trabajo entrega una herramienta concreta para anticipar flujos de aportes y rescates en fondos mutuos de renta fija, contribuyendo a la toma de decisiones informadas en la asignación de activos, estrategias de emisión de deuda y oportunidades de inversión. Su implementación permitirá a bancos y gestores de fondos reducir riesgos asociados a la liquidez y optimizar la gestión financiera en un mercado dinámico y sensible a factores macroeconómicos, así como también a múltiples inversores en la búsqueda de oportunidades de compra de cartera de renta fija.

Executive Summary

The fixed-income market in Chile plays a fundamental role in the financial system by providing investors with access to a broad range of debt instruments. Understanding and anticipating the contribution and redemption flows in fixed-income mutual funds is key to improving asset management, debt issuance planning, and investment opportunities. This work develops and evaluates a predictive model aimed at forecasting these flows using historical data on contributions, redemptions, and their corresponding past returns.

The study applied a mixed approach, combining statistical models (ARIMA and SARIMAX) with machine learning techniques (GRU, LSTM, Decision Tree, Random Forest, SVM, and XGBoost), assessing predictive performance across different time horizons and fund categories.

Results from the ARIMA models generally showed good ability to capture the historical mean of flows but exhibited limitations in anticipating structural changes, especially in short-term funds (<365 days) characterized by high volatility and wide confidence intervals. In contrast, longer-duration funds (>365 days), denominated in UF or Chilean pesos, exhibited lower historical dispersion, enabling more stable predictions with reduced uncertainty.

The SARIMAX model consistently outperformed ARIMA across nearly all categories by incorporating exogenous variables such as past returns. For example, in short-duration funds, the RMSE decreased from 0.059 (ARIMA) to 0.0014 (SARIMAX) for the 1-day horizon, indicating a significantly more accurate fit. In categories with long-term horizons in UF (>3 years), SARIMAX better captured medium-term trends and reduced uncertainty, validating its superiority where external variables have a stronger influence.

In the evaluation of machine learning models, XGBoost emerged as the most robust tool for multi-horizon flow prediction. It delivered low average error and high stability in medium- and long-term debt funds, with projected average returns ranging between 0.43 and 0.50 for funds <365 days in pesos, and around 0.49 for funds >365 days in pesos. Models such as Random Forest and Decision Tree also demonstrated solid and

consistent performance, particularly in funds with lower volatility. Neural networks like GRU and LSTM showed good capacity in longer and more stable series, though with more variable performance in highly volatile series. SVM, for its part, was more effective in short-term funds and categories with lower structural complexity.

Overall, the results confirm that the choice of predictive model should be sensitive to the fund profile. While ARIMA can serve as a baseline for capturing historical inertia, SARIMAX improves predictive power by including return factors. For operational and strategic purposes, the use of machine learning models such as XGBoost is recommended, given their ability to adapt to different fund structures and consistently reduce prediction error.

This work provides a concrete tool for anticipating contribution and redemption flows in fixed-income mutual funds, supporting informed decision-making in asset allocation, debt issuance strategies, and investment opportunities. Its implementation will enable banks and fund managers to reduce liquidity-related risks and optimize financial management in a dynamic market that is sensitive to macroeconomic factors, as well as to multiple investors seeking opportunities to purchase fixed-income portfolios.

1. Introducción

Actualmente, el mercado de renta fija en Chile constituye un componente esencial del sistema financiero local. Dentro de este mercado, los instrumentos de deuda representan una de las principales formas de inversión¹. Entre ellos se incluyen los Pagarés Descontables del Banco Central (PDBC), Bonos de la Tesorería denominados en UF y pesos (BTU y BTP), Bonos Bancarios y Corporativos, así como instrumentos de intermediación financiera como depósitos a plazo en UF, dólares y pesos, y efectos de comercio.

La característica principal de estos instrumentos es que los inversionistas prestan dinero a cambio de una rentabilidad previamente establecida¹. Este tipo de activos es utilizado tanto por empresas como por gobiernos para financiar proyectos y operaciones, ofreciendo a los inversionistas una fuente de ingresos fija y predecible.

En Chile, los fondos mutuos de renta fija local desempeñan un rol destacado dentro del mercado de inversión, facilitando a los inversionistas el acceso a una amplia gama de instrumentos de deuda a través de vehículos de inversión colectiva². Según el Banco Central de Chile (2024), al cierre del primer trimestre los Fondos Mutuos y de Inversión representaron el 12,8 % del stock total de títulos de deuda en el mercado local, mientras que Bancos y Cooperativas alcanzaron el 17,7 %, Fondos de Pensiones el 25,1 % y Compañías de Seguros el 7,5 %³. Este contexto resalta la importancia de los fondos mutuos en la diversificación y democratización de las inversiones en instrumentos de deuda, permitiendo tanto a inversionistas individuales como institucionales acceder a una participación en el mercado de renta fija local.

Dado que estos fondos pertenecen a actores relevantes del mercado local, es fundamental entender los aportes y rescates de fondos mutuos en el mercado de renta fija chilena, ya que estos movimientos reflejan las expectativas de los inversionistas sobre las condiciones macroeconómicas y las tasas de interés. Los rescates masivos pueden generar fluctuaciones en la demanda de instrumentos de renta fija, afectando su precio y rendimiento, mientras que los aportes indican confianza en el mercado y pueden incrementar la demanda.

Además, los aportes y rescates impactan la estabilidad de los fondos mutuos, ya que los rescates obligan a los gestores a liquidar activos, lo que puede alterar la oferta y la demanda de títulos de deuda. En un mercado financiero clave como el chileno, entender estos flujos es esencial para anticipar movimientos del mercado, tomar decisiones

¹ CFA Institute. (2015). *Fixed Income Analysis* (3rd ed.). Wiley.

² Asociación de Fondos Mutuos de Chile. (2024). Informe de la industria. Disponible en: <https://www.afm.cl/>

³ Banco Central de Chile. (2024). Estadísticas del mercado de deuda (Boletín trimestral). Disponible en: <https://si3.bcentral.cl/Siete/secure/cuadros/arboles.aspx>

informadas y garantizar la estabilidad económica, siendo crucial para reguladores como el Banco Central de Chile y la Comisión para el Mercado Financiero⁴.

Predecir estos movimientos puede ser clave para tomar mejores decisiones para diferentes actores del mercado en la economía chilena: por ejemplo, para un banco, saber cuándo es mejor emitir deuda; para una empresa corporativa, estimar el apetito del mercado por sus bonos y la duración ideal de la emisión; o para un banco de inversión, definir el momento oportuno para aumentar su posición en cartera de renta fija.

⁴ Comisión para el Mercado Financiero (CMF). (sitio oficial). Disponible en: <https://www.cmfchile.cl>

2. Planteamiento y Formulación del Problema

El problema que surge al analizar el mercado de renta fija chileno, específicamente los movimientos de AUM (Activos Bajo Gestión) de los fondos mutuos de renta fija local, radica en la incertidumbre y volatilidad que pueden generar los flujos de aportes y rescates. Estos movimientos afectan tanto el precio de los instrumentos de deuda como la confianza de los inversionistas.

Para un banco, entender los momentos adecuados para emitir deuda es crucial, ya que un flujo de rescates masivos puede reducir la demanda de bonos y encarecer el costo de financiamiento. De igual manera, para una empresa corporativa, conocer el apetito del mercado y el momento ideal para emitir bonos permite optimizar los costos de financiamiento, considerando la confianza del mercado reflejada en los aportes y rescates de fondos mutuos. Para un banco de inversión, prever el comportamiento de los flujos de AUM es determinante para identificar el momento oportuno para adquirir activos de renta fija, evitando la compra en contextos de alta volatilidad.

Por lo tanto, comprender estos flujos no solo facilita la toma de decisiones de inversión, sino que también es esencial para gestionar los riesgos asociados con las fluctuaciones del mercado, garantizando la estabilidad financiera tanto para los inversionistas como para los actores clave del sistema financiero chileno. Al hablar con distintos *Portfolio Managers* de fondos mutuos de renta fija es común escuchar que no se posee ningún modelo predictivo sobre cuándo los clientes realizarán aportes y rescates; la práctica habitual se basa en suposiciones como que los inversionistas tienden a moverse entre fondos en función de sus pérdidas o ganancias recientes.

Frente a este escenario, la implementación de un modelo predictivo de flujos de aportes y rescates busca entregar resultados concretos que mejoren la gestión de activos y la toma de decisiones estratégicas en un banco de inversión:

- **Previsión de cambios en indicadores financieros:** Anticipar variaciones en liquidez y rentabilidad de los fondos, gestionando riesgos de crédito y de mercado al identificar con antelación aumentos en rescates.
- **Mejora en la toma de decisiones:** Permitir ajustes proactivos en estrategias de inversión y optimizar el momento de emisiones de deuda según la demanda prevista del mercado.
- **Reducción del riesgo de mercado:** Ajustar carteras para minimizar el impacto de movimientos repentinos en flujos, evitando ventas forzadas y mejorando la gestión de liquidez.
- **Optimización de la asignación de activos:** Ajustar la exposición a distintos instrumentos de deuda y la duración de cartera según las condiciones macroeconómicas anticipadas, logrando un alineamiento más eficiente con el entorno esperado.

3. Hipótesis

La hipótesis central de este estudio es que mediante el desarrollo de un modelo predictivo basado en rentabilidades pasadas de los aportantes de cada fondo se puede anticipar con mayor precisión los flujos de AUM⁵ (aportaciones y rescates) en los fondos mutuos de renta fija local en Chile.

Este modelo permitirá predecir el comportamiento de los inversionistas, identificando los momentos en que se realizarán movimientos significativos en el mercado de renta fija, lo que a su vez ayudará a los actores clave del mercado, como bancos, empresas y bancos de inversión, a tomar decisiones estratégicas más informadas.

Así, será posible optimizar la emisión de deuda, la compra de activos de renta fija y la gestión de riesgos asociados a la volatilidad del mercado. En consecuencia, este modelo no solo mejorará la toma de decisiones dentro del sistema financiero chileno, sino que también contribuiría a reducir los riesgos derivados de la incertidumbre y los flujos inesperados de fondos, promoviendo la estabilidad financiera en el mercado de renta fija local.

⁵ *Asset Under Management*

4. Objetivos

4.1 Objetivo General

Desarrollar un modelo predictivo basado en análisis de datos macroeconómicos y del comportamiento de los inversionistas, que permita anticipar los flujos de aportes y rescates en los fondos mutuos de renta fija administrados por un *Portfolio Manager* de un Banco de Inversión.

Este modelo deberá proporcionar predicciones precisas y oportunas, optimizando la toma de decisiones en la gestión de activos, mejorando la estrategia de emisión de deuda y la asignación de inversiones, reduciendo la exposición al riesgo de mercado, riesgo de crédito y contribuyendo a la estabilidad financiera del banco.

4.2 Objetivos Específicos

- **Realizar un análisis exploratorio de los datos históricos de aportes y rescates de fondos mutuos:** Investigar los patrones y tendencias pasadas en los flujos de aportes y rescates, identificando posibles correlaciones con factores macroeconómicos, como tasas de interés, inflación y eventos políticos o económicos.
- **Desarrollar y validar un modelo de predicción de flujos de AUM:** Construir un modelo estadístico o de *Machine Learning* que pueda predecir con precisión los aportes y rescates futuros de fondos mutuos, utilizando variables macroeconómicas y datos históricos de los fondos.
- **Evaluar el impacto de los flujos de fondos en la rentabilidad y riesgo de los fondos mutuos:** Analizar cómo los movimientos de AUM (aportaciones y rescates) afectan la rentabilidad, la volatilidad y el riesgo de los fondos, ayudando a mejorar las decisiones de asignación de activos y estrategias de inversión.
- **Optimizar la toma de decisiones estratégicas en emisión de deuda y gestión de activos:** Utilizar las predicciones del modelo para asesorar a los *Portfolio Managers* en la estrategia de emisión de deuda, ayudando a determinar los momentos oportunos para emitir bonos o ajustar la cartera de renta fija, optimizando la exposición al riesgo y la rentabilidad esperada.

5. Marco Teórico

El presente marco teórico establece los fundamentos conceptuales y teóricos que respaldan el desarrollo de un modelo predictivo orientado a anticipar los flujos de aportes y rescates de fondos mutuos de renta fija.

En este contexto, se abordan los principios de los mercados financieros, con un enfoque particular en los fondos mutuos de renta fija como vehículos de inversión clave. Además, se exploran los conceptos relacionados con la limpieza de datos, búsqueda de correlación entre las variables a controlar, construcción de modelos predictivos, poniendo especial énfasis en las variables de rentabilidades pasadas (diaria, 7 días, 30 días, etc) que influyen en el comportamiento de los inversionistas. Este análisis permite comprender la interrelación de estos elementos y su impacto sobre el comportamiento de los flujos de aportes y rescates en el mercado financiero, contribuyendo a la toma de decisiones informadas en el sector.

5.1 Mercados Financieros y Fondos Mutuos de Renta Fija

Mercados financieros: Los mercados financieros son estructuras organizadas donde los individuos, empresas, bancos, Fondos de Pensiones, Fondos mutuos, gobiernos y bancos centrales realizan intercambios de activos financieros, tales como acciones, bonos, derivados y otros instrumentos de deuda.

Estos mercados permiten la asignación eficiente de capital y proporcionan a los participantes acceso a una amplia gama de instrumentos para financiar sus necesidades y gestionar riesgos. En el contexto chileno, el mercado de renta fija se destaca por ser uno de los segmentos más relevantes, llegando a equivaler a un 57,5% del Producto Interno Bruto de Chile (Banco Central de Chile, 2024). dado que está compuesto por instrumentos de deuda emitidos tanto por entidades gubernamentales como privadas. Los inversionistas adquieren estos instrumentos con la expectativa de recibir una rentabilidad fija, en función de las condiciones del mercado y el riesgo asociado a la solvencia del emisor, dentro de los inversionistas encontramos los siguientes:

- **Fondos de Pensiones (AFP):** Administran los ahorros previsionales de los trabajadores.
- **Inversionistas Extranjeros:** Participan en el mercado a través de inversiones directas o mediante fondos mutuos.
- **Bancos y Cooperativas:** Ofrecen productos de fondos mutuos a sus clientes.
- **Compañías de Seguros:** Invierten en fondos mutuos como parte de su estrategia de inversión.
- **Gobierno General:** Participa como emisor de deuda y en la regulación del mercado.
- **Otros Intermediarios Financieros:** Incluyen corredoras de bolsa y otras instituciones financieras.

Fondos mutuos: Son vehículos de inversión colectiva que permiten a los inversionistas diversificar su portafolio invirtiendo en una variedad de instrumentos de deuda, como bonos corporativos, bonos del gobierno y otros activos de renta fija, así como también instrumentos de inversión de renta variable como Acciones, ETF, derivados, Fx, entre otros. Estos fondos están gestionados por administradores profesionales que toman decisiones de inversión basadas en diversos factores económicos y del mercado.

Funcionamiento y Estructura: Los fondos mutuos operan bajo la figura de sociedades anónimas abiertas, reguladas por la Comisión para el Mercado Financiero (CMF). Los inversionistas compran participaciones en el fondo, y el valor de estas participaciones varía según el rendimiento de los activos subyacentes.

Tipos de Fondos Mutuos

Existen diversos tipos de fondos mutuos, clasificados según su estrategia de inversión, nivel de riesgo y horizonte temporal. Entre ellos se encuentran:

- **Fondos de Renta Fija:** Invierten principalmente en bonos y otros instrumentos de deuda.
- **Fondos de Renta Variable:** Invierten en acciones y otros instrumentos de renta variable.
- **Fondos Mixtos:** Combinan inversiones en renta fija y variable.
- **Fondos de Libre Inversión:** Tienen mayor flexibilidad en sus inversiones, sin restricciones específicas.
- **Perfil de Riesgo y Rentabilidad:** Cada tipo de fondo tiene un perfil de riesgo y rentabilidad asociado. Los fondos de renta fija suelen tener menor riesgo y rentabilidad más estable, mientras que los fondos de renta variable pueden ofrecer mayores rendimientos, pero con mayor volatilidad. Para el caso de los fondos de Renta Fija que analizaremos en este documento, encontramos que se agrupan por horizonte de inversión y por lo tanto un riesgo de duración asociado (circular AAFM 2011)

Los fondos a evaluar en este proyecto son todos los fondos de Renta Fija local, los cuales se detallan a continuación:

Fondos De Deuda < 365 Días Nacional En Pesos

Estos fondos invierten exclusivamente en instrumentos de deuda con una duración de menos de 365 días, denominados en pesos chilenos. El objetivo es ofrecer una inversión a corto plazo, que busca estabilidad y seguridad en el tipo de cambio nacional, con un enfoque en la rentabilidad a corto plazo.

Fondos De Deuda < 365 Días Nacional En UF

Similar a los fondos anteriores, pero con la diferencia de que los instrumentos en los que invierte están denominados en Unidades de Fomento (UF), una unidad de cuenta ajustada por la inflación. Estos fondos se orientan a aquellos inversionistas que buscan protegerse de la inflación en el corto plazo, manteniendo una inversión de bajo riesgo.

Fondos De Deuda < 90 Días Nacional

Estos fondos invierten en instrumentos de deuda de corto plazo (menos de 90 días), con una estrategia similar a los fondos de deuda a menos de 365 días, pero con una mayor liquidez debido a su menor duración. También están denominados en pesos chilenos o en unidades de reajuste nacionales (como la UF).

Fondos De Deuda > 365 Días Nacional, Inversión En Pesos

En esta categoría, los fondos invierten en instrumentos de deuda con vencimientos mayores a 365 días, todos denominados en pesos chilenos. La estrategia de inversión es a más largo plazo, con un enfoque en activos que ofrezcan rendimientos más altos debido a su mayor duración y exposición a las tasas de interés.

Fondos De Deuda > 365 Días Nacional, Inversión En UF < 3 Años

Estos fondos invierten en instrumentos de deuda de más de 365 días, denominados en UF, pero con una duración de menos de 3 años. El enfoque es proteger la inversión contra la inflación a mediano plazo, con una estrategia de deuda que se ajusta a los movimientos de la inflación, pero en un horizonte más corto.

Fondos De Deuda > 365 Días Nacional, Inversión En UF > 5 Años

Este tipo de fondo invierte en instrumentos de deuda denominados en UF con una duración mayor a 5 años. Está dirigido a inversionistas con un horizonte de inversión a largo plazo, buscando un rendimiento que se beneficie de los ajustes por inflación en el largo plazo.

Fondos De Deuda > 365 Días Nacional, Inversión En UF > 3 Años Y =< 5

Estos fondos se enfocan en instrumentos de deuda denominados en UF, con vencimientos mayores a 3 años pero menores o iguales a 5 años. La estrategia es mantener la inversión a mediano-largo plazo, buscando rentabilidades ajustadas por inflación con una duración moderada.

Fondos De Deuda > 365 Días Orig. Flex

Este fondo incluye una mezcla de instrumentos de deuda con una duración mayor a 365 días, pero sin restricciones específicas sobre el tipo de moneda o unidad de reajuste. Esto permite mayor flexibilidad en las inversiones, adaptándose a diferentes condiciones del mercado y estrategias de diversificación.

Inversionistas Calificados Títulos De Deuda

Este fondo está dirigido exclusivamente a inversionistas calificados, quienes tienen la capacidad de asumir riesgos mayores en la inversión en instrumentos de deuda. La estrategia es de mayor flexibilidad y de mayor riesgo, permitiendo una mayor exposición a títulos de deuda de largo plazo y denominados en diferentes unidades de reajuste o monedas.

Instrumentos en los que Invierten los Fondos Mutuos

Los fondos mutuos de renta fija invierten en una amplia gama de instrumentos financieros de deuda, especialmente aquellos de largo plazo. A continuación, se describen los principales instrumentos en los que estos fondos invierten:

En primer lugar, es necesario señalar que los fondos de renta fija invierten en instrumentos denominados principalmente en tres monedas: el peso chileno (CLP), la Unidad de Fomento (UF) y el dólar estadounidense (USD).

- **Peso chileno (CLP):** El peso chileno es la moneda oficial de la República de Chile y se utiliza como medio de intercambio en el sistema económico del país. Esta moneda está regulada por el Banco Central de Chile. El valor del peso chileno puede fluctuar en el mercado de divisas, y su poder adquisitivo está sujeto a factores como la inflación y las políticas monetarias del país.
- **Dólar estadounidense (USD):** El dólar estadounidense es la moneda oficial de los Estados Unidos y la divisa de reserva más utilizada a nivel mundial en el comercio internacional. Emitido por la Reserva Federal de los Estados Unidos, el dólar es ampliamente aceptado como medio de pago en transacciones internacionales y sirve como un estándar de comparación en los mercados de divisas, influyendo en el valor de muchas otras monedas globalmente.
- **UF:** La Unidad de Fomento (UF) es un índice de reajustabilidad utilizado en operaciones de crédito de dinero en moneda nacional. Su valor se ajusta diariamente, desde el día 10 de cada mes hasta el día 9 del mes siguiente, en función de la variación del Índice de Precios al Consumidor (IPC) determinado por el Instituto Nacional de Estadísticas (INE) o el organismo que lo reemplace. Este ajuste se realiza mediante una tasa promedio geométrica calculada sobre la variación mensual del IPC del mes calendario inmediatamente anterior al período para el cual se calcula la UF.

La UF fue creada en 1967 con el objetivo de permitir la revalorización de los ahorros y créditos en función de la inflación, asegurando así que el poder adquisitivo se mantenga constante a lo largo del tiempo. Actualmente, es ampliamente utilizada en Chile para la determinación de valores en contratos financieros, como préstamos hipotecarios, depósitos a plazo y otros instrumentos financieros.

Es importante destacar que la UF no es una moneda de curso legal, sino una unidad de cuenta que se expresa en pesos chilenos al momento de realizar pagos, según el valor diario de la UF. Esta característica permite que los contratos y obligaciones financieras se ajusten automáticamente a las variaciones de la inflación, protegiendo tanto a deudores como a acreedores de los efectos de la pérdida de poder adquisitivo.

Una vez definida la moneda en que pueden invertir los fondos de Mutuos de Renta Fija, es necesario indicar cuales son los instrumentos disponibles en los cuales pueden invertir cada uno de los fondos:

I. Instrumentos de Renta Fija (IRF) o de Deuda de Largo Plazo

Los IRF son títulos representativos de obligaciones de mediano y largo plazo que contrae el emisor con el poseedor del instrumento. Su plazo hasta su total extinción excede a 365 días y pagan intereses según una tasa de carátula. Dentro de esta categoría, se incluyen los siguientes instrumentos:

II. Bonos del Banco Central (BCU-BCP-BCD) y de la Tesorería (BTU-BTP)

Estos instrumentos son emitidos por entidades públicas con el objeto de regular la oferta monetaria, apoyar la política cambiaria, obtener financiamiento para proyectos del Estado, o reemplazar deuda externa. Pueden estar expresados en pesos chilenos (CLP), indexados a la inflación (UF), o en moneda extranjera. Además, incluyen el saldo vigente de otras obligaciones por títulos públicos, como PRC y Ceros del Banco Central, y bonos MINVU8 / Bonos de Reconocimiento del Gobierno.

III. Bonos Bancarios y Debentures (Bonos Corporativos)

Son instrumentos emitidos por bancos y empresas con el fin de financiar proyectos de inversión de largo plazo o cumplir compromisos financieros. En los bonos bancarios se incluyen los de tipo “subordinados” (que poseen una prioridad más baja para el acreedor) y los “hipotecarios” (emitidos para financiar préstamos para la vivienda). Dentro de los bonos corporativos también se encuentran los bonos “securitizados”, emitidos por sociedades securitizadoras con el objetivo de anticipar los flujos de ciertos activos financieros, como créditos hipotecarios, automotrices, tarjetas de crédito, etc. Estos bonos pueden estar expresados en pesos chilenos (CLP), indexados a la inflación (UF), o en moneda extranjera, aunque la mayoría de ellos se encuentran emitidos en unidades de fomento.

IV. Letras Hipotecarias

Son instrumentos emitidos por bancos e instituciones financieras para financiar hipotecas o actividades productivas diversas. Estas letras pueden estar indexadas a la inflación (UF) o expresadas en pesos chilenos (CLP). Aunque su relevancia disminuyó después del año 2000, siguen siendo un componente de los fondos de renta fija. Comportamiento de los Inversionistas y Flujos de Aportes y Rescates

V. Depósitos a plazo y Efectos de Comercio

Efectos de comercio son instrumentos financieros utilizados en el ámbito del comercio para financiar transacciones comerciales, como facturas y pagarés, y son una forma de deuda a corto plazo. Generalmente, estos instrumentos son negociables en el mercado, permitiendo que los beneficiarios reciban pagos anticipados de una entidad financiera a cambio de una comisión. Depósitos a plazo, por otro lado, son productos bancarios que permiten a los inversionistas depositar su dinero por un período específico a cambio de una tasa de interés fija o variable. Los depósitos a plazo son una opción segura de inversión, ya que están garantizados por el banco. Ambos instrumentos, efectos de comercio y depósitos a plazo, son utilizados por empresas e inversionistas como parte

de su estrategia de financiamiento o inversión, contribuyendo a la liquidez y estabilidad en los mercados financieros.⁶

Participantes del Mercado de Fondos Mutuos:

Son sociedades anónimas encargadas de administrar los fondos mutuos por cuenta y riesgo de los partícipes. Estas entidades deben estar registradas y supervisadas por la Comisión para el Mercado Financiero (CMF). Entre las AGF más relevantes en Chile se encuentran:

- Banchile Administradora General de Fondos (filial del Banco de Chile)
- Santander Asset Management Chile
- BICE Inversiones AGF
- LarrainVial AGF
- Sura Investment Management Chile AGF

Estas administradoras ofrecen una variedad de fondos que invierten en distintos instrumentos financieros, como acciones, bonos y otros valores de oferta pública.

5.2 Flujo de Aporte y Rescates en Fondos Mutuos de Renta Fija

Los flujos de aportes y rescates son fundamentales para el funcionamiento de los fondos mutuos. Los aportes son la entrada de dinero de nuevos inversionistas o los que deciden aumentar sus inversiones en los fondos, mientras que los rescates son la salida de dinero, donde los inversionistas retiran sus fondos. Estos flujos pueden reflejar las expectativas de los inversionistas sobre las condiciones macroeconómicas, la rentabilidad de los fondos, y el riesgo asociado.

Comportamiento de los inversionistas: El comportamiento de los inversionistas está profundamente influenciado por factores macroeconómicos y psicológicos. En línea con el enfoque de corridas bancarias propuesto por Gorton (2009), las decisiones de rescate en fondos mutuos pueden propagarse como "corridas financieras" ante señales de inestabilidad, afectando los precios de los activos subyacentes y amplificando el riesgo sistémico (Bank of England, 2017).

5.3 Riesgos Asociados a Fondos de Renta Fija

A continuación, se analizan distintos tipos de shocks y su efecto esperado sobre las decisiones de aporte o rescate en fondos mutuos.

⁶ Banco Central de Chile, 2024; Comisión para el Mercado Financiero, 2024

- I. **Shock de tasa de interés:** Cambios abruptos o sostenidos en la tasa de interés referencial afectan directamente el valor presente de los instrumentos financieros, particularmente los de renta fija.

Impacto: Subida de tasas: desincentiva la inversión en fondos de renta fija, al reducir el precio de los bonos existentes. Los inversionistas migran hacia instrumentos de corto plazo o depósitos a plazo más rentables lo que implica mayores rescates.

Baja de tasas: hace más atractiva la permanencia o el aporte a fondos mutuos, especialmente de renta variable o de mayor duración gatillando mayores aportes. (Anderson 2010)

- II. **Incertidumbre social o política:** Se refiere a condiciones sociopolíticas inestables o cambios institucionales que afectan la confianza de los inversionistas.

Impacto: Eleva la percepción de riesgo y reduce la tolerancia a la iliquidez, por ejemplo el estallido social de octubre de 2019 provocó un aumento significativo en el riesgo de deuda de los hogares chilenos, según lo documentado por Madeira (2022).

Esta situación llevó a muchos inversionistas a rescatar sus fondos mutuos, buscando liquidez ante la creciente incertidumbre económica. Este comportamiento reflejó una pérdida de confianza en el mercado financiero y contribuyó a la volatilidad del mercado de capitales durante ese período. Por otro lado la pandemia de COVID-19 exacerbó las vulnerabilidades financieras de los hogares chilenos, impulsándolos a rescatar fondos mutuos en busca de liquidez (Bank of Canada 2020). Este comportamiento refleja una respuesta racional ante la incertidumbre económica y la necesidad de cumplir con obligaciones financieras en un entorno de ingresos reducidos.

Genera un comportamiento de huida hacia activos percibidos como seguros (dólar, oro, depósitos en el extranjero) repercutiendo en rescates masivos (Pastor 2012)

- III. **Percepción de riesgo del mercado:** Evaluación subjetiva que hacen los inversionistas sobre la probabilidad de pérdida. Puede ser influenciada por eventos globales (crisis, guerras, defaults) o locales (caídas bursátiles, fallas corporativas).

Impacto: Aumento del “*risk aversion*” (aversión al riesgo), incentivando la retirada de fondos más expuestos (acciones, mercados emergentes) llevando a salida desde fondos de renta variable.

Posible reubicación hacia fondos conservadores o monetarios promoviendo aportes a fondos de bajo riesgo. (Baker 2007)

IV. **Riesgo inflacionario:** Se refiere a las expectativas sobre aumentos sostenidos de precios, que deterioran el poder adquisitivo de los instrumentos no indexados.

Impacto: Inversionistas evitan activos de renta fija nominal que pierden valor real lo que generará rescates en fondos no indexados.

Se favorecen fondos que invierten en activos en UF, bienes reales, acciones de empresas con capacidad de fijar precios llevando a aportes a fondos indexados o diversificados (Campbell 2011)

De acuerdo con el estudio del Banco de Inglaterra el cual modela un escenario de estrés en el que los inversionistas realizan rescates masivos en fondos mutuos abiertos, lo que obliga a las administradoras a vender activos rápidamente. Este fenómeno puede desencadenar una cadena de eventos que amplifica el estrés financiero:

Choque inicial: Un evento externo (como un aumento abrupto en las tasas de interés o una crisis económica) provoca una pérdida de confianza y rescates masivos por parte de los inversionistas.

Ventas forzadas ("*fire sales*"): Para cumplir con las solicitudes de rescate, los fondos venden activos rápidamente, lo que presiona a la baja los precios de mercado.

Reducción de liquidez: La caída en los precios y la venta masiva de activos reducen la liquidez del mercado, dificultando la venta de activos sin afectar significativamente su precio.

Efecto dominó: La disminución en el valor de los activos afecta a otros participantes del mercado, incluidos bancos y otros fondos, que pueden verse obligados a vender activos adicionales, amplificando la caída de precios.

Riesgo sistémico: La combinación de ventas forzadas y reducción de liquidez puede llevar a una crisis más amplia en el sistema financiero.

5.4 Predicción y Modelos de Series Temporales Asociado a Finanzas:

En el contexto de la analítica financiera, una serie temporal corresponde a una secuencia de datos observados y registrados en momentos sucesivos. A diferencia de los datos transversales, en los que las observaciones son independientes entre sí, las series temporales se caracterizan por la existencia de dependencia temporal, en otras palabras, la observación actual puede estar influenciada por sus valores pasados.

De acuerdo con Box y Jenkins (2008), el análisis de series temporales permite modelar y predecir el comportamiento dinámico de variables observadas en el tiempo, descomponiendo los datos en componentes sistemáticos y aleatorios. Esta capacidad predictiva es especialmente útil en aplicaciones financieras, donde los fenómenos como los flujos de aporte de capital, tasas de interés, o precios de activos, presentan patrones

temporales complejos los cuales podrían modelarse por estos modelos, siempre y cuando cumplan con los siguientes requisitos.

Estacionariedad

Una serie temporal es estacionaria cuando sus propiedades estadísticas fundamentales —como la media, la varianza y la autocovarianza— permanecen constantes en el tiempo. La estacionariedad es una condición esencial para aplicar muchos modelos de predicción clásicos, ya que garantiza que las relaciones entre las variables pasadas y futuras no cambian con el tiempo, lo cual permite extrapolar el comportamiento histórico.

En la práctica, se suelen utilizar *tests* estadísticos como ADF (Augmented Dickey-Fuller) o KPSS para verificar si una serie es estacionaria, y se aplican transformaciones (diferenciación, logaritmos, etc.) si no lo es. En el caso de flujos de aportes y rescates, es común observar tendencias o estacionalidades que requieren ser removidas para construir un modelo robusto.

Ruido blanco

El ruido blanco representa el componente puramente aleatorio de una serie temporal. Se define como una secuencia de variables independientes e idénticamente distribuidas con media cero, varianza constante y sin autocorrelación. Es decir, cada observación de ruido blanco no contiene información predecible sobre las anteriores o las siguientes.

En el contexto de modelado, los residuos de un modelo bien ajustado deben comportarse como un ruido blanco. Si después de ajustar un modelo ARIMA o SARIMAX los residuos muestran autocorrelación significativa, esto indica que aún hay estructura no explicada por el modelo y, por tanto, puede mejorarse.

Tendencia, estacionalidad y ciclos

Según explica Hyndman estos tres componentes son fundamentales para descomponer y entender una serie temporal:

Tendencia (Trend): Se refiere a un cambio sistemático y prolongado en el nivel medio de la serie a lo largo del tiempo. Puede ser creciente, decreciente o cambiante. En series financieras, una tendencia podría reflejar, por ejemplo, una preferencia de aporte creciente por un tipo de fondo a lo largo del tiempo o bien una tendencia decreciente por efecto coyunturales

Estacionalidad: Son fluctuaciones regulares que se repiten en intervalos específicos, como meses o trimestres. Por ejemplo, los rescates de fondos podrían aumentar consistentemente en ciertos días del mes debido a razones tributarias o necesidad de liquidez.

Ciclos: A diferencia de la estacionalidad, los ciclos no tienen una periodicidad fija. Están asociados a factores económicos de largo plazo, como expansiones o recesiones. En el caso de fondos mutuos, un ciclo podría manifestarse durante un periodo prolongado de incertidumbre macroeconómica o durante shocks financieros.

La identificación y separación de estos componentes, a través de métodos como la descomposición STL (Seasonal-Trend decomposition using Loess), facilita la construcción de modelos más precisos y explicativos.

ACF y PACF

Como explica Jenkins la Función de Autocorrelación (ACF) y la Función de Autocorrelación Parcial (PACF) son herramientas fundamentales para analizar la estructura interna de una serie temporal y determinar el orden de los modelos AR (autoregresivos) y MA (medias móviles):

La ACF mide el grado de correlación lineal entre observaciones separadas por un cierto número de periodos (*lags*). Es útil para detectar la presencia de patrones persistentes. Mientras que PACF mide la correlación entre una observación y su rezago, descontando el efecto de los rezagos intermedios. Esto permite identificar la influencia directa de un determinado rezago, eliminando los efectos indirectos.

El análisis gráfico de estas funciones permite seleccionar los parámetros adecuados de los modelos ARIMA (p, d, q), siendo esencial para evitar problemas de sobreajuste o subajuste. Por ejemplo, si la ACF decae lentamente y la PACF corta abruptamente en el rezago 1, esto podría sugerir un modelo AR(1).

5.5 Modelos ARIMA, SARIMA y SARIMAX

Modelo ARIMA

El modelo ARIMA (*AutoRegressive Integrated Moving Average*), propuesto por Box y Jenkins, es uno de los enfoques más clásicos y ampliamente utilizados en el análisis y predicción de series temporales. Este modelo se utiliza principalmente cuando los datos no son estacionarios, pero pueden volverse estacionarios mediante la diferenciación entre ellos mismos:

Un modelo ARIMA se representa como ARIMA (p, d, q), donde:

- p es el número de términos autorregresivos (AR)
- d es el número de diferenciaciones necesarias para lograr estacionariedad (*Integrated*)
- q es el número de términos de media móvil (MA).

El componente AR modela la dependencia lineal entre una observación y sus rezagos pasados, el componente I transforma la serie en estacionaria, y el componente MA capta la dependencia entre una observación y los errores residuales pasados.

Según Box et al. (2008), los modelos ARIMA permiten capturar de manera eficiente patrones lineales en series temporales univariadas, y su correcta especificación depende en gran medida del análisis de la ACF y PACF de la serie transformada.

Sin embargo, una limitación del modelo ARIMA es que no contempla estacionalidad explícita ni variables exógenas, lo que puede reducir su eficacia en series temporales que presentan dichos patrones.

Modelo SARIMA

Por otro lado, el modelo SARIMA (*Seasonal ARIMA*) extiende el modelo ARIMA para incorporar comportamientos estacionales. Es especialmente útil en contextos donde los datos presentan patrones que se repiten en intervalos regulares, como meses, trimestres o años.

denotándose como SARIMA $(p, d, q)(P, D, Q)_s$, donde:

- (p, d, q) : Parámetros del modelo ARIMA no estacional
- (P, D, Q) : Parámetros del componente estacional
- s : Periodicidad de la estacionalidad (por ejemplo $s = 12$ para datos mensuales con estacionalidad anual)

Hyndman y Athanasopoulos (2018) destacan que SARIMA permite modelar tanto la estructura de corto plazo como los patrones estacionales, haciendo que sea particularmente útil en campos como las finanzas y economía.

En el caso de este proyecto, los flujos de aportes y rescates pueden presentar estacionalidad mensual o anual debido a comportamientos sistemáticos de los inversionistas, como cierre de año, eventos macroeconómicos recurrentes o decisiones sistemáticas en la conducta de las personas.

Modelo SARIMAX

El modelo SARIMAX (*Seasonal ARIMA with exogenous regressors*) es una extensión del SARIMA que permite incluir variables explicativas externas (exógenas), es decir, variables que no forman parte de la serie temporal que se quiere predecir, pero que podrían influir en ella.

Se representa como SARIMAX $(p, d, q)(P, D, Q)_s + X$, donde:

X representa una o más series externas que pueden aportar información adicional (por ejemplo: tasas de interés, variaciones del IPSA, tipo de cambio, rentabilidades de fondos, etc.).

Este modelo permite capturar tanto la estructura temporal como el efecto de variables exógenas en la serie de interés. En el contexto de tu investigación, esto permite analizar cómo influyen variables como la rentabilidad pasada de los fondos, la volatilidad de los mercados o decisiones de política monetaria en los flujos de aportes y rescates.

5.6 Aplicación de modelos de series temporales en finanzas

El análisis de series temporales ha demostrado ser una herramienta fundamental en el ámbito financiero, ya que permite modelar y predecir el comportamiento dinámico de variables que evolucionan a lo largo del tiempo. A diferencia de otros tipos de datos, las series financieras presentan una estructura secuencial en la que el orden temporal tiene un papel central: las observaciones pasadas influyen directamente en las futuras, lo que permite explotar dicha dependencia para propósitos predictivos (Box y Jenkins, 2008).

En finanzas, es común utilizar modelos de series temporales para predecir precios de activos, tasas de interés, retornos, volúmenes de transacción y flujos de capital. La premisa detrás de su aplicación es que, si bien los mercados están sujetos a incertidumbre, muchas de sus variables clave presentan patrones sistemáticos que pueden ser identificados y modelados estadísticamente (Wei, 2006)

Aplicado al contexto de los fondos mutuos de renta fija, los flujos de aportes y rescates reflejan decisiones de inversión agregadas que están influenciadas por múltiples factores, como expectativas de retorno, liquidez disponible y condiciones macroeconómicas. Estos flujos suelen presentar tendencias, ciclos de liquidez, y respuestas a shocks como anuncios de política monetaria o cambios regulatorios. Esta naturaleza dinámica y estructurada justifica el uso de modelos como ARIMA o SARIMAX, que permiten capturar la evolución temporal de los flujos e incluso incorporar variables externas explicativas (Hyndman & Athanasopoulos, 2018).

5.7 Limitaciones de los modelos tradicionales

A pesar de su extensa utilización y validación en diversos contextos, los modelos clásicos de series temporales —como ARIMA, SARIMA y SARIMAX— presentan limitaciones relevantes que deben considerarse, especialmente en entornos financieros marcados por alta volatilidad y la ocurrencia de eventos inesperados.

Una de las principales restricciones de estos modelos es su suposición de relaciones lineales entre las variables y sus rezagos, lo cual puede limitar su capacidad para capturar dinámicas complejas o comportamientos no lineales frecuentes en series financieras, como efectos de umbral o interacciones estructurales (Wei, 2006). Además, su desempeño está estrechamente vinculado al cumplimiento del supuesto de

estacionariedad; ante cambios estructurales —como crisis económicas, reformas regulatorias o eventos exógenos de gran magnitud—, su capacidad predictiva puede verse considerablemente afectada (Lütkepohl, 2005).

En el estudio de Chu (2022), el modelo ARIMA fue utilizado como punto de comparación estadístico (*baseline*) para predecir el desempeño de más de 600 fondos mutuos abiertos en Estados Unidos, empleando como métrica principal el Sharpe ratio anualizado, calculado a partir de retornos mensuales. Su elección se basa en la capacidad del modelo para capturar patrones lineales y estructuras temporales en series univariadas, siendo útil en contextos donde se dispone de un historial de datos consistente y se busca interpretar el comportamiento subyacente de la variable objetivo.

Aunque los autores concluyen que modelos de aprendizaje profundo como LSTM y GRU alcanzan una mayor precisión predictiva, ARIMA se posicionó como el método estadístico tradicional más competitivo dentro del conjunto evaluado, superando incluso a modelos como ETS y Theta en varias métricas de error. Esto sugiere que, en escenarios con limitaciones de datos o donde la interpretabilidad es prioritaria, ARIMA continúa siendo una herramienta robusta y pertinente.

Otra limitación crítica de estos enfoques tradicionales es su alta sensibilidad ante una especificación inadecuada de la estacionalidad. Cuando los datos presentan estacionalidades múltiples, irregulares o cambiantes, los modelos pueden subajustar o sobre ajustar la serie, lo que compromete la calidad de las predicciones. En estos casos, es recomendable explorar métodos más flexibles, como los modelos híbridos o técnicas basadas en aprendizaje automático, que no dependen de supuestos tan restrictivos y pueden adaptarse mejor a la complejidad de los datos financieros.

5.8 Modelos de Machine Learning Utilizados

La elección de modelos en este estudio respondió a la necesidad de capturar de manera robusta y explicativa la relación entre rentabilidades pasadas y los flujos de aporte/rescate en fondos mutuos. Se optó por una combinación de modelos tradicionales de *machine learning* y redes neuronales recurrentes para comparar enfoques estadísticos basados en árboles de decisión y clasificadores con arquitecturas profundas capaces de modelar la secuencia temporal de las variables.

Esta estrategia mixta busca aprovechar las ventajas de modelos interpretables y rápidos de entrenar (árboles de decisión, Random Forest, XGBoost, SVM) junto con modelos de redes neuronales recurrentes (LSTM, GRU) que pueden capturar dependencias temporales de largo plazo y no linealidades complejas.

Decision Tree

Un árbol de decisión es un modelo predictivo no paramétrico que divide iterativamente el espacio de las variables independientes en regiones homogéneas respecto de la variable objetivo. Lo hace construyendo una estructura jerárquica de decisiones binarias (o *multi-clase*) que se asemeja a un árbol, con nodos internos que representan decisiones basadas en umbrales de variables, y hojas que representan las predicciones finales.

La construcción del árbol consiste en elegir en cada paso la variable y el punto de corte que maximiza una medida de ganancia (reducción de varianza para regresión o ganancia de información/impureza para clasificación).

- El algoritmo sigue dividiendo hasta que se alcanza una condición de parada (profundidad máxima, número mínimo de muestras en un nodo, etc.).
- Las predicciones se generan siguiendo el camino de reglas desde la raíz hasta la hoja.

Ventajas:

- Altamente interpretable: se puede visualizar como un conjunto de reglas "si-entonces".
- Capaz de modelar relaciones no lineales e interacciones complejas entre variables.
- Funciona bien con datos mixtos (numéricos y categóricos).

Limitaciones:

- Propenso al sobreajuste si no se poda o regula.
- Sensible a ligeras variaciones en los datos (alta varianza).
- No necesariamente óptimo para capturar dependencias temporales en series. Según Sirignano y Cont (2019) en su predicción de precio de mercado en finanzas, si bien es cierto que no se implementan árboles de decisión como su modelo principal, sin embargo se destacan sus limitaciones al modelar datos financieros altamente no lineales y secuenciales como los libros de órdenes, justificando con esto la necesidad de utilizar redes neuronales profundas.

Su estudio sirve para contextualizar el uso de árboles de decisión como *baseline* en finanzas cuantitativas y para argumentar la evolución hacia modelos más complejos como las redes recurrentes.

Random Forest

El Random Forest es un algoritmo de ensamble basado en la construcción de múltiples árboles de decisión entrenados sobre diferentes subconjuntos aleatorios del conjunto de datos mediante *bagging* y la selección aleatoria de variables en cada división, reduciendo así la correlación entre árboles.

Cada árbol se entrena sobre una muestra *bootstrap* (con reemplazo) del *dataset* y, en cada nodo, sólo un subconjunto aleatorio de variables está disponible para la división. La predicción final se obtiene promediando en el caso de regresión o votando en clasificación las predicciones individuales de los árboles, lo que permite reducir la varianza y mejorar la capacidad de generalización del modelo.

Ventajas:

- Reduce significativamente el sobreajuste respecto a un árbol individual.
- Puede capturar relaciones no lineales complejas.
- Robusto ante ruido y valores atípicos.
- Maneja bien datos faltantes.

Limitaciones:

- Menor interpretabilidad: aunque se pueden extraer importancias de variables, el modelo global es una “caja negra” con cientos de árboles.
- Puede ser computacionalmente costoso con muchos árboles y datos.
- No modela explícitamente secuencia o temporalidad.

Según Gu, Kelly y Xiu (2020) demuestra la utilidad de métodos de *machine learning* como Random Forest para la predicción de retornos de activos financieros. Los autores comparan Random Forest con otros algoritmos, mostrando que este método de ensamble basado en árboles de decisión permite capturar relaciones no lineales y complejas entre características fundamentales y precios de activos, superando en muchos casos la capacidad predictiva de modelos lineales tradicionales.

Random Forest, gracias a su estructura de múltiples árboles entrenados sobre subconjuntos aleatorios, ofrece robustez frente al sobreajuste y una mayor capacidad para modelar interacciones entre variables, lo que lo convierte en una herramienta valiosa en problemas de *asset pricing* con alta dimensionalidad y heterogeneidad de datos.

XGBoost (Extreme Gradient Boosting)

XGBoost es un algoritmo de *boosting* de gradiente altamente optimizado. A diferencia de Random Forest, el *boosting* entrena los árboles de forma secuencial, donde cada nuevo árbol se ajusta para corregir los errores cometidos por el conjunto previo. Esto permite que el modelo final sea más preciso.

Cada árbol en el modelo intenta predecir los residuos o errores del modelo actual, refinando progresivamente las predicciones globales. La optimización del modelo se realiza mediante gradiente descendente sobre la función de pérdida, lo que permite ajustar de forma eficiente los parámetros. Además, XGBoost incluye técnicas de regularización L1 y L2 para controlar el sobreajuste, mejorando la capacidad de generalización del modelo. También incorpora estrategias avanzadas para el manejo de valores faltantes, así como métodos de poda y paralelización que optimizan el rendimiento computacional y la eficiencia del entrenamiento.

Ventajas:

- Precisión predictiva muy alta.
- Control de sobreajuste con parámetros de regularización.
- Soporte para datos faltantes y paralelización.
- Muy usado en competencias de ciencia de datos por su rendimiento.

Limitaciones:

- Menor interpretabilidad global que un solo árbol.
- Mayor complejidad en la selección de hiperparámetros (learning rate, profundidad, número de árboles).
- Computacionalmente más exigente.

En su trabajo, Gu, Kelly y Xiu (2020) aplican y evalúan una amplia gama de modelos de *machine learning* para predecir retornos de activos financieros, incluyendo métodos de *boosting* como XGBoost. Los autores muestran que XGBoost ofrece ventajas significativas para problemas de *asset pricing* debido a su capacidad para capturar relaciones altamente no lineales entre características fundamentales y precios de activos. A diferencia de métodos lineales tradicionales, XGBoost mejora la capacidad predictiva al entrenar de manera secuencial múltiples árboles que corrigen los errores previos, incorporando regularización y control de sobreajuste. Su capacidad para manejar *datasets* de alta dimensión, modelar interacciones complejas y procesar valores faltantes de manera eficiente lo convierte en una herramienta poderosa en entornos financieros caracterizados por datos ruidosos, heterogéneos y con relaciones no triviales.

Support Vector Machine (SVM)

Es un modelo supervisado para clasificación o regresión que busca encontrar el hiperplano óptimo en el espacio de características que maximiza el margen entre clases (o que minimiza el error en regresión con margen de tolerancia).

El principio de funcionamiento de SVM se basa en encontrar, para datos linealmente separables, el hiperplano que maximiza el margen entre las clases. Para datos no lineales, emplea funciones kernel —como el polinomial o *radial basis function*— que

transforman el espacio original en uno de mayor dimensión donde la separación sea posible.

Ventajas:

- Capacidad para capturar relaciones no lineales mediante kernels.
- Buena generalización si se ajustan bien los parámetros.
- Robusto a *outliers* si se usa el margen suavizado (*soft-margin*).

Limitaciones:

- Sensible a la selección del kernel y parámetros (C , γ).
- Escalabilidad limitada con grandes *datasets*.
- Interpretabilidad reducida para kernels no lineales.
- No diseñado para datos secuenciales o temporales

Al igual que los modelos anteriores, Gu, Kelly y Xiu (2020) aplican Support Vector Machine (SVM) junto con otros modelos de *machine learning* como Random Forest, XGBoost y redes neuronales para abordar el problema de predicción de retornos de activos financieros. El enfoque de SVM se utiliza para capturar relaciones no lineales complejas entre estas características y los retornos futuros, superando las limitaciones de modelos lineales tradicionales que no pueden representar interacciones ni efectos de umbral. Los resultados muestran que SVM, al igual que otros métodos no paramétricos, ofrece mejoras sustanciales en precisión predictiva respecto de modelos lineales restringidos, destacando su potencial para modelar patrones intrincados presentes en los datos financieros de alta dimensión, por lo que podría ser útil para el caso de estudiar movimiento de fondos mutuos.

LSTM (Long Short-Term Memory)

LSTM son redes neuronales recurrentes (RNN) diseñadas para resolver el problema del desvanecimiento del gradiente y poder aprender dependencias de largo plazo en secuencias.

De acuerdo con Hochreiter y Schmidhuber (1997), el funcionamiento de las redes LSTM se basa en una estructura de “celdas” que contienen mecanismos llamados compuertas de entrada, olvido y salida, los cuales regulan de manera precisa el flujo de información a través de la red. La celda de memoria permite almacenar información relevante durante periodos prolongados, manteniendo el contexto necesario para procesar secuencias de datos. Gracias a este diseño, las LSTM son capaces de recordar patrones de largo plazo y decidir de forma dinámica qué información conservar y cuál olvidar, lo que las hace especialmente eficaces para modelar dependencias temporales en series de tiempo.

Ventajas:

- Modela dependencias temporales largas en series de tiempo, ideal para evaluar series de rentabilidad que puedan inferir en aportes y rescates de fondos mutuos
- Capaz de capturar relaciones no lineales y dinámicas complejas.
- Adecuada para series con patrones secuenciales, estacionales o atrasos significativos.

Limitaciones:

- Necesita grandes cantidades de datos para entrenar bien.
- Alta carga computacional.
- Menor interpretabilidad: es difícil entender qué “aprende” internamente, debido a la complejidad en mostrar como está compuesta la red.
- Requiere ajuste cuidadoso de hiperparámetros (número de capas, tamaño de celda, tasa de aprendizaje).

Fischer y Krauss (2018) presentan uno de los estudios pioneros y más citados sobre la aplicación de redes *Long Short-Term Memory* (LSTM) en la predicción de precios bursátiles. En su trabajo, los autores construyen un modelo de LSTM para predecir la dirección de los retornos diarios de las S&P 500 stocks, basándose en la capacidad de las LSTM para capturar dependencias temporales de largo plazo presentes en las series de precios financieros, superando el problema del desvanecimiento del gradiente que afecta a redes neuronales recurrentes tradicionales. Este modelo se entrena para aprender patrones históricos en los movimientos de precios que puedan tener valor predictivo para el día siguiente.

Para evaluar la efectividad del modelo, Fischer y Krauss comparan su desempeño predictivo con el de varios métodos tradicionales, donde sus hallazgos muestran que el modelo LSTM logra tasas de acierto significativamente superiores y mejores métricas de desempeño financiero (como el Sharpe Ratio en *backtesting* de estrategias de trading) frente a los modelos comparados.

El estudio destaca que las LSTM son especialmente útiles para capturar no solo las relaciones no lineales entre precios pasados y retornos futuros, sino también la dinámica secuencial y temporal de los mercados financieros, ofreciendo un marco potente para predecir precios de activos en entornos complejos y ruidosos.

GRU (Gated Recurrent Unit)

El *Gated Recurrent Unit* (GRU) es una variante simplificada de las redes neuronales LSTM, diseñada para mantener la capacidad de capturar dependencias de largo plazo en datos secuenciales pero con una arquitectura más sencilla y menos parámetros.

Su principio de funcionamiento se basa en combinar las funciones de olvido y entrada en una única compuerta de actualización, reduciendo la complejidad del modelo y

facilitando el entrenamiento. Además, incorpora una compuerta de reinicio que regula cómo se integra la nueva entrada con la memoria pasada, permitiendo controlar de forma eficiente el flujo de información relevante.

Entre sus principales ventajas se encuentran un entrenamiento más rápido que el de LSTM, un menor riesgo de sobreajuste en conjuntos de datos pequeños y una buena capacidad para modelar dependencias temporales. Sin embargo, presenta limitaciones como una menor interpretabilidad, y en problemas con dependencias extremadamente largas puede resultar menos eficaz que LSTM, requiriendo una configuración cuidadosa de su arquitectura e hiperparámetros.

Ventajas:

- Entrenamiento más rápido que LSTM.
- Menor riesgo de sobreajuste en *datasets* pequeños.
- Buena capacidad para modelar dependencias temporales.

Limitaciones:

- Aunque simplificado, sigue siendo menos interpretable.
- En problemas con dependencias extremadamente largas, a veces menos eficaz que LSTM.
- Requiere configuración cuidadosa de arquitectura y entrenamiento.

Cao, Li y Li (2019) proponen un modelo de predicción de series temporales financieras que combina la técnica de descomposición CEEMDAN con redes neuronales GRU para mejorar la precisión en la predicción de precios bursátiles.

El enfoque consiste en descomponer primero la serie de precios en componentes más simples y menos ruidosos utilizando CEEMDAN, permitiendo aislar patrones más predecibles. Posteriormente, cada uno de estos componentes se modela mediante redes GRU, que gracias a sus compuertas de actualización y reinicio son capaces de capturar dependencias temporales de largo plazo de forma eficiente y con menor complejidad computacional que las LSTM.

Los resultados del estudio muestran que este enfoque híbrido mejora significativamente métricas de error como RMSE y MAE frente a modelos tradicionales como ARIMA y redes neuronales *feedforward*. Los autores concluyen que la arquitectura GRU, por su diseño más sencillo y menor riesgo de sobreajuste, resulta especialmente adecuada para aplicaciones financieras caracterizadas por datos ruidosos y no lineales, ofreciendo una herramienta potente para apoyar la toma de decisiones en predicción de precios y trading algorítmico.

6. Descripción del enfoque de solución

En el contexto de la gestión de fondos mutuos de renta fija, uno de los desafíos clave es predecir con precisión los flujos de aportes y rescates, los cuales pueden verse influenciados por diversos factores económicos, sociales y financieros.

El enfoque de solución propuesto para este proyecto se basa en la implementación de técnicas de *machine learning* y modelos estadísticos tradicionales, con el objetivo de crear un sistema predictivo que permita anticipar los movimientos de los fondos mutuos en función de variables claves como lo son las rentabilidades pasadas.

A continuación, se detalla la metodología adoptada para el desarrollo de este modelo, desde la recolección de datos hasta su implementación final, así como las técnicas utilizadas para garantizar su efectividad en escenarios de alta volatilidad.

Como parte de la solución propuesta para predecir los flujos de aportes y rescates en fondos mutuos, se llevó a cabo un proceso de *web scraping* en la página web de la Asociación de Administradoras de Fondos Mutuos de Chile (AAFM). Este proceso permitió la extracción de datos clave relacionados con las rentabilidades de los fondos y los movimientos de aportes y rescates, elementos esenciales para alimentar los modelos predictivos desarrollados en este estudio.

El principal objetivo de este *web scraping* fue rescatar información histórica sobre los flujos de aportes y rescates de fondos mutuos y las rentabilidades de estos fondos en diferentes plazos, con el fin de poder predecir el porcentaje de aportes y rescates considerando sus diferentes rentabilidades pasadas. Los datos extraídos incluyen variables como:

- Rentabilidad diaria nominal (diaria_nominal)
- Rentabilidad nominal a 7 días (nominal_7d)
- Rentabilidad real a 7 días (real_7d)
- Rentabilidad nominal a 30 días (nominal_30d)
- Rentabilidad real a 30 días (real_30d)
- Rentabilidad nominal a 3 meses (nominal_3m)
- Rentabilidad real a 3 meses (real_3m)
- Rentabilidad nominal a 12 meses (nominal_12m)
- Rentabilidad real a 12 meses (real_12m)

Es importante destacar que estas rentabilidades se agrupan según el horizonte temporal (rentabilidad diaria, a 7 días, 30 días, 90 días, 12 meses y YTD) y su naturaleza, ya sea nominal o real (ajustada por la inflación correspondiente a cada periodo).

6.1 Carga y Preprocesamiento de Datos

Carga del archivo y Selección de Variables: Una vez que ejecuté el *web scraping* y obtuve información de los últimos 15 años de operaciones. Se eligieron las columnas específicas para analizar los flujos, como % aporte/rescate, y las variables de rendimiento a diferentes plazos, tales como Nom_7d+1, Real_7d+1, Nom_30d+1, , etc. Con esto sólo se incluyó la data con la que se entrenarían los modelos, beneficiando la optimización en la resolución de estos.

Identificación de *outliers*: Se agrupan los datos por categoría_afm (categoría del fondo, las cuales son Fondos de Deuda < 365 días Nacional en Pesos, Fondos de Deuda < 365 días Nacional en UF, Fondos de Deuda < 90 días Nacional, Fondos De Deuda > 365 Dias Nacional Inversion En Uf > 5 Años, Fondos De deuda > 365 Dias Nacional, Inversion Uf > 3 Años Y =<5, Fondos De Deuda > 365 Dias Nacional, Inversión En Pesos, Fondos De Deuda > 365 Dias Nacional, Inversión En Uf < 3 Años, Fondos De Deuda > 365 Dias Orig. Flex, Inversionistas Calificados Títulos De Deuda) y, para cada grupo, se calcula la media y la desviación estándar de las variables seleccionadas.

Los *outliers* son identificados como valores que se encuentran fuera del rango definido por la media ± 3 veces la desviación estándar. Estos valores se almacenan y luego se eliminan del *DataFrame* creado para limpiar los datos.

La finalidad de este paso es asegurar que los datos estén limpios, sin valores erróneos o extremos, y listos para ser analizados de forma efectiva.

6.2 Limpieza de Datos y Filtrado por Categorías

Filtrado por valores extremos: Se eliminan valores extremos en las rentabilidades para todos los plazos como -10% y 10% en las columnas seleccionadas para asegurar que no afecten el análisis. Este paso se realiza para cada grupo o categoría de fondo (categoría_afm).

Eliminación de valores faltantes: Después de filtrar los datos, se eliminan las filas que contienen valores faltantes, lo cual asegura que no haya datos incompletos durante el análisis y modelado.

Con esto se mejora la calidad de los datos al eliminar valores que podrían distorsionar los análisis o modelos predictivos, asegurando que solo los datos limpios y consistentes se utilicen en el proceso.

6.3 Análisis Descriptivo

Cálculo de estadísticas descriptivas: Se agrupan los datos por categoría de fondo, y luego se calcula un análisis descriptivo sobre las columnas seleccionadas. Este análisis incluye métricas como la media, desviación estándar, mínimo, máximo, y los cuartiles, proporcionando una visión general de cómo se distribuyen los flujos y rendimientos a través de diferentes categorías de fondos.

Este paso es fundamental para obtener una comprensión profunda de la distribución y el comportamiento de las variables clave. Esto sirve como base para los siguientes pasos de modelado, proporcionando información que puede guiar el ajuste de los modelos.

6.4 Generación de Gráficos de Análisis Exploratorio

Gráficos de líneas: Para cada categoría de fondo, como también sus respectivas rentabilidades, se generan gráficos de líneas para mostrar la evolución de las variables seleccionadas a lo largo del tiempo y ver de manera gráfica como se distribuyen cada una de estas variables. Esto permite observar tendencias temporales y posibles ciclos en los flujos de aportes y rescates.

Gráficos de dispersión (*scatter plots*): Se crean gráficos de dispersión para cada variable de rendimiento frente al porcentaje de aporte/rescate (% aporte/rescate). Además, se calcula la correlación de Pearson entre las variables para identificar relaciones lineales.

Histogramas: Se generan histogramas para cada columna seleccionada, con el fin de visualizar la distribución de cada variable y entender mejor su comportamiento, observando si las variables siguen una distribución normal o si presentan sesgos.

Boxplots: Se generan *boxplots* para cada categoría, lo que ayuda a identificar los valores atípicos (*outliers*) y a entender la dispersión de los datos dentro de cada grupo.

Generar la visualización de las relaciones y patrones subyacentes en los datos proporciona una comprensión intuitiva de cómo se comportan los flujos de fondos a lo largo del tiempo, ayudando en la toma de decisiones para la selección de modelos adecuados.

6.5 Pruebas de Normalidad

- Test de normalidad: Se utilizan tres pruebas estadísticas para evaluar si las series de tiempo siguen una distribución normal:

- Shapiro-Wilk: Para determinar si una muestra proviene de una distribución normal.
- Kolmogorov-Smirnov: Para comparar la distribución empírica de los datos con una distribución normal teórica.
- Anderson-Darling: Para evaluar la normalidad en función de los valores críticos.

Si las pruebas indican que las variables no son normales, el modelo debe ajustarse en consecuencia, ya que algunos modelos estadísticos requieren datos normalmente distribuidos. Esto es importante porque muchos modelos estadísticos, como ARIMA, asumen que los datos son distribuidos normalmente.

Dado esto es importante garantizar que los modelos estadísticos seleccionados sean adecuados para los datos, evitando sesgos o resultados incorrectos debido a la no normalidad de las variables.

6.6 Descomposición de Series Temporales

Descomposición aditiva: Para cada serie temporal de la columna % aporte/rescate, se realiza una descomposición aditiva usando el complemento *seasonal_decompos*. Esto separa la serie en tres componentes: tendencia, estacionalidad y residualidad.

El fin de este proceso es entender los componentes subyacentes de las series temporales, lo que mejora la capacidad para prever los flujos futuros. Al identificar estos componentes, se pueden ajustar los modelos para capturar la estacionalidad y las tendencias de manera más precisa.

Evaluación de Estacionariedad

Prueba ADF (*Augmented Dickey-Fuller*): La prueba ADF se aplica a cada serie temporal de % aporte/rescate para determinar si las series son estacionarias o no. Si la serie no es estacionaria, se podría requerir una transformación, como la diferenciación, para hacerla estacionaria antes de aplicar ciertos modelos como ARIMA.

La salida de la prueba ADF incluye el estadístico ADF, el *p-valor*, y los valores críticos. Si el *p-valor* es menor a 0.05, se rechaza la hipótesis nula, lo que indica que la serie es estacionaria.

Esta prueba ayuda a determinar si las series temporales son estacionarias, lo que es una condición necesaria para la aplicación de modelos como ARIMA. Si una serie no es estacionaria, se aplican transformaciones, como la diferenciación, para hacerla estacionaria y garantizar que los modelos predictivos puedan generar resultados válidos.

6.7 Modelado Predictivo con ARIMA y SARIMAX

Los modelos ARIMA y SARIMAX se utilizan para predecir los flujos de aportes y rescates a partir de series temporales pasadas. ARIMA es adecuado para datos sin estacionalidad, mientras que SARIMAX incorpora componentes estacionales y variables exógenas, como la rentabilidad pasada de los fondos, lo que permite capturar patrones más complejos.

El fin de ambos modelos es predecir con mayor precisión los flujos de los fondos mutuos utilizando modelos robustos que pueden adaptarse tanto a las tendencias como a las variaciones estacionales y exógenas. Esto es crucial para la toma de decisiones informadas en la gestión de los fondos.

ARIMA: Se ajusta un modelo ARIMA (*AutoRegressive Integrated Moving Average*) a la serie temporal de cada categoría. El modelo es ajustado con parámetros predefinidos (p , d , q), y luego se generan predicciones para los próximos 12 pasos (por ejemplo, meses). Los resultados se grafican y se evalúan utilizando el RMSE (*Root Mean Squared Error*) para medir el error de las predicciones.

SARIMAX: Para capturar componentes estacionales en los datos, se utiliza SARIMAX (*Seasonal ARIMA with Exogenous Variables*). Este modelo también incluye variables exógenas (como los rendimientos de otros plazos) que podrían influir en los flujos de aportes y rescates.

Comparación de modelos: Se comparan los modelos ARIMA y SARIMAX utilizando métricas como AIC (*Akaike Information Criterion*) y BIC (*Bayesian Information Criterion*), que ayudan a seleccionar el modelo más adecuado para cada categoría de fondo.

6.8 Evaluación y Comparación de Modelos

El RMSE y otras métricas como AIC y BIC se utilizan para evaluar la precisión de los modelos y comparar su rendimiento. Este paso es esencial para determinar qué modelo (ARIMA o SARIMAX) proporciona las predicciones más exactas y es más adecuado para los datos.

Dicho esto, se calcula el RMSE para cada modelo y horizonte de predicción (1, 7, 30, 90 días). Este paso evalúa qué tan bien se ajustan los modelos ARIMA y SARIMAX a los datos históricos, graficando las predicciones generadas por ambos modelos y se comparan visualmente con los valores reales de los flujos de aportes y rescates.

Con esto se selecciona el modelo más eficiente para la predicción de flujos de fondos, asegurando que los resultados sean confiables y útiles para la toma de decisiones en la gestión de carteras.

6.9 Preprocesamiento de Datos para Modelos de Machine Learning

Una vez ejecutado el proceso de descomponer la serie temporal y evaluar modelos de series de tiempo, se comienza a realizar el preprocesamiento inicial de modelos de *machine learning*: Redes Neuronales Recurrentes (GRU y LSTM) y Modelos Tradicionales de *machine learning* (SVM, Árboles de Decisión, Random Forest, XGBoost). El preprocesamiento se realiza una sola vez para ambos enfoques, garantizando que los datos estén listos para su uso en diversos modelos sin necesidad de repetir pasos innecesarios.

6.10 Escalado de Datos y Creación de Secuencias Temporales

Para asegurar que las características y la variable objetivo estén en el mismo rango, se utiliza *MinMaxScaler* para escalar tanto las variables de entrada (X) como la variable de salida (% aporte/rescate). Luego, se crean las secuencias temporales, que son esenciales para los modelos de Redes Neuronales Recurrentes como GRU y LSTM. Este proceso genera una representación secuencial de los datos con un tamaño de ventana (*time_step*), lo que es crucial para capturar dependencias temporales.

El escalado y la creación de secuencias asegura que los datos estén adecuadamente preparados tanto para los modelos GRU y LSTM como para los modelos tradicionales de *machine learning*, sin redundancias en el preprocesamiento.

6.11 Entrenamiento de Modelos GRU y LSTM

Se entrenan los modelos GRU (Gated Recurrent Unit) y LSTM (*Long Short-Term Memory*) para predecir los flujos de aportes y rescates a partir de las secuencias temporales generadas. Ambos modelos son variantes de redes neuronales recurrentes (RNN), diseñadas para capturar dependencias a largo plazo en series temporales. Los modelos se entrenan con las mismas características y la variable objetivo, utilizando el optimizador Adam y aplicando *EarlyStopping* para evitar el sobreajuste.

Los modelos GRU y LSTM son entrenados para captar patrones temporales complejos en los datos, lo que es esencial para realizar predicciones precisas de los flujos de fondos. Los resultados de cada modelo se evalúan utilizando métricas como MSE y RMSE.

6.12 Entrenamiento de Modelos Tradicionales de Machine Learning

De manera paralela se entrenan modelos tradicionales de *machine learning* como SVM (Support Vector Machine), Árbol de Decisión, Random Forest y XGBoost. Al igual que en los modelos de redes neuronales, se escalan los datos y se dividen en conjuntos de entrenamiento y prueba. Estos modelos no requieren secuencias temporales, pero son igualmente capaces de capturar patrones en los datos de aportes y rescates.

Con esto se prueban otros enfoques de *machine learning* que puedan ser adecuados para predecir los flujos de aportes y rescates. Estos modelos son útiles para comparar la precisión y eficiencia con los modelos recurrentes GRU y LSTM.

6.13 Evaluación de Modelos con Métricas de Rendimiento

Una vez entrenados los modelos, se evalúa el rendimiento utilizando las métricas MSE (*Mean Squared Error*) y RMSE (*Root Mean Squared Error*). Estas métricas son utilizadas para comparar el rendimiento entre los modelos de Redes Neuronales (GRU y LSTM) y los modelos tradicionales de *Machine Learning* (SVM, Árbol de Decisión, Random Forest, XGBoost). Los valores de cada métrica se almacenan en *DataFrames* separados, lo que permite una comparación clara entre los modelos.

Con el fin de evaluar y comparar el rendimiento de los modelos entrenados, asegurando que los más precisos y adecuados para predecir los flujos de fondos sean seleccionados para su implementación.

Generación de tablas para Evaluar las Predicciones

Se generan gráficos para comparar las predicciones realizadas por los modelos con los valores reales de los flujos de aportes y rescates. Los gráficos permiten visualizar cómo los modelos GRU, LSTM y los modelos tradicionales capturan las tendencias y fluctuaciones de los datos a lo largo del tiempo. Los gráficos proporcionan una forma visual de entender la precisión de las predicciones.

Ayudar a interpretar visualmente los resultados de los modelos, permitiendo una comparación directa de las predicciones frente a los datos reales. Esto también facilita la detección de patrones no capturados por los modelos y áreas de mejora.

6.14 Generación de Resultados y Discusiones

Los resultados de las predicciones y las métricas de rendimiento (RMSE, AIC, BIC) se almacenan en un archivo Excel para facilitar su revisión, proporcionando una documentación clara y accesible de los resultados, lo que facilita la interpretación y la

toma de decisiones basadas en los modelos predictivos. Además, los gráficos generados durante el análisis, como los de las predicciones de ARIMA y SARIMAX, se almacenan en un archivo PDF para su presentación y análisis visual.

Con los resultados de las métricas almacenados en Excel, se realiza un análisis comparativo entre los diferentes modelos, centrado en determinar cuál de ellos, ya sea GRU, LSTM o los modelos tradicionales de *machine learning*, ofrece las predicciones más precisas.

Este análisis permite tomar decisiones informadas sobre el modelo más adecuado para predecir los flujos de aportes y rescates en fondos mutuos. La finalidad de este enfoque es seleccionar el modelo más preciso y adecuado para predecir los flujos, optimizando así la toma de decisiones en la gestión de fondos mutuos, mejorando la precisión de las predicciones y utilizando el modelo seleccionado para guiar las decisiones de inversión y gestión de carteras.

7. Resultados

En esta sección se presentan los resultados del estudio organizados en cuatro etapas principales para facilitar su comprensión y análisis. Primero, se describe el análisis exploratorio y las pruebas de estacionaridad aplicadas a las series de tiempo, identificando sus propiedades estadísticas básicas.

En segundo lugar, se detallan los resultados de la descomposición de las series en componentes de tendencia, estacionalidad y residuales para cada categoría de fondo. En la tercera parte, se comparan los modelos ARIMA y SARIMAX en términos de capacidad predictiva y error cuadrático medio, destacando las ventajas de incluir variables exógenas.

Finalmente, se analizan los resultados obtenidos con diferentes enfoques de *machine learning*, evaluando su desempeño predictivo en distintos horizontes temporales y tipos de fondo. Cada subsección incluye métricas, gráficos clave y una discusión breve que permite interpretar los hallazgos en el contexto del problema de negocio

Dado esto, es que a partir de la base de datos consolidada con métricas de rentabilidad nominal y real en distintos plazos (diaria, 7 días, 30 días, 3 meses, 12 meses y YTD), se construyó un resumen estadístico por cada categoría de fondo (categoria_afm) y de la variable que se quiere medir que es %Aporte/Rescate, donde se hicieron cálculos como:

La media general de rentabilidad, como indicador de retorno esperado, además de la desviación estándar promedio, como aproximación al riesgo total o volatilidad asociada a las rentabilidades observadas y %Aporte y Rescates con respecto al patrimonio de cada fondo

Este enfoque permite evaluar y comparar el rendimiento global ajustado por riesgo de los distintos fondos. A continuación se resumen los principales hallazgos:

7.1 %Aporte/Rescates y Distribución de Rentabilidades

Esta variable (ver tabla 1) muestra valores similares para los fondos de mayor duración y, por ende, con un mayor riesgo implícito, donde las medias oscilan entre 0.08 y 0.24⁷, con desviaciones estándar comparables entre ellos, a excepción de los fondos de Inversionistas Calificados en Títulos de Deuda.

⁷ Para hacer comparables las rentabilidades de todos los fondos, lo que se realizó fue una anualización de los resultados, con el fin de extrapolar cada rentabilidad a una medida anual y con eso poder compararlas.

Por otro lado, el único fondo que presenta una clara diferencia en sus valores es el de "Deuda <90 días Nacional", el cual exhibe una alta volatilidad en sus porcentajes de aportes y rescates, evidenciando una gran brecha entre su valor mínimo y máximo.

Tabla 1.

Resumen Estadístico variable %Aporte/Rescate

Categoría FM	count	mean	std	min	25%	50%	75%	max
Fondos De Deuda < 365 Días Nacional En Pesos	3.718	0,24	0,73	-2,94	-0,15	0,09	0,52	3,54
Fondos De Deuda < 365 Días Nacional En Uf	3.721	0,17	0,78	-3,99	-0,22	0,11	0,50	4,44
Fondos De Deuda < 90 Días Nacional	3.689	4,46	10,58	-27,02	-0,52	0,22	1,82	31,00
Fondos De Deuda > 365 Días Nacional, Inversion En Uf > 5 Años	3.189	0,07	0,52	-2,36	-0,14	0,06	0,29	2,66
Fondos De Deuda > 365 Días Nacional, Inversion Uf > 3 Años Y =<5	3.629	0,10	0,32	-1,19	-0,08	0,10	0,30	1,34
Fondos De Deuda > 365 Días Nacional, Inversión En Pesos	3.513	0,08	0,60	-2,25	-0,24	0,01	0,34	2,39
Fondos De Deuda > 365 Días Nacional, Inversión En Uf < 3 Años	3.698	0,11	0,48	-3,46	-0,14	0,11	0,35	3,24
Fondos De Deuda > 365 Días Orig. Flex	3.613	0,19	0,46	-1,60	-0,06	0,17	0,43	1,98
Inversionistas Calificados Títulos De Deuda	3.467	0,16	1,21	-5,03	-0,24	0,04	0,48	5,65

De acuerdo con la tabla número 2⁸ podemos inferir lo siguiente sobre la estadística descriptiva de cada fondo.

Tabla 2.

Resumen Estadísticos Rentabilidades de cada Categoría FM

Plazo	Mean/ Std	Fondos De Deuda < 365 Días Nacional En Pesos	Fondos De Deuda < 365 Días Nacional En Uf	Fondos De Deuda < 90 Días Nacional	Fondos De Deuda > 365 Días Nacional, Inversion En Uf > 5 Años	Fondos De Deuda > 365 Días Nacional, Inversion Uf > 3 Años Y =<5	Fondos De Deuda > 365 Días Nacional, Inversión En Pesos	Fondos De Deuda > 365 Días Nacional, Inversión En Uf < 3 Años	Fondos De Deuda > 365 Días Orig. Flex	Inversionistas Calificados Títulos De Deuda
Promedio	Mean Std	2,33 3,86	2,76 5,30	2,05 3,09	-57,46 104,43	3,80 11,91	2,36 7,32	3,41 8,64	3,84 9,91	3,69 29,78

Fondos de Deuda < 365 Días Nacional en Pesos

- Rentabilidad promedio: 2.33%
- Volatilidad promedio: 3.86%

Perfil conservador con retornos moderados y comportamiento estable, ideal para inversionistas de bajo riesgo.

Fondos de Deuda < 365 Días Nacional en UF

- Rentabilidad promedio: 2.76%

⁸ Esta tabla es un resumen de la estadística descriptiva de estas variables, la cual esta de manera más detallada en el anexo 1 de este documento.

- Volatilidad promedio: 5.30%

Mejor rendimiento que su par en pesos, con una leve alza en la dispersión. Recomendable en contextos de inflación alta.

Fondos de Deuda < 90 Días Nacional

- Rentabilidad promedio: 2.05%
- Volatilidad promedio: 3.09%

Fondos muy líquidos y de bajo rendimiento, pero con excelente estabilidad en el corto plazo.

Fondos de Deuda > 365 Días Nacional, Inversión en UF > 5 Años

- Rentabilidad promedio: -57.46%
- Volatilidad promedio: 104.43%

Es la categoría con peor desempeño agregado y mayor riesgo, reflejando fuertes salidas y baja valorización en períodos de alta volatilidad en tasas largas, este fondo es altamente volátil a cambios en la percepción del riesgo local e internacional.

Fondos de Deuda > 365 Días Nacional, Inversión en UF entre 3 y 5 Años

- Rentabilidad promedio: 3,80%
- Volatilidad promedio: 11,91%

Atractivo rendimiento, aunque acompañado de una dispersión significativa. Fondo adecuado para perfiles con tolerancia al riesgo intermedio.

Fondos de Deuda > 365 Días Nacional, Inversión en Pesos

- Rentabilidad promedio: 2.36%
- Volatilidad promedio: 7.32%

Alternativa en moneda local con buen control de riesgo. Muestra retornos estables, inferiores a su par en UF.

Fondos de Deuda > 365 Días Nacional, Inversión en UF < 3 Años

- Rentabilidad promedio: 3.41%
- Volatilidad promedio: 8.64%

Equilibrio entre retorno y riesgo, adecuado para inversionistas que buscan duración intermedia.

Fondos de Deuda > 365 Días, Origen Flexible

- Rentabilidad promedio: 3.84%
- Volatilidad promedio: 9.91%

Fondo versátil, con una rentabilidad atractiva y riesgo relativamente contenido.

Inversionistas Calificados – Títulos de Deuda

- Rentabilidad promedio: 3.69%
- Volatilidad promedio: 29.78%

Categoría que presenta el perfil más especulativo. Altos retornos, pero acompañados de máxima dispersión, reflejando estrategias más activas y concentradas.

Al visualizar la forma en que se comportan estas rentabilidades, vemos que se condicen con su expectativa de inversión y perfil del inversionista, donde al ser fondos de mayor riesgo (por su horizonte y forma de inversión) presentan una mayor volatilidad en sus desempeños.

Comportamiento general de las rentabilidades

En términos generales, los fondos con mayor duración y denominados en UF tienden a mostrar mayores rentabilidades medias, aunque acompañadas de una mayor dispersión. Por ejemplo:

Fondos de Deuda >365 días en UF (flexibles y >3 años) presentan rentabilidades nominales de 12 meses superiores al 4,5% en promedio, con desviaciones estándar también elevadas (más de 2,4%), lo cual evidencia mayor volatilidad pero potencial de rendimiento en el largo plazo.

En contraste, los fondos de corto plazo en pesos (<90 días) muestran rentabilidades estables pero bajas, con medias cercanas al 1% y baja dispersión, ideal para perfiles conservadores.

Boxplots: Distribución y presencia de *outliers*

Los gráficos de *boxplot* (ver gráfico de anexos) evidencian una alta presencia de valores atípicos en rentabilidades reales, particularmente:

En rentabilidad real 3m y 12m de los fondos de largo plazo en UF, se observan extremos significativos tanto positivos como negativos, indicando exposición a choques de inflación o movimientos del tipo de cambio.

Fondos en pesos a corto plazo muestran distribuciones más simétricas y concentradas, con menor dispersión y prácticamente sin *outliers*.

7.2 Evaluación de Normalidad, Estacionariedad y Estructura Temporal de la Variable Objetivo

Como paso previo al modelamiento, se realizó un análisis estadístico de la variable objetivo % aporte/rescate para evaluar su distribución, comportamiento temporal y características de estacionariedad. Este análisis permite definir si es necesario aplicar transformaciones o utilizar enfoques robustos al momento de ajustar modelos predictivos.

A. Evaluación de Normalidad: Se aplicaron tres pruebas estadísticas clásicas para determinar la normalidad de las rentabilidades: Shapiro-Wilk, Kolmogorov-Smirnov (KS) y Anderson-Darling. Los resultados, indican de manera sistemática que las rentabilidades asociadas a todas las categorías de fondos no siguen una distribución normal.

En resumen en la prueba de Shapiro-Wilk, todos los p-valores fueron significativamente menores a 0.05. Mientras que las pruebas de Kolmogorov-Smirnov y Anderson-Darling confirmaron esta conclusión, con valores críticos que superan los umbrales establecidos.

B. Estacionariedad de la Serie: Adicionalmente, se aplicó la prueba de Dickey-Fuller aumentado (ADF) a la serie % aporte/rescate para cada categoría de fondo con el objetivo de evaluar si las series son estacionarias, es decir, si su comportamiento estadístico no varía en el tiempo.

Los resultados fueron contundentes, en todos los fondos el estadístico ADF fue significativamente negativo y el p-valor menor a 0.01, permitiendo rechazar la hipótesis nula de presencia de raíz unitaria (Ver tabla 2). Esto significa que todas las series analizadas son estacionarias.

Este hallazgo es especialmente relevante, ya que valida el uso de modelos lineales y de series de tiempo que requieren estacionariedad como supuesto base (por ejemplo, ARMA o modelos SARIMAX).

Tabla 2

<i>Resultados de Estacionariedad</i>					
Categoría de Fondo	ADF Test Statistic	P-Value	Lags Used	Numero Observaciones	Estacionario/No Estacionario
Fondos De Deuda < 365 Dias Nacional En Pesos	-7.871	4.968e-12	30	3687	Se rechaza hipótesis nula y es Estacionaria
Fondos De Deuda < 365 Dias Nacional En Uf	-8.577	7.869e-12	30	3.690	Se rechaza hipótesis nula y es Estacionaria
Fondos De Deuda < 90 Dias Nacional	-7.047	5.637e-10	30	3.658	Se rechaza hipótesis nula y es Estacionaria

Fondos De Deuda > 365 Dias Nacional, Inversión En Uf > 5 Años	-8.278	4.594e-10	24	3.164	Se rechaza hipótesis nula y es Estacionaria
Fondos De Deuda > 365 Dias Nacional, Inversión Uf > 3 Años Y =<5	-9.018	5.847e-15	24	3.604	Se rechaza hipótesis nula y es Estacionaria
Fondos De Deuda > 365 Dias Nacional, Inversión En Pesos	-9.273	1.311e-15	26	3.486	Se rechaza hipótesis nula y es Estacionaria
Fondos De Deuda > 365 Dias Nacional, Inversión En Uf < 3 Años	-8.430	1.874e-13	30	3.667	Se rechaza hipótesis nula y es Estacionaria
Fondos De Deuda > 365 Dias Orig. Flex	-8.536	1.003e-13	27	3.585	Se rechaza hipótesis nula y es Estacionaria
Inversionistas Calificados Títulos De Deuda	-11.082	4.266e-20	19	3.447	Se rechaza hipótesis nula y es Estacionaria

Nota. Fuente: Generación Propia

7.3 Autocorrelación

Finalmente, se analizó la autocorrelación de la variable % aporte/rescate para distintos horizontes (1 día, 7 días, 30 días, 90 días y 365 días). Los resultados reflejan que:

En la mayoría de los fondos, la autocorrelación a corto plazo (1 y 7 días) es positiva y significativa, entre 0.3 y 0.4. Para horizontes de 30 y 90 días, algunos fondos muestran autocorrelaciones moderadas (hasta 0.59 en fondos de <90 días), mientras que a 365 días, los niveles son bajos o incluso cercanos a cero (tabla 3).

Este comportamiento evidencia una persistencia de corto plazo, lo cual es coherente con un sistema influenciado por decisiones de inversión o rescate en ventanas semanales o mensuales.

Tabla 3

Resultados de Autocorrelación de Categorías de Fondo sobre % Aporte/Rescate

Categoría de Fondo	1 día	7 días	30 días	90 días	365 días
Fondos de Deuda <365 días Nacional en CLP	- 0.00	0.02	0.32	0.19	0.03
Fondos De Deuda < 365 Dias Nacional en UF	0.42	0.28	0.07	0.03	0.03
Fondos De Deuda < 90 Dias Nacional	- 0.25	-0.20	0.59	0.47	0.10
Fondos De Deuda > 365 Dias Nacional, Inversión En Uf > 5 Años	0.39	0.25	0.09	0.04	-0.01

Fondos De Deuda > 365 Dias Nacional, Inversión Uf > 3 Años Y =<5	0.41	0.28	0.11	0.02	-0.01
Fondos De Deuda > 365 Dias Nacional, Inversión En Pesos - Número de datos	0.4	0.3	0.07	0.02	-0.03
Fondos De Deuda > 365 Dias Nacional, Inversión En Uf < 3 Años	0.41	0.24	0.15	0.07	0.02
Fondos De Deuda > 365 Dias Orig. Flex	0.31	0.24	0.07	0.06	0.01
Inversionistas Calificados Títulos De Deuda	- 0.01	-0.04	0.03	-0.01	0.00


Nota.Fuente: Generación propia

7.4 Análisis de la Descomposición de Series de Tiempo por Categoría de Fondo

Al aplicar la descomposición clásica aditiva sobre la serie temporal del porcentaje de aportes y rescates, se identificaron patrones diferenciados en los componentes de tendencia, estacionalidad y residuos, los cuales varían según el tipo de fondo. A continuación, se describe de manera integrada el comportamiento observado en cada categoría:


I. Fondos De Deuda < 365 Días Nacional En Pesos

Este fondo presenta una tendencia estable, con oscilaciones leves a lo largo del tiempo. Se identifica una estacionalidad cíclica clara, lo que sugiere patrones de comportamiento recurrentes. Los residuos están bien distribuidos en torno a cero, lo que indica variabilidad idiosincrática pero sin anomalías estructurales.




II. Fondos De Deuda < 365 Días Nacional En UF

Similar al fondo anterior, se observa una tendencia relativamente plana y una estacionalidad persistente. Sin embargo, se presentan picos y caídas aisladas, lo que podría reflejar eventos exógenos como cambios en la inflación o ajustes regulatorios temporales.




III. Fondos De Deuda < 90 Días Nacional

La serie de % aporte/rescate en fondos de deuda < 90 días nacionales muestra alta volatilidad y valores extremos, especialmente con un quiebre notable alrededor de 2018 (eliminación de *outliers*). La tendencia evidencia ciclos de alza y baja en el tiempo, mientras que la estacionalidad revela patrones repetitivos pero irregulares. El residuo concentra gran parte del ruido e imprevisibilidad, confirmando la dificultad de anticipar estos flujos solo con modelos basados en historia. Sin embargo, la separación en componentes ofrece una base para mejorar la predicción incorporando tendencias, ciclos y variables externas.




IV. Fondos De Deuda > 365 Días Nacional, Inversión En UF > 5 Años

Este fondo muestra una tendencia levemente creciente, pero con oscilaciones moderadas. La componente estacional es débil, lo que sugiere que los flujos no responden a un patrón cíclico marcado. Los residuos relativamente altos apuntan a una posible mayor sensibilidad frente a eventos de mercado o condiciones de liquidez.




V. Fondos De Deuda > 365 Días Nacional, Inversión UF > 3 Años y ≤ 5 Años

En este caso, se aprecia un comportamiento más estructurado, con una tendencia ascendente sostenida y una estacionalidad estable, probablemente vinculada a ciclos anuales de inversión institucional. La variabilidad residual se mantiene controlada, lo que facilita su análisis predictivo.




VI. Fondos De Deuda > 365 Días Nacional, Inversión En Pesos

Este fondo mantiene una tendencia sin dirección clara, lo que refleja estabilidad en el mediano plazo. La estacionalidad moderada sugiere cierta influencia de calendarios fiscales o monetarios, y los residuos muestran baja variabilidad, indicando un comportamiento predecible.




VII. Fondos De Deuda > 365 Días Nacional, Inversión En UF < 3 Años

Se observa un patrón muy similar al de otros fondos en UF, con una estacionalidad definida y tendencia plana. Algunos incrementos puntuales en la serie podrían asociarse a ajustes por expectativas inflacionarias u otros elementos macroeconómicos.




VIII. Fondos De Deuda > 365 Días Orig. Flex

En esta categoría se obtiene una de las descomposiciones más limpias, caracterizada por una estacionalidad clara y una tendencia levemente positiva. La moderación del componente residual sugiere un comportamiento bastante predecible, útil para propósitos de modelamiento.



IX. Inversionistas Calificados Títulos De Deuda

Finalmente, este fondo destaca por su alta variabilidad y por la prominencia de los residuos, lo que refleja su naturaleza más especulativa o volátil. La tendencia es casi nula y la estacionalidad poco marcada, lo que dificulta la predicción basada en patrones históricos recurrentes.



7.5 Conclusiones generales de Estacionaridad

El análisis de la descomposición aditiva de las series temporales del porcentaje de aportes y rescates evidencia diferencias claras entre categorías de fondos, con implicancias directas para su modelado predictivo.

En fondos de deuda <365 días denominados en pesos y UF, se observa una tendencia plana y estacionalidad definida, indicando ciclos recurrentes asociados a calendarios fiscales o bien rotación de liquidez en el sistema. Sin embargo, los fondos <90 días destacan por alta volatilidad, valores extremos y un quiebre estructural alrededor de 2018, con residuos significativos. Esto confirma la dificultad de predecir estos flujos únicamente con datos históricos, resaltando la necesidad de incorporar variables exógenas.

En fondos >365 días, el comportamiento es más heterogéneo. Los de UF >5 años muestran tendencia levemente creciente y estacionalidad débil, junto con residuos altos, sugiriendo mayor exposición a shocks de mercado. En cambio, los UF entre 3 y 5 años presentan tendencia ascendente sostenida y estacionalidad estable, reflejando flujos institucionales más predecibles.

Los fondos en pesos >365 días muestran tendencia sin dirección clara y estacionalidad moderada, con residuos bajos, indicando estabilidad y mayor previsibilidad en el mediano plazo. Los fondos UF <3 años mantienen tendencia plana con estacionalidad definida, aunque con picos asociados a factores macroeconómicos como expectativas inflacionarias.

Destaca la categoría Orig. Flex, con una descomposición limpia, tendencia levemente positiva y estacionalidad clara, además de residuos bajos, lo que la hace especialmente apta para modelos deterministas. Por el contrario, los fondos para Inversionistas Calificados presentan alta variabilidad residual, sin tendencia ni estacionalidad marcada, lo que sugiere un carácter más especulativo y menor previsibilidad.

7.6 Discusión de Modelos ARIMA y SARIMAX

El modelo SARIMAX aplicado a las distintas categorías de fondos de deuda, muestra un comportamiento diverso según la naturaleza y estabilidad histórica de cada fondo. En general, los modelos logran capturar la dinámica temporal con un grado razonable de precisión, especialmente en aquellos fondos con menor volatilidad estructural.

El fondo "Fondos de Deuda < 365 Días Nacional en Pesos" destaca por tener un excelente ajuste: la serie histórica muestra una clara estabilización desde 2016, y el modelo entrega un pronóstico ajustado, con bandas de confianza estrechas, lo que sugiere alta confiabilidad. De forma similar, el fondo "Fondos de Deuda > 365 Días Nacional, Inversión en UF < 3 Años" presenta una serie más ordenada, y el modelo genera una proyección suave y consistente, con bajo nivel de incertidumbre.

En contraste, el modelo aplicado a "Fondos de Deuda < 90 Días Nacional" evidencia un pobre desempeño visual, con bloques o tramos de datos planos o ausentes, lo que afecta negativamente la continuidad y credibilidad del *forecast*.


Fondos con horizontes más largos y denominados en UF, como "> 365 días, UF > 5 Años" o "UF entre 3 y 5 Años", muestran una volatilidad estructural más alta, aunque el modelo logra moderar su predicción en los tramos futuros. Las bandas de confianza son algo más amplias, lo que refleja la mayor incertidumbre asociada a este tipo de fondos.

Por su parte, el fondo "Fondos de Deuda > 365 Días Orig. Flex" combina una alta dispersión histórica con una proyección bastante controlada, lo que indica que el modelo logra adaptarse bien pese al ruido. Al igual que el anterior, el fondo de "Inversionistas Calificados Títulos de Deuda" presenta oscilaciones frecuentes, pero con un ajuste decente del modelo SARIMAX, y una predicción dentro de rangos esperables.










Por otro lado, los resultados de los modelos ARIMA (tabla 2) para las distintas categorías de fondos de deuda muestran en general proyecciones que siguen el nivel promedio reciente de las series, sin grandes tendencias previstas. Para los fondos de deuda de corto plazo (< 365 días en pesos y UF, y < 90 días nacional), las series históricas son muy volátiles y muestran oscilaciones extremas, lo que se traduce en pronósticos levemente ascendentes pero con bandas de confianza muy amplias, reflejando alta incertidumbre.

En las categorías de mayor duración (>365 días en UF o pesos), las predicciones tienden a ser más estables y con bandas de confianza más estrechas, mostrando comportamientos planos o con suaves tendencias y menor riesgo proyectado, especialmente en tramos como UF >5 años o UF 3–5 años; sin embargo, en fondos como Inversionistas Calificados Títulos de Deuda y de origen Flex, aunque las proyecciones son casi planas, persiste una incertidumbre relevante por la dispersión histórica, y en conjunto los modelos ARIMA logran capturar la volatilidad pero proyectan principalmente la continuidad del promedio reciente sin anticipar cambios estructurales.

Gráfico 1: Sarimax



Gráficos 2: ARIMA



7.7 Análisis con variables Exógenas:

Con el objetivo de evaluar la capacidad predictiva sobre los flujos de aportes y rescates en fondos mutuos, se aplicaron modelos ARIMA y SARIMAX a cada una de las categorías de fondos, considerando múltiples horizontes temporales de predicción (1, 7, 12, 30 y 90 días). A continuación, se presenta un análisis integral por categoría y resumido en tabla número 4

Tabla 4,

Resultados de RMSE de Arima y Sarimax de las variables exogenas retabilidades

Categoría Fondo	modelo	RMSE 1d	RMSE 7 d	RMSE 30 d	RMSE 3M	RMSE 12 M
Fondos De Deuda < 365 Días Nacional En Pesos	ARIMA	0,06	0,13	0,39	0,46	0,25
	SARIMAX	0,00	0,37	0,47	0,72	0,47
Fondos De Deuda < 365 Días Nacional En Uf	ARIMA	0,03	0,32	0,36	0,33	0,27
	SARIMAX	0,16	0,34	0,36	0,46	0,22
Fondos De Deuda < 90 Días Nacional	ARIMA	0,75	5,79	7,27	8,95	4,05
	SARIMAX	13,61	14,61	28,08	35,64	14,29
Fondos De Deuda > 365 Días Nacional, Inversion En Uf > 5 Años	ARIMA	0,18	0,31	0,29	0,31	0,21
	SARIMAX	0,19	0,38	0,29	1,01	0,39
Fondos De Deuda > 365 Días Nacional, Inversion Uf > 3 Años Y =<5	ARIMA	0,13	0,06	0,22	0,21	0,31
	SARIMAX	0,03	0,25	0,43	0,35	0,36
Fondos De Deuda > 365 Días Nacional, Inversión En Pesos	ARIMA	0,00	0,17	0,57	0,45	0,41
	SARIMAX	0,00	0,50	1,38	2,08	1,20
Fondos De Deuda > 365 Días Nacional, Inversión En Uf < 3 Años	ARIMA	0,28	0,18	0,35	0,32	0,41
	SARIMAX	0,15	0,36	0,50	1,21	0,37
Fondos De Deuda > 365 Días Orig. Flex	ARIMA	0,06	0,09	0,16	0,19	0,14
	SARIMAX	0,08	0,27	0,21	0,26	0,28
Inversionistas Calificados Títulos De Deuda	ARIMA	0,01	0,16	0,25	0,74	0,14
	SARIMAX	0,06	0,24	0,42	3,95	0,34

Nota. Fuente: Generación Propia

A. Fondos De Deuda < 365 Días Nacional En Pesos

SARIMAX presentó un menor error cuadrático medio (RMSE) que ARIMA, indicando que la inclusión de variables exógenas mejora la capacidad predictiva.

RMSE ARIMA: 0.059 (1 día), 0.130 (7 días), aumentando levemente hacia horizontes mayores.

RMSE SARIMAX: 0.0014 (1 día), 0.107 (7 días), mostrando mayor precisión especialmente en periodos de alta volatilidad.

B. Fondos De Deuda < 365 Días Nacional En UF

Ambos modelos capturan adecuadamente la dinámica del fondo, pero SARIMAX supera levemente a ARIMA en precisión, anticipando mejor ciertos picos de aportes y rescates.

RMSE ARIMA: 0.030 (1 día), 0.180 (30 días).

RMSE SARIMAX: mejora marginal, sobre todo en horizontes medios como 12 días.

C. Fondos De Deuda < 90 Días Nacional

Es uno de los fondos con mayor dificultad de predicción. Ambos modelos presentan errores más altos que en otras categorías.

RMSE ARIMA: 0.745 (1 día), 8.951 (90 días).

Aun así, SARIMAX muestra menor dispersión en sus errores, lo que sugiere una mejor robustez frente al ruido estructural.

D. Fondos De Deuda > 365 Días Nacional, Inversión En UF > 5 Años

El modelo SARIMAX obtiene un desempeño claramente superior, especialmente en la captura de la tendencia de mediano plazo.

ARIMA tiende a subestimar movimientos bruscos, mientras que SARIMAX logra representar mejor los puntos de inflexión.

E. Fondos De Deuda > 365 Días Nacional, Inversión UF > 3 Años y ≤ 5 Años

Ambos modelos tienen un buen ajuste, pero SARIMAX reduce sustancialmente el RMSE respecto a ARIMA.

La inclusión de rentabilidades como variables externas aporta significativamente a la mejora en la predicción.

F. Fondos De Deuda > 365 Días Nacional, Inversión En Pesos

La diferencia de desempeño entre ARIMA y SARIMAX es moderada, aunque el segundo muestra mejor comportamiento frente a cambios abruptos en los flujos.

Esto resulta especialmente útil en contextos con sensibilidad a variables monetarias o fiscales.

G. Fondos De Deuda > 365 Días Nacional, Inversión En UF < 3 Años

Ambos modelos muestran desempeños aceptables.

El patrón estacional permite un ajuste relativamente bueno con ARIMA, aunque SARIMAX mejora la predicción durante episodios extremos.

H. Fondos De Deuda > 365 Días Orig. Flex

Es uno de los fondos con mejor desempeño en ambos modelos.

No obstante, SARIMAX proporciona una mejor captura de las inflexiones cíclicas, probablemente por su sensibilidad a rentabilidades recientes.

I. Inversionistas Calificados Títulos De Deuda

Este fondo presenta la mayor volatilidad y dificultad de modelación.

Ambos modelos presentan errores más altos, pero SARIMAX reduce significativamente la magnitud de estos, validando su uso incluso en contextos altamente complejos.

7.8 Conclusiones de Variables Exógenas

El análisis comparativo entre los modelos ARIMA y SARIMAX aplicado a distintas categorías de fondos de renta fija demuestra que la inclusión de variables exógenas, como las rentabilidades pasadas, mejora significativamente la capacidad predictiva del modelo. En general, SARIMAX supera consistentemente a ARIMA, aunque la magnitud de esta mejora depende de cada fondo.

En los fondos de corto plazo (menos de 365 días), ARIMA logra capturar adecuadamente la estacionalidad estable, pero muestra limitaciones frente a episodios de alta volatilidad. En estos casos, SARIMAX mejora considerablemente el desempeño, especialmente en horizontes de predicción cortos (1 a 7 días), por su lado en fondos de muy corto plazo (menos de 90 días), ambos modelos enfrentan dificultades debido a la alta volatilidad estructural. Sin embargo, SARIMAX presenta menor dispersión en sus errores y mayor robustez frente al ruido, lo que demuestra su capacidad para manejar escenarios impredecibles mediante la incorporación de información externa.

Para los fondos de largo plazo (más de 365 días), SARIMAX destaca aún más por su capacidad para capturar tendencias de mediano plazo y puntos de inflexión, especialmente en fondos denominados en UF con duraciones superiores a 3 años. En estos casos, ARIMA tiende a subestimar los cambios estructurales, mientras que SARIMAX se ajusta mejor gracias a la información exógena relacionada con expectativas inflacionarias y ciclos institucionales.

En categorías de mayor estabilidad, como los fondos de largo plazo en pesos o en UF con duración menor a 3 años, ambos modelos logran un desempeño adecuado; sin embargo, SARIMAX destaca por su capacidad de adaptarse mejor a eventos inesperados. Asimismo, en fondos Orig. Flex —donde la serie es estructuralmente clara— ambas metodologías funcionan bien, pero SARIMAX identifica con mayor precisión las inflexiones cíclicas, donde la incorporación de variables exógenas agrega valor al modelo.

En conclusión, ARIMA funciona bien como línea base en series estables, pero su capacidad es limitada ante cambios estructurales o influencias externas. Por el contrario, SARIMAX, al incorporar variables exógenas, se muestra como una herramienta más robusta y precisa, capaz de adaptarse a la diversidad de fondos y condiciones del mercado.

7.9 Resultados de Modelos de Machine Learning

Se evaluaron múltiples modelos de machine learning (GRU, LSTM, Decision Tree, SVM, XGBoost y Random Forest) para predecir los flujos de aportes y rescates por categoría de fondo.

A continuación, se presenta un análisis por fondo, destacando el modelo con mejor rendimiento en términos de error cuadrático medio (RMSE), métrica que cuantifica el promedio de los errores de predicción al elevarlos al cuadrado, promediarlos y luego aplicar la raíz cuadrada. En este caso, el RMSE se interpreta en puntos porcentuales, representando el desvío promedio entre los valores reales y los valores predichos por cada modelo.

Modelo GRU:

El modelo GRU muestra un rendimiento destacado en fondos de deuda a largo plazo, como los fondos de más de 365 días, con un RMSE promedio de 0.44 (Tabla 5), lo que indica una buena precisión en las predicciones. Sin embargo, presenta un desempeño significativamente peor en fondos de deuda a corto plazo, como los de menos de 90 días nacionales, con un RMSE promedio de 10.65.

En Palabras simples este modelo es capaz de predecir con una desviación de un 24%, las variaciones porcentuales de la variable %aportes/rescates considerando su variable de rentabilidad como variable independiente sus rentabilidades

Tabla 5.

Resultados de GRU de cada tipo de Rentabilidad sobre "%Aporte/Rescate"

Categoría Fondo	Diaria	Nom7d	Real7d	Nom30d	Real30d	Nom3m	Real3m	Nom12m	Real12m	Avg
Fondos De Deuda < 365 Días Nacional En Pesos	0,44	0,42	0,43	0,40	0,42	0,42	0,42	0,44	0,43	0,42
Fondos De Deuda > 365 Días Nacional, Inversion Uf > 3 Años Y =<5	0,24	0,25	0,26	0,25	0,24	0,25	0,25	0,25	0,26	0,25
Fondos De Deuda > 365 Días Nacional, Inversión En Pesos	0,46	0,48	0,46	0,46	0,43	0,44	0,44	0,46	0,52	0,46
Fondos De Deuda < 90 Días Nacional	10,56	10,63	10,63	10,77	10,57	10,64	10,66	10,59	10,84	10,65
Fondos De Deuda > 365 Días Nacional, Inversión En Uf < 3 Años	0,33	0,34	0,33	0,34	0,33	0,34	0,33	0,33	0,34	0,33
Inversionistas Calificados Títulos De Deuda	0,87	0,87	0,88	0,91	0,86	0,86	0,86	0,87	0,90	0,87
Fondos De Deuda > 365 Días Orig. Flex	0,27	0,28	0,28	0,27	0,26	0,28	0,27	0,29	0,30	0,28
Fondos De Deuda < 365 Días Nacional En Uf	0,33	0,36	0,34	0,43	0,33	0,39	0,37	0,39	0,37	0,37
Fondos De Deuda > 365 Días Nacional, Inversion En Uf > 5 Años	0,43	0,44	0,44	0,43	0,43	0,43	0,44	0,45	0,45	0,44

Nota. Fuente: Generación Propia

Modelo SVM:

El modelo SVM muestra un desempeño consistente en la predicción de %aporte y rescate, destacándose especialmente en los fondos de inversionistas calificados en títulos de deuda, con una rentabilidad constante alrededor de 0.73 en todas las categorías de rentabilidad (diaria, 7d, 30d, 90d, 12m).

Los fondos de deuda a corto plazo (< 90 días nacionales) muestran una alta rentabilidad promedio de 11.62, aunque con una notable volatilidad. En los fondos más estables, como los de deuda a más de 365 días con inversión en UF, las rentabilidades se mantienen entre 0.22 y 0.32, evidenciando una mayor estabilidad. Los fondos con mayor riesgo, como los de deuda > 365 días nacionales, inversión en pesos, presentan rentabilidades cercanas al 0.46.

En general, SVM es más efectivo en fondos de corto plazo o de baja volatilidad, mientras que tiene un desempeño más moderado en fondos de mayor duración o con mayor riesgo (Tabla 6).

Tabla 6.

Resultados de SVM de cada tipo de Rentabilidad sobre "%Aporte/Rescate"

Categoría Fondo	Diaria	Nom7d	Real7d	Nom30d	Real30d	Nom3m	Real3m	Nom12m	Real12m	Avg
Fondos De Deuda < 365 Días Nacional En Pesos	0,42	0,42	0,42	0,42	0,44	0,43	0,43	0,43	0,43	0,43
Fondos De Deuda > 365 Días Nacional, Inversión Uf > 3 Años Y =<5	0,22	0,21	0,22	0,22	0,22	0,22	0,22	0,24	0,29	0,23
Fondos De Deuda > 365 Días Nacional, Inversión En Pesos	0,47	0,49	0,48	0,46	0,46	0,46	0,45	0,46	0,46	0,46
Fondos De Deuda < 90 Días Nacional	11,63	11,62	11,62	11,62	11,62	11,63	11,61	11,62	11,60	11,62
Fondos De Deuda > 365 Días Nacional, Inversión En Uf < 3 Años	0,31	0,31	0,30	0,32	0,29	0,30	0,30	0,31	0,39	0,32
Inversionistas Calificados Títulos De Deuda	0,73	0,73	0,73	0,73	0,73	0,73	0,73	0,73	0,73	0,73
Fondos De Deuda > 365 Días Orig Flex	0,21	0,21	0,21	0,20	0,20	0,22	0,21	0,19	0,23	0,21
Fondos De Deuda < 365 Días Nacional En Uf	0,34	0,33	0,32	0,33	0,29	0,32	0,32	0,33	0,41	0,33
Fondos De Deuda > 365 Días Nacional, Inversión En Uf > 5 Años	0,29	0,29	0,29	0,30	0,30	0,30	0,30	0,29	0,34	0,30

Nota. Fuente: Generación Propia

Modelo Decision Tree:

El modelo Decision Tree muestra un rendimiento equilibrado en la predicción de %aporte y rescate. Se destaca especialmente en los fondos de inversionistas calificados en títulos de deuda, con rentabilidades consistentes que oscilan entre 0.75 y 0.94, con un promedio de 0.79. En los fondos de deuda a corto plazo (< 90 días nacionales), muestra una alta rentabilidad promedio de 10.89, con una mínima variabilidad.

Los fondos de deuda a más de 365 días con inversión en pesos también presentan un buen desempeño, con rentabilidades estables entre 0.47 y 0.52, promediando 0.50. Los

fondos más arriesgados, como los de deuda > 365 días nacionales, inversión en UF y deuda > 365 días orig. Flex, muestran rentabilidades más moderadas, entre 0.23 y 0.40.

En general, el modelo Decision Tree tiene un buen desempeño en fondos de baja volatilidad y más estables, aunque muestra un comportamiento algo más variable en fondos de mayor riesgo o con mayor duración (Tabla 7)

Tabla 7.

Resultados de Decision Tree de cada tipo de Rentabilidad sobre "%Aporte/Rescate"

Categoría Fondo	Diaria	Nom7d	Real7d	Nom30d	Real30d	Nom3m	Real3m	Nom12m	Real12m	Avg
Fondos De Deuda < 365 Días Nacional En Pesos	0,43	0,44	0,44	0,55	0,45	0,48	0,46	0,46	0,56	0,47
Fondos De Deuda > 365 Días Nacional, Inversion Uf > 3 Años Y =<5	0,23	0,23	0,23	0,24	0,22	0,23	0,23	0,23	0,28	0,24
Fondos De Deuda > 365 Días Nacional, Inversión En Pesos	0,50	0,51	0,52	0,49	0,47	0,52	0,50	0,47	0,48	0,50
Fondos De Deuda < 90 Días Nacional	10,83	10,84	11,08	10,85	11,11	10,85	10,83	10,83	10,83	10,89
Fondos De Deuda > 365 Días Nacional, Inversión En Uf < 3 Años	0,36	0,34	0,35	0,42	0,30	0,32	0,31	0,32	0,34	0,34
Inversionistas Calificados Títulos De Deuda	0,76	0,75	0,75	0,76	0,78	0,75	0,86	0,94	0,80	0,79
Fondos De Deuda > 365 Días Orig. Flex	0,25	0,23	0,23	0,25	0,24	0,26	0,24	0,22	0,40	0,26
Fondos De Deuda < 365 Días Nacional En Uf	0,37	0,34	0,55	0,39	0,35	0,36	0,33	0,37	0,45	0,39
Fondos De Deuda > 365 Días Nacional, Inversion En Uf > 5 Años	0,31	0,30	0,32	0,37	0,35	0,30	0,32	0,29	0,35	0,32

Nota. Fuente: Generación Propia

Modelo Random Forest:

El modelo Random Forest muestra un rendimiento consistente en la predicción del %aporte y rescate, destacándose en ciertos fondos. Los fondos de deuda a corto plazo (< 365 días nacionales en pesos) tienen un desempeño sólido con rentabilidades que oscilan entre 0.44 y 0.51, con un promedio de 0.46, destacándose por su baja volatilidad. Los fondos de deuda a más de 365 días con inversión en pesos tienen un comportamiento similar, con rentabilidades promedio de 0.50, con una variabilidad mínima (Tabla 8).

Por otro lado, los fondos de deuda a más de 365 días con inversión en UF y los fondos de deuda a más de 365 días, originados en flex presentan una menor rentabilidad promedio, con valores en torno a 0.30 y 0.24, respectivamente, y una mayor volatilidad en sus valores, lo que indica que son menos predecibles y tienen una mayor exposición al riesgo. Los fondos de inversionistas calificados en títulos de deuda muestran una rentabilidad estable y más alta, con un promedio de 0.76, lo que indica una menor variabilidad y una mayor previsibilidad en su rendimiento.

Tabla 8.

Resultados de Random Forest de cada tipo de Rentabilidad sobre "%Aporte/Rescate"

Categoría Fondo	Diaria	Nom7d	Real7d	Nom30d	Real30d	Nom3m	Real3m	Nom12m	Real12m	Avg
Fondos De Deuda < 365 Días Nacional En Pesos	0,44	0,44	0,44	0,45	0,45	0,48	0,45	0,46	0,51	0,46
Fondos De Deuda > 365 Días Nacional, Inversion Uf > 3 Años Y =<5	0,22	0,22	0,23	0,23	0,23	0,22	0,22	0,23	0,26	0,23
Fondos De Deuda > 365 Días Nacional, Inversión En Pesos	0,50	0,51	0,50	0,49	0,47	0,52	0,47	0,46	0,50	0,49
Fondos De Deuda < 90 Días Nacional	10,84	10,81	10,82	10,85	10,82	10,83	10,82	10,84	10,83	10,83
Fondos De Deuda > 365 Días Nacional, Inversión En Uf < 3 Años	0,35	0,34	0,33	0,33	0,29	0,31	0,31	0,32	0,34	0,33
Inversionistas Calificados Títulos De Deuda	0,75	0,75	0,75	0,76	0,75	0,76	0,75	0,77	0,77	0,76
Fondos De Deuda > 365 Días Orig. Flex	0,24	0,23	0,23	0,24	0,24	0,26	0,24	0,21	0,35	0,25
Fondos De Deuda < 365 Días Nacional En Uf	0,33	0,34	0,33	0,36	0,31	0,37	0,34	0,36	0,46	0,36
Fondos De Deuda > 365 Días Nacional, Inversion En Uf > 5 Años	0,30	0,31	0,33	0,37	0,35	0,29	0,31	0,29	0,33	0,32

Nota. Fuente: Generación Propia

Modelo XGB:

El modelo XGB (XGBoost) muestra un rendimiento destacado en la predicción de %aporte y rescate en diferentes tipos de fondos, con una buena consistencia en los fondos a corto y largo plazo. Los fondos de deuda a corto plazo (< 365 días nacionales en pesos) presentan un rendimiento bastante estable con valores que oscilan entre 0.43 y 0.50, con un promedio de 0.47, lo que sugiere una predicción confiable en fondos de bajo riesgo. De manera similar, los fondos de deuda nacionales en pesos a más de 365 días muestran una rentabilidad promedio de 0.49, destacándose también en su estabilidad y baja volatilidad.

Los fondos de deuda a más de 365 días con inversión en UF, tanto para plazos más cortos como más largos (menos de 3 años y más de 5 años), tienen un rendimiento más moderado, con valores que oscilan entre 0.30 y 0.39, reflejando una predicción más conservadora y controlada. Los fondos de deuda a más de 365 días con inversión en UF > 3 años y <=5 años también muestran una tendencia estable con valores promedio de 0.34.

Los fondos de deuda a menos de 90 días nacionales presentan una volatilidad notablemente alta, con un promedio de 10.86 y valores que oscilan entre 10.70 y 10.98, indicando un comportamiento impredecible y una alta exposición al riesgo en este

segmento. Finalmente, los inversionistas calificados en títulos de deuda muestran una rentabilidad constante y alta, con un promedio de 0.78, lo que sugiere que este fondo tiene un comportamiento estable y confiable.

Tabla 9.

Resultados de XGB de cada tipo de Rentabilidad sobre "%Aporte/Rescate"

Categoría Fondo	Diaria	Nom7d	Real7d	Nom30d	Real30d	Nom3m	Real3m	Nom12m	Real12m	Avg
Fondos De Deuda < 365 Dias Nacional En Pesos	0,45	0,45	0,43	0,45	0,47	0,49	0,46	0,47	0,50	0,46
Fondos De Deuda > 365 Dias Nacional, Inversion Uf > 3 Años Y <=5	0,23	0,22	0,23	0,24	0,23	0,23	0,22	0,23	0,26	0,23
Fondos De Deuda > 365 Dias Nacional, Inversión En Pesos	0,49	0,52	0,51	0,49	0,48	0,53	0,46	0,47	0,49	0,49
Fondos De Deuda < 90 Dias Nacional	10,86	10,80	10,71	10,87	10,98	10,87	10,70	10,86	10,88	10,84
Fondos De Deuda > 365 Dias Nacional, Inversión En Uf < 3 Años	0,35	0,34	0,34	0,33	0,30	0,32	0,32	0,31	0,35	0,33
Inversionistas Calificados Títulos De Deuda	0,76	0,75	0,77	0,78	0,77	0,78	0,78	0,78	0,79	0,77
Fondos De Deuda > 365 Dias Orig. Flex	0,24	0,23	0,24	0,24	0,24	0,25	0,24	0,23	0,33	0,25
Fondos De Deuda < 365 Dias Nacional En Uf	0,34	0,36	0,32	0,37	0,31	0,39	0,34	0,39	0,50	0,37
Fondos De Deuda > 365 Dias Nacional, Inversion En Uf > 5 Años	0,32	0,33	0,33	0,37	0,35	0,30	0,33	0,30	0,34	0,33

Nota. Fuente: Generación Propia

Modelo LSTM:

El modelo LSTM muestra un desempeño heterogéneo en la predicción del porcentaje de aportes y rescates, con resultados que varían según la categoría de fondo y el horizonte temporal evaluado. Destaca especialmente en los fondos de inversionistas calificados

en títulos de deuda, donde mantiene una rentabilidad promedio alta y estable, alrededor de 0.87 a 0.90 en las distintas frecuencias (diaria, 7d, 30d, 90d, 12m), lo que evidencia su capacidad para capturar patrones complejos y no lineales en segmentos con cierta estructura histórica.

En fondos de deuda de corto plazo (<90 días nacionales), el modelo enfrenta mayores dificultades, con rentabilidades promedio muy elevadas, cercanas a 10.6 en todos los horizontes, reflejando una elevada volatilidad y una exposición al ruido que resulta difícil de modelar incluso con arquitecturas recurrentes. En contraste, los fondos más estables o de duración intermedia y larga, como los de más de 365 días con inversión en UF o en pesos, muestran resultados más consistentes, con rentabilidades que oscilan entre 0.25 y 0.45. Esto sugiere que LSTM logra aprovechar la información secuencial en series con menor volatilidad estructural y tendencias más suaves.

Asimismo, en fondos denominados en UF, tanto para tramos cortos (<3 años) como más largos (>5 años), el modelo mantiene un desempeño relativamente estable con valores promedio entre 0.33 y 0.45, evidenciando una capacidad adecuada para capturar dinámicas influenciadas por factores macroeconómicos como la inflación esperada. En fondos con estructura más flexible o de origen Flex, LSTM muestra rentabilidades algo más moderadas, en torno a 0.28–0.31, lo que indica un desempeño aceptable pero menos sobresaliente en escenarios con mayor heterogeneidad.

En general, el modelo LSTM demuestra ser particularmente útil en fondos de duración media y larga con comportamiento más estable, donde su arquitectura secuencial puede modelar dependencias de largo plazo y capturar señales sutiles en los datos históricos. Sin embargo, presenta limitaciones importantes en categorías de muy corto plazo y alta volatilidad, donde el ruido estructural domina y reduce su capacidad de generar predicciones precisas.

Tabla 10.

Resultados de LSTM de cada tipo de Rentabilidad sobre “%Aporte/Rescate”

	Diaria	Nom7d	Real7d	Nom30d	Real30d	Nom3m	Real3m	Nom12m	Real12m	Avg
Fondos De Deuda < 365 Días Nacional En Pesos	0,42	0,40	0,44	0,42	0,42	0,42	0,46	0,42	0,44	0,43
Fondos De Deuda > 365 Días Nacional, Inversión Uf > 3 Años Y =<5	0,25	0,25	0,26	0,24	0,25	0,25	0,25	0,27	0,26	0,25
Fondos De Deuda > 365 Días Nacional, Inversión En Pesos	0,45	0,45	0,45	0,43	0,43	0,43	0,43	0,43	0,43	0,44
Fondos De Deuda < 90 Días Nacional	10,57	10,62	10,57	10,56	10,62	10,61	10,57	10,68	10,66	10,61
Fondos De Deuda > 365 Días Nacional, Inversión En Uf < 3 Años	0,34	0,35	0,33	0,34	0,33	0,33	0,35	0,37	0,35	0,34
Inversionistas Calificados Títulos De Deuda	0,89	0,86	0,87	0,90	0,88	0,88	1,00	0,90	0,87	0,89
Fondos De Deuda > 365 Días Orig. Flex	0,28	0,29	0,30	0,26	0,26	0,31	0,28	0,31	0,30	0,29
Fondos De Deuda < 365 Días Nacional En Uf	0,34	0,35	0,33	0,41	0,33	0,38	0,40	0,36	0,44	0,37
Fondos De Deuda > 365 Días Nacional, Inversión En Uf > 5 Años	0,45	0,43	0,43	0,43	0,43	0,43	0,43	0,44	0,44	0,44

Nota. Fuente: Generación Propia

7.10 Discusión modelo de Machine Learning

El análisis comparativo de los modelos de *machine learning* aplicados a la predicción de flujos de aportes y rescates en fondos mutuos evidencia diferencias claras en rendimiento según la naturaleza del fondo y el horizonte temporal. En términos generales, se observa que ningún modelo es universalmente superior en todas las categorías, sino que la efectividad depende en gran medida de la volatilidad estructural, el horizonte de rentabilidad y la estabilidad de la serie.

En fondos de corto plazo, especialmente aquellos con vencimientos <90 días, los resultados muestran consistentemente mayores dificultades para todos los modelos. GRU y LSTM, pese a su capacidad para modelar secuencias largas y no linealidades, presentan errores promedio elevados en este segmento (con RMSE cercanos a 10.65 para GRU y valores promedio superiores a 10.6 para LSTM), reflejando su limitada capacidad para anticipar movimientos en los fondos. Mientras que modelos basados en árboles de decisión (Decision Tree, Random Forest y XGBoost) muestran mejor control de la variabilidad y mayor robustez, destacándose en su capacidad para reducir la dispersión en los resultados. En particular, XGBoost y Random Forest logran mantener predicciones más estables incluso en condiciones de ruido elevado, demostrando cierta resiliencia frente a la imprevisibilidad característica de los plazos ultracortos.

Para los fondos de duración intermedia y larga (>365 días), los modelos neuronales como GRU y LSTM revelan un rendimiento notablemente mejor. La capacidad de capturar patrones temporales persistentes y dependencias de largo plazo los vuelve especialmente adecuados para series más estables, con RMSE promedio cercanos a 0.44 en fondos de más de 365 días. En el caso de LSTM, el modelo muestra resultados consistentes en categorías más estables y de duración media o larga, con rentabilidades promedio entre 0.25 y 0.45 para fondos de más de 365 días en UF o en pesos, reflejando su capacidad para aprovechar la información secuencial y las señales contenidas en las rentabilidades pasadas.

Los modelos basados en árboles, por su parte, como Decision Tree y Random Forest, se destacan por su versatilidad. Muestran un rendimiento equilibrado tanto en fondos de corto como de largo plazo, adaptándose bien a escenarios con estacionalidad clara y variabilidad controlada.

En conjunto, los modelos neuronales como GRU y LSTM resultan especialmente valiosos para fondos de duración larga y series con estructuras temporales bien definidas. En cambio, para segmentos de alta volatilidad o con patrones menos regulares, los métodos basados en árboles (Random Forest y XGBoost) destacan por su capacidad de adaptación flexible, manejo del ruido y regularización efectiva. SVM, aunque más limitado en su capacidad de capturar interacciones complejas, muestra resultados sólidos en segmentos de menor volatilidad y plazos intermedios.

8. Conclusión

El presente análisis permitió evaluar de manera integral la capacidad predictiva de distintos modelos sobre los flujos de aportes y rescates en fondos mutuos, considerando tanto su comportamiento histórico como la eficacia de técnicas estadísticas y de *machine learning*. Los resultados obtenidos con modelos ARIMA muestran que, en general, estos tienden a proyectar la media reciente de las series, sin anticipar grandes cambios estructurales. En fondos de corto plazo (<365 días en pesos y UF, y especialmente <90 días nacionales), se observa alta volatilidad histórica, generando predicciones con bandas de confianza muy amplias y mayor incertidumbre. En contraste, los fondos de mayor duración (>365 días, en UF o en pesos) muestran menor dispersión histórica, lo que se traduce en proyecciones más estables y bandas de confianza más contenidas. Este comportamiento evidencia que el modelo ARIMA captura bien la inercia estadística de los datos, pero es limitado para anticipar cambios más complejos o explicados por factores externos.

Por su parte, los modelos SARIMAX lograron superar consistentemente a ARIMA en la mayoría de las categorías, gracias a la inclusión de variables exógenas que permiten capturar mejor la dinámica de los flujos, en especial en fondos de mayor duración y denominados en UF. Se destacó su capacidad de reducir significativamente el error de predicción (RMSE), así como de entregar proyecciones más suaves y creíbles, incluso en series con comportamiento cíclico o tendencias de mediano plazo.

Complementariamente, la aplicación de modelos de *machine learning* reveló que XGBoost es la alternativa más robusta para la predicción multihorizonte de aportes y rescates en fondos mutuos, logrando los menores errores en la mayoría de las categorías. Su rendimiento es particularmente sólido en fondos de mediano y largo plazo, donde las rentabilidades pasadas y otras variables externas influyen más marcadamente en el comportamiento futuro. Modelos como Decision Tree y Random Forest también mostraron muy buen desempeño, especialmente en fondos con estructura más estable y menor volatilidad, mientras que redes GRU y LSTM se destacaron en categorías con secuencias más largas y menos ruido extremo, aunque con resultados más variables en series altamente volátiles.

En conjunto, el análisis confirma que la elección del modelo debe ser segmentada y sensible al perfil del fondo: mientras ARIMA puede ser útil como línea base para capturar la inercia histórica, la inclusión de variables exógenas (SARIMAX) mejora sustancialmente la capacidad predictiva en la mayoría de los casos. Para optimizar la predicción operacional y la toma de decisiones, se recomienda utilizar modelos de *machine learning* como XGBoost, que demostraron mayor adaptabilidad y precisión frente a diferentes estructuras de fondo.

Esta clasificación de herramientas ofrece una guía concreta para seleccionar el enfoque más adecuado según el horizonte de inversión, el riesgo histórico y la disponibilidad de variables explicativas, apoyando así una gestión más informada y eficiente de los flujos en fondos mutuos.

Dado esto la hipótesis planteada se cumple satisfactoriamente en aquellos fondos donde el RMSE fue inferior a 0.4, ya que en dichos casos los modelos predijeron los flujos con un error promedio bajo en puntos porcentuales, validando la capacidad predictiva a partir de rentabilidades pasadas. Sin embargo, en fondos donde el RMSE superó ese umbral —particularmente en fondos de corto plazo o de alta volatilidad—, la hipótesis no se verifica.

Esto puede atribuirse a factores como: alta exposición a shocks exógenos los cuales no fueron evaluados en este informe, ruido residual elevado y menor persistencia de las señales en las rentabilidades, lo que dificulta la predicción incluso para modelos avanzados. Estos hallazgos refuerzan la necesidad de seleccionar modelos en función de las características específicas de cada fondo y no aplicar una solución única a todos los segmentos.

Finalmente, para fortalecer y profundizar este trabajo en el futuro, se sugiere avanzar en varias direcciones: incorporar variables macroeconómicas y de mercado (como tasas swap, expectativas de inflación o indicadores de liquidez), probar enfoques híbridos que integren la capacidad explicativa de SARIMAX con la flexibilidad no lineal de modelos como XGBoost, y diseñar herramientas prácticas como *dashboards* interactivos para analistas y *portfolio managers*.

También sería posible incorporar una variable ponderadora de rentabilidades, ya que en este documento no se evaluó la correlación entre las distintas rentabilidades y su impacto en la variable %aportes/rescates. Por lo tanto, resulta plausible considerar la inclusión de un ponderador que integre dicha relación en futuros análisis.

Además, será clave validar los modelos con datos más recientes, incluyendo escenarios de stress y distintos ciclos económicos, para asegurar su aplicabilidad y robustez en un mercado dinámico y sensible a factores externos.

9. Referencias Bibliográficas

Banco Central de Chile. (2018). *Minutas citadas IEF segundo semestre 2018* [PDF]. Banco Central de Chile. Recuperado de

Asociación de Administradoras de Fondos Mutuos de Chile (AAFM). (2011). *Circular N° 7: Clasificación de fondos mutuos según estrategia de inversión*. Recuperado de

Compendio de Normas Contables para Bancos. Comisión para el Mercado Financiero.

Banco Central de Chile. (2024). *Estadísticas del Mercado de Valores de Renta Fija e Intermediación Financiera a abril de 2024*.

Anderson, R. G. (2010). *Interest Rates and Bond Prices*. Federal Reserve Bank of St. Louis.
Bilyk, O., Ho, A. T. Y., Khan, M., & Vallée, G. (2020). *Household indebtedness risks in the wake of COVID-19* (Staff Analytical Note 2020-8). Bank of Canada.

Wei, W. W. S. (2006). *Time Series Analysis: Univariate and Multivariate Methods* (2ª ed.). Pearson/Addison Wesley

Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: Principles and practice* (2nd ed.).

Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2008). *Time series analysis: Forecasting and control* (4th ed.). Wiley.

Chu, N., Dao, B., Pham, N., Nguyen, H., & Tran, H. (2022). *Predicting mutual funds' performance using deep learning and ensemble techniques*.

Pastor, L., & Veronesi, P. (2012). *Uncertainty about government policy and stock prices*. *Journal of Finance*, 67(4), 1219–1264.

Sirignano, A. J., & Cont, R. (2019). Universal features of price formation in financial markets: perspectives from deep learning. *Quantitative Finance*, 19(9), 1449–1459.

Fischer, T., & Krauss, C. (2018). Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, 270(2), 654–669.

Baker, M., & Wurgler, J. (2007). *Investor sentiment in the stock market*. *Journal of Economic Perspectives*, 21(2), 129–151.

Campbell, J. Y., Shiller, R. J., & Viceira, L. M. (2011). *Inflation-indexed bond markets*. In B. M. Friedman & M. Woodford (Eds.), *Handbook of Monetary Economics* (Vol. 3, pp. 995–1053). Elsevier.

Gu, S., Kelly, B., & Xiu, D. (2020). Empirical Asset Pricing via *Machine Learning*. *The Review of Financial Studies*, 33(5), 2223–2273.

Bank of England. (2019). *Open-ended funds and the stress episode of 2019*. Financial Stability Report – July 2019.

Chandrapala, P. & Sharma, P. (2012). *Forecasting the performance of mutual funds using time series models*. *International Journal of Economics and Finance*, 4(10), 67–74.

Madeira, C. (2022). *The double impact of deep social unrest and a pandemic: Evidence from Chile* (Documento de trabajo N.º 952). Banco Central de Chile.

Comisión para el Mercado Financiero (CMF). (s.f.). *Fondos Mutuos*. Recuperado el 25 de mayo de 2025,

Gorton, G. (2008). The Subprime Panic. *Financial Markets Conference*. Federal Reserve Bank of Atlanta.

Lütkepohl, H. (2005). *New Introduction to Multiple Time Series Analysis* (1ª ed.). Springer.

Banco de Inglaterra. (2017). *Simulating stress across the financial system: Resilience of corporate bond markets and the role of investment funds* (Financial Stability Paper No. 41). Bank of England.

Ley Orgánica Constitucional, Banco Central de Chile.

Ley 18.010 sobre operaciones de crédito y otras obligaciones de dinero que indica. Vínculo:

Bilyk, O., Ho, A. T. Y., Khan, M., & Vallée, G. (2020). *Household indebtedness risks in the wake of COVID-19* (Nota Analítica del Personal N.º 2020-8). Banco de Canadá.

Banco Central de Chile. (s.f.). Unidad de Fomento. Recuperado de

Manual Metodológico del Índice de Precios al Consumidor (IPC) base anual 2018 Vínculo:

Gorton G. (2009), “Slapped in the Face by the Invisible Hand: Banking and the Panic of 2007” paper prepared for the Federal Reserve Bank of Atlanta’s 2009 Financial

De Gregorio, J. (2007). *Macroeconomía: Teoría y políticas*. Pearson Educación.

Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780.

Cao, J., Li, Z., & Li, J. (2019). Financial time series forecasting model based on CEEMDAN and GRU. *Physica A: Statistical Mechanics and its Applications*, 519, 127–139.

10. Anexos

Estadística Descriptiva


Tabla 2.

Resumen Estadísticos Rentabilidades de cada Categoría FM


Plazo Rentabilidad	Mean/Std	Fondos De Deuda < 365 Dias Nacional En Pesos	Fondos De Deuda < 365 Dias Nacional En Uf	Fondos De Deuda < 90 Dias Nacional	Fondos De Deuda > 365 Dias Nacional, Inversion En Uf > 5 Años	Fondos De Deuda > 365 Dias Nacional, Inversion Uf > 3 Años Y =<5	Fondos De Deuda > 365 Dias Nacional, Inversión En Pesos	Fondos De Deuda > 365 Dias Nacional, Inversión En Uf < 3 Años	Fondos De Deuda > 365 Dias Orig. Flex	Inversionistas Calificados Títulos De Deuda	Promedio
Diaria	Mean	4,24	4,53	3,87	-386,30	4,17	4,01	5,81	6,01	7,54	-38,46
	Std	7,56	14,05	2,67	659,01	36,13	20,88	24,53	29,84	116,73	101,27
Nom7d	Mean	4,07	4,56	3,88	-52,30	5,87	3,74	5,26	5,70	5,86	-1,48
	Std	3,84	6,24	2,63	97,96	16,00	9,12	11,41	13,31	40,34	22,32
Real_7d	Mean	0,24	0,76	-0,24	-55,59	2,17	0,25	1,61	1,99	1,95	-5,21
	Std	5,37	7,08	4,52	97,42	16,32	9,90	11,91	13,79	40,43	22,97
Nom_30d	Mean	4,02	4,48	3,91	-9,37	5,84	3,81	5,06	5,59	5,08	3,16
	Std	2,97	4,31	2,68	26,86	10,13	5,94	7,26	8,23	20,09	9,83
Real_30d	Mean	0,18	0,67	-0,18	-12,64	2,13	0,42	1,39	1,88	1,20	-0,55
	Std	4,47	5,08	4,11	26,40	10,45	6,80	7,78	8,83	20,12	10,45
Nom_3m	Mean	4,06	4,50	3,90	-0,24	5,67	4,05	4,99	5,50	4,82	4,14
	Std	2,61	3,31	2,65	12,42	6,20	4,00	4,70	5,03	10,61	5,72
Real_3m	Mean	0,18	0,67	-0,21	-3,55	1,87	0,61	1,23	1,73	0,91	0,38
	Std	3,43	3,35	3,35	11,73	6,11	4,46	4,71	5,13	10,44	5,86
Nom_12m	Mean	3,79	4,07	3,67	3,04	5,10	3,85	4,51	4,83	4,69	4,17
	Std	2,06	2,40	2,51	4,21	2,96	2,14	2,80	2,44	4,57	2,90
Real_12m	Mean	0,15	0,58	-0,17	-0,17	1,36	0,55	0,85	1,33	1,17	0,63
	Std	2,42	1,89	2,68	3,82	2,89	2,67	2,65	2,59	4,70	2,93
Promedio	Mean	2,33	2,76	2,05	-57,46	3,80	2,36	3,41	3,84	3,69	
	Std	3,86	5,30	3,09	104,43	11,91	7,32	8,64	9,91	29,78	

Gráficos Boxplot


Boxplots para la categoría: Fondos De Deuda < 365 Dias Nacional En Pesos




Boxplots para la categoría: Fondos De Deuda < 365 Dias Nacional En Uf




Boxplots para la categoría: Fondos De Deuda < 90 Dias Nacional




Boxplots para la categoría: Fondos De Deuda > 365 Dias Nacional, Inversion En Uf > 5 Años




Boxplots para la categoría: Fondos De Deuda > 365 Dias Nacional, Inversion Uf > 3 Años Y =<5



Boxplots para la categoría: Fondos De Deuda > 365 Dias Nacional, Inversión En Pesos





Boxplots para la categoría: Fondos De Deuda > 365 Días Orig. Flex

