



MEMORIA
PARA OPTAR AL TÍTULO DE MAGISTER EN ANALÍTICA DE NEGOCIOS

TÍTULO:
**Determinantes sociales del empleo forestal en Chile: Un enfoque de machine learning
aplicado a datos CASEN 2022**

ALUMNO:
NICOLÁS ANDRÉS ASTUDILLO MOLINA

PROFESOR GUÍA:
DAVID DIAZ SOLIS

2026

Contenido

Resumen ejecutivo.....	4
Capítulo 1: Introducción.....	6
Capítulo 2: Definición y justificación del problema.....	10
2.1 Contextualización.....	10
2.2 Planteamiento y justificación del problema.....	12
2.3 Pregunta de investigación.....	14
2.4 Viabilidad del proyecto.....	14
2.5 Objetivos de la investigación.....	15
2.6 Hipótesis de investigación.....	15
Capítulo 3: Metodología propuesta.....	17
3.1 Definición del alcance.....	17
3.2 Recolección de datos.....	18
3.3 Metodología propuesta para abordar la solución.....	19
Consideraciones éticas.....	22
Capítulo 4: Marco teórico.....	23
4.1 Determinantes sociales de salud y empleo.....	23
4.2 Marco ESG: dimensión social en contexto corporativo y financiero.....	24
4.3 Industria forestal chilena: contexto histórico y estructura contemporánea.....	25
4.4 Machine learning: teoría, algoritmos e interpretabilidad.....	26
4.5 Comparación de enfoques econométricos versus machine learning para análisis socioeconómico.....	27
4.6 Aplicaciones de machine learning en contextos socioeconómicos y sostenibilidad.....	28
Capítulo 5: Descripción del enfoque de solución.....	30
5.1 Introducción.....	30
Justificación y estructura de los dos enfoques de análisis.....	30
5.2 Datos y Metodología.....	31
Fuente de datos.....	31
Definición y construcción de variables.....	32
Consideraciones sobre endogeneidad y multicolinealidad.....	34
Estrategia de entrenamiento y evaluación.....	36
Interpretabilidad: SHAP values.....	37
Selección y justificación de algoritmos.....	38
Capítulo 6: Resultados y discusión.....	42
6.1.1 Enfoque A: validación mediante aprendizaje automático con las 19 variables del conjunto base.....	42
6.1.2 Enfoque B: aprendizaje automático con variables enriquecidas.....	44
6.1.3 Significancia estadística de la mejora.....	46
6.1.4 Importancia relativa de variables.....	47
6.1.5 Análisis SHAP: interpretabilidad a nivel individual.....	49
6.1.6 Interacciones no lineales reveladas por SHAP.....	54

6.2 Discusión.....	55
6.2.1 Complementariedad entre la econometría tradicional y el aprendizaje automático.....	55
6.2.2 Aportes del aprendizaje automático a cada dimensión ESG.....	56
6.2.3 Implicancias para la política pública.....	58
6.2.4 Capacidad predictiva y aplicaciones prácticas.....	59
6.2.5 Limitaciones del análisis de aprendizaje automático.....	59
6.2.6 Líneas futuras de investigación.....	61
Capítulo 7: Conclusiones y limitaciones.....	62
Bibliografía.....	64

Resumen ejecutivo

La industria forestal chilena representa un sector estratégico para la economía nacional, contribuyendo significativamente al empleo rural y a las exportaciones. Sin embargo, los trabajadores forestales enfrentan desafíos importantes relacionados con condiciones laborales, seguridad ocupacional y acceso a beneficios sociales. Este estudio adopta un enfoque innovador al aplicar técnicas de aprendizaje automático (Machine Learning) para identificar y analizar los determinantes sociales que influyen en el empleo del sector forestal, utilizando datos de la Encuesta de Caracterización Socioeconómica Nacional (CASEN) 2022 (CASEN, 2022).

Esta tesis enmarca el análisis de los determinantes del empleo forestal dentro del marco de gobernanza ambiental, social y corporativa (ESG) y propone la aplicación de múltiples algoritmos de aprendizaje automático como alternativa a los enfoques econométricos tradicionales, como el modelo probit. Los algoritmos comparados incluyen regresión logística, bosques aleatorios (Random Forest), potenciación del gradiente (Gradient Boosting), XGBoost, LightGBM, K-Nearest Neighbors (KNN, $k=7$) y redes neuronales multicapa (MLP).

Se espera que los modelos de aprendizaje automático propuestos ofrezcan una capacidad predictiva competitiva y revelen relaciones no lineales más complejas entre las variables independientes y la probabilidad de que un individuo trabaje en el sector forestal. Los determinantes sociales analizados se clasifican en cinco categorías ESG: diversidad (género, edad, nivel educativo, ascendencia indígena), brecha salarial (quintil de ingresos), beneficios laborales (tipo de contrato, incentivos económicos y no económicos), seguridad laboral (tipo de cobertura de salud, problemas de salud, problemas nutricionales) y programas sociales (acceso a internet, acceso a transporte público).

Este trabajo contribuye al cuerpo creciente de investigación que aplica machine learning a problemas de análisis socioeconómico y sustentabilidad en América Latina. Al complementar los enfoques econométricos tradicionales, como el probit, con algoritmos más modernos, se demuestra cómo las técnicas de aprendizaje automático pueden proporcionar insights más profundos sobre relaciones complejas entre variables sociales, económicas y demográficas. Además, se emplean valores SHAP para mejorar la interpretabilidad de los modelos, permitiendo identificar qué características son más importantes en la predicción del empleo forestal.

Los resultados de esta investigación tienen implicaciones importantes para las políticas públicas de desarrollo sostenible, regulación ESG corporativa, y mejora de condiciones laborales en el sector

forestal chileno. La metodología propuesta puede ser adaptada para otros sectores económicos y contribuir a un mejor entendimiento de los determinantes sociales en contextos latinoamericanos. Este estudio busca cerrar la brecha entre la investigación econométrica tradicional y las capacidades analíticas del aprendizaje automático contemporáneo.

Capítulo 1: Introducción

La industria forestal chilena ocupa un lugar privilegiado en la economía nacional como uno de los principales sectores de exportación y de empleo rural del centro y sur del país. Con más de 140 años de historia, ha moldeado el desarrollo territorial de Chile, especialmente en el Biobío, la Araucanía, Los Ríos y Los Lagos. Pese a su peso económico, sus trabajadores enfrentan condiciones complejas: riesgos ocupacionales, variabilidad de ingresos y acceso desigual a la protección laboral (INFOR, 2023).

A nivel global, la industria enfrenta desafíos de sostenibilidad sin precedentes: la deforestación mundial continúa a cerca de 10 millones de hectáreas anuales (FAO, 2022), mientras crece la demanda de productos certificados. En Chile, la superficie plantada pasó de 1,3 millones de hectáreas en 1990 a más de 3 millones en 2023 (INFOR). Martín-Gallego et al. (2024) documentan la dinámica de bosques nativos y plantaciones mediante series temporales de observación terrestre, evidenciando transformaciones que han generado oportunidades económicas, pero también presiones sobre comunidades rurales, ecosistemas y trabajadores.

La industria tiene una marcada vocación exportadora: las exportaciones forestales alcanzaron US\$5.493 millones en 2022, con China como principal destino (más del 35% del valor) y la celulosa como principal producto (cerca del 48%) (INFOR, 2023). Los exportadores enfrentan presión de clientes internacionales -sobre todo europeos con estándares ESG exigentes- para certificar una producción sostenible y socialmente responsable; la certificación FSC exige estándares laborales de asociación, seguridad y salarios justos. Documentar los determinantes del empleo aporta una línea base para monitorear mejoras (CORMA, 2024; INFOR, 2023).

Entre los desafíos sociales destaca la brecha de género. Históricamente calificado como trabajo masculino de "fuerza bruta", persiste esa etiqueta pese a que muchas ocupaciones modernas no exigen fuerza física. Las barreras para las mujeres incluyen una cultura laboral que no acomoda su presencia, falta de infraestructura en operaciones remotas, discriminación, ausencia de referentes e intersección con la ruralidad y la etnia (Grosser Villar y Carrasco Henríquez, 2019; Sjølie et al., 2023). El *machine learning* permite identificar qué barreras pesan más en cada subgrupo.

La dimensión de género exige un análisis interseccional: las mujeres no son un grupo homogéneo, y una mujer mapuche rural difiere de una no indígena urbana. Comparar solo "hombre" y "mujer" sin desagregar por etnia, ubicación o educación omite hallazgos que el *machine learning*, al analizar subgrupos e interacciones, sí puede capturar.

Los derechos laborales de las poblaciones indígenas son especialmente sensibles: La Araucanía concentra cerca del 40% de la población mapuche y buena parte de los trabajadores forestales. Históricamente, la tierra mapuche fue convertida en plantaciones mediante procesos vividos como despojo territorial (Painecura-Medina, 2022; Ehrnström-Fuentes, 2022). Las organizaciones indígenas advierten sobre la destrucción de bosques nativos, el impacto en agua y suelo, la contratación precaria y la insuficiente consulta previa del Convenio 169 de la OIT. Identificar las barreras específicas de estos trabajadores puede orientar políticas de reconciliación y equidad.

El concepto de «justicia ambiental» sostiene que las externalidades ambientales recaen desproporcionadamente sobre los colectivos marginados (Schlosberg, 2007). En Chile, las comunidades mapuches vecinas a las plantaciones, sin vínculos laborales con el sector, sufren degradación del bosque nativo, contaminación hídrica y pérdida de biodiversidad sin percibir beneficios (Ehrnström-Fuentes, 2022; Torres-Salinas et al., 2023); a la vez, parte de la fuerza laboral es mapuche y vive la dualidad entre el empleo y la transformación de sus tierras.

El papel de la sindicalización es complejo: la afiliación forestal cayó desde cerca del 50% en los años ochenta a un 25-30% actual (Morales, 2022) por la precarización, la subcontratación y la debilidad institucional. Paradójicamente, ese debilitamiento aumenta la necesidad de datos que documenten los problemas laborales, pues sin negociación colectiva los trabajadores requieren información independiente. Además, el reclutamiento de mano de obra forestal es un desafío mundial (Mijoč et al., 2023). El *machine learning* puede aportar ese análisis independiente.

Estos desafíos ocurren dentro de un marco regulatorio en evolución. Las exigencias de gobernanza ambiental, social y corporativa (ESG) han transformado la evaluación de las empresas, ya no solo por su desempeño financiero. La CMF (2021) implementó la NCG 461, que obliga a divulgar información no financiera sobre diversidad, brechas salariales, beneficios, seguridad ocupacional y programas sociales. Los trabajadores forestales, mayoritariamente hombres rurales o indígenas, son un segmento clave para analizar los determinantes de un empleo sostenible.

Surge entonces una pregunta metodológica central: ¿cómo analizar con rigor estos determinantes? Históricamente se ha recurrido a modelos econométricos como la regresión probit que, aunque sólidos, asumen relaciones funcionales específicas, capturan vínculos lineales o paramétricos y pueden no detectar interacciones ni patrones no lineales. Con la creciente potencia computacional y los algoritmos de aprendizaje automático, es posible explorar relaciones más complejas sin imponer estructuras funcionales restrictivas (Wooldridge, 2010).

En la última década, el *machine learning* ha transformado las ciencias sociales, pasando de herramienta auxiliar a enfoque central para datos de alta dimensionalidad, relaciones no lineales y predicción robusta. Mullainathan y Spiess (2017) han precisado cuándo supera a la econometría y cuándo la complementa. En la investigación laboral, estas técnicas manejan mejor las variables categóricas con múltiples niveles, detectan interacciones automáticamente y prescinden de una forma funcional predefinida.

Sus ventajas incluyen capturar relaciones no lineales, interacciones de múltiples órdenes y patrones que los modelos tradicionales omiten. Métodos como Random Forests, Gradient Boosting y redes neuronales tienen alta capacidad predictiva, y técnicas de interpretabilidad como los valores SHAP (*SHapley Additive exPlanations*) permiten discernir la incidencia de cada variable, aportando hallazgos cuantitativos y cualitativos (Mullainathan y Spiess, 2017; Hastie et al., 2009).

La encuesta CASEN, administrada cada dos años por el Ministerio de Desarrollo Social, tiene reconocimiento internacional, muestreo estratificado multietápico y tasas de respuesta superiores al 80%. Aporta variables socioeconómicas y de ocupación detalladas que permiten identificar a los trabajadores forestales. La base 2022 abarca cerca de 200.000 hogares, lo que la vuelve una fuente validada para el estudio cuantitativo de los determinantes laborales.

La aplicación de estas herramientas conlleva consideraciones éticas. El empleo informal suele subestimarse en las estadísticas oficiales: la CASEN reporta la ocupación por autorreporte, de modo que un trabajador que troza madera sin contrato podría declararse en agricultura o desempleo. Si el empleo informal es sustancial, el análisis identificaría solo a los trabajadores formales y sesgaría las conclusiones, pues ambos grupos difieren. Una exploración cualitativa complementaria ayudaría a capturar este fenómeno.

Se utiliza la base CASEN 2022, con información socioeconómica detallada -género, edad, educación, ingresos, tipo de contrato, cobertura de salud y acceso a servicios-, que permite validar tanto la capacidad predictiva de los modelos como la robustez de los determinantes.

La contribución es metodológica y original, en la intersección de las ciencias de la computación, la política social y la sustentabilidad corporativa. Al demostrar que el aprendizaje automático puede mejorar la precisión y ofrecer interpretabilidad profunda -vía SHAP- de los determinantes del empleo forestal, se establece un modelo replicable para otros sectores latinoamericanos y se fortalece la evidencia disponible para los tomadores de decisiones.

Finalmente, la contribución más relevante es epistemológica: el *machine learning* no sustituye la teoría económica, sociológica o política, sino que la complementa cuando se aplica con rigor. Resulta valioso para generar hipótesis y explorar datos antes de cualquier afirmación causal, mientras que los valores SHAP vuelven translúcidos los modelos de "caja negra". El objetivo central es demostrar este enfoque integral y formular recomendaciones de política basadas en evidencia.

Capítulo 2: Definición y justificación del problema

2.1 Contextualización

El sector forestal es uno de los pilares de la economía nacional por su aporte al empleo rural, las exportaciones y el desarrollo territorial. Su estructura de mercado es concentrada: pocas grandes empresas (Arauco y CMPC) dominan la pulpa y el papel, junto a firmas medianas y pequeñas de explotación y servicios. La zona centro-sur, del Biobío a Los Lagos, es la más relevante por su clima, tierra disponible y cercanía a puertos (CORMA, 2024; INFOR, 2023).

El sector y sus actividades asociadas generan unos 102.000 empleos directos y 153.000 indirectos, con impacto sobre cerca de un millón de personas (CORMA, 2025). Son empleos ocupados sobre todo por hombres (más del 95%) (Sjølief et al., 2023), con niveles educativos variables, una proporción relevante de comunidades indígenas -especialmente en La Araucanía- y riesgos ocupacionales elevados. La Organización Internacional del Trabajo (ILO, 2024) ha enfatizado que los déficits de justicia social exigen esfuerzos colectivos para implementar la Agenda 2030 y el Trabajo Decente.

La adopción de estándares ESG en Chile es impulsada por la CMF, que con la NCG 461 de 2021 estableció requisitos de divulgación no financiera en ocho dimensiones, entre ellas diversidad, brecha salarial, seguridad laboral y responsabilidad social (CMF, 2021). En paralelo, iniciativas globales como la *Sustainable Stock Exchange* (SSE) y el *International Sustainability Standards Board* (ISSB) promueven la transparencia; la SSE exige reconfigurar estrategias para mejorar el impacto social (SSE, 2015). Así, las forestales que cotizan en bolsa enfrentan presión para reportar de forma consistente y verificable.

El empleo forestal es cerca del 1,2% del empleo nacional, pero mucho mayor a escala regional: en el Biobío supera el 8% y en algunos municipios rurales el 15%. Existen unos 170.000 trabajadores directos, con un multiplicador indirecto de 2,5 a 3,0 (INE, 2024). La distribución se concentra en Biobío (28%), Araucanía (22%), Los Ríos (19%) y Los Lagos (18%), y las regiones norte y metropolitana suman menos del 5%. Esta concentración crea una dependencia regional que amplifica la importancia de la estabilidad laboral.

El sector reúne subsectores con perfiles laborales distintos. La silvicultura genera empleo estacional (preparación, plantación y poda); la explotación forestal (cosecha, trozado y transporte) se concentra en la cosecha, con personal permanente para equipos y accesos; y la manufactura

(aserraderos y plantas de celulosa) ofrece el empleo más estable, aunque exige mayores destrezas. Según CORMA (2024), el 60% del empleo se genera en explotación y transporte, el 25% en silvicultura y el 15% en manufactura, con perfiles educativos, sindicalización y riesgos diferenciados.

La composición demográfica refleja segregación ocupacional histórica: cerca del 94% son hombres, por la demanda de fuerza física y las barreras culturales para las mujeres. Su edad promedio es 43 años, sobre el promedio nacional de 39, lo que sugiere dificultades de acceso o abandono temprano de los jóvenes. El 18% se identifica como indígena (frente al 12% nacional) y el nivel educativo promedio es de 10,2 años, inferior al 11,5 nacional. Estos patrones son clave para interpretar los determinantes, pues los efectos pueden reflejar tanto productividad real como discriminación estructural (INE, 2024; CASEN, 2022).

La clasificación de ocupaciones forestales requiere precisión. El INE distingue silvicultura, explotación y manufactura (INE, 2024). Aunque el presente análisis las agrupa como "forestal", existe heterogeneidad: la silvicultura es más estacional, la explotación conlleva mayor riesgo de accidentes y la manufactura ofrece más estabilidad con salarios relativamente menores. Desagregar por ocupación mejoraría el análisis, aunque el tamaño muestral de la CASEN lo dificulta.

Los determinantes agregados del empleo regional han sido documentados por CORMA e INFOR: la actividad de cosecha, la regulación ambiental, las organizaciones sindicales y la disponibilidad de mano de obra. Sin embargo, escasean los estudios sobre los determinantes a nivel individual, es decir, sobre qué características -educación, edad, género, ruralidad y vulnerabilidad social- predicen la inserción de una persona en el sector. Cubrir ese vacío con aprendizaje automático es una motivación central de esta investigación.

La relevancia trasciende lo académico y alcanza la política pública. Si el *machine learning* muestra que la formación técnica incide menos de lo previsto, la capacitación por sí sola sería insuficiente para elevar la empleabilidad; si evidencia mayor peso de la ubicación y las redes sociales, convendría fortalecer los mercados laborales locales y la vinculación con las oportunidades. Un estudio riguroso de estos factores ofrece base empírica para políticas racionales y una gestión forestal de largo plazo (Labarre et al., 2025).

Pese a los avances en transparencia, persiste una brecha entre los datos que divulgan las empresas y los análisis independientes de las condiciones reales. Los informes corporativos suelen presentar métricas agregadas con sesgos que ocultan la variabilidad entre grupos. La asimetría informacional es crítica en sectores con fuerza laboral vulnerable, donde el menor poder de negociación y de denuncia favorece la subnotificación (Alsayegh et al., 2020; Arvidsson y Dumay, 2022).

2.2 Planteamiento y justificación del problema

El problema central es que el análisis de los determinantes del empleo forestal ha descansado en modelos econométricos como el probit. Aunque ofrecen coeficientes interpretables y sólido respaldo teórico, imponen supuestos restrictivos sobre la forma funcional: el probit asume que la relación entre las variables y la probabilidad sigue una distribución normal estandarizada, con una estructura aditiva y lineal en sus parámetros.

En contextos reales, con mercados segmentados y estructuras heterogéneas, abundan las relaciones no lineales e interacciones múltiples. El efecto de la edad sobre la inserción podría describir una U invertida, con máximo en los rangos intermedios; y la combinación de baja educación y ruralidad podría generar un efecto sinérgico que excede la aditividad, algo que el probit no captura con precisión. El aprendizaje automático identifica estas complejidades sin especificar la forma funcional.

La interpretabilidad tampoco es unidireccional. El probit ofrece coeficientes directos, pero limitados a efectos marginales promedio cuyo reporte exhaustivo es infrecuente. Las técnicas modernas de *machine learning*, como los valores SHAP y la importancia por permutación, brindan interpretabilidad local (por individuo) y global (agregada), facilitando la comprensión tanto del efecto promedio como de la heterogeneidad de los impactos.

Los modelos probit, pese a su solidez teórica, presentan limitaciones significativas para capturar la no linealidad. Su especificación funcional asume que la variable latente subyacente sigue una distribución normal:

$$Y^* = \beta_0 + \beta_1 X_1 + \dots + \beta_n X_n + \varepsilon, \text{ donde}$$

$$P(Y = 1) = \Phi(\beta_0 + \beta_1 X_1 + \dots + \beta_n X_n)$$

Esta estructura hace que el efecto marginal de cada variable disminuya simétricamente a medida que la probabilidad se acerca a 0 o 1. Sin embargo, muchas relaciones socioeconómicas son asimétricas: la escolaridad puede influir hasta completar la media (12 años) y volverse marginal después, cuando los más calificados migran a otros sectores. El supuesto de aditividad, además, reduce el efecto conjunto de ser mujer y rural a la suma de ambos, cuando la interseccionalidad genera barreras multiplicativas (Wooldridge, 2010; Hosmer y Lemeshow, 2000).

La flexibilidad del *machine learning* permite capturar no linealidades e interacciones. Los árboles de decisión particionan el espacio de características: por ejemplo, una regla puede combinar escolaridad menor a 12 años y ubicación rural para elevar la probabilidad de empleo forestal. El Random Forest integra múltiples árboles con distintas interacciones, XGBoost los construye secuencialmente sobre los errores residuales, y las redes neuronales multicapa aproximan casi cualquier función continua mediante capas no lineales (Breiman, 2001; Hastie et al., 2009).

El aprendizaje automático también gestiona mejor las variables categóricas de alta dimensionalidad. Mientras los enfoques econométricos exigen convertirlas en binarias (codificación *dummy*), eligiendo una referencia y definiendo *a priori* las interacciones, los árboles las procesan directamente. Ante una variable como «ocupación anterior» con 50 categorías, un probit requeriría 49 binarias y sus interacciones manuales, mientras que el *machine learning* evalúa de forma autónoma cada nivel y detecta interacciones emergentes, algo especialmente útil para la CASEN.

Esto es aún más relevante con variables de alta cardinalidad. La «rama económica» de la CASEN tiene cerca de cien categorías: un probit requeriría 99 binarias (*dummy variables*), con riesgo de multicolinealidad, mientras que Random Forest o XGBoost la procesan directamente mediante codificación ordinal o tratamiento nativo, identificando las categorías más predictivas y reduciendo el sesgo de especificación y la ingeniería de características (*feature engineering*).

Es probable que los efectos no lineales predominen en la CASEN. La edad podría describir una U invertida: mínima antes de los 18, creciente hasta los 40-50 y luego decreciente; y la educación, un efecto de umbral que cae abruptamente al completar la media, por la apertura de alternativas laborales. Estos patrones, difíciles para los modelos lineales, son intrínsecos a los árboles, por lo que su validación empírica es un objetivo del análisis.

La investigación tiene además justificación metodológica. El estudio de las problemáticas laborales y los criterios ESG (*Environmental, Social, and Governance*) transita hacia métodos avanzados, proceso más lento en América Latina y en el contexto chileno. Al mostrar que el aprendizaje automático puede superar a los modelos tradicionales en predicción con interpretabilidad equiparable, este trabajo contribuye al progreso metodológico regional.

2.3 Pregunta de investigación

La interrogante central es: ¿en qué medida el *machine learning* optimiza la identificación y la capacidad predictiva de los determinantes sociales del empleo forestal chileno?

Las hipótesis sobre interacciones exigen precisión conceptual. La «interseccionalidad» describe cómo diversas dimensiones identitarias (género, etnia, clase) convergen en formas de discriminación no reducibles a la suma de sus partes. Una mujer mapuche rural podría enfrentar barreras combinadas -baja representación de su género, discriminación étnica y oferta laboral restringida- cuyo efecto neto no es aditivo. El *machine learning* detecta estos patrones de forma automatizada, sin exigir especificar *a priori* las interacciones (Grosser Villar y Carrasco Henríquez, 2019).

2.4 Viabilidad del proyecto

La viabilidad se sustenta en cuatro ejes. Primero, los datos: la CASEN 2022 (CASEN, 2022), de acceso público, tiene cobertura nacional superior a 200.000 hogares y variables socioeconómicas detalladas. Para el análisis del Capítulo 5 se usan los 73.676 registros de individuos ocupados (sin ponderación), identificando el empleo sectorial con la variable *ramal*, volumen suficiente para entrenar y validar diversos algoritmos.

Segundo, las herramientas: Python y bibliotecas como scikit-learn (Pedregosa et al., 2011), XGBoost, TensorFlow/Keras y SHAP proveen el ecosistema necesario. Al ser de código abierto y validadas académicamente, evitan software comercial como STATA o SAS, reduciendo barreras y favoreciendo la replicabilidad.

Tercero, los requerimientos computacionales son moderados: un hardware estándar procesa redes neuronales de complejidad media y ejecuta análisis SHAP en tiempos eficientes.

Cuarto, la literatura reciente aporta marcos consolidados: Bashir et al. (2020) sobre predicción socioeconómica y Molnar (2020) sobre interpretabilidad establecen estándares de rigor y replicabilidad. La convergencia de estos factores ratifica la viabilidad del proyecto en datos, tecnología y metodología.

2.5 Objetivos de la investigación

2.5.1 Objetivo general

Implementar técnicas avanzadas de *machine learning* para identificar, caracterizar y contrastar los determinantes sociales del empleo forestal chileno.

2.5.2 Objetivos específicos

1. Evaluar la capacidad predictiva de siete algoritmos de *machine learning* (regresión logística, bosques aleatorios, XGBoost, Gradient Boosting, LightGBM, KNN y redes neuronales) mediante exactitud, precisión, exhaustividad, F1-score y AUC-ROC.
2. Determinar los determinantes de mayor relevancia mediante el análisis de valores SHAP, utilizando la mediana del valor absoluto de las contribuciones individuales como medida de importancia.
3. Analizar la heterogeneidad de los efectos con gráficos de dependencia SHAP (*SHapley Additive exPlanations*), identificando cómo varía el impacto de cada variable según otros predictores, con énfasis en mujeres, comunidades indígenas y distintos rangos etarios.
4. Verificar la robustez de los hallazgos mediante validación cruzada estratificada, pruebas de estabilidad de los coeficientes y análisis de sensibilidad al preprocesamiento.

2.6 Hipótesis de investigación

Se formula la siguiente hipótesis de investigación, que orienta el análisis empírico:

- Hipótesis de investigación: Los algoritmos de aprendizaje automático supervisado, entrenados sobre los determinantes sociales del empleo forestal, alcanzan una capacidad predictiva superior a la de un modelo lineal de referencia y, mediante los valores SHAP, permiten identificar y jerarquizar dichos determinantes, revelando efectos no lineales y heterogéneos entre grupos demográficos —género, ascendencia indígena y tramos etarios— que un enfoque tradicional no captura.

Cabe advertir los riesgos de sesgo y equidad (*fairness*) del aprendizaje automático: un modelo así no debería usarse en decisiones de selección sin validar antes que no discrimine a grupos protegidos como mujeres o comunidades indígenas; su evaluación formal se plantea como línea futura.

Capítulo 3: Metodología propuesta

3.1 Definición del alcance

La investigación es cuantitativa, de alcance predictivo-comparativo y diseño transversal. Es cuantitativa por usar datos numéricos y análisis estadístico-computacional; predictiva porque estima la probabilidad de inserción laboral forestal a partir de atributos individuales; comparativa al contrastar diversos algoritmos de *machine learning* con la metodología econométrica tradicional (regresión logística); y transversal, pues usa un solo periodo (CASEN 2022) sin seguimiento longitudinal.

El diseño se enmarca en el análisis confirmatorio (*Confirmatory Data Analysis*, CDA), frente al exploratorio (*Exploratory Data Analysis*, EDA). Mientras el exploratorio descubre patrones para generar hipótesis *post-hoc*, el confirmatorio parte de hipótesis predefinidas para contrastarlas. No obstante, se integran elementos exploratorios al examinar la relevancia de las variables y su variación entre subgrupos, combinación considerada robusta.

La validación se estructura en niveles. El primero es una validación cruzada (*k-fold cross-validation*) sobre el entrenamiento, para garantizar la generalización. El segundo contempla idealmente un conjunto de prueba (*holdout*) independiente. Cuando el número de trabajadores forestales es reducido, reservar una fracción amplia comprometería el aprendizaje; en tales casos se privilegia una validación cruzada exhaustiva, reportando la estabilidad en distintos subconjuntos (Hastie et al., 2009; James et al., 2013).

El alcance geográfico es nacional: aunque la industria se concentra en la zona centro-sur, la CASEN 2022 permite analizar factores territoriales en todo el país. El poblacional comprende a personas de 18 años o más clasificadas por su ocupación principal. El temático se restringe a cinco dimensiones ESG -diversidad, compensación, beneficios, seguridad laboral y protección social-, excluyendo los pilares ambiental y de gobernanza pese a su interconexión (CASEN, 2022).

Finalmente, se reconocen las limitaciones inherentes al alcance:

- Sesgo de muestreo: posible subrepresentación de individuos con ocupaciones informales o ingresos no declarados en la encuesta CASEN.

- Tamaño muestral: el número de observaciones reales de trabajadores forestales limita el poder estadístico para el análisis de subgrupos muy específicos.
- Naturaleza de los datos: al ser datos transversales, el estudio identifica asociaciones predictivas, pero no permite realizar inferencias causales directas.
- Variables omitidas: la ausencia de datos desagregados por empresa sobre brechas salariales, tasas de sindicalización o siniestralidad laboral específica restringe la profundidad del análisis ESG (CASEN, 2022).

3.2 Recolección de datos

3.2.1 Fuentes primarias

La fuente primaria es la CASEN 2022, en su levantamiento estándar de octubre-noviembre, de acceso público a través del Ministerio de Desarrollo Social y Familia. La recolección se hizo mediante entrevistas domiciliarias presenciales. La calidad de la CASEN es reconocida en la región por sus protocolos de validación en terreno, el entrenamiento de encuestadores y la verificación de consistencia (CASEN, 2022).

3.2.2 Fuentes secundarias y consideraciones metodológicas

Debe considerarse la heterogeneidad en la calidad de respuesta. Las variables de ingresos presentan más omisiones por su carácter sensible; las de ocupación tienen respuesta casi universal, pero con errores de clasificación, pues la pluriactividad puede omitir el empleo forestal si no es la fuente principal. Esto desafía al *machine learning*, ya que puede provocar un etiquetado incorrecto (*mislabeling*) de la variable dependiente (CASEN, 2022).

La validez de las inferencias exige cautela con datos observacionales. Si el modelo señala la «edad superior a 40 años» como predictor, no implica causalidad: la edad opera como *proxy* de factores no observados, como la experiencia o las redes de contacto. Los algoritmos identifican correlaciones predictivas, no mecanismos causales, por lo que estos determinantes deben leerse como factores de riesgo o protección, no como causas.

Los datos de la CASEN se complementan con fuentes secundarias: el INFOR aporta estadísticas de empleo y producción; el INE, series de actividad y clasificaciones ocupacionales (CIUO); y CORMA, reportes de sostenibilidad como referente del mercado laboral (INFOR, 2023; INE,

2024). Esta base se enriquece con literatura previa -Alvear Vega (2023), Villalobos y Riquelme (2023) y la CMF (2021)-, consolidando el marco metodológico.

3.3 Metodología propuesta para abordar la solución

La metodología se articula en una arquitectura modular de seis etapas, desde el preprocesamiento hasta la interpretación mediante explicabilidad. El diseño permite aislar y evaluar cada componente por separado, facilitando la reproducibilidad y la comparación entre enfoques, y se ejecuta de forma iterativa con retroalimentación entre fases contiguas.

El diseño es cuantitativo, observacional y comparativo. Se emplea la CASEN (2022) como fuente primaria, por ser el instrumento más comprehensivo de medición de pobreza y condiciones de vida en Chile. El razonamiento es deductivo: de marcos teóricos sobre los determinantes sociales del empleo y la vulnerabilidad laboral se derivan hipótesis contrastables. Es un estudio ex-post facto, sin manipulación experimental, que analiza patrones observacionales con aprendizaje automático supervisado (Hosmer y Lemeshow, 2000).

El análisis se estructura en dos perspectivas complementarias. El Enfoque A usa un conjunto base de 19 variables binarias derivadas de la literatura sobre determinantes del empleo forestal, como línea base comparable. El Enfoque B lo amplía con variables enriquecidas -región, variables continuas, tipo de empleo y estacionalidad-. En ambos se valida la representatividad contrastando las distribuciones con el INE (2024) y CORMA (2024).

Etapas 1: Preprocesamiento. Se restringe la muestra a personas de 25 a 65 años con vínculo activo al mercado laboral, descartando estudiantes, rentistas y pensionados, según las definiciones de la OIT. Los valores ausentes (códigos -88 y -99) se imputan por mediana; cuando la proporción de faltantes es alta -como en el ingreso-, se añade además una variable indicadora de “faltante”. Las variables categóricas se codifican según los requerimientos de cada modelo: tratamiento categórico nativo u ordinal en los modelos de árboles, y one-hot encoding con estandarización en los modelos sensibles a la escala. Ante el desbalance entre trabajadores forestales y no forestales, se aplica submuestreo aleatorio de la clase mayoritaria hasta lograr una distribución 50/50, preservando

datos reales sin generación sintética y evitando el sobreajuste del sobremuestreo (Hastie et al., 2009).

Etapas 2: Ingeniería de características. Se construyen variables que capturan los determinantes sociales del empleo forestal, organizadas en las cinco dimensiones ESG del estudio: diversidad (género, tramos etarios, educación y ascendencia indígena), brecha salarial (quintiles de ingreso autónomo), beneficios laborales (tipo de contrato e incentivos económicos, de alimentación y de vivienda), seguridad laboral (cobertura de salud, problemas de salud y nutricionales) y programas sociales (acceso a internet y a transporte público). En el enfoque enriquecido se incorporan además variables territoriales (región y ruralidad), continuas (edad, escolaridad, logaritmo del ingreso y horas trabajadas) y de inserción laboral (tipo de empleo y estacionalidad).

Etapas 3: Entrenamiento de múltiples algoritmos. Se entrenan siete algoritmos de clasificación supervisada, elegidos por su diversidad y eficacia en datos tabulares de alta dimensionalidad. La regresión logística es el modelo de referencia paramétrico, con coeficientes interpretables (Hosmer y Lemeshow, 2000). El random forest es un ensamble de árboles sobre submuestras aleatorias, robusto al sobreajuste y capaz de estimar la importancia de variables (Hastie et al., 2009). El gradient boosting construye árboles secuenciales que corrigen los errores residuales previos (Hastie et al., 2009). XGBoost lo optimiza con regularización L1 y L2, poda por ganancia y procesamiento paralelo (Chen y Guestrin, 2016); LightGBM usa histogramas, eficiente en alta dimensionalidad (Ke et al., 2017). El KNN ($k=7$) clasifica por mayoría entre vecinos próximos, de forma no paramétrica. Las redes neuronales multicapa (MLP) capturan interacciones de orden superior mediante capas sucesivas (Goodfellow et al., 2016; Hornik et al., 1989).

Detalles de implementación por algoritmo

Detalles por algoritmo. La regresión logística usa regularización L2 (Ridge) con un máximo de 1.000 iteraciones. El random forest emplea 300 árboles, profundidad máxima de 10 y un mínimo de cinco observaciones por hoja. El gradient boosting -en su implementación basada en histogramas-, XGBoost y LightGBM usan 300 iteraciones, profundidad máxima de 6 y tasa de aprendizaje de 0,1; XGBoost añade regularización L1 y L2 (Chen y Guestrin, 2016) y LightGBM su algoritmo de

histogramas, eficiente en alta dimensionalidad (Ke et al., 2017). El KNN ($k=7$) usa distancia euclidiana y voto mayoritario. La MLP tiene dos capas ocultas de 64 y 32 neuronas, activación ReLU y sigmoide de salida, optimizador Adam y detención temprana (early stopping) cuando el error de validación deja de mejorar (Goodfellow et al., 2016; Hornik et al., 1989). Los hiperparámetros se fijan en valores estándar de la literatura, sin búsqueda sistemática; su optimización se plantea como línea futura (sección 6.2).

Etapas 4: Validación cruzada estratificada. Se usa validación cruzada estratificada con $k=5$ pliegues para estimar el desempeño esperado en datos no vistos y la estabilidad de los modelos. La estratificación mantiene la proporción de clases en cada pliegue, crítico ante el desbalance. En cada iteración, cuatro pliegues entrenan el modelo y el restante valida; las métricas se promedian para reducir la varianza de la partición (Hastie et al., 2009).

Etapas 5: Evaluación comparativa. Se evalúa el desempeño de los siete modelos sobre un conjunto de prueba reservado (30%, $\text{test_size}=0,3$), separado por partición holdout estratificada antes de cualquier transformación. Las métricas incluyen exactitud, precisión, sensibilidad (recall), especificidad, F1 y AUC-ROC, complementadas con intervalos de confianza bootstrap, relevantes ante el desbalance. La comparación se hace entre algoritmos y entre enfoques, cuantificando el aporte de las variables enriquecidas del Enfoque B (Hastie et al., 2009).

Etapas 6: Interpretabilidad mediante SHAP. Se aplican los valores SHAP (*SHapley Additive exPlanations*) para explicaciones locales y globales. Derivados de la teoría de juegos cooperativos, descomponen aditivamente la contribución de cada característica, con propiedades de eficiencia, simetría y linealidad. A nivel global, los valores absolutos medianos producen un ranking de importancia; a nivel local, los gráficos de enjambre (*beeswarm*) muestran cómo cada variable desplaza la predicción. Esta etapa garantiza transparencia y auditabilidad, indispensables en política pública.

Consideraciones éticas

El uso de aprendizaje automático en políticas sociales conlleva responsabilidades éticas que exceden la optimización de métricas. Todos los datos provienen de una fuente oficial pública (CASEN, 2022), sin identificación personal directa, tratados conforme a la normativa chilena. Los modelos no se diseñan para decisiones individuales sobre trabajadores específicos, sino para el análisis agregado de patrones poblacionales que orienten políticas laborales y de sostenibilidad (ESG) en el sector forestal.

Capítulo 4: Marco teórico

4.1 Determinantes sociales de salud y empleo

El concepto de determinantes sociales nace en la epidemiología y la salud pública y se expande a la economía laboral y las ciencias sociales. La OMS los define como las circunstancias en que las personas nacen, crecen, viven, trabajan y envejecen. Revelan que las disparidades no son biológicas, sino estructurales, ligadas a la distribución del poder y los recursos. Aplicado al empleo, la calidad del trabajo depende de estructuras socioeconómicas, del capital humano y social y de la gobernanza.

El modelo de Dahlgren y Whitehead (1991 y 2021) organiza los factores en capas concéntricas: individuales no modificables (edad, sexo, genética); comportamientos y estilos de vida (educación, ocupación); redes sociales y comunitarias; factores socioeconómicos y estructurales (ingresos); y el macroambiente (economía política y cultura). Un análisis completo consideraría todas, aunque la CASEN capta principalmente de la primera a la cuarta, con limitaciones para la quinta, referida a macro-determinantes como las políticas forestales.

La teoría del capital social (Bourdieu, 1986; Coleman, 1990; Putnam, 2000) subraya el papel de las redes sociales para acceder a recursos y oportunidades. En el empleo, son las redes de contacto que facilitan información y recomendaciones. En el sector forestal esto es clave, pues muchos empleos se obtienen por conexiones familiares o de colegas. Aunque la CASEN no mide el capital social directamente, la ubicación rural o una historia familiar forestal pueden operar como *proxies*.

Al aplicar el modelo al empleo forestal, los factores individuales interactúan con los contextuales y estructurales. El marco de justicia social advierte que la equidad no es dar a todos un acceso idéntico: quienes enfrentan barreras históricas -mujeres, indígenas o trabajadores rurales de baja educación- pueden requerir apoyo adicional. La igualdad trata a todos igual; la equidad da a cada cual lo necesario para resultados justos, como programas para mujeres o alianzas con comunidades mapuche.

La teoría del capital humano (Becker, 1964) sostiene que la inversión en educación y entrenamiento eleva la productividad y, con ella, los salarios y la empleabilidad; en el empleo forestal, la educación y la experiencia serían determinantes positivos. Sin embargo, se le critica no

reconocer factores no meritocráticos -discriminación de género, racismo institucional y acceso educativo desigual por clase- que separan el talento del empleo pese al capital humano.

4.2 Marco ESG: dimensión social en contexto corporativo y financiero

El acrónimo ESG (*environmental, social, and governance*) designa los tres pilares para evaluar el desempeño corporativo más allá de lo financiero. Emergió en la década de 2000 como respuesta de inversionistas, reguladores y sociedad civil ante el reconocimiento de que las externalidades negativas, la falta de protección laboral o la gobernanza opaca son riesgos de largo plazo. Su adopción se impulsó con los Objetivos de Desarrollo Sostenible de la ONU (2015), los principios para la inversión responsable y una regulación creciente.

En la práctica global, los estándares ESG son integrales para las operaciones e inversiones. El riesgo ESG ya no es solo responsabilidad social, sino riesgo financiero real, pues las malas prácticas derivan en huelgas, litigios, rotación y pérdida de reputación. Esto impulsa la analítica de datos y el *machine learning* para documentar progresos y evitar el mayor costo de capital o la exclusión de índices responsables.

En América Latina, la evolución la han guiado la Bolsa de Valores de Santiago (BVS) y la CMF. En 2021, la BVS lanzó el Índice de Sostenibilidad Integral (ISI) y la CMF, con la NCG 461, fijó requisitos obligatorios de reportería, ubicando la trayectoria chilena entre las más avanzadas de la región, aunque aún rezagada frente a los mercados más desarrollados (CMF, 2021).

Un aspecto crítico del marco ESG en el sector es el equilibrio entre biodiversidad y producción. La "conservación inteligente" busca balancear la producción maderera con la protección de bosques nativos, lo que exige datos sobre la viabilidad de las alternativas. Si el aprendizaje automático revela barreras desproporcionadas para mujeres, jóvenes o indígenas, la inclusión laboral podría volverse una estrategia complementaria a la conservación, creando empleos de menor impacto ecológico.

En Chile, la regulación se formalizó con la NCG 461 de la CMF, de 2021 (CMF, 2021). Exige divulgar información no financiera en ocho dimensiones: diversidad de género directiva, brecha salarial, conciliación trabajo-familia, seguridad laboral, capacitación, bienestar, responsabilidad social y cumplimiento normativo. Las primeras son cuantificables con datos de nómina; otras, como el bienestar o los programas sociales, son más cualitativas.

Para esta tesis, las ocho dimensiones de la NCG 461 se adaptan en cinco categorías coherentes con la CASEN: diversidad, brecha salarial, beneficios, seguridad laboral y programas sociales. Esta consolidación permite un análisis riguroso sin perder representatividad. La hipótesis subyacente es que los trabajadores forestales presentan heterogeneidad en estas dimensiones y que su variación predice la probabilidad de empleo en el sector.

4.3 Industria forestal chilena: contexto histórico y estructura contemporánea

La industria forestal chilena tiene más de 140 años de industrialización, con explotación maderera desde el periodo colonial. La forestación moderna nace en el siglo XIX con empresarios, sobre todo de origen alemán, que plantan eucalipto y pino. Entre 1900 y 1970 la expansión es lenta y doméstica. El cambio ocurre tras 1973, cuando la dictadura promueve la forestación con el Decreto Ley 701 (1974) y sus subsidios tributarios; eliminado en 2012, dejó extensas plantaciones de monocultivo que transformaron el sur, sobre todo La Araucanía (Ehrnström-Fuentes, 2022; Kröger, 2020).

Hoy la industria está muy concentrada: Arauco y CMPC controlan cerca del 60% de las plantaciones, el procesamiento y la exportación. Operan negocios integrados, de la silvicultura al procesamiento en aserraderos y a la manufactura de pulpa, papel y cartón. El subsector exportador es clave -cerca del 10% de las exportaciones de mercancías-, con China, Japón, Europa y América Latina como mercados principales (CORMA, 2024; INFOR, 2023).

La regulación ambiental refleja una presión creciente por la sustentabilidad, desde la Ley de Bases del Medio Ambiente (1994) hasta la Ley de Cambio Climático de 2021, que compromete la carbono neutralidad en 2050. Así, la sustentabilidad es una obligación legal que exige mejores prácticas laborales. Aun así, el impacto de las plantaciones en el agua es controvertido en La Araucanía: estudios de ECOCENAR (Universidad de Chile) muestran que consumen mucha más agua que los bosques nativos, en conflicto con las comunidades mapuche.

Los ciclos económicos afectan el empleo de forma procíclica según la demanda global de celulosa y papel: la crisis de 2008-2009 causó fuertes contracciones y la pandemia de COVID-19 elevó la demanda de embalajes, protegiendo parcialmente el empleo. La cadena de suministro es asimétrica y permite a las grandes empresas dictar condiciones. Un análisis que ignore estas dinámicas o el

carácter transversal de la CASEN 2022 podría omitir transiciones ocupacionales y realidades de coerción laboral.

El empleo forestal se reparte en silvicultura, procesamiento y servicios, con la silvicultura predominantemente masculina y concentrada en Biobío y La Araucanía. Aunque los salarios superan la media agrícola no especializada, el sector enfrenta desafíos críticos reportados por la OIT (ILO, 2024): accidentabilidad sobre el promedio nacional y conflictos territoriales persistentes. Investigar estos determinantes provee una línea base para evaluar políticas que equilibren sostenibilidad y equidad.

4.4 Machine learning: teoría, algoritmos e interpretabilidad

El aprendizaje automático o *machine learning* comprende los métodos que permiten a los sistemas aprender patrones sin reglas fijas. Aquí se centra en el aprendizaje supervisado, en particular la clasificación binaria: predecir la categoría de una observación -trabajador forestal frente a otros- a partir de características observadas. La teoría del aprendizaje estadístico (Vapnik, 1995; Hastie et al., 2009) da el marco riguroso para entender cómo generalizan hacia datos nuevos.

Los algoritmos empleados representan enfoques distintos. La regresión logística modela la probabilidad de la clase positiva con una función logística de las características; es similar al probit, pero con distribución logística. Los bosques aleatorios o *random forests* (Breiman, 2001) promedian múltiples árboles para reducir la varianza. El *gradient boosting*, como XGBoost (Chen y Guestrin, 2016), construye árboles secuenciales que corrigen errores previos. El KNN (k=7) (Cover y Hart, 1967) clasifica por vecinos cercanos, y las redes neuronales (Goodfellow et al., 2016) transforman la información de forma no lineal mediante capas interconectadas.

Un desafío histórico ha sido la interpretabilidad: mientras el probit da coeficientes legibles, los modelos complejos operan como cajas negras. Por eso el *interpretable machine learning* (Molnar, 2020) desarrolla técnicas *post-hoc* que explican tras el entrenamiento. Los valores SHAP (*SHapley additive explanations*), de Lundberg y Lee (2017), aplican la teoría de juegos cooperativos (Shapley, 1953) para atribuir la contribución exacta de cada característica, con base matemática sólida.

Los valores SHAP resultan idóneos porque satisfacen tres propiedades. La consistencia asegura que, si un modelo depende más de una característica, su valor SHAP es mayor. La localidad hace

que los valores de una observación sumen la diferencia entre su predicción y el valor base. La simetría garantiza valores idénticos para características intercambiables. Así, un modelo complejo se vuelve transparente y explica los determinantes con claridad comparable a la de los modelos tradicionales.

4.5 Comparación de enfoques econométricos versus machine learning para análisis socioeconómico

La econometría tradicional, en especial modelos binarios como el probit y el logit, ha sido el estándar en investigación socioeconómica. Sus ventajas son la solidez teórica de supuestos explícitos y una interpretabilidad clara, con coeficientes de significado económico directo; la inferencia por pruebas de hipótesis, intervalos y valores p cuantifica la incertidumbre, y su parsimonia favorece la reproducibilidad. En el ámbito forestal chileno, esta tradición se refleja en Alvear y Astudillo (2025), publicado en *Forest Policy and Economics*, que aplicó un modelo probit sobre datos de la CASEN para identificar los determinantes sociales del empleo forestal y constituye el antecedente econométrico directo de este trabajo.

Sin embargo, estos modelos tienen limitaciones. La especificación funcional puede ser incorrecta: el supuesto de distribución normal o logística es una simplificación que no siempre se ajusta, y en datos multidimensionales las relaciones suelen ser más complejas. La linealidad en los parámetros es restrictiva: interacciones o términos cuadráticos no declarados sesgan los estimadores. Además, la inferencia es muy sensible a la especificación y a supuestos sobre los errores que a menudo se violan.

Una comparación ayuda a decidir cuándo usar cada método. La econometría es útil para estimar un parámetro causal específico -como el retorno de la educación- o con muestras pequeñas respecto al número de variables, pues sus supuestos reducen la varianza a costa de algo de sesgo. El *machine learning* destaca cuando la predicción es el objetivo, hay gran volumen de datos y coexisten múltiples tipos de variables.

El propósito guía la elección metodológica en tres niveles: metodológico, mostrar que el aprendizaje automático se aplica con rigor a problemáticas latinoamericanas; empírico, identificar los determinantes del empleo forestal para informar políticas; y práctico, demostrar que las empresas pueden verificar de forma independiente sus progresos en ESG (*environmental, social,*

and governance) mediante analítica avanzada. Ello justifica un enfoque híbrido que una rigor computacional y reflexión teórica.

El *machine learning* ofrece fortalezas complementarias: descubre patrones sin especificación previa y capta interacciones automáticamente; los árboles, por ejemplo, crean divisiones que equivalen a interacciones, con desempeño superior y robustez ante atípicos. Sus debilidades son la menor interpretabilidad, el riesgo de sobreajuste (*overfitting*) y la falta de inferencia formal. La estrategia más sólida es maximizar la predicción y complementarla con interpretabilidad *post-hoc*.

Esta tesis adopta esa estrategia híbrida: se emplean modelos de aprendizaje automático para descubrir patrones y valores SHAP para restaurar la transparencia. Calculados sobre un modelo ya entrenado, revelan la importancia relativa de las variables y los efectos marginales heterogéneos. El enfoque permite trabajar con menos restricciones que un probit tradicional, conservando una interpretación cercana a la de los métodos clásicos y logrando lo mejor de ambos.

4.6 Aplicaciones de machine learning en contextos socioeconómicos y sostenibilidad

La aplicación del aprendizaje automático a problemas socioeconómicos ha crecido con rapidez. En países desarrollados, el Banco Mundial, organismos de estadística y ministerios del trabajo lo usan para predecir la pobreza, analizar el mercado laboral y evaluar programas, con casos como la pobreza multidimensional en Asia del Sur o el acceso financiero en África.

Las aplicaciones forestales y ambientales van de la detección de cambios en la cobertura del suelo con imágenes satelitales a la predicción de incendios y rendimientos. En Chile han apoyado la verificación independiente de reportes mediante el monitoreo de la deforestación. En economía laboral predicen el desempleo de larga duración e identifican transiciones ocupacionales. Es relevante la literatura de aprendizaje automático para política social (Athey y Wager, 2019; Chernozhukov et al., 2018), que evalúa efectos de tratamiento heterogéneos; y el *ESG tech*, que monitorea cadenas de suministro y riesgos reputacionales.

Estos marcos vinculan los determinantes sociales con los resultados laborales. La teoría de los determinantes sociales de la salud, del trabajo de Michael Marmot en los años ochenta y noventa, reconoce que factores no médicos -educación, ingresos, ocupación y estructuras sociales- influyen tanto como el acceso a la salud. El marco de Marmot (1998, 2004) plantea que el estatus

socioeconómico opera vía estrés y exposición a riesgos. Aplicado al empleo, el acceso al trabajo forestal estable depende del género, la ubicación o la pertenencia indígena.

La OMS (2007) subraya que una ocupación segura y decente depende de la educación vocacional, las políticas activas de empleo y la protección social. En paralelo, los estándares ESG pasaron de la retórica a normas reportables: la Global Reporting Initiative (1997) fue pionera; el Sustainability Accounting Standards Board (2011) se enfocó en temas materiales, identificando para el sector la gestión de tierras y las relaciones comunitarias; y el ISSB (2023) propone marcos convergentes. En Chile, la CMF adoptó estas orientaciones con la NCG 461 (2023).

Los fundamentos del aprendizaje automático, de la teoría del aprendizaje estadístico de Vapnik (1995), abordan el compromiso entre sesgo y varianza: el sesgo surge de un modelo demasiado simple y la varianza de una sensibilidad excesiva al ruido. Mullainathan y Spiess (2017) señalan que la econometría se optimiza para la inferencia causal y el aprendizaje automático para la predicción, aunque la frontera es difusa; un enfoque híbrido -aprendizaje automático para heterogeneidades y econometría para efectos causales- resulta el más potente.

En síntesis, el aprendizaje automático transforma el abordaje de preguntas complejas en ciencias sociales, pero exige aplicación cuidadosa y reflexión sobre sus sesgos; no resuelve la desigualdad estructural, aunque revela patrones que los métodos tradicionales omiten. En el contexto forestal chileno, se espera que aporte evidencia robusta para políticas de acceso equitativo, dentro de una investigación aplicada responsable, rigurosa, atenta a los sesgos y honesta sobre sus incertidumbres.

Capítulo 5: Descripción del enfoque de solución

5.1 Introducción

Este capítulo desarrolla un análisis de aprendizaje automático o *machine learning* para identificar los determinantes sociales del empleo forestal chileno. El enfoque permite además explorar la

heterogeneidad individual -si el efecto de cada variable es uniforme o varía según el perfil- y ofrece escalabilidad para incorporar variables adicionales. La robustez se fortalece al comprobar si los determinantes se sostienen bajo múltiples algoritmos independientes. Más que invalidar los enfoques econométricos previos, busca extender sus conclusiones y comprender mejor los patrones subyacentes en la CASEN 2022.

El aprendizaje automático en el sector tiene antecedentes consolidados, aunque concentrados en teledetección, inventarios y predicción de incendios (Fassnacht et al., 2016; Biau y Scornet, 2016). Su aplicación sociolaboral es incipiente: estudios recientes usan random forest y gradient boosting para predecir la informalidad en sectores primarios (Suddeepong et al., 2023) y los determinantes del empleo rural (Villalobos y Riquelme, 2023). Este capítulo aporta a esa línea aplicando un marco interpretable, basado en SHAP, al sector forestal chileno.

Justificación y estructura de los dos enfoques de análisis

El análisis de *machine learning* se estructura en dos enfoques complementarios que dialogan con la tradición econométrica del estudio de los determinantes del empleo forestal desde la perspectiva ESG (*environmental, social, and governance*). El primero valida la robustez de un conjunto base de determinantes ya identificados en la literatura; el segundo amplía el análisis con variables enriquecidas de la CASEN 2022, aprovechando la totalidad de sus registros.

El enfoque A valida la robustez de un conjunto base de determinantes. Dado que la tradición econométrica suele estimar efectos marginales sobre conjuntos acotados de variables binarias, cabe preguntar si los 19 determinantes identificados en la literatura sobre el empleo forestal (Capítulo 4) se sostienen bajo metodologías distintas. Este enfoque somete esas 19 variables a siete algoritmos de diversas familias -lineales, de árboles, de distancia y redes neuronales-. Su convergencia reforzaría que los determinantes son robustos e independientes del método. La evaluación es out-of-sample, con validación cruzada de cinco pliegues.

El enfoque B extiende el análisis con variables enriquecidas. Mientras el conjunto base se limita a binarias, propias de la tradición probit, la CASEN 2022 contiene información adicional relevante: la región -con énfasis en Biobío, La Araucanía y Maule-, la distinción urbano-rural y variables continuas como escolaridad, ingreso y horas trabajadas, además del tipo de inserción. El *machine learning* maneja estas 42 variables sobre 73.676 observaciones, sin las restricciones muestrales del

enfoque tradicional, y determina cuánto mejora la caracterización del trabajador y qué variables son más predictivas.

La lógica de ambos enfoques es secuencial y complementaria. El A establece la línea base con las 19 variables bajo evaluación rigurosa; el B mide la ganancia incremental de las variables adicionales. Comparar ambos permite atribuir cualquier mejora a la información de las nuevas variables y no a la complejidad de los algoritmos, ya que se usan los mismos siete modelos, logrando una transición coherente desde la econometría clásica.

5.2 Datos y Metodología

Fuente de datos

Se utiliza la Encuesta de Caracterización Socioeconómica Nacional (CASEN) 2022, del Centro de Encuestas y Estudios Longitudinales del Ministerio de Desarrollo Social y Familia. La muestra comprende 73.676 individuos empleados de 25 a 65 años con actividad económica declarada. De ellos, 14.565 (19,8%) son trabajadores forestales, según la rama de actividad en silvicultura, manufactura de madera o de papel.

Es clave precisar la estrategia muestral: se usan los 73.676 registros completos sin factores de expansión, identificando a los trabajadores forestales por la variable codificada de actividad económica. Esto aprovecha toda la información y evita la duplicación ponderada, pues aunque la expansión es adecuada para la inferencia poblacional, en modelos predictivos podría inflar artificialmente las métricas de ajuste.

Tabla 1
Comparación metodológica entre el enfoque econométrico tradicional (regresión logística) y el presente análisis (ML)

Aspecto	Enfoque econométrico tradicional (probit)	Presente análisis (ML)
---------	---	------------------------

Muestra	Muestras frecuentemente reducidas y balanceadas para la estimación	73.676 individuos (sin expansión)
Balanceo	Balanceo aplicado a la muestra completa	Undersampling 50/50 solo en entrenamiento; conjunto de prueba con distribución natural (19,8% forestales)
VARIABLES INDEPENDIENTES	VARIABLES BINARIAS (DUMMIES) con forma funcional impuesta	Enfoque A: 19 binarias (replicación); Enfoque B: 42 variables (binarias, categóricas y continuas)
Evaluación	In-sample (bondad de ajuste)	Out-of-sample (conjunto de prueba 30%) + validación cruzada estratificada 5-fold
Algoritmos	Modelo único	7 algoritmos de ML con distintos paradigmas de aprendizaje
Interpretabilidad	Efectos marginales promedio (AME)	SHAP values (efecto por individuo y por variable)

Definición y construcción de variables

El enfoque A replica un conjunto base de 19 variables binarias en cinco dimensiones ESG. La diversidad incluye género femenino, ausencia de educación, descendencia indígena y tramos etarios; la brecha salarial, los quintiles de ingreso autónomo; los beneficios, el tipo de contrato e incentivos económicos o de vivienda; y la seguridad y los programas sociales, el acceso a salud pública, los problemas nutricionales, internet y transporte.

El enfoque B enriquece el modelo con 42 características que el análisis exploratorio identifica como relevantes. Incorpora variables geográficas -el sector se concentra en Biobío, La Araucanía y Maule- y la distinción urbano-rural; transita de la binarización a variables numéricas para edad y escolaridad, y usa el logaritmo del ingreso para preservar su variabilidad. Integra además el tipo de

empleo, la estacionalidad y las horas trabajadas, con imputación por mediana y un indicador de ingreso faltante.

Tabla 2

Variables del Enfoque B: descripción y justificación de las 42 variables enriquecidas

Variable	Columna CASEN	Tipo	Justificación
Región (15 dummies)	`región`	Categórica	El sector forestal se concentra geográficamente: Biobio (22,6%), Araucanía (11,7%), Maule (9,6%)
Zona rural	`área`	Binaria	El sector forestal es predominantemente rural
Edad continua	`edad`	Numérica	Captura la relación edad-empleo forestal sin pérdida de información por binarización
Edad al cuadrado	`edad <sup>2</sup> `	Numérica	Captura efectos no lineales de la edad
Escolaridad	`esc`	Numérica (años)	Reemplaza la binaria "sin educación", capturando todo el gradiente educativo
Ingreso (log)	`y1`	Numérica (log-transformada)	Reemplaza quintiles, preservando la variabilidad continua del ingreso

Indicador de ingreso faltante	`y1`	Binaria	Controla el 29% de valores missing en ingreso
Tipo de empleo (7 dummies)	`o15`	Catagórica	Asalariado, cuenta propia, empleador, etc. - altamente discriminante
Estacionalidad	`o12`	Binaria	Distingue empleo permanente de temporal/estacional
Horas trabajadas	`o10`	Numérica	Intensidad laboral semanal
+ 10 variables retenidas del conjunto base	Varias	Binarias	indígena, contrato fijo, incentivos (3), salud pública, problemas de salud (2), internet, transporte

Nota. Elaboración propia a partir de variables de la Encuesta de Caracterización Socioeconómica Nacional CASEN 2022 (Ministerio de Desarrollo Social y Familia, 2022). Las columnas CASEN corresponden a los nombres de variables en la base de datos pública.


Consideraciones sobre endogeneidad y multicolinealidad

Debe advertirse el riesgo de endogeneidad en variables del enfoque B, como el tipo de empleo o las horas, que podrían ser consecuencia de pertenecer al sector más que un determinante previo. Como en un modelo probit, el análisis es asociativo y descriptivo: las variables mejoran la caracterización del trabajador y la focalización de políticas, aunque su interpretación causal exige cautela.

Sobre la multicolinealidad, variables como escolaridad e ingreso presentan correlaciones esperables. Para los árboles, como random forest o xgboost, no es un problema crítico, pues seleccionan la variable más informativa en cada partición. En los valores SHAP puede diluir el impacto de una variable cuando otra correlacionada está presente, efecto mitigado aquí promediando múltiples modelos independientes. La Figura 1 muestra la matriz de correlación de las 42 variables.

Figura 1

Matriz de correlación de las 42 variables del enfoque B



Estrategia de entrenamiento y evaluación

La partición fue única, 70%/30%, estratificada por la variable dependiente y con los mismos índices para ambos enfoques, de modo que cualquier diferencia de rendimiento se atribuya a las variables y no a los datos de evaluación. Ante el desbalance -19,8% de forestales frente a 80,2%, se aplicó un submuestreo aleatorio (*undersampling*) de la clase mayoritaria en el entrenamiento, obteniendo 20.390 observaciones balanceadas al 50%. Se prefirió el submuestreo sobre SMOTE porque el volumen resultante basta para el aprendizaje sin datos sintéticos. El balanceo se aplicó solo al entrenamiento; el conjunto de prueba conservó la distribución natural.

En el procesamiento se usó StandardScaler para media cero y desviación uno en los modelos sensibles a la escala -regresión logística, KNN y redes neuronales-, ajustado solo sobre el entrenamiento para evitar la fuga de información (*data leakage*). Los árboles -random forest, gradient boosting, xgboost y lightgbm- no lo requieren, pues particionan por cortes ordinales. Además, se calculó el AUC por validación cruzada estratificada de cinco pliegues; su cercanía con el AUC de prueba indica una generalización adecuada.

Para evaluar los modelos en esta clasificación binaria desbalanceada se eligió un conjunto de métricas robustas, que miden no solo la exactitud global sino también la capacidad de identificar a los trabajadores forestales sin exceso de falsos positivos. La interpretación de la precisión, el *recall* y el F1 ofrece una visión integral de la utilidad práctica de los determinantes para la política pública y la sostenibilidad corporativa.

Tabla 3

Métricas de evaluación del rendimiento de los modelos de aprendizaje automático

Métrica	Definición	Relevancia
AUC-ROC	Area bajo la curva ROC (Receiver Operating Characteristic). Mide la capacidad del modelo de distinguir entre clases a través de todos los umbrales de clasificación posibles. Rango [0,5 = azar; 1,0 = perfecto].	Métrica principal: es independiente del umbral de clasificación y robusta ante el desbalance de clases, lo que permite una comparación directa del poder discriminativo entre modelos.
Accuracy	Proporción de predicciones correctas sobre el total.	Métrica intuitiva, pero puede ser engañosa con clases desbalanceadas (un modelo que siempre prediga "no forestal" tendría 80,2% de accuracy).
Sensibilidad (Recall)	Proporción de forestales reales correctamente	Critica para política pública: mide cuántos trabajadores

	identificados: $TP / (TP + FN)$.	forestales vulnerables son detectados por el modelo.
Especificidad	Proporción de no forestales correctamente identificados: $TN / (TN + FP)$.	Complemento de la sensibilidad: mide cuántos no forestales son correctamente excluidos.
F1-Score	Media armónica de precisión y sensibilidad: $2 \cdot (Precision \cdot Recall) / (Precision + Recall)$.	Resume el equilibrio entre identificar correctamente a los forestales y no generar falsos positivos.
CV AUC (5-fold)	AUC-ROC promedio en validación cruzada estratificada de 5 folds.	Estima la estabilidad y generalidad del modelo. Su cercanía al AUC del conjunto de prueba indica ausencia de sobreajuste.

Interpretabilidad: SHAP values

Los modelos de aprendizaje automático, sobre todo los de árboles, se critican como "caja negra": predicen con precisión pero no explican por qué. Los valores SHAP (*SHapley additive explanations*) lo resuelven con base matemática. Su fundamento son los valores de Shapley de la teoría de juegos cooperativos (Shapley, 1953): la contribución marginal promedio de un jugador sobre todas las coaliciones. Lundberg y Lee (2017) lo adaptan al aprendizaje automático, donde cada variable es un "jugador" y la predicción, el "juego"; así, el valor SHAP es la contribución marginal promedio de una variable a esa predicción.

Una razón clave es que SHAP es el único método que satisface tres axiomas (Lundberg y Lee, 2017). La eficiencia local: la suma de los valores iguala la diferencia entre la predicción individual y la base. La consistencia: si una variable contribuye más en un modelo, su valor es mayor. Y la simetría: contribuciones idénticas reciben el mismo valor. Estas propiedades le dan una robustez teórica superior a otros métodos de importancia.

Respecto a los efectos marginales promedio (AME) que reportan los modelos econométricos tradicionales, hay una analogía importante. Los AME miden el efecto promedio de cambiar una variable de 0 a 1 sobre la probabilidad, con las demás constantes; el valor SHAP medio cumple una función similar. La diferencia es que los AME asumen un efecto aditivo y uniforme para todos, mientras que SHAP capta efectos heterogéneos e interacciones. Esta analogía conserva una interpretabilidad cercana a la de los métodos clásicos, dentro de un marco no paramétrico.

Para la implementación se usó el módulo TreeExplainer de la librería SHAP, optimizado para árboles. El cálculo se hizo sobre el conjunto de prueba completo, de 22.103 observaciones, con LightGBM (AUC de 0,874), el mejor modelo del enfoque B compatible con TreeExplainer -la variante de gradient boosting basada en histogramas, pese a su AUC levemente superior (0,875), no es soportada por ese módulo-, para analizar la importancia de las características y los efectos marginales en el sector.

Selección y justificación de algoritmos

La selección de los siete algoritmos busca cubrir las principales familias del aprendizaje supervisado en clasificación binaria. El objetivo no es solo la máxima precisión, sino evaluar si los determinantes relevantes son detectables por métodos con supuestos matemáticos muy distintos. Si convergen, se obtiene evidencia robusta de que los patrones pertenecen a la estructura de los datos y no a un algoritmo particular.

Familia 1: modelo lineal generalizado

La primera familia es la regresión logística, contraparte directa del probit. Ambos son modelos lineales generalizados (GLM) para variables binarias y difieren solo en la función de enlace: la logística usa la sigmoide y el probit la normal acumulada (Φ). Como señala Wooldridge (2010), producen resultados casi idénticos salvo en los extremos. Configurada con regularización L2 y 1000 iteraciones, permite una comparación transparente con el enfoque econométrico tradicional, distinguiendo si las diferencias vienen del algoritmo o del tamaño muestral y la validación (Hosmer y Lemeshow, 2000).

Familia 2: ensambles basados en árboles de decisión

La segunda familia son los ensambles de árboles, que particionan el espacio mediante reglas condicionales. Se incluyen cuatro variantes de las dos estrategias de ensamble. El random forest,

basado en bagging, promedia árboles independientes para reducir la varianza sin aumentar el sesgo (Breiman, 2001). El gradient boosting usa aprendizaje aditivo secuencial que corrige errores previos (Friedman, 2001). Sobre esa base, XGBoost añade regularización L1 y L2 contra el sobreajuste (Chen y Guestrin, 2016) y LightGBM crece por hoja y maneja variables categóricas de alta dimensión, como la región o el tipo de empleo (Ke et al., 2017).

Incluir estos cuatro modelos se justifica por sus diferencias de regularización y construcción (paralela o secuencial). Si todos coinciden en el orden de importancia de las variables, se fortalece la validez del ranking. Además, promediar su importancia mitiga la variabilidad de cada técnica, produciendo una jerarquía de determinantes más estable para los datos de la CASEN.

Familia 3: clasificador basado en distancia

La tercera familia es el clasificador de k-vecinos más cercanos (KNN), que asigna la clase mayoritaria de sus siete vecinos más próximos en el espacio euclidiano (Cover y Hart, 1967). Al ser no paramétrico, no asume relación funcional previa y prueba que los patrones existen con independencia de los supuestos del modelo. Aunque sufre la "maldición de la dimensionalidad", su rendimiento entre los enfoques A y B indica si las nuevas variables son geoméricamente discriminantes.

Familia 4: red neuronal artificial

La cuarta familia es una red neuronal artificial de tipo perceptrón multicapa (MLP), aproximador universal que capta interacciones de orden superior con capas ocultas y activaciones no lineales como ReLU (Hornik et al., 1989). La red tiene dos capas ocultas de 64 y 32 neuronas e incorpora early stopping para detener el entrenamiento cuando el error de validación deja de mejorar. Como representante del aprendizaje profundo, ofrece un paradigma distinto al de los árboles o los modelos lineales.

En síntesis, esta diversidad permite una validación por convergencia: usar modelos lineales, ensambles de árboles, clasificadores de distancia y redes neuronales asegura que los hallazgos sobre el empleo forestal no dependan de una arquitectura, sino que reflejen la realidad socioeconómica de los datos.

La Tabla 4 resume la lógica de selección:

Tabla 4

Algoritmos de aprendizaje automático evaluados según familia y paradigma de aprendizaje

Algoritmo	Familia	Paradigma de aprendizaje	¿Captura interacciones?	Rol en el análisis
Logistic Regression	GLM lineal	Maximiza verosimilitud lineal	No (solo efectos aditivos)	Referencia directa al modelo probit
Random Forest	Ensamble (bagging)	Árboles independientes + votación	Si (automático)	Baseline tree-based, robusto
Gradient Boosting	Ensamble (boosting)	Árboles secuenciales correctivos	Si (automatico)	Boosting clásico de referencia
XGBoost	Ensamble (boosting regularizado)	Boosting + regularización L1/L2	Si (automatico)	Estado del arte en ML tabular
LightGBM	Ensamble (boosting eficiente)	Boosting leaf-wise + histogramas	Si (automatico)	Eficiente en datasets grandes
KNN	Basado en distancia	Similitud geométrica entre casos	Si (implícito)	Test no paramétrico sin modelo
Neural Network	Red neuronal	Retro propagación del error	Si (capas ocultas)	Paradigma Deep learning

Si los siete algoritmos, con supuestos tan distintos, convergen en los mismos patrones, estos son propiedades de los datos y no artefactos de un método. Esta es la principal ventaja del enfoque multi-algoritmo frente a un modelo único.

Capítulo 6: Resultados y discusión

6.1.1 Enfoque A: validación mediante aprendizaje automático con las 19 variables del conjunto base

El enfoque A evalúa si los 19 determinantes sociales del conjunto base, identificados en la literatura sobre el empleo forestal (Capítulo 4), son robustos ante distintas metodologías de clasificación. Se someten las 19 variables binarias a los siete algoritmos descritos en la sección metodológica, mediante evaluación out-of-sample con un conjunto de prueba del 30% y validación cruzada de cinco folds. Los resultados se presentan en la Tabla 5.

Tabla 5

Rendimiento de siete algoritmos de aprendizaje automático con las 19 variables binarias del conjunto base, evaluado en la muestra de prueba (30 %)

Modelo	Accuracy	Precisión (forestal)	Recall (forestal)	Precisión (no forestal)	Recall (no forestal)	F1-score	AUC-ROC	CV AUC (5-fold)
Random forest	0,676	0,345	0,708	0,903	0,669	0,464	0,751	0,752
Logistic regression	0,670	0,335	0,683	0,895	0,667	0,450	0,735	0,737
Neural network	0,652	0,331	0,746	0,909	0,629	0,459	0,748	0,748
Gradient boosting	0,673	0,343	0,717	0,905	0,662	0,464	0,750	0,750
XGBoost	0,676	0,343	0,700	0,901	0,670	0,461	0,743	0,742
LightGBM	0,672	0,342	0,715	0,904	0,661	0,463	0,746	0,745
KNN (k = 7)	0,652	0,314	0,645	0,882	0,653	0,423	0,700	0,697


Nota. Métricas calculadas sobre la muestra de prueba (30 %; $n = 22.103$; prevalencia de la clase forestal de 19,8 %). El recall de la clase forestal corresponde a la sensibilidad y el recall de la clase no forestal, a la especificidad; el F1-score se reporta para la clase forestal. La última columna (CV AUC) corresponde a la validación cruzada de cinco folds sobre el conjunto de entrenamiento balanceado.

Los siete algoritmos convergen a un AUC-ROC entre 0,700 y 0,751 (media 0,739). Que algoritmos con supuestos tan distintos -lineales, de árboles, de distancia y redes neuronales- coincidan indica que las 19 variables binarias poseen un poder predictivo real, aunque moderado. La regresión logística (0,735) se aproxima a los modelos más complejos (random forest: 0,751; gradient boosting: 0,750). Dado que la regresión logística y el probit son modelos lineales generalizados que solo difieren en la función de enlace (logit frente a la normal acumulada), la capacidad predictiva generalizable de las 19 variables es de aproximadamente 0,74, con independencia del algoritmo.

La validación cruzada de cinco folds confirma la estabilidad (AUC-ROC de CV entre 0,697 y 0,752). Los F1-scores, en cambio, son bajos (0,42-0,46): con una clase positiva del 19,8% y entrenamiento balanceado 50/50, el modelo sobre-clasifica la clase positiva, elevando el recall de la clase forestal (0,65-0,75) a costa de su precisión (0,31-0,35), mientras la clase no forestal mantiene precisiones altas (0,88-0,91), como muestran las columnas por clase de la Tabla 5. Esto no invalida los modelos, pues el AUC-ROC -que evalúa la discriminación en todos los umbrales- es la métrica más apropiada; el F1 bajo solo implica que, para la detección directa, habría que ajustar el umbral según la prioridad entre sensibilidad y precisión. La Figura 2 presenta las curvas ROC de ambos enfoques.

Figura 2

Curvas ROC comparativas: enfoque A (19 features) frente a enfoque B (42 features).



Un AUC de 0,75 con evaluación out-of-sample rigurosa confirma que los 19 determinantes poseen poder discriminativo real y no trivial (un modelo sin poder predictivo tendría 0,50), y los siete

algoritmos coinciden en ello. Cabe notar que esta cifra no es comparable con las métricas in-sample habituales en los estudios econométricos: la evaluación in-sample -estándar cuando se busca inferir efectos marginales y no predecir datos nuevos- sobreestima el desempeño frente a la out-of-sample, que mide la capacidad de clasificar individuos no observados.

6.1.2 Enfoque B: aprendizaje automático con variables enriquecidas

El enfoque B evalúa cuánto mejora la caracterización del trabajador forestal al incorporar variables adicionales de CASEN 2022 no consideradas en el conjunto base. La motivación es doble. Primero, el conjunto base emplea solo variables binarias, pero la escolaridad (años), el ingreso (pesos) y la edad son continuas y su binarización pierde información. Segundo, la concentración geográfica del sector -el 22,6% del empleo forestal se localiza en el Biobío y el 11,7% en la Araucanía- sugiere que la dimensión territorial es un determinante relevante, difícil de estimar de forma estable en especificaciones econométricas con muestras reducidas.

Al aplicar los mismos siete algoritmos sobre la misma partición train/test, cualquier diferencia de rendimiento entre los enfoques A y B se atribuye exclusivamente a la información de las variables adicionales, no a la complejidad de los modelos. Los resultados se sintetizan en la Tabla 6.

Tabla 6

Rendimiento de siete algoritmos de aprendizaje automático con 42 variables enriquecidas, evaluado en la muestra de prueba (30 %)

Modelo	Accuracy	Precisión (forestal)	Recall (forestal)	Precisión (no forestal)	Recall (no forestal)	F1-score	AUC-ROC	CV AUC (5-fold)
Gradient boosting	0,791	0,483	0,800	0,941	0,789	0,603	0,875	0,871
XGBoost	0,790	0,480	0,793	0,939	0,789	0,598	0,873	0,864
LightGBM	0,789	0,479	0,794	0,939	0,788	0,598	0,874	0,866
Random forest	0,786	0,475	0,790	0,938	0,785	0,593	0,869	0,865

Neural network	0,777	0,463	0,798	0,940	0,771	0,586	0,860	0,853
Logistic regression	0,768	0,450	0,766	0,930	0,769	0,567	0,846	0,842
KNN (k = 7)	0,751	0,426	0,747	0,924	0,752	0,543	0,817	0,809

Nota. Métricas calculadas sobre la muestra de prueba (30 %; $n = 22.103$; prevalencia de la clase forestal de 19,8 %). El recall de la clase forestal corresponde a la sensibilidad y el recall de la clase no forestal, a la especificidad; el F1-score se reporta para la clase forestal. La última columna (CV AUC) corresponde a la validación cruzada de cinco folds sobre el conjunto de entrenamiento balanceado.

La incorporación de variables enriquecidas produce una mejora sustancial: el mejor modelo (gradient boosting) alcanza un AUC-ROC de 0,875, un incremento de +0,124 respecto al mejor del enfoque A (random forest: 0,751). Todos los algoritmos se benefician -incluso la regresión logística asciende de 0,735 a 0,846 (+0,111)-, lo que demuestra que la mejora proviene de la información de las nuevas variables y no de la complejidad algorítmica. La brecha entre modelos lineales (regresión logística: 0,846) y no lineales (gradient boosting: 0,875) es de apenas 0,029, indicando que las interacciones no lineales aportan un beneficio adicional modesto pero relevante.

La validación cruzada confirma la robustez: el AUC-ROC de CV del gradient boosting es 0,871, cercano al 0,875 del conjunto de prueba, lo que indica un sobreajuste mínimo. Los F1-scores mejoran notablemente respecto al enfoque A, de 0,46 a 0,60 en gradient boosting (+30%); aunque aún no son óptimos para la detección directa, revelan predicciones más equilibradas: la precisión de la clase forestal aumenta de 0,31-0,35 a 0,43-0,48 entre enfoques, con un recall que se mantiene alto (0,75-0,80), mientras la clase no forestal alcanza precisiones en torno a 0,92-0,94 (Tabla 6). Con todo, conviene leer parte de esta mejora con cautela: como se discute en la sección 6.2.5, algunas de las variables incorporadas -en particular el tipo de empleo, las horas trabajadas y la estacionalidad- presentan riesgo de endogeneidad, por lo que una fracción del incremento predictivo podría reflejar características estructurales del propio sector más que determinantes previos a la inserción laboral.

6.1.3 Significancia estadística de la mejora

La diferencia de AUC entre el enfoque A (0,751) y el B (0,875) es de +0,124. Para evaluar su significancia estadística se calcularon intervalos de confianza bootstrap al 95% mediante 1.000 repeticiones con remuestreo del conjunto de prueba (Figura 3 y Tabla 7).




Figura 3

Comparación de AUC-ROC de todos los modelos en ambos enfoques.

Tabla 7

Intervalos de confianza bootstrap (95%) para AUC-ROC

Modelo	AUC enfoque A	IC 95% A	AUC enfoque B	IC 95% B
Gradient boosting	0,750	[0,742; 0,758]	0,875	[0,869; 0,880]
XGBoost	0,743	[0,735; 0,751]	0,873	[0,867; 0,878]
LightGBM	0,746	[0,738; 0,754]	0,874	[0,868; 0,879]
Random forest	0,751	[0,743; 0,758]	0,869	[0,863; 0,874]
Neural network	0,748	[0,740; 0,756]	0,860	[0,855; 0,866]
Logistic regression	0,735	[0,727; 0,743]	0,846	[0,840; 0,852]
KNN (k = 7)	0,700	[0,691; 0,708]	0,817	[0,811; 0,824]

--	--	--	--	--

Los intervalos de confianza del mejor modelo del enfoque A [0,743; 0,758] y del enfoque B [0,869; 0,880] no se solapan, confirmando que la mejora es estadísticamente significativa ($p < 0,05$). La mejora es consistente en los siete algoritmos: el peor modelo del enfoque B (KNN: 0,817) supera al mejor del enfoque A (random forest: 0,751) incluso considerando sus intervalos. La estrechez de los intervalos ($\pm 0,008$ en promedio) indica alta estabilidad.

6.1.4 Importancia relativa de variables

La importancia relativa de las variables se evalúa exclusivamente mediante los valores SHAP, utilizando como estadístico la mediana del valor absoluto de las contribuciones individuales (mediana de $|\text{SHAP}|$) sobre la muestra de prueba. Se prefiere esta métrica por sobre las importancias internas de los modelos de árboles (basadas en la reducción de impureza) porque estas últimas pueden ser inestables entre algoritmos, entregan solo un ordenamiento -sin signo ni escala interpretable- y tienden a sobrestimar variables de alta cardinalidad. Para interpretar la Tabla 8 conviene precisar que las categorías de tipo de empleo (o15 en CASEN 2022) son: 1 = patrón o empleador, 2 = trabajador por cuenta propia, 3 = empleado u obrero del sector privado, 4 = empleado u obrero del sector público, 5 = personal de servicio doméstico, 6 = familiar no remunerado, 7 = Fuerzas Armadas y de Orden, 8 = otro, y 9 = no clasificable.

Tabla 8

Importancia de variables según la mediana del valor absoluto de los valores SHAP (enfoque B, LightGBM, muestra de prueba)

#	Variable	Descripción	Origen	Mediana de $ \text{SHAP} $
1	schooling	Años de escolaridad	Nueva	0,503
2	female	Género femenino	Base	0,455
3	emptytype_cat	Tipo de empleo (categórica)	Nueva	0,332
4	log_income	Ingreso (log)	Nueva	0,248
5	hours_worked	Horas trabajadas/semana	Nueva	0,231

6	region_cat	Región (categórica)	Nueva	0,226
7	incentive_economic	Incentivos económicos	Base	0,108
8	age_continuous	Edad (años)	Nueva	0,106
9	seasonal	Empleo no permanente	Nueva	0,062
10	fixed_contract	Contrato plazo indefinido	Base	0,050

Cuatro de las cinco variables más importantes son nuevas, no incluidas en el conjunto base de 19 variables: la escolaridad continua (mediana de $|\text{SHAP}| = 0,503$), el tipo de empleo (0,332), el ingreso logarítmico (0,248) y las horas trabajadas (0,231). Esto explica la mejora de AUC de 0,75 a 0,87. La variable female (género) es la variable del conjunto base más relevante -segunda posición, mediana de $|\text{SHAP}| = 0,455$ -, lo que confirma la brecha de género como determinante del empleo forestal; también permanecen entre las diez primeras el incentivo económico y el contrato de plazo indefinido.

La escolaridad continua (primera posición) captura mucha más información que la binaria «sin educación»: el gradiente educativo completo -de cero a 25 años de estudio- es un predictor más potente que la simple distinción educación/sin educación. El tipo de empleo (o15), tratado como variable categórica única, ocupa la tercera posición (mediana de $|\text{SHAP}| = 0,332$): los trabajadores forestales se insertan predominantemente como obreros de empresas privadas, consistente con que el 78,4 % de la fuerza laboral forestal es contratada por empresas externas (CORMA, 2024), mientras que categorías como el trabajo por cuenta propia o el empleo público ayudan a distinguir perfiles no forestales. La forma de inserción laboral emerge así como un determinante social clave.

La región, tratada igualmente como variable categórica única, ocupa la sexta posición (mediana de $|\text{SHAP}| = 0,226$), lo que refleja la concentración geográfica del sector y confirma la relevancia de la dimensión territorial incorporada en el enfoque B.

6.1.5 Análisis SHAP: interpretabilidad a nivel individual

Los valores SHAP (SHapley Additive exPlanations) descomponen la predicción de cada individuo en la contribución de cada variable. A diferencia de los efectos marginales promedio (AME) de los modelos econométricos tradicionales, que reportan un efecto medio, el análisis SHAP revela la

heterogeneidad del efecto y las interacciones no lineales. Para evaluar la robustez de los determinantes, la Tabla 9 compara la dirección del efecto SHAP de cada variable del conjunto base en ambos enfoques: con las variables originales (enfoque A) y en presencia de las variables enriquecidas (enfoque B). A lo largo del capítulo se emplean dos estadísticos SHAP complementarios, denominados de manera consistente: el efecto SHAP medio (promedio con signo de los valores SHAP, que informa la dirección del efecto y se reporta en la Tabla 9) y la mediana de |SHAP| (que informa la magnitud o importancia y se reporta en la Tabla 8 y las Figuras 4 a 6).

Tabla 9

Efecto SHAP medio (promedio con signo de los valores SHAP) de las variables del conjunto base: enfoque A (19 variables) frente a enfoque B (42 variables)

Variable	SHAP medio (enfoque A)	SHAP medio (enfoque B)	Mantiene dirección
female	-0,013	-0,079	Sí
indigenous	+0,000	+0,000	Sí
fixed_contract	-0,013	-0,013	Sí
incentive_economic	-0,011	-0,027	Sí
incentive_food	-0,000	-0,003	Sí
incentive_housing	-0,001	-0,005	Sí
public_health	-0,003	-0,004	Sí
health_problems	-0,000	+0,001	No
nutrition_problems	-0,000	-0,001	Sí
has_internet	-0,002	-0,003	Sí
transport_access	-0,000	+0,000	No

Mantienen la dirección del efecto: 9 de 11 variables (82%)




Figura 4

Importancia SHAP de las variables del enfoque B (mediana de $|SHAP|$, LightGBM).

Los gráficos de enjambre (beeswarm) complementan el ranking de importancia con la distribución individual de los valores SHAP: cada punto representa a un individuo del conjunto de prueba, su posición horizontal indica la magnitud y el signo de la contribución de la variable a la predicción de inserción forestal, y el color codifica el valor de la variable. La Figura 5 presenta el enfoque B y la Figura 6, el enfoque A, lo que permite contrastar la dispersión y la dirección de los efectos entre ambas especificaciones.




Figura 5

Gráfico de enjambre (beeswarm) SHAP del enfoque B (42 variables, LightGBM). Cada punto es un individuo del conjunto de prueba.




Figura 6

Gráfico de enjambre (beeswarm) SHAP del enfoque A (19 variables del conjunto base, random forest).

De las 19 variables del conjunto base, solo 11 están presentes directamente en el enfoque B. Las ocho restantes fueron reemplazadas por versiones continuas más informativas: los tres tramos etarios (36-45, 46-55, 56-65) por la edad continua y cuadrática; los cuatro quintiles de ingreso por el ingreso logarítmico; y la binaria «sin educación» por los años de escolaridad. La versión continua captura más información sobre las mismas dimensiones subyacentes -edad, ingreso y educación-. La Figura 4 ilustra la importancia SHAP de las variables del enfoque B.

Los valores SHAP del enfoque A se calcularon con el mejor modelo tree-based de ese enfoque (random forest, AUC = 0,751), que emplea la información de las 19 variables del conjunto base con los tramos etarios y los quintiles de ingreso agrupados en sendas variables categóricas; los del

enfoque B, con LightGBM sobre el mismo conjunto de prueba. Al usar la misma partición y los mismos individuos, las diferencias entre ambas columnas reflejan únicamente el efecto de incorporar las variables enriquecidas.

La comparación de las dos columnas es informativa: 9 de las 11 variables comparables mantienen la dirección de su efecto al pasar del enfoque A al B (82%), y las dos excepciones -health_problems y transport_access- presentan magnitudes prácticamente nulas en ambos enfoques, por lo que su signo no es informativo. Esta estabilidad indica que las direcciones estimadas responden a la estructura de los datos y no a una especificación particular.

Las variables que mantienen dirección y magnitud apreciable en ambos enfoques -female, fixed_contract e incentive_economic- constituyen los hallazgos más robustos y genuinamente asociados al empleo forestal; incentive_food, incentive_housing, public_health y has_internet conservan el signo negativo, aunque con magnitudes menores.

Resulta notable la estabilidad de female: su valor SHAP medio es negativo tanto en el enfoque A ($-0,013$) como en el B ($-0,079$). La brecha de género emerge así como el hallazgo más consistente entre especificaciones. Los valores SHAP del enfoque A son de magnitud pequeña (a lo sumo $\pm 0,013$), lo que refleja que las variables del conjunto base contribuyen individualmente poco a la predicción, algo consistente con el AUC moderado (0,75): poseen poder predictivo colectivo, pero cada una aporta marginalmente. En el enfoque B las magnitudes son mucho mayores (mediana de $|\text{SHAP}|$ de 0,503 para schooling), lo que indica que las variables continuas y el tipo de empleo son individualmente más informativos. El aumento de la magnitud de female entre enfoques (de $-0,013$ a $-0,079$) sugiere además que el efecto de género se manifiesta con más claridad al controlar por el tipo de inserción laboral y el ingreso.

La lectura conjunta de ambos enfoques requiere interpretación cuidadosa. Las variables cuyo efecto es lo bastante fuerte para sobrevivir a la inclusión de las variables enriquecidas -como female ($-0,079$), incentive_economic ($-0,027$) y fixed_contract ($-0,013$)- pueden considerarse determinantes de primer orden. En cambio, las que se atenúan hasta magnitudes casi nulas no necesariamente carecen de relevancia: su información puede estar contenida en las variables nuevas.

Este efecto de mediación es esperable. Por ejemplo, el contrato fijo se diluye al incluir el tipo de empleo (o15), más granular; los problemas de salud tienen un efecto prácticamente nulo en

presencia de las variables de ingreso y empleo, que capturan la misma vulnerabilidad de manera más directa; y la descendencia indígena, con magnitud casi nula, es coherente con un efecto mediado por las variables regionales, pues las comunidades indígenas se concentran en regiones forestales.

6.1.6 Interacciones no lineales reveladas por SHAP

Los gráficos de dependencia SHAP de la Figura 7 revelan relaciones no lineales que los modelos aditivos tradicionales no capturan. En la escolaridad, los individuos con 0 a 8 años presentan valores SHAP positivos (mayor probabilidad forestal), con un efecto que crece a medida que disminuye la escolaridad; entre 8 y 12 años el efecto es cercano a cero; y a partir de 12 años (educación media completa) se vuelve fuertemente negativo, hasta SHAP de $-3,0$ en educación universitaria. Una especificación binarizada de la educación pierde todo este gradiente y solo captura el extremo inferior.

La edad continua muestra un efecto no monótono (Figura 7): entre 25 y 40 años los valores SHAP son ligeramente negativos; entre 40 y 55 se vuelven positivos; y a partir de 55 vuelven a ser negativos. Este patrón en U invertida es consistente con el ciclo de vida laboral del sector y resulta imposible de capturar con tramos etarios binarios. La edad cuadrática (`age_squared`) recoge parcialmente esta no linealidad, que los modelos tree-based modelan con mayor flexibilidad.




Figura 7

Gráficos de dependencia SHAP de la edad y la escolaridad (enfoque B) y matrices de confusión de los mejores modelos de cada enfoque.

6.2 Discusión

6.2.1 Complementariedad entre la econometría tradicional y el aprendizaje automático

Los resultados demuestran que el enfoque de aprendizaje automático no contradice a los enfoques econométricos tradicionales, sino que los complementa en múltiples dimensiones, como sintetiza la Tabla 10.

Tabla 10

Complementariedad entre la econometría tradicional y el aprendizaje automático

Dimensión	Enfoque econométrico tradicional	ML (presente análisis)
Pregunta central	¿Qué factores influyen?	¿Cuánto importa cada uno y cómo interactúan?
Tipo de efecto	AME promedio	Valor SHAP por individuo
Relaciones	Lineales (aditivas)	No lineales (interacciones automáticas)
Variables	Conjuntos acotados de variables binarias	42 mixtas (aprovecha N = 73.676)
Validación	In-sample	Out-of-sample + CV 5-fold
Resultado	Identifica dirección del efecto	Ranquea importancia y revela heterogeneidad

6.2.2 Aportes del aprendizaje automático a cada dimensión ESG

Los determinantes sociales se organizan en cinco dimensiones según la Norma de Carácter General N.º 461 de la CMF (CMF, 2021). El aprendizaje automático permite reevaluar y enriquecer cada una de estas dimensiones, como detalla la Tabla 11.

Tabla 11

Aportes del aprendizaje automático a cada dimensión ESG

Dimensión ESG	Variables del conjunto base	Aporte del ML
Diversidad (género, edad, educación, etnia)	Género, tramos etarios, educación y ascendencia indígena.	El ML confirma el género como predictor clave: segundo por mediana de SHAP en el modelo enriquecido. La escolaridad continua reemplaza la binaria y se revela como el primer predictor por mediana de SHAP : no es solo la ausencia de educación, sino el gradiente educativo completo lo que discrimina. El efecto de la edad es no monótono (U invertida), no capturado por los tramos binarios. El efecto de etnia indígena conserva la dirección positiva, pero con magnitud casi nula: estaría mediado por las variables regionales, sugiriendo que la asociación etnia-forestal opera vía la ubicación geográfica.
Brecha salarial (quintiles de ingreso)	Quintiles de ingreso autónomo.	El ingreso logarítmico continuo (tercer predictor) captura toda la distribución, no solo los escalones de quintiles. Revela una relación gradual ingreso-empleo forestal que los quintiles binarios simplifican excesivamente.
Beneficios laborales (contrato, incentivos)	Tipo de contrato e incentivos económicos, de alimentación y de vivienda.	El ML confirma la dirección de incentivos alimenticios y económicos. Además, identifica el tipo de empleo (nueva variable, no incluida en el conjunto base) como el predictor más

		importante de todo el modelo: los trabajadores forestales se insertan mayoritariamente como asalariados de empresas privadas (CORMA, 2024).
Seguridad laboral (salud)	Cobertura de salud, problemas de salud y nutricionales.	Las tres variables de salud pierden relevancia predictiva en presencia de las 42 variables del enfoque B (SHAP cercano a cero). Esto sugiere que su efecto aparente está confundido con otras variables (ingreso, tipo de empleo) que capturan la misma vulnerabilidad de manera más directa.
Programas sociales (internet, transporte)	Acceso a internet y a transporte público.	El ML confirma internet como predictor (SHAP negativo). Agrega zona rural como variable nueva relevante: la ruralidad del empleo forestal es un determinante territorial que complementa la perspectiva de acceso a servicios.

6.2.3 Implicancias para la política pública

Los hallazgos del aprendizaje automático tienen implicaciones directas para la focalización de políticas. La escolaridad continua es la variable más importante del modelo, lo que indica que no basta con identificar a quienes carecen de educación formal: el gradiente educativo completo muestra que la vulnerabilidad del sector se extiende a todos los niveles por debajo de la educación media. Las políticas ESG deberían, por tanto, priorizar programas de capacitación y formación técnica específicos para el sector.

Las categorías de empleo (o15) resultan altamente discriminantes, evidenciando que la forma de inserción laboral -asalariado privado, cuenta propia, contratista- es un determinante social clave, lo que respalda las observaciones de CORMA (2024) sobre la alta proporción de trabajadores contratados por empresas externas (78,4%). El género femenino disminuye significativamente la

probabilidad de empleo forestal en ambos enfoques; la magnitud de su efecto SHAP -el segundo mayor del modelo enriquecido por mediana de $|\text{SHAP}|$ - valida la urgencia de políticas de inclusión de género.

Las variables regionales, aunque individualmente modestas, confirman colectivamente la concentración geográfica del empleo forestal; un modelo predictivo con $\text{AUC} = 0,875$ podría identificar comunas y territorios donde focalizar programas de mejora de condiciones laborales. Finalmente, los quintiles binarios pierden información valiosa: el ingreso logarítmico, tercera variable más importante, sugiere que la relación ingreso-empleo forestal es gradual y no escalonada.

6.2.4 Capacidad predictiva y aplicaciones prácticas

El modelo gradient boosting del enfoque B, con AUC-ROC de 0,875, posee capacidad predictiva suficiente para aplicaciones prácticas. Primero, su aplicación a futuras encuestas CASEN permitiría rastrear cambios en el perfil del trabajador forestal y evaluar el impacto de las políticas ESG en el tiempo. Segundo, a partir de las variables sociodemográficas de un territorio, el modelo puede estimar la probabilidad de concentración de empleo forestal vulnerable, posibilitando la focalización territorial. Tercero, los valores SHAP individuales permiten identificar qué combinación de determinantes caracteriza a los trabajadores más vulnerables, facilitando la construcción de perfiles de riesgo.

6.2.5 Limitaciones del análisis de aprendizaje automático

El análisis presenta varias limitaciones. En primer lugar, los valores SHAP indican asociación, no causalidad, y se reportan en la escala interna del modelo (log-odds en los modelos de gradient boosting), no directamente en cambios de probabilidad. Cabe precisar que esto último no es una limitación intrínseca de la metodología: los valores SHAP pueden reescalarsse para obtener una interpretación análoga a la de los efectos marginales promedio (average marginal effects, AME) de los modelos econométricos -es decir, cuánto cambia la probabilidad predicha ante un cambio marginal en una variable explicativa, manteniendo las demás constantes-; si bien dicha transformación era posible, no formó parte del alcance de este estudio y se plantea como extensión en la sección 6.2.6. Ambos enfoques se complementan, y resulta fundamental interpretar los resultados de aprendizaje automático como una caracterización predictiva del trabajador forestal, no como la identificación de factores causales.

En segundo lugar, algunas variables del enfoque B presentan riesgo de endogeneidad. Como se advirtió en la sección 5.2, el tipo de empleo (o15) -la variable más importante- podría ser consecuencia del empleo forestal más que un determinante: si la industria opera predominantemente con empleados privados y contratistas, la variable captura una propiedad estructural del sector y no una característica individual que predispone al empleo forestal. El mismo razonamiento aplica parcialmente a las horas trabajadas y la estacionalidad. Esto no invalida el modelo predictivo -para la focalización, la predicción precisa es suficiente-, pero limita su interpretación causal. Las variables del conjunto base (género, educación, etnia, quintil de ingreso) son menos susceptibles a esta crítica, pues describen características sociodemográficas previas a la inserción laboral.

En tercer lugar, el análisis está limitado a las variables disponibles en CASEN 2022. Factores como la proximidad a plantaciones forestales, la tradición familiar en el sector, las redes sociales locales o la disponibilidad de empleo alternativo no están capturados, y probablemente expliquen parte del AUC residual, dado que el modelo alcanza 0,875 y no 1,0.

En cuarto lugar, la clasificación basada en ramal (códigos 2, 16, 17) puede no capturar toda la cadena de valor forestal -por ejemplo, el transporte de madera, la consultoría o la comercialización-; tiende a capturar las actividades primarias y de manufactura, que concentran la mano de obra más vulnerable. En quinto lugar, el análisis es transversal (CASEN 2022); uno longitudinal con múltiples encuestas permitiría evaluar cambios en el tiempo. Finalmente, los resultados de las tablas 5 y 6 dependen de una única partición aleatoria 70/30; esta limitación se mitiga parcialmente mediante la validación cruzada de cinco folds y los intervalos de confianza bootstrap (Tabla 7), que confirman la estabilidad (IC de $\pm 0,008$), aunque repetir el análisis con múltiples semillas aleatorias la fortalecería aún más.

6.2.6 Líneas futuras de investigación

Los resultados abren varias avenidas de investigación. En primer lugar, aplicar el mismo marco de aprendizaje automático a las encuestas CASEN 2017, 2020 y futuras permitiría evaluar la evolución temporal de los determinantes y medir el impacto de las políticas ESG entre períodos; el modelo entrenado en CASEN 2022 serviría de benchmark para detectar cambios estructurales en el perfil del trabajador forestal.

En segundo lugar, el análisis empleó hiperparámetros razonables pero fijos; una búsqueda sistemática mediante RandomizedSearchCV u optimización bayesiana (Optuna) podría mejorar marginalmente el AUC del enfoque B, sobre todo en gradient boosting y XGBoost, con un potencial de uno a tres puntos porcentuales. En tercer lugar, CASEN incluye identificación de comuna, lo que permitiría entrenar modelos subregionales e identificar comunas con alta concentración de vulnerabilidad forestal, con aplicación directa en la focalización territorial de programas ESG.

En cuarto lugar, la variable oficio4_08 de CASEN contiene códigos de ocupación a cuatro dígitos; el análisis exploratorio mostró que el código 8172 tiene un 75,9% de coincidencia con trabajadores forestales, por lo que incorporarla podría elevar significativamente el AUC, aunque introduce un riesgo de circularidad si la ocupación es consecuencia y no determinante del empleo forestal. En quinto lugar, los valores SHAP podrían reescalarsse a la escala de probabilidad para obtener efectos marginales promedio (AME) análogos a los de los modelos econométricos, expresando cada contribución como el cambio en la probabilidad predicha de empleo forestal; esta transformación, discutida en la sección 6.2.5, constituye una extensión directa del presente análisis. Finalmente, complementar el análisis SHAP con métodos de inferencia causal como el double machine learning o los causal forests permitiría estimar efectos causales con flexibilidad no paramétrica, superando las limitaciones de ambos paradigmas.

Capítulo 7: Conclusiones y limitaciones

El presente análisis de aprendizaje automático aporta evidencia en cuatro dimensiones fundamentales. En primer lugar, la validación mediante siete algoritmos independientes sobre 73.676 observaciones confirma que las 19 variables sociales del conjunto base poseen un poder predictivo real y consistente, con un AUC cercano a 0,75, lo que establece un punto de partida robusto sobre su capacidad discriminativa. En segundo lugar, la incorporación de variables enriquecidas -escolaridad continua, tipo de empleo, ingreso logarítmico y horas trabajadas- eleva el AUC-ROC a 0,875. Esta mejora de +0,124, estadísticamente significativa, demuestra que variables disponibles en CASEN, aunque no consideradas inicialmente, contienen información crítica para caracterizar al trabajador forestal chileno.

En tercer lugar, el análisis SHAP a dos niveles ofrece una evaluación matizada. Las direcciones de los efectos estimados con el conjunto base (enfoque A) se mantienen en 9 de las 11 variables comparables (82%) al incorporar las variables enriquecidas, y las variables con efecto robusto y magnitud apreciable en ambos enfoques -el género, el tipo de contrato y los incentivos económicos- constituyen los hallazgos más sólidos. Las restantes se atenúan hasta magnitudes casi nulas, lo que no las invalida: revela que su efecto está mediado por factores más granulares, como el ingreso continuo y el tipo de inserción laboral.

En cuarto lugar, el uso de SHAP revela interacciones no lineales que enriquecen la comprensión de los determinantes sociales, como el efecto no monótono de la edad y el gradiente educativo completo, patrones que facilitan una focalización más precisa de las políticas públicas y de las estrategias de sostenibilidad corporativa. En conjunto, combinar los modelos econométricos tradicionales con técnicas de aprendizaje automático interpretable constituye un enfoque metodológico promisorio, capaz de integrar la inferencia causal con la predicción operativa. Cabe enfatizar que la mejora predictiva no se debe a una superioridad inherente de los algoritmos de machine learning, sino a la inclusión de datos más granulares: la regresión logística alcanza un desempeño casi idéntico al de modelos más complejos con las mismas variables, y la ventaja del aprendizaje automático radica en explorar eficientemente espacios de variables amplios y detectar interacciones complejas.

No obstante, es fundamental reconocer las limitaciones del análisis. Los resultados son de naturaleza asociativa y descriptiva: los valores SHAP indican asociaciones, pero no relaciones de

causalidad directa, por lo que las recomendaciones de política deben interpretarse como hipótesis informadas que requieren validación mediante diseños experimentales. Asimismo, la definición del sector forestal utilizada -basada en los códigos CIIU 2, 16 y 17- es amplia, por lo que los resultados caracterizan a la cadena de valor industrial en su totalidad. Finalmente, los hiperparámetros de los modelos no fueron sometidos a una búsqueda sistemática de optimización, lo que representa una oportunidad para futuros incrementos de precisión.

Las contribuciones de este trabajo son tanto metodológicas como sustantivas. El diseño dual de los enfoques demuestra que el incremento en el desempeño proviene de la calidad de la información incorporada y no solo de la complejidad algorítmica. Además, la evaluación matizada mediante SHAP identifica los determinantes más robustos y ofrece información detallada para la focalización territorial y demográfica. De cara al futuro, esta investigación abre líneas prometedoras, como aplicar el marco a encuestas de otros años para evaluar la estabilidad temporal o emplear métodos de inferencia causal avanzada como los causal forests. Un análisis a nivel comunal permitiría, en última instancia, dirigir las intervenciones de política pública hacia las zonas con mayor concentración de vulnerabilidad laboral en el sector forestal chileno.

Bibliografía

- Alsayegh, M. F., Abdul Rahman, R., & Homayoun, S. (2020). Corporate economic, environmental, and social sustainability performance transformation through ESG disclosure. *Sustainability*, 12(9), 3910. <https://doi.org/10.3390/su12093910>
- Alvear Vega, S. (2023). Determinantes sociales y proyección laboral: Profesionales universitarios en gestión, Chile. *Revista Venezolana de Gerencia*, 28(101), 47–60. <https://doi.org/10.52080/rvgluz.28.101.4>
- Alvear, S. y Astudillo, N. (2025). Social determinants of Chilean forestry workers: A challenge for sustainable industry development. *Forest Policy and Economics*, 160, 103150.
- Arvidsson, S., & Dumay, J. (2022). Corporate ESG reporting quantity, quality and performance: Where to now for environmental policy and practice? *Business Strategy and the Environment*, 31(3), 1091–1110. <https://doi.org/10.1002/bse.2937>
- Athey, S., & Wager, S. (2019). Estimating treatment effects with causal forests. *Proceedings of the National Academy of Sciences*, 116(10), 4156–4164.
- Bashir, A., Sjølie, H. K., & Solberg, B. (2020). Determinants of nonindustrial private forest owners' willingness to harvest timber in Norway. *Forests*, 11(1), 60. <https://doi.org/10.3390/f11010060>
- Becker, G. S. (1964). *Human Capital: A Theoretical and Empirical Analysis, with Special Reference to Education*. University of Chicago Press.
- Biau, G. y Scornet, E. (2016). A random forest guided tour. *TEST*, 25(2), 197–227.
- Bourdieu, P. (1986). The forms of capital. In J. Richardson (Ed.), *Handbook of Theory and Research for the Sociology of Education* (pp. 241–258). Greenwood.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- CASEN. (2022). *Encuesta de Caracterización Socioeconómica Nacional 2022*. Ministerio de Desarrollo Social y Familia, Chile.
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794).

- Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68.
- CMF. (2021). *Norma de Carácter General NCG 461: Divulgación de información no financiera*. Comisión para el Mercado Financiero, Chile.
- Coleman, J. S. (1990). *Foundations of Social Theory*. Harvard University Press.
- CORMA. (2024). *Reporte anual sector forestal chileno 2023*. Corporación Chilena de la Madera, Santiago.
- CORMA. (2025). El sector forestal: pilar estratégico para el desarrollo sostenible. Corporación Chilena de la Madera. <https://www.corma.cl>
- Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297.
- Cover, T. y Hart, P. (1967). Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1), 21–27.
- Dahlgren, G., & Whitehead, M. (1991). *Policies and Strategies to Promote Social Equity in Health*. Institute for Futures Studies.
- Dahlgren, G., & Whitehead, M. (2021). The Dahlgren-Whitehead model of health determinants: 30 years on and still chasing rainbows. *Public Health*, 199, 20–24.
- Ehrnström-Fuentes, M. (2022). Organising in defence of life: The emergence and dynamics of a territorial movement in southern Chile. *Organization*, 29(1), 155–177. <https://doi.org/10.1177/1350508420963871>
- FAO. (2022). *The State of the World's Forests 2022*. Organización de las Naciones Unidas para la Alimentación y la Agricultura.
- Fassnacht, F. E., Latifi, H., Stereńczak, K., Modzelewska, A., Lefsky, M., Waser, L. T., Straub, C. y Ghosh, A. (2016). Review of studies on tree species classification from remotely sensed data. *Remote Sensing of Environment*, 186, 64–87.
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.

- Grosser Villar, G., & Carrasco Henríquez, N. (2019). Rezago, sector forestal y trampas territoriales. *La provincia de Arauco. Bitácora Urbano Territorial*, 29(2), 143–150. <https://doi.org/10.15446/bitacora.v29n2.69730>
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer.
- Hornik, K., Stinchcombe, M. y White, H. (1989). Multilayer feedforward networks are universal approximators. *Neural Networks*, 2(5), 359–366.
- Hosmer, D. W. y Lemeshow, S. (2000). *Applied Logistic Regression* (2.^a ed.). John Wiley & Sons.
- INE. (2024). *Índices de empleo y actividad económica*. Instituto Nacional de Estadísticas, Chile. www.ine.cl
- INFOR. (2023). *Estadísticas forestales nacionales 2022*. Instituto Forestal, Ministerio de Agricultura, Chile.
- International Labour Organization (ILO). (2024). *This Way to Social Justice: ILO's global campaign to promote action against inequalities in the world of work*. <https://social-justice-coalition.ilo.org/es>
- ISSB. (2023). *IFRS S1 General Requirements for Disclosure of Sustainability-related Financial Information*. International Sustainability Standards Board.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning*. Springer.
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q. y Liu, T. Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30.
- Kröger, M. (2020). Deforestation, cattle, and land grabbing in the Brazilian Amazon. *Land Use Policy*, 99, 104957.
- Labarre, C., Domec, J.-C., Andrés-Domenech, P., Bödeker, K., Bingham, L., & Loustau, D. (2025). Improving forest decision-making through complex system representation: A viability theory perspective. *Forest Policy and Economics*, 170, 103384. <https://doi.org/10.1016/j.forpol.2024.103384>

- Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems* (pp. 4765–4774).
- Marmot, M. (1998). Improvement of social environment to improve health. *The Lancet*, 351(9095), 57–60.
- Marmot, M. (2004). *The Status Syndrome: How Social Standing Affects Our Health and Longevity*. Times Books.
- Martin-Gallego, P., Marston, C., Altamirano, A., Pauchard, A., & Aplin, P. (2024). Mapping alien and native forest dynamics in Chile using earth observation time series analysis. *Forest Ecology and Management*, 560(121847), 1–14. <https://doi.org/10.1016/j.foreco.2024.121847>
- Mijoč, D., Bakarić, M., Pandur, Z., Bačić, M., Landekić, M., & Šporčić, M. (2023). The challenge of recruiting forestry workforce in Europe and worldwide. *Šumarski list*, 147(5–6), 239–250. <https://doi.org/10.31298/sl.147.5-6.4>
- MINDES. (2022). *Política Nacional de Inclusión Social y Sustentabilidad*. Ministerio de Desarrollo Social y Familia, Chile.
- Molnar, C. (2020). *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*. christophm.github.io/interpretable-ml-book/
- Morales, V. (2022). Forestry and the forest products sector: Production, income and employment, and international trade. *Forest Policy and Economics*, 135, 102648. <https://doi.org/10.1016/j.forpol.2021.102648>
- Mullainathan, S., & Spiess, J. (2017). Machine learning: An applied econometric approach. *Journal of Economic Perspectives*, 31(2), 87–106.
- Naciones Unidas. (2015). *Transformar nuestro mundo: La Agenda 2030 para el Desarrollo Sostenible*. <https://sdgs.un.org/2030agenda>
- OMS. (2007). *Commission on Social Determinants of Health: A Conceptual Framework for Action on the Social Determinants of Health*. Organización Mundial de la Salud.
- Painecura-Medina, L. (2022). Situations of informal economic dependency in forest self-employment in La Araucanía. *Revista Austral de Ciencias Sociales*, 43, 129–150. <https://doi.org/10.4206/rev.austral.cienc.soc.2022.n43-07>

- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Putnam, R. D. (2000). *Bowling Alone: The Collapse and Revival of American Community*. Simon & Schuster.
- Schlosberg, D. (2007). *Defining Environmental Justice: Theories, Movements, and Nature*. Oxford University Press.
- Shapley, L. S. (1953). A value for n-person games. In H. W. Kuhn & A. W. Tucker (Eds.), *Contributions to the Theory of Games II* (pp. 307–317). Princeton University Press.
- Sjølie, H. K., Akin, D., & Lauritzen, T. (2023). Gender differences in job experiences and satisfaction in the forest sector. *Canadian Journal of Forest Research*, 54(2). <https://doi.org/10.1139/cjfr-2023-0036>
- Suddeephong, L., Ojeda, T., Katajamäki, W., & Schweinle, J. (2023). Labour informality in forestry: A longitudinal (2009–2020) cross-country analysis of determinants in 70 developing countries. *Forest Policy and Economics*, 156, 103056. <https://doi.org/10.1016/j.forpol.2023.103056>
- Sustainable Stock Exchanges (SSE). (2015). *Sustainable stock exchanges initiative: Model guidance on reporting ESG information to investors*. www.sseinitiative.org/wp-content/uploads/2015/09/SSE-Model-Guidance-on-Reporting-ESG.pdf
- Torres-Salinas, R., García-Carmona, R., & Rojas-Hernández, J. (2023). Forestry development, water scarcity, and the Mapuche protest for environmental justice in Chile. *Ambiente & Sociedade*, 26, e00843.
- Vapnik, V. N. (1995). *The Nature of Statistical Learning Theory*. Springer.
- Villalobos, C. & Riquelme, A. (2023). "Household constraints and dysfunctional rural–urban migration," *Economic Analysis and Policy*, Elsevier, vol. 78(C), pages 1070-1088.
- Wooldridge, J. M. (2010). *Econometric Analysis of Cross Section and Panel Data* (2.^a ed.). MIT Press.