



TASA DE NATALIDAD Y POLITICA PUBLICA
MODELOS PREDICTIVOS CON DATOS DE PANEL MUNDIAL Y MACHINE LEARNING
SUPERVISADO

ACTIVIDAD FORMATIVA EQUIVALENTE
PARA OPTAR AL GRADO DE MAGÍSTER EN ANALÍTICA DE NEGOCIOS

Estudiante: Cristian Cabezas Lepilla

Profesor Guía: Charles Thraves

Santiago, Chile

2026

DEDICATORIA

A mis hijos Rodrigo Cabezas y Martín Cabezas, por ser mi norte y mi refugio. Este logro no es solo mío, sino de todos nosotros como familia. Gracias por comprender mis ausencias y por ser el motor que me impulsó a terminar este camino.

AGRADECIMIENTOS

Deseo expresar mi más sincero agradecimiento a la Fundación Luksic Scholars por el financiamiento otorgado para este magíster, gracias por confiar en mis capacidades para ser de Chile un mejor país. Su respaldo fue una pieza fundamental para mi desarrollo profesional y personal.

Asimismo, extendo mi gratitud al profesor Charles Thraves. Su guía experta en el desarrollo del Modelo Predictivo de la Tasa de Natalidad fue esencial para el rigor analítico de esta investigación. Gracias por plantearme un problema de estudio de alto impacto económico y social.

Hago un reconocimiento especial a mis compañeros de estudio, Marcelo Adaros, Juan Gajardo y Bastián Valenzuela. La colaboración con profesionales de sus niveles y de tan diversas disciplinas fue fundamental para ampliar mi perspectiva en el mundo de la analítica.

Finalmente, agradezco profundamente a Verónica Ahumada. Su paciencia y comprensión respecto al tiempo demandado por este proyecto fueron vitales para culminar con éxito este proceso de titulación.

ÍNDICE

1	RESUMEN EJECUTIVO	6
2	INTRODUCCION	8
3	PLANTEAMIENTO Y FORMULACION DEL PROBLEMA	10
4	HIPOTESIS	12
5	OBJETIVOS	12
6	REVISION BIBLIOGRAFICA	13
6.1	ANÁLISIS DE INVESTIGACIONES RECIENTES (2020-2025)	13
6.1.1	DESEMPEÑO DE ALGORITMOS DE ENSAMBLE Y REDES NEURONALES	13
6.1.2	PREDICCIÓN DE INTENCIONES Y PREFERENCIAS REPRODUCTIVAS	13
6.1.3	FACTORES DETERMINANTES E IMPACTO AMBIENTAL	13
6.1.4	CHOQUES EXTERNOS Y SOSTENIBILIDAD	14
7	MARCO TEORICO	15
8	METODOLOGIA	18
9	DESCRIPCION DEL ENFOQUE DE SOLUCION	21
10	RESULTADOS	23
10.1	COMPRESIÓN DE LOS DATOS	23
10.1.1	ORIGEN DE LOS DATOS	23
10.1.2	EXPLORACIÓN INICIAL	24
10.2	PREPARACIÓN DE LOS DATOS	28
10.2.1	SELECCIÓN DE VARIABLES	28
10.2.2	LIMPIEZA DE DATOS	29
10.2.3	ANÁLISIS DE REPRESENTATIVIDAD Y SESGO DE SELECCIÓN:	29
10.2.4	TRANSFORMACIÓN Y ESCALAMIENTO:	29
10.3	MODELAMIENTO	30
10.3.1	DEFINICIÓN DE MODELOS IMPLEMENTADOS:	30
10.3.2	ESTRATEGIA DE VALIDACIÓN Y PARTICIÓN DE DATOS:	31
10.4	EVALUACIÓN	31
10.4.1	COMPARACIÓN DE DESEMPEÑO	31
10.4.2	ANÁLISIS DE LA CAPACIDAD PREDICTIVA	31
10.4.3	INTERPRETACIÓN MEDIANTE VALORES SHAP	31
11	CONCLUSIONES	33

<u>12 BIBLIOGRAFIA</u>	<u>34</u>
<u>13 ANEXOS</u>	<u>36</u>
13.1 ESTADÍSTICAS DESCRIPTIVAS	36
13.2 DISTRIBUCIONES VARIABLES PREDICTORAS ORIGINALES (CON RUIDO)	37

1 RESUMEN EJECUTIVO

Español

Contexto/Introducción

La tasa de natalidad ha disminuido de forma sostenida en numerosos países, alcanzando en Chile una tasa global de fecundidad de 1,03 hijos por mujer en 2024 (INE, 2024). Esta situación plantea desafíos asociados al envejecimiento poblacional, la reducción de la fuerza laboral y la sostenibilidad de los sistemas de salud y pensiones.

Motivación/Necesidad

La complejidad de los factores que influyen en la natalidad requiere herramientas analíticas capaces de capturar relaciones no lineales entre variables demográficas, sociales y económicas. En este contexto, la investigación tuvo como objetivo desarrollar un modelo predictivo que apoye la toma de decisiones en políticas públicas.

Enfoque de Solución

Bajo la metodología CRISP-DM, se construyó una base de datos de panel utilizando información del Banco Mundial para el período 1998–2023. Se evaluaron modelos de Regresión Lineal Múltiple (OLS), Ridge, Random Forest y Gradient Boosting, incorporando variables relacionadas con educación, empleo, salud, desarrollo económico y condiciones demográficas.

Resultados

El modelo Gradient Boosting presentó el mejor desempeño predictivo, alcanzando un Coeficiente de Determinación (R^2) de 0,903 y un error absoluto medio (MAE) de 0,084. El análisis mediante SHAP identificó a la esperanza de vida, la educación terciaria y el empleo agrícola como los principales determinantes de la natalidad.

Conclusiones

Los resultados evidencian que las técnicas de aprendizaje supervisado permiten estimar la tasa de natalidad con alta precisión y aportar evidencia para la planificación y formulación de políticas públicas orientadas a enfrentar los desafíos demográficos futuros.

English

Context / Introduction

Fertility rates have steadily declined across numerous countries, with Chile reaching a Total Fertility Rate of 1.03 children per woman in 2024 (INE, 2024). This situation poses significant challenges related to population aging, a shrinking workforce, and the sustainability of healthcare and pension systems.

Motivation / Need

The complexity of the factors influencing fertility requires analytical tools capable of capturing nonlinear relationships among demographic, social, and economic variables. In this context, the objective of this research was to develop a predictive model to support public policy decision-making.

Solution Approach

Following the CRISP-DM methodology, a panel dataset was constructed using World Bank data covering the period 1998–2023. Ordinary Least Squares (OLS), Ridge Regression, Random Forest, and Gradient Boosting models were evaluated, incorporating variables related to education, employment, health, economic development, and demographic conditions.

Results

The Gradient Boosting model achieved the best predictive performance, reaching a coefficient of determination (R^2) of 0.903 and a Mean Absolute Error (MAE) of 0.084. SHAP analysis identified life expectancy, tertiary education, and agricultural employment as the main determinants of fertility.

Conclusions

The results demonstrate that supervised learning techniques can estimate fertility rates with high accuracy and provide valuable evidence for the planning and formulation of public policies aimed at addressing future demographic challenges.

2 INTRODUCCION

La tasa de natalidad es un indicador demográfico fundamental que refleja el número de nacimientos en una población y su impacto se extiende a numerosos aspectos de la sociedad.

En Chile, como en muchos países de ingresos medios y altos, la tasa de natalidad ha experimentado una disminución significativa en las últimas décadas, lo que plantea diversos desafíos y oportunidades en términos de planificación y gestión de políticas públicas.

Según datos del INE, en 1992 los nacimientos en Chile alcanzaron a los 279.098 casos, treinta años más tarde, en 2022 la cifra llegó 189.303 nacidos vivos, lo que representa una caída en 89.795 (32,2%) nacimientos, si se compara con 2024p cuando nacieron 154.441 personas, la diferencia es del orden de 124.657 nacimientos (44,7%). (INE, 2024).

Esta disminución ha llevado a que la tasa de fecundidad promedio en el país sea de 1,03 hijos por mujer, por debajo del 2,1 para evitar un envejecimiento excesivo de la población (INE, datos provisionales 2024).

Este descenso en la tasa de natalidad se atribuye a múltiples factores, entre ellos:

- **Aumento en el nivel educacional:** mayor acceso a la educación, especialmente entre las mujeres, ha influido en la postergación de la maternidad y en la reducción del número de hijos.
- **Participación femenina en el mercado laboral:** la incorporación de las mujeres al ámbito laboral ha modificado las dinámicas familiares y las decisiones reproductivas.
- **Acceso a métodos anticonceptivos:** la disponibilidad y uso de anticonceptivos han facilitado una planificación familiar más efectiva.
- **Cambios socioculturales:** evolución en las percepciones sobre la familia, el matrimonio y la maternidad.

Comprender y anticipar las tendencias en la tasa de natalidad es importante para la toma de decisiones en áreas como la economía, la educación, la salud y los sistemas de pensiones. A medida que la tasa de natalidad disminuye, el crecimiento de la población tiende a estabilizarse o incluso disminuir, lo que plantea retos para el financiamiento de servicios públicos y el equilibrio intergeneracional, especialmente en un contexto de envejecimiento poblacional. La capacidad de prever con precisión estas tendencias a través de modelos predictivos permite a los responsables de la formulación de políticas planificar y adaptar sus estrategias, asegurando así una respuesta adecuada a los futuros cambios demográficos.

En este contexto, la analítica de datos y las técnicas de aprendizaje supervisado ofrecen una alternativa para modelar relaciones no lineales entre variables sociodemográficas y económicas, permitiendo mejorar la capacidad predictiva y apoyar la toma de decisiones basada en evidencia.

El objetivo de esta investigación fue desarrollar y evaluar un modelo predictivo de la tasa de natalidad utilizando información histórica proveniente del Banco Mundial para el período 1998–2023. El estudio se estructuró sobre una base de datos de panel de alcance mundial, integrando variables relacionadas con educación, desarrollo económico, empleo, salud y condiciones demográficas.

Siguiendo la metodología CRISP-DM, se desarrollaron y compararon cuatro modelos predictivos (Regresión Lineal Múltiple (OLS), Ridge, Random Forest y Gradient Boosting) con el objetivo de identificar la técnica con mejor capacidad para estimar la tasa de natalidad. Para asegurar la validez de los resultados, la base de datos se dividió por países, utilizando un 70% para entrenamiento y un 30% para prueba. De esta manera, los modelos fueron evaluados sobre países que no participaron en el entrenamiento, permitiendo medir su capacidad de generalizar y realizar predicciones confiables en contextos internacionales nuevos.

Los resultados obtenidos permitieron identificar al algoritmo Gradient Boosting como la alternativa de mejor desempeño predictivo, alcanzando un Coeficiente de Determinación (R^2) de 0,903. Esto indica que el modelo logra explicar aproximadamente el 90,3% de la variabilidad observada en la tasa de natalidad, evidenciando una elevada capacidad predictiva sobre países no utilizados durante el entrenamiento. Asimismo, mediante técnicas de interpretabilidad basadas en SHAP, se identificaron los factores con mayor influencia sobre la natalidad, destacando la esperanza de vida, la educación terciaria y el empleo agrícola.

El presente informe expone el problema de investigación, los fundamentos teóricos, la metodología aplicada, el desarrollo del modelo predictivo, los resultados obtenidos y sus implicancias para la formulación de políticas públicas orientadas a enfrentar los desafíos asociados al descenso de la natalidad.

3 PLANTEAMIENTO Y FORMULACION DEL PROBLEMA

La disminución sostenida de la tasa de natalidad en Chile y en el mundo en las últimas décadas plantea una serie de desafíos socioeconómicos que afectan tanto a corto como a largo plazo. Este descenso, que ha llevado la tasa de fecundidad de Chile a niveles de 1,03 hijos por mujer en 2024, está por debajo del nivel de reemplazo poblacional de 2,1 hijos. Las implicancias de esta tendencia se extienden a múltiples dimensiones, como el envejecimiento de la población, la disminución de la fuerza laboral y la presión creciente sobre los sistemas de pensiones y de salud.

La persistencia de esta tendencia sin una intervención o ajuste adecuado en las políticas públicas podría llevar a un desequilibrio intergeneracional y a una disminución en la capacidad de sostenibilidad de los servicios sociales. Sin un modelo predictivo que anticipe estos cambios, los responsables de la formulación de políticas podrían carecer de información vital para tomar mejores decisiones. Esto resalta la importancia de integrar la analítica de negocios en el desarrollo de políticas públicas, utilizando datos y modelos para adaptar estrategias a las realidades demográficas.

Actualmente, el mundo enfrenta el desafío de prever los efectos de esta disminución de la natalidad y desarrollar estrategias de mitigación que aseguren la estabilidad social y económica en el futuro.

Además, la volatilidad en las tendencias demográficas, derivada de factores como las variaciones en políticas sociales, cambios en las expectativas de vida y transformaciones culturales, hacen que las predicciones sean complejas y que se requiera un modelo adaptativo. Es fundamental considerar las limitaciones de los datos, como posibles sesgos en la recolección de información y la calidad de estos, que podrían afectar la precisión de las predicciones. Asimismo, la evolución de factores socioeconómicos y culturales puede influir en la validez del modelo a largo plazo, lo que debe tenerse en cuenta al interpretar los resultados.

Problema Principal

La principal problemática es: ¿Cómo desarrollar un modelo predictivo de la tasa de natalidad de un país a mediano y largo plazo, considerando los factores socioeconómicos y demográficos cambiantes?

Este problema se puede descomponer en varias preguntas específicas:

¿Cuáles son los factores más significativos que influyen en la tasa de natalidad? Identificar estos factores es esencial para construir un modelo que capture con precisión la realidad demográfica del país.

¿Cómo afectan los cambios en el nivel de educación, la incorporación de la mujer al mercado laboral y el acceso a la salud reproductiva en la tasa de natalidad? La influencia de estos factores debe ser cuantificada y entendida en el contexto mundial.

¿Qué técnicas son más adecuadas para la predicción de la natalidad en un contexto de cambios demográficos y socioeconómicos constantes? Elegir el modelo adecuado (por ejemplo, regresión, series temporales, machine learning) es crítico para lograr predicciones precisas y que el modelo sea adaptable a nuevas condiciones o cambios en los factores determinantes.

¿Cómo puede un modelo predictivo informar la formulación de políticas públicas para mitigar los efectos negativos de una baja en la tasa de natalidad?, este subproblema busca conectar el modelo predictivo con su aplicación práctica, asegurando que los resultados sean útiles para los tomadores de decisiones.

Justificación

La formulación de un modelo predictivo de la tasa de natalidad tiene el potencial de contribuir significativamente a la planificación social y económica de un país. La capacidad de anticipar cambios demográficos permite a los responsables de la formulación de políticas públicas disponer de información basada en evidencia para apoyar la toma de decisiones estratégicas.

Las proyecciones de natalidad son especialmente relevantes para la planificación de sistemas de salud, educación, pensiones y programas de apoyo familiar, debido a que los cambios en la estructura poblacional generan efectos de largo plazo sobre la disponibilidad de recursos y la sostenibilidad de los servicios públicos.

En este contexto, la analítica de datos y las técnicas de aprendizaje supervisado ofrecen una alternativa para identificar patrones complejos entre variables sociodemográficas y económicas, permitiendo estimar la evolución futura de la natalidad con un mayor nivel de precisión. El desarrollo de una herramienta predictiva puede aportar información útil para evaluar escenarios demográficos y apoyar el diseño, implementación y seguimiento de políticas públicas orientadas a enfrentar los desafíos asociados al envejecimiento poblacional y a la disminución de la fuerza laboral.

4 HIPOTESIS

Hipótesis General

La tasa de natalidad puede ser estimada con un alto nivel de precisión mediante modelos de aprendizaje supervisado que integren variables sociodemográficas y económicas obtenidas a partir de datos de panel de alcance internacional.

Hipótesis Específicas

H1. Las variables asociadas al desarrollo humano y socioeconómico, tales como la esperanza de vida, la educación terciaria, el empleo agrícola y otros indicadores económicos, presentan una relación significativa con la tasa de natalidad y contribuyen a su capacidad predictiva.

H2. Los modelos de aprendizaje supervisado basados en técnicas de ensamble, tales como Random Forest y Gradient Boosting, presentan un mejor desempeño predictivo que los modelos lineales tradicionales, debido a su capacidad para capturar relaciones no lineales e interacciones complejas entre las variables explicativas.

H3. La aplicación de técnicas de interpretabilidad permite identificar los principales determinantes de la natalidad y cuantificar la contribución relativa de cada variable al resultado estimado, fortaleciendo la comprensión del fenómeno y la utilidad del modelo para la toma de decisiones en políticas públicas.

5 OBJETIVOS

Objetivo general:

Desarrollar y evaluar un modelo predictivo que permita estimar la tasa de natalidad utilizando variables sociodemográficas y económicas de alcance internacional, con el propósito de apoyar la toma de decisiones y la formulación de políticas públicas basadas en evidencia frente a los desafíos demográficos asociados al descenso de la natalidad.

Objetivos específicos:

- Identificar y seleccionar las variables sociodemográficas y económicas con mayor influencia sobre la tasa de natalidad.
- Implementar y comparar diferentes técnicas de modelado predictivo, incluyendo modelos lineales y algoritmos de aprendizaje supervisado, para determinar la alternativa con mejor desempeño predictivo.
- Validar el desempeño y la capacidad de generalización de los modelos mediante métricas de evaluación y una estrategia de partición basada en países.
- Interpretar la contribución de las variables explicativas mediante técnicas de explicabilidad, identificando los principales determinantes de la natalidad y evaluando la utilidad del modelo como herramienta de apoyo para la toma de decisiones en políticas públicas.

6 REVISION BIBLIOGRAFICA

La presente sección constituye una compilación exhaustiva de resultados derivados de investigaciones internacionales y nacionales sobre la dinámica de la natalidad y su modelamiento predictivo. El objetivo es establecer el estado actual de la disciplina, identificando los avances logrados en el último lustro mediante la integración de la estadística demográfica y la analítica avanzada.

6.1 Análisis de Investigaciones Recientes (2020-2025)

En los últimos cinco años, la demografía ha evolucionado hacia un enfoque integrador que fusiona la estadística clásica con algoritmos de aprendizaje automático para capturar interacciones no lineales de variables socioeconómicas y biológicas.

6.1.1 Desempeño de Algoritmos de Ensamble y Redes Neuronales

Las investigaciones demuestran de forma consistente que los métodos de ensamble superan a los modelos lineales tradicionales:

- **En Colombia**, un estudio de registros históricos determinó que el método Bagging (Random Forest) redujo significativamente la varianza y el error de generalización en comparación con la regresión lineal (Ordóñez-Erazo et al., 2022).

Asimismo, otro análisis basado en microdatos del DANE identificó al modelo XGBoost como el más preciso para predecir la variabilidad de los datos de natalidad nacional (Largo Quintero & Valencia Cadena, 2024).

- **En Etiopía**, se evaluaron siete modelos para predecir tendencias mensuales de nacimientos, resultando el modelo GLMNET (Red Elástica) el de mejor desempeño al explicar el 77% de la varianza (Alemayehu et al., 2025).
- **En contextos clínicos**, el uso de Redes Neuronales (NN) para predecir nacimientos vivos en tratamientos de fertilidad asistida logró precisiones de hasta 0.90, superando ampliamente el rango de la estadística clásica (Barnett-Itzhaki et al., 2020).

6.1.2 Predicción de Intenciones y Preferencias Reproductivas

El ML ha permitido modelar el deseo de procrear en regiones con datos escasos:

- **En Somalia**, el algoritmo Random Forest fue pionero en predecir la preferencia de fecundidad, revelando que la edad de la madre y la paridad son los predictores más influyentes (Sani et al., 2025).
- **En Nigeria**, este mismo algoritmo alcanzó una precisión del 92% al identificar patrones ocultos en el deseo de las mujeres de no tener más hijos (Tadese et al., 2025).

6.1.3 Factores Determinantes e Impacto Ambiental

Mediante técnicas de interpretabilidad como SHAP, se ha logrado cuantificar el peso de las variables:

- **Jerarquía de importancia:** En Colombia, el factor educativo materno se confirmó como una variable predictiva crítica junto con la ubicación geográfica (Largo Quintero & Valencia Cadena, 2024).

- **Variables ambientales:** La aplicación de modelos GAMLSS demostró que factores como la temperatura media y la contaminación del aire (PM2,5) influyen significativamente en la tasa de natalidad a nivel de país (Quintero López & Saavedra Coneo, 2022).

6.1.4 Choques Externos y Sostenibilidad

- **Efectos de la Pandemia:** Un análisis multivariable reveló que la inflación (costo de vida) y el progreso de los programas de vacunación fueron predictores más determinantes del descenso de la natalidad en 2022 que el desempleo (Winkler-Dworak et al., 2024).
- **Simulación de población rural:** El uso de Modelado Basado en Agentes (ABM) permitió predecir cambios en la población rural hasta 2035, superando la precisión de modelos demográficos tradicionales (Huang et al., 2025).
- **Sostenibilidad fiscal:** En Corea del Sur, se utilizó el análisis de transferencias monetarias para demostrar que, sin incentivos fiscales, la tasa de fecundidad habría sido un 4.7% inferior en 2015, advirtiendo sobre la viabilidad futura de los sistemas de pensiones (Kim, 2024).

7 MARCO TEORICO

El marco teórico establece las bases conceptuales para el desarrollo del modelo predictivo, combinando teorías demográficas, factores socioeconómicos y metodologías analíticas. A continuación, se detallan los enfoques teóricos relevantes y las fuentes correspondientes.

Indicadores de Natalidad y Fecundidad:

- **Natalidad y Tasa Bruta de Natalidad (TBN):** Representa la frecuencia de los nacimientos vivos en una población. Se calcula como el cociente entre el número de nacimientos en un año y la población total a mitad de ese mismo año, expresado por cada 1.000 habitantes (INE, 2025).
- **Fecundidad:** A diferencia de la natalidad, la fecundidad se refiere específicamente a la relación entre los nacimientos y la población femenina en edad fértil (15 a 49 años). Es una medida más precisa para el modelamiento predictivo, ya que elimina el efecto de la estructura por edad de toda la población (INE, 2025).
- **Tasa Global de Fecundidad (TGF):** Es el indicador central de esta investigación. Representa el número promedio de hijos que tendría una mujer durante su vida fértil si se mantuvieran constantes las tasas de fecundidad por edad. Se considera que el nivel de reemplazo poblacional es de 2,1 hijos por mujer; bajo este umbral, la población tiende a envejecer y disminuir en el largo plazo (Larrañaga, 2007; INE, 2025).

Teorías demográficas:

- **Teoría de la Transición Demográfica:** Explica la evolución de las sociedades de altas tasas de natalidad y mortalidad hacia niveles bajos, producto de cambios en salud, educación y economía. En Chile, entre 1960 y 2003, la tasa de hijos por mujer disminuyó drásticamente de 4.5 a 2.4, mientras la proporción de nacimientos fuera del matrimonio aumentó de 15,9% a 53,8% (Larrañaga, 2007).
- **Teoría de la Segunda Transición Demográfica:** Vincula cambios culturales y sociales, como el aumento de nacimientos fuera del matrimonio y la postergación de la maternidad. En Chile, estos fenómenos se asocian con mayor acceso a métodos anticonceptivos, participación laboral femenina y transformaciones en las estructuras familiares (Van de Kaa, 1987; Larrañaga, 2007).

Factores Socioeconómicos y su relación con la natalidad:

La natalidad en Chile ha sido influenciada por múltiples factores, como:

- **Educación:** La escolaridad de las mujeres entre 25 y 29 años aumentó de 6,4 años en 1960 a 11,5 en 2003. Este incremento ha favorecido la planificación familiar y la reducción de la fecundidad, especialmente entre mujeres de niveles socioeconómicos bajos (Larrañaga, 2007).
- **Participación laboral femenina:** Aunque la inserción laboral de las mujeres aumentó considerablemente desde los años 90, esta tendencia está correlacionada con una menor tasa de fecundidad, especialmente entre mujeres casadas, cuya tasa de natalidad cayó de 258,9 nacimientos por cada 1000 mujeres en 1960 a 68,9 en 2000 (Larrañaga, 2007).

- **Acceso a métodos anticonceptivos:** La masificación del control de natalidad a partir de la década de 1960 fue clave para reducir las tasas de fecundidad, especialmente entre mujeres casadas, al permitirles planificar mejor los embarazos (Larrañaga, 2007).
- **Reducción de la mortalidad infantil:** Entre 1960 y 2003, la tasa de mortalidad infantil en Chile cayó de 125,1 a 8,3 muertes por cada 1000 nacidos vivos. Esto redujo la necesidad de tener más hijos para garantizar la supervivencia de una cantidad deseada de niños (Larrañaga, 2007).

Metodologías Predictivas en demografía:

El análisis predictivo en demografía se sustenta en metodologías cuantitativas que permiten modelar tendencias y relaciones entre variables. Estas técnicas no solo identifican patrones históricos, sino que también proyectan escenarios futuros. A continuación, se desarrolla en profundidad cada metodología relevante, destacando su utilidad específica en el contexto de la predicción de la tasa de natalidad.

- **Regresión lineal múltiple:** es una herramienta básica y poderosa para modelar relaciones entre una variable dependiente (e.g., tasa de natalidad) y múltiples variables independientes (e.g., nivel educativo, ingresos, acceso a métodos anticonceptivos). Según Montgomery et al. (2012), esta técnica tiene varias aplicaciones en demografía:
 - o **Propósito:** identificar la contribución relativa de diferentes factores socioeconómicos a la variación en la natalidad.
 - o **Supuestos:** relación lineal entre variables, normalidad de los errores, homocedasticidad y no multicolinealidad entre las variables independientes.
 - o **Aplicación en demografía:** por ejemplo, modelar cómo el ingreso per cápita y la participación laboral femenina afectan la tasa de natalidad.
- **Análisis de series temporales:** Hyndman y Athanasopoulos (2018) destacan las series temporales como una técnica clave para analizar datos históricos y proyectar tendencias futuras. Este método se enfoca en identificar patrones cíclicos, estacionales y de tendencia en los datos.
 - o **Propósito:** Predecir la tasa de natalidad futura basada en datos históricos, considerando componentes como estacionalidad (e.g., patrones anuales) y tendencia (e.g., disminución sostenida en la natalidad).
 - o **Modelos más comunes:**
 - ARIMA (Autoregressive Integrated Moving Average): Adecuado para datos con patrones complejos, como ciclos de largo plazo.
 - ETS (Error, Trend, Seasonality): Se utiliza para datos con fuertes patrones estacionales.
- **Machine learning:** estas técnicas son útiles para capturar relaciones complejas y no lineales entre variables. Bishop (2006) explica que estos métodos pueden superar las limitaciones de los enfoques tradicionales en problemas con muchas variables y grandes volúmenes de datos.

o Métodos relevantes:

- **Bosques Aleatorios (Random Forests):** son un método de aprendizaje supervisado que combina múltiples árboles de decisión independientes para mejorar la precisión de las predicciones y la robustez frente a datos ruidosos o atípicos. Un bosque aleatorio podría analizar cómo factores como el ingreso per cápita, la educación y el acceso a servicios de salud interactúan para influir en la tasa de natalidad, destacando las variables más relevantes.

Cómo funcionan:

- Se crean múltiples árboles de decisión utilizando subconjuntos aleatorios del conjunto de datos y de las características disponibles (bootstrap sampling y feature bagging).
 - Cada árbol genera una predicción, y el bosque utiliza la media (para regresión) o el voto mayoritario (para clasificación) de los árboles para obtener el resultado final.
- **Redes Neuronales (Artificial Neural Networks, ANN):** son modelos inspirados en el cerebro humano, diseñados para detectar patrones complejos en grandes conjuntos de datos. Son especialmente útiles para capturar interacciones no evidentes y no lineales entre múltiples variables. Una red neuronal podría capturar cómo la interacción no lineal entre factores como la edad promedio de maternidad, la proporción de mujeres en educación superior y las políticas públicas afectan la tasa de natalidad.

Cómo funcionan:

- Constan de capas de neuronas: una capa de entrada (variables predictoras), capas ocultas (procesamiento intermedio) y una capa de salida (predicción).
 - Cada conexión entre neuronas tiene un peso que se ajusta durante el entrenamiento para minimizar el error en las predicciones.
- **Gradient Boosting Machines (GBM):** técnica de aprendizaje supervisado que utiliza una serie de modelos débiles (habitualmente árboles de decisión) y los optimiza iterativamente, ajustándose a los errores residuales en cada paso. Un modelo GBM podría ajustarse para optimizar las predicciones de la tasa de natalidad considerando factores como tendencias económicas, cambios demográficos y políticas públicas, logrando capturar patrones complejos en los datos.

Cómo funcionan:

- Se construyen árboles de decisión secuenciales, donde cada árbol posterior corrige los errores del árbol anterior.
- Los modelos resultantes se combinan para producir una predicción más precisa

8 METODOLOGIA

La metodología utilizada es la adaptación del proceso CRISP-DM, que asegura una estructura clara y replicable para el desarrollo del modelo. El enfoque corresponde al método inductivo-cuantitativo, ya que parte de datos específicos para llegar a conclusiones generales sobre patrones en la tasa de natalidad y utiliza técnicas cuantitativas para modelar estos patrones de manera precisa.

La metodología CRISP-DM (Cross-Industry Standard Process for Data Mining), desarrollada en 1996 por un consorcio liderado por empresas como Daimler Chrysler y SPSS, se consolidó como el estándar más utilizado para proyectos de análisis de datos y minería de información. Este método se basa en un enfoque iterativo, estructurado y adaptativo para resolver problemas mediante el análisis de datos.

Según Maldonado y Vairetti (2022), CRISP-DM es una metodología práctica porque proviene de experiencias reales de analistas de minería de datos, la cual se organiza en fases, procesos, entregables y actividades para el cumplimiento del proceso completo, como se muestra en la siguiente figura:




Figura 1: Proceso CRISP-DM

Se propone utilizar esta metodología para modelar la tasa de natalidad por las siguientes razones:

- Flexibilidad: permite iteraciones y ajustes según los descubrimientos en cada etapa
 - Estructura: define un flujo claro para guiar desde el problema hasta la implementación del modelo
 - Orientación a datos: su enfoque en el análisis de datos lo hace ideal para proyectos predictivos como este
- **Comprensión del negocio:** en el contexto del proyecto de predicción de la tasa de natalidad de Chile, esta etapa busca obtener una visión clara y realista de las necesidades del país en relación con este indicador demográfico. Esto incluye identificar los objetivos clave del proyecto, los recursos disponibles (como datos históricos, herramientas analíticas y personal experto) y los problemas o preguntas que el modelo debe responder.

Para cumplir con estos objetivos, es esencial establecer un objetivo principal claro, como generar un modelo predictivo robusto, junto con objetivos secundarios, como identificar los factores más influyentes en la natalidad y proponer recomendaciones para la formulación de políticas públicas.

Además, se deben analizar las restricciones y supuestos actuales, como las limitaciones en la calidad de los datos y cantidad de datos disponibles. También es importante identificar posibles riesgos, como problemas relacionados con la representatividad de los datos, limitaciones tecnológicas o sesgos.

- **Compresión de los datos:** se enfoca en recolectar y analizar los datos disponibles en su estado inicial. Esto incluye identificar su origen (e.g., INE, Registro Civil, Banco Mundial, Unesco), evaluar su calidad, y comprender sus características, estructura y posibles problemas, como datos faltantes o inconsistentes. También se deben considerar los riesgos asociados al uso de estos datos, como sesgos en la recolección o falta de representatividad.

Dado que los datos son el elemento central para construir el modelo predictivo, esta fase es fundamental para garantizar que los insumos sean de la mayor calidad posible. Este análisis inicial permitirá establecer un punto de partida para las etapas posteriores, como la preparación y el modelado de los datos.

- **Preparación de los datos:** incluye todas las actividades necesarias para obtener un conjunto de datos limpio y listo para el modelado. Esto implica seleccionar las variables relevantes, limpiar los datos para garantizar su calidad, transformar valores (e.g., normalización, creación de nuevas variables si fuera necesario) e integrar información de distintas fuentes cuando sea necesario. Estas acciones aseguran que los datos sean adecuados para aplicar las herramientas analíticas del modelo.
- **Modelado:** consiste en construir un modelo que ayude a cumplir los objetivos definidos, tanto en términos de análisis de datos como en la toma de decisiones. En esta etapa, se aplican diferentes técnicas al conjunto de datos preparado previamente, con el propósito de identificar patrones o predecir la variable objetivo (tasa de natalidad).

La elección de las técnicas (como regresión, clasificación o métodos avanzados como machine learning) dependerá del tipo de problema y de los objetivos específicos del análisis. El enfoque busca seleccionar la técnica más adecuada para obtener resultados consistentes.

- **Evaluación del modelo:** aquí se analiza la calidad de los resultados obtenidos para determinar si cumplen con los objetivos planteados inicialmente. Esto incluye verificar si el modelo responde adecuadamente a las preguntas definidas y si contribuye a los objetivos del negocio, ya sea de forma directa o indirecta. Además, se revisa el proceso completo de desarrollo del modelo para identificar posibles errores y proponer mejoras o ajustes que optimicen su desempeño.

El modelo podría evaluarse con métricas de desempeño específicas, como el Error Cuadrático Medio (RMSE), el Error Absoluto Medio (MAE) o el Coeficiente de Determinación (R^2), dependiendo de la técnica que se utilice. Además, se pueden realizar pruebas de validación cruzada para garantizar su generalización y comparar las predicciones del modelo con datos históricos no utilizados en el entrenamiento, evaluando así su precisión y robustez en distintos escenarios.

- **Despliegue o implementación:** el modelo predictivo, desarrollado como un proyecto académico, se presenta como una herramienta que podría apoyar la toma de decisiones en políticas públicas para gestionar la tasa de natalidad y las implicancias que esta tiene en el ámbito económico y social del país. Los resultados se pueden compartir con posibles interesados, como académicos, instituciones públicas, u organismos internacionales como el Banco Mundial para mostrar su utilidad práctica.

9 DESCRIPCION DEL ENFOQUE DE SOLUCION

El desarrollo del modelo predictivo se realizó utilizando información proveniente del Banco Mundial correspondiente al período 1998–2023. El objetivo fue construir una herramienta capaz de estimar la tasa de natalidad a partir de variables sociodemográficas y económicas observadas a nivel internacional, permitiendo identificar patrones comunes entre países y evaluar la capacidad predictiva de distintas técnicas de modelamiento.

La base de datos se estructuró en formato de panel, integrando información histórica de múltiples países y años. A partir de la revisión bibliográfica y del marco teórico desarrollado en los capítulos anteriores, se seleccionaron variables asociadas a educación, salud, empleo, desarrollo económico y características demográficas, debido a su relevancia reportada en la literatura para explicar las diferencias observadas en los niveles de natalidad.

Como parte de la etapa de preparación de los datos, se efectuaron procesos de integración, depuración y validación de la información recopilada. Se eliminaron registros con información insuficiente para el análisis y se verificó la consistencia temporal y estructural de las variables seleccionadas. Posteriormente, se construyó una base consolidada que permitiera la comparación homogénea entre países y períodos.

Con el propósito de mejorar la calidad de los datos para el modelamiento, se analizaron las distribuciones de las variables explicativas y se identificó la presencia de asimetrías significativas en algunos indicadores económicos y demográficos. Para abordar esta situación, se aplicaron transformaciones logarítmicas a aquellas variables que presentaban distribuciones altamente sesgadas, reduciendo la influencia de valores extremos y favoreciendo una mejor capacidad de aprendizaje de los modelos predictivos.

La estrategia de validación se diseñó considerando la necesidad de evaluar la capacidad de generalización de los modelos en contextos no observados. Para ello, la muestra fue dividida en conjuntos de entrenamiento y prueba utilizando una partición basada en países. Esta decisión metodológica permitió evitar que registros de un mismo país estuvieran presentes simultáneamente en ambos conjuntos, generando una evaluación más exigente y representativa del desempeño esperado en aplicaciones reales.

Una vez finalizada la etapa de preparación de datos, se implementaron distintos modelos predictivos con el propósito de comparar su capacidad para estimar la tasa de natalidad. Los modelos evaluados incluyeron Regresión Lineal Múltiple (OLS), Ridge Regression, Random Forest y Gradient Boosting. La selección de estas técnicas permitió comparar enfoques tradicionales basados en relaciones lineales con algoritmos de aprendizaje supervisado capaces de capturar relaciones no lineales e interacciones complejas entre variables.

El desempeño de cada modelo fue evaluado mediante métricas ampliamente utilizadas en problemas de regresión, incluyendo el Coeficiente de Determinación (R^2), el Error Absoluto Medio (MAE) y la Raíz del Error Cuadrático Medio (RMSE). Estas métricas permitieron analizar tanto la capacidad explicativa de los modelos como la magnitud de los errores de predicción obtenidos sobre el conjunto de prueba.

Posteriormente, se seleccionó el modelo con mejor desempeño para profundizar su análisis e interpretación. Con el fin de comprender los factores que contribuyen a las predicciones generadas por el modelo, se aplicó la metodología SHAP (SHapley Additive exPlanations), la cual permite cuantificar la contribución individual de cada variable explicativa sobre el resultado estimado.

La utilización de técnicas de interpretabilidad permitió complementar el análisis predictivo con una perspectiva explicativa, identificando los factores con mayor influencia sobre la tasa de natalidad y proporcionando evidencia adicional para comprender las relaciones observadas entre las variables estudiadas. De esta forma, el modelo no sólo fue evaluado en función de su precisión predictiva, sino también respecto de su capacidad para aportar conocimiento útil para la toma de decisiones y el diseño de políticas públicas basadas en evidencia.

Los resultados obtenidos mediante la aplicación de esta metodología se presentan y analizan en el capítulo siguiente, donde se comparan los distintos modelos implementados, se identifica la alternativa de mejor desempeño y se examinan los principales determinantes de la natalidad mediante técnicas de interpretabilidad.

10 RESULTADOS

En este capítulo se describe la ejecución técnica del modelo predictivo, transitando desde la abstracción teórica hacia la implementación analítica. Utilizando como marco de trabajo la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining), se detalla el ciclo de vida del proyecto de ciencia de datos, el cual integra la comprensión de los fenómenos demográficos con el rigor del modelamiento estadístico y computacional.

El desarrollo aquí expuesto aborda la complejidad de la tasa de natalidad como una serie temporal influenciada por factores multivariantes, garantizando la transparencia en el tratamiento de los datos y la robustez en la selección de los algoritmos de aprendizaje automático.

El objetivo principal de esta sección es construir, validar y evaluar un modelo predictivo capaz de estimar la trayectoria de la tasa de natalidad con un alto grado de precisión. Para ello, se persiguen los siguientes objetivos:

- **Sistematizar la recolección de datos:** Consolidar una base de datos histórica robusta (1960-2023) proveniente de fuentes oficiales como el Banco Mundial e instituciones nacionales.
- **Identificar variables críticas:** Determinar, mediante análisis de correlación y feature importance, qué factores socioeconómicos tienen el mayor impacto predictivo sobre la natalidad.
- **Comparar arquitecturas de modelado:** Evaluar el desempeño de los modelos para determinar la técnica con menor error de generalización (RMSE y MAE).

10.1 Comprensión de los datos

En esta etapa se realiza una auditoría técnica de la fuente de información para garantizar que el modelo predictivo se sustente en datos íntegros y representativos de la realidad demográfica global.

10.1.1 Origen de los datos

La selección de la materia prima para este modelo predictivo no fue arbitraria, sino que responde a la necesidad de construir una solución con alta capacidad de generalización. A continuación, se justifica técnicamente el uso del repositorio de datos del Banco Mundial (World Bank Open Data).

Se optó por la base de datos del Banco Mundial debido a su posición como el estándar en indicadores de desarrollo global. El periodo de estudio abarca desde 1960 hasta 2023, lo que proporciona una profundidad histórica de 63 años. Esta extensión temporal es crítica para los modelos de Machine Learning, ya que permite capturar múltiples ciclos demográficos y transiciones económicas que fuentes de corto plazo omitirían.

A diferencia de los modelos demográficos tradicionales que suelen limitarse a un análisis nacional o regional, este proyecto se ha diseñado bajo un enfoque transversal. Los argumentos técnicos para esta decisión son:

- **Robustez del Modelo:** Al entrenar los algoritmos con datos de múltiples países con diferentes niveles de desarrollo (economías emergentes vs. desarrolladas), el modelo aprende patrones universales de comportamiento en la tasa de natalidad, reduciendo el sesgo de localidad.
- **Escalabilidad y Replicabilidad:** La arquitectura del modelo permite que sea aplicado a cualquier unidad geográfica con datos disponibles en el Banco Mundial. Esto garantiza que la herramienta predictiva sea

útil tanto para el diseño de políticas públicas en Chile como para proyecciones en otros contextos internacionales.

- **Riqueza Multivariable:** La base de datos permite integrar muchas variables internacionales. Para este modelo, se seleccionaron variables clave (PIB, escolaridad, mortalidad, empleo en agricultura, esperanza de vida, entre otros) que están estandarizadas bajo la misma metodología para todos los países, asegurando la interoperabilidad de los datos.

El conjunto de datos final se estructuró como una matriz de datos de panel (panel data), combinando dimensiones de corte transversal (países) y series de tiempo (años). Esta estructura es la más adecuada para identificar cómo los cambios en las variables socioeconómicas preceden o impactan las variaciones en la tasa de natalidad a nivel global.

10.1.2 Exploración inicial

Una vez consolidada la base de datos de panel (1960-2023), se procedió a realizar un análisis exploratorio con el objetivo de validar la integridad de la información y extraer los primeros insights demográficos que orientarán la selección de algoritmos.

El análisis incluye estadísticas descriptivas (promedios, valores mínimos y máximos) y gráficos como histogramas para conocer la distribución de la tasa de natalidad y las variables independientes.

Para el análisis de datos y preparación del modelo predictivo se realizó utilizando el lenguaje de programación Python en la plataforma Google Colab.

Diagnóstico de Calidad y Gestión de datos nulos (Missing Values)

La Matriz de Integridad y Completitud de Datos reveló una disponibilidad de datos asíncrona, un desafío típico en datos de desarrollo global:

- **Variables de alta densidad:** La Tasa_natalidad (target), Esperanza_vida, Mortalidad_bruta y Poblacion_total presentan una completitud superior al 99.1%, lo que asegura una base sólida para el entrenamiento.
- **Variables con brechas críticas:** El indicador de Educación_terciaria (UNESCO) presenta un 54.5% de valores faltantes, mientras que el Empleo_agricultura muestra un 55.6%.
- **Variable descartada:** Se identificó que el Gasto_hogares_educación presenta un 91.6% de nulos, por lo cual se determinó su potencial exclusión técnica para evitar introducir ruido excesivo en el modelo.

	Valores Nulos	Porcentaje (%)
Gasto_hogares	12868	91.61%
Empleo_agricultura	7814	55.63%
Educación_terciaria	7661	54.54%
Paridad_poder_compra	7386	52.58%
Inflación	5079	36.16%
PIB_per capita	2622	18.67%
Esperanza_vida	129	0.92%
Tasa_natalidad	126	0.90%
Mortalidad_bruta	125	0.89%
Poblacion_total	125	0.89%
Grupo_ingresos	0	0.00%
Nombre_pais	0	0.00%
Anio	0	0.00%
Codigo_pais	0	0.00%
Region	0	0.00%

Tabla: Matriz de Integridad y Completitud de Datos

Análisis de Distribución de la Natalidad

El histograma de la variable objetivo muestra una distribución multimodal. Se observa una concentración de frecuencia en tasas de natalidad bajas (países en etapas avanzadas de la transición) y una cola larga hacia la derecha que representa países con regímenes de alta fecundidad. Esta falta de normalidad justifica la desestimación de modelos lineales simples y valida el uso de algoritmos de Machine Learning no paramétricos como Random Forest y Gradient Boosting, entre otros.




Gráfico: Histograma Tasa Natalidad Global

Estadísticas descriptivas

Se realizó un análisis descriptivo de las variables clave para entender la distribución y variabilidad de los factores que inciden en la natalidad global.

- **Comportamiento de la variable objetivo (Tasa de Natalidad):**
 - Presenta una media histórica de 3,80 (con una mediana de 3,22). La diferencia entre la media y la mediana, sumado a una desviación estándar de 1,98, confirma un sesgo positivo en la distribución. Esto indica que, aunque la mayoría de los países han avanzado hacia tasas bajas, existe un grupo persistente de naciones con tasas significativamente altas (hasta un máximo de 8,86), lo que refuerza la necesidad de un modelo que capture comportamientos heterogéneos.
- **Dinámicas de salud y desarrollo (Esperanza de Vida y Mortalidad):**
 - **Esperanza de Vida:** Presenta un promedio global de 65,2 años, con una dispersión que va desde los 10,9 años hasta los 86,3 años. El hecho de que el 75% de los datos se sitúe sobre los 58 años indica un progreso global que correlaciona inversamente con la natalidad.
 - **Mortalidad Bruta:** Con una media de 10,26, esta variable muestra una estabilidad relativa, aunque con valores atípicos máximos que coinciden con periodos de alta volatilidad demográfica.
- **Factores Socioeconómicos y de Capital Humano:**
 - **PIB per cápita:** Es la variable con mayor disparidad, con una desviación estándar de USD18.474, lo que supera ampliamente a su media (USD 9.398). Esta brecha económica es un indicador de la desigualdad estructural que el modelo debe procesar al proyectar la natalidad en diferentes regiones.
 - **Educación Terciaria:** Muestra una media de participación del 26,6%. Sin embargo, su rango es extremadamente amplio (0% a 166%, considerando tasas brutas de escolarización), lo que sugiere que el acceso a la educación superior es un factor de diferenciación crítica entre los regímenes de natalidad de "ingreso alto" vs "ingreso bajo".
- **Entorno Macroeconómico (Inflación):**
 - La Inflación muestra una volatilidad extrema (media de 22,7% pero con máximos de hiperinflación). Para efectos del modelo predictivo, esta variable actúa como un indicador de estabilidad; periodos de alta inflación suelen correlacionar con una postergación en las decisiones de formación de familia y nacimientos.

La combinación de una media decreciente en la natalidad y una alta dispersión en el PIB y la Educación confirma que no existe un "país promedio". El modelo de Machine Learning, por lo tanto, no debe buscar una solución lineal única, sino que debe ser capaz de segmentar el impacto de estos predictores según el contexto de cada país, justificando el uso de algoritmos de ensamble como Random Forest.

Disparidad por niveles de ingreso

Mediante el uso de diagramas de caja (Boxplots), se confirmó que el Grupo_ingresos es un segmentador crítico:

- Los países de ingreso bajo muestran una mediana de natalidad significativamente superior y una dispersión extrema (varianza alta).

- Los países de ingreso alto muestran una convergencia hacia tasas bajas y estables. Esta heterocedasticidad confirma que el modelo debe incluir el nivel de ingresos como una variable categórica fundamental para lograr la transversalidad buscada.




Gráfico: Boxplots Tasa Natalidad por Grupo de Ingresos

Matriz de Correlación y Selección de Predictores

Se calculó la Matriz de Correlación de Pearson para las variables numéricas. Los hallazgos principales son:

- **Esperanza de Vida ($r = -0.85$):** Es el predictor con mayor peso negativo; mejoras en salud pública son el principal precursor de la caída de la natalidad.
- **Educación Terciaria ($r = -0.66$):** Confirma la teoría de que el aumento del capital humano femenino posterga la maternidad.
- **Empleo en Agricultura ($r = 0.72$):** Refleja que la transición de sociedades rurales a industriales es un motor directo de la reducción de nacimientos.




Gráfico: Matriz de Correlaciones

10.2 Preparación de los datos

Esta fase detalla las transformaciones aplicadas al conjunto de datos para convertir la información bruta en un insumo apto para algoritmos de aprendizaje supervisado. El proceso se centró en la limpieza de registros incompletos y la creación de nuevas dimensiones de análisis.

10.2.1 Selección de variables

El dataset evolucionó de 15 variables originales a 16 variables finales, aplicando criterios de relevancia teórica y técnica:

- **Variables Eliminadas:** Se descartaron Poblacion_total y Paridad_poder_compra. La primera presentaba baja varianza explicativa para un modelo per cápita, y la segunda una nula correlación con la variable objetivo.
- **Creación de Nuevos Predictores:** Para enriquecer el análisis transversal, se integraron:
 - o **PPP_relativa:** calculada como el cociente entre la Paridad de Poder de Compra y el Tipo de Cambio de mercado. Esta variable permite capturar la asequibilidad relativa de la vida en cada país. Su relevancia para el modelo reside en que actúa como un proxy del costo real de crianza; en entornos donde el nivel de precios es elevado respecto al estándar internacional, se observa una presión económica que incentiva la reducción del tamaño familiar, mejorando así la capacidad predictiva del modelo en análisis transversales.
 - o **Dimensiones Geográficas (Región y Continente):** Variables categóricas añadidas para capturar sesgos culturales y geográficos que la economía por sí sola no explica.

10.2.2 Limpieza de datos

Para asegurar la estabilidad de los modelos (como Random Forest o Gradient Boosting), se aplicó un filtrado de casos completos:

- **Resultados del filtrado:** El volumen de datos pasó de 14.047 a 923 registros. Se eliminó el 93% de los datos originales por la presencia de valores nulos en varias variables de muchos países.
- **Justificación:** Aunque la reducción es significativa, se garantiza que cada observación cuenta con el 100% de la información en los 16 campos. Esto elimina la necesidad de técnicas de imputación (como promedios o modas) que podrían introducir sesgos artificiales en la predicción de la natalidad.

10.2.3 Análisis de representatividad y sesgo de selección:

Al comparar el dataset original con el final, se identifican cambios estructurales que deben considerarse al interpretar el modelo:

- **Perfil Socioeconómico:** El dataset final está sesgado hacia economías con sistemas de reporte más robustos. Los países de Ingreso Alto pasaron de representar el 39% de la muestra original al 61% en la muestra final.
- **Dinámica de la Natalidad:** La media de la Tasa_natalidad descendió de 3.80 a 2.11. Esto indica que el modelo final es un especialista en predecir la natalidad en contextos de post-transición demográfica (países que ya han iniciado el descenso de la natalidad).

10.2.4 Transformación y escalamiento:

Para mejorar la capacidad de aprendizaje del modelo y reducir el impacto de los valores atípicos (outliers), se aplicaron transformaciones matemáticas específicas a las variables con distribuciones sesgadas:

- **Transformación Logarítmica $\log(x)$:** Se aplicó el logaritmo natural a las variables con alta dispersión para normalizar sus escalas y linealizar relaciones complejas. Las variables transformadas fueron:
 - o $\log_Tasa_natalidad$ (Variable Objetivo)
 - o $\log_Empleo_agricultura$
 - o $\log_Gasto_hogares_educación$
 - o $\log_PIB_percapita$
- **Tratamiento de la Inflación:** Debido a que la inflación puede presentar valores negativos o cero, se utilizó la transformación $\log_abs_Inflación$ (logaritmo del valor absoluto), permitiendo capturar la magnitud del fenómeno macroeconómico sin errores matemáticos.

En cuanto al escalamiento, en lugar de un escalamiento lineal tradicional, se aplicó una **estabilización de varianza mediante transformaciones logarítmicas**. Este procedimiento permitió homogeneizar las magnitudes de predictores heterogéneos (como el PIB y la Educación), asegurando que el modelo de Machine Learning capture las elasticidades y relaciones proporcionales entre las variables, mitigando el dominio artificial de las variables con mayores valores nominales. La fundamentación técnica es la siguiente:

- **Reducción del Sesgo de Magnitud:** Variables con valores nominales muy altos y distribuciones asimétricas, como el PIB_per capita y el Empleo_agricultura, fueron transformadas mediante el logaritmo natural. Esta transformación comprime la escala de los datos. Por ejemplo, la diferencia entre un PIB de 1.000 y 10.000 es enorme en términos absolutos, pero en escala logarítmica se reduce

a una diferencia de 2.3 unidades. Esto permite que el modelo trate las variaciones porcentuales y no los valores brutos.

- **Equidad en el Peso de los Predictores:** Al transformar la variable objetivo ($\log_Tasa_natalidad$) y los predictores principales a una escala logarítmica, se logra que casi todas las variables operen en rangos numéricos similares (generalmente entre 0 y 12). El fundamento, es que al acercar los rangos de las variables (por ejemplo, haciendo que el PIB ya no sea 10.000 veces más grande que la Educación Terciaria), se fuerza por ejemplo al algoritmo de Random Forest que no priorice una variable simplemente por su magnitud numérica, sino por su capacidad explicativa.
- **Tratamiento de la Inflación:** Se aplicó logaritmo al valor absoluto de la inflación para mantener la variable en una escala comparable a las demás sin perder los registros que tienen valores de inflación negativos (deflación) o muy cercanos a cero.

10.3 Modelamiento

En esta etapa, se aplican algoritmos de Machine Learning para identificar patrones en los datos y construir una función matemática que prediga la tasa de natalidad usando variables socioeconómicas. Se evaluaron cuatro enfoques para determinar cuál explica mejor la variabilidad global.

10.3.1 Definición de modelos implementados:

Con el objetivo de garantizar la robustez de las predicciones y minimizar el riesgo de sesgos algorítmicos, se seleccionaron cuatro modelos de regresión que abarcan el espectro fundamental del aprendizaje supervisado. Esta selección transita desde la estadística paramétrica clásica y los métodos de regularización ideales para la interpretabilidad y el control de la colinealidad hasta los algoritmos avanzados de ensamble y potenciación, los cuales permiten capturar relaciones no lineales complejas que los modelos tradicionales suelen omitir:

- **Regresión Lineal Múltiple (OLS):** Actúa como el modelo base (baseline). Permite validar la significancia estadística de cada predictor y establecer una referencia de interpretabilidad directa a través de coeficientes.
- **Regresión Ridge:** Se incluyó para gestionar la multicolinealidad detectada en la fase de comprensión de datos (especialmente entre el PIB y la Esperanza de Vida). Aplica una penalización que evita que los coeficientes crezcan desproporcionadamente, aportando estabilidad al modelo.
- **Random Forest Regressor:** Construye múltiples árboles de decisión de forma independiente y promedia sus resultados. Es ideal para capturar interacciones no lineales y segmentar la muestra de forma automática.
- **Gradient Boosting Regressor:** A diferencia del anterior, este modelo utiliza la técnica de potenciación (boosting). Construye árboles de forma secuencial, donde cada nuevo árbol intenta corregir los errores residuales del anterior. Es conocido por ser uno de los algoritmos más potentes en términos de precisión predictiva pura.

10.3.2 Estrategia de Validación y Partición de Datos:

Para garantizar la validez externa de los resultados, se aplicó un criterio de partición basado en identificadores de país en lugar de registros individuales. Se reservó un 70% de los países para el entrenamiento y un 30% para la validación (test). Esta metodología asegura que el modelo sea capaz de generalizar su aprendizaje a

países que no estuvieron presentes durante el entrenamiento, simulando un escenario real de predicción demográfica internacional.

10.4 Evaluación

La evaluación se realizó comparando las métricas de rendimiento en los conjuntos de entrenamiento y prueba, utilizando el Coeficiente de Determinación (R^2) y el Error Absoluto Medio (MAE).

10.4.1 Comparación de desempeño

Tras la ejecución del experimento, se obtuvieron los resultados detallados en la tabla adjunta. Es imperativo notar que el rendimiento se mide sobre la variable objetivo transformada ($\log_Tasa_natalidad$).

=== COMPARATIVA DE DESEMPEÑO DE MODELOS ===					
	Modelo	R2 Train	R2 Test (Precisión)	MAE Test (Error)	
3	Gradient Boosting	0.974466	0.903418	0.083908	
2	Random Forest	0.994384	0.897092	0.087204	
1	Ridge	0.734609	0.839236	0.115673	
0	Regresión Lineal	0.734695	0.835883	0.116735	

Tabla: Desempeño comparativo de los modelos evaluados

10.4.2 Análisis de la capacidad predictiva

El modelo Gradient Boosting se identificó como el algoritmo superior para este estudio, alcanzando una precisión del 90.3% en el conjunto de prueba. Si bien el Random Forest mostró un rendimiento excepcional en el entrenamiento (0.994), el Gradient Boosting demostró una mayor estabilidad al enfrentarse a países nuevos, presentando el menor error promedio (MAE = 0.084).

Asimismo, se observa que los modelos lineales (OLS y Ridge) presentan un desempeño notablemente alto (83.9%), lo cual valida que la selección de predictores y las transformaciones logarítmicas previas lograron linealizar gran parte de la relación entre el desarrollo socioeconómico y la natalidad.

10.4.3 Interpretación mediante valores SHAP

Para determinar la influencia individual de cada variable socioeconómica sobre la tasa de natalidad, se implementó el uso de SHAP Values. Esta técnica permite descomponer la predicción de un modelo complejo para cuantificar cuánto contribuye cada predictor al valor final estimado, garantizando una distribución equitativa y matemáticamente sólida de la importancia de las variables.

A través de esta metodología, se identificaron patrones estructurales clave:

- **Impacto Negativo:** Se observó de forma consistente que niveles altos de **Esperanza de Vida y Educación Terciaria** desplazan los valores SHAP hacia la izquierda, lo que se traduce en una reducción significativa de la tasa de natalidad.
- **Impacto Positivo:** Inversamente, valores elevados en el **Empleo en la Agricultura** mostraron una relación directa con el incremento en la variable objetivo, situando los puntos en la zona de impacto positivo del gráfico.

- **Neutralidad y Dispersión:** Variables como **la Inflación** presentaron una distribución más concentrada cerca del centro, sugiriendo un impacto marginal o más volátil en comparación con los indicadores estructurales de desarrollo.




Gráfico: SHAP Values

Este análisis permite concluir que el modelo no solo es preciso numéricamente, sino que sus predicciones son coherentes con las teorías de transición demográfica.

11 CONCLUSIONES

La presente investigación tuvo como propósito desarrollar y evaluar un modelo predictivo de la tasa de natalidad utilizando variables sociodemográficas y económicas de alcance internacional. Los resultados obtenidos permiten extraer las siguientes conclusiones:

- **Desempeño predictivo de los modelos evaluados**

La comparación entre los modelos implementados evidenció que los algoritmos de aprendizaje supervisado basados en técnicas de ensamble presentaron un mejor desempeño predictivo que los modelos lineales tradicionales dentro del conjunto de datos analizado. En particular, el modelo Gradient Boosting alcanzó un Coeficiente de Determinación (R^2) de 0.903 y un Error Absoluto Medio (MAE) de 0.084 sobre el conjunto de prueba, constituyéndose como la alternativa de mejor desempeño entre las técnicas evaluadas. Estos resultados sugieren una elevada capacidad para estimar la tasa de natalidad en países no observados durante el entrenamiento, bajo las condiciones y alcance de la presente investigación.

- **Determinantes de la natalidad y evidencia empírica**

El análisis de interpretabilidad mediante SHAP permitió identificar a la esperanza de vida, la educación terciaria y el empleo agrícola como las variables con mayor influencia sobre las predicciones del modelo. Estos hallazgos son consistentes con la teoría de la transición demográfica, que plantea que el desarrollo humano, la mejora de las condiciones de salud y el aumento del nivel educativo se asocian con reducciones sostenidas en la fecundidad. Los resultados obtenidos sugieren que las transformaciones estructurales vinculadas al desarrollo económico y social desempeñan un papel relevante en la evolución de la natalidad.

- **Contribución metodológica**

La investigación demuestra la utilidad de combinar modelos predictivos de alto desempeño con técnicas de interpretabilidad para abordar fenómenos demográficos complejos. La incorporación de SHAP permitió complementar la capacidad predictiva de los algoritmos con una explicación transparente de los factores que influyen en los resultados, fortaleciendo el potencial de estas herramientas para apoyar procesos de análisis y toma de decisiones basadas en evidencia.

- **Implicancias y limitaciones del estudio**

Los resultados obtenidos muestran que las técnicas de aprendizaje supervisado constituyen una alternativa prometedora para apoyar el análisis de la natalidad a nivel internacional. No obstante, las conclusiones deben interpretarse considerando las características de la muestra utilizada. El proceso de selección de casos completos redujo significativamente el número de observaciones disponibles y generó una mayor representación de países con sistemas estadísticos más consolidados. En consecuencia, los resultados reflejan principalmente los patrones observados en los países incluidos en el análisis y constituyen evidencia relevante dentro del alcance definido para esta investigación.

- **Proyección futura**

Futuras investigaciones podrían ampliar la cobertura de países y variables disponibles, incorporar nuevas fuentes de información y evaluar metodologías adicionales para fortalecer la capacidad de generalización de los modelos predictivos. Asimismo, resulta de interés profundizar en el análisis de factores institucionales, culturales y territoriales que puedan complementar la explicación de las diferencias observadas en la natalidad entre países.

12 BIBLIOGRAFIA

- Alemayehu, M. A., Ejigu, A. G., Mekonen, H., Teym, A., Temesegen, A., Bayeh, G. M., et al. (2025). Forecasting birth trends in Ethiopia using time-series and machine-learning models: a secondary data analysis of EDHS surveys (2000–2019). *BMJ Open*, 15(e101006). <https://doi.org/10.1136/bmjopen-2025-101006>
- Barnett-Itzhaki, Z., Elbaz, M., Buttermann, R., Amar, D., Amitay, M., Racowsky, C., et al. (2020). Machine learning vs. classic statistics for the prediction of IVF outcomes. *Journal of Assisted Reproduction and Genetics*, 37(10), 2405–2412. <https://doi.org/10.1007/s10815-020-01908-1>
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- Goldscheider, F., Bernhardt, E., & Lappegård, T. (2015). The gender revolution: A framework for understanding changing family and demographic behavior. *Population and Development Review*, 41(2), 207–239.
- Huang, S., Huang, Y., Bao, S., Wang, J., & Chen, S. (2025). Simulation and prediction of rural population changes using agent-based modeling. *PLOS One*, 20(6), e0324563. <https://doi.org/10.1371/journal.pone.0324563>
- Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: Principles and Practice* (2nd ed.). OTexts. <https://otexts.com/fpp2/>
- Instituto Nacional de Estadísticas (INE). (2025). *Evolución de la Fecundidad en Chile: Informe de Estadísticas Vitales*. Santiago, Chile.
- Kelleher, J. D., & Tierney, B. (2020). *Ciencia de Datos*. Serie de conocimientos esenciales de MIT Press.
- Kim, W. (2024). *Baby Bonus, Fertility, and Missing Women*. CESifo Working Paper No. 11215. Ifo Institute. <https://hdl.handle.net/10419/301341>
- Largo Quintero, L. V., & Valencia Cadena, S. (2024). *Análisis de reducción de tasas de natalidad en Colombia: un enfoque con técnicas de aprendizaje automático* [Trabajo de especialización]. Universidad de Antioquia.
- Larrañaga, O. (2007). *Tendencias de la fertilidad en Chile 1960-2003*. Universidad de Chile.
- Maldonado, S., & Vairetti, C. (2022). *Analytics y Big Data: Ciencia de los datos aplicado al mundo de los negocios*. RIL editores.
- Montgomery, D. C., Peck, E. A., & Vining, G. G. (2012). *Introduction to Linear Regression Analysis* (5th ed.). Wiley.
- Ordóñez-Erazo, H. A., Ordóñez, C., & Bucheli-Guerrero, V. A. (2022). Predicción de factores clave en el aumento de la demografía en Colombia a través del ensamble de modelos de Machine Learning. *Revista Científica*, 44(2), 282-295. <https://doi.org/10.14483/23448350.19205>

Quintero López, J., Hernández Barajas, F., & Saavedra Coneo, Y. A. (2022). *Modelos alternativos para predecir la tasa de natalidad en función de los factores ambientales y socioeconómicos de un país.* Universidad Nacional de Colombia.

Sani, J., Halane, S., Ahmed, A. M., & Ahmed, M. M. (2025). Application of machine learning algorithms and SHAP explanations to predict fertility preference among reproductive women in Somalia. *Scientific Reports*. <https://doi.org/10.1038/s41598-025-85695-8>

Tadese, Z. B., et al. (2025). Exploring machine learning algorithms for predicting fertility preferences among reproductive age women in Nigeria. *Frontiers in Digital Health*, 6(1495382). <https://doi.org/10.3389/fdgth.2024.1495382>

Van de Kaa, D. J. (1987). Europe's second demographic transition. *Population Bulletin*, 42(1), 1–57.

Winkler-Dworak, M., Zeman, K., & Sobotka, T. (2024). Birth rate decline in the later phase of the COVID-19 pandemic: the role of policy interventions and economic uncertainty. *Human Reproduction Open*, 2024(3), hoae052. <https://doi.org/10.1093/hropen/hoae052>

13 ANEXOS

13.1 Estadísticas descriptivas

Estadísticas Descriptivas para las variables numéricas seleccionadas:

	Educación_terciaria	Empleo_agricultura	Esperanza_vida	Gasto_hogares	Inflación	Mortalidad_bruta	PIB_percapita	Paridad_poder_compra	Poblacion_total	Tasa_natalidad
count	6386.000000	6233.000000	13918.000000	1179.000000	8968.000000	13922.000000	11425.000000	6.661000e+03	1.392200e+04	13921.000000
mean	26.661553	27.964432	65.238145	1.130524	22.723355	10.261670	9398.146861	2.262775e+02	5.016205e+07	3.801218
std	25.429315	23.600441	11.224617	1.004863	319.359165	5.662929	18474.461619	1.814291e+03	3.959916e+08	1.984530
min	0.000000	0.090952	10.989000	0.000000	-17.640424	0.841000	11.801322	7.335387e-10	2.715000e+03	0.586000
25%	5.700308	6.440072	58.461561	0.428370	2.148832	6.732250	601.578590	8.367170e-01	5.247360e+05	2.020000
50%	18.692953	21.607121	67.912134	0.880220	4.801643	8.935500	2161.639646	2.506261e+00	4.346712e+06	3.227000
75%	41.553859	44.989385	73.375000	1.511338	10.022658	12.101500	9197.701063	4.082081e+01	1.440385e+07	5.650000
max	166.665649	92.482459	86.372000	9.200000	23773.131774	153.963000	256580.515123	8.939181e+04	8.061876e+09	8.864000

13.2 Distribuciones variables predictoras originales (con ruido)

