



“PREDICTIVE ANALYTICS: FORECAST MULTI ESCENARIO DEL PIPELINE COMERCIAL CON MACHINE LEARNING & XAI”

**TESIS PARA OPTAR AL GRADO DE MAGÍSTER EN ANALÍTICA DE
NEGOCIOS**

**Estudiante: Bastian Celedón Aguirre
Profesor Guía: David Díaz Solís**

Santiago, Agosto 2026

Dedicatoria

Dedico este trabajo a quienes han sostenido mi camino, tanto a quienes hoy comparten conmigo este logro como a quienes continúan presentes a través de su recuerdo, su ejemplo y la huella que dejaron en mi vida.

A Valeska Muñoz, mi novia, por tu amor y apoyo incondicional, por ser mi calma y mi motivación constante. Gracias por acompañarme en los momentos de mayor dificultad y exigencia, por confiar en mí incluso cuando el cansancio hacía más difícil continuar y por recordarme que los grandes procesos también se sostienen con cariño, paciencia y amor.

A mi familia, raíz de todo lo que soy. A mis padres, Marco Celedón Contreras y Pamela Aguirre Velásquez, a mis hermanos, Carolina, Felipe y Katerina, y a mi sobrina, Ámbar, por entregarme los valores, la fortaleza y la convicción necesarios para perseguir mis objetivos con responsabilidad y perseverancia.

A la familia de Valeska, que también se ha convertido en mi familia y me ha hecho sentir en casa en el lugar que sueño como mi futuro hogar: la amada Patagonia, en Porvenir, Tierra del Fuego, Región de Magallanes y de la Antártica Chilena. A mi cuñado Milan Martić, por inspirarme a mejorar desde la inocencia y el cariño que compartes, eres como un hijo para mí. A mi suegra, Marly Muñoz, por su apoyo incondicional, sus palabras de inspiración y su permanente motivación para ser mejor. A tía Sarita, por hacerme sentir en casa con su inmenso cariño, a la Nena, porque sin sus abrazos nada sería igual, al Tata, por ser un ejemplo de perseverancia frente a la adversidad, a tío Pato, por su alegría y por aceptarme tal como soy, y a Ricardo, por sus palabras de apoyo y prosperidad, además de tantos viajes inolvidables.

A mi tía y madrina Carmen Aguirre, por cuidarme siempre y desearme lo mejor, a mi tía Claudia Aguirre, por esas palabras de aliento que enseñan que el esfuerzo termina dando frutos, y a mis primos hermanos, Claudio Contreras y Gonzalo Contreras, porque crecimos juntos, compartimos los mismos valores y hoy hemos alcanzado muchas de aquellas metas que imaginábamos cuando éramos niños.

A mis mejores amigos, Christian Salvo, Guido Mödinger, Natalia Contreras, Daniela Rodríguez Rivas, Fabián Claverie, Marcelo Guzmán, Fernanda Covarrubias, Vanessa Giraudo, Javier Fontt, Omar Urbina, Nery Venegas y Patricia Castro, por estar presentes de manera genuina, escucharme, acompañarme y celebrar cada avance. Gracias por ser parte de mi vida y por hacer que este camino nunca se sintiera solitario.

De manera muy especial, dedico este logro a la memoria de mi abuela, Carmela Velásquez Valencia, y de mi tío, Alejandro del Carmen Celedón Contreras. Aunque ya no estén físicamente entre nosotros, su recuerdo permanece vivo en mi historia y en la persona que he llegado a ser. Su ejemplo dejó una huella profunda y me enseñó a enfrentar las dificultades con perseverancia, fortaleza y estoicismo. Este logro también les pertenece, porque su legado continúa acompañándome y motivándome a seguir adelante.

A todos ustedes, gracias por el amor, la confianza y la compañía entregados en cada etapa de este proceso. Esta tesis no representa únicamente un resultado académico, sino también una expresión de todo lo que he recibido de quienes han caminado junto a mí y de quienes, aún desde la distancia o el recuerdo, me han dado la convicción necesaria para perseguir mis metas, objetivos y sueños.

Agradecimientos

Agradezco con especial aprecio a mis compañeros de la 1ra generación de este Magíster y, particularmente, a Claudia Torres, Felipe del Río, Pablo Quintanilla, Nicolás Ceroni, Jorge Gutiérrez, Diego Acevedo y Simón Lagos, entre otros. Compartir este postgrado significó recorrer un camino de esfuerzo, aprendizaje, trabajo colaborativo y también de muchas risas. El compromiso y la entrega que mantuvimos, especialmente durante la exigente etapa final, nos permitieron superar las dificultades y cerrar este proceso con la misma convicción con la que lo iniciamos.

Expreso también mi profundo agradecimiento al profesor David Díaz Solís, por su apoyo y orientación desde una perspectiva profesional, crítica y enfocada en generar impacto real en el negocio. Sus reflexiones sobre la incorporación responsable y objetiva de la Inteligencia Artificial Generativa en entornos laborales de alto valor enriquecieron de manera significativa el desarrollo de esta tesis. Agradezco, además, la confianza depositada en mí al invitarme a participar como expositor en una charla desde la perspectiva interna en grandes empresas utilizando IA como driver de Innovación y también al permitirme colaborar como profesor ayudante en distintas instancias académicas. Sus consejos y enseñanzas fueron fundamentales para integrar esta tecnología con mayor profundidad y sentido práctico en la investigación.

Agradezco a Paulo Valenzuela, mi líder directo, por impulsarme constantemente a mejorar y por brindarme la oportunidad de crecer y desarrollarme profesionalmente. Su confianza me ha permitido aplicar los conocimientos adquiridos, asumir nuevos desafíos y procurar que cada aprendizaje se traduzca en un aporte concreto, responsable y de valor para la organización.

A mi equipo de trabajo, tanto a quienes continúan compartiendo este camino como a quienes han emprendido nuevas etapas en sus trayectorias profesionales: Fabián Claverie, Marcelo Guzmán, Fernanda Covarrubias, Sorciret Lucena, Vanessa Giraudo, Javier Fontt, Cintamani Herrera, Andrea Jaña y Samuel Venegas. Gracias por su compañerismo, confianza y entusiasmo, por alentarme a seguir mejorando y por hacer de cada desafío compartido una oportunidad de aprendizaje. Ha sido un privilegio trabajar y crecer junto a ustedes.

Finalmente, agradezco a todas las personas que formaron parte de este proceso y que, mediante sus observaciones, críticas constructivas, apoyo y palabras de aliento, contribuyeron a fortalecer tanto este trabajo como mi desarrollo personal y profesional. Cada consejo, conversación y muestra de confianza dejó un aprendizaje valioso. Todos ustedes forman parte de este logro y permanecerán como una fuente de inspiración para continuar creciendo y enfrentando nuevos desafíos.

Tabla de Contenidos

1. Resumen Ejecutivo.....	7
2. Introducción	8
3. Planteamiento y Formulación del Problema	12
4. Hipótesis y Preguntas de Investigación	15
5. Objetivos.....	16
6. Marco Teórico.....	17
7. Revisión Bibliográfica y Estado del Arte	30
8. Metodología	33
9. Descripción del Enfoque de Solución	51
10. Resultados.....	53
11. Impacto de Negocio y Ecosistema Analítico Comercial.....	87
12. Discusión de Resultados	91
13. Conclusiones y Recomendaciones.....	93
14. Trabajo Futuro: Extensión Prescriptiva y Forecast Decision Agent	97
Bibliografía.....	100
Anexos.....	102

Índice de Ilustraciones

Ilustración 1. Progresión metodológica desde referencias simples hasta decisión explicable.	10
Ilustración 2. Progresión analítica y criterio de complejidad incremental.	11
Ilustración 3. Serie semanal de cierres ganados y concentración en semanas de cierre.	34
Ilustración 4. Ingresos de cierres ganados agregados por trimestre.	35
Ilustración 5. Perfil de cierres por fase del trimestre.	36
Ilustración 6. Nivel y variabilidad móvil de los cierres semanales.	38
Ilustración 7. Dependencia temporal y rezagos relevantes de la serie transformada.	38
Ilustración 8. Descomposición STL de la serie transformada con periodicidad trimestral.	39
Ilustración 9. Esquema de validación temporal mediante origen móvil.	42
Ilustración 11. Desempeño típico y riesgo extremo en la progresión de modelos clásicos.	55
Ilustración 12. Desempeño de Prophet en validación de origen móvil.	57
Ilustración 13. Aporte incremental de los componentes de Prophet.	57
Ilustración 14. Dispersión del desempeño de Temporal Fusion Transformer entre semillas.	58
Ilustración 15. Comparación del riesgo extremo de Chronos-2 y referencias.	59
Ilustración 16. Complementariedad por fase de Chronos-2 frente a otros modelos.	59
Ilustración 17. WAPE por ventana de modelos de Gradient Boosting y referencias.	60
Ilustración 18. Comparación final entre desempeño típico y riesgo extremo de todas las familias.	61
Ilustración 19. Panel completo de WAPE mediano y techo observado.	62
Ilustración 20. Detalle de los modelos con desempeño operacional competitivo.	63
Ilustración 21. Mapa comparativo de métricas para el panel final.	65
Ilustración 22. Síntesis multicriterio de los cinco modelos mejor posicionados.	66
Ilustración 23. Conjunto de confianza de modelos bajo bootstrap estacionario.	67
Ilustración 24. Importancia global SHAP del modelo CatBoost fuera de muestra.	68
Ilustración 25. Distribución de efectos SHAP y dirección de las contribuciones.	69
Ilustración 26. Concordancia de rankings de variables entre CatBoost y XGBoost.	70
Ilustración 27. Importancia normalizada de variables en CatBoost y XGBoost.	71
Ilustración 28. Participación SHAP por familia de variables.	72
Ilustración 29. Estabilidad de drivers CatBoost entre ventanas.	73
Ilustración 30. Explicación local de CatBoost para una semana de cierre de Q1/2026.	74
Ilustración 31. Drivers que explican la principal mejora de CatBoost frente a XGBoost.	75
Ilustración 32. Interacciones estructurales principales estimadas para CatBoost.	76
Ilustración 33. Complementariedad entre modelos en semanas ordinarias y semanas de cierre.	77
Ilustración 34. Relación entre cobertura fuera de muestra y amplitud de las bandas.	78
Ilustración 35. Sensibilidades de escenario para SARIMAX en Q2/2026.	79
Ilustración 36. Sensibilidades de escenario para CatBoost en Q2/2026.	80
Ilustración 37. Sensibilidades de escenario para la señal Committed en Q2/2026.	81
Ilustración 38. Bandas empíricas de error por fase del trimestre.	82
Ilustración 39. Trayectoria acumulada de sensibilidades SARIMAX durante Q2/2026.	83
Ilustración 40. Cobertura rolling de sensibilidades por ventana.	83
Ilustración 41. Ingresos reales y pronósticos agregados para Q2/2026.	84
Ilustración 42. Error semanal acumulado y brecha neta trimestral.	86
Ilustración 43. Reducción histórica de error absoluto frente a Committed.	87
Ilustración 44. Sensibilidad ilustrativa del error de forecast potencialmente reducido.	88
Ilustración 45. Ecosistema analítico comercial y conexión con el forecast de ingresos.	89
Ilustración 47. Arquitectura conceptual resumida del Forecast Decision Agent.	98
Ilustración 48. Semáforo de monitoreo para forecast, sesgo, divergencia y calidad de datos.	99
Ilustración 49. Desempeño durante el trimestre de catorce semanas.	103
Ilustración 50. Complementariedad del modelo Prophet por fase.	103
Ilustración 51. Complementariedad de Temporal Fusion Transformer por fase.	104
Ilustración 52. Estabilidad entre ventanas de Chronos-2.	104
Ilustración 53. Síntesis de afirmaciones sostenibles para Chronos-2.	105
Ilustración 54. Riesgo extremo de modelos de Gradient Boosting.	105
Ilustración 55. Desviación entre ventanas de modelos de Gradient Boosting.	106
Ilustración 56. Síntesis de evidencia XAI de CatBoost.	106

Índice de Cuadros

Cuadro 1. Reglas de calidad y riesgos metodológicos controlados.....	14
Cuadro 2. Síntesis de la revisión bibliográfica y su traducción metodológica.....	32
Cuadro 3. Variables principales, disponibilidad y función dentro del estudio.....	33
Cuadro 4. Diagnósticos de estacionariedad para transformaciones de la serie.....	40
Cuadro 5. Panel principal de ventanas temporales de evaluación.....	42
Cuadro 6. Familias de modelos y función dentro del estudio.....	44
Cuadro 7. Métricas de evaluación y su interpretación.....	45
Cuadro 8. Rúbrica de factibilidad por perfil de decisión.....	50
Cuadro 9. Comparación de la progresión clásica en el panel principal.....	56
Cuadro 10. Comparación cuantitativa final bajo un protocolo común.....	64
Cuadro 11. Evidencia inferencial clave y alcance de las conclusiones.....	67
Cuadro 12. Resultados descriptivos de Q2/2026.....	85
Cuadro 13. Marco propuesto para medir crecimiento y valor comercial.....	89
Cuadro 14. Complementariedad funcional del ecosistema analítico.....	90

1. Resumen Ejecutivo

Esta tesis desarrolla y evalúa una capacidad de forecasting semanal y multiescenario para el pipeline comercial de un Corporativo de Tecnologías de Información con foco en Negocios de Integración Tecnológica B2B. El estudio parte del análisis de la serie temporal de cierres ganados, caracteriza su concentración trimestral y compara la señal cualitativa *Committed* (Comprometido) con referencias ingenuas, modelos AR, MA, ARMA, ARIMA, ARIMAX, SARIMA y SARIMAX, además de Prophet, TFT, Chronos-2 y algoritmos de Machine Learning tabular explicados mediante SHAP Values.

La evaluación utiliza ventanas de origen móvil, métricas comunes de error, sesgo y estabilidad, y contrastes inferenciales que preservan la dependencia temporal. SARIMAX ex ante con variables de fase presenta el mejor equilibrio operacional: WAPE agrupado de 55,38%, techo de 67,74% y desviación de 8,55, frente a 74,30%, 102,24% y 22,70 del Committed, respectivamente, considerándose *champion*. En el panel histórico reduce 412,55 MM USD de exposición al error absoluto, mientras que en Q2/2026 reduce 156,70 MM USD de forma descriptiva. CatBoost alcanza la mejor mediana de WAPE, pero mantiene un riesgo extremo superior y se conserva como *challenger*. La recomendación final corresponde a una arquitectura *champion-challenger* con revisión humana, monitoreo de MegaDeals e integración futura con modelos comerciales complementarios para evolucionar desde Analítica Predictiva hacia un Forecast Decision Agent con Multi Context Protocol (MCP) para transformar resultados predictivos en recomendaciones prescriptivas para la toma de decisiones de Ejecutivos C-Levels.

Palabras clave: Analítica Predictiva, Forecasting Comercial B2B, Pipeline, CRM, Series de Tiempo, SARIMAX, Prophet, Temporal Fusion Transformer, Chronos-2, Machine Learning, XAI, SHAP Values.

2. Introducción

La gestión del pipeline comercial en una empresa de tecnologías de información con foco en B2B requiere anticipar el volumen y la oportunidad temporal de los cierres que pueden transformarse en ingresos. En organizaciones con ciclos de venta extensos, soluciones complejas y operaciones de alto monto, una diferencia de pocas semanas en la fecha esperada de cierre puede modificar la lectura trimestral, la asignación de capacidades de preventa, la planificación financiera y la priorización ejecutiva. Por esta razón, el forecast no puede entenderse únicamente como una cifra de cierre, sino como un sistema de apoyo a la toma de decisiones que debe informar cuánto podría cerrarse, en qué momento, con qué incertidumbre y bajo qué condiciones.

Desde la perspectiva de Analítica de Negocios, esta necesidad configura un problema de series de tiempo con consecuencias directas sobre decisiones de presupuesto, cobertura comercial, asignación de capacidades y seguimiento ejecutivo. La variable objetivo no sólo cambia entre trimestres, sino también dentro de cada trimestre. Las primeras semanas suelen registrar montos menores, mientras que la fase de cierre concentra operaciones de alto valor y una proporción elevada del error. Esta forma temporal impide tratar las observaciones como registros independientes y obliga a preservar el orden cronológico durante todo el diseño experimental.

El estudio se plantea, por lo tanto, como una investigación de Time Series Analysis aplicada al negocio. Antes de seleccionar algoritmos, se analiza la frecuencia semanal, la tendencia, la estacionalidad, la estacionariedad, la autocorrelación, los rezagos de 13 y 26 semanas, la variación por fase del trimestre y el efecto de operaciones extraordinarias. Esta caracterización permite distinguir qué parte del comportamiento puede explicarse por memoria temporal, qué parte requiere covariables del *Customer Relationship Management* (CRM) y qué parte debe permanecer bajo revisión humana.

El Corporativo de Tecnologías de Información gestiona su proceso comercial mediante un CRM que concentra oportunidades, montos, fechas estimadas, estados, unidades comerciales y señales de avance. El método vigente utiliza principalmente la clasificación *Committed* (del inglés y que significa “Comprometido”), construida a partir del criterio del ejecutivo responsable. Esta señal contiene información valiosa de negocio, pero no aprende de manera sistemática de sus errores históricos, no representa explícitamente la estacionalidad trimestral y no entrega una estimación cuantificada de su incertidumbre, por lo tanto, se considera meramente un criterio de decisión actual para el cálculo del Forecast del negocio, considerado entonces un Forecast del tipo Cualitativo.

La investigación adopta un enfoque progresivo. Inicialmente, la estrategia progresiva incorpora referencias simples que permiten establecer un nivel mínimo de desempeño antes de aumentar la complejidad del modelamiento. Se consideran la señal comercial *Committed*, el *Naive Mean*, que utiliza el promedio histórico como referencia, el *Naive Seasonal*, que reproduce el valor observado 13 semanas antes como aproximación de la periodicidad trimestral, y una referencia basada en media móvil, orientada a suavizar la variabilidad reciente. Estas alternativas no se incorporan únicamente como modelos elementales, sino como *benchmarks* necesarios para determinar si las técnicas posteriores aportan mejoras reales en precisión, estabilidad y control del riesgo. Sobre esta línea base se desarrolla posteriormente la progresión que permiten verificar si la complejidad adicional aporta valor real. Luego se incorporan los componentes autorregresivos, de medias móviles, diferenciación, estacionalidad y variables exógenas mediante *AutoRegressive* (AR), *Moving Average* (MA), *AutoRegressive Moving Average* (ARMA), *AutoRegressive Integrated Moving Average* (ARIMA), *AutoRegressive Integrated Moving Average with exogenous variables* (ARIMAX), *Seasonal AutoRegressive Integrated Moving Average* (SARIMA) y *Seasonal AutoRegressive Integrated Moving Average with exogenous variables* (SARIMAX). Posteriormente se contrastan modelos de mayor complejidad, entre ellos *Prophet*, *Temporal Fusion Transformer* (TFT) y *Chronos-2*, además de modelos supervisados tabulares como lo son *Elastic Net*, *Random Forest*, *HistGradientBoosting*, *XGBoost*, *LightGBM*, *CatBoost*, con variables rezagadas y señales del CRM.

La progresión no representa una enumeración de modelos, sino una secuencia de hipótesis analíticas. AR evalúa si el pasado inmediato del objetivo contiene memoria suficiente, MA examina la dependencia respecto de tendencias anteriores, ARMA combina ambos mecanismos, ARIMA incorpora diferenciación, ARIMAX añade información exógena, SARIMA introduce periodicidad trimestral, y SARIMAX integra estructura temporal, estacionalidad y señales comerciales disponibles ex ante. Sobre esa base se examina si arquitecturas más flexibles o preentrenadas generan una mejora material y estable.

El criterio de selección también responde a la naturaleza del negocio. Una mediana favorable puede coexistir con fallas severas en trimestres de mayor exposición. Por esa razón, el análisis compara el error central con el techo observado, la dispersión entre ventanas, el sesgo, el comportamiento en semanas ordinarias y de cierre, y la estabilidad de los drivers. Esta lectura evita promover un modelo únicamente porque obtiene el menor valor en una métrica agregada.

La comparación no se limita a elegir el menor error promedio. La tesis distingue desempeño típico, riesgo extremo, dispersión, sesgo, comportamiento en semanas de cierre, consistencia entre ventanas y factibilidad de implementación. Esta decisión metodológica responde a que el ingreso presenta alta concentración en pocas

oportunidades. Un modelo puede obtener una mediana favorable y, al mismo tiempo, fallar de forma severa precisamente en los trimestres que más afectan la planificación.

La explicabilidad se incorpora mediante *eXplainable Artificial Intelligence* (XAI) y *SHapley Additive exPlanations* (SHAP Values) para identificar la contribución de rezagos, variables del CRM y características temporales en los modelos tabulares. El propósito no es atribuir causalidad, sino comprender qué información utiliza el algoritmo, detectar dependencias inestables y traducir resultados técnicos a una lectura comprensible para la Gestión Comercial Corporativa.




Ilustración 1. Progresión metodológica desde referencias simples hasta decisión explicable.

Fuente: Elaboración propia.

Finalmente, el estudio conecta el forecasting con un ecosistema analítico más amplio. Los modelos de propensión de compra, fuga de Clientes, Upselling y Cross Selling, y reactivación de Clientes aportan señales a nivel de cuenta u oportunidad, mientras que el forecast consolida esas señales en una perspectiva temporal de ingresos. Esta integración se plantea como extensión estratégica, sin confundir los resultados efectivamente evaluados en esta tesis con capacidades complementarias que deberán validarse en su propio diseño experimental.

La estructura del documento sigue esta lógica: se formula el problema de decisión, se establecen hipótesis y objetivos, se desarrolla el marco teórico y una revisión bibliográfica separada, se describe el protocolo metodológico, se presentan resultados comparables para todas las familias y se concluye con el impacto de negocio, el ecosistema analítico y la extensión prescriptiva futura.



Ilustración 2. Progresión analítica y criterio de complejidad incremental.

Fuente: Elaboración propia.

La tesis mantiene un equilibrio entre comprensión técnica y aplicación de negocio. Los fundamentos estadísticos se desarrollan hasta el nivel necesario para interpretar el funcionamiento de cada familia, sus supuestos y sus limitaciones, mientras que la discusión se orienta a la decisión que el modelo puede apoyar. Las ecuaciones y métricas se presentan como instrumentos de interpretación y no como un fin aislado.

3. Planteamiento y Formulación del Problema

El problema central consiste en estimar semanalmente los ingresos comerciales que serán reconocidos como cierres ganados dentro de un horizonte trimestral. La decisión debe tomarse antes de observar el resultado, utilizando únicamente información disponible o reconstruida bajo una lógica *ex ante*. El sistema debe superar o complementar al Committed sin depender de información futura, y debe mantener una estabilidad suficiente para ser utilizado en un proceso corporativo recurrente.

La decisión posee dos dimensiones inseparables. La primera corresponde al nivel: cuánto ingreso se espera cerrar en el trimestre. La segunda corresponde a la calendarización: en qué semana se materializará ese cierre. Un pronóstico trimestral cercano al total real puede ocultar errores semanales elevados, mientras que una trayectoria semanal razonable puede terminar con una brecha trimestral reducida por compensación de sobreestimaciones y subestimaciones. La tesis evalúa ambos planos para evitar una interpretación parcial del desempeño.

La dificultad aumenta porque el pipeline comercial se gestiona con un foco B2B y no constituye una demanda masiva de baja variabilidad. Un número reducido de oportunidades concentra gran parte del ingreso y puede modificar de manera abrupta el total de una semana o de un trimestre con los llamados *MegaDeals*, negocios con monto sobre los USD\$20MM. Esta concentración genera colas pesadas, heterocedasticidad y sensibilidad a cambios de estado. En términos de negocio, una única operación puede superar el umbral de materialidad definido para el forecast y requerir una revisión separada del resultado agregado.

El desafío no es un problema de pronóstico regular. El 10% de las oportunidades concentra aproximadamente el 87,3% de los ingresos observados, lo que produce una distribución con colas pesadas y semanas de cierre dominadas por operaciones extraordinarias. En Q2/2026, dos oportunidades explican cerca de la mitad del trimestre y una sola operación representa aproximadamente 46% del ingreso. Esta concentración incrementa el *Root Mean Squared Error* (RMSE), altera el sesgo y puede invertir la evaluación de un modelo cuando se analiza un único trimestre.

El método Committed resume conocimiento del ejecutivo de ventas respecto de oportunidades que considera altamente probables. Su valor no se cuestiona como señal comercial. El problema se origina cuando esa señal se utiliza como forecast autónomo sin una medición sistemática de sus errores históricos, sin descomposición temporal y sin un mecanismo explícito para aprender de sesgos recurrentes. La solución propuesta conserva el juicio comercial, pero lo compara con modelos y registra sus divergencias, ya que el forecast actual al ser cualitativo, simplemente se pronostica bajo el Committed, pero siquiera existe una revisión del error con respecto a lo determinado previamente.

La formulación analítica exige además evitar fuga de información. Las variables del CRM cambian durante el ciclo comercial y el último estado disponible no siempre reproduce lo que se conocía en cada fecha histórica. Por este motivo, el estudio reconstruye covariables ex ante mediante emparejamiento por fase del trimestre anterior y distingue las variantes contemporáneas como análisis diagnóstico. Esta decisión limita la cantidad de información utilizable, pero aumenta la validez operacional del resultado.

La serie semanal también presenta una estructura trimestral irregular. La mayoría de los trimestres poseen 13 semanas bajo la regla de agregación utilizada, pero el Q3/2024 tiene catorce. Un rezago fijo de 13 semanas puede desplazar el patrón de cierre y asociar la semana final con una posición equivocada del trimestre anterior. Por ello, la fase relativa del trimestre debe modelarse de forma explícita y no únicamente mediante el número de semana calendario.

Existe además una tensión entre exactitud típica y riesgo ejecutivo. Las métricas basadas en monto, como *Weighted Absolute Percentage Error* (WAPE), entregan mayor peso a las semanas de alto ingreso, mientras que una pérdida logarítmica trata de manera más uniforme las semanas. Ninguna medida representa por sí sola todas las consecuencias del error. La solución requiere un conjunto de métricas y un protocolo de origen móvil que permita observar el comportamiento en múltiples trimestres.

El problema de negocio se formula de la siguiente manera: ¿puede un sistema cuantitativo de forecasting semanal mejorar de forma sostenible la capacidad del Committed para anticipar ingresos comerciales y, simultáneamente, entregar explicaciones, escenarios y criterios de control que permitan una adopción ejecutiva responsable?

La contribución esperada no consiste en sustituir el juicio comercial. El objetivo es separar tres funciones que actualmente se confunden: la señal cualitativa del ejecutivo, la estimación cuantitativa del modelo y la decisión final de gestión. Esta separación permite medir cada componente, registrar ajustes humanos y evaluar de forma posterior si las intervenciones generaron valor.

3.1. Alcance

El alcance considera datos comerciales anonimizados del periodo 2023 a Q2/2026, es decir, 3 años y medio de datos agregados a frecuencia semanal y evaluados sobre cierres ganados expresados en millones de dólares. Se incluyen modelos de series de tiempo, modelos avanzados y Machine Learning tabular. El impacto cuantificado corresponde a reducción de exposición al error de forecast. La generación de ingresos incrementales se define como resultado futuro que debe medirse de forma controlada.

3.2. Restricciones y Limitaciones Iniciales

El alcance se restringe a cierres ganados y a las reglas comerciales disponibles en el periodo analizado. No se intenta explicar causalmente por qué una oportunidad fue ganada ni estimar el efecto de una acción comercial específica. El objetivo es pronosticar y comparar, bajo un protocolo temporal común, la evolución agregada de ingresos.

La extracción presenta cobertura desigual entre variables. La taxonomía de producto alcanza completitud suficiente desde 2025, el Committed histórico corresponde al último estado disponible y la última semana de Q2/2026 contiene sólo dos días. Estas condiciones se incorporan como limitaciones explícitas y se excluyen de afirmaciones que requieran trazabilidad histórica completa.

Control	Aplicación	Riesgo Mitigado
Montos negativos	Eliminación de oportunidades con importes incompatibles con cierres válidos	Pronósticos negativos o distorsión del nivel
Duplicados	Revisión a nivel de oportunidad y líneas asociadas	Doble contabilización de ingresos
Fechas	Tipificación y normalización semanal por lunes	Desalineación entre trimestres y fases
Nulos críticos	Control por carga y exclusión cuando afecta variables ex ante	Sesgo por imputación no documentada
Disponibilidad ex ante	Emparejamiento por fase del trimestre anterior	Fuga de información futura
MegaDeals	Identificación por atributo identificador e impacto en pipeline	Dominancia de una operación sobre el forecast agregado

Cuadro 1. Reglas de calidad y riesgos metodológicos controlados.

Fuente: Elaboración propia.

Las principales restricciones son la corta historia temporal para modelos de alta capacidad, la concentración de MegaDeals, la disponibilidad desigual de atributos a lo largo del periodo, la utilización del último estado registrado del CRM como aproximación histórica y el corte parcial de la última semana de Q2/2026. Estas restricciones se incorporan en el análisis y limitan el alcance de las conclusiones.

4. Hipótesis y Preguntas de Investigación

4.1. Hipótesis General

Un sistema de forecasting semanal que combine estructura temporal, variables exógenas del CRM y evaluación de origen móvil puede reducir el error y el riesgo extremo del método cualitativo Committed, manteniendo una explicación suficiente para su uso en decisiones comerciales corporativas.

4.2. Hipótesis Específicas

H1. La incorporación progresiva de memoria, errores, diferenciación, estacionalidad y variables exógenas permite identificar qué componentes agregan valor y evita atribuir el resultado únicamente al modelo final.

H2. SARIMAX puede entregar un mejor equilibrio entre error típico, riesgo extremo y estabilidad que el Committed y que modelos de mayor complejidad cuando la muestra temporal es limitada y existen señales exógenas relevantes.

H3. Prophet, TFT y Chronos-2 pueden capturar estructuras adicionales, pero una mayor complejidad no garantiza superioridad si el tamaño de muestra, la concentración de ingresos y el horizonte reducen la capacidad de generalización.

H4. Los modelos tabulares complementan el análisis al capturar rezagos, relaciones no lineales y señales del CRM, mientras SHAP permite identificar sus principales variables explicativas sin atribuir causalidad.

H5. La mejora del forecast puede cuantificarse mediante la reducción del error de predicción, mientras que su contribución a cierres ganados e ingresos incrementales debe validarse prospectivamente mediante un grupo de comparación.

4.3. Preguntas de Investigación

¿Qué familia de modelos presenta el mejor equilibrio entre WAPE, sesgo, techo de error y dispersión?

¿Qué aporta cada transición desde AR y MA hasta SARIMAX?

¿Los modelos avanzados superan de manera consistente a los modelos estadísticos?

¿Qué variables explican las predicciones del mejor modelo de Machine Learning con datos tabulares?

¿Cuánto error económico se evita frente al Committed y cómo debe traducirse esa mejora a decisiones comerciales?

¿Cómo puede integrarse el forecast con otras capacidades analíticas y con una futura capa prescriptiva?

5. Objetivos

5.1. Objetivo General

Desarrollar y evaluar comparativamente un sistema de forecasting semanal multi escenario para el pipeline comercial de un Corporativo de Tecnologías de Información, utilizando modelos estadísticos, modelos avanzados de Machine Learning e Inteligencia Artificial explicable, con el fin de mejorar la anticipación de ingresos, reducir la exposición al error del Committed y establecer una arquitectura de decisión controlada y trazable.

5.2. Objetivos Específicos

1. Preparar y auditar los datos comerciales, aplicando reglas de negocio, tratamiento de montos inválidos, consolidación por oportunidad y agregación semanal.
2. Construir referencias cuantitativas simples y comparar su desempeño con el Committed.
3. Desarrollar de forma progresiva AR, MA, ARMA, ARIMA, ARIMAX, SARIMA y SARIMAX, documentando el aporte y las limitaciones de cada componente.
4. Evaluar Prophet, TFT y Chronos-2 bajo el mismo panel temporal y las mismas reglas de información.
5. Desarrollar modelos tabulares con rezagos y variables exógenas, comparando Elastic Net, Random Forest, HistGradientBoosting, XGBoost, LightGBM y CatBoost.
6. Aplicar XAI y SHAP Values para interpretar el comportamiento global y local de los modelos tabulares.
7. Comparar todas las familias mediante WAPE, *Mean Absolute Error* (MAE), RMSE, *symmetric Mean Absolute Percentage Error* (sMAPE), sesgo, techo, desviación y evidencia inferencial.
8. Cuantificar el error económico evitado y proponer un marco de medición de ingresos incrementales y cierres ganados para un piloto prospectivo.
9. Diseñar una extensión futura que conecte el forecast con otros modelos comerciales y con un Forecast Decision Agent orientado a analítica prescriptiva.

6. Marco Teórico

6.1. Forecasting como Apoyo a la Toma de Decisiones

El forecasting aplicado a la gestión comercial no debe interpretarse como una proyección aislada, sino como un proceso de reducción de incertidumbre para decisiones recurrentes. La salida debe permitir comparar el escenario esperado con la señal cualitativa del negocio (*Committed*), detectar desviaciones, anticipar concentración y establecer cuándo la revisión humana agrega valor. Por ello, el criterio de utilidad combina precisión estadística, estabilidad temporal, explicabilidad y capacidad de gobierno.

En una serie semanal, cada observación está condicionada por el momento del trimestre y por información acumulada en semanas anteriores. La independencia entre registros, supuesto común en problemas tabulares, no resulta adecuada. La modelación debe representar la secuencia, utilizar únicamente historia disponible y evaluar el desempeño sobre periodos posteriores a los usados para entrenar.

El forecasting transforma información histórica y señales disponibles en estimaciones sobre resultados futuros. En Analítica de Negocios, su utilidad no depende únicamente de la precisión estadística, sino también de su adecuación al problema de decisión, al horizonte considerado y a la información disponible. La selección y evaluación de los métodos debe considerar estas condiciones y verificar su desempeño sobre información no utilizada durante el ajuste (Hyndman & Athanasopoulos, 2021).

La literatura distingue entre pronósticos puramente estadísticos y ajustes de juicio. El juicio experto puede incorporar eventos no observados en la historia, pero también introduce sesgos, inconsistencias y dificultades de auditoría. Los sistemas efectivos no eliminan el juicio, sino que establecen un baseline cuantitativo, registran los ajustes y evalúan su valor posterior (Fildes et al., 2009).

6.2. Modelos de Referencia

Las referencias simples cumplen una función de control metodológico. Naive Mean pregunta si el nivel promedio histórico basta para aproximar los cierres. Naive Seasonal replica la semana equivalente del trimestre anterior y crea una referencia especialmente exigente cuando la serie presenta concentración al cierre. Committed representa la señal cualitativa de la organización y permite cuantificar cuánto aporta el criterio experto frente a reglas reproducibles.

Un modelo complejo sólo agrega valor cuando mejora estas referencias de manera consistente. Esta regla evita atribuir mérito a una arquitectura que obtiene resultados razonables debido a patrones que una repetición estacional también captura. En el estudio, Naive Seasonal se mantiene durante toda la comparación y opera además como sanity check para el cierre trimestral.

Los modelos ingenuos cumplen una función metodológica central. Naive Mean estima el futuro con un promedio histórico, Naive Moving Average utiliza una ventana reciente y Naive Seasonal replica el valor observado en la misma posición del ciclo anterior. Si un modelo complejo no supera estas referencias, la complejidad adicional no está justificada. La referencia estacional resulta especialmente exigente cuando el proceso presenta patrones trimestrales recurrentes.

En términos analíticos, las referencias cuantitativas se expresan mediante reglas de cálculo transparentes. Naive Mean utiliza todo el nivel histórico disponible, Naive Moving Average restringe ese cálculo a las k observaciones más recientes, y Naive Seasonal replica la observación ubicada en la misma posición del ciclo anterior.

$$\hat{y}_{t+h|t} = \frac{1}{t} \sum_{i=1}^t y_i$$

$$\hat{y}_{t+1|t} = \frac{1}{k} \sum_{i=0}^{k-1} y_{t-i}$$

$$\hat{y}_t = y_{t-s}, s = 13$$

En estas expresiones, $y(t)$ representa el cierre observado en la semana t , h el horizonte de pronóstico, k la longitud de la ventana móvil y s la periodicidad estacional. Committed no se expresa mediante una ecuación estadística de estimación, porque corresponde a una señal comercial registrada en el CRM y se conserva como referencia cualitativa independiente.

6.3. AR, MA y ARMA

Un modelo autorregresivo (AR) representa el valor actual como combinación de valores pasados. En este contexto, la pregunta es si el monto cerrado durante semanas recientes contiene información suficiente para anticipar el cierre siguiente. El parámetro de orden p define cuántos rezagos se incorporan y su selección debe considerar tanto ajuste como estabilidad fuera de muestra.

Un modelo de medias móviles (MA) no utiliza promedios móviles descriptivos, sino tendencias o errores previos. Su propósito es capturar shocks transitorios que siguen afectando la serie durante algunas semanas. ARMA combina memoria autorregresiva y tendencias, pero requiere una serie estacionaria. Por esta razón, su uso se interpreta como parte de la progresión diagnóstica y no como una solución final independiente del análisis de estacionariedad (Box et al., 2015).

La formulación autorregresiva de orden p utilizada como base conceptual se expresa como:

$$y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \varepsilon_t$$

En esta aplicación, la variable dependiente corresponde a la serie semanal modelada de cierres ganados y los términos rezagados representan sus valores observados en semanas anteriores. Los coeficientes autorregresivos cuantifican cuánto aporta cada uno de esos rezagos al nivel esperado de la semana siguiente, mientras el término de innovación recoge la parte no explicada por la memoria del proceso. Cuando una especificación se ajusta sobre escala logarítmica, la misma relación se aplica a la serie transformada y el pronóstico se reconvierte posteriormente a MM USD. El propósito de AR dentro de la tesis es aislar la memoria de corto plazo antes de introducir estacionalidad o información del CRM (Box et al., 2015).

El componente Moving Average de orden q se representa mediante tendencias pasadas:

$$y_t = \mu + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

A diferencia de una media móvil descriptiva, los coeficientes de MA no ponderan cierres observados, sino tendencias o errores producidos por shocks anteriores. En el pipeline comercial, esta formulación prueba si una sorpresa de cierre o un desplazamiento no anticipado deja una corrección temporal que continúa siendo informativa durante las semanas siguientes.

ARMA combina ambas fuentes de información en una sola estructura:

$$y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

La ecuación integra memoria de los cierres y memoria de las tendencias. Su uso es deliberadamente intermedio: permite comprobar si ambas fuentes reducen el error antes de introducir diferenciación, estacionalidad trimestral o covariables comerciales. Por ello, la comparación AR, MA y ARMA funciona como una prueba incremental de estructura y no como una mera enumeración de algoritmos (Box et al., 2015).

La progresión desde AR a MA y ARMA es importante porque separa dos fuentes de información. La primera es la persistencia del ingreso, la segunda es la estructura remanente en los errores. Esta separación permite observar si el problema responde a memoria temporal o a correcciones transitorias.

6.4. ARIMA y ARIMAX

ARIMA incorpora diferenciación para estabilizar el nivel y modelar una serie cuya media no permanece constante. Los parámetros p , d y q representan, respectivamente, el componente autorregresivo, el número de diferencias y el componente de medias

móviles. En la aplicación comercial, la diferenciación permite separar cambios de nivel de la dinámica recurrente, aunque puede aumentar la sensibilidad a semanas extraordinarias.

ARIMA incorpora diferenciación para tratar no estacionariedad. Su notación $ARIMA(p, d, q)$ integra autoregresión, número de diferencias y medias móviles. En notación de operador de rezago, la estructura $ARIMA(p, d, q)$ puede expresarse como:

$$\Phi(B)(1 - B)^d y_t = c + \Theta(B)\varepsilon_t$$

B es el operador de rezago, d es el número de diferencias regulares y los polinomios $\Phi(B)$ y $\Theta(B)$ representan, respectivamente, los componentes autorregresivos y de medias móviles. En la serie comercial, la diferenciación se utiliza para separar cambios persistentes de nivel de la dinámica semanal recurrente. Esta decisión se sustenta en los diagnósticos de estacionariedad y no en una elección automática de parámetros (Box et al., 2015).

ARIMAX extiende esta formulación mediante variables exógenas X , por ejemplo, el monto comprometido, el pipeline estimado o señales de cierre. La inclusión de exógenas permite representar información de negocio que no está contenida en la historia de la variable objetivo. El desafío principal no consiste en añadir cualquier señal disponible, sino en garantizar que esa señal existía antes del horizonte pronosticado. Esta restricción es central para que la mejora observada represente una capacidad operable y no una ventaja producida por información futura.

ARIMAX incorpora a esa estructura un vector de información exógena disponible antes del horizonte de pronóstico:

$$\Phi(B)(1 - B)^d y_t = c + \beta^T x_t + \Theta(B)\varepsilon_t$$

En esta tesis, el vector de covariables reúne las señales ex ante del CRM, entre ellas monto y conteo Committed, pipeline estimado, número de oportunidades, indicadores de calendario y variables de fase. Los coeficientes asociados a esas covariables cuantifican su aporte condicional después de controlar la dependencia temporal. La reconstrucción ex ante es indispensable: una señal sólo se incorpora cuando podía conocerse en el momento real de decisión, evitando que una mejora aparente provenga de información futura.

6.5. SARIMA y SARIMAX

SARIMA agrega una estructura estacional con periodicidad s . Para una serie comercial semanal, $s = 13$ aproxima la repetición del trimestre y conecta semanas equivalentes entre periodos. Los parámetros estacionales p , d y q cumplen una función análoga a los componentes no estacionales. El modelo permite distinguir memoria de corto plazo y comportamiento recurrente dentro del ciclo trimestral.

La extensión estacional SARIMA incorpora, además de los componentes regulares, una segunda estructura de rezagos, diferencias y errores asociada a una periodicidad estacional s :

$$\Phi(B)\Phi_s(B^s)(1-B)^d(1-B^s)^D y_t = c + \theta(B)\theta_s(B^s)\varepsilon_t$$

Para el pipeline semanal se utiliza una periodicidad de 13 semanas como referencia trimestral. Los componentes estacionales de la ecuación permiten relacionar posiciones equivalentes de trimestres consecutivos, mientras los componentes no estacionales conservan la dinámica de corto plazo. La existencia de un trimestre de catorce semanas se trata mediante variables de fase y no mediante la eliminación del caso real.

SARIMAX integra estacionalidad y covariables exógenas. Su ventaja conceptual es que no obliga a elegir entre memoria temporal y señales del CRM, sino que evalúa su contribución conjunta. La especificación seleccionada utiliza variables de fase, montos y conteos reconstruidos ex ante, además de una estructura que controla la autocorrelación residual. El resultado debe interpretarse junto con diagnósticos Ljung-Box, estabilidad entre ventanas y riesgo extremo.

Por lo tanto, SARIMAX combina la dinámica no estacional, la dinámica estacional y variables exógenas a esa dinámica estacional:

$$\Phi(B)\Phi_s(B^s)(1-B)^d(1-B^s)^D y_t = c + \beta^T x_t + \theta(B)\theta_s(B^s)\varepsilon_t$$

Esta es la formulación que mejor representa la lógica aplicada del champion: la historia semanal y la estacionalidad trimestral se combinan con un vector de señales comerciales reconstruidas ex ante y variables de fase. Así, el pronóstico no depende exclusivamente de repetir el trimestre anterior, sino que puede ajustar el nivel esperado ante cambios observables en el pipeline sin sacrificar la trazabilidad temporal.

La adecuación de un modelo no se determina sólo mediante criterios de información. El diagnóstico de residuos verifica si permanece autocorrelación no modelada. La prueba de Ljung-Box permite evaluar independencia serial y constituye una condición relevante para interpretar que el modelo capturó la estructura sistemática disponible (Box et al., 2015).

El diagnóstico de residuos se complementa con el estadístico de Ljung-Box:

$$Q = n(n+2) \sum_{k=1}^h \frac{\rho_k^2}{n-k}$$

En esta expresión, n corresponde al número de residuos, h al horizonte de rezagos evaluado y la autocorrelación residual mide la dependencia que permanece en cada rezago. En el estudio se revisan especialmente 13 y 26 rezagos, porque corresponden aproximadamente a uno y dos ciclos trimestrales. Un p -valor que no rechaza independencia residual indica que no queda evidencia suficiente de una estructura serial

sistemática en esos rezagos, aunque no implica que el modelo sea perfecto (Ljung & Box, 1978).

6.6. Prophet

Prophet formula la serie mediante componentes de tendencia, estacionalidad y eventos. Su estructura descomponible facilita incorporar el calendario de cierre trimestral y permite evaluar si la posición dentro del trimestre explica parte de la variación. La inclusión de regresores del CRM amplía el modelo, pero también exige el mismo control de disponibilidad ex ante aplicado a las familias estadísticas.

La flexibilidad de puntos de cambio y eventos puede representar variaciones de calendario, aunque no garantiza una respuesta adecuada ante operaciones extraordinarias. Por ello, Prophet se evalúa con el mismo panel de origen móvil y no mediante un único trimestre favorable.

Prophet representa la serie mediante una tendencia, componentes estacionales, eventos y regresores. Su diseño privilegia parámetros interpretables y la participación del analista, lo que lo convierte en una alternativa atractiva para procesos de negocio con calendarios y cambios de nivel (Taylor & Letham, 2018). En esta tesis se utiliza con eventos de cierre y regresores del CRM, bajo la misma disponibilidad ex ante de información.

La descomposición aditiva de Prophet se puede representar como:

$$y(t) = g(t) + s(t) + h(t) + x_t^T \beta + \varepsilon_t$$

En la ecuación, el primer componente $g(t)$ representa la tendencia y sus cambios de nivel, el segundo $s(t)$ las estacionalidades, el tercero $h(t)$ los eventos definidos por calendario y el término matricial incorpora los regresores adicionales. Para esta tesis, los eventos de cierre trimestral permiten representar la posición de cierre y los regresores del CRM se incorporan bajo disponibilidad ex ante. La formulación es útil porque separa explícitamente calendario y tendencia, pero su flexibilidad no garantiza que pueda reproducir la amplitud de un Mega Deal no anticipado (Taylor & Letham, 2018).

6.7. Temporal Fusion Transformer (TFT)

Temporal Fusion Transformer combina redes recurrentes, mecanismos de atención, selección de variables y pronóstico multi horizonte. Su diseño permite integrar covariables estáticas y temporales, además de producir interpretaciones internas. Sin embargo, la capacidad paramétrica requiere suficientes patrones repetidos. Una historia corta, una única serie agregada y alta concentración de MegaDeals pueden impedir que la complejidad se traduzca en generalización.

En esta investigación, el Temporal Fusion Transformer se implementa mediante el framework Darts, utilizando TFTModel para el entrenamiento y la generación de pronósticos. La implementación incorpora covariables temporales y una formulación probabilística mediante Quantile Regression, con el propósito de estimar distintos cuantiles de la distribución predictiva y evaluar la incertidumbre del forecast.

La comparación incorpora dispersión entre semillas y desempeño por ventana. Este control es necesario porque una arquitectura profunda puede entregar resultados sensibles a inicialización, longitud de entrada y regularización. La mediana aislada no basta para justificar su adopción.

Temporal Fusion Transformer combina redes recurrentes, mecanismos de selección de variables y atención interpretable para pronósticos multi horizonte. Su arquitectura permite integrar covariables estáticas, observadas y conocidas a futuro (Lim et al., 2021). Su principal riesgo en este caso es la relación entre alta capacidad paramétrica y la historia temporal acotada.

TFT no se reduce a una ecuación lineal única, porque combina selección de variables, redes recurrentes, mecanismos de gating y atención. Para el pronóstico probabilístico, una de sus formulaciones centrales es la pérdida cuantílica o pinball loss:

$$L_q(y_t, \hat{y}_t^{(q)}) = \max\{q(y_t - \hat{y}_t^{(q)}), (q - 1)(y_t - \hat{y}_t^{(q)})\}$$

El parámetro q identifica el cuantil que se desea estimar, la ecuación compara el cierre observado con el pronóstico correspondiente a ese cuantil. La pérdida penaliza de forma asimétrica subestimaciones y sobreestimaciones según el nivel elegido, permitiendo construir una distribución predictiva en lugar de un único punto. En el estudio, esta capacidad se evalúa junto con la estabilidad entre semillas y la cobertura observada, porque una banda probabilística sólo es útil cuando conserva comportamiento consistente fuera de muestra (Lim et al., 2021).

6.8. Modelos Fundacionales y Chronos-2

Los modelos fundacionales de series temporales se entrenan sobre colecciones extensas de series y permiten realizar forecasting sin ajuste específico o con una adaptación limitada. Chronos tokeniza valores temporales y aprende distribuciones de secuencias, Chronos-2 amplía el enfoque hacia tareas univariadas, multivariadas y con covariables. Su atractivo radica en transferir conocimiento previo cuando el dominio local dispone de poca historia.

La transferencia no elimina la necesidad de validación. La distribución de cierres comerciales, la periodicidad trimestral, la concentración de operaciones y la función de pérdida local pueden diferir de los datos de preentrenamiento. Por este motivo, Chronos-2 se utiliza como benchmark avanzado y se compara con referencias simples y modelos estadísticos especializados.

Chronos adapta arquitecturas de lenguaje al forecasting al cuantizar valores temporales y tratarlos como una secuencia de tokens. El modelo original fue diseñado para forecasting probabilístico zero-shot (Ansari et al., 2024). Chronos-2 extiende el enfoque a series multivariadas y tareas informadas por covariables mediante aprendizaje en contexto. Debido a que el trabajo de Chronos-2 corresponde a un preprint reciente, su resultado se interpreta como benchmark avanzado y no como evidencia consolidada para producción (Ansari et al., 2025).

Por tratarse de un modelo fundacional autoregresivo sobre una representación tokenizada, Chronos no dispone de un conjunto pequeño de coeficientes comparables a ARIMA. Su lógica probabilística puede resumirse mediante la factorización:

$$p(z_{T+1:T+H} \vee z_{1:T}, X) = \prod_{h=1}^H p(z_{T+h} \vee z_{1:T+h-1}, X)$$

Los términos de la secuencia corresponden a valores temporales escalados y representados como tokens, H corresponde al horizonte de pronóstico y el vector de contexto resume la información adicional disponible. El modelo estima cada paso condicionado por la secuencia anterior y por ese contexto. Chronos-2 amplía esta lógica hacia tareas multivariadas y con covariables mediante aprendizaje en contexto. En esta tesis se utiliza como benchmark avanzado para comprobar si el conocimiento transferido desde grandes colecciones de series supera a una especificación estadística adaptada explícitamente al ciclo comercial (Ansari et al., 2024, 2025).

6.9. Machine Learning tabular

Los modelos tabulares transforman la serie en un problema supervisado mediante rezagos, estadísticas móviles, variables de calendario (fechas declaradas en cada oportunidad), fase y señales del CRM. Random Forest reduce varianza mediante ensambles de árboles, XGBoost y LightGBM optimizan gradualmente funciones de pérdida con estrategias diferentes de construcción (Chen & Guestrin, 2016, Ke et al., 2017, respectivamente), CatBoost controla sesgos de boosting y gestiona relaciones no lineales (Prokhorenkova et al., 2018)., HistGradientBoosting discretiza variables para mejorar eficiencia, y Elastic Net entrega una referencia lineal regularizada.

A diferencia de los modelos estadísticos de series de tiempo, en los modelos de Machine Learning tabular la estructura temporal no se encuentra incorporada de forma explícita en la arquitectura del algoritmo. Por esta razón, antes del entrenamiento se realiza un proceso de feature engineering temporal que transforma la memoria de la serie en variables predictoras. En esta investigación se construyen rezagos de 1, 13 y 26 semanas para representar memoria de corto plazo, trimestral y semestral, junto con estadísticos móviles que resumen nivel, dispersión y comportamiento reciente. Estas variables se complementan con covariables de calendario, fase trimestral y señales

comerciales ex ante del CRM, conformando el vector de entrada utilizado por Elastic Net, Random Forest, HistGradientBoosting, XGBoost, LightGBM y CatBoost.

De esta forma, los algoritmos tabulares no reciben la serie temporal como una secuencia ordenada de manera nativa, sino como una matriz de características construida a partir exclusivamente de información disponible hasta cada punto de decisión.

Esta transformación permite capturar interacciones que no están especificadas de forma paramétrica. También introduce riesgos: una construcción incorrecta de rezagos puede filtrar información futura, las variables pueden cambiar de distribución y la importancia interna del modelo no equivale a causalidad. La evaluación fuera de muestra y SHAP se utilizan para controlar parte de estas limitaciones.

Elastic Net representa la referencia lineal regularizada de esta familia. Su estimación combina penalización L1 y L2:

$$\hat{\beta} = \underset{\beta}{\operatorname{argmin}} \left\{ \frac{1}{2n} \sum_{i=1}^n (y_i - \beta_0 - x_i^T \beta)^2 + \lambda \left[\alpha \|\beta\|_1 + \frac{1-\alpha}{2} \|\beta\|_2^2 \right] \right\}$$

En este caso, el vector de entrada contiene rezagos de la serie, estadísticas móviles, calendario, fase y señales ex ante del CRM. El parámetro de regularización controla la intensidad de la penalización y el parámetro de mezcla distribuye el peso entre selección tipo Lasso (L1) y contracción tipo Ridge (L2). Su función en la tesis es verificar si una combinación lineal estable de estas variables basta para explicar el forecast antes de recurrir a interacciones no lineales (Zou & Hastie, 2005).

Random Forest construye múltiples árboles sobre muestras y subconjuntos de variables y promedia sus predicciones:

$$\hat{f}_{RF}(x) = \frac{1}{B} \sum_{b=1}^B T_b(x)$$

Cada término del promedio corresponde a un árbol de regresión y B al número total de árboles del ensamble. El promedio reduce la varianza asociada a un único árbol y permite capturar relaciones no lineales entre rezagos y señales comerciales. En el contexto del pipeline, su valor es comprobar si las interacciones no paramétricas mejoran sobre Elastic Net sin imponer una secuencia de corrección entre árboles (Breiman, 2001).

Los métodos de gradient boosting comparten una lógica aditiva: cada nuevo aprendiz corrige la pérdida residual del ensamble acumulado (Friedman, 2001):

$$F_m(x) = F_{m-1}(x) + \eta h_m(x)$$

En esta recurrencia, el primer término representa el ensamble acumulado hasta la iteración anterior, el segundo corresponde al nuevo árbol y la tasa de aprendizaje regula cuánto aporta ese árbol a la actualización. Esta ecuación es la base común, pero no hace equivalentes a XGBoost, LightGBM, HistGradientBoosting y CatBoost: cada implementación modifica cómo calcula gradientes, regulariza, selecciona particiones o construye los árboles.

XGBoost pertenece a la familia de Gradient Boosting Decision Trees (GBDT) y formaliza el ensamble como una suma de árboles de regresión y optimiza una función objetivo regularizada (Chen & Guestrin, 2016):

$$\begin{aligned}
 \hat{y}_i &= \sum_{k=1}^K f_k(x_i), f_k \in F \\
 Obj^{(m)} &= \sum_{i=1}^n \ell(y_i, \hat{y}_i^{(m-1)} + f_m(x_i)) + \Omega(f_m) \\
 \Omega(f) &= \gamma T + \frac{1}{2} \lambda \|w\|_2^2
 \end{aligned}$$

En estas expresiones, cada función del ensamble pertenece al espacio de árboles de regresión, la función de pérdida mide el error de predicción y el término de regularización penaliza la complejidad a través del número de hojas y de sus pesos terminales. Aplicado a esta tesis, el vector de entrada contiene rezagos, estadísticas móviles, fase, calendario y variables ex ante del CRM. XGBoost busca entonces combinaciones no lineales de esas señales, pero controla que la mejora del ajuste no provenga únicamente de árboles progresivamente más complejos.

LightGBM también pertenece a la familia de GBDT, pero su aporte no se limita a incrementar secuencialmente el número de árboles. El algoritmo busca reducir la función de pérdida mediante particiones sucesivas y, para una hoja que contiene el conjunto de observaciones O , evalúa la ganancia de dividir la variable j en el punto d a partir de los gradientes de las observaciones (Ke et al., 2017). La ganancia de la partición puede expresarse como:

$$V_{j|O}(d) = \frac{\left[\frac{(\sum_{x_i \in O: x_{ij} \leq d} g_i)^2}{n_{l|O}^j(d)} + \frac{(\sum_{x_i \in O: x_{ij} > d} g_i)^2}{n_{r|O}^j(d)} \right]}{n_O}$$

En esta expresión, g_i representa el gradiente negativo de la función de pérdida para la observación i , x_{ij} es el valor de la variable j , y n_l y n_r corresponden al número de observaciones que quedan a la izquierda y a la derecha después de la división. Para cada variable, el algoritmo selecciona el punto de corte que maximiza esa ganancia:

$$d_j^* = \arg \max_d V_{j|O}(d)$$

Sobre esta lógica de búsqueda, LightGBM utiliza crecimiento leaf-wise o best-first: en lugar de expandir uniformemente todos los nodos de un mismo nivel, continúa el árbol desde la hoja cuya mejor partición ofrece la mayor reducción potencial de pérdida. El paper incorpora además Gradient-based One-Side Sampling (GOSS), que prioriza observaciones con gradientes de mayor magnitud para estimar la ganancia con menor costo computacional, y Exclusive Feature Bundling (EFB), que agrupa variables prácticamente excluyentes para reducir la dimensionalidad efectiva.

Aplicado a esta tesis, cada observación corresponde a una semana del pipeline comercial y las variables candidatas incluyen rezagos de cierres ganados, estadísticas móviles, posición y fase del trimestre y señales ex ante del CRM. En consecuencia, LightGBM evalúa si una partición sobre estas variables reduce el error residual que el ensamble aún no explica. Su crecimiento leaf-wise permite concentrar capacidad en combinaciones locales complejas, pero esa misma flexibilidad puede aumentar el riesgo de sobreajuste en una historia temporal acotada y altamente concentrada. Por esta razón, su desempeño se evalúa mediante origen móvil y se interpreta en conjunto con WAPE, techo y dispersión entre ventanas, en lugar de considerar únicamente su precisión central.

CatBoost comparte la construcción secuencial de boosting, pero su formulación original introduce ordered boosting para reducir *prediction shift*: el gradiente usado para aprender la contribución de una observación se construye a partir de información precedente en una permutación, en lugar de reutilizar indiscriminadamente el propio objetivo (Prokhorenkova et al., 2018):

$$h_m^{(i)} = \text{Fit} \left(\{ (x_j, g_j^{(m)}) : \sigma(j) < \sigma(i) \} \right), F_m^{(i)} = F_{m-1}^{(i)} + \eta h_m^{(i)}$$

La condición de orden incluida en la ecuación expresa que el ajuste asociado a cada caso se construye utilizando observaciones que lo preceden en la permutación definida por el algoritmo. En esta tesis, donde predominan rezagos, estadísticas temporales y señales del CRM, la relevancia empírica de CatBoost no se atribuye a variables categóricas por sí solas, sino a su capacidad para aprender interacciones no lineales bajo una regularización y un esquema de boosting distintos de XGBoost y LightGBM. El origen móvil sigue siendo el control de validez temporal y no es sustituido por el *ordered boosting*.

6.10. XAI y SHAP Values

SHAP distribuye la diferencia entre una predicción y un valor base entre las variables utilizadas. La magnitud absoluta promedio permite construir una importancia global, mientras que el signo de cada contribución muestra si una variable aumenta o reduce el log-forecast en una observación específica. Esta descomposición facilita comparar drivers, revisar casos críticos y detectar dependencias excesivas.

La interpretación debe mantenerse en el plano predictivo. Un valor SHAP alto indica que el modelo utilizó una variable para modificar su pronóstico, no que la variable causó el cierre. Además, cuando existen variables correlacionadas, la contribución puede repartirse de manera distinta entre modelos. Por ello se analizan concordancia de rankings, familias de variables y estabilidad entre ventanas.

SHAP asigna a cada variable una contribución aditiva sobre una predicción, utilizando principios derivados del valor de Shapley. La suma de las contribuciones y el valor base reconstruye la salida del modelo, lo que permite analizar importancia global y explicaciones locales (Lundberg & Lee, 2017). En modelos de árboles, TreeSHAP ofrece un procedimiento eficiente y consistente para estudiar patrones de atribución (Lundberg et al., 2020).

La propiedad de eficiencia de SHAP permite reconstruir cada predicción mediante un valor base y la suma de contribuciones:

$$f(x) = E[f(X)] + \sum_{j=1}^M \phi_j$$

El valor esperado del modelo funciona como referencia y cada contribución SHAP representa cuánto desplaza una variable la predicción de la observación analizada respecto de ese punto base. El valor de Shapley se define como un promedio ponderado del aporte marginal de incorporar una variable a todos los subconjuntos posibles:

$$\phi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|! (|N| - |S| - 1)!}{|N|!} (v(S \cup \{i\}) - v(S))$$

En la aplicación, la importancia global se obtiene agregando la magnitud absoluta de las contribuciones SHAP sobre observaciones fuera de muestra, mientras las explicaciones locales conservan signo y magnitud para semanas específicas. Esto permite analizar lags de 13 y 26 semanas, variables de pipeline, Committed y fase sin interpretar esas contribuciones como efectos causales (Lundberg & Lee, 2017, Lundberg et al., 2020).

La interpretación de SHAP es descriptiva. Una variable con alta contribución puede estar correlacionada con la predicción sin ser causa del resultado. Esta distinción es fundamental cuando se interpretan variables como Committed o pipeline, porque ambas reflejan decisiones comerciales previas y pueden contener información común.

6.11. Métricas, Inferencia y Escenarios

WAPE se utiliza como métrica primaria porque agrega el error absoluto en relación con el volumen real y evita que semanas de bajo monto dominen el resultado porcentual. MAE traduce la magnitud típica a MM USD, RMSE penaliza con mayor fuerza errores extremos, sMAPE normaliza la diferencia respecto del promedio de real y pronóstico. El

sesgo identifica sobreestimación o subestimación neta. Hyndman y Koehler (2006) destacan que la elección de la métrica debe considerar escala, ceros, comparabilidad y propósito. El techo del WAPE y su desviación entre ventanas miden riesgo operacional.

La prueba *Diebold-Mariano* (DM) compara pérdidas de pronóstico y requiere una estimación robusta de varianza ante dependencia temporal. El Model Confidence Set identifica un conjunto de modelos que no puede diferenciarse estadísticamente al nivel definido. Los escenarios, por su parte, se construyen como sensibilidades descriptivas. Sólo pueden denominarse intervalos calibrados cuando la cobertura fuera de muestra respalda esa interpretación.

La evaluación de origen móvil reproduce el uso real: el modelo se entrena con información disponible hasta cada punto y pronostica el siguiente trimestre. El conjunto de modelos de confianza compara procedimientos considerando incertidumbre de selección (Hansen et al., 2011), mientras que Diebold-Mariano contrasta diferencias de pérdida entre dos pronósticos (Diebold & Mariano, 1995). Las varianzas de largo plazo requieren correcciones robustas ante dependencia temporal, como Newey-West (Newey & West, 1987).

Los escenarios “adverso”, “base” y “favorable” permiten explorar sensibilidad, pero no deben presentarse como intervalos calibrados si su cobertura no ha sido validada. Esta tesis distingue forecast puntual, bandas empíricas y escenarios de estrés para evitar que una visualización de incertidumbre sea interpretada como garantía probabilística.

7. Revisión Bibliográfica y Estado del Arte

7.1. Forecast Cualitativo y Combinación con Modelos

La evidencia sobre ajustes por juicio muestra que la experiencia puede incorporar información no disponible en la serie, pero también puede introducir optimismo, anclaje y falta de trazabilidad. La recomendación no es excluir el juicio, sino separarlo del forecast estadístico, registrar el ajuste experto y medir su contribución posterior. Esta lógica sustenta el tratamiento del Committed como señal independiente.

En el contexto comercial, la combinación adquiere especial relevancia porque los ejecutivos conocen riesgos contractuales, negociaciones y dependencias que el histórico agregado no observa. Al mismo tiempo, la organización necesita una referencia reproducible que permita verificar si esas percepciones mejoran o deterioran la estimación. La arquitectura propuesta responde a esta tensión mediante comparación y gobierno.

La evidencia sobre ajustes de juicio muestra que los expertos pueden mejorar un forecast cuando poseen información contextual no incorporada por el modelo. Sin embargo, los ajustes frecuentes, no documentados o motivados por objetivos internos pueden deteriorar la exactitud. Fildes et al. (2009) proponen sistemas donde el modelo genera una referencia objetiva y el ajuste humano se registra, justifica y evalúa. Este principio sustenta la separación entre Committed, forecast cuantitativo y ajuste experto ejecutivo.

7.2. Modelos Simples frente a Modelos Complejos

La literatura de forecasting y las competencias empíricas muestran que modelos simples pueden mantener resultados competitivos cuando la señal es corta, ruidosa o cambia de régimen. La complejidad ofrece flexibilidad, pero aumenta el espacio de parámetros y la sensibilidad a la muestra. En esta tesis, la progresión se utiliza para observar en qué momento aparece un aporte incremental y cuándo la complejidad deja de compensar la incertidumbre.

El benchmark Naive Seasonal cumple una función crítica: obliga a demostrar que el algoritmo agrega información por sobre la repetición del trimestre anterior. Esta exigencia es coherente con una serie donde los cierres se concentran en posiciones similares del calendario, aunque los montos específicos varíen.

Las competencias y estudios comparativos de forecasting han mostrado que no existe una familia universalmente superior. El rendimiento depende del horizonte, la longitud de la serie, la frecuencia, la estacionalidad, la disponibilidad de covariables y la función de pérdida. Por ello, la literatura recomienda establecer baselines fuertes, evaluar con ventanas temporales y evitar conclusiones basadas en una sola partición (Hyndman & Athanasopoulos, 2021).

Esta tesis adopta esa orientación. La progresión AR, MA, ARMA, ARIMA, ARIMAX, SARIMA y SARIMAX no se presenta como una enumeración teórica, sino como un experimento de aporte incremental. Prophet, TFT y Chronos-2 se incorporan después de definir una referencia estadística competitiva, de modo que su valor se determine por evidencia y no por novedad tecnológica.

7.3. Modelos Avanzados y Disponibilidad de Datos

TFT y los modelos fundacionales representan dos estrategias distintas. TFT aprende parámetros específicamente sobre la serie local y requiere suficientes ejemplos. Chronos-2 transfiere patrones aprendidos en grandes colecciones y puede operar sin fine-tuning. La comparación permite evaluar si la historia local favorece aprendizaje específico o transferencia. En ambos casos, la validación rolling y la revisión del peor caso son indispensables.

Darts se utiliza como framework de implementación y comparación para parte de las familias temporales. Su aporte consiste en estandarizar interfaces de ajuste, predicción, backtesting y covariables, lo que reduce diferencias operativas entre modelos. La librería no constituye un algoritmo ni reemplaza el diseño metodológico, la validez depende de la construcción de ventanas, las variables y las métricas definidas por la investigación.

TFT fue diseñado para integrar fuentes heterogéneas y generar pronósticos multi horizonte con interpretabilidad. No obstante, su capacidad requiere suficiente diversidad temporal para aprender relaciones estables. En series corporativas cortas y dominadas por eventos extraordinarios, el riesgo de alta varianza aumenta. Chronos y Chronos-2 reducen la necesidad de entrenamiento específico mediante preentrenamiento, pero su desempeño zero-shot sigue dependiendo de la similitud entre el problema y las estructuras aprendidas (Lim et al., 2021, Ansari et al., 2024, 2025).

7.4. Explicabilidad y Adopción

La adopción de un modelo comercial depende de que los usuarios comprendan su propósito, sus límites y las condiciones que activan una revisión. La explicabilidad global ayuda a identificar qué señales sostienen el forecast, mientras que la explicación local permite revisar una semana o trimestre específico. La estabilidad de drivers es tan relevante como su importancia promedio, porque un modelo que cambia de lógica entre ventanas puede ser difícil de gobernar.

La literatura de XAI también advierte que una visualización convincente no transforma una asociación predictiva en explicación causal. La tesis incorpora esta distinción en los títulos, fuentes y notas de las figuras, y evita traducir contribuciones SHAP en recomendaciones directas sin una regla de negocio o una validación adicional.

La literatura de XAI distingue explicación del comportamiento del modelo y explicación del fenómeno real. SHAP es útil para responder qué variables influyeron en una predicción, pero no prueba qué acción produjo el cierre. La adopción ejecutiva exige

complementar las atribuciones con controles de estabilidad, calidad de datos y revisión de casos críticos (Lundberg & Lee, 2017, Lundberg et al., 2020).

7.5. Brecha de Investigación Aplicada

La contribución aplicada se encuentra en articular una cadena completa: diagnóstico de series de tiempo, comparación con juicio comercial, progresión de modelos, validación cronológica, inferencia, XAI, escenarios, cuantificación de error evitado y diseño de gobierno. Cada componente se conecta con una decisión. La investigación no busca declarar un algoritmo universalmente superior, sino establecer qué combinación es más adecuada para la estructura observada y cómo debe operarse.

La brecha de negocio se relaciona con la dificultad de convertir un forecast en acciones medibles. El estudio separa la mejora predictiva observada de los ingresos incrementales futuros y propone un marco de evaluación con grupos comparables. Esta separación evita presentar como *Return on Investment* (ROI) una reducción de error que todavía no ha sido vinculada causalmente con crecimiento.

La brecha abordada por esta tesis se encuentra en la integración de cinco dimensiones que suelen analizarse por separado: comparación del juicio comercial (cualitativo) con modelos cuantitativos, progresión completa desde modelos simples hasta modelos fundacionales, evaluación de origen móvil con medidas de riesgo extremo, explicabilidad de modelos tabulares y, traducción del error a impacto económico y gobierno. El aporte no consiste únicamente en identificar un predictor, sino en diseñar una capacidad corporativa de forecasting medible y controlable.

Línea bibliográfica	Aporte al estudio	Decisión metodológica
Forecast con juicio	El criterio experto agrega contexto, pero debe medirse y auditarse.	Committed se conserva como señal y no como único forecast.
Modelos clásicos	La estructura temporal debe identificarse antes de aumentar complejidad.	Desarrollo progresivo desde AR y MA hasta SARIMAX.
Prophet	Modelo descomponible con eventos y participación del analista.	Evaluación con cierre trimestral y regresores del CRM.
TFT	Arquitectura multi horizonte con selección de variables.	Benchmark avanzado condicionado por la longitud de la serie.
Chronos-2	Modelo fundacional zero-shot con covariables.	Benchmark reciente, interpretado con cautela.
Machine Learning tabular	Captura no linealidad e interacciones sobre variables construidas.	Comparación de seis algoritmos bajo origen móvil.
XAI	Permite atribuciones globales y locales.	SHAP descriptivo, sin inferencia causal.
Analítica prescriptiva	Conecta predicción y decisión.	Extensión futura con control humano y medición de valor.

Cuadro 2. Síntesis de la revisión bibliográfica y su traducción metodológica.

Fuente: Elaboración propia.

8. Metodología

8.1. Enfoque Metodológico

La investigación es empírica, cuantitativa, aplicada y comparativa. Es empírica porque utiliza registros reales anonimizados, cuantitativa porque evalúa modelos con métricas e inferencia, aplicada porque busca resolver una decisión comercial a un problema de negocios real y comparativa porque todas las familias se someten a un protocolo temporal común.

8.2. Fuente, Confidencialidad y Unidad de Análisis

La serie final contiene 183 semanas entre enero de 2023 y junio de 2026. La frecuencia semanal responde al equilibrio entre granularidad y estabilidad: una frecuencia diaria aumenta la proporción de ceros y la volatilidad de calendario, mientras que una frecuencia mensual oculta la concentración de las últimas semanas del trimestre. La agregación semanal permite representar fases y mantener una cantidad suficiente de observaciones para origen móvil.

La unidad analítica del forecast es el monto de cierres ganados por semana, expresado en millones de dólares. Las variables de apoyo incluyen conteo de cierres, monto y conteo Committed, monto y conteo del pipeline estimado, semana ISO, mes, trimestre, semana dentro del trimestre, fase y funciones cíclicas de calendario.

Variable	Tipo recomendado	Disponibilidad	Función analítica
Cierres ganados semanales	Variable Objetivo	Observada al cierre de la semana	Monto a pronosticar
Committed USD y conteo	Covariable comercial ex ante	Reconstrucción ex ante por fase	Señal cualitativa del negocio
Pipeline estimado USD y conteo	Covariable comercial ex ante	Reconstrucción ex ante por fase	Volumen y maduración esperada
Semana dentro del trimestre	Covariable de Calendario	Conocida anticipadamente	Representar concentración temporal
Fase y semana de cierre	Covariable de Calendario y fase	Conocida anticipadamente	Separar inicio, medio, final y cierre
Rezagos 1, 13 y 26	Variable Temporal Derivada	Construidos sólo con historia	Memoria corta, trimestral y semestral
Estadísticos móviles	Variable Temporal Derivada	Construidos sólo con historia	Nivel, dispersión y extremos recientes

Cuadro 3. Variables principales, disponibilidad y función dentro del estudio.

Fuente: Elaboración propia.

Esto resume las variables consideradas en el estudio, aunque su utilización específica varía según el modelo analizado. El monto semanal de cierres ganados corresponde a la variable objetivo. Las señales comerciales obtenidas desde el CRM incluyen el monto y el número de oportunidades clasificadas como Committed, además del monto y el número de oportunidades contenidas en el pipeline estimado. Estas variables se reconstruyen considerando únicamente la información que habría estado disponible al momento de emitir cada pronóstico. A ellas se agregan variables de calendario y fase, como la semana ISO, el mes, el trimestre, la semana dentro del trimestre, la identificación de las semanas de cierre y las representaciones cíclicas de la fase comercial, todas conocidas anticipadamente. En cambio, los rezagos de 1, 13 y 26 semanas y los estadísticos móviles de nivel, dispersión y valores extremos se calculan exclusivamente a partir de la información histórica de los cierres ganados. Por esta razón, las variables del estudio no deben entenderse como un conjunto homogéneo de regresores exógenos, sino como una combinación de señales comerciales disponibles ex ante, variables de calendario y características temporales derivadas. Cada modelo utiliza el subconjunto de variables que resulta coherente con su estructura y especificación.




Ilustración 3. Serie semanal de cierres ganados y concentración en semanas de cierre.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

La visualización muestra una serie con variabilidad marcada y peaks recurrentes en las semanas de cierre. Los máximos se concentran en Q4/2025, Q1/2026 y Q2/2026, aunque también aparecen operaciones extraordinarias en fases intermedias. Esta combinación confirma que la estacionalidad existe, pero no explica por sí sola la totalidad del riesgo.




Ilustración 4. Ingresos de cierres ganados agregados por trimestre.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

Los totales trimestrales fluctúan entre 180,69 MM USD y 435,36 MM USD dentro del periodo completo. La variación de nivel impide asumir un patrón estacionario simple en la escala original y justifica evaluar transformaciones, diferenciación y covariables exógenas. También demuestra que una regla estacional debe adaptarse a cambios de amplitud.




Ilustración 5. Perfil de cierres por fase del trimestre.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

La fase de cierre reúne 33,85% del ingreso total con sólo 15 de las 183 observaciones. Su promedio semanal alcanza 91,18 MM USD, frente a 9,63 MM USD en las primeras cuatro semanas. La diferencia de escala explica por qué RMSE, techo del WAPE y error de cierre son métricas indispensables para la decisión operacional.

Los datos provienen del CRM del Corporativo de Tecnologías de Información y cubren oportunidades comerciales entre 2023 y Q2/2026. La unidad original corresponde a líneas de productos asociadas a oportunidades. Para evitar doble contabilización, el análisis consolida montos a nivel de oportunidad y utiliza el precio total convertido a dólares.

La información se anonimiza. No se incluyen nombres de Clientes, ejecutivos ni identificadores operacionales. Los resultados se presentan de forma agregada y las operaciones extraordinarias se describen por su efecto estadístico, sin revelar su identidad.

8.3. Reglas de Calidad y Preparación

La preparación incluye normalización de encabezados, tipificación de fechas y montos, eliminación de oportunidades con montos negativos, control de nulos materiales, identificación de reversas, verificación de duplicados y aplicación de reglas de negocio. Las filas idénticas asociadas a unidades repetidas se conservan cuando

representan componentes reales de la oportunidad y su suma reproduce el monto de control.

Las reglas de negocio reducen el ingreso bruto disponible para modelamiento de aproximadamente 7.486 MM USD a 3.952 MM USD. Esta reducción refleja exclusión de registros que no corresponden a cierres válidos bajo el alcance y no constituye pérdida aleatoria de información.

8.4. Construcción de la Serie Semanal

La transformación logarítmica $\log(1 + y)$ se utiliza en varias familias para reducir asimetría y evitar que los peaks dominen completamente el ajuste. Las predicciones se reconvierten a la escala monetaria antes de calcular métricas de negocio. Esta decisión obliga a revisar posibles sesgos de retransformation y a comparar siempre en MM USD (millones de dólares).

La transformación y su retorno a escala monetaria se expresan como:

$$z_t = \log(1 + y_t)$$
$$\hat{y}_t = \exp(\hat{z}_t) - 1$$

En estas expresiones, el valor original corresponde al monto semanal de cierres ganados y la variable transformada a su escala logarítmica. La transformación comprime la influencia de los peaks durante el ajuste, pero todas las métricas de negocio se calculan después de volver a MM USD. De esta forma, la estabilización estadística no cambia la unidad con que se interpreta el error ejecutivo.

La posición dentro del trimestre se construye a partir del lunes de cada semana. Debido al calendario, Q3/2024 contiene catorce semanas bajo esta regla. El estudio no elimina esa observación, sino que documenta el trimestre irregular y utiliza variables de fase para mantener comparabilidad. La eliminación habría simplificado el análisis a costa de perder un caso real que el sistema debe enfrentar.




Ilustración 6. Nivel y variabilidad móvil de los cierres semanales.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

La media y la desviación móvil de 13 semanas cambian durante el periodo, lo que indica que el proceso no mantiene un nivel y una variabilidad constantes. La transformación y la diferenciación no se aplican de manera mecánica, sino que se evalúan como parte de la identificación de los modelos ARIMA y SARIMA.

Dependencia temporal y rezagos relevantes




Ilustración 7. Dependencia temporal y rezagos relevantes de la serie transformada.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

La autocorrelación confirma dependencia en rezagos cortos y señales asociadas a 13 y 26 semanas. Estos rezagos coinciden con la periodicidad trimestral y semestral del

proceso comercial y posteriormente aparecen entre los principales drivers de CatBoost. La coincidencia entre diagnóstico estadístico y XAI fortalece la interpretación, aunque no prueba causalidad.




Ilustración 8. Descomposición STL de la serie transformada con periodicidad trimestral.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

Transformación	n	ADF p-valor	KPSS p-valor	Lectura
Nivel semanal	183	0.2076	$\geq 0,10$	Evidencia mixta
Log1p	183	0.0252	$\geq 0,10$	Estacionariedad fortalecida
Diferencia regular del log	182	$< 0,0001$	$\geq 0,10$	Estacionariedad fortalecida
Diferencia estacional 13 del log	170	$< 0,0001$	$\geq 0,10$	Estacionariedad fortalecida
Diferencia regular y estacional del log	169	$< 0,0001$	$\geq 0,10$	Estacionariedad fortalecida

Cuadro 4. Diagnósticos de estacionariedad para transformaciones de la serie.

Fuente: Elaboración propia.

Las pruebas ADF y KPSS no entregan una lectura idéntica en el nivel original. ADF no rechaza raíz unitaria, mientras KPSS no rechaza estacionariedad alrededor de una media. Esta evidencia mixta se interpreta junto con los gráficos y no como una decisión automática. La transformación logarítmica y las diferencias regular o estacional fortalecen la evidencia de estacionariedad y respaldan la progresión hacia ARIMA, SARIMA y SARIMAX.

La variable objetivo es el monto semanal de cierres ganados en millones de dólares. Se agregan como covariables el monto y conteo de oportunidades Committed, el pipeline estimado, el número de oportunidades, indicadores calendario, posición relativa en el trimestre y variables de fase. El calendario se define por la fecha del lunes de cada semana, lo que explica la existencia de un trimestre de catorce semanas.

Para efectos metodológicos, las covariables exógenas se separan en señales comerciales ex ante del CRM y covariables de calendario y fase:

Señales comerciales ex ante del CRM

- Monto Committed: Valor monetario de las oportunidades clasificadas como comprometidas y disponibles antes del horizonte de pronóstico.
- Conteo Committed: Número de oportunidades clasificadas como Committed, utilizado como señal de volumen y convicción comercial.
- Pipeline Estimado: Monto total de oportunidades activas con expectativa de cierre, utilizado como señal anticipada del volumen comercial disponible.
- Conteo de Oportunidades del Pipeline: Cantidad de oportunidades que conforman el pipeline estimado, complementando el monto con una medida de densidad comercial.

- Número de Oportunidades: Volumen total de oportunidades presentes en la semana o fase analizada, utilizado como indicador de actividad comercial.

Covariables exógenas de calendario y fase

- Semana dentro del Trimestre: Posición relativa de la semana dentro del ciclo trimestral, utilizada para representar la concentración temporal de los cierres.
- Fase del Trimestre: Clasificación de la semana en inicio, medio, final o cierre, utilizada para capturar diferencias estructurales entre etapas del trimestre.
- Indicador de Semana de Cierre: Variable binaria que identifica la semana final del trimestre, donde históricamente existe una mayor concentración de ingresos.
- Variables de Calendario: Información conocida anticipadamente, como semana ISO, mes y trimestre, utilizada para representar patrones temporales sistemáticos.

Esta separación permite diferenciar la información generada por la gestión comercial de aquella asociada a la estructura temporal del proceso.

8.5. Disponibilidad Ex Ante

La evaluación operacional exige que una variable exista antes del horizonte. Para evitar fuga de información, las covariables monetarias se emparejan con la misma fase del trimestre anterior. Esta regla permite comparar trimestres de 13 y catorce semanas sin desplazar la señal de cierre. La versión contemporánea se mantiene sólo como referencia diagnóstica y no gobierna la recomendación productiva.

8.6. Particiones y Origen Móvil

Una partición aleatoria habría permitido que semanas futuras influyeran en el entrenamiento y habría mezclado fases de distintos trimestres. El diseño cronológico conserva entrenamiento, validación y prueba en secuencia. Después se aplica un origen móvil con ocho ventanas desde Q2/2024 hasta Q1/2026 y 105 semanas evaluadas. En cada ventana, el entrenamiento se expande y el trimestre siguiente permanece completamente fuera de muestra.

Validación temporal mediante origen móvil

El entrenamiento se expande y la prueba siempre corresponde al trimestre siguiente




Ilustración 9. Esquema de validación temporal mediante origen móvil.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

Ventana	Trimestre de prueba	Semanas	Historia mínima	Evaluación
1	Q2/2024	13	Al menos 4 trimestres	Evaluación fuera de muestra
2	Q3/2024	14	Historia expandida	Evaluación y trimestre irregular
3	Q4/2024	13	Historia expandida	Evaluación fuera de muestra
4	Q1/2025	13	Historia expandida	Evaluación fuera de muestra
5	Q2/2025	13	Historia expandida	Evaluación fuera de muestra
6	Q3/2025	13	Historia expandida	Evaluación fuera de muestra
7	Q4/2025	13	Historia expandida	Evaluación fuera de muestra
8	Q1/2026	13	Historia expandida	Evaluación final del panel

Cuadro 5. Panel principal de ventanas temporales de evaluación.

Fuente: Elaboración propia.

La agregación de métricas distingue dos operaciones. El WAPE por ventana evalúa cada trimestre por separado y permite estudiar dispersión. El WAPE agrupado suma errores y valores reales de todas las semanas antes de calcular la razón, entregando una lectura ponderada por volumen. Ambas medidas se reportan porque responden preguntas diferentes.

8.7. Familias de Modelos

El estudio considera distintas familias de modelos con el propósito de contrastar enfoques progresivamente más complejos bajo un mismo diseño de evaluación. La comparación comienza con referencias operativas y estadísticas simples, continúa con modelos clásicos de series temporales e incorpora posteriormente modelos avanzados y algoritmos de Machine Learning. Esta organización permite determinar si el aumento de complejidad produce mejoras efectivas y consistentes frente a alternativas más sencillas.

La primera familia comprende el pronóstico Committed, utilizado como referencia basada en el criterio experto del proceso comercial, junto con los métodos Naive Mean, Naive Seasonal y media móvil. Estas alternativas establecen niveles mínimos de comparación y permiten evaluar si los demás modelos capturan información adicional respecto del promedio histórico, la repetición del patrón trimestral o el comportamiento reciente de la serie.

Los modelos estadísticos incluyen AR, MA, ARMA, ARIMA y ARIMAX, además de sus extensiones estacionales SARIMA y SARIMAX. En conjunto, estas especificaciones permiten representar la dependencia temporal, la persistencia de los errores, los cambios en el nivel de la serie y el patrón comercial asociado al ciclo trimestral de 13 semanas. ARIMAX y SARIMAX amplían esta estructura mediante la incorporación de covariables comerciales disponibles ex ante, lo que permite combinar la información histórica de los cierres con señales provenientes del CRM.

La familia de modelos avanzados considera Prophet, Temporal Fusion Transformer y Chronos-2.

Para Prophet se definió una secuencia incremental de especificaciones. P1a incorporó una estacionalidad trimestral fija mediante términos de Fourier, P1b reemplazó esta representación por variables de fase calendarizada, P2 combinó la fase con eventos asociados a las semanas de cierre, y Prophet P3 agregó señales comerciales reconstruidas ex ante. Esta última correspondió a la especificación final de Prophet e incluyó `phase_sin` y `phase_cos`, los eventos de cierre incorporados mediante el calendario del modelo y los regresores `log_committed_exante` y `log_pipeline_exante`. Por lo tanto, la denominación Prophet P3 identifica específicamente a Prophet con fase, eventos de cierre y regresores CRM disponibles ex ante.

Por su parte, Temporal Fusion Transformer permite modelar relaciones no lineales entre la historia de la serie y las covariables disponibles, mientras que Chronos-2 incorpora un enfoque fundacional preentrenado para contrastar la capacidad de generalización de modelos desarrollados sobre grandes colecciones de series temporales.

Los modelos de Machine Learning tabular comprenden Elastic Net, Random Forest, HistGradientBoosting, XGBoost, LightGBM y CatBoost. Para su implementación, la serie temporal se transforma en una estructura supervisada que integra rezagos, estadísticos móviles, variables de calendario, indicadores de fase y señales comerciales reconstruidas ex ante. Esto permite que los algoritmos identifiquen relaciones lineales y no lineales entre el comportamiento histórico del pipeline y los cierres observados.

Finalmente, cada familia conserva sus propios supuestos, requerimientos de información y mecanismos de estimación, por lo que la estandarización de las interfaces computacionales no implica que los modelos sean metodológicamente equivalentes. Las implementaciones se realizaron mediante librerías especializadas para cada enfoque, mientras que Darts se utilizó específicamente en la implementación de Temporal Fusion Transformer. Para asegurar una comparación consistente, todos los modelos generan pronósticos sobre los mismos orígenes, horizontes y ventanas de evaluación. Sus resultados se contrastan posteriormente mediante métricas comunes de error y estabilidad, desarrolladas en el apartado siguiente. El Cuadro 6 sintetiza las familias consideradas, sus principales insumos y la función que cumplen dentro del diseño comparativo.

Familia	Modelos	Información que incorpora	Rol
Referencias	Committed, Naive Mean, Naive Seasonal y media móvil	Juicio comercial o repetición histórica	Definir la vara mínima.
Clásicos no estacionales	AR, MA, ARMA, ARIMA y ARIMAX	Rezagos, errores, diferencias y exógenas	Identificar aporte incremental.
Clásicos estacionales	SARIMA y SARIMAX	Estacionalidad trimestral y exógenas	Modelo estadístico operativo.
Avanzados	Prophet P3, TFT y Chronos-2	Eventos, atención, aprendizaje profundo y preentrenamiento	Contrastar complejidad adicional.
Machine Learning tabular	Elastic Net, Random Forest, HistGradientBoosting, XGBoost, LightGBM y CatBoost	Lags, estadísticas móviles, calendario y CRM	Capturar no linealidad y apoyar XAI.

Cuadro 6. Familias de modelos y función dentro del estudio.

Fuente: Elaboración propia.

8.8. Métricas Comparables

Métrica	Definición operacional	Lectura de negocio
WAPE	Error absoluto agregado dividido por el ingreso real agregado.	Proporción del volumen que el forecast no representa correctamente.
MAE	Promedio del error absoluto semanal en MM USD.	Magnitud típica del desvío semanal.
RMSE	Raíz del promedio de errores cuadrados.	Penaliza especialmente semanas con MegaDeals.
sMAPE	Error porcentual simétrico.	Comparación relativa con menor dependencia de escala.
Forecast Bias	Suma del error dividida por el real.	Dirección sistemática de sobreestimación o subestimación.
Techo de WAPE	Máximo WAPE entre ventanas.	Riesgo extremo observado.
Desviación	Dispersión del WAPE entre ventanas.	Estabilidad del procedimiento.
MAE logarítmico	Pérdida uniforme sobre escala transformada.	Evita que las semanas de mayor monto dominen toda la comparación.

Cuadro 7. Métricas de evaluación y su interpretación.

Fuente: Elaboración propia.

Las definiciones del Cuadro 7 se operacionalizan sobre el valor real y el pronóstico correspondiente a cada semana. WAPE se calcula como:

$$WAPE = 100 \times \frac{\sum_{t=1}^n |y_t - \hat{y}_t|}{\sum_{t=1}^n |y_t|}$$

WAPE pondera cada error por el volumen monetario total del periodo. En una ventana trimestral, las sumas se restringen a las semanas de ese trimestre, en el WAPE agrupado se utilizan conjuntamente las 105 semanas del panel. Por ello, una semana con un Mega Deal influye de manera proporcional a su materialidad económica y no igual que una semana de bajo cierre.

MAE conserva directamente la unidad monetaria del error:

$$MAE = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|$$

En este estudio, MAE se reporta en MM USD y responde a una pregunta operativa directa: ¿cuál es la desviación absoluta semanal promedio del pronóstico? A diferencia

de WAPE, no normaliza por el volumen total, por lo que facilita traducir la magnitud típica del error a planificación financiera.

RMSE aumenta el peso de los errores de mayor magnitud mediante el cuadrado del residuo:

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}$$

Esta propiedad es especialmente relevante en una serie concentrada, porque un error asociado a un Mega Deal o a una semana de cierre recibe una penalización mayor. Por ello, RMSE complementa a MAE cuando se desea observar exposición a fallas extremas y no únicamente el error típico.

sMAPE introduce una normalización simétrica entre valor real y pronosticado:

$$sMAPE = \frac{100}{n} \sum_{t=1}^n \frac{2|y_t - \hat{y}_t|}{|y_t| + |\hat{y}_t|}$$

La normalización permite comparar el error relativo cuando la escala cambia entre semanas y trimestres. Se utiliza como métrica complementaria y no como criterio único, porque semanas cercanas a cero pueden volver inestable cualquier medida porcentual (Hyndman & Koehler, 2006).

El Forecast Bias conserva el signo del error agregado:

$$Bias = 100 \times \frac{\sum_{t=1}^n (\hat{y}_t - y_t)}{\sum_{t=1}^n |y_t|}$$

Un sesgo negativo indica subestimación acumulada y un valor positivo sobreestimación. Esta métrica es indispensable porque dos modelos pueden presentar un WAPE similar y, sin embargo, inducir decisiones distintas si uno subestima sistemáticamente el cierre esperado.

El riesgo extremo observado se resume mediante el mayor WAPE entre las Q ventanas evaluadas:

$$WAPE_{techo} = \max_{q=1, \dots, Q} \{WAPE_q\}$$

En esta tesis $Q = 8$. El techo responde a una pregunta distinta de la mediana: ¿cuál fue el peor trimestre observado bajo el protocolo común? Su inclusión evita promover un modelo con buen desempeño típico, pero con una falla severa en una ventana de alta materialidad.

La estabilidad se cuantifica mediante la desviación estándar del WAPE entre ventanas:

$$s_{WAPE} = \sqrt{\frac{1}{Q-1} \sum_{q=1}^Q (WAPE_q - \overline{WAPE})^2}$$

Una desviación menor indica que el procedimiento cambia menos su nivel de error entre trimestres. Esta medida es central para la selección operacional, porque la utilidad ejecutiva depende tanto de la precisión como de la previsibilidad del comportamiento del modelo.

Para la comparación inferencial semanal se utiliza además una pérdida absoluta sobre escala logarítmica:

$$L_t = |\log(1 + y_t) - \log(1 + \hat{y}_t)|$$

Esta pérdida reduce la dominancia de las semanas de mayor monto sin eliminarlas de la evaluación. Su función es complementaria al WAPE monetario, permite preguntar si la ventaja de un modelo persiste cuando las semanas tienen una influencia más uniforme sobre el contraste estadístico.

8.9. Inferencia y Control de Multiplicidad

Las pérdidas se comparan semanalmente sobre una transformación logarítmica para reducir la dominancia de valores extremos sin eliminar su efecto. La corrección de Newey-West considera autocorrelación en la diferencia de pérdidas. Cuando se evalúan múltiples pares, la corrección de Holm controla el error familiar y evita declarar significancia por acumulación de pruebas.

Para dos procedimientos de pronóstico, la prueba Diebold-Mariano parte de la diferencia entre sus pérdidas semanales y estandariza el promedio de esas diferencias mediante una estimación de varianza de largo plazo:

$$d_t = L_{1,t} - L_{2,t}, DM = \frac{\bar{d}}{\sqrt{\hat{var}(\bar{d})}}$$

Los dos términos de pérdida corresponden a los modelos comparados sobre la misma semana. En esta tesis, la varianza del promedio de sus diferencias se estima de forma robusta con Newey-West para reconocer dependencia temporal. Cuando el primer modelo de la comparación es SARIMAX, un estadístico negativo indica menor pérdida de SARIMAX. La corrección de Holm se aplica posteriormente sobre los p – valores cuando se realizan múltiples contrastes (Diebold & Mariano, 1995, Newey & West, 1987).

El *Model Confidence Set* se interpreta como un conjunto de modelos plausibles, no como una clasificación total. Un modelo puede permanecer en el conjunto y, al mismo

tiempo, presentar un perfil operativo menos conveniente por sesgo, techo o complejidad. La decisión final combina evidencia inferencial y criterios de negocio.

El conjunto de modelos de confianza se estima mediante *bootstrap* estacionario, preservando dependencia temporal (Politis & Romano, 1994, Hansen et al., 2011). Las comparaciones confirmatorias utilizan Diebold-Mariano con corrección de Holm. Se reporta la dirección del estadístico para evitar interpretar como mejora una diferencia estadísticamente significativa favorable a la referencia.

8.10. XAI y Escenarios

La explicación global se calcula con observaciones fuera de muestra de todas las ventanas. La estabilidad se resume mediante media y dispersión de SHAP. La explicación local se aplica a semanas con errores altos o mejoras relevantes frente a XGBoost. Las interacciones se utilizan de forma exploratoria para identificar combinaciones de rezagos, fase y señales del CRM.

Los escenarios de nivel se obtienen a partir de los factores históricos y bandas empíricas por fase. La evaluación *rolling* muestra que la cobertura total no alcanza el nivel nominal. Por esta razón, se utilizan las expresiones sensibilidad, rango descriptivo y estrés, y evita denominar intervalos de confianza o intervalos predictivos a resultados no calibrados.

La cobertura empírica de una banda delimitada por un límite inferior y uno superior se calcula como:

$$Coverage = \frac{1}{n} \sum_{t=1}^n 1 \{L_t \leq y_t \leq U_t\}$$

La función indicadora es binaria (0 y 1), vale uno (1) cuando el cierre real queda dentro de la banda y cero (0) en caso contrario. Comparar esta proporción con el nivel nominal permite decidir si el rango puede denominarse intervalo calibrado.

8.11. Metodología de Impacto Económico

El impacto observado se define como error absoluto evitado respecto del Committed. Esta métrica representa exposición de forecast reducida y no ROI realizado. Para medir crecimiento comercial se propone, como fase futura, comparar carteras tratadas y de control, registrando ingresos ganados incrementales, número de cierres adicionales, margen bruto, tasa de conversión y tiempo de ciclo.

La cuantificación se realiza comparando, sobre las mismas semanas, el error absoluto acumulado de la referencia y del modelo:

$$EA = \sum_{t=1}^n |y_t - \hat{y}_t^{(ref)}| - \sum_{t=1}^n |y_t - \hat{y}_t^{(model)}|$$

El error evitado mide reducción de error predictivo en unidades monetarias. Cuando es positivo, el modelo acumuló menos desviación absoluta que la referencia. La reducción relativa se calcula como:

$$Reducción(\%) = 100 \times \frac{EA}{\sum_{t=1}^n |y_t - \hat{y}_t^{(ref)}|}$$

Estas expresiones son las que permiten reportar la exposición al error evitada frente a Committed sin convertirla indebidamente en ahorro financiero realizado. El monto expresa cuánto disminuyó la desviación del forecast, el ROI sólo podría estimarse después de vincular prospectivamente esa mejora con decisiones, ingresos, margen o costos frente a un contrafactual, pero esos son resultados financieros, vienen posteriormente al cálculo del alcance de esta tesis.

Para separar precisión de nivel y calendarización, la brecha neta trimestral se calcula como:

$$G_q = \sum_{t \in q} \hat{y}_t - \sum_{t \in q} y_t$$

Una brecha trimestral pequeña puede coexistir con un error absoluto semanal elevado si sobreestimaciones y subestimaciones se compensan dentro del trimestre. Esta distinción es esencial en el pipeline comercial, porque acertar el total al cierre del trimestre no equivale a anticipar correctamente en qué semana se materializará el ingreso.

Con el propósito de evitar que la selección del modelo dependa de una sola métrica, la factibilidad se analiza mediante tres perfiles complementarios de decisión. El perfil de despliegue ejecutivo considera si el modelo puede ser comprendido, reproducido e integrado en la operación, el de precisión central evalúa su desempeño habitual, y el de riesgo operacional examina su comportamiento en ventanas adversas. Esta rúbrica no constituye una nueva ponderación ni reemplaza las métricas comparables, sino que organiza su interpretación conjunta de acuerdo con el uso esperado del pronóstico.

Perfil	Factibilidad alta	Factibilidad media	Factibilidad baja
Despliegue ejecutivo	Implementación reproducible, interpretable y basada en información disponible ex ante.	Requiere ajustes, monitoreo o desarrollo adicional para su uso operativo.	Evidencia exploratoria, baja trazabilidad o dependencia de información no disponible.
Precisión central	Se ubica en el tercio superior en WAPE, MAE y RMSE, sin contradicciones relevantes.	Presenta resultados intermedios o liderazgos parciales entre las métricas.	Mantiene errores elevados o un desempeño consistentemente inferior.
Riesgo operacional	Presenta bajo techo, baja dispersión y un sesgo controlado.	Exhibe estabilidad moderada o deterioro en algunas ventanas.	Presenta techo elevado, alta dispersión o un sesgo material.

Cuadro 8. Rúbrica de factibilidad por perfil de decisión

Fuente: Elaboración propia.

9. Descripción del Enfoque de Solución

La solución se organiza como un pipeline reproducible. Los datos del CRM ingresan a controles de calidad, se consolidan a nivel de oportunidad y se agregan semanalmente. El mismo conjunto temporal alimenta referencias, modelos clásicos, modelos avanzados y Machine Learning tabular. Cada salida se evalúa mediante un repositorio común de pronósticos, errores, métricas y trazabilidad, como fue explicado anteriormente.

El pipeline separa cinco capas:

1. La primera controla calidad e integridad temporal.
2. La segunda construye la serie, rezagos y covariables.
3. La tercera ejecuta modelos por familia.
4. La cuarta consolida pronósticos y métricas.
5. La quinta traduce resultados a gobierno, escenarios y decisión.

Esta separación permite repetir el proceso cuando se incorporan nuevas semanas sin reescribir la lógica completa.

La trazabilidad se mantiene mediante archivos de pronósticos semanales, métricas por ventana, tablas de inferencia, matrices SHAP y un paquete de decisión final. Cada cifra presentada en el reporte se vincula con una salida de Python ordenada en carpetas. Por lo tanto, se conservan en anexos la descripción de fuentes, etapas y limitaciones necesarias para auditar los resultados.

El enfoque evita seleccionar el modelo únicamente por una métrica. La decisión operacional pondera cuatro dimensiones: desempeño típico, riesgo extremo, estabilidad e integridad metodológica. Bajo esta regla, un *challenger* puede exhibir una mediana menor y no ser promovido si su techo es materialmente mayor o si fue seleccionado después de observar los resultados.

La arquitectura recomendada separa el forecast central, el challenger explicable, la señal Committed y la referencia Naive Seasonal. Las divergencias activan revisión humana, especialmente ante MegaDeals, cambios de régimen, baja calidad de datos o diferencias significativas entre modelos. El *ajuste experto* se registra separado de la salida cuantitativa.

Champion y *challenger* se ejecutan en paralelo sobre las mismas fuentes controladas. El *challenger* no utiliza la salida del *champion* como entrada. La divergencia se calcula después de generar ambas predicciones y se clasifica por fase, materialidad y riesgo. Esta regla evita que el modelo alternativo replique mecánicamente al central y permite evaluar si aporta información distinta.

El comité de forecast recibe el pronóstico cuantitativo, la señal Committed, las diferencias, los principales drivers y los escenarios. La revisión humana puede mantener

el forecast publicado u originar un *ajuste experto*. El *ajuste experto* se almacena como una capa separada con responsable, motivo, monto y efecto posterior, de modo que el valor del juicio pueda medirse y no quede mezclado con la salida estadística (*Ilustración 1*).

10. Resultados

10.1. Calidad de Datos y Estructura de la Serie Comercial

Los resultados del diagnóstico previo establecen las condiciones bajo las cuales debe interpretarse la comparación predictiva posterior. La serie presenta concentración en semanas de cierre, variación de amplitud entre trimestres y episodios extraordinarios fuera de la fase final, mientras que la disponibilidad histórica de determinadas covariables limita algunas especificaciones.

Por lo tanto, el análisis temporal confirma tres propiedades dominantes:

1. Primero, la serie presenta una concentración de nivel en semanas de cierre.
2. Segundo, la amplitud cambia entre trimestres, por lo que la estacionalidad no opera con magnitud constante.
3. Tercero, existen peaks fuera de la última semana, asociados a cierres extraordinarios.

Estas propiedades explican por qué un modelo debe combinar calendario, memoria y señales comerciales.

La comparación entre promedio y mediana por fase muestra una asimetría importante. En la fase de cierre, el promedio supera a la mediana debido a operaciones de alto monto. En fases ordinarias, la diferencia es menor. Esta distribución respalda el uso de métricas robustas y la evaluación del techo, porque el error promedio puede ocultar fallas en los eventos que más impactan la planificación.

La auditoría confirma una distribución altamente concentrada. El 10% de las oportunidades explica 87,3% del ingreso y las semanas de cierre concentran una parte desproporcionada del error. Esta estructura justifica el uso de WAPE como métrica primaria, pero también exige reportar RMSE, sesgo y resultados por fase para no ocultar la exposición a eventos extremos.

Las covariables del CRM no poseen el mismo nivel de disponibilidad histórica. La taxonomía de producto se encuentra completa sólo desde 2025 y la última semana de Q2/2026 contiene únicamente dos días. Estas condiciones se documentan como límites del análisis y se excluyen de afirmaciones causales.

10.2. Committed y Baselines Cuantitativos

El Committed obtiene WAPE agrupado de 74,30%, WAPE mediano de 61,41%, techo de 102,24% y desviación de 22,70 en el panel final. La combinación indica que la señal contiene información, pero su error aumenta de forma importante en determinadas ventanas. Naive Seasonal alcanza WAPE agrupado de 60,21%, lo que demuestra que repetir la posición del trimestre anterior constituye una referencia más exigente que el método cualitativo.

Este hallazgo es metodológicamente relevante, ya que el valor de un modelo no debe medirse sólo frente al proceso vigente, sino frente a una referencia estacional simple. La señal Committed se conserva porque resume conocimiento comercial, pero no debe operar como forecast autónomo.

Los resultados de estas referencias se incorporan en la comparación progresiva del apartado siguiente, donde Committed y Naive Seasonal se mantienen como puntos de contraste frente a AR, MA, ARMA, ARIMA, ARIMAX, SARIMA y SARIMAX. De esta forma, la evaluación permite determinar si el aumento de complejidad genera una mejora efectiva tanto en desempeño típico como en riesgo extremo.

10.3. Progresión AR, MA, ARMA, ARIMA, ARIMAX, SARIMA y SARIMAX

AR y MA presentan medianas de WAPE de 77,29% y 80,82%, respectivamente. Su desempeño muestra que la memoria del objetivo o la corrección de errores por separado no capturan la dinámica del pipeline. ARMA y ARIMA mejoran a medianas cercanas a 64,8%, pero mantienen autocorrelación residual y no alcanzan la referencia estacional.

El bajo aporte de AR y MA indica que la dependencia de corto plazo no es suficiente cuando se modela de manera aislada. AR mantiene una mediana alta, aunque su desviación es relativamente acotada. MA presenta un comportamiento semejante y no logra representar el aumento de nivel en cierres. ARMA reduce parte del error mediante la combinación de memoria y tendencias, pero continúa por sobre Naive Seasonal.

ARIMA mejora frente a AR y MA porque la diferenciación reduce cambios de nivel persistentes. Sin embargo, al no incorporar explícitamente la periodicidad trimestral ni covariables comerciales, su capacidad se concentra en la dinámica interna de la serie. El resultado muestra un aporte incremental real, pero insuficiente para la decisión final.

ARIMAX incorpora señales exógenas y logra una mediana competitiva, pero su techo alcanza 116,50% en la especificación ex ante con fase. Esta inestabilidad impide seleccionarlo como alternativa operacional. SARIMA obtiene una mediana de 56,01%, prácticamente equivalente a Naive Seasonal, lo que indica que la estacionalidad por sí sola reproduce el patrón, pero no agrega una ventaja sostenida.

La diferencia entre variantes contemporáneas y ex ante revela el costo de la validez operacional. Las variantes contemporáneas pueden utilizar señales más cercanas al cierre y obtener un mejor ajuste, pero no reproducen una decisión histórica. La reconstrucción ex ante reduce ese riesgo y permite evaluar un escenario productivo, aunque aumenta el error en determinadas ventanas.

SARIMA confirma que la periodicidad de 13 semanas constituye una señal relevante. Su mediana se aproxima a Naive Seasonal y mejora respecto de ARIMA. La conclusión no es que ambos modelos sean equivalentes en estructura, sino que una proporción

importante del patrón puede representarse mediante repetición estacional. SARIMAX agrega valor cuando combina esa estructura con covariables y fase.

SARIMAX combina estructura temporal, diferenciación estacional, monto Committed, pipeline estimado y variables de fase. La especificación ex ante obtiene WAPE mediano de 54,64%, techo de 67,74% y desviación de 8,55. Además, es la única familia clásica que no rechaza independencia residual en Ljung-Box a 13 rezagos, con $p=0,6253$. A 26 rezagos el resultado es marginal, $p=0,0578$, por lo que la adecuación se interpreta con cautela.

El menor techo de SARIMAX constituye su principal ventaja. La diferencia respecto de la mejor mediana es pequeña, pero la reducción del peor caso es material. El modelo presenta además una de las menores dispersiones entre ventanas y un desempeño de 36,28% en semanas de cierre. Estas propiedades son coherentes con un uso ejecutivo, donde el costo de una falla extrema puede superar la ganancia obtenida por pequeñas mejoras en semanas ordinarias.

El diagnóstico Ljung-Box no rechaza independencia residual a 13 rezagos y entrega un resultado marginal a 26. Esto no demuestra que el modelo sea perfecto, pero indica que la especificación captura una parte sustantiva de la dependencia trimestral. La interpretación se mantiene prudente debido al tamaño de muestra y a la presencia de MegaDeals.




Ilustración 10. Desempeño típico y riesgo extremo en la progresión de modelos clásicos.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

Modelo	WAPE mediano	Techo	Desviación	Interpretación
Committed	61,41%	102,24%	22,70	Señal comercial con alta variabilidad.
Naive Seasonal	56,01%	84,81%	14,07	Referencia estacional exigente.
AR	77,29%	84,43%	6,79	Memoria insuficiente.
MA	80,82%	85,92%	5,89	Corrección de error insuficiente.
ARMA	64,81%	76,44%	6,53	Mejora, pero sin estructura estacional adecuada.
ARIMA	64,61%	76,46%	6,60	Diferenciación sin ventaja material.
ARIMAX	58,78%	116,50%	23,73	Mediana competitiva con riesgo extremo alto.
SARIMA	56,01%	86,38%	14,78	Equivalente a repetir la estacionalidad.
SARIMAX ex ante con fase	54,64%	67,74%	8,55	Mejor equilibrio operacional.

Cuadro 9. Comparación de la progresión clásica en el panel principal.

Fuente: Elaboración propia.

10.4. Prophet

Prophet P3 con regresores CRM alcanza WAPE agrupado de 58,04%, mediana de 59,64%, techo de 69,37% y desviación de 14,20. El resultado es competitivo y su techo se aproxima al de SARIMAX, pero su sesgo agrupado de -40,81% refleja subestimación acumulada. Los eventos de cierre mejoran la representación de la posición trimestral, aunque no corrigen completamente la amplitud de operaciones extraordinarias.

La progresión interna de Prophet muestra que la tendencia aislada no es suficiente. La estacionalidad y los eventos de cierre reducen el error, y los regresores del CRM entregan el mejor resultado dentro de la familia. El aporte incremental, no obstante, se acompaña de un sesgo negativo elevado, lo que sugiere una subestimación sistemática del nivel agregado.




Ilustración 11. Desempeño de Prophet en validación de origen móvil.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.




Ilustración 12. Aporte incremental de los componentes de Prophet.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

10.5. Temporal Fusion Transformer y Chronos-2

TFT obtiene WAPE agrupado de 62,41%, mediana de 56,09% y techo de 134,71%. La mediana sugiere capacidad para aprender patrones, pero el techo y la desviación de 31,62 evidencian alta inestabilidad. La corta historia y la concentración de ingresos limitan la ventaja de una arquitectura de mayor capacidad.

Las distintas semillas producen variaciones materiales en ciertas ventanas. La dispersión confirma que la arquitectura aprende una señal, pero no converge a una solución suficientemente estable para el volumen de datos disponible. El resultado es coherente con la alta capacidad del modelo y con la limitada cantidad de ciclos trimestrales completos.




Ilustración 13. Dispersión del desempeño de Temporal Fusion Transformer entre semillas.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

Chronos-2 alcanza WAPE agrupado de 62,37%, mediana de 60,47% y techo de 75,30%. Su riesgo extremo es menor que el de TFT y de varios modelos tabulares, pero no supera el equilibrio de SARIMAX. Este resultado no invalida el enfoque fundacional, sino que demuestra que el preentrenamiento no elimina la necesidad de evaluar la adecuación al dominio y a la función de pérdida.

Chronos-2 reduce el peor caso frente a TFT y presenta una desviación menor. Su desempeño se mantiene, sin embargo, por debajo de SARIMAX y Prophet en el equilibrio central extremo. La variante con fase y covariables confirma que el modelo puede utilizar información contextual, pero no supera el beneficio de una especificación estadística adaptada al ciclo comercial.




Ilustración 14. Comparación del riesgo extremo de Chronos-2 y referencias.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.




Ilustración 15. Complementariedad por fase de Chronos-2 frente a otros modelos.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

10.6. Machine Learning Tabular

CatBoost obtiene la mejor mediana de WAPE del panel, 53,46%, y WAPE agrupado de 59,58%. Sin embargo, su techo llega a 100,17% y su desviación a 22,41. Como la selección corresponde a un análisis exploratorio posterior, se conserva como challenger y no reemplaza al modelo estadístico sin una nueva validación temporal independiente.

La ventaja de CatBoost se concentra en el desempeño central y en ventanas específicas. El modelo aprende interacciones entre rezagos y señales del CRM que XGBoost pondera de manera distinta. No obstante, la ventana con WAPE cercano a 100% determina un techo que duplica ampliamente el del champion. La recomendación distingue, por lo tanto, precisión central y control del riesgo.

LightGBM y CatBoost mejoran a XGBoost en el análisis post hoc, pero no superan a SARIMAX en riesgo extremo. Random Forest presenta una mediana razonable y una dispersión alta. HistGradientBoosting mejora la referencia lineal, aunque mantiene errores elevados. Elastic Net confirma que una relación lineal estable no basta para capturar peaks y cambios de fase.

LightGBM obtiene WAPE agrupado de 60,00% y XGBoost de 62,20%. Random Forest alcanza 60,65%, mientras HistGradientBoosting llega a 64,55%. Elastic Net presenta el resultado menos favorable del panel final, con WAPE de 76,55% y techo de 222,07%, lo que confirma que una relación lineal regularizada no representa adecuadamente la dinámica no lineal y concentrada del ingreso.




Ilustración 16. WAPE por ventana de modelos de Gradient Boosting y referencias.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

10.7. Comparación Final Homologable

La comparación final utiliza exactamente las ocho ventanas y las mismas 105 semanas para los modelos incluidos. Esta condición evita mezclar resultados obtenidos sobre periodos distintos. Se presentan WAPE mediano, WAPE agrupado, techo, desviación, MAE, RMSE, sMAPE, sesgo, desempeño en cierre y desempeño en semanas ordinarias.




Ilustración 17. Comparación final entre desempeño típico y riesgo extremo de todas las familias.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

El gráfico de desempeño central frente a riesgo extremo debe leerse hacia la esquina inferior izquierda: menores valores son mejores en ambos ejes. CatBoost se ubica a la izquierda por su mediana, mientras SARIMAX se posiciona en la zona de menor techo. Prophet P3 con regresores del CRM y Chronos-2 muestran fortalezas parciales, pero no dominan simultáneamente ambas dimensiones.




Ilustración 18. Panel completo de WAPE mediano y techo observado.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

El panel completo amplía la lectura del desempeño típico y del riesgo extremo para todas las familias. La dispersión observada muestra que una mediana competitiva no garantiza control del peor caso: Elastic Net, TFT y varios modelos tabulares se desplazan hacia techos elevados, mientras SARIMAX permanece en la zona de menor exposición extrema. La figura confirma, por lo tanto, que la selección final requiere evaluar conjuntamente precisión central y estabilidad entre ventanas.




Ilustración 19. Detalle de los modelos con desempeño operacional competitivo.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

Al concentrar la visualización en los modelos con desempeño operacional más competitivo, la diferencia se vuelve más interpretable. CatBoost mantiene la mejor mediana, pero con un techo cercano a 100%, Prophet y Chronos-2 controlan mejor el riesgo que otros modelos avanzados, aunque con una precisión central inferior, y Naive Seasonal conserva una referencia sólida de baja complejidad. SARIMAX se distingue por combinar una mediana competitiva con el menor techo del grupo.

Modelo	WAPE med.	WAPE agr.	Techo	Desv.	MAE MM	RMSE MM	sMAPE	Sesgo	Evidencia
SARIMAX ex ante con fase	54.64%	55.38%	67.74%	8.55	11.50	23.08	62.39%	-19.35%	Referencia
Prophet P3 con regresores CRM	59.64%	58.04%	69.37%	14.20	12.05	25.56	64.75%	-40.81%	Referencia
Chronos-2 ex ante con fase	60.47%	62.37%	75.30%	11.89	12.95	27.33	64.95%	-36.63%	Referencia
Naive Seasonal (13)	56.01%	60.21%	84.81%	14.07	12.50	25.96	62.37%	-8.61%	Referencia
CatBoost	53.46%	59.58%	100.17%	22.41	12.37	24.61	59.98%	-16.70%	Exploratorio
Committed	61.41%	74.30%	102.24%	22.70	15.43	32.23	84.87%	12.75%	Referencia
LightGBM	59.84%	60.00%	103.42%	22.22	12.46	23.88	63.11%	-12.36%	Exploratorio
XGBoost	57.18%	62.20%	107.70%	22.25	12.92	24.64	65.00%	-10.95%	Referencia
Random Forest	55.41%	60.65%	117.91%	26.85	12.60	24.60	63.06%	-19.45%	Referencia
HistGradientBoosting	60.17%	64.55%	119.77%	25.10	13.40	25.53	66.68%	-12.43%	Referencia
TFT	56.09%	62.41%	134.71%	31.62	12.96	25.48	65.79%	-16.43%	Referencia
Elastic Net	59.81%	76.55%	222.07%	57.72	15.90	41.67	71.06%	-14.71%	Referencia

Cuadro 10. Comparación cuantitativa final bajo un protocolo común.

Fuente: Elaboración propia.

Considerada junto con la rúbrica de factibilidad definida en la metodología, la comparación final muestra que el liderazgo se distribuye entre distintas métricas, pero también revela una ventaja global consistente de SARIMAX en los perfiles de precisión central y riesgo operacional, junto con una alta factibilidad de despliegue ejecutivo.

Por lo tanto, la comparación final muestra que el liderazgo se distribuye entre distintas métricas, pero también revela una ventaja global consistente de SARIMAX. El modelo obtiene el mejor resultado en cinco de las ocho medidas consideradas: WAPE agrupado, techo de error, desviación, MAE y RMSE. Además, alcanza el segundo menor WAPE mediano, con 54,64%, situándose apenas 1,18 puntos porcentuales por sobre CatBoost. Su principal fortaleza no radica, Por lo tanto, en dominar una única métrica, sino en mantener simultáneamente un error promedio competitivo, el menor deterioro en las ventanas más adversas y la mayor estabilidad entre los modelos comparados. Esta combinación resulta especialmente relevante para el contexto comercial, donde un pronóstico debe ser preciso en condiciones habituales, pero también confiable frente a periodos de mayor incertidumbre.

Frente al pronóstico Committed, que representa el criterio experto utilizado por la operación, SARIMAX reduce el WAPE agrupado desde 74,30% hasta 55,38%, el techo de error desde 102,24% hasta 67,74% y la desviación entre ventanas desde 22,70 hasta 8,55 puntos porcentuales. Asimismo, disminuye el MAE en USD 3,93 millones y el RMSE en USD 9,15 millones. CatBoost alcanza la mejor mediana y el menor sMAPE, pero su techo de 100,17% y su mayor dispersión reflejan un comportamiento menos estable, además de corresponder a evidencia exploratoria. Prophet presenta el segundo menor techo, aunque con mayor error mediano, dispersión y sesgo, Chronos-2 reduce parte de la variabilidad observada en los modelos avanzados, pero no iguala el desempeño agregado de

SARIMAX. Naive Seasonal, por su parte, conserva su valor como referencia estadística sólida y presenta un menor sesgo, sin alcanzar el mismo equilibrio entre precisión y control del riesgo. En consecuencia, la selección de SARIMAX como modelo champion no responde únicamente al promedio de error, sino a su capacidad para combinar precisión, estabilidad y protección frente a escenarios adversos, manteniendo además una estructura interpretable y extensible mediante señales comerciales disponibles ex ante.




Ilustración 20. Mapa comparativo de métricas para el panel final.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

El mapa normalizado permite observar que ningún procedimiento domina de forma simultánea todas las métricas. CatBoost concentra su fortaleza en precisión central, Naive Seasonal mantiene un comportamiento competitivo como referencia estacional y Committed pierde posición cuando se consideran error agregado y riesgo. SARIMAX presenta el perfil más equilibrado entre WAPE, techo, dispersión y desempeño por fase, lo que respalda su selección como referencia operacional sin ocultar las fortalezas parciales de los demás modelos.




Ilustración 21. Síntesis multicriterio de los cinco modelos mejor posicionados.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

El score multicriterio no reemplaza las métricas originales. Su propósito es sintetizar criterios cuantitativos y una rúbrica de factibilidad para tres perfiles de decisión: despliegue ejecutivo, precisión central y riesgo operacional. SARIMAX ocupa el primer lugar en los tres perfiles. Naive Seasonal aparece segundo por su estabilidad y baja complejidad, mientras CatBoost se ubica tercero debido a su mejor mediana y mayor exposición extrema.

El ranking no implica que Naive Seasonal deba reemplazar modelos más informativos. Su posición demuestra que una referencia simple puede ser operacionalmente valiosa y que cualquier arquitectura compleja debe justificar su costo. CatBoost, Prophet P3 y LightGBM mantienen utilidad como challengers o diagnósticos, especialmente cuando sus divergencias coinciden con cambios de pipeline.

En consecuencia, la selección de SARIMAX como modelo champion responde a su mejor equilibrio entre precisión central, control del riesgo operacional y factibilidad de despliegue ejecutivo, además de mantener una estructura interpretable y extensible mediante señales comerciales disponibles ex ante.

10.8. Evidencia Inferencial

En pérdida semanal logarítmica, SARIMAX supera al Committed con estadístico Diebold-Mariano de -3,903 y p de Holm de 0,0019. La dirección negativa indica menor pérdida del modelo. CatBoost supera a XGBoost en una sensibilidad exploratoria, con p de Holm de 0,0407. CatBoost no supera

de forma sostenible a SARIMAX como reemplazo operacional, debido a su mayor techo y a su estatus de selección posterior.




Ilustración 22. Conjunto de confianza de modelos bajo bootstrap estacionario.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

La prueba confirmatoria utiliza pérdidas semanales y no totales trimestrales. Esta elección aumenta el número de observaciones, pero requiere controlar dependencia temporal. El signo negativo del estadístico favorece a SARIMAX porque la pérdida del modelo es menor que la del Committed. La corrección de Holm mantiene la conclusión después de considerar comparaciones múltiples.

El Model Confidence Set conserva modelos que no pueden eliminarse con la evidencia disponible. La pertenencia al conjunto no transforma a todos los modelos en equivalentes desde el punto de vista operacional. El techo, el sesgo y la factibilidad siguen siendo necesarios para seleccionar el champion.

La comparación entre SARIMAX y Naive Seasonal no entrega separación estadística considerable en todos los contrastes. Este resultado se declara de forma explícita. El aporte principal de SARIMAX se encuentra en reducir el riesgo extremo y la dispersión, no en demostrar una superioridad universal sobre toda referencia estacional.

Afirmación	Resultado	Estadístico	Alcance
SARIMAX supera a Committed en pérdida semanal logarítmica	True	DM= -3.903, Holm=0.0019	Confirmatorio dentro del panel
CatBoost supera a XGBoost	True	DM= -2.763, Holm=0.0407	Sensibilidad post hoc
CatBoost supera a SARIMAX	False	No existe separación significativa, el techo es mayor	No sostenible como reemplazo operacional

Cuadro 11. Evidencia inferencial clave y alcance de las conclusiones.

Fuente: Elaboración propia.

10.9. Explicabilidad y SHAP Values

La explicación global de CatBoost muestra que los rezagos de 26 y 13 semanas concentran la mayor contribución. A continuación, aparecen el conteo y monto de pipeline estimado, el Committed, la razón entre rezagos y la fase del trimestre. En conjunto, las variables asociadas al CRM representan 28,78% de la importancia agregada y los rezagos 33,11%.




Ilustración 23. Importancia global SHAP del modelo CatBoost fuera de muestra.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

El rezago de 26 semanas concentra 26,2% de la magnitud SHAP promedio del conjunto mostrado, seguido por el rezago de 13 semanas con 16,7%. La importancia de ambos rezagos confirma que el modelo utiliza patrones trimestrales y semestrales. Los conteos y montos del pipeline y del Committed complementan esa memoria con una lectura del estado comercial.




Ilustración 24. Distribución de efectos SHAP y dirección de las contribuciones.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

Los SHAP Values muestran que el modelo se apoya principalmente en la memoria comercial de 13 y 26 semanas. Valores altos de lag_13 y lag_26 aumentan el pronóstico, mientras que valores bajos lo reducen, confirmando la presencia de patrones trimestrales y semestrales. Las señales reconstruidas ex ante desde el CRM siguen una dirección similar: mayores conteos y montos de pipeline estimado y Committed contribuyen positivamente, mientras que niveles bajos disminuyen la predicción. Entre estas variables, el conteo del pipeline estimado presenta el efecto más amplio, seguido por el conteo de Committed y sus respectivos montos.

En cambio, valores altos de lag_1, ratio_lag1_roll13 y delta_1_13 tienden a reducir el forecast, lo que sugiere una corrección después de semanas recientes excepcionalmente altas, en lugar de proyectar su crecimiento de manera automática. Las variables de fase y calendario modifican la dirección de las contribuciones según la posición de la semana dentro del ciclo comercial, mientras que ratio_committed_pipeline_exante presenta efectos más acotados y dependientes de otras variables. En conjunto, los SHAP Values muestran que el modelo combina memoria estacional, señales comerciales disponibles ex ante y ajustes de corto plazo. Estas contribuciones explican el mecanismo predictivo sobre la escala logarítmica, pero no representan relaciones causales ni variaciones porcentuales directas del pronóstico.




Ilustración 25. Concordancia de rankings de variables entre CatBoost y XGBoost.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

La correlación de Spearman de 0,713 muestra una concordancia positiva y relevante, aunque no completa, entre los rankings de importancia de CatBoost y XGBoost. Ambos modelos sitúan lag_26 y lag_13 entre las variables más influyentes, lo que confirma que la memoria trimestral y semestral constituye un componente central compartido. También existe una valoración relativamente similar de los montos de pipeline estimado y Committed, el conteo de Committed, la fase comercial y la relación entre el último cierre y su promedio móvil.

Las principales diferencias muestran que CatBoost asigna mayor importancia al conteo del pipeline estimado, ubicado en el puesto 3 frente al 20 de XGBoost, a la brecha monetaria ex ante, situada en los puestos 9 y 22, respectivamente, y al componente cíclico mensual, clasificado en los puestos 15 y 29. XGBoost, en cambio, prioriza la media móvil de 13 semanas, ubicada en el puesto 5 frente al 19 de CatBoost, y la desviación móvil de 26 semanas, situada en los puestos 11 y 26. Esto sugiere que CatBoost se apoya relativamente más en señales comerciales y de calendario, mientras XGBoost otorga mayor peso a los estadísticos temporales. La concordancia, Por lo tanto, refleja una estructura predictiva común, pero también mecanismos diferentes para combinar la información. Los

rankings expresan importancia relativa, no la dirección ni la magnitud de las contribuciones, por lo que deben interpretarse junto con los SHAP Values.




Ilustración 26. Importancia normalizada de variables en CatBoost y XGBoost.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

La comparación normalizada entre CatBoost y XGBoost muestra una base explicativa parcialmente común, dominada por los rezagos de 13 y 26 semanas, pero también diferencias relevantes en la ponderación de señales del CRM y estadísticas móviles. CatBoost asigna mayor peso relativo a algunas variables de conteo y pipeline, mientras XGBoost concentra más importancia en determinadas señales monetarias y móviles. La divergencia confirma que dos modelos entrenados con el mismo conjunto de variables pueden construir mecanismos predictivos distintos.




Ilustración 27. Participación SHAP por familia de variables.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

La agregación por familias refuerza esa lectura. En CatBoost, los rezagos del objetivo representan 33,11% de la importancia agregada y las variables ex ante del CRM 28,78%, de modo que la predicción combina memoria temporal con información comercial contemporánea disponible antes del cierre. Las estadísticas móviles, el calendario y la dinámica reciente completan la explicación, pero con una participación menor y más sensible al trimestre.




Ilustración 28. Estabilidad de drivers CatBoost entre ventanas.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

La estabilidad entre ventanas es mayor para los principales drivers de CatBoost que para variables secundarias. Lag 26 y lag 13 permanecen en posiciones superiores, mientras funciones de calendario y estadísticos móviles varían según el trimestre. El monitoreo productivo debería revisar tanto el valor de las variables como la persistencia de su importancia.




Ilustración 29. Explicación local de CatBoost para una semana de cierre de Q1/2026.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

La explicación local de la semana de cierre de Q1/2026 muestra cómo la predicción resulta de contribuciones simultáneas y no de una única variable. El conteo estimado de pipeline, los rezagos de 26 y 13 semanas, el conteo Committed y la condición de semana de cierre empujan el log-forecast al alza, mientras algunas variables cíclicas y estadísticas móviles compensan parcialmente ese efecto. El caso evidencia la utilidad de SHAP para reconstruir una decisión puntual y detectar qué señales sostienen una divergencia relevante.




Ilustración 30. Drivers que explican la principal mejora de CatBoost frente a XGBoost.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

La comparación de contribuciones para la ventana donde CatBoost mejora más frente a XGBoost muestra que la ventaja no proviene de un driver aislado. El modelo redistribuye el peso entre memoria estacional, conteos del CRM, fase y señal de cierre, mientras otras variables reducen su contribución relativa. Esta descomposición permite explicar la mejora observada sin interpretarla como causalidad, se trata de diferencias en la forma en que cada algoritmo combina la misma información disponible.




Ilustración 31. Interacciones estructurales principales estimadas para CatBoost.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

Las interacciones estimadas muestran que los principales efectos no son puramente aditivos. Las combinaciones entre lag 26 y lag 3, entre lag 26 y la razón respecto de la media móvil, y entre rezagos de corto y largo plazo concentran los mayores puntajes de interacción. En términos de negocio, CatBoost utiliza simultáneamente posición temporal, memoria trimestral y dinámica reciente para ajustar la predicción, lo que explica parte de su capacidad para capturar configuraciones que un modelo lineal no representa de forma explícita.

10.10. Complementariedad por Fase del Trimestre

SARIMAX presenta su mayor ventaja relativa en semanas de cierre, con WAPE de 36,28%, mientras CatBoost obtiene 47,06%. Fuera del cierre, ambos modelos presentan errores mayores y más cercanos. Esta diferencia respalda una arquitectura complementaria: SARIMAX como forecast central y CatBoost como diagnóstico de divergencias y drivers.

Naive Seasonal obtiene el menor WAPE en semanas de cierre dentro de la comparación visual, pero su desempeño en semanas ordinarias es más débil. SARIMAX se mantiene competitivo en ambas fases y reduce el riesgo extremo total. CatBoost y Prophet P3 concentran su utilidad en semanas ordinarias y en la explicación de señales del CRM. Esta distribución respalda una arquitectura que utiliza referencias con roles diferentes en lugar de forzar un único modelo para todas las condiciones.




Ilustración 32. Complementariedad entre modelos en semanas ordinarias y semanas de cierre.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

La fase también afecta la interpretación del error. Un mismo error absoluto representa una proporción mayor en semanas de bajo nivel, mientras una operación extraordinaria puede dominar el total en cierre. La combinación de WAPE por fase y error monetario permite evitar conclusiones contradictorias.

10.11. Incertidumbre y Escenarios




Ilustración 33. Relación entre cobertura fuera de muestra y amplitud de las bandas.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

Las bandas empíricas presentan una amplitud cercana a USD 39 millones, frente a aproximadamente USD 62 millones bajo el supuesto de normalidad, lo que representa una reducción de 37%. Aunque su cobertura dentro de la muestra se aproxima al nivel nominal del 80%, fuera de muestra disminuye a cerca del 73%, mientras que la banda normal alcanza aproximadamente el 77%. Esto evidencia que el menor ancho de la banda empírica mejora su precisión aparente, pero reduce su capacidad para contener resultados futuros. La operación extraordinaria registrada en la semana de cierre de Q2/2026 quedó fuera del rango estimado, mostrando que los errores históricos no representan adecuadamente eventos extremos. Por esta razón, las bandas se utilizan como escenarios de sensibilidad y estrés para apoyar la planificación, y no como intervalos predictivos con una probabilidad de cobertura calibrada.




Ilustración 34. Sensibilidades de escenario para SARIMAX en Q2/2026.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

En SARIMAX, el pronóstico reproduce razonablemente el nivel de varias semanas de baja actividad y anticipa el aumento de los cierres hacia el final del trimestre. Sin embargo, distribuye parte de ese crecimiento en semanas anteriores, generando sobreestimaciones en algunos puntos intermedios de mayo y junio, mientras los cierres reales permanecen bajos. En la última semana, el pronóstico puntual aumenta hasta aproximadamente USD 170 millones y el escenario base se acerca a USD 187 millones, frente a un cierre real superior a USD 210 millones. Esto muestra que el modelo identifica correctamente el momento de la concentración comercial, pero subestima la magnitud de la operación extraordinaria.

La envolverte se amplía a medida que se aproxima el cierre trimestral, reflejando una mayor sensibilidad esperada, pero el valor real de la última semana supera incluso su límite superior. Por lo tanto, los escenarios permiten representar trayectorias adversas y favorables, evaluar sensibilidad y dimensionar situaciones de estrés, pero no capturan completamente eventos extremos que no están representados en la historia. Su interpretación debe ser descriptiva y operacional, no probabilística ni equivalente a un intervalo predictivo con cobertura garantizada.




Ilustración 35. Sensibilidades de escenario para CatBoost en Q2/2026.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

CatBoost reproduce razonablemente las semanas de baja actividad y reconoce los principales momentos de aumento dentro del trimestre. Sin embargo, tiende a anticipar parte de los cierres antes de que ocurran. En mayo, por ejemplo, el pronóstico puntual se aproxima a USD 49 millones y el escenario base a USD 60 millones, frente a un cierre real cercano a USD 28 millones. Este comportamiento indica que el modelo distribuye parte de lo esperado del cierre entre semanas intermedias, mientras la serie real mantiene montos bajos y concentra una proporción mayor al final del trimestre.

En la última semana, CatBoost identifica correctamente la dirección ascendente, pero subestima ampliamente su magnitud: el pronóstico puntual alcanza aproximadamente USD 116 millones y el escenario base cerca de USD 92 millones, frente a un valor real superior a USD 210 millones. La operación extraordinaria también supera con amplitud el límite superior de la envolvente, demostrando que las sensibilidades construidas con el comportamiento histórico no representan adecuadamente eventos extremos. Por lo tanto, los escenarios resultan útiles para analizar variaciones habituales y tensiones moderadas, pero requieren mecanismos complementarios para gestionar Mega Deals o concentraciones extraordinarias. La envolvente debe interpretarse como una representación descriptiva de sensibilidad y estrés, no como un intervalo probabilístico con cobertura garantizada.




Ilustración 36. Sensibilidades de escenario para la señal Committed en Q2/2026.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

La señal Committed aproxima razonablemente varias semanas de baja actividad y representa adecuadamente el cierre intermedio de mayo. Sin embargo, concentra su principal expectativa hacia fines de abril, cuando el pronóstico puntual alcanza aproximadamente USD 132 millones y el escenario base cerca de USD 121 millones, frente a un cierre real cercano a USD 34 millones. La amplitud de la envolvente en esa semana, que se extiende aproximadamente entre USD 80 millones y USD 210 millones, muestra que la principal incertidumbre no se relaciona solamente con el monto, sino también con el momento en que las oportunidades podrían materializarse. Este patrón es consistente con desplazamientos de fecha o con oportunidades comprometidas que no cerraron según lo esperado, aunque la agregación semanal no permite atribuir la diferencia a un negocio específico.

En la última semana ocurre el comportamiento contrario: el cierre real supera los USD 210 millones, mientras el pronóstico puntual de Committed se aproxima a USD 72 millones y el escenario base a USD 30 millones. La señal reconoce parcialmente un aumento hacia el cierre, pero subestima de manera considerable su concentración y magnitud, sin que la envolvente alcance a contener la operación extraordinaria. El resultado confirma que Committed aporta información ex ante valiosa sobre negocios identificados por la gestión comercial, pero su precisión depende de la actualización de etapas, montos y fechas esperadas de cierre. Por ello, resulta más adecuado utilizarlo como referencia experta y señal complementaria dentro del modelamiento que como un forecast autónomo. La envolvente representa sensibilidad operacional y no un intervalo predictivo con cobertura probabilística garantizada.




Ilustración 37. Bandas empíricas de error por fase del trimestre.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

Las bandas empíricas muestran que el error entre *Committed* y el resultado real no permanece constante durante el trimestre. En las semanas iniciales, la mediana se sitúa cerca de cero y la banda es acotada, lo que refleja una correspondencia relativamente equilibrada entre ambas magnitudes. En la fase media aumenta la dispersión, especialmente hacia valores positivos, aunque el error típico continúa próximo a cero. En las semanas finales previas al cierre, la distribución se extiende principalmente hacia valores negativos, evidenciando un mayor riesgo de que el resultado real supere la señal anticipada.

La semana de cierre presenta el cambio más marcado: el 80% central de los errores se ubica por encima de cero y la mediana alcanza aproximadamente 37 MM USD, lo que indica una tendencia histórica de *Committed* a sobreestimar el resultado efectivo en esta fase. No obstante, el cierre extraordinario de Q2/2026 produjo el comportamiento contrario y quedó fuera de este patrón. Por ello, las bandas permiten identificar sesgos diferenciados por fase, pero no aseguran cobertura frente a operaciones atípicas.




Ilustración 38. Trayectoria acumulada de sensibilidades SARIMAX durante Q2/2026.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

En Q2/2026, los rangos adverso y favorable ilustran cómo cambios de nivel pueden modificar la trayectoria. Las líneas se cruzan semana a semana y no constituyen cuantiles ordenados. Por este motivo, el escenario base se interpreta como una trayectoria ajustada y las envolventes como estrés descriptivo.

La trayectoria acumulada de SARIMAX permite separar la lectura semanal de la lectura trimestral. Durante buena parte del trimestre, el real acumulado permanece entre las trayectorias de estrés, pero las diferencias se amplifican al acercarse al cierre. El gráfico evidencia que una sensibilidad útil debe analizar no sólo el punto semanal, sino también cómo los desvíos se acumulan y modifican la expectativa total del trimestre.




Ilustración 39. Cobertura rolling de sensibilidades por ventana.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

La cobertura rolling confirma que el ancho de una banda no puede evaluarse de forma independiente. SARIMAX entrega el mayor ancho mediano y una cobertura de 20%, mientras CatBoost y Committed presentan coberturas nulas bajo los rangos construidos. El resultado no implica que SARIMAX disponga de un intervalo probabilístico adecuado, indica que sus sensibilidades históricas cubren más casos a costa de una amplitud mayor.

La cobertura rolling varía materialmente entre ventanas y entre procedimientos, sin converger a un nivel nominal estable. Esta inestabilidad confirma que los rangos construidos no deben comunicarse como intervalos predictivos calibrados. En operación, su función es ofrecer una referencia de sensibilidad que debe recalibrarse con nuevos trimestres y contrastarse continuamente contra el resultado real.

10.12. Lectura descriptiva de Q2/2026

El trimestre Q2/2026 registra cierres reales por 365,44 MM USD. SARIMAX proyecta 354,30 MM USD, con una brecha neta de -11,14 MM USD, WAPE de 38,66% y sesgo de -3,05%. CatBoost proyecta 273,68 MM USD y Committed 282,40 MM USD. La comparación es descriptiva porque el trimestre fue consultado durante el desarrollo y no se utiliza como única base inferencial.

La cercanía del total trimestral de SARIMAX no elimina el error de calendarización semanal. El error absoluto acumulado alcanza 141,29 MM USD, aunque la brecha neta es de -11,14 MM USD. Esta diferencia demuestra que sobreestimaciones y subestimaciones se compensan en el agregado. La lectura ejecutiva debe utilizar ambas cifras: la brecha para nivel trimestral y el error semanal para planificación de la trayectoria.




Ilustración 40. Ingresos reales y pronósticos agregados para Q2/2026.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

Modelo	Forecast MM	Error abs. MM	Brecha neta MM	WAPE	Sesgo	Reducción vs. Committed
CatBoost	273.68	167.16	-91.77	45.74%	-25.11%	43.90%
Committed	282.40	297.99	-83.04	81.54%	-22.72%	0.00%
SARIMAX ex ante con fase	354.30	141.29	-11.14	38.66%	-3.05%	52.59%

Cuadro 12. Resultados descriptivos de Q2/2026.

Fuente: Elaboración propia.

Los resultados descriptivos de Q2/2026 muestran que SARIMAX ex ante con fase alcanza el desempeño más equilibrado entre precisión semanal y ajuste trimestral. Su pronóstico de 354,30 MM USD se aproxima al resultado real de 365,44 MM USD, con una brecha de -11,14 MM USD y un sesgo de -3,05%. Además, registra el menor error absoluto acumulado, con 141,29 MM USD, y el WAPE más bajo, con 38,66%, lo que representa una reducción del error de 52,59% frente a Committed. CatBoost también mejora la precisión semanal, pero subestima el total trimestral en 91,77 MM USD, incluso más que Committed. En consecuencia, SARIMAX no sólo distribuye mejor los montos entre semanas, sino que también reproduce con mayor precisión el nivel agregado del trimestre. Este resultado es descriptivo y complementa, sin sustituir, la evidencia obtenida mediante validación temporal fuera de muestra.




Ilustración 41. Error semanal acumulado y brecha neta trimestral.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

La precisión trimestral y la precisión semanal representan dimensiones distintas del desempeño predictivo. Una brecha neta reducida puede coexistir con errores semanales relevantes cuando las sobreestimaciones y subestimaciones se compensan al finalizar el trimestre. Las diferencias de error sustentan la selección de SARIMAX. Frente a CatBoost, reduce el error absoluto semanal acumulado en 25,87 MM USD y disminuye la brecha trimestral en 80,63 MM USD, frente a Committed, estas reducciones alcanzan 156,70 MM USD y 71,90 MM USD, respectivamente. CatBoost mejora la distribución semanal respecto del criterio experto, pero conserva una subestimación trimestral elevada. SARIMAX, en cambio, obtiene simultáneamente el menor error semanal y la menor desviación respecto del total real, además de reducir el WAPE en 7,08 puntos porcentuales frente a CatBoost y en 42,88 puntos frente a Committed. Estas brechas muestran que su elección no depende sólo de aproximar el total trimestral, sino de mantener una trayectoria semanal comparativamente más precisa y con menor sesgo acumulado.

11. Impacto de Negocio y Ecosistema Analítico Comercial

11.1. Impacto Cuantificado sobre el Error de Forecast

El impacto observado se expresa como exposición al error evitada frente al Committed. En las 105 semanas del panel, SARIMAX reduce 412,55 MM USD de error absoluto, equivalente a 25,46%. CatBoost reduce 321,04 MM USD, equivalente a 19,82%. Estas cifras representan mejora de precisión y no flujo de caja capturado. Su valor se encuentra en disminuir la incertidumbre con la que se toman decisiones.

La mejora puede afectar planificación financiera, priorización de preventa, revisión de oportunidades y asignación de esfuerzos. Sin embargo, para convertirla en crecimiento realizado se necesita demostrar que una decisión modificada por el forecast produce cierres adicionales o protege ingresos. La tesis propone esa medición como una fase posterior y no la incorpora dentro del impacto realizado.




Ilustración 42. Reducción histórica de error absoluto frente a Committed.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

En el panel histórico, SARIMAX reduce el error absoluto acumulado en 412,55 MM USD frente al Committed, equivalente a 25,46%. Prophet con regresores del CRM reduce 354,67 MM USD, CatBoost 321,04 MM USD y LightGBM 311,90 MM USD. Estas cifras representan exposición de forecast reducida. No deben interpretarse como ingresos adicionales ni como ahorro contable realizado.




Ilustración 43. Sensibilidad ilustrativa del error de forecast potencialmente reducido.

Fuente: Elaboración propia. La sensibilidad no representa ROI ni ingresos realizados.

En Q2/2026, SARIMAX evita 156,70 MM USD de error absoluto frente al Committed, lo que equivale a una reducción descriptiva de 52,59%. El beneficio operativo potencial se relaciona con una mejor anticipación de brechas, una asignación más oportuna de capacidad comercial y una menor dependencia de correcciones de cierre.

11.2. Desde la Precisión Predictiva al Crecimiento Medible

La ruta hacia crecimiento comienza con una decisión accionable. Una divergencia alta puede activar revisión de pipeline, actualización de fecha, reasignación de capacidad, escalamiento de una dependencia o intervención sobre una cuenta. Cada acción debe registrarse junto con la oportunidad, el responsable, el momento y el resultado. Sin esta trazabilidad, el modelo puede mejorar el forecast sin demostrar un efecto comercial.

El diseño recomendado utiliza grupos de tratamiento y comparación definidos antes de la intervención. Los ingresos ganados incrementales se estiman como diferencia entre el resultado observado de la cartera tratada y un contrafactual comparable. El análisis debe controlar mix de cuentas, tamaño de oportunidad, unidad comercial, etapa y trimestre, además de separar ingresos, margen y tiempo de ciclo.

La reducción de error puede mejorar decisiones, pero no demuestra por sí sola que existan nuevos cierres ganados. Para cuantificar crecimiento se requiere un piloto prospectivo. Las unidades comparables pueden asignarse a un grupo de tratamiento que utilice las recomendaciones analíticas y a un grupo de control que mantenga el proceso vigente. La diferencia ajustada permite estimar ingreso ganado incremental y número de cierres atribuibles a la intervención.

Esto se resume de la siguiente manera:

Indicador	Fórmula de medición	Propósito
Ingresos ganados incrementales	Ingresos ganados del grupo tratado menos contrafactual estimado del grupo control.	Cuantificar crecimiento atribuible.
Cierres incrementales	Número de oportunidades ganadas en tratamiento menos número esperado en control.	Medir volumen adicional de negocios.
Lift de conversión	Tasa de cierre tratada menos tasa de cierre control.	Evaluar efectividad comercial.
Margen incremental	Margen bruto de cierres incrementales menos costo de intervención.	Evitar maximizar ingresos sin rentabilidad.
Tiempo de ciclo	Días promedio desde calificación hasta cierre.	Medir aceleración comercial.
Error de forecast evitado	Error absoluto Committed menos error absoluto del modelo.	Medir calidad predictiva.
Adopción y ajuste experto	Uso de recomendaciones, frecuencia y resultado de ajustes humanos.	Evaluar cambio de comportamiento y control.

Cuadro 13. Marco propuesto para medir crecimiento y valor comercial.

Fuente: Elaboración propia.

11.3. Ecosistema de Modelos Comerciales Vigentes



Ilustración 44. Ecosistema analítico comercial y conexión con el forecast de ingresos.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

El forecast responde cuánto y cuándo podría cerrarse como ganado. Los modelos complementarios responden dónde actuar. Propensión de compra prioriza oportunidades con alta probabilidad ponderada a cierre, Fuga de Clientes identifica Clientes con mayor riesgo de pérdida en cierres, Upselling y Crossselling estiman expansión de venta por productos adicionales o complementos de la oferta actual, Reactivación de Clientes identifica demanda potencial en Clientes inactivos en los últimos 12 a 24 meses, Modelo de Priorización Comercial que identifica Clientes con mayores ingresos anuales y, Segmentación y Clasificación de Clientes identifica los Clientes con mayor potencial de cierres en los últimos 3 años. La combinación permite pasar desde una proyección agregada hacia una cartera de acciones con valor esperado.

La integración debe mantener separadas las unidades de análisis. El forecast opera semanalmente a nivel agregado, mientras los modelos comerciales operan a nivel de cuenta u oportunidad. Una capa de orquestación puede sumar señales, pero no debe mezclar probabilidades y montos sin calibración. El resultado final debe conservar trazabilidad desde la recomendación hasta el ingreso observado.

El forecast agrega la perspectiva temporal de ingresos, pero no cubre todas las decisiones del ciclo comercial. Estas capacidades se consideran complementarias y ya abordadas como problemáticas analíticas dentro del Ecosistema Comercial de Data Analytics Corporativo. La tesis no reestima sus métricas ni las incorpora al benchmark de forecasting. Su integración futura permitirá que la señal agregada de ingresos se conecte con decisiones concretas sobre dónde proteger, acelerar, expandir o recuperar negocio.

Modelo complementario	Pregunta que responde	Contribución al forecast y a la gestión
Propensión de compra	¿Qué oportunidades presentan mayor probabilidad de cierre?	Prioriza esfuerzos que pueden transformar pipeline en ingresos.
Fuga de Clientes	¿Qué ingresos recurrentes presentan riesgo de pérdida?	Incorpora riesgo defensivo y protege la base.
Upselling y Cross Selling	¿Dónde existe espacio de expansión?	Genera potencial adicional por cuenta y portafolio.
Reactivación	¿Qué Clientes inactivos pueden volver a comprar?	Recupera demanda y amplía cobertura comercial.
Priorización Comercial	¿Cuáles son el Top de Clientes con Mayores ingresos en cierres?	Identificación de Clientes que brindan los mayores ingresos anuales
Segmentación y Clasificación de Clientes	¿Cuál es la Categoría Tier a la que pertenece un Cliente?	Consolida la perspectiva de foco Estratégico de Clientes con mayores Cierres en los últimos 3 años
Forecasting multi escenario	¿Cuánto ingreso podría cerrarse y cuándo?	Consolida la perspectiva temporal y la incertidumbre.

Cuadro 14. Complementariedad funcional del ecosistema analítico.

Fuente: Elaboración propia.

12. Discusión de Resultados

12.1. Time Series Analysis y Estructura del Problema

Los resultados confirman que el problema comercial está determinado por una estructura temporal específica. La periodicidad trimestral es visible, pero su amplitud cambia y coexiste con operaciones extraordinarias sin periodicidad y alto impacto llamados Mega Deals. Esta combinación explica por qué Naive Seasonal constituye una referencia fuerte y, al mismo tiempo, por qué SARIMAX agrega valor mediante covariables y fase.

La diferencia entre error semanal y brecha trimestral es uno de los hallazgos más importantes. Un modelo puede aproximar el total y fallar en la calendarización, lo que limita su utilidad para capacidad y seguimiento. La evaluación conjunta de WAPE, MAE, sesgo y brecha evita seleccionar una solución que sólo compensa errores al final del trimestre.

12.2. Complejidad, Generalización y Disponibilidad de Datos

La comparación no respalda la idea de que mayor complejidad garantiza mejor desempeño. TFT aprende patrones útiles, pero presenta alta variabilidad, Chronos-2 entrega un benchmark competitivo, aunque no domina a SARIMAX, y los modelos de boosting mejoran el desempeño central con un riesgo extremo superior. Las características de los datos aconsejan utilizar una especificación parsimoniosa y coherente con el contexto analizado, con el fin de reducir el riesgo de sobreajuste (overfitting).

Este resultado no debe generalizarse a otras organizaciones o frecuencias. Con más trimestres, series por unidad comercial, mejores snapshots históricos y covariables estables, los modelos avanzados podrían mejorar. La recomendación es dinámica: SARIMAX es champion bajo la evidencia actual y CatBoost es challenger sujeto a nueva validación.

12.3. Explicabilidad y Lectura Comercial

SHAP identifica como relevantes la memoria de 13 y 26 semanas y las señales provenientes del CRM. Esta evidencia coincide con los patrones observados mediante las funciones de autocorrelación total y parcial, ACF y PACF, que permiten evaluar la relación de los cierres actuales con sus valores anteriores. La convergencia entre ambos enfoques aporta coherencia al análisis, pero no demuestra relaciones causales. Es por esto que las decisiones comerciales deben complementarse con reglas de negocio, evidencia del proceso y evaluación posterior de sus resultados.

La divergencia entre CatBoost y XGBoost demuestra que la explicación depende del modelo. Una narrativa ejecutiva no debería presentar una única importancia como verdad del negocio. El monitoreo de rankings, estabilidad y casos locales ofrece una lectura más responsable y permite detectar cambios de forma dinámica en los modelos implementados o desarrollados.

12.4. Alcance del Impacto Económico

El error evitado cuantifica una mejora real del sistema de forecast, pero no constituye ROI. La tesis mantiene esta frontera para evitar sobreestimar el aporte. El beneficio económico potencial

surge cuando la organización utiliza la mejora para modificar decisiones y esas decisiones producen ingresos o margen adicionales frente a un futuro condicional.

La integración con modelos de Propensión, Fuga, Expansión de venta (Up y Cross Selling), Reactivación, Priorización Comercial y Segmentación y Clasificación de Cuentas ofrecen una ruta para construir ese esquema de trabajo en la Gestión Comercial que permita madurar la capacidad analítica actual. Por lo tanto, el forecast puede identificar el momento y el volumen de riesgo, mientras los modelos de oportunidad priorizan dónde intervenir. La combinación debe probarse mediante piloto y gobierno de datos comercial.

13. Conclusiones y Recomendaciones

La investigación demuestra que una comparación válida de forecasting comercial debe comenzar por la estructura de la serie temporal y no por la selección anticipada de un algoritmo. La concentración de cierres en posiciones específicas del trimestre, la periodicidad aproximada de 13 semanas, los cambios de nivel entre periodos y la presencia de Mega Deals condicionan la construcción de variables, las transformaciones y las métricas de evaluación. Este diagnóstico permite que la progresión de modelos responda a una pregunta analítica común y evita interpretar la complejidad como una mejora por sí misma.

La progresión AR, MA, ARMA, ARIMA, ARIMAX, SARIMA y SARIMAX permite identificar el aporte incremental de memoria, innovaciones, diferenciación, estacionalidad y covariables. AR y MA resultan insuficientes cuando estos mecanismos se analizan por separado, ARMA y ARIMA mejoran la representación de la dinámica interna, pero no incorporan adecuadamente la estructura trimestral, ARIMAX añade señales comerciales relevantes, aunque con mayor inestabilidad, SARIMA confirma la importancia de la periodicidad, y SARIMAX integra finalmente dinámica temporal, estacionalidad, señales comerciales ex ante y variables de fase con el mejor control de riesgo entre las familias clásicas evaluadas.

SARIMAX ex ante con fase es, por tanto, el modelo recomendado por su equilibrio operacional y no por una supuesta superioridad universal. Obtiene WAPE agrupado de 55,38%, WAPE mediano de 54,64%, techo de 67,74% y desviación de 8,55. El WAPE mediano continúa siendo elevado en términos absolutos y no debe interpretarse como una precisión alta ni como una tasa de acierto equivalente. Su valor se encuentra en la robustez relativa frente a un proceso comercial difícil de pronosticar, donde el error está concentrado y la magnitud de los cierres puede variar abruptamente entre trimestres.

La principal fortaleza de SARIMAX se encuentra en la combinación de desempeño típico, control del peor caso y estabilidad. Frente a referencias con mayor exposición a fallas extremas, el modelo presenta un techo de WAPE más acotado y una dispersión menor entre ventanas. A ello se suma un WAPE de 36,28% en semanas de cierre, precisamente la fase con mayor materialidad para la planificación comercial. Esta evidencia fortalece su selección como champion operacional, porque una falla extrema en un trimestre de alta exposición puede ser más perjudicial que una diferencia reducida en la métrica central.

La especificación también presenta una fortaleza de validez operacional. Las señales de Committed, pipeline estimado y variables de fase se utilizan bajo disponibilidad ex ante, evitando que información conocida sólo después del horizonte contamine la evaluación histórica. Este criterio puede reducir el ajuste retrospectivo en algunas ventanas, pero aumenta la credibilidad del resultado porque aproxima las condiciones bajo las cuales el forecast debería funcionar en producción.

El diagnóstico residual a 13 semanas aporta evidencia adicional a favor de la especificación. La prueba de Ljung-Box entrega $p=0,6253$ a 13 rezagos, por lo que no existe evidencia estadística suficiente para rechazar la ausencia de autocorrelación residual conjunta dentro de un ciclo trimestral aproximado. Este resultado es consistente con que SARIMAX captura una parte sustantiva de la dependencia trimestral disponible mediante su estructura estacional, las señales comerciales y las variables de fase. Sin embargo, no constituye una prueba de independencia perfecta ni demuestra que toda la información sistemática haya sido explicada.

La lectura cambia cuando se amplía el diagnóstico a 26 rezagos. El p-valor de 0,0578 permanece sobre el umbral convencional de 5%, pero se encuentra suficientemente próximo como para considerarlo marginal. En consecuencia, no corresponde declarar una adecuación residual concluyente a dos ciclos trimestrales. El resultado sugiere que pueden permanecer dependencias de mayor horizonte que deben ser monitoreadas y revaluadas cuando se incorporen nuevas observaciones.

Entre las explicaciones plausibles de esta señal a 26 semanas se encuentran cambios de régimen entre trimestres, Mega Deals capaces de dejar patrones residuales persistentes, una historia temporal todavía acotada para evaluar rezagos largos, una estacionalidad imperfecta debido a que el calendario no siempre se ajusta exactamente a las 13 semanas, variables comerciales relevantes no incluidas en la especificación y cambios estructurales en el mix de clientes, unidades comerciales, industrias o tamaño de oportunidades. Estas condiciones no se establecen como causas demostradas del resultado, sino como riesgos metodológicos coherentes con la estructura observada y como líneas concretas de monitoreo futuro.

Un segundo riesgo central corresponde a la calidad de las señales comerciales que alimentan el modelo. La capacidad predictiva de SARIMAX depende también de que el pipeline represente de manera razonable el estado comercial disponible al momento de decisión. Oportunidades desactualizadas, registros que permanecen ficticiamente activos, fechas estimadas de cierre mal mantenidas, montos inflados o una representación incompleta de Mega Deals pueden introducir ruido, sesgo y cambios artificiales en las covariables. Por esta razón, la calidad del pipeline debe considerarse parte del riesgo del modelo y no únicamente un problema operativo de registro.

La consecuencia metodológica es que la gobernanza del forecast debe incorporar controles explícitos sobre oportunidad de actualización, consistencia de fechas, nulos, montos negativos, oportunidades estancadas y cambios relevantes de estado. La calidad de un modelo con covariables comerciales no puede evaluarse separadamente de la calidad y disponibilidad temporal de esas covariables. Este vínculo refuerza el uso de un esquema champion-challenger acompañado de monitoreo de datos y revisión humana en eventos materiales.

Los modelos avanzados aportan evidencia complementaria, pero no desplazan al champion. Prophet se aproxima en algunos criterios de riesgo, Chronos-2 constituye un benchmark fundacional competitivo y TFT demuestra capacidad para aprender patrones con una variabilidad elevada. CatBoost alcanza la mejor mediana de WAPE y ofrece una lectura explicable mediante SHAP, pero su techo de 100,17% y su carácter post hoc impiden promoverlo de inmediato. Su rol más defendible es el de challenger explicable, sujeto a validación externa y nuevas ventanas temporales.

En conjunto, SARIMAX presenta varias fortalezas simultáneas, mejor equilibrio operacional entre error típico y peor caso, menor riesgo extremo observado que las principales referencias, dispersión relativamente baja, incorporación de información comercial real, respeto de disponibilidad ex ante, estructura explícita de periodicidad trimestral, diagnóstico residual favorable a 13 semanas y una trazabilidad estadística superior a alternativas más opacas. Estas fortalezas justifican su utilización como modelo central, pero no eliminan las limitaciones derivadas del error absoluto todavía elevado, la sensibilidad a Mega Deals y la calidad del pipeline.

13.2. Conclusiones de Negocio

El valor principal de la solución no consiste en reemplazar el criterio comercial, sino en mejorar la calidad de la decisión bajo incertidumbre. Un forecast cuantitativo, reproducible y auditable permite anticipar desvíos, identificar periodos de mayor exposición, concentrar la revisión sobre oportunidades materiales y separar la señal estadística del juicio ejecutivo. La arquitectura propuesta convierte el forecast en un mecanismo de aprendizaje organizacional, porque cada divergencia entre modelo, Committed y ajuste experto puede ser registrada y evaluada posteriormente.

La mejora observada puede cuantificarse como reducción de exposición al error de forecast. En las 105 semanas del panel, SARIMAX reduce 412,55 MM USD de error absoluto frente a Committed, equivalente a 25,46% sobre el error acumulado de este criterio experto. En Q2/2026 evita 156,70 MM USD de error absoluto de manera descriptiva. Estas magnitudes representan error predictivo evitado y no ahorro financiero, flujo de caja capturado ni ingresos incrementales realizados. Su valor económico potencial se encuentra en reducir la incertidumbre con que se asignan capacidades, se priorizan oportunidades y se anticipan brechas comerciales.

La utilización ejecutiva del modelo debe considerar que la información comercial es parte del sistema de forecast. Mejorar la disciplina de actualización del pipeline, la calidad de las fechas estimadas, la identificación temprana de Mega Deals y la consistencia de Committed puede generar un beneficio doble: elevar la calidad del proceso comercial y, al mismo tiempo, mejorar la capacidad del modelo para transformar esas señales en pronósticos utilizables. En este sentido, el forecast funciona también como incentivo para fortalecer gobierno y calidad de datos comerciales de las oportunidades de negocio en el CRM.

El crecimiento adicional no puede atribuirse directamente a la reducción del error. Para demostrar impacto sobre cierres ganados, ingresos incrementales, margen o duración del ciclo comercial se requiere una integración futura con el Ecosistema de Modelos Comerciales que puedan trasladar la señal agregada del forecast hacia decisiones a nivel de cuenta y oportunidad, pero su contribución deberá medirse constantemente controlando *Data Drift* mediante MLOps (*Machine Learning Operations*).

13.3. Recomendaciones

1. Consolidar una mayor cantidad de registro histórico del CRM anterior con el objetivo de realizar un estudio con datos estructurados que deben ser homologados en sus campos y posteriormente consolidados y adaptados para el análisis de Series Temporales.
2. Realizar un nuevo benchmark comparado con los modelos challenger-champion.
3. Implementar SARIMAX en shadow mode como forecast central, manteniendo CatBoost como challenger hasta acumular evidencia externa suficiente para una eventual promoción.
4. Incorporar controles formales de calidad de pipeline mediante el Proceso de Clean Up o Depuración de Pipeline como parte del gobierno del modelo, incluyendo actualización de oportunidades, consistencia de fechas estimadas de cierre, oportunidades estancadas, montos atípicos, nulos críticos y materialidad de Mega Deals.
5. Mantener Committed como señal comercial independiente y registrar todo ajuste experto con responsable, motivo, monto, fecha y efecto posterior, evitando sobrescribir el forecast original.
6. Monitorear trimestralmente WAPE, sesgo, error de cierre, techo, dispersión entre ventanas, divergencia champion-challenger y calidad de covariables, complementando la revisión con diagnósticos residuales a 13 y 26 rezagos a medida que aumente la historia disponible.

7. Aplicar revisión humana obligatoria ante Mega Deals, cambios de régimen, deterioro de calidad de datos o alertas críticas, utilizando el modelo como soporte a la decisión y no como reemplazo automático del criterio ejecutivo.
8. Revalidar periódicamente CatBoost y otros challengers sobre nuevas ventanas, manteniendo idénticas reglas ex ante y evitando promover modelos a partir de mejoras post hoc o de una única ventana favorable.
9. Desarrollar un piloto prospectivo de valor comercial con grupos comparables para medir cierres incrementales, ingresos adicionales, margen y reducción de ciclo atribuibles a decisiones apoyadas por el forecast.
10. Construir la capa prescriptiva y el Forecast Decision Agent sólo después de estabilizar la calidad de datos, los recursos analíticos, el versionamiento, la trazabilidad y el gobierno del esquema champion-challenger.

13.4. Limitaciones

La principal limitación estructural corresponde a la concentración extrema de los ingresos. Una cantidad reducida de oportunidades puede modificar de forma material el resultado semanal y trimestral, por lo que los errores no se distribuyen de manera homogénea. Esta característica limita la precisión alcanzable mediante una serie agregada y obliga a interpretar WAPE, RMSE, sesgo y desempeño por fase de manera conjunta.

La historia temporal sigue siendo limitada. El panel de ocho ventanas mejora sustancialmente la evidencia frente a una única partición, pero continúa siendo pequeño para arquitecturas profundas y para diagnósticos de dependencia a horizontes largos. El resultado Ljung-Box a 13 rezagos es favorable, mientras que a 26 rezagos es marginal, es por eso que la adecuación temporal del champion debe actualizarse cuando nuevas observaciones permitan evaluar uno, dos y más ciclos trimestrales con mayor potencia estadística.

Las covariables históricas del CRM no provienen de snapshots completos para todo el periodo, lo que obliga a reconstrucciones ex ante y reduce la información disponible. Adicionalmente, la calidad del pipeline puede cambiar en el tiempo. Oportunidades desactualizadas, fechas inexactas, registros artificialmente activos, montos inflados o Mega Deals mal identificados pueden deteriorar tanto el forecast como su interpretación. Esta limitación refuerza la necesidad de tratar la calidad de datos y el riesgo de modelo como dimensiones integradas.

La periodicidad trimestral de 13 semanas constituye una aproximación útil, pero no perfecta. Existen trimestres con catorce semanas y la distribución interna de cierres puede variar por calendario, operación extraordinaria o cambios estructurales del negocio. Las variables de fase permiten absorber parte de esta irregularidad, pero no garantizan que todos los cambios de régimen o amplitud sean anticipados.

Las pruebas estadísticas se interpretan dentro del diseño temporal utilizado y no demuestran causalidad ni equivalencia absoluta entre modelos. Los escenarios no alcanzan cobertura suficiente para presentarse como intervalos probabilísticos plenamente calibrados. La lectura de Q2/2026 es descriptiva y la reducción del error no debe confundirse con ingresos adicionales realizados. El efecto sobre crecimiento permanece como una hipótesis de implementación futura que requiere validación prospectiva.

En consecuencia, las conclusiones se restringen al periodo, frecuencia semanal, reglas de negocio, disponibilidad de datos y proceso comercial analizado. Estas limitaciones no invalidan la contribución de la investigación, pero establecen con claridad las condiciones bajo las cuales SARIMAX puede utilizarse como champion y los controles necesarios para mantener su validez a medida que evolucione el negocio.

14. Trabajo Futuro: Extensión Prescriptiva y Forecast Decision Agent

14.1. Propósito

La extensión prescriptiva no busca reemplazar la decisión ejecutiva. Su propósito es organizar evidencia, priorizar excepciones y recomendar acciones bajo reglas explícitas. El agente analítico debe recibir salidas validadas de los modelos, métricas, SHAP, escenarios y reglas de negocio. La calidad de la recomendación dependerá de la calidad del forecast y de la trazabilidad de las acciones.

El sistema puede transformar una divergencia en una pregunta operativa: qué oportunidades explican el cambio, qué driver se alteró, cuánto ingreso está expuesto, qué acción corresponde y quién debe resolverla. Esta lógica evoluciona desde Predictive Analytics hacia Prescriptive Analytics sin incorporar procesamiento de lenguaje natural como objeto de estudio de la tesis.

Como evolución futura, se propone un Forecast Decision Agent con Multi Context Protocol (MCP) que consuma métricas, pronósticos, escenarios, residuos, semanas críticas y resultados XAI. Su función sería sintetizar la evidencia, explicar diferencias entre modelos, identificar riesgos y generar recomendaciones ejecutivas. El agente no constituye un nuevo predictor y no debe evaluarse mediante WAPE o RMSE.

14.2. Arquitectura Resumida


La arquitectura contiene una capa de datos y controles, un champion, un challenger, la señal Committed, un motor de comparación, sensibilidades y un comité de forecast. Las salidas publicadas permanecen separadas de los ajustes expertos. El sistema debe registrar versiones de datos, parámetros, fecha de ejecución, modelo activo y decisión final.

Las reglas de monitoreo incluyen WAPE trimestral, sesgo, divergencia *champion-challenger*, error de semana de cierre, valores monetarios negativos, nulos en covariables críticas y materialidad de MegaDeals. Los umbrales históricos son referencias provisionales y deben recalibrarse con datos de producción.

La arquitectura se organiza en tres capas. La primera expone recursos analíticos generados por Python. La segunda incorpora herramientas para comparar modelos, consultar brechas, interpretar escenarios y cuantificar impacto. La tercera entrega resúmenes, alertas y recomendaciones a usuarios ejecutivos. La interoperabilidad entre estas capas debe estandarizar el acceso a recursos y herramientas mediante interfaces controladas, con mecanismos de seguridad, trazabilidad, versionamiento y gobierno que permitan auditar cada recomendación y preservar la independencia del forecast publicado.

De Analítica Predictiva a Analítica Prescriptiva

Extensión futura del framework: convertir el pronóstico en decisión ejecutiva



Potencial de máximo valor: decisiones más rápidas, priorizadas y trazables

El agente interpreta resultados. No reemplaza la decisión ejecutiva, no modifica oportunidades y requiere revisión humana (human on the loop).

Ilustración 45. Arquitectura conceptual resumida del Forecast Decision Agent.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

14.3. Límites y Validación

La promoción del challenger requiere nuevas ventanas no consultadas, persistencia de la mejora, estabilidad de drivers y factibilidad operativa. Una mediana inferior no es suficiente si el techo permanece alto. También se requiere comprobar que el modelo puede ejecutarse con los datos disponibles en cada fecha y que los tiempos de procesamiento son compatibles con el ciclo de forecast.

La capa prescriptiva debe evaluarse por decisiones y no por calidad narrativa. Los indicadores relevantes son adopción de recomendaciones, tiempo de respuesta, calidad del ajuste experto, ingresos incrementales, margen y reducción de ciclo. La revisión constante permanece obligatoria ante MegaDeals y alertas críticas.

El agente no reemplaza la decisión ejecutiva, no modifica oportunidades, no ejecuta acciones automáticas en el CRM y no accede a datos productivos sin autorización. Toda recomendación debe indicar la evidencia que la sustenta y mantener revisión supervisada al panel de Calidad de datos. Su evaluación debe considerar claridad ejecutiva, coherencia técnica, trazabilidad, utilidad de negocio, identificación de riesgos y calidad de recomendaciones.

La transición desde analítica predictiva hacia analítica prescriptiva exige medir el efecto de la recomendación sobre decisiones reales. Bertsimas y Kallus (2020) plantean que la prescripción debe vincular predicciones con acciones y resultados. En este caso, el agente deberá validarse en ambiente QA que compare acciones sugeridas, decisiones ejecutadas y cierres posteriores.

14.4. Roadmap Propuesto y Métricas de Impacto

El roadmap comienza con preparación y controles, continúa con shadow mode, formaliza gobierno, incorpora adopción ejecutiva y mantiene una validación externa de dos a cuatro trimestres. La evolución del challenger sólo debe iniciarse después de una decisión formal basada en evidencia nueva. Esta secuencia reduce el riesgo de promover un resultado post hoc.

La evolución contempla cuatro pasos: operación en shadow mode, validación trimestral del champion y challengers, integración de señales de los modelos comerciales complementarios, y prueba controlada del agente con registro de recomendaciones y resultados. Ningún modelo debe promoverse por desempeño retrospectivo sin una ventana temporal independiente.

Indicador	Frecuencia	Naturaleza del umbral	Verde	Ámbar	Rojo
WAPE trimestral champion	Trimestral	Umbral histórico	$\leq 54,64\%$	54,64% a 62,31%	$> 62,31\%$
Sesgo absoluto trimestral	Trimestral	Umbral histórico	$\leq 30,66\%$	30,66% a 39,03%	$> 39,03\%$
Divergencia SARIMAX–CatBoost sobre total	Semanal / trimestral	Umbral histórico	$\leq 24,47\%$	24,47% a 25,23%	$> 25,23\%$
Error absoluto de semana de cierre	Trimestral	Umbral histórico	$\leq 45,88$ MM	45,88 a 67,78 MM	$> 67,78$ MM
Valores monetarios negativos	Cada carga	Control de calidad	0 registros	No aplica	> 0 registros
Nulos en covariables críticas	Cada carga	Control de calidad	0%	$> 0\%$ y $\leq 1\%$	$> 1\%$
Mega Deal individual	Semanal	Regla de negocio	$< 10\%$ del forecast trimestral	10%–20%	$> 20\%$

Ilustración 46. Semáforo de monitoreo para forecast, sesgo, divergencia y calidad de datos.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

Bibliografía

- Ansari, A. F., Stella, L., Türkmen, A. C., Zhang, X., Mercado, P., Shen, H., Shchur, O., Rangapuram, S. S., Pineda Arango, S., Kapoor, S., Zschiegner, J., Maddix, D. C., Wang, H., Mahoney, M. W., Torkkola, K., Wilson, A. G., Bohlke-Schneider, M., & Wang, Y. (2024). Chronos: Learning the language of time series. *Transactions on Machine Learning Research*. <https://openreview.net/forum?id=gerNCVqqtR>
- Ansari, A. F., Shchur, O., Küken, J., Auer, A., Han, B., Mercado, P., Rangapuram, S. S., Shen, H., Stella, L., Zhang, X., Goswami, M., Kapoor, S., Maddix, D. C., Gueron, P., Hu, T., Yin, J., Erickson, N., Desai, P. M., Wang, H., ... Bohlke-Schneider, M. (2025). Chronos-2: From univariate to universal forecasting. *arXiv*. <https://arxiv.org/abs/2510.15821>
- Bertsimas, D., & Kallus, N. (2020). From predictive to prescriptive analytics. *Management Science*, 66(3), 1025-1044. <https://doi.org/10.1287/mnsc.2018.3253>
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5th ed.). Wiley.
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. <https://doi.org/10.1145/2939672.2939785>
- Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253-263. <https://doi.org/10.1080/07350015.1995.10524599>
- Fildes, R., Goodwin, P., Lawrence, M., & Nikolopoulos, K. (2009). Effective forecasting and judgmental adjustments: An empirical evaluation and strategies for improvement in supply-chain planning. *International Journal of Forecasting*, 25(1), 3-23. <https://doi.org/10.1016/j.ijforecast.2008.11.010>
- Gneiting, T. (2011). Making and evaluating point forecasts. *Journal of the American Statistical Association*, 106(494), 746-762. <https://doi.org/10.1198/jasa.2011.r10138>
- Hansen, P. R., Lunde, A., & Nason, J. M. (2011). The model confidence set. *Econometrica*, 79(2), 453-497. <https://doi.org/10.3982/ECTA5771>
- Herzen, J., Lässig, F., Piazzetta, S. G., Neuer, T., Tafti, L., Raille, G., Van Pottelbergh, T., Pasieka, M., Skrodzki, A., Huguenin, N., Dumonal, M., Kościsz, J., Bader, D., Gusset, F., Benheddi, M., Williamson, C., Kosinski, M., Petrik, M., & Grosch, G. (2022). Darts: User-friendly modern machine learning for time series. *Journal of Machine Learning Research*, 23(124), 1-6.
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3rd ed.). OTexts. <https://otexts.com/fpp3/>
- Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679-688. <https://doi.org/10.1016/j.ijforecast.2006.03.001>
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3146-3154.

- Lim, B., Arik, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal Fusion Transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4), 1748-1764. <https://doi.org/10.1016/j.ijforecast.2021.03.012>
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765-4774.
- Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S.-I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2, 56-67. <https://doi.org/10.1038/s42256-019-0138-9>
- Newey, W. K., & West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703-708. <https://doi.org/10.2307/1913610>
- Politis, D. N., & Romano, J. P. (1994). The stationary bootstrap. *Journal of the American Statistical Association*, 89(428), 1303-1313. <https://doi.org/10.1080/01621459.1994.10476870>
- Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, 31, 6638-6648.
- Taylor, S. J., & Letham, B. (2018). Forecasting at scale. *The American Statistician*, 72(1), 37-45. <https://doi.org/10.1080/00031305.2017.1380080>
- Breiman, L. (2001). Random forests. *Machine Learning*, 45, 5-32. <https://doi.org/10.1023/A:1010933404324>
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189-1232. <https://doi.org/10.1214/aos/1013203451>
- Ljung, G. M., & Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297-303. <https://doi.org/10.1093/biomet/65.2.297>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting*, 38(4), 1346-1364. <https://doi.org/10.1016/j.ijforecast.2021.11.013>
- Zou, H., & Hastie, T. (2005). Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society: Series B*, 67(2), 301-320. <https://doi.org/10.1111/j.1467-9868.2005.00503.x>

Anexos

Anexo A. Criterios de Gobierno y Monitoreo

Los umbrales de monitoreo se derivan del panel observado y no constituyen objetivos permanentes. Deben recalibrarse cuando se incorporen nuevos trimestres, cambie la taxonomía comercial o se modifique la distribución de MegaDeals. La alerta roja activa revisión humana y no reemplazo automático del forecast.

El paquete operativo mínimo incluye versión de datos, fecha de ejecución, modelo activo, métricas rolling, divergencia, principales drivers, calidad de covariables, lista de MegaDeals y registro de ajuste experto. La ausencia de alguno de estos componentes debe documentarse antes de publicar el forecast.

El protocolo operativo considera controles de calidad, generación paralela del champion y el challenger, cálculo de divergencia, revisión humana ante umbrales críticos, separación entre forecast y ajuste experto, y revalidación trimestral. Los escenarios se publican como sensibilidad y no sustituyen la referencia puntual.

Anexo B. Registro de Limitaciones

1. El Committed histórico corresponde al último estado disponible y no a una captura completa de cada fecha de decisión.
2. La semana final de Q2/2026 está truncada por el corte de extracción.
3. La taxonomía de producto tiene cobertura completa sólo desde 2025.
4. Existe un trimestre de catorce semanas bajo la regla de agregación.
5. Las operaciones extraordinarias pueden quedar fuera de bandas construidas con historia previa.
6. Los resultados de modelos exploratorios requieren una nueva ventana no consultada.
7. El error evitado no equivale a ROI ni a ingresos incrementales realizados.
8. Los modelos comerciales complementarios se presentan como integración futura y no forman parte del benchmark.
9. Las pruebas de estacionariedad entregan evidencia mixta en el nivel original y se interpretan junto con diagnóstico gráfico y transformaciones.
10. La selección de CatBoost y LightGBM es post hoc y requiere una nueva muestra antes de cualquier promoción operacional.
11. La comparación de SHAP describe la lógica de cada modelo y no establece relaciones causales entre señales del CRM y cierres.
12. El score multicriterio combina métricas cuantitativas y una rúbrica de factibilidad, por lo que debe revisarse cuando cambien prioridades ejecutivas.

Anexo C. Figuras Complementarias de Robustez y Trazabilidad

Este anexo conserva visualizaciones que amplían la comparación sin interrumpir el argumento central. Las figuras corresponden a resultados fuera de muestra, sensibilidades o diagnósticos específicos del estudio.




Ilustración 47. Desempeño durante el trimestre de catorce semanas.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.




Ilustración 48. Complementariedad del modelo Prophet por fase.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.




Ilustración 49. Complementariedad de Temporal Fusion Transformer por fase.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.




Ilustración 50. Estabilidad entre ventanas de Chronos-2.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.




Ilustración 51. Síntesis de afirmaciones sostenibles para Chronos-2.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.




Ilustración 52. Riesgo extremo de modelos de Gradient Boosting.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.




Ilustración 53. Desviación entre ventanas de modelos de Gradient Boosting.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.




Ilustración 54. Síntesis de evidencia XAI de CatBoost.

Fuente: Elaboración propia a partir de datos anonimizados del CRM.

Anexo D. Glosario

Agregación semanal

Transformación de los registros comerciales del CRM en observaciones semanales comparables para modelar los cierres ganados.

Arquitectura champion–challenger

Esquema de gobierno en el que un modelo principal se utiliza como referencia operacional y los modelos alternativos permanecen en evaluación.

Bandas empíricas

Rangos construidos con cuantiles de errores históricos para representar sensibilidad y estrés, no corresponden a intervalos predictivos calibrados.

Brecha neta trimestral

Diferencia entre el total pronosticado y el total real del trimestre. Un valor negativo indica subestimación y uno positivo, sobreestimación.

Calendarización y error de calendarización

Distribución del ingreso esperado entre las semanas del trimestre y error producido cuando un cierre se asigna a una semana distinta de aquella en que ocurre.

CatBoost

Modelo de Gradient Boosting evaluado como challenger. Su configuración post hoc aporta capacidad predictiva y explicativa, aunque no posee la misma disponibilidad ex ante del champion.

Chronos-2

Modelo fundacional preentrenado para series de tiempo, evaluado como referencia avanzada de forecasting.

Cierres ganados semanales (o variable objetivo)

Ingresos semanales asociados con oportunidades comerciales finalizadas exitosamente y que el estudio busca pronosticar.

Committed

Señal del CRM basada en criterio comercial sobre oportunidades consideradas altamente probables. Se utiliza como referencia experta, no como forecast autónomo.

Covariables ex ante

Información disponible antes del horizonte de pronóstico, como Committed, pipeline estimado y variables de calendario y fase.

CRM (Customer Relationship Management)

Sistema de origen que concentra cuentas, oportunidades, montos, estados y señales utilizadas por el proceso comercial y el modelamiento de esta tesis.

Desempeño central

Comportamiento típico de un modelo entre ventanas temporales, representado principalmente mediante la mediana del WAPE.

Error absoluto acumulado

Suma de las diferencias absolutas entre valores reales y pronosticados durante las semanas evaluadas.

Error económico evitado

Reducción del error absoluto acumulado frente a una referencia, representa error predictivo evitado y no ahorro financiero realizado.

Estabilidad temporal

Capacidad de mantener un desempeño relativamente consistente entre distintas ventanas de evaluación.

Estacionalidad

Patrón recurrente de la serie asociado con el ciclo comercial trimestral, aproximado mediante una periodicidad de trece semanas.

Estacionariedad

Propiedad de una serie cuya estructura estadística se mantiene relativamente estable a través del tiempo.

Ex ante

Condición de una variable o predicción construida exclusivamente con información disponible antes del periodo pronosticado.

Forecasting

Proceso de estimar cierres ganados futuros utilizando historia temporal, señales comerciales disponibles y un método reproducible.

Gobierno y trazabilidad del modelo

Controles que permiten registrar datos, versión, métricas, decisiones y ajustes asociados con cada pronóstico.

MAE (Mean Absolute Error)

Promedio de los errores absolutos semanales, expresado en MM USD.

Machine Learning tabular

Modelamiento supervisado que utiliza una matriz de covariables y variables temporales construidas, en lugar de una secuencia temporal nativa.

Naive Seasonal

Referencia que replica el valor observado en la misma posición del ciclo trimestral anterior.

Pipeline comercial

Conjunto de oportunidades activas en las distintas etapas del proceso de venta (proceso comercial) que representa potenciales cierres e ingresos futuros.

Prophet P3 con regresores CRM

Configuración de Prophet que combina tendencia y estacionalidad con regresores del CRM disponibles ex ante. P3 identifica esta especificación y no una familia de modelos diferente.

Riesgo operacional del forecast

Exposición a errores relevantes considerando el peor WAPE, la dispersión entre ventanas, el sesgo, la semana de cierre y la calidad de los datos.

RMSE (Root Mean Squared Error)

Raíz del promedio de los errores cuadrados, asigna mayor peso a las desviaciones semanales de gran magnitud.

Rúbrica de factibilidad

Marco de evaluación que organiza la decisión en tres perfiles: despliegue ejecutivo, precisión central y riesgo operacional.

SARIMAX ex ante con fase (6B)

Configuración seleccionada como champion, que combina estructura temporal y estacional con señales del CRM y variables de fase disponibles ex ante.

Sensibilidad descriptiva

Evaluación de trayectorias alternativas bajo cambios de supuestos, se utiliza para analizar escenarios y estrés, sin atribuirles cobertura probabilística garantizada.

Sesgo del forecast

Diferencia neta entre pronóstico y resultado real. Un sesgo positivo indica sobreestimación y uno negativo, subestimación.

SHAP Values

Atribuciones que cuantifican la dirección y magnitud de la contribución de cada variable a las predicciones de un modelo.

Temporal Fusion Transformer (TFT)

Arquitectura profunda de forecasting multihorizonte que combina selección de variables, mecanismos de atención y covariables temporales.

Validación temporal de origen móvil

Evaluación que avanza cronológicamente, reentrena con la historia disponible y mide cada modelo sobre periodos posteriores no utilizados en su ajuste.

Variable de fase

Covariable que identifica si una semana pertenece al inicio, medio, final o cierre del trimestre.

Variables temporales construidas

Rezagos y estadísticas móviles calculados exclusivamente a partir de la historia disponible antes de cada predicción.

WAPE y sus variantes

Error absoluto agregado dividido por el ingreso real agregado. El WAPE mediano resume el desempeño típico, el agrupado consolida todo el panel y el techo corresponde al peor valor observado entre ventanas.

XGBoost

Modelo de Gradient Boosting utilizado en la comparación tabular y en el análisis de concordancia de importancia de variables frente a CatBoost.