



UNIVERSIDAD DE CHILE

**UNIVERSIDAD DE CHILE  
FACULTAD DE ECONOMÍA Y NEGOCIOS  
ESCUELA DE POSTGRADO**

**PREDICCIÓN DE ELECCIÓN PRESIDENCIAL A PARTIR DE  
RESULTADOS DE ELECCIONES MUNICIPALES**

**ACTIVIDAD FORMATIVA EQUIVALENTE  
PARA OPTAR AL GRADO DE MAGÍSTER EN ANALÍTICA DE  
NEGOCIOS**

FELIPE ANDRÉS DEL RÍO NOVA

CHARLES THRIVES

Santiago, Chile

2026

## **Tabla de contenido**

|                                                                  |    |
|------------------------------------------------------------------|----|
| Resumen Ejecutivo.....                                           | 4  |
| Introducción .....                                               | 6  |
| Planteamiento del problema .....                                 | 9  |
| Hipótesis .....                                                  | 13 |
| Objetivos.....                                                   | 17 |
| Objetivo general .....                                           | 17 |
| Objetivos específicos.....                                       | 17 |
| Metodología .....                                                | 21 |
| Revisión Bibliográfica.....                                      | 26 |
| Contenido .....                                                  | 37 |
| 1. Construcción y estandarización del dataset.....               | 37 |
| 2. Las dos modalidades de asignación (manual y RxC/FASTEI) ..... | 42 |
| 3. Formulación de los modelos predictivos .....                  | 49 |
| 4. Diseño de validación .....                                    | 58 |
| 5. Resultados por modalidad y modelo .....                       | 62 |
| 6. Comparación entre modalidades y análisis de robustez.....     | 67 |
| 7. Síntesis de hallazgos.....                                    | 75 |
| Conclusiones .....                                               | 80 |
| Bibliografía .....                                               | 85 |
| Anexos .....                                                     | 88 |

## **Tabla Ilustraciones**

|                                                              |    |
|--------------------------------------------------------------|----|
| Ilustración 1- Proceso Simplificado .....                    | 41 |
| Ilustración 2- Alineación de Partidos Ejemplo.....           | 48 |
| Ilustración 3 - Esquema comparativo de los tres modelos..... | 56 |
| Ilustración 4 - Línea tiempo datasets .....                  | 59 |
| Ilustración 5 - Predicciones por camino y modelo. ....       | 66 |
| Ilustración 6 - Comparativo MAE por modelo y camino. ....    | 75 |

## **Tablas**

|                                                                                             |    |
|---------------------------------------------------------------------------------------------|----|
| Tabla 1 - Estandarización Comunas.....                                                      | 39 |
| Tabla 2 - Diccionario de asignación manual de votos, ciclo 2021 (ejemplo ilustrativo) ..... | 45 |
| Tabla 3 - Hiperparámetros por modelo y modalidad de asignación.....                         | 56 |
| Tabla 4 - Resultados Camino FASTEI.....                                                     | 63 |
| Tabla 5 - Resultados Camino Manual.....                                                     | 64 |
| Tabla 6 - Resumen predicciones 2025 por modalidad y modelo .....                            | 67 |
| Tabla 7 - Estadística Errores por Modelo.....                                               | 68 |
| Tabla 8 - Voto de partido no asignado por modalidad manual, por ciclo. ..                   | 70 |
| Tabla 9 - Comunas seleccionadas por el modelo Beta=0 ( $k=3$ ) y su peso B. ....            | 73 |
| Tabla 10 - Resumen de Hipótesis. ....                                                       | 79 |

## **Resumen Ejecutivo**

La predicción de resultados electorales constituye un desafío central de la analítica aplicada al ámbito político, en un escenario donde las encuestas de opinión han mostrado fallas de precisión. Este trabajo evalúa si los resultados de elecciones municipales contienen información para anticipar la segunda vuelta presidencial chilena, ofreciendo una alternativa basada exclusivamente en registros electorales oficiales.

Bajo un enfoque predictivo y cuantitativo, se construyó una base longitudinal de 346 comunas y se compararon dos modalidades de asignación de votos —manual experta e inferencia ecológica mediante el modelo  $R \times C$ — sobre tres modelos de alta dimensionalidad: PLS, PCR y selección de variables  $L_0$ . La evaluación empleó una partición temporal, con ciclos históricos para entrenamiento, 2021 para validación y 2025 para prueba.

Cinco de seis configuraciones anticiparon correctamente el triunfo de la oposición en 2025. La combinación de PLS con inferencia ecológica obtuvo

el menor error, de 1,24 puntos porcentuales, y la asignación ecológica superó a la manual en todos los modelos.

Se concluye que el voto municipal mostró valor predictivo bajo la configuración más rigurosa. Los hallazgos son preliminares, limitados por el reducido número de observaciones y el sobreajuste detectado.

## **Introducción**

La predicción de resultados electorales constituye un desafío central de la analítica aplicada al ámbito político, particularmente en contextos donde la información disponible es dispersa, costosa o susceptible de sesgo. La elección de este tema responde a la necesidad de contar con herramientas predictivas complementarias a las encuestas de opinión, cuya capacidad para anticipar resultados ha sido cuestionada en episodios recientes, tanto en Chile como en el extranjero. Frente a ese vacío, las elecciones municipales ofrecen una fuente de información poco explotada: por su granularidad territorial y su elevado volumen de participación, contienen señales sobre alineamientos políticos que podrían anticipar el comportamiento del electorado en comicios presidenciales posteriores.

El trabajo se fundamenta en dos pilares. Por una parte, se apoya exclusivamente en registros oficiales de votación del Servicio Electoral de Chile (SERVEL), lo que favorece la trazabilidad y la replicabilidad del análisis, a diferencia de los enfoques basados en datos auto reportados. Por otra parte, se inscribe en la disciplina de la analítica de negocios, entendida como el uso de métodos cuantitativos para apoyar la toma de decisiones

estratégicas a partir de datos observables, en este caso aplicada a un problema de decisión bajo incertidumbre y con información estructuralmente incompleta.

El objetivo general de la investigación es desarrollar un modelo predictivo capaz de estimar el resultado de la segunda vuelta presidencial chilena a partir de los resultados de elecciones municipales. Como objetivos específicos, se busca recolectar y estandarizar los datos electorales municipales y presidenciales del período de estudio; diseñar dos modalidades de asignación de votos municipales a candidaturas presidenciales —una manual, basada en criterio experto, y otra automatizada, basada en inferencia ecológica—; aplicar y comparar tres enfoques predictivos sobre ambas modalidades; y discutir las implicancias y limitaciones del enfoque propuesto.

La hipótesis que orienta el estudio sostiene que es posible predecir de manera consistente el resultado de una elección presidencial a partir de los resultados de elecciones municipales previas, siempre que se utilicen métodos adecuados de reducción de dimensionalidad, selección de variables y asignación estructurada de votos. De ella se derivan hipótesis secundarias

relativas al efecto de la modalidad de asignación y al desempeño relativo de los distintos modelos en condiciones de alta dimensionalidad.

En cuanto a la metodología, el estudio adopta un enfoque cuantitativo-deductivo. Se construye una base histórica longitudinal con votación comunal de múltiples ciclos electorales, configurando un problema de alta dimensionalidad ( $p \gg n$ ), con un universo homogéneo de 346 comunas como predictores y dos candidaturas por ciclo en segunda vuelta como observaciones. Los votos municipales se vinculan a candidaturas presidenciales mediante las dos modalidades de asignación señaladas, y sobre las matrices resultantes se aplican tres modelos: Partial Least Squares (PLS), Principal Component Regression (PCR) y un modelo de selección de variables con penalización  $L_0$ . El desempeño se evalúa mediante validación cruzada y la partición de los datos en conjuntos de entrenamiento, validación y prueba, reservando el ciclo 2025 —cuya votación municipal corresponde a octubre de 2024— como conjunto de prueba para la evaluación fuera de muestra.



## **Planteamiento del problema**

Esta investigación se sitúa en el cruce entre el análisis electoral y la analítica de negocios, con el propósito de apoyar un problema concreto de toma de decisiones: anticipar el resultado de una elección presidencial a partir de información observable y disponible con antelación. Los destinatarios de este tipo de predicción —organizaciones políticas, comandos de campaña, instituciones públicas y analistas— deben asignar recursos escasos (tiempo, presupuesto, despliegue territorial, mensaje) en un horizonte de alta incertidumbre y antes de que el resultado sea conocido. La decisión de fondo no es únicamente "quién ganará", sino dónde concentrar el esfuerzo y qué territorios resultan más informativos o sensibles para la configuración del resultado nacional. En ese sentido, el problema abordado es el de un sistema de apoyo a la decisión que transforma datos electorales históricos en insumos accionables.

La importancia de este problema se acentúa por las limitaciones de la herramienta tradicionalmente usada para anticipar resultados: las encuestas de opinión. Su representatividad y precisión han sido cuestionadas, especialmente en escenarios de voto voluntario, fragmentación partidaria y

cambios abruptos en la opinión pública. En ese contexto, disponer de una fuente alternativa, objetiva y de bajo costo marginal —los registros oficiales de votación— constituye un aporte directo a la calidad de las decisiones estratégicas de los actores señalados.

Desde la perspectiva de la analítica de negocios, el trabajo es relevante porque reúne los rasgos que definen a la disciplina: un problema de decisión bajo incertidumbre, una fuente de datos masiva y sistemática, y la necesidad de extraer de ella conocimiento útil bajo restricciones reales. El estudio se enmarca específicamente en la analítica predictiva, al estructurarse como un problema de aprendizaje supervisado con entradas claramente definidas (resultados municipales por comuna) y una salida de interés (la votación presidencial en segunda vuelta). A ello se suma una exigencia propia de la analítica de negocios aplicada: la preferencia por modelos interpretables. A diferencia de los enfoques de caja negra, las técnicas empleadas permiten identificar qué comunas aportan mayor información a la predicción, respondiendo no sólo al "qué" del resultado, sino también al "dónde", dimensión esencial para la toma de decisiones territoriales.

El primer desafío técnico que condiciona el alcance del trabajo es la construcción de una base de datos longitudinal a partir de los registros del Servicio Electoral de Chile (SERVEL). Esta fuente, aunque oficial, presenta inconsistencias relevantes a lo largo del tiempo: cambios en la codificación y nomenclatura de regiones, y variaciones en el número y delimitación de comunas entre los distintos ciclos. Estas inconsistencias obligan a un proceso riguroso de estandarización territorial para asegurar comparabilidad entre periodos, del que resulta un universo homogéneo de 346 comunas. La base completa queda así conformada por una docena de observaciones — seis ciclos en segunda vuelta, con dos candidaturas cada uno— frente a 346 predictores de las cuales ocho se destinan a entrenamiento. Esta relación, en la que el número de variables excede ampliamente al de observaciones, configura un caso típico de alta dimensionalidad ( $p \gg n$ ), que restringe las técnicas aplicables y exige modelos diseñados para evitar el sobreajuste y la inestabilidad de los coeficientes.

El segundo desafío es el problema de correspondencia entre niveles electorales. Los datos municipales reflejan votos a nivel de pactos, partidos y candidaturas independientes, mientras que los presidenciales

corresponden a individuos respaldados por coaliciones que varían en el tiempo. Vincular ambas estructuras requiere un modelo de asignación, y la elección de ese modelo es en sí misma una decisión metodológica con consecuencias sobre la predicción. Este trabajo asume el alcance de comparar dos modalidades de asignación, dejando fuera otras posibles.

Finalmente, el alcance del estudio queda delimitado por un conjunto explícito de restricciones y supuestos. Ambas modalidades de asignación suponen que la totalidad de los votos de un partido se transfiere a una única candidatura presidencial, descartando flujos cruzados y particiones internas; es una simplificación necesaria, pero que ignora parte de la complejidad real del comportamiento electoral. Los votos de candidaturas independientes, difíciles de asociar a un bloque nacional, se conservan de manera explícita en el dataset para no distorsionar la composición real de la votación, asumiendo el costo de introducir ruido estructural en el entrenamiento. Los votos nulos y blancos, en cambio, se excluyen por no representar preferencias políticas atribuibles, lo que reduce marginalmente el universo considerado. El análisis se restringe además a la segunda vuelta presidencial, por su estructura binaria y su mayor estabilidad para la

comparación entre ciclos. Estas decisiones acotan deliberadamente el alcance del trabajo y, al mismo tiempo, delimitan con transparencia las condiciones bajo las cuales deben interpretarse sus resultados.

## **Hipótesis**

Esta investigación se organiza en torno a un conjunto de preguntas que surgen de la intersección entre la analítica electoral y el modelamiento predictivo en contextos de alta incertidumbre estructural. La pregunta fundamental que guía el trabajo es la siguiente:

¿Es posible predecir de manera consistente el resultado de una elección presidencial en Chile a partir de los resultados de elecciones municipales previas, utilizando métodos multivariados de reducción de dimensionalidad y selección de variables?

Esta interrogante adquiere relevancia en un escenario donde las encuestas tradicionales enfrentan cuestionamientos respecto de su representatividad y precisión, mientras que los resultados de elecciones municipales —por su granularidad territorial y su volumen de participación— constituyen una fuente empírica sistemática cuya capacidad predictiva no ha sido

suficientemente explorada. De la pregunta principal se desprenden tres preguntas secundarias que permiten operacionalizar el problema y examinar la sensibilidad del análisis a distintos supuestos metodológicos:

¿En qué medida la modalidad de asignación de votos municipales a candidaturas presidenciales —manual versus inferencia ecológica mediante el modelo  $RxC$ — afecta la capacidad predictiva de los modelos aplicados?

¿Cómo se comportan los modelos predictivos empleados (PLS, PCR y selección  $L_0$ ) frente a un conjunto de datos de alta dimensionalidad y bajo número de observaciones, en presencia de ruido estructural derivado de votos independientes o no atribuibles?

¿Existen patrones territoriales persistentes en la relación entre el voto municipal y el voto presidencial que puedan ser capturados por componentes latentes o por subconjuntos reducidos de comunas?

A partir de estas preguntas, y siguiendo una lógica cuantitativo-deductiva, se formulan las siguientes hipótesis de investigación, planteadas como proposiciones a contrastar empíricamente:

**Hipótesis nula ( $H_0$ ):** No es posible predecir de forma sistemática el resultado de una elección presidencial en Chile a partir de los resultados de elecciones municipales previas, debido a la disociación estructural entre ambos niveles de votación.

**Hipótesis alternativa ( $H_1$ ):** Es posible predecir el resultado de una elección presidencial a partir de los resultados de elecciones municipales previas, en la medida en que se empleen métodos adecuados de reducción de dimensionalidad, selección de variables y asignación estructurada de votos.

Asociadas a la hipótesis alternativa, se plantean tres hipótesis secundarias que orientan la comparación metodológica y que serán evaluadas en el desarrollo del trabajo:

**$H_{1a}$ :** La modalidad de asignación de votos (manual versus inferencia ecológica  $RxC$ ) incide en la estabilidad y la capacidad de generalización de las predicciones.

**$H_{1b}$ :** Los modelos que incorporan reducción de dimensionalidad o selección de variables (PLS, PCR y  $L_0$ ) presentan comportamientos diferenciados en escenarios de alta colinealidad y bajo número de observaciones.

**H<sub>1c</sub>:** La inclusión de votos de candidaturas independientes en el conjunto de datos afecta la capacidad predictiva de los modelos, planteando una tensión entre fidelidad a la composición real del electorado y estabilidad del modelo.

En conjunto, estas preguntas e hipótesis delimitan el marco analítico del estudio, estableciendo las proposiciones que serán sometidas a verificación empírica en las secciones posteriores.



## **Objetivos**

### **Objetivo general**

Desarrollar un modelo predictivo capaz de estimar el resultado de elecciones presidenciales en Chile a partir de los resultados de elecciones municipales previas, empleando técnicas de analítica de negocios basadas en reducción de dimensionalidad, selección de variables y asignación estructurada de votos.

### **Objetivos específicos**

Para abordar el objetivo general, el trabajo se aproxima a él por etapas sucesivas, cada una asociada a un capítulo y vinculada con la siguiente:

**Recolectar, depurar y estandarizar los datos electorales municipales y presidenciales del período de estudio.**

Este primer objetivo corresponde al capítulo de preparación del dataset y persigue construir una base de datos longitudinal, coherente en términos territoriales y temporales, que permita comparar distintos ciclos electorales.

En él se abordan los problemas de codificación regional, el número variable de comunas y la evolución de la oferta electoral, hasta consolidar un universo homogéneo de comunas. Su resultado —una base depurada— constituye el insumo sobre el que operan todas las etapas posteriores.

**Diseñar y aplicar dos modalidades de asignación de votos municipales a candidaturas presidenciales: una manual, basada en criterio experto, y otra automatizada, basada en inferencia ecológica mediante el modelo  $RxC$ .**

Este objetivo corresponde al capítulo de asignación y toma como punto de partida la base depurada de la etapa anterior. En él se explicitan las decisiones de correspondencia entre niveles electorales y los supuestos asumidos, generando las dos matrices de entrada que alimentan el modelamiento. El contraste entre ambas modalidades es, además, uno de los ejes comparativos del trabajo.

**Aplicar tres enfoques predictivos —PLS, PCR y selección de variables con penalización  $L_0$ — para modelar la relación entre voto municipal y voto presidencial.**

Este objetivo corresponde al capítulo de modelamiento y se ejecuta sobre las matrices construidas en la etapa previa. En él se documenta el proceso de selección de componentes o de variables relevantes y la validación empleada, considerando las restricciones impuestas por el bajo número de observaciones frente al alto número de predictores. Su resultado es un conjunto de modelos entrenados y listos para ser evaluados.

**Comparar el desempeño de las dos modalidades de asignación y los tres modelos predictivos, y evaluar su capacidad predictiva sobre la segunda vuelta presidencial de 2025.**

Este objetivo corresponde al capítulo de predicción y evaluación, y articula los productos de las etapas anteriores. En él se contrastan las predicciones entre sí y frente al resultado observado, analizando la consistencia entre modalidades y métodos y la robustez de los patrones identificados.

**Discutir las implicancias analíticas, políticas y metodológicas de los hallazgos, junto con las limitaciones y las posibilidades de replicabilidad del enfoque propuesto.**

Este último objetivo corresponde al capítulo de discusión y conclusiones, y cierra el encadenamiento al interpretar los resultados de la evaluación a la luz de los supuestos del trabajo, situando su aporte dentro de la analítica de negocios aplicada al análisis electoral.

## **Metodología**

Esta investigación adopta un enfoque cuantitativo-deductivo de carácter empírico. Es deductivo porque parte de una hipótesis general —la existencia de una relación estructural entre los resultados de elecciones municipales y presidenciales— que se somete a contraste mediante un razonamiento lógico, derivando de ella proposiciones verificables con datos. Es cuantitativo y empírico porque ese contraste se apoya en la medición y comparación sistemática de evidencia observable: los registros oficiales de votación del Servicio Electoral de Chile (SERVEL). Si bien el método cuantitativo-deductivo suele asociarse a la medición de variables económicas, en este trabajo la magnitud medida y comparada no es monetaria sino predictiva —el grado de ajuste entre la votación estimada y la observada—, conservando intacta la lógica del método: medir, comparar y concluir a partir de evidencia.

Se descartan otros enfoques por no corresponder a la naturaleza del problema. No se emplea un método inductivo puro, dado que el análisis no busca generalizar desde casos hacia una teoría, sino contrastar una hipótesis previamente formulada. Tampoco se recurre a métodos interpretativos

basados en entrevistas semiestructuradas, pues el objeto de estudio no son las motivaciones individuales de los votantes, sino patrones agregados de comportamiento territorial. Por la misma razón, el diseño no es mixto: prescinde deliberadamente de datos cualitativos y autorreportados, como encuestas, en favor de registros administrativos completos y objetivos.

El procedimiento metodológico se organiza en cinco etapas encadenadas, en correspondencia con los objetivos específicos del estudio.

### **Etapas 1. Recolección y estandarización de los datos electorales.**

Se recopilan los resultados oficiales de votación a nivel comunal, tanto municipales como presidenciales, y se realiza un proceso de depuración que resuelve las inconsistencias en las variables geográficas —cambios en la codificación de regiones, creación o fusión de comunas y modificaciones de nomenclatura— hasta obtener un universo homogéneo y comparable de 346 comunas a lo largo de todos los ciclos. El resultado es una base longitudinal con observaciones definidas por cada par año-candidato en segunda vuelta y

las comunas como predictores, configurando un problema de alta dimensionalidad ( $p \gg n$ ).

## **Etapla 2. Asignación de la votación municipal a candidaturas presidenciales.**

Como los datos municipales se expresan a nivel de partidos y pactos, y los presidenciales a nivel de candidatos, se construyen dos modalidades de correspondencia. La primera, manual, asigna los votos según el criterio experto de afinidad partidaria y las coaliciones que respaldaron a cada candidatura. La segunda, automatizada, estima la asignación mediante inferencia ecológica con el modelo  $R \times C$  implementado en la librería FASTEI del lenguaje R. En la modalidad ecológica (FASTEI), los votos de candidaturas independientes se conservan y se reparten probabilísticamente entre las candidaturas. En la modalidad manual, en cambio, esos votos — junto con los del Partido Regionalista Independiente Demócrata, de bloque ambiguo— quedan fuera de la asignación, al no admitir una clasificación inequívoca. En ambas se excluyen los votos nulos y blancos.

### **Etapla 3. Modelamiento predictivo.**

Sobre las matrices resultantes de cada modalidad se aplican tres enfoques de aprendizaje supervisado, seleccionados por su idoneidad en contextos de alta dimensionalidad y colinealidad: *Partial Least Squares* (PLS), que extrae componentes latentes maximizando la covarianza entre predictores y variable objetivo; *Principal Component Regression* (PCR), que regresa sobre los primeros componentes principales de los predictores; y un modelo de selección de variables con penalización  $L_0$ , formulado como un problema de optimización entera-mixta y resuelto con herramientas de programación matemática, orientado a identificar un subconjunto mínimo de comunas con valor predictivo.

### **Etapla 4. Evaluación y comparación.**

El desempeño de cada combinación de modalidad y modelo se examina mediante validación cruzada y la partición de los datos en conjuntos de entrenamiento, validación y prueba. Se reserva como conjunto de prueba el ciclo 2025, cuya votación municipal corresponde a 2024, lo que permite una evaluación fuera de muestra contrastando las predicciones con un resultado efectivamente observado. Se utilizan métricas de error y de ajuste para



comparar el comportamiento de los modelos entre sí y entre ambas modalidades de asignación.

### **Etapas 5. Discusión y validación de los hallazgos.**

Se interpretan los resultados a la luz de los supuestos del trabajo, se analiza la consistencia entre modalidades y métodos, y se examinan las limitaciones inherentes al uso de datos agregados y a las decisiones de asignación y estandarización adoptadas.

## **Revisión Bibliográfica**

### **Introducción general al estudio del comportamiento electoral.**

El estudio del comportamiento electoral es una de las áreas más consolidadas de la ciencia política empírica desde mediados del siglo XX. Los modelos clásicos de las escuelas de Columbia [Lazarsfeld, Berelson & Gaudet, 1944] y de Michigan [Campbell, Converse, Miller & Stokes, 1960] destacaron el peso de los factores sociológicos y de la identificación partidaria sobre la decisión de voto. A partir de la década de los noventa, el avance del análisis cuantitativo y el acceso creciente a datos desagregados dieron paso a un enfoque más estadístico y explícitamente orientado a la predicción.

En ese nuevo paradigma, las herramientas de inferencia multivariada y el aprendizaje automático comenzaron a complementar a los enfoques descriptivos, dando lugar a un campo conocido como election forecasting [Lewis-Beck & Tien, 2016], que se desarrolló en paralelo a la disponibilidad de datos abiertos y herramientas computacionales accesibles.

Chile no ha sido ajeno a esta transformación. Si bien la literatura nacional ha tendido a privilegiar los estudios descriptivos y el análisis post-electoral [Navia, 2006; Luna, 2017], la consolidación de los registros públicos del Servicio Electoral (SERVEL) ha abierto oportunidades inéditas para aplicar modelos predictivos sobre bases históricas de votación. En este contexto surge la hipótesis de que las elecciones municipales —por su cobertura territorial, volumen de votantes y estructura partidaria— podrían contener información anticipatoria sobre las dinámicas que se manifiestan en elecciones presidenciales posteriores.

### **Elecciones municipales como predictor de elecciones presidenciales.**

Uno de los supuestos centrales de esta investigación es la existencia de una relación estructural entre el comportamiento electoral municipal y el desempeño posterior de los bloques políticos en elecciones presidenciales. La premisa es que las votaciones locales reflejan no sólo preferencias coyunturales hacia liderazgos específicos, sino también alineamientos ideológicos, capital político territorial y fortaleza organizacional de los partidos a nivel subnacional.

La literatura comparada ha explorado esta posibilidad. Spoon y West analizaron cómo los resultados de elecciones subnacionales inciden en la probabilidad de que un partido decida presentar candidatura presidencial, concluyendo que un buen desempeño local incrementa esa probabilidad y genera un efecto anticipatorio observable en la configuración de la oferta electoral [Spoon & West, 2015].

En el caso chileno, la hipótesis encuentra terreno fértil. El país tuvo un sistema de partidos históricamente consolidado, pero ha experimentado una fragmentación creciente en la última década [Bunker, 2023]. Esta fragmentación, acompañada por la emergencia de candidaturas independientes y coaliciones inestables, ha erosionado la capacidad predictiva basada exclusivamente en lealtades partidarias; aun así, las elecciones municipales siguen siendo un espacio privilegiado de expresión política territorial.

En esa línea, el trabajo de Thraves, Ubilla y Hermosilla constituye una de las aplicaciones recientes de inferencia ecológica al caso chileno, proponiendo un algoritmo para estimar el problema  $R \times C$  con datos electorales reales [Thraves, Ubilla & Hermosilla, 2024].

Este enfoque no está exento de críticas. La asimetría de incentivos entre ambos tipos de comicios —elecciones municipales personalizadas y de vínculo comunitario frente a presidenciales estructuradas en torno a clivajes ideológicos amplios— puede limitar la validez del traslado directo de preferencias de un nivel a otro, especialmente en presencia de candidaturas independientes o desafección partidaria.

### **Inferencia ecológica y el modelo $R \times C$ como herramienta metodológica.**

La inferencia ecológica es una técnica estadística para estimar relaciones de nivel individual a partir de datos agregados, útil cuando no se dispone de microdatos. En el ámbito electoral permite modelar cómo los votantes de distintos grupos —por ejemplo, partidos en elecciones municipales— se redistribuyen entre opciones en una elección posterior, a partir de matrices agregadas de votación territorial.

El desafío central es el problema de identificación: múltiples combinaciones de preferencias individuales pueden producir los mismos agregados observados. King abordó este problema de manera sistemática, proponiendo un modelo que estima distribuciones probabilísticas sobre las celdas no

observadas de una tabla de contingencia a partir de restricciones y supuestos informativos [King, 1997].

A partir de ese marco se desarrollaron formulaciones para el caso  $R \times C$ , que estima la distribución conjunta entre  $R$  filas (partidos o pactos) y  $C$  columnas (candidaturas), construyendo una matriz de transición electoral [Rosen, Jiang, King & Tanner, 2001]. Wakefield discutió las limitaciones de estos modelos, advirtiéndole que las inferencias ecológicas describen patrones agregados y no deben leerse como representaciones exactas de decisiones individuales [Wakefield, 2004].

En esta investigación se emplea la implementación computacional del modelo  $R \times C$  contenida en la librería FASTEI de R, que estima la matriz de probabilidades mediante el algoritmo *Expectation-Maximization*, ofreciendo varios métodos de aproximación para el paso E (entre ellos aproximaciones multinomial y normal multivariada, además de un método exacto). La ventaja de este enfoque frente a la asignación manual es su carácter reproducible y susceptible de validación, aunque su precisión depende de la calidad y homogeneidad de los datos de entrada.

## **Modelos predictivos en alta dimensionalidad: PLS, PCR y Lo**

Cuando el número de predictores ( $p$ ) excede ampliamente al de observaciones ( $n$ ), surge el problema de alta dimensionalidad o " $p \gg n$ ", frecuente en bioinformática, finanzas y, crecientemente, en la analítica electoral con datos territorialmente desagregados. En este escenario se han desarrollado técnicas para mitigar el sobreajuste, la multicolinealidad y la inestabilidad de los coeficientes.

### **Partial Least Squares (PLS)**

El PLS, introducido por Wold, extiende el análisis de componentes principales hacia la predicción: busca componentes latentes que expliquen la máxima covarianza entre los predictores y la variable dependiente, a diferencia del PCA, que solo maximiza la varianza de los predictores [Wold, 1985]. Su robustez frente a estructuras altamente colineales lo hace apropiado para contextos de baja dimensionalidad efectiva.

## Principal Component Regression (PCR)

La PCR transforma los predictores en componentes ortogonales y ajusta una regresión sobre un subconjunto de ellos. Aunque no optimiza la relación con la variable respuesta —como sí lo hace el PLS—, mitiga la colinealidad y reduce la varianza de los estimadores, ofreciendo predicciones competitivas cuando se selecciona adecuadamente el número de componentes a retener.

## Selección de variables mediante penalización $L_0$

La regresión con restricción  $L_0$  busca el subconjunto mínimo de predictores que explica la variable objetivo, limitando el número de coeficientes distintos de cero. Corresponde a un problema de optimización combinatoria —el *best subset selection*— históricamente abordado mediante algoritmos exhaustivos o heurísticos [Miller, 2002]. En su versión reciente se implementa mediante formulaciones de optimización entera-mixta



compatibles con entornos como Pyomo<sup>1</sup>, lo que vuelve tratable un problema antes considerado intratable e identifica, en este caso, comunas con valor predictivo real.

El uso conjunto de estos tres enfoques se inscribe en la discusión más amplia sobre la incorporación del aprendizaje automático a las ciencias sociales, que propone seleccionar los métodos en función de la tarea analítica antes que del algoritmo [Grimmer, Roberts & Stewart, 2021].

### **Analítica de negocios y predicción electoral.**

La analítica de negocios puede definirse como el conjunto de metodologías cuantitativas y tecnológicas orientadas a analizar datos y apoyar la toma de decisiones estratégicas [Shmueli, Bruce, Gedeck & Patel, 2019]. La predicción electoral constituye un caso particularmente representativo, al combinar incertidumbre estructural, variabilidad territorial y dinámicas sociales complejas.

---

<sup>1</sup> PYOMO: Python Optimization Modeling Objects

A nivel internacional, diversos estudios han aplicado aprendizaje supervisado, redes neuronales y regresión a la predicción electoral a partir de encuestas, datos económicos o actividad en redes sociales [Tumasjan, Sprenger, Sandner & Welpe, 2010]. El enfoque de esta investigación difiere de esas aproximaciones al apoyarse exclusivamente en datos históricos de votación, prescindiendo de información auto reportada.

Desde la perspectiva de la analítica de negocios, este enfoque aprovecha datos objetivos y sistemáticamente recolectados por un organismo público (SERVEL), estructura el problema como aprendizaje supervisado con entradas y salidas bien definidas, y habilita el uso de modelos interpretables. A diferencia de los enfoques de caja negra, las técnicas empleadas (PLS, PCR y L<sub>0</sub>) permiten identificar qué comunas aportan mayor información a la predicción, respondiendo al "dónde" además del "qué" —dimensión clave para la toma de decisiones territoriales.

## **Críticas, limitaciones y brechas en la literatura**

Pese a los avances, la literatura presenta limitaciones que conviene reconocer. Una crítica recurrente es la dependencia de las encuestas de opinión, cuya capacidad para anticipar resultados ha mostrado fallas sistemáticas por sesgos de no respuesta, errores de muestreo o voto oculto [Kennedy et al., 2018]. En Chile, episodios como la elección presidencial de 2021 y el plebiscito constitucional de 2022 evidenciaron la dificultad de las encuestas para anticipar cambios abruptos de la opinión pública [CIPER, 2021].

El uso de elecciones municipales como predictor enfrenta además desafíos no resueltos: la asimetría estructural entre comicios locales y nacionales, la heterogeneidad territorial y los cambios institucionales en la delimitación comunal, que dificultan construir series comparables en el tiempo. La inferencia ecológica, por su naturaleza, no captura la heterogeneidad individual, por lo que su utilidad reside en generar insumos para modelos predictivos más que en la interpretación causal del voto [Wakefield, 2004].

Los métodos de reducción y selección (PLS, PCR,  $L_0$ ) también tienen costos: su desempeño depende de la correcta elección de hiperparámetros y del número de componentes o variables, y la interpretación de los componentes latentes puede resultar poco transparente. Finalmente, una brecha notoria es la escasa aplicación de estos enfoques al contexto chileno con bases públicas y replicables como las del SERVEL; salvo trabajos aislados [Thraves, Ubilla & Hermosilla, 2024], no existe aún una línea consolidada que combine analítica de negocios, inferencia ecológica y aprendizaje estadístico para la predicción electoral, lo que constituye la oportunidad que este trabajo busca aprovechar.

## **Contenido**

1. Construcción y estandarización del *dataset*
2. Las dos modalidades de asignación (manual y RxC/FASTEI)
3. Formulación de los modelos (PLS, PCR y Beta=0)
4. Diseño de validación (entrenamiento / validación 2021 / prueba 2025)
5. Resultados por modalidad y modelo
6. Comparación FASTEI vs. MANUAL y análisis de robustez
7. Síntesis de hallazgos

### **1. Construcción y estandarización del dataset**

El punto de partida del análisis es la construcción de una base de datos longitudinal que reúna, de forma comparable, los resultados electorales municipales y presidenciales de los seis ciclos considerados. Esta etapa concentra una parte sustantiva del esfuerzo metodológico del trabajo, por una razón que conviene explicitar: la calidad de las predicciones depende menos de la sofisticación de los modelos que de la homogeneidad y

consistencia de los datos que los alimentan. En un problema de alta dimensionalidad, cualquier inconsistencia territorial se propaga y amplifica a lo largo de todo el pipeline.

La fuente primaria son los registros oficiales del Servicio Electoral de Chile (SERVEL). A partir de ellos se conformaron seis archivos de trabajo, cada uno asociando la votación municipal de un período con la elección presidencial en segunda vuelta correspondiente: los ciclos 2005, 2009, 2013, 2017, 2021 y el ciclo 2025 —cuya elección municipal se realizó en 2024—. La lógica del emparejamiento es que los resultados municipales de un período operan como predictores (la matriz de entrada), mientras que el resultado presidencial de ese mismo ciclo constituye la variable objetivo.

### **Estandarización territorial**

El principal obstáculo para la comparabilidad es que el universo de comunas no es estable en el tiempo. A lo largo de los ciclos se observan tres tipos de inconsistencia: cambios en la nomenclatura de comunas, diferencias de codificación heredadas de los registros del SERVEL, y la

creación o reorganización de unidades territoriales entre elecciones. Sin un tratamiento explícito, estas diferencias impedirían alinear las matrices de distintos años en un mismo espacio de columnas.

El proceso de estandarización se resolvió en dos pasos. Primero, se aplicó un diccionario de equivalencias para unificar nombres históricos que designan a una misma comuna bajo grafías distintas. Segundo, se definió como universo de referencia el conjunto de comunas del ciclo más reciente (2024) y se verificó, para cada ciclo anterior, qué comunas quedaban fuera de esa referencia y cuáles faltaban respecto de ella, de modo de garantizar que todas las matrices compartieran exactamente el mismo conjunto de columnas. El resultado es un universo homogéneo de 346 comunas, que constituye la dimensión de predictores del problema.

**Tabla 1 - Estandarización Comunas.**

| Ciclo | Comunas en referencia (2025) | Comunas faltantes en el ciclo | Detalle de faltantes   |
|-------|------------------------------|-------------------------------|------------------------|
| 2005  | 346                          | 0                             | —                      |
| 2009  | 346                          | 2                             | Alto Hospicio, Hualpén |
| 2013  | 346                          | 0                             | —                      |
| 2017  | 346                          | 1                             | Antártica              |
| 2021  | 346                          | 0                             | —                      |
| 2025  | 346                          | —                             | ciclo de referencia    |

## **Tratamiento de votos no atribuibles**

Dos decisiones de depuración delimitan qué se considera una preferencia política válida. Los votos nulos y los votos en blanco se excluyen del análisis, por no representar una preferencia atribuible a una opción política.

Los votos de candidaturas independientes, en cambio, se conservan de manera explícita en la matriz, bajo el criterio de no distorsionar la composición real de la votación comunal; esta decisión asume el costo de introducir cierto ruido estructural en el entrenamiento, a cambio de preservar la fidelidad de los datos al comportamiento electoral observado.

## **Estructura final de la matriz**


Una vez estandarizadas las comunas y depurados los votos, los datos se organizan en dos niveles. En el nivel intermedio, cada ciclo produce una matriz de comunas por opciones políticas. En el nivel final, esas matrices se consolidan y se reorganizan en un formato orientado al modelo, donde cada fila corresponde a un par año-candidato y cada columna a una comuna.

Como cada ciclo aporta dos candidaturas en segunda vuelta, los seis ciclos



generan una matriz consolidada de 12 filas (6 años  $\times$  2 candidatos) por 346 comunas.

Sobre esta matriz consolidada se define después la partición que sustenta la evaluación: los cuatro ciclos más antiguos (2005, 2009, 2013 y 2017) conforman el conjunto de entrenamiento, con ocho observaciones; el ciclo 2021 se reserva como conjunto de validación; y el ciclo 2025 se reserva como conjunto de prueba. Esta relación —ocho observaciones de entrenamiento frente a 346 predictores— es la que configura formalmente el problema de alta dimensionalidad ( $p \gg n$ ) que justifica los modelos empleados en las secciones siguientes. La construcción y el detalle de esta partición se desarrollan en la subsección 4.



**Ilustración 1- Proceso Simplificado**

## **2. Las dos modalidades de asignación (manual y RxC/FASTEI)**

El núcleo conceptual de este trabajo reside en resolver un problema de correspondencia: los datos municipales registran votos a nivel de partidos y pactos, mientras que la variable que se desea predecir está definida a nivel de candidaturas presidenciales individuales. Antes de aplicar cualquier modelo, es necesario transformar la votación por partido de cada comuna en votación por candidato. Esa transformación no es neutra: la forma de asignar los votos condiciona la matriz de entrada y, por lo tanto, las predicciones. Por esta razón el trabajo no adopta un único criterio, sino que construye y compara dos modalidades de asignación, y trata esa comparación como uno de sus ejes de análisis.

Ambas modalidades comparten el mismo punto de partida —la matriz de votos por partido y comuna, ya estandarizada en la subsección anterior— y producen el mismo tipo de salida —una matriz de votos por candidato y comuna—. Lo que cambia es el mecanismo que vincula partidos con candidatos. Es importante subrayar que, una vez generada esa matriz, el modelo predictivo que opera sobre ella es idéntico en ambos caminos; toda

diferencia de resultados entre modalidades es atribuible exclusivamente al esquema de asignación, no al modelo.

## **2.1 Modalidad manual**

La modalidad manual asigna los votos según criterio experto de afinidad política. Para cada ciclo electoral se define un diccionario que vincula cada partido o pacto con la candidatura presidencial de su bloque, sobre la base de las coaliciones que efectivamente respaldaron a cada candidato en esa elección. Los votos de los partidos asignados a un mismo bloque se suman para obtener la votación del candidato correspondiente en cada comuna. Los votos de candidaturas independientes y de partidos sin una adscripción de bloque inequívoca quedan, por tanto, fuera de la asignación. Esta exclusión no es menor: los votos no asignables representan una fracción creciente del electorado a lo largo del período, cuyo peso se cuantifica y discute en la subsección 6.1.

Esta modalidad tiene la virtud de la transparencia: cada asignación es explícita, auditable y fundada en conocimiento del contexto político. Su debilidad es la subjetividad, especialmente en los casos limítrofes —

partidos con posición ambigua o pactos que cruzan el eje tradicional—, donde la decisión depende del juicio del analista y no de un criterio reproducible.

A esta subjetividad se suma una limitación más profunda, que conviene advertir desde ya: la asignación manual se realiza en el presente sobre elecciones del pasado, por lo que el analista conoce de antemano el resultado de cada ciclo. Ese conocimiento introduce un sesgo retrospectivo (hindsight bias) que afecta a toda la modalidad y no solo a un año en particular, pues la decisión sobre los partidos limítrofes puede verse influida —consciente o inconscientemente— por cómo terminó efectivamente la elección. Conviene distinguir, no obstante, dos grados de este sesgo. En los ciclos 2005 a 2017, la asignación se apoya mayormente en un hecho documentado y verificable —qué partidos integraron formalmente cada coalición en esa segunda vuelta—, lo que acota el margen de juicio a los casos ambiguos. En el ciclo 2025, en cambio, el sesgo es de mayor severidad, porque la asignación no reconstruye coaliciones, sino que se ajusta directamente al resultado, asignando cada partido a la candidatura

con la que su votación comunal correlaciona más alto. Este punto se retoma y desarrolla en la sección de limitaciones.

**Tabla 2 - Diccionario de asignación manual de votos, ciclo 2021 (ejemplo ilustrativo)**

| <b>Partido / pacto</b>               | <b>Bloque</b> | <b>Candidatura</b> |
|--------------------------------------|---------------|--------------------|
| Partido Comunista de Chile           | Izquierda     | Boric              |
| Partido Demócrata Cristiano          | Izquierda     | Boric              |
| Partido Ecologista Verde             | Izquierda     | Boric              |
| Partido Humanista                    | Izquierda     | Boric              |
| Partido Liberal de Chile             | Izquierda     | Boric              |
| Partido por la Democracia            | Izquierda     | Boric              |
| Partido Progresista de Chile         | Izquierda     | Boric              |
| Partido Radical de Chile             | Izquierda     | Boric              |
| Partido Socialista de Chile          | Izquierda     | Boric              |
| Convergencia Social                  | Izquierda     | Boric              |
| Comunes                              | Izquierda     | Boric              |
| Revolución Democrática               | Izquierda     | Boric              |
| Federación Regionalista Verde Social | Izquierda     | Boric              |
| Igualdad                             | Izquierda     | Boric              |
| Sin partido (SP)                     | Izquierda     | Boric              |
| Unión Patriótica                     | Izquierda     | Boric              |
| Renovación Nacional                  | Derecha       | Kast               |
| Unión Demócrata Independiente        | Derecha       | Kast               |
| Evolución Política                   | Derecha       | Kast               |
| Partido Republicano de Chile         | Derecha       | Kast               |
| Partido Conservador Cristiano        | Derecha       | Kast               |
| Partido Nacional Ciudadano           | Derecha       | Kast               |
| Ciudadanos                           | Derecha       | Kast               |
| Nuevo Tiempo                         | Derecha       | Kast               |

Nota: el diccionario asigna cada partido al bloque de la candidatura con la que se alinea de forma predominante en la segunda vuelta. Se excluyen los votos de independientes (y sus variantes de lista) y del Partido Regionalista Independiente Demócrata, por carecer de una adscripción de bloque clara. Esta exclusión implica que la modalidad manual descarta una fracción del electorado, a diferencia de la inferencia ecológica (FASTEI), que reparte probabilísticamente la totalidad de los votos; constituye una limitación propia de esta modalidad.

## **2.2 Modalidad automatizada: inferencia ecológica con el modelo $R \times C$ (FASTEI)**


La modalidad automatizada reemplaza el juicio experto por una estimación estadística. En lugar de decidir a priori a qué candidato pertenece cada partido, infiere esa relación a partir de la estructura conjunta de los datos mediante inferencia ecológica. Concretamente, se emplea el modelo  $R \times C$  implementado en la librería FASTEI de R, que estima la matriz de probabilidades de transición entre las  $R$  filas (partidos) y las  $C$  columnas (candidaturas) usando el algoritmo *Expectation-Maximization*.

El procedimiento tiene tres pasos. Primero, el modelo  $R \times C$  estima, para cada partido, la probabilidad de que sus votos correspondan a cada candidatura. Segundo, esa matriz de probabilidades se dicotomiza: cada partido se asigna a la candidatura con la que presenta mayor probabilidad estimada, generando una matriz de asignación binaria (la asignación dicotomizada resultante para cada ciclo se presenta en el Anexo A, Figuras A1-A6). Tercero, la matriz de votos por partido y comuna se multiplica por esa matriz de asignación, produciendo la votación por candidato y comuna.

**Implementación.** La estimación se realizó en R con la librería FASTEI. Para cada ciclo se construyeron dos matrices a nivel comunal: X, con los votos de la elección presidencial (las C candidaturas), y W, con los votos municipales por partido (las R filas). Previo a la estimación, los votos presidenciales se reescalaron por comuna mediante un factor fila que iguala su total al de los votos de partido, y las comunas sin votos presidenciales válidos se descartaron. Sobre estas matrices se construyó el objeto de estimación con la función `eim()` y se ejecutó el algoritmo Expectation-Maximization mediante `run_em()`, empleando el método de aproximación del paso E - `mvn_pdf` (aproximación por función de densidad normal multivariada). El resultado es, para cada ciclo, una matriz  $R \times C$  de probabilidades de transición partido  $\rightarrow$  candidatura. Finalmente, cada partido se asignó de forma determinista a la candidatura de mayor probabilidad estimada (regla del máximo a posteriori), obteniendo la matriz de asignación binaria que alimenta a los modelos predictivos.

La ventaja de esta modalidad es su carácter reproducible y susceptible de validación: no depende del criterio del analista, sino de un procedimiento estadístico documentado. Su límite es que la inferencia ecológica describe

patrones agregados bajo supuestos de identificación, por lo que la asignación resultante es una estimación —no una verdad observada— y su calidad depende de la homogeneidad de los datos de entrada.



### Ilustración 2- Alineación de Partidos Ejemplo

### 2.3 Sentido de la comparación

La coexistencia de ambas modalidades convierte al esquema de asignación en una variable de análisis, no en un supuesto fijo. Como el modelo



predictivo posterior es idéntico, comparar los resultados de FASTEI y MANUAL permite aislar el efecto del método de agregación de votos sobre la calidad de la predicción. Esta comparación responde directamente a la hipótesis secundaria  $H_{1a}$ , que plantea que la modalidad de asignación incide en la estabilidad y la capacidad de generalización de las predicciones. El contraste cuantitativo entre ambas se desarrolla en las subsecciones 5 y 6. Conviene precisar que ambas modalidades no operan sobre un universo idéntico de votos: mientras FASTEI distribuye la totalidad de los sufragios, la asignación manual descarta los no clasificables. Esta diferencia de cobertura forma parte de lo que se compara y debe tenerse presente al interpretar la ventaja de una modalidad sobre otra.

### **3. Formulación de los modelos predictivos**

Sobre la matriz consolidada se aplican tres modelos de aprendizaje supervisado, elegidos por su idoneidad frente al problema de alta dimensionalidad. Antes de describirlos, conviene precisar la definición común de entradas y salida, porque es idéntica para los tres y para ambas modalidades de asignación.

La variable objetivo y de cada observación es la fracción de votos que obtiene un candidato dentro de su par presidencial del mismo año, es decir, votos del candidato divididos por la suma de votos de las dos candidaturas de esa segunda vuelta. Los predictores  $X$  corresponden, para cada comuna, a la participación de ese candidato-año en la comuna, normalizada también dentro del par del mismo año. Así, tanto la entrada como la salida quedan expresadas como proporciones internas de cada contienda, lo que hace comparables ciclos con distinto nivel de participación. Los tres modelos responden a lógicas distintas de manejar el exceso de predictores: PLS y PCR reducen la dimensionalidad proyectando las comunas sobre un pequeño número de componentes latentes, mientras que el modelo Beta=0 selecciona directamente un subconjunto mínimo de comunas. Los dos primeros priorizan la capacidad predictiva; el tercero, la interpretabilidad territorial.

### **3.1 Partial Least Squares (PLS)**

El PLS construye un número reducido de componentes latentes que maximizan la covarianza entre los predictores y la variable objetivo, y ajusta sobre ellos una regresión lineal. A diferencia del análisis de

componentes principales, orienta la reducción hacia la variable que se desea predecir, lo que suele otorgarle ventaja cuando la señal útil no coincide con las direcciones de mayor varianza de los predictores.

El número de componentes se selecciona mediante validación cruzada leave-one-out (LOO-CV) sobre las ocho observaciones de entrenamiento, escogiendo el valor que minimiza el error absoluto medio (las curvas de selección por LOO-CV de ambos caminos se presentan en el Anexo B, Figuras B1-B4).

### **3.2 Principal Component Regression (PCR)**

La PCR transforma los predictores en componentes principales ortogonales —tras estandarizarlos— y ajusta una regresión lineal sobre los primeros  $k$  componentes. A diferencia del PLS, la extracción de componentes no considera la variable objetivo: solo busca las direcciones de mayor varianza de los predictores. Mitiga la colinealidad y reduce la varianza de los estimadores, aunque puede descartar direcciones poco varianza-densas pero predictivamente relevantes. El número de componentes se selecciona

también por LOO-CV minimizando el error absoluto medio. En ambos modelos, las predicciones crudas se reescalan finalmente para que las dos candidaturas de cada año sumen 1, mediante una normalización por pares.

### **3.3 Modelo Beta=0: regresión LAD con selección de cardinalidad**

El tercer modelo aborda la alta dimensionalidad por una vía distinta: en lugar de comprimir las 346 comunas en componentes, selecciona exactamente un número reducido de ellas y descarta el resto fijando su coeficiente en cero —de ahí el nombre  $Beta = 0$ —. Se formula como un problema de optimización lineal entera-mixta (MILP) que combina una regresión de mínima desviación absoluta (LAD) con una restricción de cardinalidad. Dado que esta formulación es propia del trabajo, se desarrolla aquí en detalle.

#### **Conjuntos.**

Sea  $I = \{1, \dots, n\}$  el conjunto de observaciones de entrenamiento —los ocho pares año-candidato— y  $J = \{1, \dots, p\}$  el conjunto de comunas, con  $p$  hasta 346.

**Parámetros.**

$X_{ij}$  es la fracción de votos del candidato-año  $i$  en la comuna  $j$ ;  $y_i$  es la fracción de votos del candidato-año  $i$  dentro de su par;  $k = 3$  es el número exacto de comunas a seleccionar; y  $M = 1$  es la cota superior (big-M) para los coeficientes.

**Variables de decisión.**

Para cada comuna  $j$ : un peso no negativo  $\beta_j \in [0, M]$  y un indicador binario  $z_j \in \{0,1\}$  que vale 1 si la comuna se selecciona. Para cada observación  $i$ : dos desviaciones no negativas  $\varepsilon_i^+$  y  $\varepsilon_i^-$  que capturan, respectivamente, la parte positiva y negativa del residuo.

**Función objetivo.**

Se minimiza la suma de errores absolutos sobre las ocho observaciones de entrenamiento de forma conjunta:

$$\min \sum_i (\varepsilon_i^+ + \varepsilon_i^-)$$

Como las restricciones obligan a que  $\varepsilon_i^+ - \varepsilon_i^-$  sea igual al residuo y ambas variables son no negativas, en el óptimo una de las dos se anula y la otra toma el valor absoluto del residuo. El objetivo equivale entonces a  $\min \sum_i |y_i - \sum_j X_{ij} \cdot \beta_j|$ , es decir, una regresión de mínima desviación absoluta. Un único vector  $\beta$  se comparte entre los ocho procesos de entrenamiento.

### **Restricciones.**

(1) Residuo, para cada observación  $i$ :

$$y_i = \sum_j X_{ij} \cdot \beta_j + \varepsilon_i^+ - \varepsilon_i^-$$

(2) Acoplamiento big-M entre peso e indicador, para cada comuna  $j$ :

$$\beta_j \leq M \cdot z_j$$

Si  $z_j = 0$ , el peso se fuerza a cero; si  $z_j = 1$ , queda libre en  $[0, M]$ . Como los betas son no negativos por construcción, no se requiere la cota simétrica inferior.

(3) Cardinalidad:

$$\sum_j z_j = k$$

Selecciona exactamente  $k = 3$  comunas; las restantes quedan con  $\beta_j = 0$ .

### **Tipo de problema y resolución.**

Todas las restricciones y el objetivo son lineales; la integralidad proviene de las variables binarias  $z_j$ , lo que clasifica el problema como MILP. Se resuelve con el solver de código abierto CBC (COIN-OR Branch and Cut) desde Pyomo, con un único hilo y límite de tiempo. Por las razones que se detallan más abajo, la solución obtenida es factible, pero se certifica como optimo global.

Al igual que en PLS y PCR, las predicciones del modelo  $Beta = 0$  se reescalan por pares para que las dos candidaturas de cada año sumen 1; esta normalización es posterior y externa a la optimización, ya que la formulación ajusta cada  $y_i$  por separado y no impone esa restricción de suma.



### Ilustración 3 - Esquema comparativo de los tres modelos.

**Tabla 3 - Hiperparámetros por modelo y modalidad de asignación**

| Modelo | Hiperparámetro              | FASTEI | MANUAL |
|--------|-----------------------------|--------|--------|
| PLS    | Componentes latentes (n)    | 6      | 6      |
| PCR    | Componentes principales (n) | 7      | 7      |
| Beta=0 | Comunas seleccionadas (k)   | 3      | 3      |
| Beta=0 | Cota superior big-M         | 1      | 1      |

Nota: en PLS y PCR, el número de componentes se selecciona por validación cruzada leave-one-out (LOO-CV) minimizando el error absoluto medio, dentro de un rango de búsqueda de 1 a 7 componentes (máximo  $n-1$  sobre 8 observaciones de entrenamiento). El modelo Beta=0 se resuelve con el solver CBC (semilla 2025, un hilo, límite de 600 s, tolerancia de brecha absoluta  $10^{-4}$ ); el solver no certifica optimalidad (véase la nota de la subsección 3.3). Los hiperparámetros son idénticos en ambas modalidades; lo único que varía entre caminos es la matriz de entrada  $X$ .

### Nota sobre la resolución y la replicabilidad.

El problema Beta=0 presenta una dificultad computacional inherente a su formulación. Al tratarse de un MILP cuya relajación lineal admite cota inferior cero, el solver CBC no logra certificar la optimalidad dentro de tiempos de cómputo razonables y la búsqueda se interrumpe por límite de



tiempo, entregando la mejor solución factible hallada. Se evaluó el uso de un solver comercial (Gurobi), descartado porque el tamaño del modelo excede el límite de su licencia académica. En consecuencia, las comunas y los coeficientes seleccionados por  $\text{Beta}=0$  corresponden a una solución factible de alta calidad, pero no necesariamente al óptimo global, y pueden variar entre ejecuciones según el punto de interrupción del solver. Los resultados que se reportan en las secciones siguientes corresponden a una corrida representativa, fijada para garantizar la consistencia entre tablas y figuras.

### **3.4 Identidad del modelo entre modalidades**

Es importante reiterar que la formulación de los tres modelos es idéntica para los caminos FASTEI y MANUAL: mismas variables, mismas restricciones, mismos hiperparámetros y mismo procedimiento de selección. Lo único que varía es la matriz  $X$  que entra al modelo, construida según la modalidad de asignación de la subsección 2. Esto es lo que permite atribuir cualquier diferencia de desempeño al esquema de asignación y no al modelo, y es la base de la comparación que se presenta a continuación.

## **4. Diseño de validación**

Habiendo definido los datos (subsección 1), las modalidades de asignación (subsección 2) y los modelos (subsección 3), resta especificar cómo se evalúa si las predicciones son confiables. Esta es la pieza que da credibilidad a todo el análisis: con ocho observaciones de entrenamiento y 346 predictores, un modelo puede ajustar casi perfectamente los datos vistos y, aun así, carecer por completo de capacidad predictiva. El diseño de validación está construido precisamente para distinguir el ajuste genuino del sobreajuste.

### **4.1 Partición temporal de los datos**

La estrategia central es una partición temporal de los seis ciclos en tres conjuntos disjuntos, respetando el orden cronológico para imitar las condiciones reales de predicción —usar el pasado para anticipar el futuro—. El conjunto de entrenamiento reúne los cuatro ciclos más antiguos (2005, 2009, 2013 y 2017), con ocho observaciones; sobre él se estiman los parámetros de los modelos. El conjunto de validación corresponde al ciclo 2021 (Boric–Kast) y se reserva para evaluar el desempeño fuera de muestra

durante la fase de desarrollo. El conjunto de prueba corresponde al ciclo 2025 (Jara–Kast) y se mantiene completamente al margen del ajuste, utilizándose una sola vez para la evaluación final.

La elección de una partición temporal —en lugar de una división aleatoria— no es accesorio. Una división aleatoria de observaciones de distintos años permitiría que información de un ciclo "filtrara" hacia la evaluación de otro, sobrestimando la capacidad predictiva. La partición cronológica evita ese problema y, además, plantea la pregunta en los términos en que realmente importa: ¿permite lo aprendido en elecciones pasadas anticipar una elección posterior que el modelo nunca vio?



**Ilustración 4 - Línea tiempo datasets**

## **4.2 Validación cruzada en entrenamiento**

Dentro del conjunto de entrenamiento, la selección de hiperparámetros —el número de componentes en PLS y PCR— se realiza mediante validación cruzada leave-one-out (LOO-CV). Dado el reducido número de observaciones, esta técnica es la más apropiada: en cada iteración deja fuera una sola observación, ajusta el modelo con las siete restantes y predice la observación omitida; el proceso se repite para las ocho y se promedia el error. Se escoge el número de componentes que minimiza el error absoluto medio en este esquema.

Conviene advertir una cautela interpretativa que se retomará en los resultados: con tan pocas observaciones, un desempeño alto en LOO-CV no garantiza un buen desempeño en validación o prueba. El LOO-CV mide consistencia interna del entrenamiento, no capacidad de generalización a un ciclo nuevo; esa última solo la revelan los conjuntos de 2021 y 2025.

## **4.3 Métricas de evaluación**

El desempeño se cuantifica con tres métricas complementarias. El error absoluto medio (MAE), expresado en puntos porcentuales, mide la

magnitud típica del error de predicción y es la métrica principal por su interpretabilidad directa. El error cuadrático medio (MSE) penaliza con más fuerza los errores grandes. El coeficiente de determinación ( $R^2$ ) indica qué proporción de la variabilidad queda explicada por el modelo respecto de una predicción trivial basada en la media; a diferencia de las dos anteriores, puede tomar valores negativos cuando el modelo predice peor que esa media, situación perfectamente posible —y reveladora— en contextos de alta dimensionalidad.

La evaluación se aplica en dos niveles. Sobre el conjunto de validación (2021) se contrastan las predicciones de cada modelo con el resultado real, lo que permite comparar modelos y modalidades antes de la prueba final. Sobre el conjunto de prueba (2025) se realiza la evaluación definitiva, contrastando la predicción con el resultado efectivamente observado en la segunda vuelta presidencial de 2025.

#### **4.4 Alcance y honestidad del diseño**

Dos precisiones delimitan el alcance de esta evaluación. La primera es que las predicciones crudas se reescalan por pares antes de medir el error, de modo que las dos candidaturas de cada año sumen 1; esta normalización es un post-procesamiento externo al ajuste. La segunda, más importante, es que la evaluación sobre 2025 debe leerse como una evaluación retrospectiva y no como una predicción prospectiva en sentido estricto, puesto que el resultado de la segunda vuelta ya era conocido al momento del análisis. Como se discutió en la subsección 2, la construcción de la matriz  $X$  del año de prueba utiliza información del propio resultado —de forma severa en la modalidad manual y de forma estructural en la inferencia ecológica—, por lo que las cifras de la sección siguiente miden la coherencia del enfoque frente a un resultado verificado, antes que su desempeño en condiciones de incertidumbre real. Esta distinción se desarrolla en la sección de limitaciones.

## **5. Resultados por modalidad y modelo**

Esta subsección reporta el desempeño de los tres modelos en cada modalidad de asignación. Como referencia, los resultados reales contra los

que se contrastan las predicciones son: en validación (2021), Boric 55,80% y Kast 44,20%; en prueba (2025), Jara 41,75% y Kast 58,25%.

## 5.1 Camino FASTEI

**Tabla 4 - Resultados Camino FASTEI**

| Modelo | Hiperp. | MAE LOO (pp) | R <sup>2</sup> LOO | MAE Val 2021 (pp) | R <sup>2</sup> Val 2021 | Pred. Jara 2025 | Pred. Kast 2025 | MAE Test 2025 (pp) |
|--------|---------|--------------|--------------------|-------------------|-------------------------|-----------------|-----------------|--------------------|
| PLS    | n=6     | 0,12         | 0,9995             | 6,34              | -0,192                  | 40,51%          | 59,49%          | 1,24               |
| PCR    | n=7     | 0,07         | 0,9999             | 6,27              | -0,169                  | 39,05%          | 60,95%          | 2,70               |
| Beta=0 | k=3     | —            | —                  | 4,24              | 0,466                   | 9,16%           | 90,84%          | 32,59              |

En el camino FASTEI, los tres modelos identifican correctamente a la oposición (Kast) como ganadora en 2025. El PLS es el más preciso de todo el estudio, con un error de apenas 1,24 puntos porcentuales (el detalle gráfico por candidatura en validación y prueba está en el Anexo C, Figuras C1-C4) respecto del resultado real. El PCR le sigue de cerca con 2,70 puntos. El modelo Beta=0, en cambio, acierta el ganador, pero con una magnitud degenerada (90,84% para Kast frente al 58,25% real), un error de 32,6 puntos que lo inhabilita como predictor puntual, aunque conserva valor interpretativo al señalar qué tres comunas concentran la señal: bajo

FASTEI, el modelo selecciona Peñaflor ( $\beta = 0,713$ ), Lo Prado ( $\beta = 0,232$ ) y, con un peso casi marginal, Cobquecura ( $\beta = 0,055$ ). Las dos de mayor peso absorben el 94,5% del total.

Un patrón llama la atención y debe declararse con honestidad: pese a su error casi nulo en entrenamiento ( $R^2 \text{ LOO} \approx 0,9995\text{--}0,9999$ ), PLS y PCR exhiben  $R^2$  negativo en la validación de 2021 y, de hecho, en ese ciclo predicen erróneamente la dirección del resultado (estiman a Kast por sobre Boric, cuando Boric ganó). El único modelo con  $R^2$  positivo en validación es Beta=0 (0,466). Esta combinación —ajuste casi perfecto en entrenamiento y desempeño pobre en validación— es la firma característica del sobreajuste en un escenario de  $p \gg n$ , y se analiza en la subsección 7 (el MAE y el  $R^2$  por modelo y camino se presentan en el Anexo D, Figuras D1-D4).

## 5.2 Camino MANUAL

**Tabla 5 - Resultados Camino Manual**

| Modelo | Hiperp. | MAE LOO (pp) | $R^2$ LOO | MAE Val 2021 (pp) | $R^2$ Val 2021 | Pred. Jara 2025 | Pred. Kast 2025 | MAE Test 2025 (pp) |
|--------|---------|--------------|-----------|-------------------|----------------|-----------------|-----------------|--------------------|
| PLS    | n=6     | 1,48         | 0,9147    | 10,12             | -2,040         | 47,69%          | 52,31%          | 5,94               |




|               |     |      |        |       |        |        |        |       |
|---------------|-----|------|--------|-------|--------|--------|--------|-------|
| <b>PCR</b>    | n=7 | 1,14 | 0,9501 | 11,34 | -2,820 | 48,21% | 51,79% | 6,47  |
| <b>Beta=0</b> | k=3 | —    | —      | 6,70  | -0,333 | 74,03% | 25,97% | 32,28 |

En el camino MANUAL, PLS y PCR también aciertan al ganador (Kast) (el detalle grafico por candidatura en validación y prueba esta en el Anexo C, Figuras C1-C4), aunque con errores mayores (5,94 y 6,47 puntos) y predicciones más ajustadas al empate. El modelo Beta=0, en cambio, es el único de los seis casos del estudio que se equivoca de ganador: predice un triunfo de la oficialista Jara (74,03%) cuando en realidad ganó Kast, con un error de 32,3 puntos. Los  $R^2$  de validación son negativos en los tres modelos (-2,04 en PLS, -2,82 en PCR y -0,33 en Beta=0), lo que indica un desempeño inferior al de una predicción trivial basada en la media.

### 5.3 Lectura conjunta: acierto del ganador

Reuniendo las dos modalidades, de los seis casos (2 modalidades  $\times$  3 modelos), cinco anticipan correctamente el triunfo de la oposición en la segunda vuelta de 2025, en línea con el resultado verificado (Kast 58,25%).

El único que falla es Beta=0 en su versión manual. La predicción más exacta es la del PLS en el camino FASTEI, con 1,24 puntos de error. Este es el hallazgo central del trabajo y conviene enunciarlo con precisión: bajo la modalidad de asignación más rigurosa (FASTEI) y los modelos de reducción de dimensionalidad (PLS y PCR), el voto municipal anticipó el resultado presidencial con un margen de error de uno a tres puntos porcentuales.



**Ilustración 5 - Predicciones por camino y modelo.**

**Tabla 6 - Resumen predicciones 2025 por modalidad y modelo**

| Modalidad | Modelo | Pred. Jara | Pred. Kast | Ganador predicho | Error vs. real (pp) | ¿Acierta? |
|-----------|--------|------------|------------|------------------|---------------------|-----------|
| FASTEI    | PLS    | 40,51%     | 59,49%     | Kast             | 1,24                | Sí        |
| FASTEI    | PCR    | 39,05%     | 60,95%     | Kast             | 2,70                | Sí        |
| FASTEI    | Beta=0 | 9,16%      | 90,84%     | Kast             | 32,59               | Sí        |
| MANUAL    | PLS    | 47,69%     | 52,31%     | Kast             | 5,94                | Sí        |
| MANUAL    | PCR    | 48,21%     | 51,79%     | Kast             | 6,47                | Sí        |
| MANUAL    | Beta=0 | 74,03%     | 25,97%     | Jara             | 32,28               | No        |

Nota: Resultado real: Jara 41,75% · Kast 58,25% (ganador: Kast). Cinco de seis configuraciones anticipan correctamente el triunfo de la oposición; la única excepción es Beta=0 en la modalidad manual. El error se mide como diferencia absoluta entre la predicción y el resultado real de cada candidatura. La predicción más precisa corresponde a PLS bajo asignación FASTEI (1,24 pp).

## 6. Comparación entre modalidades y análisis de robustez

Las subsecciones anteriores reportaron los resultados de cada combinación por separado. Aquí se contrastan de forma directa, primero entre modalidades de asignación, luego entre modelos, y finalmente se examina la estabilidad de los hallazgos ante variaciones de diseño.

### 6.1 FASTEI frente a MANUAL

La comparación entre modalidades es el contraste que responde a la hipótesis H<sub>1a</sub>. Como el modelo es idéntico en ambos caminos, la diferencia de desempeño se atribuye exclusivamente al esquema de asignación. La

siguiente tabla muestra la brecha en validación (2021) para cada modelo (la comparación grafica FASTEI vs. Manual se presenta en el Anexo F, Figuras F1-F4).

**Tabla 7 - Estadística Errores por Modelo**

| Modelo | MAE Val<br>FASTEI (pp) | MAE Val<br>MANUAL (pp) | $\Delta$ MAE (pp) | R <sup>2</sup> Val<br>FASTEI | R <sup>2</sup> Val<br>MANUAL | $\Delta$ R <sup>2</sup> |
|--------|------------------------|------------------------|-------------------|------------------------------|------------------------------|-------------------------|
| PLS    | 6,34                   | 10,12                  | +3,78             | -0,192                       | -2,040                       | -1,85                   |
| PCR    | 6,27                   | 11,34                  | +5,07             | -0,169                       | -2,820                       | -2,65                   |
| Beta=0 | 4,24                   | 6,70                   | +2,46             | 0,466                        | -0,333                       | -0,80                   |

El resultado es inequívoco: la modalidad FASTEI supera a la manual en los tres modelos, con menor error y mejor R<sup>2</sup> en validación, en todos los casos. La brecha es de 3,8 puntos en PLS, 5,1 en PCR y 2,5 en Beta=0. El mismo patrón se observa en la prueba de 2025 para los modelos de reducción: el PLS-FASTEI erra 1,24 puntos frente a los 5,94 del PLS-MANUAL, y el PCR-FASTEI 2,70 frente a 6,47. En Beta=0, en cambio, ambas modalidades fallan de forma severa en prueba (32,6 y 32,3 puntos), de modo que su ventaja relativa en validación no se traduce en capacidad predictiva. Esto entrega soporte empírico a H<sub>1a</sub>: la forma de asignar los

votos incide de manera sustantiva en la calidad y la estabilidad de las predicciones, y la inferencia ecológica resulta superior a la asignación manual.

Este hallazgo debe leerse junto con la salvedad de la subsección 2: parte de la ventaja de FASTEI puede deberse a que la asignación manual de 2025 incorporó un sesgo retrospectivo severo, lo que paradójicamente empeoró su desempeño en lugar de mejorarlo, al ajustar las asignaciones a correlaciones que no se generalizan. La superioridad de FASTEI es, por tanto, robusta y además conservadora.

A esta consideración se añade una diferencia de cobertura entre modalidades. La asignación manual descarta los votos no clasificables — independientes y partidos de bloque ambiguo—, que representan una fracción creciente del electorado: desde un 17,6% en 2005 hasta un 45,9% en 2021 (Tabla 8). La inferencia ecológica, en cambio, reparte la totalidad de los sufragios. Parte de la superioridad predictiva de FASTEI puede atribuirse, por tanto, no solo a una mejor asignación de los votos, sino a que opera sobre una base de información más completa. La tendencia creciente

del voto descartado es coherente con la fragmentación del sistema de partidos documentada en la literatura (Bunker, 2023).

**Tabla 8 - Voto de partido no asignado por modalidad manual, por ciclo.**

| <b>Ciclo</b> | <b>% de voto de partido no asignado</b> |
|--------------|-----------------------------------------|
| <b>2005</b>  | 17,6%                                   |
| <b>2009</b>  | 23,1%                                   |
| <b>2013</b>  | 28,6%                                   |
| <b>2017</b>  | 37,0%                                   |
| <b>2021</b>  | 45,9%                                   |
| <b>2025</b>  | n/d                                     |

Nota: porcentaje del voto de partido municipal que la modalidad manual no asigna a ningún bloque, por corresponder a independientes o a partidos sin adscripción inequívoca. En el ciclo 2025 no se determina, pues la base de ese ciclo viene agregada por bloque en origen. La modalidad ecológica (FASTEI) no presenta esta pérdida.

## **6.2 Modelos de reducción frente a selección discreta**

El contraste entre modelos responde a H<sub>1b</sub>. Los modelos de reducción de dimensionalidad (PLS y PCR) se comportan de manera consistente y precisa, especialmente bajo FASTEI. El modelo Beta=0, en cambio, muestra un comportamiento errático: bajo FASTEI obtiene el mejor R<sup>2</sup> de validación (0,466, el único positivo), pero produce predicciones de magnitud extrema en la prueba (90,84% para Kast); bajo MANUAL falla incluso el ganador. A ello se suma que la solución no es replicable entre corridas, como se advirtió en la subsección 3.3, por lo que los subconjuntos reportados corresponden a una corrida representativa.

La interpretación es que Beta=0, al forzar la solución a depender de solo tres comunas, gana interpretabilidad, pero pierde estabilidad: la predicción se vuelve muy sensible a la composición exacta de ese trío. En consecuencia, su valor en este trabajo es interpretativo —identificar qué comunas concentran la señal— y no predictivo (los pesos de PLS/PCR y las comunas seleccionadas por Beta=0 en cada camino se presentan en el Anexo E, Figuras E1-E6). Una evidencia adicional de esta inestabilidad es

que ambas modalidades seleccionan tríos completamente disjuntos:

FASTEI elige Peñaflor, Lo Prado y Cobquecura, mientras que MANUAL selecciona Diego de Almagro, Pelluhue y Río Ibáñez, sin una sola comuna en común ni relación geográfica entre ellas. Que un cambio en el esquema de asignación reconfigure por entero el subconjunto seleccionado confirma que la solución de  $\text{Beta}=0$  depende críticamente de la matriz de entrada y no identifica un núcleo territorial robusto. Esta es una conclusión matizada que conviene sostener:  $H_{1b}$  se confirma en el sentido de que los modelos presentan comportamientos diferenciados, siendo los de reducción claramente más aptos para la predicción puntual. Con todo, la comparación entre modalidades debe leerse considerando que la asignación manual ignora entre un 18% y un 46% del voto de partido según el ciclo (subsección 6.1, Tabla 8), limitación de cobertura que la inferencia ecológica no comparte.



**Tabla 9 - Comunas seleccionadas por el modelo Beta=0 (k=3) y su peso B.**

| <i>Modalidad</i>     | Comuna ( $\beta$ ) | Comuna ( $\beta$ ) | Comuna ( $\beta$ )          | $\Sigma\beta$ |
|----------------------|--------------------|--------------------|-----------------------------|---------------|
| <i><b>FASTEI</b></i> | Peñaflor (0,713)   | Lo Prado (0,232)   | Cobquecura<br>(0,055)       | 1,000         |
| <i><b>MANUAL</b></i> | Pelluhue (0,485)   | Río Ibáñez (0,267) | Diego de Almagro<br>(0,249) | 1,001         |

Nota: el modelo Beta=0 fija en cero el coeficiente de las 343 comunas restantes. Los  $\beta$  corresponden a la solución del MILP (solver CBC,  $k = 3$ ) de una corrida representativa; como se indica en la subsección 3.3, esta solución no es replicable entre ejecuciones. La suma de MANUAL (1,001) refleja redondeo.

### **6.3 Análisis de robustez**

Tres ejercicios examinan la estabilidad de los resultados.

Primero, la **sensibilidad de la PCR al escalamiento**. El notebook incluye una variante de PCR sin estandarización previa. En el camino FASTEI, esa variante alcanza un error de prueba de 1,24 puntos —prácticamente idéntico al del PLS— frente a los 2,70 de la PCR estandarizada. Esto indica que el desempeño de la PCR depende de la decisión de estandarizar, un grado de

libertad que conviene reportar de forma transparente y que sugiere preferir el PLS por su mayor estabilidad ante esta elección.


Segundo, la **inestabilidad del modelo Beta=0**, ya señalada: la cardinalidad fija en  $k = 3$  produce predicciones de varianza muy alta. Un análisis de sensibilidad sobre el valor de  $k$  sería un complemento natural para futuras versiones, dejando constancia de que el  $k=3$  actual es una decisión de diseño y no un óptimo derivado de validación.

Tercero, y más importante, la **fragilidad muestral**. Toda la evaluación descansa en dos observaciones de validación (2021) y dos de prueba (2025). Con tan pocos puntos, cualquier métrica es altamente sensible y no admite generalización estadística fuerte. Esta es la limitación estructural del estudio y condiciona la lectura de todas las cifras anteriores: los resultados son indicativos y coherentes, pero no constituyen evidencia concluyente en sentido inferencial.

#### **6.4 Síntesis de la comparación**

En conjunto, la evidencia apunta en una dirección clara dentro de sus límites: la asignación por inferencia ecológica (FASTEI) domina a la manual; los modelos de reducción (PLS, PCR) superan a la selección

discreta ( $\text{Beta}=0$ ) en capacidad predictiva; y el PLS-FASTEI emerge como la combinación más precisa y estable. Estas conclusiones, sin embargo, deben sopesarse contra el sobreajuste evidenciado en validación y la fragilidad del tamaño muestral, ambos analizados en la subsección siguiente.



**Ilustración 6 - Comparativo MAE por modelo y camino.**

## 7. Síntesis de hallazgos

Este capítulo aplicó el pipeline completo —construcción del dataset, dos modalidades de asignación, tres modelos y un diseño de validación temporal— al problema de anticipar la segunda vuelta presidencial chilena a partir del voto municipal. Conviene consolidar lo que la evidencia permite

afirmar, y con qué grado de certeza, antes de pasar a la discusión de los resultados.

El hallazgo principal es que el voto municipal contiene señal predictiva sobre el voto presidencial. Cinco de las seis combinaciones evaluadas anticiparon correctamente el triunfo de la oposición en 2025, y la mejor de ellas —PLS bajo asignación FASTEI— lo hizo con un error de 1,24 puntos porcentuales respecto del resultado real. Este resultado respalda la hipótesis alternativa  $H_1$  frente a la nula  $H_0$ : bajo métodos adecuados de asignación y reducción de dimensionalidad, la predicción es posible. La afirmación, sin embargo, debe enunciarse con la cautela que impone el diseño: se trata de una evaluación retrospectiva sobre un único ciclo de prueba, no de una predicción prospectiva validada en múltiples elecciones.

Respecto de las hipótesis secundarias, el balance es el siguiente. La hipótesis  $H_{1a}$  —sobre el efecto de la modalidad de asignación— queda respaldada con claridad: la inferencia ecológica (FASTEI) superó a la asignación manual en los tres modelos, en validación y en prueba, lo que confirma que el esquema de agregación de votos incide de forma sustantiva en la calidad de las predicciones. La hipótesis  $H_{1b}$  —sobre el

comportamiento diferenciado de los modelos— también se sostiene: los modelos de reducción de dimensionalidad (PLS y PCR) demostraron ser aptos para la predicción puntual, mientras que el modelo de selección discreta ( $\text{Beta}=0$ ) mostró valor interpretativo pero inestabilidad predictiva. La hipótesis  $H_{1c}$  —sobre el efecto de los votos independientes— no pudo aislarse experimentalmente en este diseño, ya que su tratamiento quedó entrelazado con las decisiones de asignación; se la deja planteada como una línea pendiente de verificación específica.

Junto a estos hallazgos positivos, el capítulo dejó en evidencia dos limitaciones estructurales que condicionan toda lectura de los resultados. La primera es el sobreajuste: el contraste entre un ajuste casi perfecto en entrenamiento ( $R^2$  LOO cercano a 1) y un  $R^2$  negativo en la validación de 2021 —donde los modelos de reducción incluso erraron la dirección del resultado— es la firma característica de un problema con muchos más predictores que observaciones. La segunda es la fragilidad muestral: con dos observaciones de validación y dos de prueba, ninguna métrica admite generalización estadística fuerte. A ello se suma la salvedad metodológica

del sesgo retrospectivo en la construcción de la matriz del año de prueba, más severo en la modalidad manual.

La lectura honesta, por tanto, bajo la configuración más rigurosa, el voto municipal mostró ser coherente con el resultado presidencial observado, con un margen de error notablemente bajo, y la comparación entre modalidades y modelos arrojó conclusiones metodológicas claras y, en lo esencial, reproducibles. El alcance, la interpretación de estas tensiones y las implicancias para la analítica de negocios y el análisis electoral se desarrollan en la sección de discusión y conclusiones.

**Tabla 10 - Resumen de Hipótesis.**

| <b>Hipótesis</b> | <b>Enunciado</b>                                                                                                                             | <b>Estado</b> | <b>Evidencia que lo sustenta</b>                                                                                                                                                                                        |
|------------------|----------------------------------------------------------------------------------------------------------------------------------------------|---------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| H <sub>1a</sub>  | La modalidad de asignación (manual vs. inferencia ecológica R×C) incide en la estabilidad y capacidad de generalización de las predicciones. | Respaldada    | FASTEI supera a MANUAL en los tres modelos, en validación y prueba (subsección 6.1): MAE de validación menor en 3,8 pp (PLS), 5,1 pp (PCR) y 2,5 pp (Beta=0); y en prueba, PLS-FASTEI 1,24 pp vs. 5,94 pp de PLS-MANUAL |
| H <sub>1b</sub>  | Los modelos (PLS, PCR, L <sub>0</sub> ) presentan comportamientos diferenciados en condiciones de alta dimensionalidad y colinealidad.       | Respaldada    | PLS y PCR son estables y precisos; Beta=0 es interpretable pero inestable, llegando a errar el ganador en su versión manual (subsecciones 5 y 6.2). Los comportamientos son claramente distintos.                       |
| H <sub>1c</sub>  | La inclusión de votos de candidaturas independientes afecta la capacidad predictiva de los modelos.                                          | No aislada    | El efecto de los independientes quedó entrelazado con las decisiones de asignación y no se diseñó un experimento que lo aislara (subsección 6.3). No es posible confirmarla ni refutarla con la evidencia disponible.   |

Nota: el estado "no aislada" indica que el diseño del estudio no permitió evaluar la hipótesis de forma independiente, no que haya sido refutada. Su verificación específica se plantea como línea de trabajo futura.

## **Conclusiones**

Esta investigación se propuso determinar si es posible anticipar el resultado de una segunda vuelta presidencial chilena a partir de los resultados de elecciones municipales previas, empleando técnicas de analítica de negocios apropiadas para contextos de alta dimensionalidad. El análisis desarrollado en el capítulo de Contenido permite responder afirmativamente a esa pregunta, dentro de límites que conviene precisar, y arroja además conclusiones metodológicas de valor sobre cómo debe abordarse el problema.

La primera conclusión, y la más relevante, es que el voto municipal contiene señal predictiva sobre el voto presidencial. Cinco de las seis combinaciones evaluadas anticiparon correctamente el triunfo de la oposición en la segunda vuelta de 2025, y la configuración más precisa —el modelo PLS bajo asignación FASTEI— lo hizo con un error de apenas 1,24 puntos porcentuales respecto del resultado real. Esta evidencia respalda la hipótesis alternativa frente a la nula: con métodos adecuados de asignación y reducción de dimensionalidad, la predicción es posible. La afirmación se sostiene en los resultados de la subsección 5 y no debe sobreinterpretarse:



corresponde a una evaluación retrospectiva sobre un único ciclo de prueba, no a una predicción prospectiva validada en múltiples elecciones.

La segunda conclusión es que la forma de asignar los votos municipales a las candidaturas presidenciales no es un detalle técnico, sino un factor determinante de la calidad predictiva. La modalidad de inferencia ecológica (FASTEI) superó a la asignación manual experta en los tres modelos, tanto en validación como en prueba, con brechas de validación de 3,8 puntos en PLS, 5,1 en PCR y 2,5 en Beta=0 (subsección 6.1). Esto confirma la hipótesis H<sub>1a</sub> y deja una recomendación práctica clara: ante este tipo de problema, conviene preferir un método de asignación reproducible y basado en datos por sobre el juicio experto, no solo por transparencia metodológica, sino porque entrega mejores resultados. Debe considerarse, no obstante, que esta superioridad se explica en parte por una diferencia de cobertura: la asignación manual descarta una fracción creciente del electorado —hasta un 46% en 2021—, mientras que la inferencia ecológica aprovecha la totalidad de los votos.

La tercera conclusión distingue entre los modelos según su propósito. Los modelos de reducción de dimensionalidad (PLS y PCR) demostraron ser

aptos para la predicción puntual, con errores bajos y comportamiento estable, mientras que el modelo de selección discreta  $Beta=0$  mostró inestabilidad predictiva —llegando a fallar el ganador en su versión manual— pero conserva valor interpretativo al identificar qué comunas concentran la señal. Se concluye, en línea con la hipótesis H1b, que no existe un "mejor modelo" en abstracto: la elección depende de si el objetivo es predecir una magnitud o comprender una estructura territorial.

La cuarta conclusión es de carácter autocrítico y resulta inseparable de las anteriores. El estudio evidenció dos limitaciones estructurales que condicionan el alcance de sus resultados. Por una parte, un sobreajuste característico de los problemas con muchos más predictores que observaciones: el ajuste casi perfecto en entrenamiento ( $R^2$  cercano a 1) contrasta con un  $R^2$  negativo en la validación de 2021, ciclo en que los modelos de reducción incluso erraron la dirección del resultado. Por otra, una fragilidad muestral severa: con dos observaciones de validación y dos de prueba, ninguna métrica admite generalización estadística fuerte. A ello se añade el sesgo retrospectivo en la construcción de la matriz del año de prueba, más agudo en la modalidad manual. Estas limitaciones no anulan

los hallazgos, pero obligan a leerlos como indicativos y coherentes antes que como evidencia concluyente.

Desde la perspectiva de la analítica de negocios, el trabajo aporta un caso concreto de cómo transformar datos públicos, masivos y objetivos en un insumo de decisión bajo incertidumbre. Más allá del acierto puntual, el valor del enfoque reside en su carácter reproducible y en su capacidad de responder no solo al "qué" —quién gana— sino también al "dónde" —qué territorios concentran información predictiva—, dimensión especialmente útil para la asignación de recursos en contextos estratégicos. Esta es una contribución que se sustenta en el diseño del estudio, aunque su explotación plena exceda el alcance de esta actividad.

En síntesis, la conclusión defendible no es que el método "predice elecciones", sino que, bajo su configuración más rigurosa, el voto municipal resultó coherente con el resultado presidencial observado con un margen de error notablemente bajo, y que la comparación sistemática entre modalidades y modelos produjo conclusiones metodológicas claras y, en lo esencial, replicables. El principal aporte de este trabajo es, en esa medida, tanto sustantivo como metodológico: ofrece evidencia preliminar a favor del

valor predictivo del voto municipal y, al mismo tiempo, un marco reproducible para seguir investigándolo. Las líneas futuras se desprenden directamente de las limitaciones señaladas: ampliar la base de ciclos para robustecer la validación, aislar experimentalmente el efecto de los votos independientes (hipótesis  $H_{1c}$ , que este diseño no permitió verificar), incorporar un análisis de sensibilidad sobre la cardinalidad del modelo  $\text{Beta}=0$  —idealmente resolviéndolo con un solver capaz de certificar el óptimo global, que el presente trabajo no pudo alcanzar—, y avanzar hacia una verdadera predicción prospectiva, evaluada antes de conocerse el resultado.

## Bibliografía

1. Lazarsfeld, P. F., Berelson, B., & Gaudet, H. (1944). *The people's choice: How the voter makes up his mind in a presidential campaign*. Duell, Sloan and Pearce.
2. Campbell, A., Converse, P. E., Miller, W. E., & Stokes, D. E. (1960). *The American Voter*. Wiley.
3. Lewis-Beck, M. S., & Tien, C. (2016). Election forecasting: Principles and practice. In J. N. Druckman (Ed.), *The Oxford Handbook of Polling and Survey Methods* (pp. 411–432). Oxford University Press.
4. Luna, J. P. (2017). The Chilean party system: From stability to crisis. *Journal of Latin American Studies*, 49(2), 241–267.
5. Navia, P. (2006). La elección presidencial de 2005 en Chile. *Revista de Ciencia Política*, 26(1), 164–179.
6. Spoon, J.-J., & West, K. J. (2015). "Bottoms Up: How Subnational Elections Predict Parties' Decisions to Run in Presidential Elections in Europe and Latin America." *Research & Politics*, 2(3), 1–8.

7. Bunker, Kenneth. (2023). La elección de 2017 y el fraccionamiento del sistema de partidos en Chile. *Revista Chilena de Derecho y Ciencia Política*. 9. 202-225. 10.7770/rchdcp-V9N2-art1823.
8. King, G. (1997). *A Solution to the Ecological Inference Problem*. Princeton University Press.
9. Rosen, O., Jiang, W., King, G., & Tanner, M. A. (2001). Bayesian and frequentist inference for ecological inference: The  $R \times C$  case. *Statistica Neerlandica*, 55(2), 134–156.
10. Wakefield, J. (2004). Ecological inference for  $2 \times 2$  tables. *Journal of the Royal Statistical Society: Series A (Statistics in Society)*, 167(3), 385–445.
11. Wold, H. (1985). Partial least squares. In S. Kotz & N. L. Johnson (Eds.), *Encyclopedia of statistical sciences* (Vol. 6, pp. 581–591). Wiley.
12. Miller, A. (2002). *Subset selection in regression* (2nd ed.). Chapman & Hall/CRC.

13. Grimmer, J., Roberts, M. E., & Stewart, B. M. (2021). Machine learning for social science: An agnostic approach. *Annual Review of Political Science*, 24, 395–419.
14. Shmueli, G., Bruce, P. C., Gedeck, P., & Patel, N. R. (2019). *Data mining for business analytics: Concepts, techniques, and applications in Python*. Wiley.
15. Tumasjan, A., Sprenger, T. O., Sandner, P. G., & Welpe, I. M. (2010). Predicting elections with Twitter: What 140 characters reveal about political sentiment. *ICWSM*, 10(1), 178–185.
16. Kennedy, C., Blumenthal, M., Clement, S., Clinton, J. D., Durand, C., Franklin, C., ... Wlezien, C. (2018). An evaluation of the 2016 election polls in the United States. *Public Opinion Quarterly*, 82(1), 1–33.
17. Thraves, C., Ubilla, P., & Hermosilla, D. (2024). *Inferencia ecológica y predicción electoral en Chile: Una aplicación del modelo  $R \times C$* . Documento de trabajo. Universidad de Chile.
18. CIPER. (2021, noviembre). *Buenas y malas encuestas*.


## Anexos

A – Alineación RXC por ciclo.

A1 → ALINEACION\_2005.png (Bachelet–Piñera)

### Alineación de partidos (R×C) – 2005


Asignación dicotomizada de cada partido a una candidatura




Fuente: elaboración propia con inferencia ecológica R×C (FASTEI).



A2 → ALINEACION\_2009.png (Frei–Piñera)




A3 → ALINEACION\_2013.png (Bachelet–Matthei)



A4 → ALINEACION\_2017.png (Guillier–Piñera)

### Alineación de partidos (RxC) – 2017

Asignación dicotomizada de cada partido a una candidatura




Fuente: elaboración propia con inferencia ecológica RxC (FASTEI).

A5 → ALINEACION\_2021.png (Boric–Kast)

Alineación de partidos (RxC) – 2021


Asignación dicotomizada de cada partido a una candidatura



A6 → ALINEACION\_2025.png (Jara–Kast)

**Alineación de partidos (R×C) – 2025**


Asignación dicotomizada de cada partido a una candidatura




Fuente: elaboración propia con inferencia ecológica R×C (FASTEI).

## B – Selección de componentes (LOO-CV)


B1 → FASTEI\_01 (PLS)




B2 → FASTEI\_02 (PCR)



B3 → MANUAL\_01 (PLS)




B4 → MANUAL\_02 (PCR)




C – Predicción por Candidatura


C1 → FASTEI\_03 (validación 2021)




C2 → FASTEI\_04 (test 2025)



C3 → MANUAL\_03




C4 → MANUAL\_04






D – Métricas por modelo (MAE y R²)


D1 → FASTEI\_05 (MAE)




D2 → FASTEI\_06 (R²)



D3 → MANUAL\_05




D4 → MANUAL\_06




E – Interpretabilidad territorial


E1 → FASTEI\_07 (top PLS)




E2 → FASTEI\_08 (top PCR)




E3 → FASTEI\_09 (Beta=0)




E4 → MANUAL\_07



E5 → MANUAL\_08




E6 → MANUAL\_09




F – Comparación entre caminos.


F1 → COMPARA\_10 (MAE val)



F2 → COMPARA\_MAE (val+prueba)



F3 → COMPARA\_11 (Kast 2025)



F4 → COMPARA\_12 ( $R^2$ )

