



“Pronóstico de demanda de consultas de urgencias respiratorias para la planificación operativa de la red asistencial en la Región de Los Lagos”

**ACTIVIDAD FORMATIVA EQUIVALENTE A TESIS PARA OPTAR AL GRADO DE
MAGÍSTER EN ANALÍTICA DE NEGOCIOS**

Estudiante: Jorge Gutiérrez Soto

Profesor Guía: Richard Weber

Santiago, junio 2026

Tabla de contenido

Resumen Ejecutivo	6
1. CAPÍTULO 1: PLANTEAMIENTO DEL PROBLEMA Y DISEÑO DE LA INVESTIGACIÓN 7	
1.1 Introducción.....	7
1.2 Planteamiento y formulación del problema	11
1.3 Hipótesis.....	13
1.4 Objetivos.....	13
1.5 Metodología propuesta	14
1.5.1 Diseño de investigación	14
1.5.2 Fuente de datos.....	15
1.5.3 Partición temporal.....	15
1.5.4 Esquema de validación: walk-forward mensual recursivo	16
1.5.5 Variables de entrada.....	16
1.5.6 Modelos evaluados.....	18
1.5.7 Métricas de evaluación	19
1.5.8 Análisis de robustez	20
1.5.9 Herramientas computacionales.....	21
1.5.10 Síntesis del diseño experimental.....	21
2. CAPÍTULO 2: MARCO TEÓRICO.....	23
2.1 Pronóstico de demanda en servicios de urgencia	23
2.2 Modelos clásicos de series temporales	24
2.3 Modelos lineales estructurados	24
2.4 Métodos de ensamble: Gradient Boosting.....	25
2.5 Redes neuronales recurrentes: LSTM	25
2.6 Síntesis	26
3. CAPÍTULO 3: ANÁLISIS EXPLORATORIO DE LA SERIE TEMPORAL	27
3.1 Análisis exploratorio y visualización de tendencias	28
3.2 Análisis de heterocedasticidad y estacionalidad.....	29
3.3 Transformación logarítmica para estabilizar varianza y nivel de la serie	31
3.4 Identificación de estacionalidades múltiples.....	33
3.5 Eliminación o marcación de observaciones en intervalos potencialmente problemáticos.....	37

3.6	Especificación de forma funcional, selección de variables estacionales y evaluación de desempeño.....	38
3.7	Definición de entrenamiento y validación temporal	39
3.8	Incorporación de efectos calendario	40
3.9	Análisis de autocorrelación residual	45
3.10	Síntesis estructural de patrones identificados	48
3.11	Implicancias para la selección metodológica	53
3.12	Definición formal de variables.....	54
4.	CAPÍTULO 4: SELECCIÓN METODOLÓGICA Y MODELAMIENTO PREDICTIVO	67
4.1	Enfoque de solución: arquitectura del sistema de pronóstico.....	67
4.2	Explicación detallada de cada etapa	69
4.3	Regresión lineal estructurada (OLS)	73
4.4	Gradient Boosting.....	74
4.5	Red Neuronal recurrente (LSTM).....	75
4.6	Síntesis comparativa del modelamiento.....	77
5.	CAPÍTULO 5: RESULTADOS Y DISCUSIÓN	79
5.1	Comparación global de desempeño predictivo	79
5.2	Justificación empírica del modelo seleccionado.....	81
5.3	Ganancia marginal por complejidad	84
5.4	Desempeño mensual del walk-forward.....	85
5.5	Robustez temporal: 2024 vs 2025.....	88
5.6	Degradación de la precisión por horizonte de predicción.....	90
5.7	Implicancias para la planificación operativa.....	94
5.8	Limitaciones	99
6.	CAPÍTULO 6: CONCLUSIONES Y TRABAJO FUTURO	101
6.1	Conclusiones	101
6.2	Trabajo futuro.....	102
	REFERENCIAS BIBLIOGRÁFICAS	104
	ANEXOS.....	107
	Anexo A. Configuración de hiperparámetros del modelo CatBoost	107
	Anexo B. Arquitectura de las variantes LSTM.....	107
	Anexo C. Reproducibilidad.....	108
	Anexo D. Índices de validez del agrupamiento (K-Means)	108

Índice de Figuras

Figura 1.1 Mapa geográfico Región de Los Lagos.....	8
Figura 1.2 Distribución nacional de consultas respiratorias (2015–2025)	9
Figura 1.3 Participación de la Región de Los Lagos en el total nacional (2015–2025)	10
Figura 3.1 Serie diaria de consultas de urgencia respiratoria, Región de Los Lagos (2015–2025)...	27
Figura 3.2 Media móvil ± 1 desviación estándar (ventana 30 días)	28
Figura 3.3 Varianza móvil de la serie (ventana 30 días)	30
Figura 3.4 Serie diaria log-transformada de consultas de urgencia respiratoria, Región de Los Lagos (2015–2025)	31
Figura 3.5 Varianza móvil (ventana 30 días) de la serie de consultas respiratorias antes y después de la transformación.....	32
Figura 3.6 Media diaria de consultas por mes	34
Figura 3.7 Media diaria de consultas por día de la semana	35
Figura 3.8 Perfil promedio anual de consultas respiratorias (día del año 1–365).....	36
Figura 3.9 Distribución de consultas diarias de urgencia respiratoria	37
Figura 3.10 Serie temporal con períodos de vacaciones escolares.....	41
Figura 3.11 Perfil estacional pre-pandemia (2015–2019)	42
Figura 3.12 Perfil estacional durante pandemia (2020–2021)	43
Figura 3.13 Perfil estacional post-pandemia (2022–2025).....	44
Figura 3.14 Ajuste del modelo OLS base en el período de entrenamiento (2015–2023).....	45
Figura 3.15 Funciones de autocorrelación (ACF) y autocorrelación parcial (PACF).....	46
Figura 3.16 Segmentación del período pandémico por tramos (A–F)	50
Figura 4.1 Esquema general del proceso metodológico y secuencia de modelamiento incremental	68
Figura 5.1 Pronóstico CatBoost fuera de muestra (walk-forward mensual, 2024–2025)	80
Figura 5.2 Pronóstico OLS fuera de muestra (walk-forward mensual, 2024–2025)	80
Figura 5.3 Pronóstico LSTM direct multi-step fuera de muestra (walk-forward mensual, 2024–2025)	81
Figura 5.4 Comparación de desempeño predictivo fuera de muestra (walk-forward mensual, enero 2024 – diciembre 2025).....	82

Figura 5.5 Comparación mensual de desempeño predictivo entre OLS y CatBoost a lo largo de las 24 ventanas del walk-forward (enero 2024 – diciembre 2025)	87
Figura 5.6 Comparación del MAPE anual por modelo (2024 vs 2025), calculado a partir de las métricas mensuales de la Tabla 5.2.	89
Figura 5.7 Degradación del MAPE por horizonte de predicción (CatBoost, walk-forward, 24 meses fuera de muestra).....	91
Figura 5.8 Trayectorias de error por mes y centroides de cada régimen	92

Índice de Tablas

Tabla 1.1 Síntesis del diseño experimental	22
Tabla 3.1 Patrones estructurales identificados en la serie de consultas respiratorias.	49
Tabla 3.2 Calendario oficial de vacaciones de invierno, Región de Los Lagos (MINEDUC)	57
Tabla 3.3 Variables de intervención y eventos puntuales	60
Tabla 3.4 Resumen de dimensionalidad por bloque de variables y modelo.....	62
Tabla 4.1 Comparación de características de los modelos implementados.	77
Tabla 5.1 Métricas de desempeño fuera de muestra sobre los 24 meses del walk-forward	79
Tabla 5.2 Métricas de desempeño por mes del walk-forward (enero 2024 – diciembre 2025).....	86
Tabla 5.3 Métricas de desempeño agregadas por año (2024 y 2025) para cada modelo, calculadas a partir de las métricas mensuales de la Tabla 5.2.	89
Tabla 5.4 Desempeño de CatBoost en horizontes de referencia (promedio sobre los 24 meses fuera de muestra).	90
Tabla 5.5 Desempeño por tramo operativo.	91
Tabla 5.6 Propuesta de protocolo de Alertas Tempranas para la red asistencial basado en predicciones algorítmicas	96
Tabla 5.7 Reducción del error de anticipación al adoptar el modelo (consultas diarias y proyección anual).	97
Tabla 5.8 Beneficio anual ilustrativo según costo unitario asumido.....	98
Tabla D.1 Índices de validez interna del agrupamiento K-Means para k entre 2 y 6.	108

Resumen Ejecutivo

La red asistencial de la Región de Los Lagos enfrenta aumentos estacionales de urgencias respiratorias que tensionan su capacidad operativa. Este estudio evalúa modelos predictivos para anticipar la demanda a 30 días, apoyando decisiones estratégicas de los **Servicios de Salud Reloncaví, Chiloé y Osorno**, dependientes de la Subsecretaría de Redes Asistenciales. Utilizando datos del DEIS (2015-2025), se compararon tres enfoques de modelación: Regresión Lineal Estructurada (OLS), Gradient Boosting (CatBoost) y una red neuronal recurrente (LSTM), evaluados mediante un esquema *walk-forward* mensual. CatBoost obtuvo el mejor desempeño ($R^2=0.79$, MAPE=11.91 %), superando a los demás al capturar eficientemente dependencias temporales y eventos móviles como vacaciones de invierno. Se concluye que este modelo permite anticipar escenarios de alta demanda, cumpliendo con el objetivo de gestión interna de los Servicios de Salud de **establecer un sistema de planificación y distribución de recursos** que mejore la oferta de la red asistencial, optimice la asignación de turnos y reduzca los tiempos de espera para resolución de problemas de salud en la población usuaria.

1. CAPÍTULO 1: PLANTEAMIENTO DEL PROBLEMA Y DISEÑO DE LA INVESTIGACIÓN

1.1 Introducción

La Región de Los Lagos se localiza en la macrozona sur de Chile y presenta una configuración territorial caracterizada por alta dispersión poblacional, presencia de archipiélagos, conectividad heterogénea y condiciones climáticas templado-lluviosas con marcada estacionalidad invernal. Estas características geográficas y climáticas influyen directamente en la organización de la red asistencial y en la dinámica de la demanda por consultas en servicios de urgencia, particularmente en patologías respiratorias, cuya incidencia tiende a incrementarse durante los meses fríos (ver Figura 1.1).

Desde el punto de vista demográfico, según el Censo 2017 del Instituto Nacional de Estadísticas (INE), la Región de Los Lagos cuenta con aproximadamente 828.708 habitantes, representando cerca del 4-5 % de la población nacional. Su red asistencial se organiza en tres servicios de salud —Osorno, Reloncaví y Chiloé— que reportan datos al Departamento de Estadísticas e Información de Salud (DEIS), constituyendo una fuente de información consolidada para el análisis de series temporales de demanda asistencial (ver Figuras 1.2 y 1.3).




Figura 1.2 Distribución nacional de consultas respiratorias (2015–2025)




Figura 1.3 Participación de la Región de Los Lagos en el total nacional (2015-2025)

Las epidemias estacionales de infecciones respiratorias constituyen un desafío recurrente para los sistemas de salud a nivel mundial, generando presión sobre la capacidad hospitalaria y obligando a las autoridades a planificar recursos físicos y humanos que frecuentemente son superados por la demanda de un año particularmente severo (Sauré et al., 2025). En Chile, esta presión se manifiesta anualmente en la denominada "campaña de invierno", durante la cual el sistema de salud debe expandir su capacidad instalada —especialmente en camas UCI pediátricas— para absorber el incremento estacional. A modo de referencia, durante la temporada 2023, la ocupación UCI por causas respiratorias alcanzó un peak de 888 camas a

nivel nacional, superando la capacidad expandida del sistema que era de 858 camas, lo que evidencia la magnitud del problema de planificación (Sauré et al., 2025).

La literatura ha señalado que los modelos de pronóstico pueden anticipar los *peaks* de admisiones hospitalarias por infecciones respiratorias con horizontes de hasta 21 días, permitiendo a los gestores hospitalarios manejar proactivamente la utilización de recursos, dotación de personal y programación de procedimientos electivos (Albrecht et al., 2024). En este contexto, la Región de Los Lagos —con su marcada estacionalidad y su estructura territorial heterogénea— representa un caso de interés para evaluar si herramientas cuantitativas de pronóstico pueden apoyar la planificación de capacidad operativa en la red asistencial regional.

1.2 Planteamiento y formulación del problema

La gestión de la demanda en servicios de urgencia hospitalaria constituye un desafío operativo crítico para los sistemas de salud, particularmente en contextos de alta estacionalidad como las consultas por patologías respiratorias. En la Región de Los Lagos, esta demanda presenta variaciones significativas a lo largo del año, con incrementos pronunciados durante periodos invernales y cambios estructurales recientes asociados a la pandemia de COVID-19.

En la práctica, la planificación de capacidad operativa —incluyendo disponibilidad de camas, dotación de personal, insumos clínicos y coordinación con la red asistencial— se realiza frecuentemente bajo esquemas reactivos o basados en promedios históricos, lo que limita la capacidad del sistema para anticipar periodos de alta presión asistencial. **Esta situación puede derivar en saturación de servicios, aumento en tiempos de espera y uso ineficiente de recursos.**

Desde una perspectiva analítica, el problema consiste en determinar si es posible generar pronósticos de demanda con un nivel de precisión y estabilidad suficiente para apoyar este tipo

de decisiones operativas en un entorno caracterizado por estacionalidad, eventos calendario móviles y cambios estructurales recientes.

En consecuencia, la presente investigación se orienta a evaluar el desempeño de distintos modelos de pronóstico aplicados a la demanda de urgencias respiratorias en la Región de Los Lagos, no solo en términos de precisión predictiva, sino en su capacidad de generar información útil para la planificación de capacidad operativa en el sistema público de salud.

Justificación Institucional y Estratégica

El desarrollo de este modelo predictivo se alinea directamente con el marco regulatorio y la misión de los **Servicios de Salud Reloncaví, Chiloé y Osorno**, dependientes del Ministerio de Salud y la Subsecretaría de Redes Asistenciales. De acuerdo con el marco legal que rige a estos servicios (que incluye la Ley N° 18.834 de Estatuto Administrativo, la Ley N° 19.937 de Autoridad Sanitaria y Gestión, y el Decreto N° 136 de 2005, entre otros), su misión institucional consiste en regular, supervisar y articular las redes de salud para **satisfacer las necesidades de la población usuaria con énfasis en la entrega de prestaciones de calidad y oportunidad.**

En este sentido, la capacidad de pronosticar la demanda asistencial a 30 días deja de ser un mero ejercicio estadístico y responde directamente a dos directrices institucionales fundamentales:

1. **Objetivo Estratégico:** Mejorar la gestión de la red asistencial para generar un **modelo eficiente de tiempos de espera** en la resolución de los problemas de salud, optimizando la resolutividad y asegurando la continuidad de los cuidados.
2. **Objetivo de Gestión Interna:** Establecer un **sistema de planificación y distribución de los recursos**, buscando mejorar proactivamente las capacidades instaladas en la red

asistencial (como camas, dotación de personal e insumos) con un enfoque territorial y de equidad en el acceso.

Por lo tanto, la implementación de modelos predictivos precisos se convierte en una herramienta analítica habilitante para que las autoridades de los Servicios de Salud puedan anticipar la demanda operativa y cumplir eficazmente con su misión institucional.

1.3 Hipótesis

Hipótesis principal (H1 – utilidad operativa)

Es posible generar pronósticos de demanda de urgencias respiratorias con un nivel de precisión suficiente para anticipar períodos en los que la demanda excede umbrales operativos relevantes, permitiendo apoyar decisiones de planificación de capacidad en la red de salud de la Región de Los Lagos.

Hipótesis secundaria (H2 – desempeño predictivo mínimo requerido)

Los modelos de pronóstico evaluados presentan un desempeño predictivo superior a un baseline estacional simple, bajo un esquema de validación temporal fuera de muestra, alcanzando niveles de error compatibles con su uso en planificación operativa.

Hipótesis complementaria (H3 – valor de información estructurada)

La incorporación de variables estructuradas que capturan estacionalidad, efectos calendario y cambios de régimen mejora significativamente el desempeño predictivo respecto a modelos que utilizan únicamente la historia de la serie.

1.4 Objetivos

Objetivo general

Diseñar y evaluar un sistema de pronóstico de demanda de urgencias respiratorias en la Región de Los Lagos, mediante modelos de series temporales aplicados a datos DEIS (2015-2025), para apoyar la planificación de capacidad operativa en la red asistencial regional.

Objetivos específicos

1. **Caracterizar la dinámica temporal de la demanda de urgencias respiratorias**, identificando patrones de estacionalidad, efectos calendario y cambios estructurales relevantes para la planificación operativa.
2. **Desarrollar y evaluar modelos de pronóstico de demanda**, incluyendo un baseline estacional simple y modelos de mayor complejidad, bajo un esquema de validación temporal fuera de muestra.
3. **Comparar el desempeño predictivo de los modelos**, evaluando su precisión, estabilidad y capacidad de generalización en distintos períodos de la serie.
4. **Analizar la utilidad operativa de los pronósticos generados**, en términos de su capacidad para anticipar períodos de alta demanda y apoyar decisiones de planificación de capacidad.
5. **Proponer lineamientos para el uso del pronóstico en la gestión operativa**, identificando decisiones concretas que pueden ser informadas según distintos escenarios de demanda.

1.5 Metodología propuesta

1.5.1 Diseño de investigación

La presente investigación adopta un diseño cuantitativo-empírico de carácter predictivo. Se enmarca en un enfoque de modelación supervisada aplicado a series temporales, cuyo

objetivo es evaluar la viabilidad de pronosticar la demanda de urgencias respiratorias con precisión y anticipación operativamente útiles para la planificación de la red asistencial.

La variable dependiente $Y(t)$ corresponde al número de consultas de urgencia respiratoria registradas diariamente en la Región de Los Lagos, consolidando los tres servicios de salud (Osorno, Reloncaví y Chiloé). La serie se analiza en frecuencia diaria para el período enero 2015 - diciembre 2025.

1.5.2 Fuente de datos

Los datos provienen del Departamento de Estadísticas e Información de Salud (DEIS) del Ministerio de Salud de Chile. Se utilizan registros de consultas de urgencia clasificadas bajo el código "Total Causas Sistema Respiratorio", filtrados para la Región de Los Lagos. El período 2015-2025 permite abarcar un ciclo pre-pandémico con estacionalidad relativamente estable, el shock estructural asociado al COVID-19, y la etapa posterior de normalización del sistema sanitario.

1.5.3 Partición temporal

La partición temporal se definió de forma ex ante y se mantuvo fija para todos los modelos evaluados:

Conjunto de entrenamiento: enero 2015 - diciembre 2023 (9 años).

Conjunto de evaluación fuera de muestra: enero 2024 - diciembre 2025 (2 años, 24 meses).

Esta separación respeta el orden cronológico de la información y permite evaluar la capacidad de generalización en un período completamente no observado durante la estimación.

1.5.4 Esquema de validación: walk-forward mensual recursivo

A diferencia de un esquema convencional one-step-ahead, esta investigación adopta un enfoque de pronóstico multi-step con horizonte de 30 días, que replica el escenario operativo de planificación sanitaria.

El procedimiento es el siguiente: para cada uno de los 24 meses del período de evaluación (enero 2024 a diciembre 2025), el modelo se reentrena utilizando todos los datos disponibles hasta el último día del mes anterior. Luego genera predicciones para los 30-31 días del mes en curso. Las predicciones se generan de forma recursiva: el valor pronosticado para el día $t+1$ se utiliza como insumo para estimar el día $t+2$, y así sucesivamente hasta completar el mes.

Este esquema es metodológicamente más exigente que la evaluación one-step-ahead, dado que los errores pueden acumularse a medida que avanza el horizonte de predicción. Sin embargo, refleja con mayor fidelidad el escenario real de uso: una autoridad sanitaria que necesita una proyección a 30 días para tomar decisiones de planificación.

1.5.5 Variables de entrada

A partir del análisis exploratorio detallado en el Capítulo 3, se construyó un conjunto de variables explicativas orientado a capturar los patrones identificados en la serie. La variable dependiente $Y(t)$ corresponde al conteo diario de consultas de urgencia por causas respiratorias en la Región de Los Lagos, consolidando los tres servicios de salud (Osorno, Reloncaví y Chiloé). La serie comprende 4.018 observaciones diarias entre el 1 de enero de 2015 y el 31 de diciembre de 2025. La media diaria es de 802 consultas, con una mediana de 810, un mínimo de 131 y un máximo de 3.164. La desviación estándar es de 351 consultas, lo que refleja la alta variabilidad documentada en el análisis exploratorio. Por subperíodos, la media pre-pandémica (2015-2019) es de 867 consultas diarias, desciende a 416 durante la pandemia (2020-2021), y se recupera a 913 en el período post-pandémico (2022-2025), superando incluso el nivel pre-pandémico. En el

conjunto de entrenamiento (2015-2023) la media es de 793 consultas diarias, mientras que en el período de evaluación (2024-2025) asciende a 840, consistente con la normalización post-pandémica de la demanda.

El detalle de las variables construidas, agrupadas en seis familias (tendencia, estacionalidad, Fourier, calendario móvil, intervenciones de régimen y dinámicas), se desarrolla formalmente en la Sección 3.12 y en la ecuación (3.11).

Variables estáticas (deterministas)

Estas variables son conocidas ex ante para cualquier fecha futura y no dependen de valores pasados de la serie. Incluyen: tendencia lineal; dummies mensuales (12) y de día de semana (7) con sus interacciones; semana del mes; componentes de Fourier para capturar periodicidades de 7, 30 y 365 días; dummy de vacaciones de invierno construida a partir del calendario escolar oficial de la Región de Los Lagos (evento móvil, actualizada año a año); variables de proximidad a vacaciones (pre-vacacional 14 días, post-vacacional 21 días, rampa de retorno); dummies de quiebre estructural COVID-19 segmentadas por tramos diferenciados con rampas de transición; dummies de eventos atípicos (estallido social, pulso 2015, ómicron); y dummies de feriados nacionales.

Variables dinámicas (dependientes de la serie)

Estas variables se construyen a partir de los valores observados (o pronosticados, en la fase recursiva) de la serie transformada en logaritmo. Incluyen: 30 rezagos (lag 1 a lag 30); medias móviles de 7, 15 y 30 días; y media móvil exponencial con span de 15 días. Estas variables capturan la dependencia temporal residual que las variables estáticas no absorben.

1.5.6 Modelos evaluados

Se implementan tres modelos de complejidad creciente, más un baseline simple. Todos se evalúan bajo el mismo esquema de walk-forward mensual descrito en la Sección 1.5.4.

Baseline: promedio por semana epidemiológica

Para cada día del período de evaluación, el pronóstico corresponde al promedio histórico de la serie para esa semana epidemiológica (1-53), calculado sobre los datos de entrenamiento disponibles hasta ese momento. Este baseline representa la estrategia más simple de planificación basada en estacionalidad histórica y constituye el piso contra el cual se mide la ganancia de cada modelo.

Este baseline se incorpora como referencia mínima de desempeño, permitiendo evaluar si los modelos de mayor complejidad entregan una mejora predictiva operativamente relevante respecto a una estrategia estacional simple.

Modelo 1: Regresión lineal estructurada (OLS)

Se estima un modelo de regresión lineal múltiple vía mínimos cuadrados ordinarios, utilizando exclusivamente variables estáticas. La variable dependiente es el logaritmo natural de las consultas, lo que estabiliza la varianza y facilita la interpretación de coeficientes como efectos porcentuales. El modelo incluye interacciones entre día de semana, semana del mes y mes, lo que genera un número sustantivo de coeficientes que capturan patrones estacionales finos.

Este modelo cumple el rol de benchmark interpretable: sus coeficientes tienen significado directo (por ejemplo, el efecto de un lunes de julio versus un viernes de enero) y permiten verificar que las variables construidas capturan efectivamente los patrones documentados en el análisis exploratorio. Al no utilizar lags, su predicción a 30 días no sufre acumulación de error recursivo.

Modelo 2: Gradient Boosting (CatBoost)

Se implementa un modelo de ensamble basado en árboles de decisión potenciados por gradiente, utilizando la implementación CatBoost. A diferencia del modelo lineal, CatBoost recibe tanto variables estáticas como dinámicas (lags, medias móviles, EMA), lo que le permite capturar dependencias temporales no lineales e interacciones complejas entre variables sin necesidad de especificarlas explícitamente.

Los hiperparámetros se fijan en: 6.000 iteraciones, tasa de aprendizaje 0.02, profundidad máxima 6, regularización L2 de 3.0, y submuestreo de 0.7. La predicción recursiva actualiza los lags y medias móviles con los valores pronosticados en cada paso del horizonte de 30 días.

Los hiperparámetros del modelo fueron definidos buscando un equilibrio entre desempeño predictivo, estabilidad y costo computacional. Una extensión posterior del trabajo podría profundizar en el análisis de sensibilidad del modelo frente a cambios en profundidad, regularización y número de árboles.

Modelo 3: Red neuronal recurrente (LSTM)

La LSTM recibe exactamente las mismas 163 variables que CatBoost (calendario, Fourier, intervenciones pandémicas, lags, rolling y EMA), y opera bajo el mismo esquema recursivo de predicción a 30 días. Esta simetría de inputs es una decisión de diseño deliberada: permite que las diferencias de desempeño entre CatBoost y LSTM se atribuyan a la capacidad representacional del algoritmo y no a la información explicativa disponible. Adicionalmente se implementa una variante direct multi-step como control metodológico, que predice los 31 días de golpe para aislar el efecto de la acumulación de error recursivo. El detalle técnico completo se presenta en la Sección 4.5.

1.5.7 Métricas de evaluación

El desempeño predictivo se evalúa exclusivamente sobre el conjunto fuera de muestra (2024-2025), utilizando las siguientes métricas calculadas sobre los 24 meses de walk-forward:

1. **RMSE (Root Mean Squared Error):** penaliza errores grandes, relevante porque los peaks son precisamente lo que se necesita anticipar.
2. **MAE (Mean Absolute Error):** mide el error promedio en unidades de consultas, interpretable directamente.
3. **MAPE (Mean Absolute Percentage Error):** permite comparar el error relativo independientemente del nivel de la serie.
4. **R² fuera de muestra:** mide la proporción de varianza explicada respecto a predecir la media, interpretable como la ganancia del modelo sobre un pronóstico naive.

Consideraciones sobre supuestos de las métricas

Es necesario señalar dos limitaciones conocidas de estas métricas en el contexto de series temporales. Primero, R² asume errores independientes, pero la serie presenta autocorrelación residual documentada; por lo tanto, R² debe interpretarse como una medida descriptiva de ajuste relativo, no como un test estadístico formal. Segundo, MAPE puede ser inestable cuando la demanda es baja (meses de verano con valores cercanos a cero), lo que puede inflar artificialmente el error porcentual en esos períodos. Por esta razón, se reportan las cuatro métricas conjuntamente y se analizan también las métricas desagregadas por mes para identificar períodos de desempeño degradado.

Por esta razón, las métricas se interpretan de manera complementaria y no aislada, considerando tanto su utilidad descriptiva como sus limitaciones en el contexto específico de series temporales de demanda sanitaria.

1.5.8 Análisis de robustez

Se evaluará la estabilidad del desempeño predictivo comparando las métricas entre subperíodos del conjunto de evaluación. Específicamente, se analizará si el desempeño varía

significativamente entre 2024 y 2025, y entre meses de alta demanda (invierno) y baja demanda (verano). Esto permite evaluar si los modelos son confiables precisamente cuando más se necesitan: durante los peaks estacionales.

Adicionalmente, se discutirá la relación entre precisión y complejidad: cuántos árboles/parámetros adicionales necesita CatBoost para superar al modelo lineal, y si esa ganancia marginal justifica la menor interpretabilidad en el contexto operativo del sistema público de salud.

1.5.9 Herramientas computacionales

Los modelos se implementan en Python utilizando: pandas y NumPy para procesamiento de datos; statsmodels para regresión lineal (OLS vía formula); CatBoost para el modelo de ensamble; PyTorch para la red neuronal LSTM; y plotly para visualización interactiva de resultados. La validación walk-forward se paraleliza utilizando joblib para reducir tiempos de cómputo.

1.5.10 Síntesis del diseño experimental

Modelo	Variables de entrada	Predicción	Complejidad	Rol
Baseline	Promedio histórico por semana epidemiológica	Puntual	Mínima	Piso de comparación
OLS	Solo estáticas (dummies, calendario, pandemia)	Determinista (sin lags)	Baja (lineal)	Benchmark interpretable
CatBoost	Estáticas + dinámicas (lags, rolling, EMA, Fourier)	Recursiva 30d	Media (6000 árboles, prof 6)	Modelo no lineal principal
LSTM	Estáticas + dinámicas (mismas 163 variables que CatBoost)	Recursiva 30d (principal) + Directa 31d (variante)	Alta (128u x 2L)	Modelo secuencial profundo

Tabla 1.1 Síntesis del diseño experimental. Todos los modelos se evalúan bajo walk-forward mensual sobre el período OOS enero 2024 - diciembre 2025

La progresión OLS, CatBoost y LSTM sintetizada en la Tabla 1.1 permite comparar no solo el desempeño predictivo de los modelos, sino también el tipo de estructura que cada uno logra representar. En términos generales, OLS captura patrones determinísticos de calendario y estacionalidad, CatBoost incorpora además dependencia temporal mediante variables dinámicas, y LSTM aprende la secuencia directamente desde los datos.

2. CAPÍTULO 2: MARCO TEÓRICO

2.1 Pronóstico de demanda en servicios de urgencia

La demanda en servicios de urgencia hospitalaria constituye un fenómeno altamente variable, cuya dinámica depende de factores epidemiológicos, estacionales y organizacionales. La congestión en unidades de emergencia se asocia a deterioro en la calidad asistencial, aumento en tiempos de espera y uso ineficiente de recursos (Gill, 1999; Sánchez et al., 2003). En particular, las variaciones estacionales en consultas respiratorias representan un factor determinante en la presión asistencial durante períodos invernales (Cárdenas et al., 2014).

En este contexto, la predicción cuantitativa de la demanda se ha posicionado como una herramienta para la planificación sanitaria. Diversos estudios internacionales han aplicado modelos de series temporales para anticipar flujos en servicios de emergencia, evidenciando que el conocimiento de patrones temporales permite optimizar la asignación de recursos (Jones et al., 2008; Sun et al., 2009; Abraham et al., 2009). Más recientemente, Albrecht et al. (2024) evaluaron modelos de aprendizaje automático para pronosticar hospitalizaciones por infecciones respiratorias severas en Auckland, Nueva Zelanda, con un horizonte de 21 días, concluyendo que estos modelos tienen potencial para informar la gestión hospitalaria durante epidemias estacionales.

En Chile, Sauré et al. (2025) demostraron que el análisis cuantitativo de datos DEIS puede informar decisiones concretas de política sanitaria: su estudio retrospectivo sobre estrategias de inmunización contra VRS estimó reducciones de hasta 27.465 días-cama hospitalarios y 46.886 visitas a urgencia, resultado que fue utilizado por el Ministerio de Salud para implementar la estrategia de nirsevimab en 2024. Este antecedente valida el uso de datos DEIS como insumo para herramientas cuantitativas de planificación.

2.2 Modelos clásicos de series temporales

El enfoque tradicional para la modelación de series temporales en el ámbito sanitario ha sido la familia de modelos ARIMA y su extensión estacional SARIMA (Box & Jenkins, 1970). En Chile, Cárdenas et al. (2014) aplicaron un modelo SARIMA para pronosticar consultas respiratorias en el Servicio de Salud Chiloé, alcanzando errores de pronóstico inferiores al 6 % (MAPE) en un contexto pre-pandémico con estacionalidad relativamente estable. En la presente investigación, los modelos ARIMA no se implementan como modelo evaluado, dado que el foco es la utilidad operativa del pronóstico ante variabilidad estructural. No obstante, los resultados de Cárdenas et al. (2014) se utilizan como referencia comparativa a lo largo del documento.

2.3 Modelos lineales estructurados

Una alternativa al enfoque autorregresivo consiste en especificar modelos de regresión lineal que incorporen explícitamente efectos estacionales, calendario y cambios de régimen mediante variables dummy y funciones de tendencia. El modelo general toma la forma:

$$Y(t) = B_0 + \text{suma}(B_j * X_{j,t}) + e(t)$$

donde $X_{j,t}$ representa el conjunto de variables explicativas construidas a partir del conocimiento del dominio: dummies mensuales, dummies de día de semana, efectos de calendario móvil, variables de intervención para cambios estructurales, entre otras.

La ventaja principal de este enfoque radica en su transparencia: cada coeficiente tiene interpretación directa y permite verificar si las variables capturan los patrones esperados. Esto lo convierte en un benchmark metodológico natural antes de evaluar modelos de mayor complejidad. Su limitación es que no puede capturar relaciones no lineales ni interacciones complejas que no hayan sido especificadas explícitamente por el analista.

2.4 Métodos de ensamble: Gradient Boosting

El Gradient Boosting pertenece a la familia de métodos de ensamble, donde múltiples modelos débiles (generalmente árboles de decisión) se combinan secuencialmente para minimizar una función de pérdida (Friedman, 2001; Chen & Guestrin, 2016). Cada árbol se ajusta sobre los residuos del ensamble anterior, corrigiendo progresivamente los errores.

Estos modelos pueden capturar no linealidades e interacciones complejas entre variables de forma automática, sin necesidad de que el analista las especifique previamente. Además, pueden incorporar simultáneamente variables de distinta naturaleza: categóricas, continuas, rezagos temporales y variables de calendario. En el contexto de series temporales, los modelos de Gradient Boosting han mostrado desempeño competitivo cuando se combinan con variables de rezago y medias móviles que capturan la dependencia temporal (Elsayed et al., 2021).

La complejidad del modelo se controla mediante hiperparámetros como el número de árboles, la profundidad máxima y los términos de regularización. La comparación relevante en un contexto aplicado no es solo la precisión final, sino la relación entre precisión y complejidad: cuántos árboles adicionales se necesitan para superar al modelo lineal y a qué costo de interpretabilidad.

2.5 Redes neuronales recurrentes: LSTM

Las redes neuronales recurrentes modelan dependencias temporales mediante estados ocultos que evolucionan en el tiempo. La arquitectura LSTM (Long Short-Term Memory) introduce mecanismos de memoria controlados por compuertas que permiten capturar dependencias de largo plazo, mitigando el problema de desvanecimiento del gradiente que afecta a redes recurrentes simples (Hochreiter & Schmidhuber, 1997).

A diferencia de los modelos de ensamble, las redes LSTM pueden operar directamente sobre la secuencia temporal sin necesidad de construir variables de rezago explícitamente, ya

que la propia arquitectura recurrente codifica la historia de la serie en su estado interno. Esto las posiciona como un enfoque complementario: donde los modelos lineales y de ensamble dependen de variables explicativas pre-construidas, la LSTM intenta aprender la representación óptima directamente desde los datos.

Sin embargo, las redes LSTM tienen mayor costo computacional, requieren más datos para generalizar bien, y su desempeño en pronósticos reales puede ser sensible a cambios en la distribución de los datos. La literatura internacional ha mostrado resultados mixtos: en algunos contextos las redes recurrentes mejoran modelos clásicos, mientras que en otros la ganancia es marginal o inexistente frente a modelos correctamente especificados (Makridakis et al., 2018).

2.6 Síntesis

El marco teórico presentado describe tres enfoques de modelación que serán evaluados en esta investigación: regresión lineal estructurada como benchmark interpretable, Gradient Boosting como modelo no lineal de complejidad intermedia, y LSTM como modelo secuencial profundo. Cada enfoque opera bajo supuestos distintos sobre la estructura del proceso generador de datos, y su desempeño comparativo es una cuestión empírica que depende de las características específicas de la serie bajo estudio.

La evaluación comparativa, desarrollada en los capítulos siguientes, se centrará en determinar si la complejidad adicional de los modelos no lineales se traduce en mejoras predictivas operativamente relevantes, o si un modelo lineal correctamente especificado es suficiente para las necesidades de planificación de la red asistencial.

3. CAPÍTULO 3: ANÁLISIS EXPLORATORIO DE LA SERIE TEMPORAL

El Capítulo 1 planteó como pregunta central si es posible pronosticar la demanda de urgencias respiratorias con precisión y anticipación suficientes para apoyar la planificación de capacidad operativa. Antes de construir y evaluar modelos predictivos, es necesario comprender la estructura temporal de la serie bajo estudio. El presente capítulo desarrolla un análisis exploratorio sistemático de la serie diaria de consultas respiratorias en la Región de Los Lagos (enero 2015 - diciembre 2025), con el objetivo de identificar los patrones que cualquier modelo deberá capturar para lograr precisión operativamente útil: estacionalidades, efectos calendario, cambios estructurales y dependencia temporal residual. Estos hallazgos constituyen el fundamento empírico para la selección de variables y la especificación de los modelos evaluados en el Capítulo 4.




Figura 3.1 Serie diaria de consultas de urgencia respiratoria, Región de Los Lagos (2015–2025). La zona sombreada indica el período pandémico COVID-19

La serie presenta un rango que oscila entre aproximadamente 100 y 3.000 consultas diarias. Se identifican peaks invernales recurrentes entre junio y agosto, con máximos que

superan las 2.500 consultas en los años pre-pandémicos. El período 2020-2021 (zona sombreada) muestra una caída abrupta de la demanda seguida de un peak atípico asociado a COVID-19, tras lo cual la serie retoma gradualmente su patrón estacional a partir de 2022. Los años 2024-2025 muestran amplitudes invernales comparables a las del período 2017-2019, sugiriendo una normalización post-pandémica.



Figura 3.2 Media móvil ± 1 desviación estándar (ventana 30 días). Se observa el incremento de variabilidad durante los peaks invernales

La banda de dispersión (± 1 desviación estándar) se ensancha sistemáticamente durante los peaks invernales, pasando de aproximadamente ± 100 consultas en verano a ± 300 en invierno. Este comportamiento indica heterocedasticidad condicional al nivel de la serie: la variabilidad aumenta proporcionalmente con la demanda, lo que motiva el uso de la transformación logarítmica para estabilizar la varianza antes del modelamiento.

3.1 Análisis exploratorio y visualización de tendencias

La demanda por consultas de urgencia hospitalaria presenta variabilidad significativa y responde a múltiples factores (epidemiológicos, estacionales y organizacionales). En particular,

la saturación de los servicios de urgencia se asocia con deterioro de la operación (p. ej., sobrecarga del personal, presión sobre recursos diagnósticos y demoras), lo que vuelve crítica la capacidad de anticipación cuantitativa de la demanda (Gill, 1999; Sánchez et al., 2003). En el caso chileno, Cárdenas et al. (2014) muestran que la demanda de urgencias totales y respiratorias en la red del Servicio de Salud Chiloé exhibe patrones temporales sistemáticos que pueden ser explotados mediante técnicas de modelación de series de tiempo.

El análisis se realiza sobre la serie diaria correspondiente al período enero 2015 – diciembre 2025, utilizando datos oficiales del DEIS para la Región de Los Lagos, con el objetivo de identificar regularidades (tendencias, estacionalidades, cambios de nivel y anomalías) relevantes para la especificación de variables explicativas y posterior comparación de modelos predictivos. La caracterización inicial se realiza mediante gráficos de la serie (nivel, dispersión y cambios aparentes de régimen), complementada con descomposición visual por subperíodos (pre-pandemia, pandemia, post-pandemia) y por estructuras de calendario (semanas/meses).

Criterio operativo: una exploración rigurosa permite pasar de una serie “aparentemente ruidosa” a un conjunto reducido de componentes interpretables (estacionalidad, calendario, quiebres), condición necesaria para construir predictores y seleccionar modelos compatibles.

3.2 Análisis de heterocedasticidad y estacionalidad

Un primer objetivo del análisis es evaluar si la variabilidad de la serie es aproximadamente constante o cambia en el tiempo (heterocedasticidad), ya que esto afecta tanto la especificación de modelos lineales como la estabilidad de modelos autorregresivos. En series de demanda sanitaria, además, se esperan componentes estacionales (p. ej., ciclos invernales/verano) y patrones dependientes del calendario (p. ej., fines de semana, feriados).

Como referencia metodológica en urgencias, Cárdenas et al. (2014) identifican estacionalidad utilizando herramientas clásicas de series temporales: análisis de autocorrelación

(ACF/PACF) y análisis espectral, encontrando una periodicidad relevante (26 semanas estadísticas) en datos semanales consolidados de urgencias en Chiloé. Este tipo de evidencia sugiere que, cuando el patrón es relativamente estable, puede modelarse con aproximaciones autorregresivas estacionales. Sin embargo, la presencia de quiebres y reordenamientos del calendario sanitario exige verificar si tales periodicidades permanecen estables en el tiempo (ver Figura 3.3).




Figura 3.3 Varianza móvil de la serie (ventana 30 días). La varianza aumenta con el nivel de la serie, lo que motiva la transformación logarítmica

La varianza móvil de 30 días confirma cuantitativamente lo observado en la Figura 3.2: alcanza valores superiores a 150.000 durante los peaks invernales pre-pandémicos y se dispara por encima de ese nivel durante el período COVID-19 (2020-2021). En los períodos estivales, la varianza se mantiene por debajo de 25.000. Esta relación proporcional entre nivel y varianza justifica la transformación logarítmica aplicada a la serie antes de la estimación de los modelos.

3.3 Transformación logarítmica para estabilizar varianza y nivel de la serie

Cuando se observa que la varianza aumenta con el nivel (picos más dispersos en períodos de alta demanda), puede considerarse una transformación (por ejemplo logarítmica o Box-Cox) para estabilizar la variabilidad y facilitar el modelamiento. Esta decisión se toma de forma empírica: se comparan ACF/PACF y desempeño predictivo preliminar antes y después de transformar la serie, priorizando la interpretabilidad y el comportamiento fuera de muestra.

En series de urgencias, parte del valor aplicado de la modelación es obtener pronósticos operativos con bandas razonables. En esa línea, el trabajo de Cárdenas et al. (2014) valida pronósticos con intervalos de confianza en un horizonte de 12 semanas, usando una especificación estacional coherente con la evidencia empírica.




Figura 3.4 Serie diaria log-transformada de consultas de urgencia respiratoria, Región de Los Lagos (2015–2025). La zona sombreada indica el período COVID-19 (marzo 2020 – marzo 2022). La transformación comprime el rango de variación de aproximadamente [131, 3164] a [4.9, 8.1] en escala logarítmica.

La Figura 3.4 muestra el resultado de aplicar la transformación logarítmica a la serie original. El rango de variación se comprime sustantivamente: los peaks invernales, que en escala original superaban las 3.000 consultas diarias, ahora se ubican alrededor de 7.4 en escala logarítmica, mientras que los mínimos del período pandémico (cerca de 50-150 consultas) quedan en torno a 4.0. La estacionalidad invernal se mantiene claramente visible como patrón

repetitivo, pero con una amplitud mucho más regular año a año, lo que facilita la estimación de los efectos sistemáticos.




Figura 3.5 Varianza móvil (ventana 30 días) de la serie de consultas respiratorias antes (panel superior, escala original) y después (panel inferior, escala logarítmica) de la transformación. La zona sombreada indica el período COVID-19. La varianza en escala original presenta una razón máximo/mínimo del orden de $1.241\times$, mientras que la varianza en escala logarítmica reduce esta razón a aproximadamente $93\times$, evidenciando la estabilización buscada. El peak residual de varianza logarítmica en marzo-abril 2020 corresponde al cambio abrupto de régimen asociado al inicio de la pandemia y se trata explícitamente mediante las variables de intervención descritas en la Sección 3.5.

La Figura 3.5 confirma cuantitativamente la estabilización de la varianza. En escala original (panel superior), la varianza móvil de 30 días oscila entre valores cercanos a cero en verano y peaks superiores a 150.000 durante los inviernos pre-pandémicos, una razón máximo/mínimo del orden de $1.241\times$. En escala logarítmica (panel inferior), la misma varianza móvil se mantiene mayoritariamente en un rango acotado cercano a 0.02-0.10, con una razón máximo/mínimo aproximadamente 13 veces menor. La transformación no elimina por completo la heterocedasticidad —persiste un peak notable asociado al inicio de la pandemia (marzo-abril 2020) y algunos peaks menores vinculados a eventos puntuales—, pero la reduce sustantivamente, generando una serie más apropiada para los supuestos de homocedasticidad implícitos en los modelos de regresión. Con esta transformación aplicada, la serie queda en

condiciones adecuadas para la identificación de estacionalidades múltiples desarrollada en la sección siguiente.

3.4 Identificación de estacionalidades múltiples

La demanda por urgencias respiratorias puede contener **más de un ciclo estacional**. En escalas diarias, suelen coexistir patrones intrasemanales (p. ej., diferencias sistemáticas entre días), ciclos anuales (invierno vs verano) y efectos institucionales (vacaciones, campañas, cambios de oferta). Por lo mismo, la identificación debe considerar:

- **Estacionalidad de corto plazo:** patrones semanales (día de semana).
- **Estacionalidad anual:** meses/estaciones.
- **Patrones asociados a calendario sanitario:** semanas específicas (p. ej., vacaciones de invierno) que pueden desplazarse entre años.

Como antecedente empírico, Cárdenas et al. (2014) documentan una estacionalidad semestral de 26 semanas en series semanales de urgencia respiratoria. Esta evidencia es útil como punto de comparación, pero no implica que dicha periodicidad se mantenga invariante en presencia de quiebres estructurales o desplazamientos del calendario (ver Figura 3.6).




Figura 3.6 Media diaria de consultas por mes. Se observa el peak invernal (junio-agosto) y el mínimo estival (enero-febrero)

El perfil mensual muestra un patrón estacional claro con forma de U invertida. El mínimo se registra en febrero (~330 consultas diarias promedio) y el máximo en junio (~940), lo que representa una razón de aproximadamente 2.8 veces entre el peak y el valle. Los meses de septiembre a noviembre presentan un segundo nivel elevado (~800-900), asociado a la persistencia de circulación viral tras el peak invernal. Este patrón fundamenta la inclusión de dummies mensuales como variables explicativas (ver Figura 3.7).




Figura 3.7 Media diaria de consultas por día de la semana. Los fines de semana presentan menor demanda que los días hábiles

Se observa un patrón intra-semanal estable: los días lunes presentan la mayor demanda promedio (~800 consultas), seguidos por martes y miércoles (~750). Los viernes y sábados descienden a ~680, y el mínimo se registra los jueves (~640). Los domingos, en cambio, muestran un repunte (~720), posiblemente porque los pacientes que no consultaron durante el sábado acuden el domingo. La diferencia entre el máximo (lunes) y el mínimo (jueves) es de aproximadamente un 25 %, lo que justifica la inclusión de dummies de día de semana (ver Figura 3.8).





Figura 3.8 Perfil promedio anual de consultas respiratorias (día del año 1–365)

El perfil promedio diario revela la estructura fina de la estacionalidad anual. Se observa un mínimo sostenido entre los días 1-60 (enero-febrero, ~300 consultas), un ascenso progresivo entre marzo y mayo, y un peak amplio entre los días 150-240 (junio-agosto, con máximos cercanos a 1.000). Destaca una depresión transitoria alrededor del día 190-200, que coincide temporalmente con el período de vacaciones de invierno. Este "dip" invernal, cuya posición varía entre años, constituye uno de los hallazgos centrales del análisis exploratorio (ver Figura 3.9).



La distribución de consultas diarias presenta asimetría positiva (sesgo a la derecha), con una moda alrededor de 500 consultas y una cola derecha que se extiende hasta aproximadamente 3.000. La mayor concentración de observaciones se encuentra en el rango 300-800 consultas diarias. Los valores extremos (>2.000) corresponden a peaks pandémicos y peaks invernales severos. Esta distribución asimétrica es consistente con la transformación logarítmica utilizada en el modelamiento, que comprime los valores extremos y aproxima la distribución a una forma más simétrica.

3.5 Eliminación o marcación de observaciones en intervalos potencialmente problemáticos

La serie puede incluir períodos con medición anómala o cambios abruptos en la generación del dato (p. ej., modificaciones de protocolos, subregistro temporal, o shocks exógenos). En lugar de eliminar indiscriminadamente observaciones, se prioriza:

1. **Marcar intervalos** como “potencialmente atípicos” (dummy de intervención/cambio de régimen).
2. **Comparar desempeño** con y sin dichas marcas.

3. **Evitar sesgo** por “limpieza” excesiva que elimine precisamente los eventos críticos que se desea anticipar.

Justificación metodológica sobre la inclusión del período pandémico (2020-2022): Es importante destacar que no se eliminaron las observaciones correspondientes a los años de pandemia, a pesar de la anomalía en la demanda. Excluir este período rompería la continuidad temporal de los datos, lo cual afecta directamente el aprendizaje de modelos que requieren secuencias completas, como la red neuronal LSTM, y limitaría la historia utilizable únicamente al tramo 2023-2025. Para evitar que este período anómalo ensucie la predicción, el control se realizó mediante la incorporación de variables dummy segmentadas por tramos (A–F) con funciones de rampa. Esto permitió aislar el ruido y los cambios de nivel asociados al COVID-19, manteniendo intacta la historia pre-pandémica (2015-2019), la cual es vital para que el modelo aprenda la estacionalidad invernal normal y el comportamiento histórico del calendario escolar. Además, el desempeño predictivo se evalúa exclusivamente en un escenario post-pandemia (validación walk-forward 2024-2025), garantizando que las métricas reportadas estén libres de sesgos pandémicos.

3.6 Especificación de forma funcional, selección de variables estacionales y evaluación de desempeño

Con base en los patrones identificados, se plantea una especificación aditiva base del tipo:

$$Y_t = f(X_t) + \varepsilon_t$$

donde Y_t es la demanda (consultas respiratorias) y X_t agrupa componentes contruidos a partir del análisis del dominio: estacionalidades (mes, semana), calendario (día de semana, feriados), y variables de intervención (quiebres/cambios de nivel).

Como benchmark inicial, se emplea una aproximación lineal con variables dummy (interpretable y controlable), para evaluar:

- capacidad de capturar estacionalidad y calendario,
- estabilidad de coeficientes entre subperíodos,
- estructura del residuo (para decidir si falta capturar autocorrelación sistemática).

3.7 Definición de entrenamiento y validación temporal

En problemas de predicción con series temporales es fundamental respetar la estructura causal de los datos, evitando fuga de información (data leakage) entre entrenamiento y evaluación.

La serie diaria utilizada comprende el período enero 2015 – diciembre 2025. La partición temporal se definió de forma ex ante y se mantuvo fija para todos los modelos evaluados:

- **Conjunto de entrenamiento (80 %):** enero 2015 – diciembre 2023.
- **Conjunto de prueba (20 %):** enero 2024 – diciembre 2025.

Esta separación respeta el orden cronológico de la información y permite evaluar la capacidad de generalización fuera de muestra en un período completamente no observado durante la estimación.

A diferencia de un esquema convencional one-step-ahead, la presente investigación adopta un enfoque de pronóstico multi-step con horizonte de 30 períodos consecutivos.

La generación del pronóstico se realiza mediante estrategia recursiva (iterativa): el valor pronosticado para el período inmediato se utiliza como insumo para estimar el siguiente, y así sucesivamente hasta completar el horizonte de 30 días.

Formalmente, si el último punto observado del entrenamiento es t , el modelo genera:

$$Y_{\{t+1\}}, Y_{\{t+2\}}, \dots, Y_{\{t+30\}}$$

donde los rezagos necesarios pueden corresponder a valores observados (si pertenecen al entrenamiento) o valores previamente pronosticados (si pertenecen al horizonte recursivo).

La evaluación del desempeño se realiza comparando la trayectoria completa pronosticada con los valores observados reales en el conjunto de prueba, utilizando métricas agregadas sobre el horizonte completo (RMSE, MAE, MAPE y R^2 fuera de muestra).

Este esquema multi-horizonte constituye un criterio metodológicamente más exigente que la evaluación one-step-ahead, dado que los errores pueden acumularse a medida que avanza el horizonte de predicción.

3.8 Incorporación de efectos calendario

La literatura en urgencias muestra que la demanda no solo depende de rezagos, sino también de patrones sistemáticos asociados a la organización del servicio y del comportamiento de consulta (Sun et al., 2009; Jones et al., 2008). En consecuencia, se incorporan variables calendario para capturar:

- **Día de semana** (patrón intrasemanal),
- **Mes/estación** (patrón anual),
- **Feriados y períodos especiales**,
- **Vacaciones de invierno** como variable explícita (dummy por rango de fechas o por “semana epidemiológica” correspondiente), permitiendo que el efecto se active aunque se desplace entre años (ver Figura 3.10).




Figura 3.10 Serie temporal con períodos de vacaciones escolares. Las franjas rojas indican vacaciones de invierno y las verdes vacaciones de verano. Se observa que el mínimo invernal se desplaza año a año según el calendario escolar

La superposición de los períodos de vacaciones escolares sobre la serie temporal revela el hallazgo más relevante del análisis exploratorio: el mínimo invernal de demanda respiratoria coincide sistemáticamente con las vacaciones de invierno (franjas rojas), no con una fecha fija del calendario. Este desplazamiento es particularmente visible en los años post-pandemia (2022-2025), donde la posición del mínimo varía en hasta dos semanas entre años consecutivos. Dado que el calendario escolar es anunciado oficialmente antes del inicio del año lectivo, este efecto constituye información exógena conocida ex ante que puede incorporarse como variable explicativa (ver Figura 3.11).




Figura 3.11 Perfil estacional pre-pandemia (2015–2019). Estacionalidad estable con peak invernal consistente

Los perfiles anuales del período pre-pandémico muestran notable consistencia entre años: todos presentan el ascenso estacional a partir de abril, un peak entre junio-agosto que alcanza 1.500-2.500 consultas diarias, y un descenso gradual hacia octubre-noviembre. La superposición de los cinco años evidencia que, en condiciones normales, la estacionalidad es predecible y el patrón se repite con variaciones moderadas de amplitud. Los marcadores de vacaciones de invierno (puntos rojos) confirman que el dip invernal se ubica consistentemente durante el receso escolar (ver Figura 3.12).




Figura 3.12 Perfil estacional durante pandemia (2020–2021). Alteración significativa del patrón estacional

El período pandémico altera completamente el patrón estacional. En 2020, se observa un peak anómalo en marzo-abril (asociado a la primera ola COVID-19) seguido de un colapso de la demanda respiratoria a menos de 200 consultas diarias durante el segundo semestre. En 2021, la demanda permanece deprimida durante todo el año, sin un peak invernal reconocible. Estos perfiles confirman que el período 2020-2021 constituye un régimen estructuralmente distinto que requiere controles específicos (variables dummy por tramos) para evitar que contamine la estimación de la estacionalidad normal (ver Figura 3.13).




Figura 3.13 Perfil estacional post-pandemia (2022–2025). Retorno gradual al patrón pre-pandémico con desplazamiento del mínimo invernal

A partir de 2022, los perfiles anuales muestran un retorno progresivo al patrón pre-pandémico: los peaks invernales reaparecen con amplitudes crecientes (2022: ~1.500, 2023-2025: ~1.500-2.000 consultas diarias). Sin embargo, los peaks post-pandémicos no alcanzan la magnitud de 2019 (~2.500), lo que podría reflejar cambios en la población susceptible o efectos residuales de las intervenciones sanitarias. Destaca que la posición del dip invernal (marcado con puntos rojos) varía visiblemente entre 2022, 2023, 2024 y 2025, confirmando el carácter móvil de este efecto calendario.

3.9 Análisis de autocorrelación residual




Figura 3.14 Ajuste del modelo OLS base en el período de entrenamiento (2015–2023)

Como se aprecia en la Figura 3.14, el ajuste captura el perfil general pero presenta subestimación sistemática en peaks invernales sobre el período de entrenamiento (2015–2023). Se analiza la estructura temporal de los residuos para determinar si el componente determinístico agota la dinámica de la serie o si persisten dependencias temporales sistemáticas. La presencia de autocorrelación significativa en los residuos indicaría que parte de la dinámica no fue capturada por las variables construidas, motivando la incorporación de variables dinámicas (rezagos, medias móviles) en los modelos de mayor complejidad del Capítulo 4 (ver Figura 3.15).




Figura 3.15 Funciones de autocorrelación (ACF) y autocorrelación parcial (PACF) de los residuos en logaritmo del modelo OLS in-sample (2015–2023, $n = 3.287$ observaciones). Las líneas rojas punteadas verticales marcan los rezagos estacionales de 7, 14, 21 y 30 días. La banda sombreada corresponde al intervalo de confianza al 95 % bajo la hipótesis de ruido blanco.

3.9.1 Lectura de los patrones

La ACF muestra un decaimiento lento que se mantiene significativo hasta más allá del rezago 30, con valores elevados en los primeros rezagos: $\rho(1) = 0.74$, $\rho(2) = 0.65$, $\rho(3) = 0.61$. Esta persistencia es una evidencia directa de dependencia temporal residual: dos días consecutivos del período 2015–2023 presentan residuos con correlación superior al 70 %, incluso después de descontar el efecto de las más de 590 variables determinísticas incluidas en el modelo. Además del decaimiento general, se identifican peaks locales en los rezagos de 7, 14 y 21 días ($\rho(7) = 0.61$, $\rho(14) = 0.46$, $\rho(21) = 0.36$), consistentes con ciclos semanales y quincenales no completamente absorbidos por las dummies de día de semana y sus interacciones.

La PACF, en cambio, concentra su estructura significativa en los primeros 5 a 7 rezagos, con un pico principal en el lag 1 ($\phi(1) = 0.74$) y coeficientes menores pero aún significativos en los rezagos 2 a 7 ($\phi(2) = 0.22$, $\phi(7) = 0.16$). Esta forma —ACF de decaimiento lento combinada

con PACF que se apaga rápidamente— corresponde al patrón típico de un proceso autorregresivo de orden bajo a moderado, posiblemente con componente estacional semanal.

Un test formal de Ljung-Box sobre los primeros 30 rezagos rechaza contundentemente la hipótesis nula de ruido blanco (estadístico $Q(30) \approx 17.983$, $p\text{-valor} < 0.001$). Si bien este test tiene potencia alta en muestras grandes y por lo tanto rechaza la hipótesis nula ante desviaciones incluso pequeñas, su magnitud aquí es varios órdenes de magnitud superior al umbral de rechazo, lo que confirma visualmente lo observado en la ACF: la estructura residual es sustantiva, no marginal.

3.9.2 Implicancias metodológicas

Dos consecuencias operativas se derivan de este análisis. Primero, la autocorrelación residual justifica empíricamente la incorporación de variables dinámicas —rezagos (lag 1 a 30), medias móviles (7, 15, 30 días) y media móvil exponencial— en los modelos CatBoost y LSTM del Capítulo 4. La estructura temporal que el modelo OLS no logra absorber con variables determinísticas es precisamente el tipo de dependencia que los modelos no lineales con lags explícitos están en posición de explotar. Segundo, la presencia de autocorrelación residual en el OLS implica que las métricas de desempeño tradicionales (R^2 , RMSE, MAE, MAPE) no pueden interpretarse como tests estadísticos formales sino como medidas descriptivas de ajuste relativo, como ya se discutió en la Sección 1.5.7. Esta limitación aplica también a los modelos posteriores: aun cuando CatBoost y LSTM incorporen variables dinámicas que capturen parte de esta estructura, la evaluación de desempeño se fundamenta en comparaciones relativas entre modelos y entre subperíodos, no en la validez de los intervalos de confianza que un supuesto de residuos independientes supondría.

3.10 Síntesis estructural de patrones identificados

El análisis exploratorio desarrollado en las secciones precedentes permitió identificar que la dinámica de las consultas de urgencia respiratoria en la Región de Los Lagos no responde a un único mecanismo temporal, sino a la superposición de múltiples componentes estructurales.

A diferencia de procesos puramente autorregresivos estacionarios, la serie presenta la coexistencia de patrones determinísticos, eventos calendario móviles, quiebres estructurales y dependencia temporal residual, lo que implica que su proceso generador puede representarse de manera más adecuada como:

$$Y_t = g(S_t, C_t, R_t, L_t) + \varepsilon_t$$

donde:

- S_t representa componentes estacionales fijos,
- C_t representa efectos calendario móviles,
- R_t corresponde a cambios de régimen o quiebres estructurales,
- L_t captura dependencia temporal residual,
- ε_t es un término de error no explicado.

La Tabla 3.1 sintetiza los patrones detectados, su evidencia empírica y sus implicancias metodológicas.

Patrón identificado	Evidencia empírica	Naturaleza	Estabilidad temporal	Implicancia metodológica
Estacionalidad anual	Caída sistemática en verano	Determinística	Relativamente estable	Dummy mensual / componente estacional
Estacionalidad semanal	Diferencias día hábil vs fin de semana	Determinística	Estable	Dummy día de semana
Vacaciones de invierno	Mínimo invernal desplazable	Calendario móvil	Variable post-pandemia	Dummy por fecha oficial
Pandemia COVID-19	Cambio abrupto de nivel	Quiebre estructural	No estacionario	Dummies segmentadas por tramo (A–F) y funciones de rampa cuando corresponda
Autocorrelación residual	ACF significativa tras modelo lineal	Estocástica	Persistente	Modelo dinámico adicional

Tabla 3.1 Patrones estructurales identificados en la serie de consultas respiratorias.

La modelación del período COVID-19 no se realizó mediante una única variable binaria, sino mediante segmentación por tramos diferenciados (A–F), permitiendo capturar: (ver Figura 3.16).

- Cambios abruptos de nivel,
- Fases de caída progresiva (rampas),
- Períodos de estabilización,
- Reaperturas graduales.




Figura 3.16 Segmentación del período pandémico por tramos (A–F). Cada tramo se modela con variables dummy independientes para capturar los distintos subregímenes

Esta segmentación evita imponer homogeneidad estructural en un período caracterizado por múltiples subregímenes.

Discusión estructural de los patrones

1. Estacionalidad anual y semanal

Tal como se ha documentado en la literatura de urgencias hospitalarias, la demanda presenta variaciones sistemáticas asociadas a ciclos anuales y semanales (Sun et al., 2009; Jones et al., 2008). En el caso chileno, Cárdenas et al. (2014) identifican estacionalidad significativa mediante análisis espectral y ACF/PACF, encontrando una periodicidad relevante en datos semanales de urgencias respiratorias.

Sin embargo, la presente serie —en frecuencia diaria— revela que esta estacionalidad se manifiesta en múltiples niveles: intrasemanal y anual. Estos componentes pueden modelarse explícitamente mediante variables dummy, sin necesidad de depender exclusivamente de autocorrelación histórica.

2. Vacaciones de invierno como evento calendario móvil

Uno de los hallazgos más relevantes es que el mínimo invernal asociado a vacaciones de invierno no ocurre en una fecha fija año a año. Mientras que en contextos previos este efecto podía aproximarse mediante una periodicidad semestral, el desplazamiento sistemático posterior a la pandemia invalida el supuesto de estacionalidad fija.

Desde una perspectiva metodológica, este desplazamiento no representa incertidumbre aleatoria, sino información exógena conocida ex ante, ya que el calendario escolar es anunciado oficialmente antes del inicio del año lectivo. Esto transforma un patrón que podría interpretarse como estacionalidad estocástica en un efecto determinístico calendarizado.

Este hallazgo es central, ya que sugiere que parte de la dinámica observada no debe modelarse como autocorrelación histórica, sino como variable explicativa explícita.

3. Quiebre estructural asociado a la pandemia

La literatura ha advertido que los modelos autorregresivos presentan sensibilidad ante cambios estructurales abruptos. La pandemia de COVID-19 introdujo alteraciones en la serie cuya magnitud y persistencia requieren verificación empírica. Visualmente se observa un cambio de nivel durante el período de restricciones (2020-2021), aunque la dinámica post-pandémica parece retomar gradualmente los patrones previos. La confirmación formal de un quiebre estructural requeriría un test específico (por ejemplo, test de Chow), lo que constituye una línea de trabajo futuro.

4. Dependencia temporal residual

Incluso tras incorporar componentes determinísticos (estacionalidad y calendario), el análisis de autocorrelación residual sugiere persistencia temporal adicional. Este fenómeno

indica que la serie combina componentes estructurales explícitos y dinámicas estocásticas no completamente capturadas por especificaciones lineales simples.

La coexistencia de estos elementos es consistente con la evidencia internacional que muestra que la demanda en urgencias puede beneficiarse de modelos multivariados o no lineales cuando el proceso subyacente presenta interacciones complejas (Jones et al., 2009; Abraham et al., 2009).

Conclusión estructural del capítulo

El análisis desarrollado demuestra que la serie de consultas respiratorias en la Región de Los Lagos no puede describirse adecuadamente mediante un único mecanismo autorregresivo estacionario. Por el contrario, se trata de un proceso híbrido donde interactúan:

- Componentes determinísticos estacionales,
- Eventos calendario móviles,
- Cambios estructurales de régimen,
- Dependencia temporal residual.

En consecuencia, la selección metodológica no puede basarse exclusivamente en tradición disciplinaria, sino en la capacidad efectiva del modelo para capturar simultáneamente estos elementos estructurales.

Por ello, cualquier modelo de pronóstico que aspire a ser operativamente útil para la planificación de la red asistencial deberá capturar simultáneamente estos componentes. La evaluación de si los modelos seleccionados lo logran con precisión suficiente es el objeto del Capítulo 4.

3.11 Implicancias para la selección metodológica

El análisis estructural desarrollado en las secciones anteriores permite derivar un conjunto explícito de criterios que debe cumplir un modelo predictivo adecuado para la serie de consultas respiratorias en la Región de Los Lagos.

En primer lugar, la presencia simultánea de estacionalidades múltiples —anual e intra-semanal— implica que el modelo debe ser capaz de representar componentes periódicos superpuestos. Tal como se ha documentado en aplicaciones previas en servicios de urgencia, la estacionalidad constituye un determinante central en la dinámica de la demanda (Sun et al., 2009; Cárdenas et al., 2014).

En segundo lugar, la identificación de eventos calendario móviles, particularmente el desplazamiento de las vacaciones de invierno, introduce un elemento determinístico exógeno cuya fecha es conocida con anticipación. Este componente no puede representarse adecuadamente mediante un rezago estacional fijo cuando la fecha varía entre años. En consecuencia, cuando la estacionalidad es inducida por eventos desplazables, su representación requiere variables explícitas de calendario, no rezagos estacionales fijos.

En tercer lugar, la evidencia de quiebre estructural asociado a la pandemia sugiere que la constancia paramétrica en el tiempo puede no sostenerse. La literatura ha advertido que los modelos autorregresivos presentan limitaciones ante cambios estructurales abruptos (Coutin, 2007). En consecuencia, el modelo seleccionado debe mostrar robustez frente a cambios de nivel o permitir la incorporación explícita de variables de intervención.

En cuarto lugar, la persistencia de autocorrelación residual tras la incorporación de componentes determinísticos indica que parte de la dinámica sigue siendo dependiente de valores pasados de la serie. Esto sugiere la necesidad de incorporar estructuras dinámicas adicionales o utilizar modelos capaces de capturar dependencias temporales no lineales, tal

como se ha explorado en enfoques multivariados y no lineales en contextos de urgencias hospitalarias (Jones et al., 2009; Abraham et al., 2009).

A partir de estos hallazgos, se derivan cuatro criterios formales de evaluación para los modelos considerados:

1. Capacidad para modelar estacionalidades múltiples.
2. Capacidad para incorporar eventos calendario móviles.
3. Robustez ante cambios estructurales.
4. Capacidad para capturar dependencia temporal residual.

Estos criterios no surgen de una preferencia metodológica a priori, sino del análisis empírico de la serie bajo estudio. En consecuencia, la comparación de modelos en el capítulo siguiente se estructurará en torno al grado en que cada enfoque satisface simultáneamente estos requisitos, privilegiando evidencia cuantitativa fuera de muestra sobre complejidad algorítmica.

De este modo, la estrategia adoptada consiste en una aproximación incremental: comenzar con un modelo lineal estructurado como benchmark interpretable, y posteriormente evaluar enfoques de mayor flexibilidad funcional, contrastando su desempeño predictivo bajo un esquema homogéneo de validación temporal.

3.12 Definición formal de variables

Los hallazgos documentados en las secciones anteriores justifican la construcción de un conjunto estructurado de variables explicativas. Esta sección formaliza cada variable con su definición operacional, la ventana temporal sobre la cual se activa y la forma funcional con que entra al modelo. Las variables se agrupan en seis familias: (i) variable dependiente y tendencia, (ii) estacionalidad determinística, (iii) componentes de Fourier, (iv) calendario escolar móvil, (v) intervenciones de cambio de régimen y eventos puntuales, y (vi) variables dinámicas

dependientes de la serie. Las primeras cinco familias son conocidas ex ante para cualquier fecha futura; la sexta depende de valores pasados de la serie y debe actualizarse recursivamente durante el pronóstico.

3.12.1 Variable dependiente y tendencia

La variable dependiente es el logaritmo natural del número de consultas diarias de urgencia respiratoria en la Región de Los Lagos:

$$Y_t = \log(N_t) \quad (3.1)$$

donde N_t corresponde al conteo diario de consultas DEIS para la glosa «Total Causas Sistema Respiratorio» consolidado sobre los tres servicios de salud de la región (Osorno, Reloncaví y Chiloé). La transformación logarítmica estabiliza la varianza proporcional al nivel documentada en la Sección 3.2 y permite interpretar los coeficientes como efectos porcentuales aproximados.

Tendencia lineal. Se define la variable t_t como el índice temporal continuo:

$$t_t = (\text{fecha}(t) - \text{fecha}(2015-01-01)) / 1 \text{ día} \quad (3.2)$$

con $t = 0$ en la primera observación de la muestra (1 de enero de 2015). Esta variable captura tendencia secular y sirve como insumo para las variables de Fourier y las rampas de intervención.

3.12.2 Estacionalidad determinística

La estacionalidad identificada en el análisis exploratorio opera en tres escalas: anual (mes), intra-mes (semana del mes) e intra-semanal (día de la semana). Para capturar estos patrones y sus interacciones se utilizan tres variables categóricas y sus productos cruzados.

Día de la semana

$D_t \in \{1, 2, \dots, 7\}$ donde 1 = lunes y 7 = domingo. Se codifica como variable categórica con seis dummies (una categoría de referencia).

Semana del mes

$S_t \in \{1, 2, \dots, 6\}$, calculada como $\lceil (\text{día del mes} + \text{día-de-la-semana del primero del mes}) / 7 \rceil$. Esto asigna a cada fecha la semana calendario dentro del mes. Se codifica con cinco dummies.

Mes

$M_t \in \{1, 2, \dots, 12\}$. Se codifica con once dummies.

Adicionalmente, se incluyen todos los términos de interacción posibles entre las tres variables categóricas: interacciones dobles ($D_t \times S_t$, $D_t \times M_t$, $S_t \times M_t$) y la interacción triple ($D_t \times S_t \times M_t$). Estas interacciones permiten que el efecto de un día particular varíe por semana y por mes, capturando estructuras finas como «lunes de la primera semana de julio» que difieren sistemáticamente de «lunes de la cuarta semana de febrero».

3.12.3 Componentes de Fourier (solo modelos no lineales)

Para complementar la codificación categórica de la estacionalidad, se construyen pares seno-coseno que aproximan las periodicidades dominantes identificadas en el análisis espectral implícito. Para cada periodicidad $P \in \{7, 30.4375, 365.25\}$ días y cada armónico $k \in \{1, 2, 3\}$ se define:

$$FP_{ks}^{\sin}(t) = \sin(2\pi kt/P), \quad FP_{ks}^{\cos}(t) = \cos(2\pi kt/P) \quad (3.3)$$

Esto produce 3 periodicidades $\times$ 3 armónicos $\times$ 2 funciones = 18 variables de Fourier. Las periodicidades corresponden aproximadamente al ciclo semanal (7 días), mensual ($365.25/12 \approx 30.44$ días) y anual (365.25 días). Estas variables se utilizan en los modelos CatBoost y LSTM;

el modelo OLS base no las incluye, dado que su estacionalidad ya está capturada mediante las variables categóricas y sus interacciones descritas en la sección anterior.

3.12.4 Calendario escolar móvil: vacaciones de invierno

Las vacaciones de invierno constituyen el evento calendario móvil más relevante identificado en el análisis exploratorio. La Sección 3.8 documentó que el mínimo invernal de demanda coincide sistemáticamente con el receso escolar, y que éste se desplaza año a año. La Tabla 3.2 presenta las fechas oficiales utilizadas, publicadas por el Ministerio de Educación para la Región de Los Lagos.

Año	Inicio vacaciones	Fin vacaciones	Duración (días)
2015	13-jul-2015	27-jul-2015	14
2016	11-jul-2016	25-jul-2016	14
2017	17-jul-2017	01-ago-2017	15
2018	17-jul-2018	30-jul-2018	13
2019	15-jul-2019	29-jul-2019	14
2020	— (pandemia, efecto neutralizado)	—	—
2021	— (pandemia, efecto neutralizado)	—	—
2022	30-jun-2022	25-jul-2022	25
2023	03-jul-2023	17-jul-2023	14
2024	24-jun-2024	08-jul-2024	14
2025	23-jun-2025	07-jul-2025	14

Tabla 3.2 Calendario oficial de vacaciones de invierno, Región de Los Lagos (MINEDUC). Los años 2020 y 2021 se neutralizan dado que los controles pandémicos alteraron la asistencia escolar y desacoplaron la dinámica vacaciones-demanda observada en condiciones normales

Dado que la duración de las vacaciones varía entre años (13 a 25 días), no es posible codificar el efecto con una única dummy de duración fija. En su lugar, se construye un conjunto de 61 dummies event-relative que se activan según la posición relativa a las fechas oficiales:

Ventana pre-vacacional (14 días)

Para cada año y y con receso oficial que inicia en la fecha I_y , y para cada $n \in \{1, 2, \dots, 14\}$:

$$V_pre_n(t) = 1 \text{ si } t = I_y - n \text{ días, } 0 \text{ en otro caso} \quad (3.4)$$

Esto genera 14 variables pre-vacacionales (pre-inicio-1, pre-inicio-2, ..., pre-inicio-14) que capturan la dinámica de la serie en los días previos al receso, un período donde el análisis exploratorio detecta un cambio de régimen en el comportamiento de consulta.

Durante el receso (variable por día del receso)

Para cada $d \in \{0, 1, \dots, 24\}$ (donde 24 corresponde a la duración máxima observada, año 2022):

$$V_vac_d(t) = 1 \text{ si } t = I_y + d \text{ días y } d < \text{duración}_y, 0 \text{ en otro caso} \quad (3.5)$$

Esto genera 25 variables intra-vacacionales. La codificación por día (en lugar de una única dummy de rango) permite que el modelo aprenda una estructura intra-período no uniforme: los primeros días del receso no tienen el mismo efecto que los últimos.

Fin del receso y ventana post-vacacional (21 días)

$$V_fin(t) = 1 \text{ si } t = F_y \text{ (fecha oficial de retorno), } 0 \text{ en otro caso} \quad (3.6)$$

Y para cada $n \in \{1, 2, \dots, 21\}$:

$$V_post_n(t) = 1 \text{ si } t = F_y + n \text{ días, } 0 \text{ en otro caso} \quad (3.7)$$

Esto agrega $1 + 21 = 22$ variables. En total, el bloque de vacaciones aporta $14 + 25 + 1 + 21 = 61$ variables event-relative. Para los años 2020 y 2021 todas estas variables se fijan en cero, siguiendo el criterio documentado en la Sección 3.5 sobre neutralización del efecto vacacional durante la pandemia.

3.12.5 Intervenciones de cambio de régimen y eventos puntuales

El análisis de la Sección 3.10 identificó que el período pandémico no puede representarse con una única dummy binaria dado que contiene múltiples subregímenes con distinto nivel y dinámica. La Tabla 3.3 presenta la segmentación implementada, que combina dummies de nivel (capturan saltos discretos) con rampas lineales (capturan cambios graduales dentro de cada tramo).

Variable	Inicio	Fin	Tipo / propósito
trend_dec_sat	17-mar-2020	13-abr-2020	Rampa saturada: caída inicial post-cuarentena
dum_level_1	14-abr-2020	21-jul-2021	Nivel tramo 1 (confinamiento extendido)
t_rel_dum1	14-abr-2020	21-jul-2021	Drift lineal dentro del tramo 1
dum_dum1_seg2	15-jul-2020	13-feb-2021	Nivel sub-tramo 1b
t_rel_dum1_seg2	15-jul-2020	13-feb-2021	Drift sub-tramo 1b
dum_dum1_seg3	14-feb-2021	21-jul-2021	Nivel sub-tramo 1c
t_rel_dum1_seg3	14-feb-2021	21-jul-2021	Drift sub-tramo 1c
dum_pulse1_dum1	15-may-2020	05-jul-2020	Pulso dentro tramo 1
dum_pulse2_dum1	20-dic-2020	05-feb-2021	Pulso dentro tramo 1
trend_inc_1	22-jul-2021	15-sep-2021	Rampa ascendente post-tramo 1
trend_inc_2	15-sep-2021	13-nov-2021	Rampa ascendente continuación

Variable	Inicio	Fin	Tipo / propósito
dum_level_2	14-nov-2021	31-mar-2022	Nivel tramo 2 (ola ómicron)
t_rel_dum2	14-nov-2021	31-mar-2022	Drift dentro del tramo 2
dum_pulso_omicron	20-dic-2021	10-feb-2022	Pulso ola ómicron
dum_post_2022	01-abr-2022	fin muestra	Nivel post-pandemia
trend_post_sat	01-abr-2022	15-jun-2022	Rampa de recuperación post-pandemia
dum_estallido_2019	30-oct-2019	09-dic-2019	Estallido social (evento exógeno)
dum_pulso_2015	30-oct-2015	30-oct-2015	Peak puntual atípico
dum_24dic	24-dic (cada año)		Efecto Nochebuena (excluye 2020, 2021)
dum_31dic	31-dic (cada año)		Efecto año nuevo (excluye 2020, 2021)

Tabla 3.3 Variables de intervención y eventos puntuales. Las rampas lineales se construyen mediante la función $\text{drift}(t; a, b) = \max(0, \min(t - a, b - a))$ que incrementa linealmente entre la fecha de inicio a y la fecha de fin b , y se mantiene constante fuera del rango. Las dummies de nivel son indicadoras binarias del intervalo $[a, b]$.

3.12.6 Feriados nacionales

Se incluyen siete dummies de feriados nacionales cuyo efecto sobre la demanda de urgencias resultó significativo en pruebas preliminares: año nuevo, día del trabajo, viernes santo, independencia (18 de septiembre), glorias del ejército (19 de septiembre), puentes de fiestas patrias (días adyacentes) y día de los pueblos indígenas (21 de junio, feriado instaurado en 2022). Cada dummy se activa exclusivamente en las fechas correspondientes a cada año, excluyendo 2020 y 2021.

3.12.7 Variables dinámicas dependientes de la serie

Este bloque de variables se construye a partir de valores pasados de la serie transformada en logaritmo. A diferencia de los bloques anteriores, requiere actualización recursiva durante la generación del pronóstico: en la fase fuera de muestra, los valores de Y_{t-k} no corresponden a observaciones reales sino a predicciones previas del propio modelo. Este

bloque solo es utilizado por los modelos CatBoost y LSTM; el modelo OLS base opera exclusivamente con variables deterministas.

Rezagos

Para cada $k \in \{1, 2, \dots, 30\}$:

$$L_k(t) = Y_{t-k} \quad (3.8)$$

Esto genera 30 variables de rezago, cubriendo dependencia temporal de hasta un mes.

Medias móviles

Para cada ventana $w \in \{7, 15, 30\}$ días:

$$Rw(t) = (1/w) \cdot \sum_{i=1}^w Y_{t-i} \quad (3.9)$$

Media móvil exponencial

Con factor de suavizamiento $\alpha = 2/(\text{span} + 1)$, $\text{span} = 15$:

$$E_t = \alpha \cdot Y_{t-1} + (1 - \alpha) \cdot E_{t-1} \quad (3.10)$$

Ambos tipos de medias móviles se calculan con desfase: $Rw(t)$ utiliza $Y_{t-1}, \dots, Y_{t-w}$ (no incluye Y_t), lo que evita fuga de información del presente al pronóstico.

3.12.8 Resumen de dimensionalidad

La Tabla 3.4 sintetiza el número de variables construidas en cada bloque y el modelo que las utiliza. La dimensionalidad total del modelo OLS es elevada debido a las interacciones categóricas, aunque una parte sustancial de los coeficientes queda cercana a cero por la escasez de observaciones en combinaciones específicas.

Bloque	N° variables	OLS	CatBoost	LSTM
Tendencia lineal	1	✓	✓	✓
Dummies de calendario (D, S, M)	22	✓	✓	✓
Interacciones 2-vías (D×S, D×M, S×M)	151	✓	—	—
Interacción 3-vías (D×S×M)	330	✓	—	—
Fourier (3 períodos × 3 armónicos × 2)	18	—	✓	✓
Vacaciones event-relative	61	✓	✓	✓
Intervenciones de régimen y pulsos	20	✓	✓	✓
Feridos nacionales	7	✓	✓	✓
Rezagos (Lag 1 a 30)	30	—	✓	✓
Medias móviles (7, 15, 30) + EMA	4	—	✓	✓
Total utilizado (aprox.)	644	592	163	163

Tabla 3.4 Resumen de dimensionalidad por bloque de variables y modelo. El modelo OLS utiliza 592 términos (interacciones categóricas + deterministas); CatBoost y LSTM comparten el mismo espacio de 163 variables (calendario principal, Fourier, vacaciones, intervenciones, feriados, lags y medias móviles), lo que garantiza comparabilidad directa entre ambos en condiciones equivalentes.

La decisión de utilizar el mismo conjunto de 163 variables para CatBoost y para la LSTM multivariada no es arbitraria, sino una condición metodológica deliberada que responde a tres objetivos. Primero, permite aislar el efecto del algoritmo: si ambos modelos reciben exactamente la misma información explicativa y difieren únicamente en su estructura interna (ensamble de árboles versus red recurrente profunda), cualquier diferencia observada en el desempeño predictivo puede atribuirse a la capacidad representacional del algoritmo y no a asimetrías en los insumos disponibles. Segundo, garantiza comparabilidad empírica: las métricas reportadas en el Capítulo 5 (R^2 , RMSE, MAE, MAPE) miden la calidad del modelo bajo condiciones equivalentes, evitando el sesgo que introduciría una comparación contra una LSTM con acceso restringido a la serie cruda. Tercero, hereda del modelo OLS base el conjunto de variables fundamentadas

empíricamente en el análisis exploratorio del Capítulo 3: los componentes de calendario, las intervenciones pandémicas y las variables dinámicas fueron construidos específicamente para capturar los patrones identificados en la serie, y su validación como benchmark interpretable (OLS) hace razonable extender ese conjunto a los modelos no lineales. Esta decisión convierte la comparación CatBoost vs. LSTM en una prueba limpia sobre qué arquitectura algorítmica captura mejor los patrones, dado el mismo espacio de información.

3.13 Especificación algebraica del modelo OLS base

Con las variables formalmente definidas en la Sección 3.12, la especificación funcional del modelo OLS base queda establecida como:

$$Y_t = \beta_0 + \beta_1 t_t + \alpha \cdot T_t + \delta \cdot J_t + \gamma \cdot K_t + \theta \cdot V_t + \lambda \cdot F_t + \varepsilon_t \quad (3.11)$$

donde cada término agrupa un bloque temático de variables. A continuación se desarrolla cada bloque explícitamente.

Bloque de tendencia (T_t)

T_t contiene la variable tendencia lineal t_t (ya incluida como término separado con coeficiente β_1) y no aporta términos adicionales en el OLS base. Se mantiene la notación por consistencia con los modelos no lineales, que agregan términos de Fourier a este bloque.

Bloque de estacionalidad determinística (J_t)

$$\alpha \cdot J_t = \sum_j \alpha_j^D \cdot 1\{D_t=j\} + \sum_j \alpha_j^S \cdot 1\{S_t=j\} + \sum_j \alpha_j^M \cdot 1\{M_t=j\} \quad (3.12a)$$

más todas las interacciones de segundo y tercer orden:

$$+ \sum_{j,k} \alpha_{jk}^{DS} \cdot 1\{D_t=j, S_t=k\} + \sum_{j,k} \alpha_{jk}^{DM} \cdot 1\{D_t=j, M_t=k\} \quad (3.12b)$$

$$+ \sum_{j,k} \alpha_{jk}^{SM} \cdot 1\{S_t=j, M_t=k\} + \sum_{j,k,l} \alpha_{jkl}^{DSM} \cdot 1\{D_t=j, S_t=k, M_t=l\} \quad (3.12c)$$

donde $1\{\cdot\}$ es la función indicadora. Este bloque concentra la gran mayoría de los coeficientes del modelo (aproximadamente 503) y permite al OLS reproducir la estructura estacional identificada en la Sección 3.4.

Bloque de intervenciones de régimen (K_t)

$$\delta \cdot K_t = \delta_1 \cdot \text{trend_dec_sat}(t) + \delta_2 \cdot \text{dum_level_1}(t) + \delta_3 \cdot \text{t_rel_dum1}(t) + \dots + \delta_{20} \cdot \text{dum_31dic}(t)$$

donde cada término corresponde a las 20 variables de la Tabla 3.3 (rampas, dummies de nivel y eventos puntuales). Explícitamente, el bloque incluye: trend_dec_sat, dum_level_1, t_rel_dum1, dum_dum1_seg2, t_rel_dum1_seg2, dum_dum1_seg3, t_rel_dum1_seg3, dum_pulse1_dum1, dum_pulse2_dum1, trend_inc_1, trend_inc_2, dum_level_2, t_rel_dum2, dum_post_2022, trend_post_sat, dum_estallido_2019, dum_pulso_2015, dum_pulso_omicron, dum_24dic y dum_31dic.

Bloque de vacaciones de invierno (V_t)

$$\theta \cdot V_t = \sum_{n=1}^{14} \theta_n^{pre} \cdot V_{pre_n}(t) + \sum_{d=0}^{24} \theta_d^{vac} \cdot V_{vac_d}(t) + \theta^h \cdot V_{fin}(t) + \sum_{n=1}^{21} \theta_n^{post} \cdot V_{post_n}(t) \quad (3.13)$$

Este bloque aporta 61 coeficientes event-relative, permitiendo que el modelo aprenda una forma funcional flexible alrededor del receso escolar: caída en los días previos, perfil intra-receso no uniforme, y rampa de retorno en las semanas posteriores.

Bloque de feriados nacionales (F_t)

$$\lambda \cdot F_t = \lambda_1 \cdot F_{año_nuevo}(t) + \lambda_2 \cdot F_{día_trabajo}(t) + \lambda_3 \cdot F_{viernes_santo}(t) + \lambda_4 \cdot F_{independencia}(t) + \lambda_5 \cdot F_{glorias_ej}(t) + \lambda_6 \cdot F_{puentes}(t) + \lambda_7 \cdot F_{pueblos_indígenas}(t)$$

cada una con su dummy binaria activándose en las fechas exactas listadas en el calendario del MINEDUC y el calendario oficial de feriados nacionales, con las exclusiones de 2020 y 2021 ya descritas.

Error

ε_t representa el término de error. La Sección 3.9 documenta que los residuos $\hat{\varepsilon}_t$ del modelo OLS presentan autocorrelación significativa en los primeros lags y en lags estacionales (7, 14, 30), lo que justifica la inclusión de variables dinámicas en los modelos posteriores (CatBoost, LSTM). Esta autocorrelación implica que las métricas de desempeño deben interpretarse descriptivamente y no como tests estadísticos formales, según lo discutido en la Sección 1.5.7.

3.13.1 Estimación y reentrenamiento

El modelo (3.11) se estima por mínimos cuadrados ordinarios utilizando la librería statsmodels (función ols con interfaz de fórmulas patsy). Bajo el esquema de walk-forward mensual descrito en la Sección 1.5.4, la estimación se repite 24 veces (una por cada mes del período fuera de muestra enero 2024 – diciembre 2025). En cada iteración, el modelo se reestima con todos los datos disponibles hasta el último día del mes anterior, y luego se generan predicciones para los 30-31 días del mes en curso. Como el OLS no utiliza variables dinámicas (lags ni medias móviles), su predicción multi-step es directa: cada día del horizonte se pronostica exclusivamente a partir de su fecha y no depende de predicciones previas, evitando acumulación de error recursivo.

3.13.2 Especificación para los modelos con variables dinámicas

Los modelos CatBoost y LSTM extienden la especificación (3.11) sustituyendo las interacciones categóricas de alto orden por componentes de Fourier (más compactos) e incorporando el bloque de variables dinámicas. La especificación general queda:

$$Y_t = g(t_t, D_t, S_t, M_t, \text{Fourier}(t), K_t, V_t, F_t, L_t, R_t, E_t) + \varepsilon_t \quad (3.14)$$

donde $g(\cdot)$ es una función no lineal (ensamble de árboles en CatBoost, red recurrente en LSTM) que aprende interacciones automáticamente. El conjunto de entrada es idéntico para ambos modelos (163 variables), lo que asegura que las diferencias de desempeño entre CatBoost y LSTM no se deban a la información disponible sino a la capacidad representacional del algoritmo. Esta decisión de diseño es central para la interpretación de los resultados del Capítulo 5.

Para el caso específico de CatBoost, $g(\cdot)$ corresponde a un ensamble de 6.000 árboles de decisión con profundidad máxima 6, regularización L2 de 3.0, submuestreo 0.7 y tasa de aprendizaje 0.02. Para LSTM, $g(\cdot)$ corresponde a una red recurrente con 128 unidades ocultas en 2 capas (variante multivariada recursiva) o 3 capas (variante direct multi-step), entrenada con Adam y early stopping. Los detalles de cada arquitectura se describen en las Secciones 4.4 y 4.5.

4. CAPÍTULO 4: SELECCIÓN METODOLÓGICA Y MODELAMIENTO PREDICTIVO

4.1 Enfoque de solución: arquitectura del sistema de pronóstico

El presente capítulo describe la implementación de los modelos predictivos evaluados en esta investigación: regresión lineal estructurada (OLS) como benchmark interpretable, Gradient Boosting (CatBoost) como modelo no lineal principal, y red neuronal recurrente (LSTM) como enfoque alternativo. Los tres se evalúan bajo un esquema común de walk-forward mensual con predicciones fuera de muestra sobre el período enero 2024 – diciembre 2025. La Figura 4.1 resume visualmente el proceso completo, desde la obtención de los datos hasta la derivación de implicancias operativas. A continuación de la figura, cada uno de los ocho pasos se explica en detalle.




Figura 4.1 Esquema general del proceso metodológico y secuencia de modelamiento incremental

4.2 Explicación detallada de cada etapa

PASO 1 · Datos DEIS — serie diaria de consultas respiratorias

La fuente primaria corresponde a los registros oficiales del Departamento de Estadísticas e Información de Salud (DEIS) del Ministerio de Salud de Chile. Se utilizan los conteos diarios de consultas de urgencia clasificadas bajo la glosa «Total Causas Sistema Respiratorio», filtrados para los establecimientos de la Región de Los Lagos y consolidados sobre los tres servicios de salud regionales: Osorno, Reloncaví y Chiloé. El período cubierto se extiende desde el 1 de enero de 2015 hasta el 31 de diciembre de 2025, generando una serie de 4.018 observaciones diarias. Esta ventana permite capturar un ciclo pre-pandémico con estacionalidad relativamente estable, el shock estructural asociado al COVID-19, y la etapa posterior de normalización del sistema sanitario. La consolidación regional (en lugar de un hospital único) reduce la varianza idiosincrática del nivel local y permite que los modelos aprendan patrones más estables y generalizables.

PASO 2 · Partición temporal — separación entrenamiento/evaluación

La serie se divide cronológicamente en dos subconjuntos: un conjunto de entrenamiento que abarca enero 2015 – diciembre 2023 (nueve años, aproximadamente 80 % de las observaciones), y un conjunto de evaluación fuera de muestra que abarca enero 2024 – diciembre 2025 (dos años, 24 meses). Esta partición se define ex ante y se mantiene fija para todos los modelos evaluados, de modo que las métricas reportadas son directamente comparables entre enfoques. Respetar el orden cronológico es fundamental en series temporales: una validación aleatoria introduciría data leakage del futuro al pasado, inflando artificialmente el desempeño aparente. Adicionalmente, situar completamente la evaluación en el período post-pandémico (2024-2025) garantiza que las métricas reportadas reflejen el desempeño en condiciones operativas normales, sin contaminación por el régimen anómalo de 2020-2021.

PASO 3 · Análisis exploratorio de la serie

Antes de cualquier modelamiento, la serie se somete a un análisis exploratorio sistemático orientado a identificar los patrones estructurales que cualquier modelo deberá capturar para ser operativamente útil. Los hallazgos centrales son cuatro: (i) la serie presenta estacionalidad anual pronunciada con un peak invernal entre junio y agosto y un mínimo estival entre enero y febrero, con una razón peak/valle cercana a 2.8; (ii) existe una estacionalidad intra-semanal estable, con los lunes registrando la mayor demanda y los jueves el mínimo; (iii) las vacaciones de invierno constituyen un evento calendario móvil cuya posición varía hasta dos semanas entre años consecutivos y coincide sistemáticamente con el mínimo invernal local; y (iv) el período pandémico 2020-2021 no se comporta como un único régimen sino como una secuencia de subregímenes con distinto nivel y dinámica. Estos hallazgos, documentados en profundidad en el Capítulo 3, fundamentan la construcción de variables del paso siguiente.

PASO 4 · Definición y construcción de variables explicativas

A partir de los hallazgos del análisis exploratorio, se construye un conjunto estructurado de variables explicativas agrupadas en seis familias (formalmente definidas en la Sección 3.12): variable dependiente y tendencia, estacionalidad determinística con sus interacciones, componentes de Fourier para capturar periodicidades superpuestas, calendario escolar móvil mediante 61 dummies event-relative que se activan según la posición relativa al receso oficial, intervenciones de cambio de régimen que segmentan la pandemia en múltiples tramos combinando dummies de nivel y rampas lineales, y variables dinámicas dependientes de la serie (30 rezagos, medias móviles de 7/15/30 días y media móvil exponencial). El OLS utiliza únicamente variables deterministas, incluyendo las interacciones categóricas triples día-semana $\times$ semana-mes $\times$ mes. CatBoost y LSTM utilizan un conjunto compartido de 163 variables que combina calendario, Fourier, intervenciones, feriados y dinámicas. Esta simetría de inputs entre

CatBoost y LSTM es una decisión de diseño deliberada para que las diferencias de desempeño se atribuyan al algoritmo y no a la información disponible.

PASO 5 · Modelos de complejidad creciente

Se implementan tres modelos que representan niveles crecientes de complejidad algorítmica y distintos supuestos sobre la estructura del proceso generador de datos. El OLS (regresión lineal por mínimos cuadrados) opera como benchmark interpretable: cada coeficiente tiene significado directo y permite verificar que las variables construidas capturan los efectos esperados; su predicción a 30 días es puramente determinista y no sufre acumulación de error recursivo. CatBoost (ensamble de 6.000 árboles de gradient boosting con profundidad máxima 6) incorpora las mismas variables estáticas más el bloque dinámico, y genera sus pronósticos de forma recursiva actualizando los rezagos y las medias móviles con los valores predichos en cada paso. LSTM (red recurrente de 128 unidades ocultas en 2 capas) recibe exactamente las mismas variables que CatBoost y opera bajo el mismo esquema recursivo, posicionándose como control metodológico: si el algoritmo recurrente aporta sobre el ensamble de árboles, debe manifestarlo con igual información disponible. Se reporta complementariamente una variante direct multi-step de LSTM que predice los 31 días de golpe, para aislar el efecto de la acumulación de error recursivo.

PASO 6 · Walk-forward mensual

El procedimiento de validación replica el escenario operativo real de planificación sanitaria. Para cada uno de los 24 meses del período de evaluación, el modelo se reentrena utilizando todos los datos disponibles hasta el último día del mes anterior, y luego genera predicciones para los 30-31 días del mes en curso. Los reentrenamientos son independientes: el modelo usado en mayo 2024 incluye datos hasta abril 2024, mientras que el modelo usado en junio 2024 incluye datos hasta mayo 2024. Esta estrategia permite que el modelo incorpore

progresivamente la información nueva que va emergiendo en el período post-entrenamiento, simulando fielmente un sistema desplegado en producción. Las predicciones dentro de cada ventana se generan con horizonte de 30 días: el día $t+1$ se pronostica primero, y para los modelos con variables dinámicas el valor pronosticado se utiliza como insumo para estimar $t+2$, $t+3$ y así sucesivamente hasta completar el mes. Este esquema es metodológicamente más exigente que la evaluación one-step-ahead convencional, dado que los errores pueden acumularse a medida que avanza el horizonte.

PASO 7 · Evaluación comparativa

El desempeño predictivo se evalúa mediante cuatro métricas complementarias calculadas sobre el conjunto completo fuera de muestra: RMSE (penaliza errores grandes, relevante porque los peaks son precisamente lo que se necesita anticipar), MAE (error promedio en unidades de consultas, directamente interpretable), MAPE (error relativo que permite comparar entre períodos con distinto nivel) y R^2 fuera de muestra (proporción de varianza explicada respecto a predecir la media). La evaluación se realiza no solo de forma agregada sino también desagregada por mes, para identificar períodos de desempeño degradado, y con análisis de robustez temporal comparando los subperíodos 2024 y 2025. Adicionalmente, todos los modelos se contrastan contra un baseline estacional simple basado en el promedio histórico por semana epidemiológica, que actúa como piso estadístico mínimo: si ningún modelo supera al baseline, el ejercicio de modelación no agrega valor sobre una estrategia trivial. Como se documenta en la Sección 1.5.7, las cuatro métricas se interpretan descriptivamente y no como tests estadísticos formales, dada la autocorrelación residual presente en la serie.

PASO 8 · Implicancias operativas

La fase final del proceso traduce los resultados predictivos en recomendaciones de gestión para la red asistencial. Este paso responde directamente al objetivo estratégico de los Servicios

de Salud Reloncaví, Chiloé y Osorno de mejorar la planificación de capacidad operativa, y se concentra en tres dimensiones: planificación de dotación y turnos (activación costo-efectiva de refuerzos solo cuando el pronóstico anticipa saturación), adquisición anticipada de insumos críticos y medicamentos en ventanas de lead-time operativo, y coordinación con la red asistencial mediante derivación proactiva a atención primaria (CESFAM y SAPU) cuando se prevé un alza de demanda. Estas implicancias se desarrollan en detalle en la Sección 5.7 y conectan el ejercicio analítico con las decisiones concretas que habilita. La precisión del pronóstico ($R^2=0.79$, MAPE=11.91 % del modelo CatBoost) se traduce operativamente en la capacidad de anticipar escenarios de alta demanda con un horizonte de 30 días, ventana compatible con los ciclos de negociación presupuestaria y ajuste de dotación de la Subsecretaría de Redes Asistenciales.

4.3 Regresión lineal estructurada (OLS)

El modelo utiliza exclusivamente variables estáticas (deterministas), sin rezagos ni variables dinámicas. Esto significa que su pronóstico a 30 días no depende de predicciones previas: cada día se pronostica directamente a partir de su fecha, mes, día de semana y las demás variables de calendario. Esta propiedad lo convierte en un benchmark robusto, ya que no sufre acumulación de error recursivo.

Variables incluidas: el conjunto completo de variables deterministas utilizadas por el OLS se define formalmente en la Sección 3.12 (tendencia lineal, estacionalidad determinística con interacciones triples día-semana $\times$ semana-mes $\times$ mes, vacaciones de invierno event-relative, intervenciones de régimen COVID-19 y feriados nacionales). La especificación algebraica explícita del modelo corresponde a la ecuación (3.11), donde cada bloque de coeficientes agrupa un conjunto temático de variables. El OLS se distingue de CatBoost y LSTM en dos aspectos: no incorpora componentes de Fourier —su estacionalidad se captura mediante las interacciones categóricas de alto orden— y no incluye variables dinámicas dependientes de la serie.

Reentrenamiento: en cada mes del walk-forward, el modelo se reestima con todos los datos disponibles hasta el mes anterior utilizando la librería statsmodels con interfaz de fórmulas patsy, tal como se describe en el Paso 6 de la síntesis metodológica de la Sección 4.1.

Este modelo cumple el rol de *benchmark interpretable* dentro del diseño experimental, tal como se justifica en el Paso 5 de la síntesis metodológica: sus coeficientes tienen significado directo (por ejemplo, el efecto porcentual asociado a un lunes de julio versus un viernes de enero) y permiten verificar empíricamente que las variables construidas en el análisis exploratorio capturan los patrones esperados. Esta característica lo convierte en una referencia metodológica clave antes de evaluar modelos de mayor complejidad funcional.

4.4 Gradient Boosting

El modelo de Gradient Boosting, fundamentado teóricamente en la Sección 2.4 (Chen & Guestrin, 2016), se implementa mediante la librería CatBoost (Prokhorenkova et al., 2018). A diferencia del modelo lineal, CatBoost recibe tanto variables estáticas como variables dinámicas construidas a partir de la serie transformada en logaritmo, lo que le permite capturar dependencias temporales no lineales e interacciones complejas entre variables sin necesidad de especificarlas explícitamente.

Variables: CatBoost utiliza las 163 variables definidas formalmente en la Sección 3.12, que incluyen el bloque de calendario (tendencia, estacionalidad determinística, semana del mes), 18 componentes de Fourier para periodicidades de 7, 30.4375 y 365.25 días (3 armónicos cada una), el conjunto de variables event-relative de vacaciones de invierno (61 dummies), las intervenciones de cambio de régimen pandémico (20 variables entre rampas y dummies de nivel), 7 feriados nacionales, 30 rezagos (lag 1 a lag 30), medias móviles de 7, 15 y 30 días, y media móvil exponencial con span de 15 días. Este conjunto es idéntico al utilizado por la LSTM multivariada (Sección 4.5), de modo que las diferencias de desempeño entre ambos modelos se

atribuyen al algoritmo y no a la información disponible, tal como se discute en la síntesis del Paso 5 (Sección 4.1).

Hiperparámetros: 6.000 iteraciones, tasa de aprendizaje 0.02, profundidad máxima 6, regularización L2 de 3.0, submuestreo 0.7, función de pérdida RMSE, semilla aleatoria 42. Estos valores se fijaron buscando un equilibrio entre desempeño predictivo, estabilidad y costo computacional. Una extensión posterior del trabajo podría profundizar en el análisis de sensibilidad del modelo frente a cambios en profundidad, regularización y número de árboles.

Predicción recursiva: durante la generación del pronóstico a 30 días, los rezagos y las medias móviles se actualizan con los valores pronosticados en cada paso. Es decir, el valor predicho para el día $t+1$ se incorpora al estado para estimar el día $t+2$, actualizando tanto el vector de lags como las ventanas de rolling mean y la media móvil exponencial. Este esquema introduce la posibilidad de acumulación de error a medida que avanza el horizonte, pero permite que el modelo utilice su propia información reciente para ajustar las predicciones sucesivas, replicando el escenario operativo real de planificación a 30 días descrito en el Paso 6 de la síntesis metodológica.

4.5 Red Neuronal recurrente (LSTM)

La implementación de la red recurrente LSTM, fundamentada teóricamente en la Sección 2.5 (Hochreiter & Schmidhuber, 1997), sigue dos variantes metodológicamente distintas para abordar dos preguntas complementarias sobre la capacidad de las redes recurrentes en esta serie.

La primera variante —denominada **LSTM multivariada recursiva**— utiliza exactamente el mismo conjunto de 163 variables que CatBoost, incluyendo las variables deterministas de calendario, las intervenciones pandémicas, los componentes de Fourier, los 30 rezagos y las medias móviles documentadas en la Sección 3.12. Bajo el esquema de walk-forward mensual,

la red se reentrena cada mes con los datos disponibles hasta el cierre del mes anterior y genera las predicciones de los 30-31 días siguientes de forma recursiva: el valor pronosticado para el día $t+1$ se incorpora al estado para estimar el día $t+2$, actualizando tanto las variables de rezago como las medias móviles. Esta variante responde la pregunta de comparación directa con CatBoost: dado el mismo conjunto de información explicativa y la misma estrategia de predicción, ¿qué arquitectura captura mejor los patrones de la serie?

La segunda variante —denominada **LSTM direct multi-step**— utiliza el mismo espacio de variables pero cambia la estrategia de predicción: en lugar de generar los 30 días uno a uno de forma recursiva, la red recibe una ventana de 60 días de contexto y produce directamente un vector de 31 valores correspondientes a los 31 días del horizonte. Esta variante evita la acumulación de error recursivo, a cambio de pedirle a la red que aprenda simultáneamente la estructura de horizontes cortos y largos. Responde una pregunta distinta a la anterior: ¿la acumulación de error en predicción recursiva es el factor limitante del desempeño de las redes recurrentes en esta serie?

Arquitectura — variante recursiva (principal): SEQ_LENGTH = 30 días de contexto; 128 unidades ocultas; 2 capas LSTM apiladas; dropout 0.2 entre capas; capa lineal de salida de dimensión 1. Entrenamiento con optimizador Adam, tasa de aprendizaje $1e-3$, batch de 256, 30 épocas, clipping de gradiente 1.0. La serie y las variables se normalizan con z-score ajustado sobre el conjunto de entrenamiento de cada mes.

Arquitectura — variante direct multi-step: SEQ_LENGTH = 60 días de contexto; 128 unidades ocultas; 3 capas LSTM apiladas; dropout 0.3; BatchNorm y Dropout a la salida; capa lineal final de dimensión 31 (un valor por día del horizonte). Entrenamiento con Adam (learning rate $5e-4$, weight decay $1e-5$), batch de 64, hasta 300 épocas con early stopping (patience 20), scheduler ReduceLROnPlateau y función de pérdida Huber.

Decisión sobre cuál variante reportar como comparación principal: se reporta la variante recursiva como comparación principal en el Capítulo 5 por dos razones. Primero, porque utiliza la misma estrategia de predicción que CatBoost (recursiva multi-step), lo que aísla el efecto del algoritmo sin introducir un grado de libertad adicional por la estrategia de pronóstico. Segundo, porque responde directamente la pregunta metodológicamente relevante sobre si la capacidad representacional de una red recurrente supera la de un ensamble de árboles cuando ambos reciben exactamente la misma información. La variante direct multi-step se reporta como resultado complementario para descartar que la acumulación de error recursivo sea el factor determinante del desempeño observado.

4.6 Síntesis comparativa del modelamiento

La Tabla 4.1 sintetiza las características estructurales de los tres modelos implementados, permitiendo contrastar sus decisiones de diseño antes de examinar los resultados empíricos del Capítulo 5.

Aspecto	OLS	CatBoost	LSTM	Justificación
Variables	Solo estáticas; 592 términos incluyendo interacciones $D \times S \times M$	163 variables: calendario, intervenciones, Fourier, lags, rolling, EMA	163 variables (mismas que CatBoost)	Simetría de inputs entre modelos no lineales
Predicción	Determinista (sin lags)	Recursiva 30d	Recursiva 30d (principal) + Directa 31d (variante)	Distintas estrategias de generación de pronóstico
No linealidad	No (lineal aditivo)	Sí (árboles)	Sí (red neuronal)	Complejidad creciente
Interpretabilidad	Alta (coeficientes)	Media (importancia de features)	Baja (caja negra)	Trade-off precisión vs interpretabilidad
Reentrenamiento	Mensual (rápido)	Mensual (~12s/mes)	Mensual (~4s/mes GPU)	Todos viables operativamente

Tabla 4.1 Comparación de características de los modelos implementados.

La progresión OLS $\rightarrow$ CatBoost $\rightarrow$ LSTM permite evaluar tres preguntas complementarias: (1) si las variables deterministas construidas a partir del análisis exploratorio son suficientes para pronosticar con precisión operativa (OLS); (2) si la incorporación de dependencia temporal explícita mejora sustantivamente el pronóstico (CatBoost vs OLS); y (3) si una arquitectura recurrente profunda, recibiendo el mismo conjunto de variables que CatBoost, captura mejor los patrones de la serie (LSTM multivariada vs CatBoost). La respuesta empírica a cada una de estas preguntas se presenta en el Capítulo 5.

5. CAPÍTULO 5: RESULTADOS Y DISCUSIÓN

5.1 Comparación global de desempeño predictivo

La Tabla 5.1 presenta las métricas de desempeño fuera de muestra para los tres modelos evaluados, calculadas sobre los 24 meses del walk-forward (enero 2024 - diciembre 2025). Todas las métricas corresponden a predicciones genuinamente fuera de muestra: en cada mes, el modelo solo utilizó datos disponibles hasta el mes anterior.

Modelo	R ² OOS	RMSE	MAE	MAPE
Baseline (prom. semanal)	0.4635	226.3	172.4	19.58 %
OLS (regresión lineal)	0.7139	165.3	128.2	16.25 %
CatBoost	0.7897	141.7	100.0	11.91 %
LSTM multivariada (recursiva — principal)	0.6223	189.9	142.8	17.16 %
LSTM direct multi-step (complementaria)	0.6431	184.6	142.8	16.60 %

Tabla 5.1 Métricas de desempeño fuera de muestra sobre los 24 meses del walk-forward. CatBoost (sombreado) obtiene el mejor desempeño en las cuatro métricas simultáneamente. Se reportan las dos variantes de LSTM: la recursiva multivariada constituye la comparación metodológica principal por operar bajo la misma estrategia de predicción que CatBoost; la variante direct multi-step se incluye como control para descartar que la acumulación de error recursivo sea el factor limitante

La Tabla 5.1 presenta las métricas de desempeño fuera de muestra para los modelos evaluados y para un baseline estacional simple basado en el promedio histórico por semana epidemiológica. Este baseline alcanza un R² de 0.4635, un RMSE de 226.3, un MAE de 172.4 y un MAPE de 19.58 %, lo que establece un piso de comparación para evaluar si los modelos de mayor complejidad aportan una mejora predictiva operativamente relevante.

En comparación con este baseline, todos los modelos evaluados muestran una mejora en desempeño. CatBoost obtiene el mejor resultado global, con un R² fuera de muestra de 0.7897 y un MAPE de 11.91 %. La regresión lineal estructurada alcanza un R² de 0.7139 y un MAPE de 16.25 %, mientras que la LSTM multivariada recursiva (comparación principal) obtiene un R² de 0.6223 y un MAPE de 17.16 %, y su variante direct multi-step alcanza un R² de 0.6431 y un

MAPE de 16.60 %. Estos resultados indican que los enfoques modelados capturan estructura adicional de la serie que no está presente en una estrategia basada únicamente en promedios históricos (ver Figuras 5.1, 5.2 y 5.3).




Figura 5.1 Pronóstico CatBoost fuera de muestra (walk-forward mensual, 2024–2025). $R^2=0.79$, MAPE=11.91 %




Figura 5.2 Pronóstico OLS fuera de muestra (walk-forward mensual, 2024–2025). $R^2=0.71$, MAPE=16.25 %




Figura 5.3 Pronóstico LSTM direct multi-step fuera de muestra (walk-forward mensual, 2024–2025). $R^2=0.64$, MAPE=16.60 %

5.2 Justificación empírica del modelo seleccionado

La comparación fuera de muestra descrita en la Sección 5.1 permite identificar empíricamente cuál de los enfoques evaluados alcanza el mejor desempeño predictivo para el problema planteado. La Figura 5.4 consolida visualmente las cuatro métricas utilizadas (R^2 , RMSE, MAE, MAPE) para los cuatro modelos de la comparación, y la Tabla 5.1 entrega los valores exactos. La conclusión es consistente en las cuatro métricas sin excepción: el modelo CatBoost supera al resto de los enfoques, superando simultáneamente al baseline estacional, al modelo lineal estructurado y a la red recurrente LSTM.




Figura 5.4 Comparación de desempeño predictivo fuera de muestra (walk-forward mensual, enero 2024 – diciembre 2025). El «Baseline» corresponde al promedio histórico por semana epidemiológica, utilizado como piso estadístico mínimo de comparación. El OLS (regresión lineal estructurada) cumple un rol distinto: es el benchmark interpretable cuyos coeficientes permiten verificar que las variables construidas capturan los efectos esperados. El modelo CatBoost (barra azul oscuro, con borde resaltado) obtiene el mejor valor en las cuatro métricas reportadas. La consistencia entre métricas descarta que el resultado dependa de la definición de pérdida utilizada para evaluar

5.2.1 Lectura métrica por métrica

El examen individual de cada métrica permite caracterizar la naturaleza de la superioridad observada y vincularla con aspectos operativos concretos de la planificación asistencial.

Varianza explicada (R^2)

CatBoost alcanza un R^2 fuera de muestra de 0.7897, es decir, explica aproximadamente el 79 % de la variabilidad observada en la demanda fuera del período de entrenamiento. Esto equivale a una mejora de +0.33 puntos respecto al baseline estacional (0.4635, equivalente a +70 % relativo), +0.08 puntos sobre el OLS (0.7139) y +0.17 puntos sobre la LSTM multivariada (0.6223). La diferencia con el baseline confirma que el ejercicio de modelación agrega valor sustantivo sobre una estrategia de planificación basada únicamente en promedios históricos.

Error cuadrático medio (RMSE)

CatBoost registra un RMSE de 141.7 consultas diarias, frente a 226.3 del baseline (reducción de 37 %), 165.3 del OLS (reducción de 14 %) y 189.9 de la LSTM (reducción de 25 %). El RMSE es la métrica más sensible a errores grandes en peaks estacionales, lo que es

relevante para planificación de capacidad: un modelo con RMSE alto es un modelo que falla precisamente cuando las decisiones son más críticas.

Error absoluto medio (MAE)

CatBoost alcanza un MAE de 100.0 consultas diarias, equivalente a un error típico de aproximadamente 100 consultas sobre una demanda promedio post-pandemia de 913 consultas/día. Esto representa una reducción de 42 % respecto al baseline, 22 % respecto al OLS y 30 % respecto a la LSTM. A diferencia del RMSE, el MAE no penaliza desproporcionadamente los errores grandes, lo que permite interpretarlo directamente como el error esperado en un día cualquiera.

Error porcentual medio (MAPE)

CatBoost reporta un MAPE de 11.91 %, significativamente menor que el 19.58 % del baseline, el 16.25 % del OLS y el 17.16 % de la LSTM. La reducción de 4.3 puntos porcentuales sobre el OLS y de 5.3 sobre la LSTM indica que el error relativo se mantiene contenido en un rango operativamente aceptable para la planificación a 30 días. Según lo discutido en la Sección 1.5.7, el MAPE debe interpretarse con precaución en los meses de verano donde el nivel de la serie es bajo; la Sección 5.4 desagrega el desempeño mensual para controlar este efecto.

5.2.2 Síntesis: por qué CatBoost

La superioridad de CatBoost no depende de la métrica elegida para evaluar. Obtener el mejor valor en R^2 , RMSE, MAE y MAPE simultáneamente implica que el modelo no solo minimiza un tipo particular de error, sino que entrega predicciones consistentemente más cercanas a la realidad en múltiples dimensiones de la misma. En términos del diseño experimental, la comparación con LSTM es especialmente informativa: ambos modelos reciben exactamente las mismas 163 variables y operan bajo el mismo esquema de walk-forward recursivo. La diferencia de desempeño (+0.17 puntos de R^2 , reducción de 48 RMSE, reducción de 43 MAE) no puede

atribuirse a diferencias en la información disponible, sino a la capacidad del algoritmo para explotarla. Este resultado sugiere que, para la estructura de dependencias observada en la serie de consultas respiratorias, los ensambles de árboles de decisión potenciados por gradiente capturan mejor las interacciones relevantes que las representaciones secuenciales aprendidas por redes recurrentes profundas.

Cabe destacar que la LSTM, pese a ser el modelo de mayor complejidad paramétrica (128 unidades ocultas en 2 capas recurrentes), obtiene un desempeño inferior incluso al del OLS lineal. Este hallazgo es consistente con la literatura que ha advertido repetidamente que la complejidad arquitectónica por sí sola no garantiza mejoras predictivas, particularmente en series de frecuencia diaria donde una especificación cuidadosa de variables de calendario y cambios de régimen puede capturar la mayor parte de la estructura explicable (Makridakis et al., 2018). La variante direct multi-step de la LSTM ($R^2=0.6431$), que elimina la acumulación de error recursivo, tampoco alcanza el desempeño de CatBoost, descartando que la estrategia de predicción sea el factor limitante.

En consecuencia, CatBoost se adopta como el modelo de referencia para la discusión de resultados operativos de la Sección 5.7 y las implicancias de planificación asistencial. La regresión lineal estructurada se mantiene como benchmark interpretable, útil para identificar la magnitud de los efectos sistemáticos (coeficientes directamente interpretables), mientras que CatBoost entrega la mejor capacidad predictiva para el pronóstico operativo a 30 días.

5.3 Ganancia marginal por complejidad

La comparación entre modelos permite cuantificar la ganancia marginal de cada nivel de complejidad adicional:

OLS a CatBoost: la incorporación de variables dinámicas (lags, medias móviles) y un modelo no lineal mejora el R^2 en 0.076 puntos (de 0.71 a 0.79) y reduce el MAPE en 4.3 puntos

porcentuales (de 16.25 % a 11.91 %). Esta mejora es sustantiva y sugiere que la dependencia temporal residual, no capturada por las variables estáticas, contiene información predictiva relevante que CatBoost logra explotar.

CatBoost a LSTM: la LSTM multivariada recibe exactamente las mismas 163 variables que CatBoost y opera bajo el mismo esquema recursivo de predicción a 30 días. Pese a contar con la misma información y la misma estrategia, su desempeño es inferior: R^2 cae de 0.79 a 0.62, MAPE sube de 11.91 % a 17.16 %. Este resultado indica que, para esta serie, la capacidad representacional de los árboles potenciados por gradiente supera a la de las redes recurrentes cuando ambos tienen acceso a la misma información explicativa estructurada.

Este resultado es consistente con la literatura que advierte que modelos de mayor complejidad no siempre superan a modelos correctamente especificados (Makridakis et al., 2018), y refuerza el principio de parsimonia: la complejidad adicional debe justificarse con mejoras medibles. En este caso, la evidencia es doblemente consistente, ya que tanto bajo un esquema de predicción recursiva (LSTM multivariada, $R^2=0.62$) como bajo predicción directa (LSTM direct, $R^2=0.64$), la ganancia esperada sobre CatBoost no se materializa.

5.4 Desempeño mensual del walk-forward

El esquema de walk-forward mensual produce 24 ventanas de pronóstico fuera de muestra, una por cada mes del período enero 2024 – diciembre 2025. Evaluar el desempeño mes a mes —en lugar de únicamente en agregado— permite identificar los períodos donde cada modelo es más o menos confiable, reconociendo que la estabilidad del pronóstico es tan importante como la precisión promedio para su uso operativo. La Tabla 5.2 presenta las cuatro métricas (R^2 , RMSE, MAE y MAPE) para los dos modelos principales —OLS como benchmark interpretable y CatBoost como modelo seleccionado— en cada uno de los 24 meses evaluados.

Mes	OLS				CatBoost			
	R ²	RMSE	MAE	MAPE%	R ²	RMSE	MAE	MAPE%
2024-01	0.60	55.7	45.5	11.2	0.81	37.9	31.2	7.3
2024-02	0.01	49.1	41.5	9.5	-0.49	60.2	51.8	11.9
2024-03	0.69	115.7	91.7	14.6	0.87	75.9	62.7	10.2
2024-04	0.15	88.9	78.2	11.2	-0.74	127.1	114.8	15.2
2024-05	-0.03	239.0	194.7	15.0	0.20	210.2	175.2	13.7
2024-06	0.63	175.4	153.6	17.0	0.56	193.1	165.3	20.4
2024-07	-0.57	240.4	221.0	36.8	0.36	152.9	97.6	12.7
2024-08	0.10	166.6	134.3	13.1	0.82	74.8	54.2	5.2
2024-09	0.06	115.2	94.7	9.0	0.41	90.8	75.5	7.0
2024-10	0.19	92.2	75.0	8.2	0.27	87.5	70.4	7.7
2024-11	0.01	95.9	79.3	8.7	0.45	71.5	59.2	6.7
2024-12	-0.41	214.6	192.9	21.4	0.77	86.5	71.9	9.4
2025-01	0.68	59.1	52.6	15.2	0.60	66.1	53.8	16.8
2025-02	-9.83	102.0	97.6	34.7	0.36	24.8	20.4	7.0
2025-03	0.71	158.5	136.6	25.3	0.50	209.8	153.7	17.8
2025-04	-0.94	186.4	171.3	17.8	0.41	102.6	88.7	9.2
2025-05	-0.43	131.5	109.9	11.5	-2.21	196.8	172.7	18.2
2025-06	-0.82	161.4	130.2	15.2	0.66	69.5	58.0	7.2
2025-07	-0.76	145.0	100.0	14.0	0.41	83.7	72.4	10.2
2025-08	-0.34	160.0	132.7	15.4	0.63	83.6	68.0	7.5
2025-09	-0.38	170.3	129.8	10.8	-1.04	207.0	189.1	16.0
2025-10	-2.25	306.1	280.2	21.9	0.09	162.0	125.1	9.7
2025-11	-1.29	286.0	246.8	20.0	-2.54	355.4	322.6	30.2
2025-12	0.66	86.0	73.2	13.2	0.84	59.6	44.0	9.2

Tabla 5.2 Métricas de desempeño por mes del walk-forward (enero 2024 – diciembre 2025). Columnas sombreadas en azul corresponden a CatBoost.




Figura 5.5 Comparación mensual de desempeño predictivo entre OLS y CatBoost a lo largo de las 24 ventanas del walk-forward (enero 2024 – diciembre 2025). Cada panel presenta una métrica (RMSE, MAE, MAPE). CatBoost (azul oscuro) muestra ventaja consistente en la mayoría de los meses, con algunos meses donde OLS es competitivo o incluso superior (notablemente 2025-05, 2025-09 y 2025-11).

5.4.1 Lectura sustantiva del desempeño mensual

El análisis mes a mes permite tres observaciones operativamente relevantes que las métricas agregadas ocultan. Primero, CatBoost es claramente superior en 17 de los 24 meses cuando se mide por MAPE, y en 15 de 24 cuando se mide por RMSE. En particular, CatBoost mantiene $MAPE \leq 10\%$ en 12 de los 24 meses, mientras que OLS logra este umbral solo en 7 meses. Segundo, ambos modelos presentan meses con R^2 negativo —12 para OLS y 6 para CatBoost—, períodos donde la dinámica real se aleja sustancialmente de los patrones históricos con los que se entrenó el modelo. Tercero, los peores meses de ambos modelos tienden a concentrarse en la segunda mitad del período de evaluación (2025), particularmente en los meses de transición estacional (marzo-mayo y septiembre-noviembre), sugiriendo que la dinámica de 2025 presenta características que no estaban completamente representadas en el período de entrenamiento (2015–2023; ver Figura 5.5).

El mes de noviembre de 2025 merece mención especial: ambos modelos obtienen sus peores métricas del período (OLS: $R^2 = -1.29$, MAPE = 20 %; CatBoost: $R^2 = -2.54$, MAPE = 30 %). Este comportamiento coincidente sugiere que el desempeño degradado no obedece a limitaciones algorítmicas específicas sino a un shock o quiebre de patrón en la demanda real de ese mes que ningún modelo basado exclusivamente en datos históricos podía anticipar. En contraste, diciembre 2025 recupera métricas saludables en ambos modelos (OLS: $R^2 = 0.66$; CatBoost: $R^2 = 0.84$), indicando que la anomalía fue transitoria.

Desde una perspectiva operativa, esta heterogeneidad temporal tiene implicancia directa: el modelo no debe interpretarse como un pronóstico confiable en todos los contextos por igual, sino como una herramienta de anticipación que requiere acompañarse de monitoreo de sus residuos y de ajustes manuales cuando la realidad se desvía persistentemente de las predicciones por varios días consecutivos.

5.5 Robustez temporal: 2024 vs 2025

Al comparar el desempeño entre los dos años del período de evaluación, se observa que CatBoost mantiene mayor estabilidad que OLS. En 2024, CatBoost alcanza meses con R^2 superior a 0.80, mientras que en 2025 la calidad del pronóstico se degrada en varios meses. Esta degradación puede atribuirse a que el modelo fue entrenado con datos hasta 2023, y la dinámica de 2025 puede presentar patrones no observados en el período de entrenamiento.

Esta observación es relevante para la discusión operativa: un sistema de pronóstico implementado en producción requeriría reentrenamiento periódico con datos actualizados para mantener su precisión, lo que el esquema de walk-forward mensual ya contempla pero que en un despliegue real implicaría actualizaciones continuas de la base de datos DEIS.

La Tabla 5.3 resume el desempeño agregado por año para los tres modelos, a partir de las métricas mensuales de la Tabla 5.2. CatBoost es el más preciso en ambos años y en las

cuatro métricas, lo que confirma que la selección del modelo es estable y no depende del año evaluado. Se observa, no obstante, un deterioro moderado en 2025 respecto de 2024 (el MAPE de CatBoost pasa de 10.57 % a 13.26 % y su R^2 de 0.84 a 0.74), coherente con que 2025 concentra cuatro de los cinco meses atípicos de transición identificados en la Sección 5.6. El LSTM es el más estable entre años, pero a un nivel de error consistentemente más alto. En consecuencia, la robustez temporal se expresa en la estabilidad del ordenamiento entre modelos y en que CatBoost mantiene una precisión operativamente útil en ambos años, más que en una invariancia total del error. La Figura 5.6 ilustra gráficamente esta comparación.

Modelo	Año	R ² OOS	RMSE	MAE	MAPE
OLS	2024	0.74	152.7	117.4	14.70 %
	2025	0.69	177.0	138.4	17.80 %
CatBoost	2024	0.84	117.7	85.8	10.57 %
	2025	0.74	162.3	114.3	13.26 %
LSTM	2024	0.61	187.3	142.3	17.01 %
	2025	0.64	192.5	143.2	17.31 %

Tabla 5.3 Métricas de desempeño agregadas por año (2024 y 2025) para cada modelo, calculadas a partir de las métricas mensuales de la Tabla 5.2.




Figura 5.6 Comparación del MAPE anual por modelo (2024 vs 2025), calculado a partir de las métricas mensuales de la Tabla 5.2.

5.6 Degradación de la precisión por horizonte de predicción

El esquema de validación walk-forward genera, para cada uno de los 24 meses fuera de muestra, una secuencia de hasta 31 predicciones recursivas a partir del último dato observado. Esto permite analizar no solo el error promedio del modelo, sino cómo evoluciona la precisión a medida que el pronóstico se aleja del origen. Para ello, cada predicción se etiquetó según su horizonte $t+k$, definido como su posición dentro del mes proyectado (el primer día corresponde a $t+1$, el segundo a $t+2$, y así sucesivamente), y se agruparon las predicciones de los 24 meses por horizonte común. Esta lectura responde directamente a la necesidad de distinguir la utilidad del pronóstico en distintos plazos de planificación.

La Tabla 5.4 reporta el desempeño en cuatro horizontes de referencia. El comportamiento es claro: la precisión se mantiene prácticamente constante durante la primera semana y luego se deteriora de forma sostenida. El MAPE pasa de 7.19 % en $t+1$ a 20.00 % en $t+30$, es decir, el error se multiplica por un factor cercano a tres entre el primer día y el final del horizonte mensual.

Horizonte	MAPE	RMSE	MAE	n meses
$t+1$ (1 día)	7.19 %	86.2	59.6	24
$t+7$ (1 semana)	7.10 %	80.1	59.1	24
$t+14$ (2 semanas)	13.06 %	147.8	116.2	24
$t+30$ (1 mes)	20.00 %	203.7	160.4	22

Tabla 5.4 Desempeño de CatBoost en horizontes de referencia (promedio sobre los 24 meses fuera de muestra).

La Figura 5.7 muestra la curva completa de degradación. El tramo de corto plazo es notablemente plano y de bajo error, mientras que el deterioro recién se vuelve relevante a partir de la segunda semana. Agrupando los horizontes en tramos operativos (Tabla 5.5), el corto plazo (hasta $t+7$) sostiene un MAPE en torno a 7 %, el mediano plazo ($t+8$ a $t+14$) se ubica cerca de 10 %, y el largo plazo ($t+15$ a $t+31$) alcanza un MAPE promedio de 14.82 %.

Tramo	MAPE	RMSE	MAE	n
t+1 (1 día)	7.19 %	86.2	59.6	24
t+2 a t+7 (1 semana)	6.90 %	72.3	55.7	144
t+8 a t+14 (2 semanas)	10.05 %	111.4	82.8	168
t+15 a t+31 (3–4 semanas)	14.82 %	171.8	125.9	395

Tabla 5.5 Desempeño por tramo operativo.




Figura 5.7 Degradación del MAPE por horizonte de predicción (CatBoost, walk-forward, 24 meses fuera de muestra). Las bandas distinguen los tramos de corto, mediano y largo plazo.

Heterogeneidad del deterioro entre meses. El error promedio por horizonte oculta una diferencia importante entre meses. Para caracterizarla se aplicó un análisis de conglomerados (K-Means) sobre la trayectoria del error porcentual absoluto de cada mes a lo largo de los primeros 28 horizontes. El número de grupos se determinó por consenso de cuatro índices internos de validez (silueta, Dunn, Davies-Bouldin y Calinski-Harabasz), de los cuales tres (silueta, Davies-Bouldin y Calinski-Harabasz) coinciden en $k=2$, mientras que el índice de Dunn favorece marginalmente $k=4$ (ver Anexo D). El resultado, ilustrado en la Figura 5.8, identifica dos regímenes claramente distintos.

Un primer grupo, mayoritario (19 de 24 meses), presenta un error que se estabiliza en torno a 9–11 % y se mantiene acotado incluso en los horizontes largos. En estos meses, la

estructura determinística del modelo (efectos de calendario, día de la semana, vacaciones escolares e intervenciones) aporta información asociada al período proyectado y limita la propagación del error característica de los esquemas recursivos. Un segundo grupo, minoritario (5 meses: junio de 2024, y enero, marzo, mayo y noviembre de 2025), exhibe un buen desempeño inicial (MAPE bajo 7 % en $t+1$) pero un deterioro pronunciado a partir de la segunda semana, llegando a superar el 30 % hacia $t+28$. Estos meses coinciden con transiciones estacionales y episodios de demanda atípica, y son los que explican la mayor parte del crecimiento del error promedio observado en la Figura 5.7.




Figura 5.8 Trayectorias de error por mes y centroides de cada régimen (K-Means, $k=2$). El régimen estable agrupa 19 meses; el atípico, 5 meses.

Interpretación: por qué la precisión no mejora en el horizonte largo. El patrón de la Figura 5.7 plantea una pregunta natural: si el modelo es preciso en el corto plazo, por qué no sostiene esa precisión hasta $t+30$. La respuesta combina tres factores encadenados.

En primer lugar, el pronóstico es recursivo. Para estimar el día $t+k$ el modelo requiere variables construidas a partir de la historia reciente de la serie (rezagos, medias móviles y suavizamientos exponenciales). En $t+1$ esas variables se calculan con valores observados; a

partir de $t+2$ se alimentan progresivamente de las propias predicciones del modelo, porque los valores reales del mes proyectado aún no existen en el momento de pronosticar. El error de cada día pasa así a ser insumo del día siguiente y se propaga a lo largo del horizonte. Esta acumulación es una propiedad estructural de cualquier esquema recursivo y no un defecto particular del modelo.

En segundo lugar, la estructura determinística del modelo contiene ese deterioro, pero no lo elimina. Las variables conocidas de antemano (mes, día de la semana, semana del mes, componentes de Fourier, calendario escolar, régimen COVID y feriados) no dependen de la historia reciente, por lo que mantienen correcto el nivel estacional incluso en los horizontes largos. Gracias a ello el error se estabiliza en torno al 20 % en $t+30$ en lugar de crecer sin control. Sin embargo, estas variables describen el patrón típico del calendario: anticipan la forma esperada de la demanda, no las desviaciones específicas de cada día.

En tercer lugar, y de forma decisiva, el límite del horizonte largo es de información y no de complejidad algorítmica. Las desviaciones que dominan el error a largo plazo, concentradas en los meses de transición estacional (Figura 5.8), responden a factores que no están representados en los datos disponibles, como la circulación viral, las condiciones climáticas o los brotes locales. Ningún modelo puede anticipar lo que no observa. Esto explica por qué el LSTM, pese a su mayor flexibilidad, no supera a CatBoost (Sección 5.2): el techo de desempeño lo fija la información de entrada, no la capacidad del algoritmo. La vía para mejorar el horizonte largo no es un modelo más complejo, sino incorporar covariables exógenas epidemiológicas y climáticas, tal como se plantea en el trabajo futuro.

En síntesis, la precisión no mejora a 30 días porque la recursión acumula error y porque los gatillantes de la variación de corto plazo no se observan. Lo que el modelo sí garantiza es un nivel estacional confiable en todo el horizonte y una precisión alta en el corto plazo, que es precisamente la escala en la que se toman las decisiones de dotación y turnos.

5.7 Implicancias para la planificación operativa

Los resultados de esta investigación demuestran que es factible anticipar la demanda de urgencias respiratorias a 30 días con un margen de error promedio de apenas 11.91 % (CatBoost). Para los **Servicios de Salud Reloncaví, Chiloé y Osorno**, dependientes de la Subsecretaría de Redes Asistenciales, esta precisión analítica trasciende el ejercicio estadístico y se convierte en una herramienta habilitante para operativizar sus objetivos estratégicos y metas de gestión interna.

A diferencia de la planificación basada en promedios históricos, que reacciona tardíamente a las fluctuaciones de la demanda, el modelo propuesto permite transitar hacia una gestión proactiva fundamentada en datos. Las implicancias de esta anticipación se agrupan en tres grandes dimensiones operativas:

5.7.1 Alineación con los ciclos de negociación presupuestaria

La gestión de los Servicios de Salud está estrictamente sujeta a los ciclos de presupuesto del Ministerio de Salud. Contar con un pronóstico a 30 días, capaz de detectar desplazamientos en los *peaks* invernales (como el efecto móvil de las vacaciones escolares), permite respaldar cuantitativamente la solicitud y redistribución de fondos. Operativamente, las proyecciones del modelo deben integrarse en los hitos críticos de negociación de la red asistencial:

- **Septiembre (Propuesta):** Uso de pronósticos agregados para justificar la proyección de demanda del año siguiente.
- **Noviembre (Compromiso) y Diciembre (Ajuste):** Calibración de la dotación de personal a honorarios (amparada en el Decreto Supremo N° 98) y programación de compras de insumos críticos.
- **Marzo (Renegociación y Campañas):** Identificación temprana de brotes adelantados.

La literatura reciente ha demostrado el valor de anticipar la demanda respiratoria: el

análisis cuantitativo que respaldó la estrategia de inmunización con nirsevimab implementada en 2024 estimó reducciones del orden de 27.465 días-cama hospitalarios y 46.886 visitas a urgencia evitadas (Sauré et al., 2025). Un sistema de pronóstico que anticipe alzas tempranas podría complementar este tipo de estrategias, permitiendo activar campañas y refuerzos de capacidad con mayor anticipación.

5.7.2 Control de costos y optimización de métricas operacionales

La saturación de las Unidades de Emergencia Hospitalaria (UEH) no debe medirse bajo el concepto difuso de "degradación de la calidad", sino a través de indicadores operacionales cuantificables. El pronóstico preciso de CatBoost incide directamente en:

1. **Ocupación de camas y dotación 24/7:** Mantener operaciones de refuerzo 24/7 en períodos de valle genera altos costos por turnos adicionales y licencias. El modelo permite habilitar o deshabilitar camas y turnos de refuerzo de forma costo-efectiva, únicamente cuando la probabilidad de saturación supera la capacidad base. A modo de referencia, el arancel FONASA (Fonasa, 2025) valoriza el día-cama de una Unidad de Cuidado Intensivo en torno a \$55.000 y el de una Unidad de Tratamiento Intermedio en \$26.430, de modo que cada jornada de sobre o sub-dimensionamiento de capacidad crítica tiene un costo cuantificable; un error de pronóstico menor se traduce directamente en una asignación más eficiente de estos recursos. Esta valorización constituye un ejercicio ilustrativo de magnitud y no un resultado del modelo.
2. **Tiempos de espera en categorización:** Al anticipar un alza de consultas (donde históricamente entre el 80 % y 90 % ingresa por urgencias sin riesgo vital por un tema de accesibilidad), los directores de hospital pueden reforzar específicamente el área de *Triage* (categorización) para agilizar el flujo de pacientes.

3. **Articulación de la Atención Primaria (APS):** Detectar alzas inusuales permite a los Servicios de Salud coordinar con los CESFAM y SAPUs de su jurisdicción, derivando pacientes de baja complejidad al nivel primario para aliviar la carga del hospital base (ej. Hospital de Castro).

5.7.3 Diseño de un Sistema de Alertas Tempranas

Para que el pronóstico se traduzca en acciones concretas, se propone el siguiente flujo operativo de Alertas Tempranas, activado por las proyecciones del modelo CatBoost:

Nivel de Alerta	Gatillador (Proyección CatBoost a 30 días)	Responsable de Recepción	Acciones Operativas a Ejecutar
Alerta Verde (Operación Normal)	Demanda proyectada dentro de la capacidad base instalada.	Jefaturas de Urgencia (UEH).	Mantener dotación estándar. Programación regular de cirugías electivas.
Alerta Amarilla (Monitoreo)	Proyección indica aumento sostenido >15 % sobre el promedio estacional o detección de brote temprano (1-3 casos iniciales inusuales).	Subdirección Médica / Dirección del Hospital.	Revisión de stock de insumos respiratorios. Alerta a red de Atención Primaria (CESFAM/SAPU) para contención de casos de baja complejidad.
Alerta Naranja (Tensión de Red)	Proyección de demanda se acerca al 90 % de la capacidad máxima de atención en la red.	Dirección del Servicio de Salud (Osorno, Reloncaví, Chiloé).	Activación de turnos de refuerzo (médicos y enfermería). Habilitación de camas críticas pediátricas/adultos de reserva. Suspensión temporal de procedimientos electivos no urgentes.
Alerta Roja (Riesgo de Saturación)	Proyección supera la capacidad máxima expandida del Servicio de Salud.	SEREMI de Salud / Subsecretaría de Redes Asistenciales.	Redistribución macro-regional de pacientes. Inyección de recursos de emergencia. Derivación al sistema privado si corresponde (ver Tabla 5.6).

Tabla 5.6 Propuesta de protocolo de Alertas Tempranas para la red asistencial basado en predicciones algorítmicas

En conclusión, la adopción de este modelo estructurado permite abandonar la planificación reactiva, dotando a la autoridad sanitaria de una herramienta sustentada en datos para anticipar la demanda operativa, cumplir con las normativas vigentes y resguardar la oportunidad en la atención de la población usuaria de la Región de Los Lagos.

5.7.4 Cuantificación del valor económico del pronóstico (ejercicio ilustrativo)

Las secciones anteriores describen los mecanismos por los cuales un pronóstico más preciso habilita decisiones de capacidad más eficientes. Esta sección entrega una aproximación cuantitativa a ese valor, vinculando explícitamente la reducción del error de predicción con las decisiones operativas de dotación y uso de recursos. Siguiendo la lógica propuesta en la revisión, el ejercicio se estructura en dos niveles: una cuantificación física, independiente de cualquier supuesto monetario, y una valorización ilustrativa que traduce esa magnitud a términos económicos.

Reducción del error en unidades físicas. El insumo central es la diferencia de error absoluto medio entre el modelo y la estrategia de planificación basada en promedios históricos, que constituye el contrafactual operativo realista. Como se reportó en la Sección 5.2, el MAE fuera de muestra de CatBoost es de 100.0 consultas diarias, frente a 172.4 del baseline estacional. La adopción del modelo reduce por lo tanto el error medio de anticipación en 72.4 consultas por día, lo que proyectado a un año equivale a aproximadamente 26.400 consultas anuales cuya demanda pasa a estar correctamente anticipada. Respecto del benchmark lineal (OLS, MAE de 128.2), la ganancia marginal atribuible a CatBoost es de 28.2 consultas diarias, del orden de 10.300 consultas anuales (ver Tabla 5.7).

Comparación	MAE	Δ MAE diario	Proyección anual
Baseline estacional	172.4	—	—
OLS estructurado	128.2	—	—
CatBoost (modelo adoptado)	100.0	—	—
Adoptar CatBoost vs. baseline	—	72.4	≈ 26.400
Ganancia marginal CatBoost vs. OLS	—	28.2	≈ 10.300

Tabla 5.7 Reducción del error de anticipación al adoptar el modelo (consultas diarias y proyección anual).

El análisis de la composición del error muestra que este se distribuye de forma aproximadamente simétrica entre días de subestimación (52 % de los días, con una magnitud

media de 100 consultas) y de sobreestimación (48 %, magnitud media de 100 consultas). Esta simetría es relevante porque las dos formas de error tienen consecuencias económicas distintas: la subestimación genera presión sobre la capacidad instalada, derivación y uso de capacidad crítica, mientras que la sobreestimación implica sobredotación de personal y recursos ociosos. La mejora en la precisión opera sobre ambos márgenes de forma simultánea.

Valorización monetaria ilustrativa. Para dimensionar el valor económico, la reducción del error diario se multiplica por un costo unitario representativo y se proyecta al año, según la expresión: $\text{Beneficio anual} \approx \Delta\text{MAE} \times \text{costo unitario} \times 365$. El costo unitario se interpreta como el costo marginal de una decisión de capacidad mal dimensionada por cada consulta no anticipada, y no como el costo de la atención en sí. Dado que la mayoría de las consultas de urgencia respiratoria se resuelven en el nivel ambulatorio, el ejercicio adopta como referencia un rango de costo por atención de urgencia de entre \$15.000 y \$30.000, acotado por el arancel FONASA 2025: el extremo inferior corresponde al valor de una consulta de urgencia o de medicina general (código 101001, del orden de \$14.870) y el superior al de una consulta de especialidad (del orden de \$28.420). Los aranceles de capacidad crítica (día-cama UTI de \$26.430 y UCI de \$55.000, Sección 5.7.2) se reservan para la fracción de demanda que escala a hospitalización. Bajo estos supuestos, el valor asociado a la mejora en precisión se ubica en el siguiente rango (ver Tabla 5.8).

Costo unitario por consulta mal anticipada	Beneficio anual estimado
\$15.000	≈ \$396 millones
\$20.000	≈ \$529 millones
\$30.000	≈ \$793 millones

Tabla 5.8 Beneficio anual ilustrativo según costo unitario asumido ($\Delta\text{MAE} = 72.4$ consultas/día).

Estas cifras constituyen un ejercicio ilustrativo de orden de magnitud y no un resultado del modelo. Su propósito es dimensionar el valor potencial de una planificación informada por pronóstico, no estimar un ahorro contable preciso, que requeriría datos de costeo específicos de

la red regional no disponibles para este trabajo. El orden de magnitud resultante es coherente con la evidencia nacional disponible: el análisis cuantitativo que respaldó la estrategia de inmunización con nirsevimab estimó reducciones del orden de 27.465 días-cama y 46.886 visitas a urgencia a escala nacional (Sauré et al., 2025), lo que sitúa el aporte de una herramienta de anticipación a escala regional en un rango plausible. La diferencia conceptual es importante y debe subrayarse: mientras esa intervención evita demanda, el sistema de pronóstico no reduce el número de consultas, sino que mejora la capacidad de anticiparlas y dimensionar los recursos en consecuencia.

5.8 Limitaciones

Los resultados de este estudio deben interpretarse considerando ciertas limitaciones metodológicas y prácticas:

1. **Métricas y supuestos:** El uso de métricas de bondad de ajuste como el R^2 asume independencia de errores; sin embargo, la serie analizada presenta autocorrelación residual documentada. Asimismo, la métrica MAPE puede inflarse artificialmente durante los meses estivales donde la demanda base es muy baja. Por esta razón, el desempeño se evaluó de forma conjunta observando métricas absolutas y relativas.
2. **Modelos evaluados:** En el diseño inicial se consideró la implementación de modelos fundacionales de series de tiempo (como *TimeGPT*); no obstante, su naturaleza de "caja negra" impedía aislar e interpretar el efecto de variables operativas críticas para la autoridad sanitaria, como el desplazamiento del calendario escolar móvil. Por otro lado, los modelos de la familia ARIMA no fueron implementados; sus resultados publicados (Cárdenas et al., 2014) se utilizan como referencia comparativa.
3. **Optimización de hiperparámetros:** Los parámetros del modelo CatBoost (profundidad, regularización, número de árboles) se fijaron buscando un equilibrio de diseño, pero no

fueron sometidos a un proceso exhaustivo de *Grid Search* o calibración bayesiana. Es probable que el rendimiento reportado (MAPE de 11.91 %) tenga un margen de mejora adicional mediante una optimización computacional más agresiva.

6. CAPÍTULO 6: CONCLUSIONES Y TRABAJO FUTURO

6.1 Conclusiones

Esta investigación evaluó la viabilidad de pronosticar la demanda de urgencias respiratorias en la Región de Los Lagos con precisión y anticipación operativamente útiles para la planificación de la red asistencial. A partir de datos DEIS (2015-2025), se implementaron tres modelos de complejidad creciente y se evaluaron bajo un esquema de walk-forward mensual con horizonte de 30 días.

Los resultados permiten responder las hipótesis planteadas de la siguiente manera:

Respecto a H1 (utilidad operativa):

Los resultados indican que es posible pronosticar la demanda de urgencias respiratorias con un nivel de precisión compatible con su uso en planificación operativa. En particular, el desempeño del modelo CatBoost sugiere que el sistema puede anticipar períodos de mayor presión asistencial con un horizonte de hasta 30 días, generando información útil para apoyar decisiones de dotación, planificación de insumos y coordinación con la red asistencial.

Respecto a H2 (desempeño predictivo superior a un baseline simple):

La evidencia respalda esta hipótesis. El baseline estacional simple basado en promedio por semana epidemiológica alcanza un MAPE de 19.58 % y un R^2 de 0.4635, mientras que los tres modelos evaluados presentan un mejor desempeño fuera de muestra. En particular, CatBoost logra la mayor mejora relativa, reduciendo el MAPE en 7.67 puntos porcentuales respecto al baseline y mejorando sustantivamente el ajuste global. Esto confirma que la incorporación de estructura temporal y variables explicativas relevantes genera una ganancia predictiva operativamente útil frente a una estrategia basada únicamente en promedios históricos.

Respecto a H3 (valor de la información estructurada):

La evidencia respalda parcialmente esta hipótesis. El mejor desempeño de CatBoost frente a la LSTM no puede atribuirse a diferencias en la información disponible, dado que ambos modelos reciben exactamente el mismo conjunto de 163 variables. Lo que la evidencia sugiere, más bien, es que la capacidad del algoritmo para explotar la información estructurada es determinante: los ensambles de árboles de decisión potenciados por gradiente capturan mejor las interacciones entre variables de calendario, componentes de Fourier y dinámicas temporales que una arquitectura recurrente profunda operando sobre los mismos inputs. Este hallazgo es consistente con la literatura que advierte que la complejidad arquitectónica no garantiza mejoras predictivas cuando la especificación de variables ya captura la estructura relevante (Makridakis et al., 2018).

En conjunto, los resultados respaldan la idea de que el valor del sistema de pronóstico no depende únicamente de la complejidad algorítmica, sino de su capacidad para representar patrones relevantes del fenómeno y traducirse en información útil para la planificación de capacidad operativa.

6.2 Trabajo futuro

Se identifican las siguientes líneas de trabajo futuro que permitirían fortalecer y extender los resultados obtenidos:

Optimización de hiperparámetros: realizar ajuste sistemático de los hiperparámetros de CatBoost (profundidad, regularización, número de árboles) mediante validación cruzada temporal, y presentar la curva de error versus complejidad del ensamble.

Arquitecturas híbridas secuencia-ensamble: explorar arquitecturas que combinen los embeddings aprendidos por una LSTM sobre la secuencia temporal con las predicciones de CatBoost como features adicionales, evaluando si la combinación supera el desempeño de cada

modelo individual. Un enfoque alternativo consiste en utilizar CatBoost para pronosticar el nivel esperado y una LSTM para predecir los residuos, capturando dinámicas no lineales residuales.

Granularidad semanal: agregar un modelo con datos agregados por semana epidemiológica, que debería reducir el ruido y potencialmente alcanzar mayor R^2 , útil para planificación de mediano plazo.

Test formal de quiebre estructural: aplicar el test de Chow u otra prueba para confirmar empíricamente la presencia de cambio de régimen asociado a la pandemia.

Validación con actores del sistema de salud: presentar los resultados a gestores de la red asistencial para evaluar si el nivel de precisión obtenido es efectivamente útil para las decisiones que necesitan tomar, y calibrar umbrales de alerta operativa.

REFERENCIAS BIBLIOGRÁFICAS

Abraham, G., Byrnes, G. B., & Bain, C. A. (2009). Short-term forecasting of emergency inpatient flow. *IEEE Transactions on Information Technology in Biomedicine*, 13, 380-388.

Albrecht, S., Broderick, D., Dost, K., Cheung, I., Nghiem, N., Wu, M., ... & Wicker, J. (2024). Forecasting severe respiratory disease hospitalizations using machine learning algorithms. *BMC Medical Informatics and Decision Making*, 24(1), 293. <https://doi.org/10.1186/s12911-024-02702-0>

Box, G. E. P., & Jenkins, G. M. (1970). *Time Series Analysis: Forecasting and Control*. Holden-Day.

Cárdenas M., C., Sovier V., C., Pérez R., U., & González A., C. A. S. (2014). Consultas de urgencia general y por causa respiratoria en la Red de establecimientos del Sistema Nacional de Servicios de Salud (SNSS): un modelo predictivo en el Servicio de Salud de Chiloé. *Revista Chilena de Enfermedades Respiratorias*, 30(3), 133–141.

Chen, C.-F., Ho, W.-H., Chou, H.-Y., Yang, S.-M., Chen, I.-T., & Shi, H.-Y. (2011). Long-term prediction of emergency department revenue and visitor volume using autoregressive integrated moving average model. *Computational and Mathematical Methods in Medicine*, 2011, 395690. <https://doi.org/10.1155/2011/395690>

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *KDD '16: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, San Francisco, CA, USA, 785-794. Association for Computing Machinery. <https://doi.org/10.1145/2939672.2939785>

Coutin, G. (2007). Utilización de modelos ARIMA para la vigilancia de enfermedades transmisibles. *Revista Cubana de Salud Pública*, 33, 11.

Elsayed, S., Thyssens, D., Rashed, A., Jomaa, H. S., & Schmidt-Thieme, L. (2021). Do we really need deep learning models for time series forecasting? *arXiv preprint arXiv:2101.02118*.

Fonasa. (2025). *Arancel de prestaciones de salud 2025: Modalidad de Libre Elección* (Libro Arancel MLE 2025). <https://www.fonasa.cl/sites/fonasa/prestadores/modalidad-libre-eleccion>

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189–1232. <https://doi.org/10.1214/aos/1013203451>

Gill, J. M. (1999). Use of Hospital Emergency Departments for Nonurgent Care: A Persistent Problem with No Easy Solutions. *The American Journal of Managed Care*, 5, 1565-1568.

Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780.

Jones, S. S., Thomas, A., Evans, R. S., Welch, S. J., Haug, P. J., & Snow, G. L. (2008). Forecasting daily patient volumes in the emergency department. *Academic Emergency Medicine*, 15, 159-170.

Jones, S. S., Evans, R. S., Allen, T. L., Thomas, A., Haug, P. J., Welch, S. J., et al. (2009). A multivariate time series approach to modeling and forecasting demand in the emergency department. *Journal of Biomedical Informatics*, 42, 123-139.

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). Statistical and Machine Learning forecasting methods: Concerns and ways forward. *PLoS ONE*, 13(3), e0194889. <https://doi.org/10.1371/journal.pone.0194889>

Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, 31, 6638–6648.

Sánchez, M., Miró, O., Coll-Vinent, B., Bragulat, E., Espinosa, G., Gómez-Angelats, E., et al. (2003). Saturación del Servicio de Urgencias: factores asociados y cuantificación. *Medicina Clínica*, 121, 167-172.

Sauré, D., O’Ryan, M., Torres, J. P., Trigo, N., Diaz, G., Goic, M., Thraves, C., Pacheco, J., Aguilera, P., Caro, A., & Basso, L. J. (2025). Cost-savings and health impact of strategies for prevention of Respiratory Syncytial Virus with nirsevimab in Chile based on the integrated analysis of 2019–2023 national databases: A retrospective study. *Journal of Infection and Public Health*, 18, 102680. <https://doi.org/10.1016/j.jiph.2025.102680>

Sun, Y., Heng, B. H., Seow, Y. T., & Seow, E. (2009). Forecasting daily attendances at an emergency department to aid resource planning. *BMC Emergency Medicine*, 9(1). <https://doi.org/10.1186/1471-227X-9-1>

ANEXOS

El presente trabajo se desarrolla íntegramente en el cuerpo del informe. Las tablas de variables, intervenciones, hiperparámetros y resultados mensuales están incluidas en los capítulos correspondientes (Tablas 3.2 a 3.4, 4.1 y 5.1 a 5.7) y las figuras se integran en el análisis exploratorio y en la sección de resultados. A continuación se presenta un anexo de apoyo con información complementaria que no forma parte del hilo argumental principal pero que permite reproducir con mayor detalle las decisiones de implementación.

Anexo A. Configuración de hiperparámetros del modelo CatBoost

La configuración utilizada en la implementación final del modelo CatBoost corresponde a los siguientes valores: iteraciones = 6.000, tasa de aprendizaje = 0.02, profundidad máxima = 6, regularización L2 = 3.0, submuestreo = 0.7, función de pérdida = RMSE, semilla aleatoria = 42. El reentrenamiento se ejecuta una vez por mes bajo el esquema de walk-forward descrito en la Sección 1.5.4, con tiempo de cómputo promedio cercano a 12 segundos por iteración en CPU estándar. La elección de estos valores corresponde a un equilibrio entre desempeño predictivo, estabilidad entre ventanas mensuales y costo computacional; una optimización sistemática mediante grid search o calibración bayesiana queda planteada como línea de trabajo futuro en la Sección 6.2.

Anexo B. Arquitectura de las variantes LSTM

La variante recursiva multivariada utiliza una ventana de contexto de 30 días, 128 unidades ocultas, 2 capas LSTM apiladas, dropout de 0.2 entre capas, optimizador Adam con tasa de aprendizaje $1e-3$, tamaño de batch 256, 30 épocas y clipping de gradiente en 1.0. La variante direct multi-step utiliza ventana de 60 días, 128 unidades ocultas, 3 capas apiladas, dropout de 0.3, BatchNorm y Dropout a la salida, capa lineal final de dimensión 31, optimizador Adam con tasa $5e-4$ y weight decay $1e-5$, batch de 64, hasta 300 épocas con early stopping (patience 20), scheduler ReduceLROnPlateau y función de pérdida Huber. Ambas variantes se

entrenan mensualmente bajo el mismo esquema de walk-forward que OLS y CatBoost, y se normalizan los inputs con z-score ajustado sobre el conjunto de entrenamiento de cada mes.

Anexo C. Reproducibilidad

Los datos provienen del repositorio público del Departamento de Estadísticas e Información de Salud del Ministerio de Salud de Chile (DEIS), sección de atenciones de urgencia, glosa «Total Causas Sistema Respiratorio», filtrados para los establecimientos de la Región de Los Lagos. Toda la implementación se desarrolló en Python 3.11, utilizando las bibliotecas pandas y NumPy para procesamiento, statsmodels para la regresión OLS con interfaz de fórmulas patsy, CatBoost para el modelo de ensamble, PyTorch para las variantes LSTM, joblib para paralelización del walk-forward, y plotly para la generación de figuras. Las semillas aleatorias se fijan explícitamente en los scripts para garantizar reproducibilidad de los resultados reportados.

Anexo D. Índices de validez del agrupamiento (K-Means)

Para determinar el número de conglomerados de las trayectorias de error mensuales se evaluaron cuatro índices de validez interna sobre soluciones de K-Means con k entre 2 y 6, usando los 24 meses del período fuera de muestra y los horizontes $t+1$ a $t+28$. La silueta, el índice de Calinski-Harabasz y el de Davies-Bouldin alcanzan su óptimo en $k=2$; el índice de Dunn favorece marginalmente $k=4$. Dado el consenso mayoritario y la interpretabilidad de la partición, se adoptó $k=2$ (ver Tabla D.1).

k	Silueta (↑)	Calinski-Harabasz (↑)	Davies-Bouldin (↓)	Dunn (↑)
2	0.402	14.57	1.080	0.508
3	0.268	11.06	1.283	0.488
4	0.239	9.43	1.122	0.546
5	0.112	8.20	1.410	0.478
6	0.106	7.27	1.131	0.429

Tabla D.1 Índices de validez interna del agrupamiento K-Means para k entre 2 y 6.

Nota. ↑ mayor es mejor, ↓ menor es mejor. En negrita, el óptimo de cada índice.