



Universidad de Chile

Facultad de Economía y Negocios · Facultad de Ciencias Físicas y Matemáticas

Magíster en Analítica de Negocios

Datos públicos como catalizador de la industria:

el caso de los datos catastrales del Servicio de Impuestos Internos en
Chile

Borrador Final

Alumno: Cristian Luis Hernández Milla

RUT: 13.885.872-1

Profesor: Richard Weber

Fecha: Abril de 2026

Índice

Resumen Ejecutivo / Abstract	6
1 Introducción	7
1.1 El dato catastral del SII: un activo público inutilizable	8
1.2 Contribución de esta AFE	9
2 Planteamiento y Formulación del Problema	10
2.1 El mercado que opera a ciegas	10
2.2 Las tres barreras de acceso	11
2.2.1 Barrera 1: el archivo de ancho fijo	11
2.2.2 Barrera 2: la API sin capacidad de consulta masiva	12
2.2.3 Barrera 3: datos espaciales atrapados en imágenes	12
2.2.4 El costo económico de la inaccesibilidad	13
2.3 Por qué este problema no se ha resuelto antes	14
3 Hipótesis y Objetivos	15
3.1 Hipótesis	15
3.2 Objetivos	16
4 Marco Teórico y Revisión de la Literatura	17
4.1 Asimetría de información en mercados inmobiliarios	17
4.2 Datos abiertos gubernamentales: de la publicidad formal a la accesibilidad efectiva	18

4.3	El valor económico del dato catastral abierto	19
4.4	Fundamentos legales del scraping sobre datos públicos	20
5	Metodología	21
5.1	Ingeniería de datos masiva sobre fuentes públicas	21
5.1.1	El problema del bloqueo por volumen	21
5.1.2	Infraestructura de extracción distribuida	22
5.2	Servicios WMS y cartografía catastral	22
5.2.1	El estándar OGC Web Map Service	22
5.2.2	Las limitaciones del raster para el análisis espacial	23
5.2.3	El comportamiento escala-dependiente del WMS del SII	23
5.3	Vectorización de datos raster catastrales	24
5.3.1	Polygonización raster con GDAL	24
5.3.2	El índice de compactness para clasificación de geometrías	25
5.3.3	Georeferenciación y sistema de coordenadas	25
5.4	Integración espacial de fuentes heterogéneas	26
5.4.1	El problema del rol predial y el lote físico	26
5.4.2	El concepto de rol base	27
5.4.3	Validación y control de calidad a escala nacional	27
5.5	Refinamiento iterativo de cobertura geométrica	28
5.5.1	Diagnóstico del problema residual	28
5.5.2	Re-descarga focalizada con supercells	29
5.5.3	Spatial join multi-pasada con tolerancia geométrica	29
5.5.4	Consulta directa al WMS mediante <code>getFeatureInfo</code>	29
5.5.5	Estrategias de fallback para predios sin coordenada válida	30
6	Descripción del Enfoque de Solución	31
6.1	Arquitectura general del pipeline	31
6.2	Fase 0: Extracción masiva de datos prediales	32

6.2.1	Parseo del archivo TXT de ancho fijo	32
6.2.2	La API <code>getPredioNacional</code>	34
6.2.3	Infraestructura de 30 túneles WireGuard	35
6.2.4	Resultados de la Fase 0	36
6.3	Fase 1: Descarga cartográfica WMS	36
6.3.1	Clasificación de comunas: Tier A y Tier B	36
6.3.2	Generación de GeoTIFFs georeferenciados	36
6.3.3	Work stealing entre túneles	38
6.4	Fase 2: Vectorización de polígonos prediales	38
6.4.1	Polygonización mediante GDAL Band 1	38
6.4.2	Descubrimiento del comportamiento blank: umbral de escala en GeoServer	39
6.4.3	Filtrado por compactness	39
6.5	Fase 3: Pipeline de dos pasadas (z19 + z17)	41
6.6	Fases 4 a 6: Join espacial y consolidación	41
6.6.1	Spatial join CSV–GeoJSON	41
6.6.2	El concepto de <code>rol_base</code>	42
6.6.3	Consolidación final (Fase 6)	43
6.7	Fase 7: QA y validación nacional	43
6.8	Diccionario de datos del producto final	43
6.9	Catastral.cl: plataforma de distribución	44
6.9.1	Separación de dominios	45
6.9.2	Pipeline ETL de carga a PostgreSQL	45
6.9.3	API REST	46
6.9.4	Frontend y modelo de acceso	47
6.9.5	Cobertura y actualización semestral	48
7	Resultados, Casos de Uso e Impacto	49
7.1	El dataset resultante	49

7.1.1	Cobertura nacional	49
7.1.2	Variables disponibles	50
7.1.3	Comparación con alternativas comerciales	50
7.2	La plataforma Catastral.cl	51
7.2.1	Descripción y alcance	51
7.2.2	Base de datos y cobertura	52
7.2.3	Funcionalidades de la plataforma	53
7.2.4	Autenticación y pagos	54
7.2.5	Modelo de distribución: pago social	54
7.2.6	Rendimiento observado	55
7.3	Evaluación de precisión geométrica	56
7.3.1	Metodología	56
7.3.2	Resultados	56
7.3.3	Interpretación	57
7.4	Casos de uso para la industria inmobiliaria	58
7.4.1	Análisis de plusvalía y valor de suelo	58
7.4.2	Prospección de predios por destino y superficie	58
7.4.3	Identificación de suelo subutilizado	59
7.4.4	Due diligence con datos objetivos	59
7.4.5	Caso aplicado: inteligencia de localización para estaciones de servicio	60
7.5	Impacto público y democratización de la información	64
7.5.1	Acceso antes y después de Catastral.cl	64
7.5.2	Observaciones preliminares sobre la recepción	65
7.5.3	Escalabilidad del modelo a América Latina	66
8	Discusión, Limitaciones y Conclusiones	67
8.1	Limitaciones	67
8.1.1	Dependencia del renderizado WMS del SII	67

8.1.2	Predios con colores especiales	67
8.1.3	Ausencia de validación externa	68
8.1.4	Sesgo geográfico del 39,7% sin polígono	68
8.1.5	Precisión geométrica de 30 centímetros	69
8.2	Conclusiones	69
8.3	Trabajo futuro	70
8.3.1	Validación muestral con datos catastrales de referencia	70
8.3.2	Sat-Catastral: validación del uso de suelo mediante series de tiempo satelitales	71
8.3.3	Valori: impugnación de avalúos ante el SII mediante analítica catastral	71
8.3.4	Integración futura con el CBR	72

Resumen Ejecutivo

El Servicio de Impuestos Internos de Chile (SII) administra 9,5 millones de predios con avalúos fiscales, superficies, destinos y geometrías poligonales. Aunque formalmente públicos (Ley 20.285), estos datos resultan inutilizables para el análisis masivo debido a tres barreras técnicas: un archivo de ancho fijo sin delimitadores, una API unitaria con bloqueo de IPs y un servicio WMS que entrega geometrías solo como imágenes PNG. Esta tesis implementa un pipeline que supera las tres barreras mediante parseo de formatos heredados, extracción distribuida con 30 túneles WireGuard y vectorización raster con GDAL, produciendo un dataset georreferenciado con geometría vectorial (≈ 30 cm) para 5,67 millones de predios (60,3%) en las 343 comunas de Chile. Los resultados confirman que las barreras son estrictamente técnicas y superables, y que el costo de la inaccesibilidad supera los 2 millones de USD anuales (véase sección 2.2.4).

Palabras clave: datos abiertos, datos catastrales, web scraping, vectorización raster, ingeniería de datos geoespaciales, SII Chile.

Abstract

Chile's Internal Revenue Service (SII) maintains 9.5 million property records with fiscal appraisals, areas, zoning classifications, and cadastral geometries. Although formally public (Law 20,285), these data are unusable for large-scale analysis due to three technical barriers: a fixed-width file with no delimiters, an API accepting only single-property queries with IP blocking, and a WMS delivering geometries solely as PNG images. This thesis implements a pipeline that overcomes all three barriers through legacy format parsing, distributed extraction via 30 WireGuard tunnels, and raster vectorization using GDAL, producing a georeferenced dataset with vector geometry (≈ 30 cm) for 5.67 million properties (60.3%) across all 343 Chilean municipalities. Results confirm that access barriers are strictly technical and surmountable, and that the cost of inaccessibility exceeds USD 2 million annually (see Section 2.2.4).

Keywords: open data, cadastral data, web scraping, raster vectorization, geospatial data engineering, SII Chile.

Capítulo 1

Introducción

La información que el Estado recopila en el ejercicio de sus funciones (catastros fiscales, registros de propiedad y estadísticas tributarias) tiene un doble carácter: es un insumo administrativo para el gobierno y, al mismo tiempo, un bien económico de alto valor para el conjunto de la sociedad ([World Bank, 2021](#)). Cuando esa información fluye libremente, reduce la asimetría entre actores y habilita decisiones más eficientes en mercados de todo tipo: inmobiliario, crediticio, logístico, de inversión pública. Cuando permanece atrapada en formatos opacos o accesible solo a quienes tienen capacidad técnica para extraerla, produce el efecto contrario: concentra la capacidad analítica en los actores más grandes y deja al resto operando con información de segunda mano ([Open Knowledge Foundation, 2023](#)).

La evidencia internacional es consistente. El informe *Data for Better Lives* del Banco Mundial documenta que los países que han avanzado en apertura de datos públicos muestran ganancias de productividad en sectores que dependen de información territorial: construcción, logística, planificación urbana y servicios financieros ([World Bank, 2021](#)). La Open Knowledge Foundation estima que el valor generado por la reutilización de datos públicos en economías desarrolladas equivale a varios puntos porcentuales del PIB ([Open Knowledge Foundation, 2023](#)). En América Latina, CEPAL advierte que la ausencia de políticas activas de apertura de datos perpetúa asimetrías que frenan la innovación y concentran el poder de mercado en los actores con mayor acceso a información ([CEPAL, 2022](#); [Janssen et al., 2012](#)).

El mecanismo económico es directo. Cuando el dato es accesible sin restricciones técnicas, los actores de menor tamaño (PyMEs, investigadores, municipios y emprendedores) pueden competir en igualdad analítica con los grandes conglomerados. Esta nivelación tiene efectos sistémicos: mercados con mayor simetría de información

son más eficientes, más transparentes y más resistentes a la corrupción ([Broxterman and Zhou, 2023](#)). Por el contrario, cuando el acceso al dato requiere capacidades técnicas sofisticadas o contratos con proveedores privados, se reproduce una forma de exclusión que no es neutral: beneficia estructuralmente a quienes ya tienen más.

Chile tiene legislación de acceso a la información pública desde 2008. La Ley 20.285 de Transparencia ([Biblioteca del Congreso Nacional de Chile, 2008](#)) consagra el derecho de cualquier persona a solicitar y recibir información de los órganos del Estado. Los datos catastrales del SII son información pública por naturaleza: no contienen datos personales protegidos, sino registros administrativos del patrimonio inmobiliario del país. Y sin embargo, la publicación formal no equivale a acceso real cuando los datos se entregan en formatos que requieren conocimientos de programación para ser leídos, cuando la API no acepta consultas masivas, y cuando las geometrías del territorio están encerradas en imágenes PNG ([Cetl et al., 2023](#)).

1.1 El dato catastral del SII: un activo público inutilizable

El Servicio de Impuestos Internos de Chile (SII) administra el catastro fiscal de todos los predios urbanos y rurales del país: aproximadamente 9,5 millones de registros que incluyen avalúos fiscales actualizados semestralmente, valor comercial de suelo por metro cuadrado, superficie de terreno y construcción, destino predial, coordenadas geográficas y la geometría vectorial de cada lote. Es, en términos de cobertura y actualización, uno de los conjuntos de datos territoriales más completos de América Latina.

Este dato es formalmente público. La Ley 20.285 de Acceso a la Información ([Biblioteca del Congreso Nacional de Chile, 2008](#)) garantiza el derecho a consultarlo. El SII lo publica en su sitio web. Y sin embargo, en la práctica, es inutilizable para el análisis masivo.

El problema no es legal. Es técnico. Los datos se publican en tres formatos que, de manera individual y combinada, impiden su uso analítico directo: un archivo de texto plano de ancho fijo sin cabeceras ni delimitadores (codificación `latin-1`, 3 GB), cuya estructura es característica de los sistemas de procesamiento por lotes de entornos mainframe; una API que solo acepta consultas predio a predio con bloqueo automático de IPs que consultan en volumen; y un servicio de mapas que entrega las geometrías prediales únicamente como imágenes PNG, sin formato vecto-

rial descargable. El resultado es un dato visualmente accesible pero inutilizable para el análisis automatizado: cualquiera puede *ver* un predio en el visor del SII; nadie puede *analizar* todos los predios de Chile sin superar barreras técnicas significativas (Janssen et al., 2012; Open Knowledge Foundation, 2023).

1.2 Contribución de esta AFE

Esta AFE aborda el problema en dos dimensiones complementarias. Por un lado, un desafío técnico de ingeniería de datos geospaciales que requiere métodos avanzados de web crawling, parseo de formatos heredados y vectorización de cartografía raster para construir el dataset nacional. Por otro lado, un desafío de accesibilidad que demanda el desarrollo de una interfaz que permita a actores con distintos niveles de conocimiento técnico consultar y descargar los datos sin escribir una línea de código.

La solución concreta es doble: un pipeline de extracción y procesamiento que supera las tres barreras técnicas del SII, produciendo un dataset georreferenciado con geometría vectorial para 5,67 millones de predios (60,3% del total nacional) en las 343 comunas de Chile; y la plataforma **Catastral.cl**, que distribuye ese dataset públicamente a través de una interfaz web sin requerir conocimientos de programación. Ambos productos son originales y no existían previamente en el ecosistema de datos públicos de Chile.

El resto del documento se organiza como sigue: el Capítulo 2 describe el problema y sus tres barreras con detalle; el Capítulo 3 formula la hipótesis y los objetivos; el Capítulo 4 desarrolla el marco teórico; el Capítulo 5 presenta la metodología; el Capítulo 6 detalla el desarrollo e implementación; el Capítulo 7 reporta los resultados y casos de uso; y el Capítulo 8 cierra con la discusión, limitaciones y trabajo futuro.

Capítulo 2

Planteamiento y Formulación del Problema

2.1 El mercado que opera a ciegas

La inaccesibilidad del dato catastral genera asimetría de información en múltiples mercados. El más expuesto es el inmobiliario.

Esta inaccesibilidad ha generado un mercado secundario de intermediarios que comercializan el dato catastral sin agregar inteligencia significativa. Diversos operadores privados y corredores de datos territoriales basan su modelo de negocio en superar las barreras técnicas de extracción del SII y revender la información estructurada a precios que, según cotizaciones observadas durante 2024–2025, oscilan entre los 2.000 y los 6.000 USD por dataset comunal (el costo agregado de este mercado se analiza en la sección [2.2.4](#)). El valor que ofrecen no radica en análisis avanzados ni en inteligencia territorial, sino en el simple hecho de haber logrado acceder y estructurar un dato que es formalmente público.

El mercado inmobiliario comercial en Chile (oficinas, bodegas, locales, industria) opera sobre transacciones de alto valor donde cada decisión de inversión puede involucrar decenas de millones de dólares. En mercados maduros como Estados Unidos o el Reino Unido, estas decisiones se apoyan en plataformas de inteligencia territorial que integran datos catastrales, transacciones registradas, permisos de edificación y variables socioeconómicas en tiempo real ([Broxterman and Zhou, 2023](#)). En Chile, ese ecosistema no existe para la mayoría de los actores.

Esta asimetría tiene dos efectos medibles. Primero, concentra la capacidad analítica

en los actores con departamentos técnicos propios: grandes fondos de inversión, consultoras multinacionales, o el Estado mismo. El resto del mercado (PyMEs inmobiliarias, desarrolladores regionales, periodistas de datos, investigadores universitarios y municipios) opera con información de segunda mano o sin información ([Janssen et al., 2012](#)). Segundo, encarece la toma de decisiones: cuando los datos no están disponibles en forma estructurada, las decisiones se fundamentan en la experiencia tácita del consultor individual, lo que introduce sesgos no auditables y eleva el costo de due diligence ([Redman, 2008](#)).

Un ejemplo ilustrativo es el de la prospección de ubicaciones para estaciones de servicio. La identificación de un sitio óptimo requiere cruzar superficie de terreno disponible, uso de suelo permitido, flujo vehicular y contexto de precios en la zona. Con el dato catastral accesible, este análisis puede automatizarse completamente sobre los 9,5 millones de predios del país en 30 minutos, como demuestra la plataforma **combustible.tremen.tech** desarrollada como caso de uso aplicado de esta tesis. Sin ese dato, el proceso requiere scouts en terreno durante 6 a 12 semanas por región.

La brecha entre disponibilidad formal y acceso efectivo tiene consecuencias documentadas por actores del ecosistema. Profesionales del sector geoespacial y de planificación urbana en Chile han descrito sus experiencias al intentar acceder a los datos catastrales del SII: emprendedores de tecnología inmobiliaria reportan la imposibilidad de construir geocoders prediales porque el SII no entrega la información fuente y sus servicios WMS no son estables; investigadores en planificación urbana señalan haber recurrido al Consejo de la Transparencia para obtener los polígonos catastrales, sin resultado; y consultores geoespaciales constatan que la información existe, pero su formato de distribución la hace inutilizable en flujos de trabajo SIG.

2.2 Las tres barreras de acceso

El análisis de los mecanismos por los cuales el dato catastral permanece inaccesible permite identificar tres barreras estructurales, de naturaleza estrictamente técnica. El dato no está protegido por ley; está bloqueado por su forma de distribución.

2.2.1 Barrera 1: el archivo de ancho fijo

El SII publica semestralmente el **Rol Semestral de Contribuciones de Bienes Raíces**, un archivo con el registro fiscal de todos los predios de Chile. El archivo es técnicamente accesible: cualquier contribuyente con RUT y clave del

SII puede descargarlo desde la sección “Detalle Catastral y Rol de Cobro” del portal institucional (https://www4.sii.cl/sismunInternet6/?caller=DETALLE_CAT_Y_ROL_COBRO). La barrera no es legal ni de acceso, sino de formato.

El archivo, denominado `BRTMPNACROL_NAC_2025_2` en su versión más reciente, es un texto plano sin cabeceras, con campos de longitud fija definidos por posición de carácter ([Servicio de Impuestos Internos, 2025](#)). Para extraer el avalúo total de un predio se debe leer exactamente desde la posición 82 hasta la 96 de cada línea. No existe delimitador de columnas, no existe cabecera descriptiva, y la codificación es `latin-1`. Este formato, diseñado para sistemas mainframe de los años ochenta, no puede ser abierto con ninguna herramienta de análisis convencional (Excel, Google Sheets, Power BI) sin un proceso previo de parseo específico. El ciudadano que descarga el archivo de 3 GB no puede leer su contenido sin escribir código ([Redman, 2008](#)).

2.2.2 Barrera 2: la API sin capacidad de consulta masiva

El SII expone la API `getPredioNacional` que devuelve los datos completos de un predio dado su código de comuna, manzana y número de predio: coordenadas, avalúos, destino, superficie construida, área homogénea y valor comercial por metro cuadrado. Esta API está diseñada para consultas unitarias. No existe un endpoint que permita obtener todos los predios de una comuna ni aplicar filtros sobre el catastro completo. Para construir el dataset nacional completo, con 9,5 millones de predios, sería necesario realizar 9,5 millones de llamadas individuales. Adicionalmente, el servidor detecta y bloquea IPs que realizan consultas en volumen, haciendo prácticamente imposible la extracción masiva desde una conexión convencional.

2.2.3 Barrera 3: datos espaciales atrapados en imágenes

El visor cartográfico del SII (<https://www4.sii.cl/mapasui>) muestra los polígonos de cada predio en un mapa interactivo. Esta geometría es extraordinariamente valiosa: permite calcular áreas reales, identificar colindancias, construir grillas de valor de suelo y ejecutar consultas espaciales. Sin embargo, el SII solo expone esta geometría a través de un servicio WMS que entrega imágenes PNG renderizadas ([Open Geospatial Consortium, 2006](#)). El servicio no ofrece los polígonos como datos vectoriales descargables. El SII declara en su documentación que no cuenta con la información de los polígonos en formato vectorial, afirmación que contradice lo que se ve en el visor, donde los predios aparecen claramente delimitados como polígonos

independientes.

2.2.4 El costo económico de la inaccesibilidad

La barrera técnica que impide el acceso al dato catastral tiene un costo económico estimable. En el mercado chileno, los intermediarios que comercializan datasets catastrales estructurados cobran entre 2.000 y 6.000 USD por un dataset comunal completo (rango observado en cotizaciones de proveedores privados durante 2024–2025). Considerando que existen 343 comunas en Chile y que múltiples actores del mercado inmobiliario, financiero, académico y municipal requieren estos datos, el costo agregado de la inaccesibilidad se traduce en transferencias significativas desde los usuarios hacia intermediarios cuyo principal valor agregado es superar las barreras técnicas de formato.

Para dimensionar este costo se propone una estimación de orden de magnitud basada en tres supuestos explícitos: (i) el número de actores que adquieren datos catastrales anualmente, (ii) el precio promedio por dataset comunal, y (iii) el número promedio de comunas adquiridas por actor. La Tabla 2.1 presenta un análisis de sensibilidad que varía estos parámetros dentro de rangos plausibles.

Tabla 2.1: Análisis de sensibilidad del costo anual de la inaccesibilidad catastral

Escenario	Actores	Precio/comuna	Comunas/actor	Costo anual (USD)
Conservador	200	USD 2.000	1	400.000
Base	500	USD 4.000	1	2.000.000
Moderado	500	USD 4.000	3	6.000.000
Alto	800	USD 5.000	3	12.000.000

El escenario base (500 actores, USD 4.000 por comuna, 1 comuna por actor) arroja un costo agregado de aproximadamente 2 millones de USD anuales (véase sección 2.2.4). El supuesto de 500 actores se basa en el número de inmobiliarias, consultoras ambientales, municipios con presupuesto para datos y centros de investigación que operan en el mercado inmobiliario chileno. El precio promedio de USD 4.000 corresponde al punto medio del rango observado. Cabe señalar que esta estimación no incluye los costos indirectos de decisiones subóptimas tomadas por actores que operan sin información territorial adecuada (costos que la teoría de la asimetría de información predice como significativos (Akerlof, 1970; Stiglitz, 2000)) ni el valor de los nuevos modelos de negocio que la disponibilidad del dato habilitaría. A nivel internacional, el European Data Portal estimó en 2020 que el mercado europeo de datos abiertos alcanzó los 184 mil millones de euros, lo que sugiere que el valor potencial de liberar datos catastrales excede el ahorro directo en adquisición (European Data Portal,

2020).

2.3 Por qué este problema no se ha resuelto antes

La persistencia del problema se explica por la confluencia de tres desafíos técnicos que deben resolverse de forma simultánea: el parseo de formatos heredados de ancho fijo, la extracción masiva distribuida frente a un servidor con detección de bots, y la vectorización de cartografía raster. Cada uno de estos problemas tiene soluciones conocidas en la literatura; sin embargo, su combinación sobre un dataset de 9,5 millones de registros presenta una complejidad operativa que no ha sido abordada previamente en el contexto chileno.

Adicionalmente, una vez construido el dataset, su distribución genera un segundo problema: los formatos analíticos (GeoJSON, GeoPackage, Parquet) son útiles para técnicos pero inaccesibles para la mayoría de los actores que podrían beneficiarse de los datos. La sola existencia del dataset no resuelve el problema de acceso si no existe una interfaz que lo haga consultable sin conocimientos de programación.

Capítulo 3

Hipótesis y Objetivos

3.1 Hipótesis

El análisis presentado en los capítulos anteriores conduce a una hipótesis central que orienta este trabajo:

Las barreras que impiden el acceso masivo a los datos catastrales del SII son de naturaleza exclusivamente técnica y de formato, sin componente legal ni político, y son superables con métodos estándar de ingeniería de datos disponibles públicamente.

Esta formulación es falseable bajo al menos tres condiciones: (i) que el SII impusiera restricciones legales explícitas al acceso automatizado, lo que convertiría la barrera en legal y no técnica; (ii) que las barreras técnicas requirieran acceso privilegiado no disponible públicamente (por ejemplo, credenciales internas o servidores no expuestos a internet), lo que las haría insuperables con métodos estándar; o (iii) que los métodos de ingeniería de datos disponibles fueran insuficientes para producir un dataset con cobertura y precisión aceptables para análisis territorial.

La hipótesis tiene una implicancia directa: si se confirma, la brecha de información que hoy favorece a los actores con mayor capacidad técnica no es un resultado inevitable del mercado, sino una consecuencia de la ausencia de herramientas apropiadas ([World Bank, 2021](#); [Stiglitz, 2000](#)). La teoría de la asimetría de información ([Akerlof, 1970](#)) predice que la reducción de esta brecha debería mejorar la eficiencia del mercado inmobiliario chileno.

3.2 Objetivos

Objetivo general: Demostrar que la apertura efectiva de datos públicos técnicamente opacos genera un impacto económico concreto y medible: reduce la asimetría de información en mercados que dependen de inteligencia territorial, nivela el acceso analítico entre actores de distinto tamaño y habilita nuevos emprendimientos y modelos de análisis que hoy no existen por ausencia del dato. Para ello, esta AFE toma el caso del catastro predial del SII (formalmente público pero prácticamente inaccesible) y construye la infraestructura técnica y la plataforma de distribución necesarias para que cualquier actor, independientemente de su capacidad técnica o presupuesto, pueda consultar, analizar y descargar la información territorial de los 9,5 millones de predios de Chile.

Los **objetivos específicos** son:

1. Desarrollar un pipeline de ingeniería de datos que supere las tres barreras de acceso identificadas: parseo del archivo de ancho fijo, extracción masiva distribuida vía API con múltiples identidades de red, y vectorización de la cartografía raster del SII.
2. Construir un dataset predial nacional con cobertura de las 343 comunas de Chile, integrando atributos tabulares (avalúos, superficies, destinos prediales, series históricas 2018–2025) y geometría vectorial (≈ 30 cm de precisión) para cada uno de los 9,5 millones de predios.
3. Diseñar e implementar la plataforma **Catastral.cl**, que materializa el objetivo de acceso: búsqueda y consulta gratuita de cualquier predio del país, visualización de la evolución histórica de avalúos (16 semestres), y descarga de datos enriquecidos en formatos analíticos (CSV, GeoJSON, GeoPackage) para las 343 comunas disponibles.

Capítulo 4

Marco Teórico y Revisión de la Literatura

El concepto de *open data* o datos abiertos designa conjuntos de datos que cualquier persona puede usar, modificar y redistribuir libremente, sin restricciones de propiedad intelectual, patentes o mecanismos de control adicionales ([Open Knowledge Foundation, 2023](#)). En el ámbito gubernamental, los datos abiertos constituyen un mecanismo de transparencia y rendición de cuentas: al poner a disposición del público información sobre el territorio, la economía y los servicios del Estado, se habilita la fiscalización ciudadana y se reduce la asimetría de información entre el gobierno y los administrados ([Janssen et al., 2012](#); [Zuiderwijk and Janssen, 2014](#)).

Sin embargo, la experiencia internacional muestra una brecha persistente entre el dato *técnicamente público* y el dato *prácticamente accesible*. Un dato es técnicamente público cuando no existe restricción legal para acceder a él; es prácticamente accesible cuando puede ser efectivamente utilizado sin barreras técnicas significativas ([Attard et al., 2015](#)). Esta distinción es central para entender el problema que este trabajo aborda.

4.1 Asimetría de información en mercados inmobiliarios

El problema de la inaccesibilidad de datos catastrales se enmarca en la teoría económica de la asimetría de información. [Akerlof \(1970\)](#) demostró que cuando los participantes de un mercado disponen de información desigual sobre la calidad

de los bienes transados, se producen ineficiencias que pueden derivar en la selección adversa y el colapso del mercado. [Stiglitz \(2000\)](#) extendió este análisis al mostrar que las asimetrías informacionales son ubicuas en mercados de activos y que su reducción genera ganancias de eficiencia medibles.

El mercado inmobiliario es particularmente susceptible a estas asimetrías. [DiPasquale and Wheaton \(1996\)](#) establecieron que la heterogeneidad de los activos inmobiliarios, combinada con la naturaleza localizada de la información catastral, produce *search costs* elevados: los compradores y vendedores incurren en costos significativos para obtener información sobre precios, características y ubicación de las propiedades disponibles. [Broxterman and Zhou \(2023\)](#) documentaron que estas fricciones informacionales persisten incluso en mercados con alta penetración tecnológica, y que la disponibilidad de datos de valor de suelo a escala granular permite a los actores ajustar precios, identificar tendencias de densificación y reducir el riesgo de inversión mediante análisis comparativos objetivos.

En este contexto, los registros catastrales públicos funcionan como un mecanismo institucional de reducción de asimetrías: al proveer información verificable sobre la propiedad, el valor fiscal y las características de cada predio, reducen los costos de transacción y mejoran la eficiencia del mercado ([Deininger and Feder, 2009](#); [Williamson and Kerekes, 2011](#)). Pero este mecanismo solo opera cuando los datos son efectivamente accesibles. Cuando el formato de publicación impone barreras técnicas que limitan el acceso a un grupo reducido de actores, la asimetría no se elimina sino que se desplaza: ya no es entre gobierno y ciudadano, sino entre quienes pueden procesar los datos y quienes no.

4.2 Datos abiertos gubernamentales: de la publicidad formal a la accesibilidad efectiva

En Chile, la Ley de Transparencia ([Biblioteca del Congreso Nacional de Chile, 2008](#)) garantiza el derecho de acceso a la información de los organismos del Estado. El SII, en cumplimiento de esta normativa, publica los datos catastrales en su sitio web. Formalmente, los datos son públicos. Pero el formato en que se publican (un archivo de texto plano de ancho fijo sin cabeceras, de 3 GB de tamaño y con codificación `latin-1`) hace que su uso efectivo requiera conocimientos de programación que solo posee una fracción mínima de la población.

La literatura sobre datos abiertos gubernamentales ha documentado extensamente

esta brecha entre publicación y accesibilidad. [Zuiderwijk and Janssen \(2014\)](#) propusieron un marco de evaluación de políticas de datos abiertos que distingue entre la disponibilidad formal del dato y su usabilidad efectiva, identificando que muchos gobiernos satisfacen el requisito legal de publicación sin garantizar que los datos sean procesables por máquinas o comprensibles por usuarios no técnicos. [Attard et al. \(2015\)](#), en una revisión sistemática de 55 iniciativas de datos abiertos gubernamentales, encontraron que las barreras técnicas de formato son tan restrictivas como las barreras legales para el acceso efectivo.

Según [CEPAL \(2022\)](#), la brecha de habilidades digitales avanzadas en América Latina agrava esta situación: solo una fracción pequeña de la población posee las competencias necesarias para procesar formatos de baja usabilidad. En la práctica, la publicación formal no equivale a accesibilidad real ([Janssen et al., 2012](#)).

4.3 El valor económico del dato catastral abierto

Cuando los datos catastrales son genuinamente accesibles, el impacto económico es significativo. [World Bank \(2021\)](#) estima que la apertura efectiva de datos gubernamentales puede generar valor equivalente al 1–3% del PIB en economías desarrolladas, principalmente a través de la reducción de costos de transacción en mercados de activos, la mejora en la asignación de recursos y la habilitación de nuevos modelos de negocio. A escala global, [McKinsey Global Institute \(2013\)](#) estimó el potencial de los datos abiertos en 3 a 5 billones de USD anuales. [Deininger and Feder \(2009\)](#) demostraron que la calidad de los registros catastrales tiene efectos directos sobre la inversión, el acceso al crédito y la recaudación fiscal, especialmente en economías en desarrollo donde la informalidad de la tenencia de tierra es alta.

La experiencia internacional ofrece ejemplos concretos. En el Reino Unido, la apertura del registro catastral (*Land Registry*) permitió el surgimiento de plataformas de inteligencia inmobiliaria que generan cientos de millones de libras anuales en valor económico ([World Bank, 2021](#)). En la Unión Europea, el European Data Portal estimó que el mercado de datos abiertos alcanzó los 184 mil millones de euros en 2020 ([European Data Portal, 2020](#)). En América Latina, Colombia liberó su catastro multipropósito en 2020, lo que permitió a municipios rurales acceder por primera vez a información territorial estructurada para la planificación de servicios públicos ([CEPAL, 2022](#)).

4.4 Fundamentos legales del scraping sobre datos públicos

La construcción del dataset que esta AFE produce requiere extracción automatizada de datos desde los servidores del SII. Este método, conocido como *web scraping* o *API harvesting*, descansa sobre un marco legal que es necesario precisar.

En Chile, no existe legislación específica que prohíba el acceso automatizado a sitios web de organismos públicos, siempre que dicho acceso no genere daño al servicio ni implique apropiación de datos protegidos por derechos de autor. Los datos catastrales del SII son de dominio público por mandato de la Ley 20.285 ([Biblioteca del Congreso Nacional de Chile, 2008](#)). A nivel internacional, el caso *hiQ Labs v. LinkedIn* (2021) en la Corte Suprema de Estados Unidos sentó un precedente relevante al confirmar que el scraping de datos públicamente accesibles no constituye necesariamente una violación del *Computer Fraud and Abuse Act*: el tribunal razonó que si los datos son accesibles sin autenticación para cualquier usuario, la extracción automatizada de los mismos no puede equipararse a un acceso no autorizado. En la Unión Europea, la Directiva 2019/1024 sobre datos abiertos (*Open Data Directive*) va más lejos: establece explícitamente que los datos gubernamentales *deben* ser accesibles en formatos legibles por máquina, lo que convierte la extracción automatizada no solo en legítima sino en el mecanismo previsto por el legislador para el uso efectivo de los datos públicos ([Attard et al., 2015](#)).

El principio rector que guía la práctica responsable de scraping sobre servicios públicos es la no interferencia: el proceso de extracción debe diseñarse para consumir la menor cantidad posible de recursos del servidor, respetando las limitaciones de tasa de consultas (*rate limits*) y distribuyendo la carga a lo largo del tiempo. Esta AFE sigue este principio mediante la distribución de consultas entre 30 túneles WireGuard con rotación dinámica, lo que mantiene la tasa de consultas por IP dentro de umbrales que no afectan la disponibilidad del servicio ([Cetl et al., 2023](#)).

Capítulo 5

Metodología

El presente capítulo describe la metodología empleada para abordar el problema descrito en el Capítulo 1. Se organiza en seis secciones: los principios de ingeniería de datos masiva aplicada a fuentes públicas, el estándar WMS y las limitaciones de la cartografía raster para el análisis espacial, los algoritmos de vectorización de imágenes catastrales, los métodos de integración espacial entre fuentes heterogéneas, los criterios de validación del dataset resultante, y la metodología de refinamiento iterativo para maximizar la cobertura geométrica en predios urbanos.

5.1 Ingeniería de datos masiva sobre fuentes públicas

La extracción sistemática de datos desde fuentes públicas en internet es una disciplina consolidada en la ciencia de datos, conocida genéricamente como *web scraping* o, cuando se trata de APIs, como *API harvesting*. Los fundamentos legales que habilitan esta práctica sobre fuentes gubernamentales se discuten en el Capítulo 4; esta sección describe los aspectos técnicos de su implementación.

5.1.1 El problema del bloqueo por volumen

Los servidores web modernos implementan mecanismos de detección de comportamiento automatizado, principalmente mediante el análisis de la frecuencia y el origen de las solicitudes HTTP. Cuando un único cliente realiza miles de consultas en un período corto, el servidor puede interpretar este comportamiento como un

ataque de denegación de servicio y bloquear la dirección IP del solicitante ([Donenfeld, 2017](#)).

Para la extracción a escala nacional de datos prediales, con 9,5 millones de consultas necesarias, este mecanismo constituye una barrera técnica determinante. La solución implementada en este trabajo es la distribución de la carga entre múltiples identidades de red mediante el uso de túneles VPN con rotación dinámica, lo que permite mantener una tasa de consultas por IP dentro de umbrales aceptables mientras se maximiza el throughput agregado del sistema.

5.1.2 Infraestructura de extracción distribuida

El concepto de *network namespace* en sistemas Linux permite crear entornos de red completamente aislados dentro de un mismo servidor físico ([Linux man-pages project, 2024](#)). Cada namespace tiene su propia interfaz de red, tabla de rutas y dirección IP, lo que permite ejecutar múltiples procesos de scraping en paralelo, cada uno saliendo por una IP distinta hacia el servidor objetivo.

La combinación de namespaces con túneles WireGuard ([Donenfeld, 2017](#)) (protocolo VPN moderno de alta performance) permite construir una infraestructura de extracción distribuida donde cada túnel actúa como un cliente independiente desde la perspectiva del servidor del SII. La detección de bloqueo y la rotación automática de relays permite recuperar un túnel bloqueado en segundos sin interrumpir los demás procesos en ejecución.

5.2 Servicios WMS y cartografía catastral

5.2.1 El estándar OGC Web Map Service

El *Web Map Service* (WMS) es un estándar del Open Geospatial Consortium (OGC) que define una interfaz HTTP para solicitar imágenes de mapas georreferenciadas desde un servidor cartográfico ([Open Geospatial Consortium, 2006](#)). Una solicitud WMS especifica una capa de datos, un sistema de referencia de coordenadas (CRS), un bounding box geográfico y unas dimensiones en píxeles; el servidor responde con una imagen renderizada que representa los datos de la capa en esa región y resolución.

El SII implementa un servidor WMS basado en GeoServer ([GeoServer Project Steer-](#)

[ing Committee, 2024](#)) sobre la URL:

`https://www4.sii.cl/mapasui/services/ui/wmsProxyService/call`

Las capas catastrales siguen la convención de nombres `sii:BR_CART_{NOMBRE_COMUNA}_WMS` con el estilo `PREDIOS_WMS_V0`. El servicio entrega imágenes PNG de 256×256 píxeles donde cada tipo de elemento del mapa tiene un color específico y consistente.

5.2.2 Las limitaciones del raster para el análisis espacial

La diferencia fundamental entre un dato *raster* y un dato *vectorial* es la naturaleza de la representación geométrica. Un raster es una grilla regular de píxeles, donde cada píxel almacena un valor (color, temperatura, elevación). Un dato vectorial es una colección de geometrías (puntos, líneas, polígonos) definidas por coordenadas exactas, con atributos asociados a cada geometría ([GDAL/OGR contributors, 2024](#)).

Para el análisis espacial catastral, la representación vectorial es indispensable. Solo con polígonos vectoriales es posible calcular áreas exactas, identificar colindancias, realizar intersecciones geométricas, construir grillas de valor de suelo y ejecutar consultas espaciales del tipo “todos los predios con destino comercial dentro de un radio de 500 metros de este punto”. El raster, al ser una imagen, no permite ninguna de estas operaciones de forma directa ([Gillies et al., 2024b](#)).

5.2.3 El comportamiento escala-dependiente del WMS del SII

Durante el desarrollo de este trabajo se descubrió empíricamente un comportamiento no documentado del servidor WMS del SII: la representación de los bordes internos entre predios depende del tamaño del bounding box solicitado. Cuando el BBOX es pequeño (equivalente a tiles de zoom 19, aproximadamente 76 metros por lado), en ciertas zonas el servidor no renderiza las líneas de borde que separan predios contiguos, entregando bloques de color uniforme sin subdivisiones internas. Cuando el mismo territorio se solicita con un BBOX mayor (equivalente a zoom 17 o menor), el servidor sí renderiza todos los bordes.

Este comportamiento es consistente con la configuración de umbrales de escala (*scale denominators*) en GeoServer ([GeoServer Project Steering Committee, 2024](#)), que permiten al administrador definir a partir de qué nivel de zoom se renderizan capas

o estilos específicos. En la práctica, este comportamiento genera polígonos anormalmente grandes en la vectorización, que deben ser detectados y corregidos mediante un proceso de re-consulta multi-resolución.

5.3 Vectorización de datos raster catastrales

5.3.1 Polygonización raster con GDAL

La *polygonización raster* es el proceso de convertir una imagen raster en un conjunto de polígonos vectoriales, donde cada polígono representa una región contigua de píxeles con el mismo valor. GDAL ([GDAL/OGR contributors, 2024](#)) implementa este algoritmo en la herramienta `gdal_polygonize`, que es también el motor interno del comando equivalente en QGIS.

El algoritmo implementa *region labeling* con 4-conectividad: recorre la imagen píxel a píxel y agrupa en un mismo polígono todos los píxeles conectados horizontal o verticalmente que tienen el mismo valor digital (DN, *Digital Number*). Los píxeles con valores distintos actúan como separadores naturales entre regiones, generando fronteras entre polígonos.

En el mapa catastral del SII, el canal rojo (banda 1) tiene valor exactamente igual a 182 en el interior de todos los predios. Los bordes entre predios son líneas de 1 a 2 píxeles de ancho con valores inferiores a 182. Al polygonizar la banda 1, cada predio se convierte en un polígono independiente, separado de sus vecinos por las líneas de borde.

Formalmente, dado un raster R de dimensiones $W \times H$ píxeles, donde $R_{i,j}$ denota el valor del píxel en la columna i y fila j , la polygonización produce un conjunto de polígonos $\{P_k\}$ tal que cada polígono P_k cubre la región conexa maximal de píxeles con el mismo valor:

$$P_k = \{(i, j) \mid R_{i,j} = v_k \text{ y } (i, j) \text{ es 4-conexo con todos los demás píxeles de } P_k\} \quad (5.1)$$

5.3.2 El índice de compactness para clasificación de geometrías

Los polígonos extraídos de la polygonización contienen agujeros internos (*holes*) causados por el texto sobreimpreso en el mapa: números de rol predial, nombres de calles y otros elementos gráficos tienen colores distintos al relleno del predio y generan discontinuidades en la región 4-conectada.

Es necesario distinguir entre dos tipos de holes:

- **Holes textuales:** causados por números y letras sobreimpresos. Son formas relativamente compactas y de área pequeña.
- **Holes reales:** corresponden a pasajes peatonales, patios interiores o espacios públicos encerrados dentro del contorno de un predio. Son formas alargadas o de área considerable.

Para distinguirlos se utiliza el índice de compactness, también conocido como cociente isoperimétrico (Gillies et al., 2024b):

$$C = \frac{4\pi \cdot A}{P^2} \quad (5.2)$$

donde A es el área del hole y P es su perímetro. Este índice vale 1 para un círculo perfecto, aproximadamente 0,785 para un cuadrado, y valores cercanos a 0 para formas muy alargadas. Los holes textuales, al ser caracteres tipográficos, tienen compactness típicamente superior a 0,25. Los pasajes interiores, al ser formas estrechas y alargadas, tienen compactness típicamente inferior a 0,25.

Se aplica la siguiente regla de clasificación:

$$\text{tipo}(h) = \begin{cases} \text{textual (rellenar)} & \text{si } C(h) > 0,25 \text{ y } A(h) < 100 \text{ m}^2 \\ \text{real (conservar)} & \text{en caso contrario} \end{cases} \quad (5.3)$$

5.3.3 Georeferenciación y sistema de coordenadas

Los tiles WMS del SII se entregan en el sistema de proyección Web Mercator (EPSG:3857). La georeferenciación del GeoTIFF ensamblado se calcula a partir de los bounds exactos de la grilla de tiles descargados, utilizando la fórmula estándar del sistema de tiles XYZ (Open Geospatial Consortium, 2006):

$$\text{pixel_size} = \frac{2\pi R_{\oplus}}{2^z \cdot 256} \quad (5.4)$$

donde $R_{\oplus} = 6.378.137$ m es el semieje mayor del elipsoide WGS84 en proyección Mercator esférica y z es el nivel de zoom. A zoom 19:

$$\text{pixel_size}_{z=19} = \frac{2\pi \times 6.378.137}{2^{19} \times 256} \approx 0,2986 \text{ m/píxel} \quad (5.5)$$

Esta resolución de aproximadamente 30 cm por píxel garantiza que los bordes entre predios (de 1 a 2 píxeles de ancho) sean suficientemente visibles para la poligonización, y que la precisión geométrica resultante sea adecuada para análisis catastrales a escala de predio.

5.4 Integración espacial de fuentes heterogéneas

El producto final de este trabajo requiere combinar dos fuentes de naturaleza distinta: los datos tabulares extraídos de la API del SII (atributos de cada predio: avalúo, destino, superficie, coordenadas) y los polígonos vectoriales extraídos del WMS (geometría de cada lote). La integración de estas fuentes es un problema de *spatial join* con particularidades importantes (Gillies et al., 2024b).

5.4.1 El problema del rol predial y el lote físico

En el catastro chileno, la relación entre predios registrales y lotes físicos no es uno a uno. Existen dos configuraciones posibles:

Lote simple: un terreno físico corresponde a un único predio registral. El predio tiene coordenadas únicas y su polígono en el mapa corresponde directamente a su rol.

Edificio multi-unidad: un terreno físico alberga múltiples predios registrales (departamentos, oficinas, bodegas, estacionamientos), todos con la misma coordenada geográfica. El polígono en el mapa corresponde al terreno completo, no a cada unidad.

Esta distinción es fundamental para el proceso de join. Si se intenta emparejar cada predio registral con el polígono que contiene sus coordenadas, los edificios multi-unidad generan un problema de asignación: decenas o cientos de predios comparten

las mismas coordenadas y por lo tanto apuntarían al mismo polígono ([GDAL/OGR contributors, 2024](#)).

5.4.2 El concepto de rol base

La solución adoptada es el concepto de *rol base*: el identificador del predio que representa al terreno o edificio completo, independientemente de cuántas unidades registrales contenga. En el sistema catastral chileno, los predios de bienes comunes de edificios multi-unidad tienen números de predio en el rango 90.000-99.999, convención que permite identificarlos y utilizarlos como clave de enlace.

El proceso de asignación del rol base opera en dos pasos:

1. **Clasificación:** se agrupan los predios del CSV por coordenada geográfica (latitud y longitud redondeados a 6 decimales, equivalente a una precisión de aproximadamente 0,1 metros). Las coordenadas con un único predio corresponden a lotes simples; las coordenadas con múltiples predios corresponden a edificios multi-unidad.
2. **Identificación del predio 90xxx:** para cada grupo multi-unidad, se consulta la API `getPredioNacional` con números de predio candidatos en el rango 90.000-99.999 hasta identificar el predio de bienes comunes. Este predio se convierte en el `rol_base` del grupo.

El `rol_base` actúa entonces como la clave foránea que enlaza la tabla de atributos prediales con la capa de polígonos catastrales, permitiendo construir el dataset final con una fila por predio registral y la geometría correspondiente al lote físico al que pertenece ([Gillies et al., 2024b](#); [GDAL/OGR contributors, 2024](#)).

5.4.3 Validación y control de calidad a escala nacional

La validación de un dataset geoespacial de cobertura nacional requiere métricas que operen a dos niveles: el nivel de predio (integridad de atributos y consistencia geométrica de cada fila) y el nivel de comuna (cobertura del join, proporción de predios con geometría asignada, ausencia de geometrías fuera de los bounds de Chile) ([GDAL/OGR contributors, 2024](#)).

Las métricas de cobertura del join son especialmente críticas porque revelan la fracción del universo predial que efectivamente pudo ser georreferenciada. Un predio sin

geometría asignada es un predio cuya ubicación en el espacio no pudo determinarse, lo que limita su utilidad para análisis territoriales. Los factores que pueden causar ausencia de geometría incluyen predios agrícolas sin coordenadas en la API, errores de georeferenciación en los tiles WMS, y predios cuyas coordenadas no caen dentro de ningún polígono vectorizado.

El proceso de QA implementado verifica, para cada una de las 343 comunas del país, la consistencia entre el número de predios en el CSV de Fase 0 y el número de filas en el producto final, la proporción de predios con geometría asignada, la validez topológica de los polígonos (ausencia de auto-intersecciones), y que todas las coordenadas se encuentren dentro de los bounds geográficos de Chile (longitud entre -76° y $-65,5^\circ$; latitud entre -56° y -17°) ([GDAL/OGR contributors, 2024](#)).

5.5 Refinamiento iterativo de cobertura geométrica

Tras la consolidación del dataset (Fases 0–7), un porcentaje significativo de predios urbanos queda sin geometría asignada. El análisis del producto de Fase 6 revela que aproximadamente el 15,6% de los predios con ubicación urbana carecen de polígono, cifra que resulta inaceptable para un dataset que aspire a constituir una capa base de análisis territorial. Esta sección describe la metodología de refinamiento diseñada para recuperar la mayor cantidad posible de estos predios.

5.5.1 Diagnóstico del problema residual

La ausencia de geometría en predios urbanos tiene dos causas principales. La primera es el comportamiento escala-dependiente del WMS descrito en la sección 2.2.3: en ciertas zonas, los tiles de zoom 19 no renderan los bordes internos entre predios, produciendo bloques de color uniforme que se vectorizan como un único polígono fusionado. La segunda es una limitación del *spatial join* por punto-en-polígono: cuando la coordenada del predio cae en el borde de un polígono o a pocos centímetros de su límite, el join estricto falla.

El hallazgo clave que motiva el diseño del refinamiento es empírico: el 99% de los predios urbanos sin geometría tienen un polígono vectorizado a menos de 3 metros de su coordenada en el producto de la fase anterior. El problema no es la ausencia del polígono en el WMS, sino la precisión del emparejamiento.

5.5.2 Re-descarga focalizada con supercells

Para las zonas afectadas por el problema de escala del WMS, se implementa una re-descarga focalizada. En lugar de descargar tiles individuales de 256×256 píxeles (como en la Fase 1), se utilizan *supercells*: cada solicitud WMS cubre un área de 4×4 tiles regulares (1024×1024 píxeles), lo que equivale a un bounding box 16 veces mayor. Al solicitar un BBOX más amplio, el servidor renderiza correctamente los bordes internos que no aparecen en tiles individuales, resolviendo el problema de escala sin necesidad de recurrir a zoom 17.

Las supercells se calculan únicamente alrededor de los predios faltantes (con un buffer de ± 2 tiles y alineamiento a la grilla), lo que limita la descarga a las zonas estrictamente necesarias.

5.5.3 Spatial join multi-pasada con tolerancia geométrica

El emparejamiento entre predios y polígonos se realiza en dos pasadas sucesivas:

1. **Pasada estricta (*point-in-polygon*):** la coordenada del predio debe caer estrictamente dentro de un polígono. Esta pasada resuelve los casos triviales donde la coordenada está claramente en el interior del lote.
2. **Pasada con tolerancia (≤ 3 m):** para los predios no emparejados en la primera pasada, se aplica un buffer de 3 metros alrededor de cada polígono y se repite el join. Este umbral cubre el *drift* típico entre la coordenada reportada por la API y el centroide real del polígono WMS, que empíricamente es de aproximadamente 0,2 metros pero puede alcanzar hasta 2–3 metros en zonas con errores de georeferenciación.

5.5.4 Consulta directa al WMS mediante `getFeatureInfo`

Para los predios que no logran emparejarse ni con tolerancia geométrica, se recurre al servicio `getFeatureInfo` del WMS del SII. Este servicio simula un clic sobre el mapa en las coordenadas del predio y devuelve el rol del predio que el servidor asocia a esa ubicación. A diferencia de `GetMap` (que devuelve una imagen), `getFeatureInfo` devuelve datos estructurados que permiten establecer la correspondencia directa entre coordenada y rol predial.

Un aspecto técnico relevante es que el endpoint del SII implementa `getFeatureInfo` exclusivamente mediante solicitudes HTTP POST con payload JSON, a diferencia de la especificación estándar del OGC que define la operación como GET ([Open Geospatial Consortium, 2006](#)). Este detalle de implementación, no documentado, fue descubierto empíricamente durante el desarrollo del pipeline.

5.5.5 Estrategias de fallback para predios sin coordenada válida

Tras el *spatial join* multi-pasada y la consulta `getFeatureInfo`, un residuo de predios sigue sin geometría. Para estos casos se aplican tres estrategias de fallback basadas en la estructura del catastro chileno:

Herencia por coordenada compartida: los predios en edificios y condominios comparten exactamente la misma latitud y longitud. Si al menos uno de los predios de un grupo con coordenada compartida tiene geometría asignada, todos los demás la heredan.

Polígono más cercano (*nearest-polygon*, 50 m): para predios con coordenada válida pero sin match, se asigna el polígono más cercano dentro de un radio de 50 metros. Dado que el 99% de los predios faltantes tienen un polígono a menos de 3 metros, esta estrategia opera con alta precisión.

Vecindad por manzana: para predios sin coordenada válida, se explota la convención del rol predial chileno (formato MMM-PPPP, donde MMM identifica la manzana y PPPP el predio). Dentro de una manzana, los predios están numerados en orden físico, por lo que se hereda la geometría del predio numéricamente más cercano que ya tenga geometría (con un límite de diferencia ≤ 10 en el número de predio para evitar asignaciones erróneas).

Capítulo 6

Descripción del Enfoque de Solución

Este capítulo documenta el pipeline de extracción catastral: su arquitectura, las decisiones de diseño adoptadas en cada fase, el código clave que implementa cada componente y los resultados intermedios observados. El pipeline transforma tres fuentes públicas del SII (archivo TXT semestral, API REST y servicio WMS) en un dataset predial nacional georreferenciado y analíticamente útil ([GDAL/OGR contributors, 2024](#); [Jordahl et al., 2024](#)).

6.1 Arquitectura general del pipeline

El pipeline está organizado en siete fases secuenciales (Fase 0 a Fase 6), más una fase de validación (Fase 7). Cada fase produce artefactos intermedios que se almacenan en un objeto de almacenamiento en la nube (S3-compatible), lo que permite la reanudación automática ante interrupciones y el procesamiento paralelo por comuna. La Tabla [6.1](#) presenta el resumen de fases.

La infraestructura de cómputo consiste en una VPS Linux de 16 núcleos y 128 GB de RAM, un bucket S3-compatible en Hetzner (Núremberg), y 30 túneles WireGuard Mullvad montados como *network namespaces* de Linux. El stack de software utilizado es Python 3.11 con GDAL 3.8, GeoPandas 0.14, Rasterio 1.3 y boto3 para interacción con S3 ([GDAL/OGR contributors, 2024](#); [Jordahl et al., 2024](#); [Gillies et al., 2024a](#)). La Figura [6.1](#) esquematiza el flujo de datos entre fases.

Tabla 6.1: Fases del pipeline de extracción catastral

Fase	Nombre	Output en S3
0	Extracción predial (API SII)	CSV por comuna
1	Descarga cartográfica WMS	GeoTIFF por comuna (z19)
2	Vectorización raster	GeoPackage de polígonos
3	Dos pasadas (z19 + z17)	GeoPackage fusionado
4	Join espacial CSV–GeoJSON	GeoJSON con atributos
5	Completar roles faltantes	GeoJSON enriquecido
6	Consolidación final	Parquet/GeoJSON por comuna
7	QA y validación nacional	Reporte CSV de alertas




Figura 6.1: Arquitectura del pipeline de extracción catastral: flujo de datos entre las 8 fases. Flechas sólidas indican dependencias de procesamiento; flechas punteadas indican artefactos persistidos en S3. El mecanismo de *resume* permite reanudar el batch sin reprocesar fases ya completadas.

6.2 Fase 0: Extracción masiva de datos prediales

6.2.1 Parseo del archivo TXT de ancho fijo

El SII publica semestralmente el archivo `BRTMPNACROL_NAC_2025_2.txt`, denominado oficialmente *Rol Semestral de Contribuciones de Bienes Raíces* ([Servicio de Impuestos Internos, 2025](#)). Es un archivo de texto de ancho fijo (encoding *latin-1*)

de aproximadamente 3 GB que contiene una línea por predio. Los campos no están delimitados por separadores: cada campo ocupa posiciones fijas dentro de la línea, con un registro de 117 caracteres por predio. La Tabla 6.2 muestra la estructura completa de los 15 campos definidos en el manual oficial del SII.

Tabla 6.2: Estructura completa del archivo BRTMPNACROL según manual oficial del SII ([Servicio de Impuestos Internos, 2025](#))

N°	Campo	Pos.	Ancho	Descripción
1	comuna	1–5	5	Código CONARA de la comuna
2	anio	6–9	4	Año del proceso de rol de cobro
3	semestre	10	1	Semestre (1 o 2)
4	ind_aseo	11	1	“A” si la cuota incluye tarifa de aseo
5	(espacios)	12–17	6	Campo sin información
6	txt_direccion	18–57	40	Dirección predial
7	manzana	58–62	5	Número de manzana
8	predio	63–67	5	Número de predio dentro de la manzana
9	cod_serie	68	1	Serie: A=Agrícola, N=No agrícola
10	cuota_trimestral	69–81	13	Contribución neta trimestral (CLP)
11	txt_avaluo_total	82–96	15	Avalúo fiscal total (CLP)
12	txt_avaluo_exento	97–111	15	Avalúo exento del impuesto territorial (CLP)
13	anio_exencion	112–115	4	Año término exención (2055 = indefinida)
14	cod_ubicacion	116	1	Ubicación: R=Rural, U=Urbana
15	txt_cod_destino	117	1	Código de destino predial (ver Tabla 6.3)

Tabla 6.3: Tabla de destinos prediales según clasificación SII ([Servicio de Impuestos Internos, 2025](#))

Cód.	Destino	Cód.	Destino	Cód.	Destino
A	Agrícola	I	Industria	S	Salud
B	Agroindustrial	L	Bodega/Almacenaje	T	Transp./Telecom.
C	Comercio	M	Minería	V	Otros no consid.
D	Deporte/Recreación	O	Oficina	W	Sitio Eriazo
E	Educación/Cultura	P	Adm. Públ./Defensa	Y	Gallineros/chanch.
F	Forestal	Q	Culto	Z	Estacionamiento
G	Hotel/Motel				
H	Habitacional				

El script `0_get_sii.py` parsea este archivo generando una lista de roles (tuplas `manzana-predio`) por comuna. Cada rol se almacena en `data/roles_split/{COD}.txt` y constituye la cola de trabajo que se distribuirá entre los 30 túneles WireGuard ([Broxterman and Zhou, 2023](#)).

```
1 def parse_line(line: str) -> dict:
2     """Extrae campos de una línea del archivo BRTMPNACROL."""
3     return {
4         "comuna": line[0:5].strip(),
5         "anio": line[5:9].strip(),
6         "semestre": line[9].strip(),
7         "manzana": line[57:62].zfill(5),
8         "predio": line[62:67].zfill(5),
9         "txt_avaluo_total": line[81:96].strip(),
10        "txt_cod_destino": line[116].strip(),
11    }
```

Listing 6.1: Parseo de línea TXT de ancho fijo

6.2.2 La API getPredioNacional

La API REST del SII expone el endpoint `getPredioNacional` (método POST), que devuelve la información completa de un predio dado su código de comuna, manzana y número de predio. La Figura 6.2 muestra la estructura de la solicitud:

```
1 payload = {
2     "rolBusqueda": {
3         "numero_manzana": "00250",
4         "numero_predio": "00001",
5         "codigo_comuna": "13101"
6     },
7     "servicios": [
8         {"nombre": "sii:BR_CART_AH_MUESTRAS",
9          "style": "AH_MUESTRA_EAC_15_2025",
10         "eac": 15, "eacano": 2025}
11     ]
12 }
13 response = requests.post(URL_API, json=payload, timeout=8)
```

Listing 6.2: Estructura de request a la API `getPredioNacional`

La respuesta JSON incluye campos de identificación del predio (`existePredio`, `nombreComuna`, `direccion`), coordenadas geográficas (`ubicacionX` y `ubicacionY`, que el SII designa con los ejes invertidos: X contiene latitud y Y contiene longitud), avalúos fiscales (`valorTotal`, `valorAfecto`, `valorExento`), superficies (`supTerreno`, `supConsMt2`), y datos de Área Homogénea con valores comerciales de suelo en CLP/m².

6.2.3 Infraestructura de 30 túneles WireGuard

La extracción a escala de 9.5M de predios requiere distribuir la carga sobre múltiples IPs para evitar bloqueos por parte del SII. La solución consiste en 30 túneles WireGuard (proveedor Mullvad), cada uno montado como un *network namespace* independiente de Linux (Donenfeld, 2017). Esta arquitectura permite que cada proceso de scraping tenga su propia pila de red aislada, con IP pública diferente, sin interferir con los demás.

```

1 # Crear namespace para el tunel i
2 ip netns add vpn${i}
3 # Levantar interfaz WireGuard dentro del namespace
4 ip netns exec vpn${i} wg-quick up wg${i}
5 # Ejecutar scraper dentro del namespace
6 ip netns exec vpn${i} python3 0_get_sii.py \
7     --comuna 13101 --workers 3 --rps 10 \
8     --chunk ${i} --total-chunks 30

```

Listing 6.3: Creación de network namespace y activación de túnel

Cada túnel opera 3 *workers* paralelos con una tasa de 10 requests/segundo. Esto entrega un caudal sostenido de aproximadamente 900 req/s en el pico. Cuando un túnel detecta que la tasa de éxito cae (señal de que esa IP está siendo bloqueada), el orquestador (`batch_30ns.sh`) descarga un nuevo relay del JSON de Mullvad y reconfigura el túnel en el lugar, sin interrumpir los demás. Este mecanismo se denomina *rotación automática de IP* (Donenfeld, 2017). La Figura 6.2 ilustra la arquitectura de extracción distribuida.




Figura 6.2: Arquitectura de extracción distribuida con 30 túneles WireGuard. Cada túnel opera como un *network namespace* independiente con IP pública propia. El orquestador monitorea la tasa de éxito cada 15s y rota IPs quemadas desde el pool de Mullvad.

```

1 [START] 13101 (272449 predios, ~9081 per chunk) - 14:30:00
2 14:30:15 [30 alive] ok=1200 fail=2 (80.0 r/s, 15s)

```

```

3  [BURNED] T14 (ok stuck at 3421)
4  [ROTATE] T14 -> jp-tyo
5  [DONE] 13101 (7812s, 272449 rows, 34.8 r/s, 23 rot)

```

Listing 6.4: Fragmento del log de la Fase 0

6.2.4 Resultados de la Fase 0

La ejecución del batch completo sobre las 343 comunas de Chile (marzo 2026) arrojó los resultados que se presentan en la Tabla 6.4.

Tabla 6.4: Resultados de la Fase 0 (batch marzo 2026)

Métrica	Valor
Comunas procesadas	343
Pedios extraídos	9.55 millones
Tiempo total	≈ 76 horas
Rate efectivo	15–42 req/s
Rotaciones de IP	594
Fallos de comuna	0
Volumen almacenado en S3	7.7 GB (CSV)

6.3 Fase 1: Descarga cartográfica WMS

6.3.1 Clasificación de comunas: Tier A y Tier B

El análisis de los CSVs de Fase 0 reveló que 643.000 predios (6.7% del total) no tienen coordenadas geográficas en la API. La causa principal son los predios agrícolas: 77 comunas tienen más del 30% de sus predios clasificados como RAV AGRICOLA, categoría que raramente incluye coordenadas. Si se usara exclusivamente el mapa de calor de coordenadas para decidir qué tiles descargar, estas zonas agrícolas quedarían sin cobertura, aunque el WMS del SII sí contiene sus polígonos.

Por este motivo se definieron dos estrategias de descarga, ilustradas en la Figura 6.3.

6.3.2 Generación de GeoTIFFs georeferenciados

El servicio WMS del SII entrega tiles de 256×256 píxeles en formato PNG. Cada tile se solicita al nivel de zoom 19 de la proyección Web Mercator (EPSG:3857), lo que




Figura 6.3: Clasificación de comunas en Tier A y Tier B según proporción de predios sin coordenadas o agrícolas. Cada tier aplica una estrategia de descarga WMS distinta para garantizar cobertura sin descargar tiles innecesarios.

equivale a una resolución de aproximadamente 0.2986 m/px, derivada de la fórmula de georeferenciación:

$$p = \frac{2\pi R_{\oplus}}{2^z \cdot 256} \approx 0.2986 \text{ m/px} \quad (z = 19) \quad (6.1)$$

donde $R_{\oplus} = 6,378,137$ m es el radio ecuatorial de la Tierra en la proyección WGS84 ([Open Geospatial Consortium, 2006](#)).

Los tiles descargados se ensamblan en un único GeoTIFF RGBA usando escritura *windowed* (Rasterio), lo que evita cargar la imagen completa en RAM. Santiago Centro, como ejemplo de referencia, genera un GeoTIFF de 14.336×13.568 px (13.3 MB, compresión deflate), a partir de 2.968 tiles descargados en aproximadamente 7 minutos ([Gillies et al., 2024a](#)).

```

1 https://www.sii.cl/mapasui/services/ui/wmsProxyService/call
2 ?layers=sii:BR_CART_SANTIAGO_CENTRO_WMS
3 &styles=PREDIOS_WMS_V0
4 &srs=EPSG:3857
5 &width=256&height=256
6 &format=image/png
7 &bbox=-7913137.9,{min_y},-7912625.9,{max_y}

```

Listing 6.5: URL de solicitud de un tile WMS al SII

6.3.3 Work stealing entre túneles

La distribución estática de tiles entre 30 túneles (cada túnel descarga los tiles donde `tile_index % 30 == chunk_id`) implica que algunos túneles terminan antes que otros, quedando ociosos mientras el más lento aún trabaja. El mecanismo de *work stealing* resuelve esto: cuando un túnel termina su chunk, el orquestador identifica el túnel activo con más tiles pendientes y le reasigna el túnel ocioso para que descargue desde ese chunk. El script `download_chunk.py` detecta tiles ya existentes en disco y los omite automáticamente, evitando re-descargas. El umbral de activación es de 20 tiles pendientes en el chunk objetivo, por debajo del cual el costo de relanzar un proceso no se justifica. El impacto medido fue pasar de ≈ 23 tiles/s (sin stealing) a ≈ 48 tiles/s en la fase final de descarga de cada comuna.

6.4 Fase 2: Vectorización de polígonos prediales

6.4.1 Polygonización mediante GDAL Band 1

La vectorización de los GeoTIFFs se realiza con `gdal_polygonize`, la herramienta de línea de comandos de GDAL que implementa el algoritmo de etiquetado de componentes conexas por 4-conectividad ([GDAL/OGR contributors, 2024](#)). El comando base es:

```
1 gdal_polygonize.py input.tif -b 1 -f GPKG output.gpkg predios
   DN
```

Listing 6.6: Polygonización del GeoTIFF usando GDAL Band 1

El parámetro `-b 1` especifica que se usa el canal rojo (Band 1) del GeoTIFF RGBA. En el estilo cartográfico del SII (`PREDIOS_WMS_V0`), los píxeles interiores de cada predio tienen un valor de canal rojo de **DN=182** (valor decimal en el rango 0–255). Los bordes entre predios, las calles y el fondo del mapa tienen valores distintos y actúan como separadores naturales entre regiones.

El resultado crudo de la polygonización contiene todos los polígonos del raster, independientemente de su valor DN. Para Santiago Centro esto produce 3.379.736 polígonos y un GeoPackage de 763 MB. El filtrado posterior mediante:

```
1 ogr2ogr -f GPKG predios.gpkg crudo.gpkg \
2   -sql "SELECT geom, DN FROM predios WHERE DN = 182" -nln
   predios
```

Listing 6.7: Filtrado de polígonos con DN=182

reduce el resultado a 21.050 polígonos y 29 MB, eliminando el 99.4% de los polígonos y el 96% del volumen. Los polígonos con área menor a 1 m² son artefactos del anti-aliasing del raster en los bordes de predio; para análisis catastral se aplica el filtro de área ≥ 10 m², que preserva el 99.9% del área total real. La Figura 6.4 muestra el proceso completo de vectorización con sus tasas de reducción.

6.4.2 Descubrimiento del comportamiento blank: umbral de escala en GeoServer

Durante el desarrollo se detectó un comportamiento no documentado del servidor GeoServer del SII: ciertos tiles descargados a zoom 19 llegaban completamente en blanco (sin geometría) aunque la zona sí tuviera predios. Este fenómeno ocurre en zonas de alta densidad predial donde el servidor sobrepasa un umbral interno de renderizado y simplemente no entrega contenido.

La solución consistió en combinar dos resoluciones. Para cada zona con tiles blank en z19, se descargó el mismo tile a zoom 17 (≈ 1.2 m/px). El zoom 17 tiene menor densidad por tile y siempre renderiza. Los polígonos obtenidos a z17 se re proyectan y fusionan con los de z19 en las zonas de cobertura faltante. En Santiago Centro, esta corrección recuperó **599 predios** que no aparecían en la descarga original a z19 (GeoServer Project Steering Committee, 2024).

6.4.3 Filtrado por compactness

La vectorización raster genera polígonos que incluyen no solo predios sino también los *agujeros* en el interior de predios con patios o huecos. Para distinguir estos agujeros (generalmente de forma irregular) de predios reales, se utiliza el índice de compactness o cociente isoperimétrico:

$$C = \frac{4\pi A}{P^2} \quad (6.2)$$

donde A es el área del polígono y P su perímetro. Un valor $C \rightarrow 1$ indica forma circular (compacta); los agujeros producidos por texto o artefactos de renderizado tienden a tener $C < 0.1$. El umbral de clasificación implementado en el pipeline es




Figura 6.4: Proceso de vectorización en tres pasos: polygonización GDAL del canal rojo (Band 1), filtrado por valor DN=182 y área mínima, y depuración por índice de compactness. En Santiago Centro, el proceso reduce 3.38M polígonos crudos a ≈ 21.000 predios válidos.

$C \geq 0.05$ para retener un polígono como candidato a predio válido.

6.5 Fase 3: Pipeline de dos pasadas (z19 + z17)

La fusión de las dos resoluciones se implementa en `3_dos_pasadas.py`. El algoritmo opera en dos etapas:

1. **Base z19:** se toman todos los polígonos vectorizados de la descarga a zoom 19. Estos representan la geometría de mayor precisión (≈ 30 cm/px) y son la fuente primaria.
2. **Complemento z17:** para cada zona del bounding box de la comuna que no esté cubierta por ningún polígono z19 (es decir, celdas de 256×256 px a z19 que resultaron blank), se inyectan los polígonos equivalentes obtenidos de la vectorización a zoom 17. La zona de cobertura de cada tile se verifica mediante una operación espacial de diferencia.

La estrategia es conservadora: los polígonos z19 nunca son reemplazados por los de z17. Solo se agregan los z17 donde z19 está vacío. Esto preserva la máxima precisión disponible en la mayor parte del territorio, mientras garantiza cobertura en zonas donde el GeoServer no renderiza a z19 ([GeoServer Project Steering Committee, 2024](#)).

6.6 Fases 4 a 6: Join espacial y consolidación

6.6.1 Spatial join CSV–GeoJSON

El objetivo de esta etapa es asignar a cada predio del CSV de Fase 0 el polígono catastral que le corresponde en el GeoPackage de Fase 3. La clave de enlace es el `rol_base`: un identificador que apunta al terreno físico (lote o edificio) al que pertenece cada predio, independientemente de si ese terreno tiene una o múltiples unidades ([Jordahl et al., 2024](#)).

El join se realiza con GeoPandas mediante una operación de intersección punto-polígono: para cada predio con coordenadas válidas (`lat`, `lon`), se construye un punto geométrico y se busca el polígono vectorizado que lo contiene:

```
1 import geopandas as gpd
2 from shapely.geometry import Point
3
4 # Construir GeoDataFrame de puntos desde CSV
5 gdf_puntos = gpd.GeoDataFrame(
6     df,
7     geometry=[Point(lon, lat)
8               for lon, lat in zip(df["lon"], df["lat"])],
9     crs="EPSG:4326"
10 )
11 # Leer poligonos vectorizados
12 gdf_pols = gpd.read_file("predios.gpkg").to_crs("EPSG:4326")
13
14 # Spatial join: each point -> polygon that contains it
15 resultado = gpd.sjoin(
16     gdf_puntos, gdf_pols,
17     how="left", predicate="within"
18 )
```

Listing 6.8: Spatial join entre puntos de predios y polígonos vectorizados

6.6.2 El concepto de rol_base

Un mismo terreno catastral puede contener múltiples predios: un edificio de departamentos tiene un predio por unidad (DP 101, DP 102, etc.) más un predio 90xxx que representa los bienes comunes del edificio completo. En el mapa WMS, el polígono dibujado corresponde al terreno completo, no a la unidad individual. Por tanto, el polígono se identifica con el rol del predio 90xxx, denominado `rol_base`.

La detección automática de si un predio es lote simple o multi-unidad se hace agrupando todos los predios con coordenadas válidas por posición geográfica (redondeada a 10^{-6} grados, equivalente a ≈ 11 cm). Si en una posición hay un solo predio, es lote simple y su `rol_base` es su propio rol. Si hay múltiples predios en la misma posición, se lanza un escaneo de la API buscando el predio 90xxx correspondiente, con variaciones ± 2 alrededor del candidato `90000 + predio_min`.

6.6.3 Consolidación final (Fase 6)

El script `6_consolidar_final.py` genera el producto definitivo por comuna: un archivo Parquet con una fila por predio y geometría vectorial asignada. Los campos del polígono (`pol_area_m2`, `pol_tipo_predio`, `pol_n_roles`, `pol_n_roles_unitarios`, `pol_direccion_base`, `pol_destino_base`) se adjuntan a cada fila del CSV enriquecido, produciendo un dataset completamente plano sin necesidad de joins adicionales para su análisis.

6.7 Fase 7: QA y validación nacional

La validación de cobertura y calidad opera sobre el producto final de Fase 6. El script `7_qa_validacion.py` descarga cada archivo Parquet desde S3 y aplica una batería de verificaciones ([GDAL/OGR contributors, 2024](#)):

- **Integridad de filas:** número de predios en el CSV de Fase 0 igual al número de filas en el Parquet de Fase 6.
- **Cobertura del join:** porcentaje de predios con polígono asignado (`pct_con_geom`). El umbral de alerta es $< 80\%$.
- **Validez topológica:** ausencia de geometrías auto-intersectantes, verificada mediante `is_valid` de Shapely ([Gillies et al., 2024b](#)).
- **Bounds geográficos de Chile:** todos los centroides de polígonos deben caer dentro de los límites $-76^\circ \leq \lambda \leq -65,5^\circ$ (longitud) y $-56^\circ \leq \phi \leq -17^\circ$ (latitud).
- **Sistema de referencia:** CRS del GeoPackage debe ser EPSG:4326.

El reporte de salida es un CSV con una fila por comuna y todas las métricas anteriores (`/tmp/fase7_reporte.csv`), más un archivo de texto con las comunas que generaron alertas. Este proceso puede ejecutarse incrementalmente (`-resume`) sobre comunas nuevas sin reprocesar las ya validadas.

6.8 Diccionario de datos del producto final

El dataset resultante contiene campos provenientes de tres fuentes distintas, consolidados en una fila por predio. La Tabla 6.5 presenta los campos principales y su

origen.

Tabla 6.5: Diccionario de datos del producto final (campos principales)

Campo	Origen	Descripción
<i>Identificación</i>		
v	Calculado	Clave única: comuna manzana predio
rol	Calculado	Rol: manzana-predio
rol_base	Fase 4	Rol del terreno/edificio padre
<i>Atributos del TXT semestral</i>		
txt_direccion	TXT SII	Dirección oficial del predio
txt_avaluo_total	TXT SII	Avalúo fiscal total (CLP)
txt_cod_destino	TXT SII	Código de destino (1 dígito)
<i>Atributos de la API</i>		
lat, lon	API SII	Coordenadas WGS84 del predio
valorTotal	API SII	Avalúo fiscal total vía API (CLP)
supTerreno	API SII	Superficie de terreno
supConsMt2	API SII	Superficie construida (m ²)
valorComercial_clp_m2	API SII	Valor comercial suelo (CLP/m ²)
destinoDescripcion	API SII	Destino en texto (HABITACIONAL, etc.)
ah	API SII	Código de Área Homogénea
ah_valorUnitario	API SII	Valor unitario del AH
<i>Atributos del polígono (WMS vectorizado)</i>		
pol_area_m2	Fase 2-3	Área del polígono catastral
pol_tipo_predio	Fase 4	lote_simple o multi_unidad
pol_n_roles_unitarios	Fase 4	Unidades en el edificio

Además de los campos de la Tabla 6.5, el dataset incluye datos del Observatorio de Mercado de Suelo Urbano del SII (prefijo `obs_`), que proveen series históricas de transacciones por Área Homogénea para los años 2022–2025, y datos de Estudio de Avalúos Comerciales (prefijo `cap__ah_muestra_*`) con el valor comercial de suelo por EAC (versiones 14 y 15). Este nivel de detalle histórico convierte al dataset en una herramienta para análisis de plusvalía y evolución de valores de suelo a escala de manzana.

6.9 Catastral.cl: plataforma de distribución

El pipeline de extracción catastral produce los datos; la plataforma **Catastral.cl** los hace accesibles. Este capítulo cierra describiendo la arquitectura de distribución construida sobre el dataset, dado que la plataforma es el resultado aplicado que concreta el objetivo central de la tesis: eliminar las barreras de acceso para cualquier actor, con independencia de su capacidad técnica.

6.9.1 Separación de dominios

La arquitectura separa físicamente dos responsabilidades en dos servidores distintos. El VPS extractor (descrito en las secciones anteriores) ejecuta el pipeline de 8 fases y almacena los productos en Hetzner Object Storage (bucket `siipredios`), con una ruta uniforme por archivo: `s3://siipredios/2025ss_bcn/fase6/comuna={COD}.{csv|geojson}`. El VPS de plataforma (Hetzner, Helsinki, 32 cores, 122 GB RAM) consume esos archivos a través de un pipeline ETL y los sirve a través de una API REST y un frontend React.




Figura 6.5: Arquitectura de dos dominios de la plataforma Catastral.cl. El VPS extractor (izquierda) ejecuta el pipeline de extracción catastral y almacena los productos en S3. El VPS de plataforma (derecha) los consume vía un pipeline ETL semestral y los sirve a través de Nginx, FastAPI, PostgreSQL/PostGIS y una SPA React bajo el dominio `catastral.cl`.

6.9.2 Pipeline ETL de carga a PostgreSQL

Los archivos generados por el pipeline de extracción catastral se cargan en PostgreSQL a través de un pipeline ETL de 9 scripts (`01_download_csvs.py` a `09_load_geometries.py`). El proceso de carga tabular tarda aproximadamente 25 minutos; la carga de geometrías poligonales desde los GeoJSON de S3 (`09_load_geometries.py`) tarda ≈ 5 horas adicionales, ya que procesa archivos de hasta 11 GB usando `ijson` en streaming para no saturar la RAM del servidor. El pipeline produce dos tablas principales:

- **catastro_actual**: 9.407.339 filas correspondientes al semestre vigente (2025-S2), con 40 columnas incluyendo la columna `geom geometry(Geometry, 4326)` que almacena los polígonos vectorizados de 5,67 millones de predios. Es la fuente de búsqueda, detalle de predio, visualización de polígonos en el mapa y estadísticas en tiempo real.
- **catastro_historico**: 136.630.730 filas que cubren 16 semestres (2018-S1 a 2025-S2), con 13 columnas. Permite calcular la evolución del avalúo fiscal de cualquier predio en los últimos 7 años.

Los índices de PostgreSQL cubren búsqueda fuzzy de direcciones (GIN trigram), búsqueda espacial por coordenadas (GIST PostGIS), y filtros por comuna, destino, avalúo y superficie. La búsqueda espacial `/api/predios/nearby` (“predios en un radio de X metros”) responde en ≈ 50 ms gracias al índice GIST.

6.9.3 API REST

El backend expone más de 40 endpoints organizados en 9 routers FastAPI. Los endpoints centrales se organizan en cinco categorías:

Búsqueda y detalle. Incluye búsqueda textual por dirección y comuna, búsqueda espacial por coordenadas y radio, detalle completo de un predio con las 39 variables, y serie histórica de avalúo para 16 semestres.

Estadísticas. Agregados nacionales y por comuna, cacheados por 1 hora, con tiempo de respuesta de ≈ 14 ms en caliente.

Polígonos vectoriales. Retorna el polígono de un predio como GeoJSON FeatureCollection ($\approx 1-2$ KB) o hasta 200 polígonos cercanos a una coordenada usando filtro de bounding box GIST más `ST_DWithin`, con color por destino predial.

Capas por comuna. Lista las 343 comunas disponibles con estadísticas de cobertura y devuelve URLs prefirmadas S3 con expiración de 15 minutos para usuarios autorizados.

Descargas históricas gratuitas. Lista 16 CSVs semestrales sin geometría ($\approx 22,8$ GB en total), descargables sin registro.

6.9.4 Frontend y modelo de acceso

El frontend React implementa 10 páginas bajo el dominio `catastral.cl`. El componente central es el **Explorador** (`/explorar`), que permite buscar cualquier predio por dirección o rol predial con autocompletado, muestra el resultado en un mapa Leaflet interactivo, y abre la ficha completa del predio con un gráfico de evolución de avalúo (Recharts) y una visualización 3D isométrica del edificio.

La plataforma implementa un modelo de **pago social** con tres niveles de acceso:

1. **Acceso gratuito:** búsqueda y consulta de cualquier predio de Chile (9,4 millones), detalle completo con 39 variables, series históricas de avalúo 2018–2025, estadísticas nacionales y por comuna, y descarga de los 16 CSVs semestrales históricos sin geometría.
2. **Acceso con pago social:** archivos enriquecidos por comuna con geometría vectorial en tres formatos (CSV, GeoJSON, GeoPackage), listos para análisis en QGIS, PostGIS o Python/GeoPandas. El *precio* de estas capas no es monetario: el usuario debe publicar una mención de Catastral.cl en LinkedIn como condición para recibir el enlace de descarga. El objetivo es liberar el dato a quien lo necesita y a la vez generar visibilidad orgánica de la plataforma en la red profesional donde se concentra su público objetivo.
3. **Acceso organizacional:** *domain grants* que permiten que todos los emails de un dominio corporativo o institucional accedan automáticamente sin pasar por el flujo individual.

La autenticación *passwordless* por OTP (código de 6 dígitos vía Resend, TTL 10 min) está reservada exclusivamente para el administrador, accesible mediante la URL directa `/admin`; el botón de login no aparece en la navegación pública. Los usuarios públicos no tienen cuenta: el acceso a las capas vectoriales se gestiona mediante un token anónimo UUID almacenado en la tabla `share_tokens` y en una cookie `httpOnly` con TTL de 1 año, generado al validar la publicación de LinkedIn. El sistema incluye un mecanismo de recuperación por LinkedIn username en caso de pérdida de la cookie. Las descargas son URLs prefirmadas S3 con expiración de 15 minutos, sin posibilidad de redistribución masiva.

6.9.5 Cobertura y actualización semestral

De las 343 comunas de Chile, 342 tienen archivos CSV + GeoJSON + GeoPackage disponibles en S3 y 343 se muestran en la plataforma. Las tres comunas sin datos son Antártica (12202), Isla de Pascua (05201) y Juan Fernández (05104), territorios insulares o antárticos sin cobertura del WMS del SII a las resoluciones utilizadas. La actualización es semestral, sincronizada con la publicación del nuevo archivo BRTMPNACROL por el SII: el pipeline ETL (`05_run_all.py`) carga los datos tabulares en ≈ 25 minutos; la actualización de geometrías (`09_load_geometries.py`) requiere ≈ 5 horas adicionales para procesar los GeoJSON de S3.

Capítulo 7

Resultados, Casos de Uso e Impacto

Este capítulo presenta los dos resultados principales de esta tesis: el dataset predial nacional construido por el pipeline de extracción catastral, y la plataforma **Catastral.cl** que lo distribuye públicamente. Se evalúa la utilidad de ambos para la industria inmobiliaria mediante casos de uso concretos, y se examina el impacto en el acceso democrático a la información pública.

7.1 El dataset resultante

7.1.1 Cobertura nacional

El dataset producido por el pipeline de extracción catastral (batch de marzo de 2026, semestre 2025-2 del SII) cubre la totalidad del territorio catastral de Chile. La Tabla 7.1 resume las métricas de cobertura a nivel nacional.

La cobertura de polígonos vectoriales alcanza el 60,3% a nivel nacional. El 39,7% restante corresponde principalmente a predios rurales y agrícolas sin levantamiento cartográfico en el WMS del SII (los predios existen en el TXT semestral pero el servidor no publica su geometría a las resoluciones utilizadas), y a unidades dentro de edificios que comparten el polígono del lote padre. Esta cobertura refleja el máximo disponible en las fuentes públicas del SII, no una limitación del pipeline. Los predios sin polígono están presentes en el dataset con todos sus atributos tabulares intactos.

Tabla 7.1: Cobertura del dataset predial nacional

Métrica	Valor
Comunas cubiertas	343 de 343
Pedios totales	9.55 millones
Pedios con polígono vectorial	5.671.116 (60,3% del total)
— Urbanos (U)	4.821.993 de 7.285.199 (66,2%)
— Rurales (R)	765.565 de 2.018.772 (37,9%)
— Habitacional (H)	3.874.400 de 5.987.385 (64,7%)
— Agrícola (A)	269.727 de 998.053 (27,0%)
Pedios sin polígono (sin levant. cartogr.)	3.736.223 (39,7%)
Resolución geométrica	≈ 30 cm/píxel (zoom 19)
Sistema de referencia	EPSG:4326 (WGS84)
Formato de entrega	Parquet por comuna + GeoJSON
Volumen total comprimido	≈ 18 GB

7.1.2 Variables disponibles

Cada predio del dataset incluye campos de tres categorías distintas, según lo descrito en el Capítulo 3:

Los **atributos de identificación y localización** incluyen el rol predial único (**rol**), el rol base del terreno (**rol_base**), la dirección oficial según el TXT semestral y según la API, el código de comuna, la latitud y longitud del centroide, y la geometría del polígono del lote o edificio.

Los **atributos de valor** incluyen el avalúo fiscal total, afecto y exento en CLP (fuente: TXT semestral y API), el valor comercial de suelo en CLP/m² por Área Homogénea, el valor unitario del EAC vigente (Estudio de Avalúos Comerciales), y series históricas de valores de suelo para los años 2022–2025 (EAC 14 y EAC 15).

Los **atributos catastrales** incluyen la superficie de terreno, la superficie construida en m², el código de destino predial en texto (**HABITACIONAL**, **COMERCIO**, **INDUSTRIA**, **AGRICOLA**, etc.), el tipo de predio (**lote_simple** o **multi_unidad**), el número de unidades en el edificio (**pol_n_rols_unitarios**), y el área del polígono vectorial calculada en m².

7.1.3 Comparación con alternativas comerciales

La Tabla 7.2 compara Catastral.cl con las principales alternativas disponibles para acceder a datos prediales a escala nacional en Chile, evaluadas en cinco dimensiones: cobertura territorial, costo de acceso masivo, precisión geométrica, disponibilidad de

atributos de valor y nivel de apertura.

Tabla 7.2: Comparación con fuentes alternativas de datos prediales en Chile

Fuente	Cobertura	Costo masivo	acceso	Geometría	Nivel de acceso
Catastral.cl (esta tesis)	343 comunas, 9,4M predios	≈USD infra	150/mes	Vectorial (≈30 cm)	Dataset abierto, API, descarga bulk
SII WMS	343 comunas	Gratuito	indiv- ual; sin bulk	Solo raster (PNG)	Consulta tile a tile; sin API ma- siva
SII portal web	343 comunas	Gratuito	indiv- ual	Sin geometría	Consulta predio a predio
Operadores pri- vados	Parcial	USD 2.000–6.000 / comuna		Variable	API privada con cuotas
Portales inmo- bil.	Parcial (avi- sos)	USD 50–500/mes		Puntual	Sin descarga ma- siva
CBR	Nacional (le- gal)	USD 200+ / mes susc.		Sin geometría	Portal web; sin API
SIG municipal	30–40 comu- nas	Variable / conve- nio		Alta donde disponible	Heterogéneo (PDF, SHP)

El diferenciador principal de Catastral.cl es la combinación de cobertura nacional completa, geometría vectorial de alta resolución, atributos de valor de suelo del propio SII, y distribución a través de una plataforma web con descarga masiva. Las alternativas existentes ofrecen alguna de estas dimensiones pero no todas simultáneamente: el SII provee cobertura nacional pero sin formato vectorial ni descarga masiva; los operadores privados ofrecen datos estructurados pero a costos que restringen el acceso a actores con presupuesto; y los SIG municipales proveen alta precisión pero solo para una fracción del territorio ([Open Knowledge Foundation, 2023](#); [Janssen et al., 2012](#)).

7.2 La plataforma Catastral.cl

7.2.1 Descripción y alcance

Catastral.cl es la interfaz pública del sistema desarrollado en esta tesis. Es el resultado aplicado que concreta el objetivo de democratización: transforma un dataset técnicamente producido por el pipeline en un servicio web consultable por cualquier actor, sin requerir conocimientos de programación, acceso a bases de datos ni software especializado.

La plataforma está operativa en producción bajo el dominio `catastral.cl`, servida desde un VPS dedicado en Helsinki (Hetzner, 32 cores, 122 GB RAM) con Nginx

como *reverse proxy*, Cloudflare para DNS y CDN con certificado SSL Full Strict, FastAPI como backend, PostgreSQL 16 + PostGIS 3.5 como motor de datos, y una Single Page Application React 19 como frontend.



Figura 7.1: Página de inicio de `catastral.cl`: 9,4 millones de predios, 345 comunas, 16 semestres y 88 columnas disponibles. Disponible en <https://catastral.cl>.

7.2.2 Base de datos y cobertura

La base de datos PostgreSQL integra los productos de todas las fases del pipeline en dos tablas principales:

`catastro_actual` almacena 9.407.339 predios del período vigente (2025-S2) con 40 columnas, incluyendo la columna `geom geometry(Geometry, 4326)` que contiene los polígonos vectorizados cargados desde los GeoJSON de la Fase 6 del pipeline. Corresponde al producto de la Fase 0 enriquecido con coordenadas, superficies, valor comercial de suelo por Área Homogénea, código de destino predial y geometría poligonal. Los índices incluyen búsqueda fuzzy de direcciones (GIN trigram), índice espacial GIST sobre coordenadas y sobre la columna `geom` (`idx_catastro_actual_geom`), y B-tree sobre comuna, destino, avalúo y superficie.


`catastro_historico` almacena 136.630.730 filas que cubren 16 semestres entre 2018-S1 y 2025-S2, con 13 columnas. Esta tabla alimenta las gráficas de evolución histórica de avalúo de cualquier predio, ofreciendo una perspectiva de 7 años de variación del valor fiscal sin precedente en fuentes públicas chilenas.

7.2.3 Funcionalidades de la plataforma

La plataforma implementa tres niveles funcionales accesibles desde el mismo dominio:

Exploración gratuita: cualquier usuario puede buscar predios por dirección, rol predial o coordenadas geográficas sin registro. El **Explorador** (/explorar) muestra los resultados en un mapa Leaflet interactivo con autocompletado de direcciones. La ficha de cada predio incluye los 39 atributos del SII, la geometría del lote sobre el mapa, y una gráfica de evolución de avalúo fiscal para los 16 semestres disponibles. La búsqueda avanzada (/buscar) permite filtrar por superficie, avalúo, destino y comuna. El dashboard de estadísticas (/estadisticas) presenta distribuciones por destino, región y valor de suelo con gráficas interactivas.

Descargas históricas gratuitas: la sección /descargas ofrece los 16 archivos CSV semestrales (datos tabulares sin geometría, desde 2018 hasta 2025), descargables directamente sin registro ni pago, representando aproximadamente 22,8 GB de datos históricos.



PERIODO	SEMESTRE	REGISTROS	TAMANO	
2025S2	2025 — Semestre 2	9.407.339	1.6 GB	↓ CSV
2025S1	2025 — Semestre 1	9.342.943	1.6 GB	↓ CSV
2024S2	2024 — Semestre 2	9.183.865	1.6 GB	↓ CSV
2024S1	2024 — Semestre 1	9.103.135	1.6 GB	↓ CSV
2023S2	2023 — Semestre 2	8.940.358	1.5 GB	↓ CSV
2023S1	2023 — Semestre 1	8.862.697	1.5 GB	↓ CSV
2022S2	2022 — Semestre 2	8.656.530	1.4 GB	↓ CSV
2022S1	2022 — Semestre 1	8.565.453	1.4 GB	↓ CSV
2021S2	2021 — Semestre 2	8.437.439	1.4 GB	↓ CSV
2021S1	2021 — Semestre 1	8.360.299	1.4 GB	↓ CSV
2020S2	2020 — Semestre 2	8.247.999	1.4 GB	↓ CSV

Figura 7.2: Sección /descargas de catastral.cl: 16 archivos CSV semestrales con 136,6 millones de registros en total, de acceso libre y gratuito sin registro.

Capas con geometría vectorial: la sección /tienda presenta el catálogo de 343 comunas con estadísticas por cada una: porcentaje de cobertura de polígonos (**C**), proporción de predios urbanos (**U**), proporción de predios agrícolas (**A**) y peso del archivo GeoJSON (desde 0,7 MB en Torres del Paine hasta 11 GB en Las Condes, mediana ≈ 184 MB). El catálogo es ordenable por cobertura y por peso. Para cada

comuna se ofrecen tres formatos de descarga: CSV plano, GeoJSON con geometría y GeoPackage (GPKG), compatibles con QGIS, PostGIS y Python/GeoPandas. El acceso no requiere pago monetario: el usuario realiza un **pago social** publicando una mención de Catastral.cl en LinkedIn. El dato se libera completamente; el precio es visibilidad en la red profesional.

La cobertura es de 342 comunas con archivos completos disponibles en S3 y 343 mostradas en la plataforma. Las tres comunas sin datos son Antártica (12202), Isla de Pascua (05201) y Juan Fernández (05104), territorios sin cobertura WMS del SII a las resoluciones utilizadas por el pipeline.

7.2.4 Autenticación y pagos

La plataforma opera sin registro para usuarios públicos. La autenticación *password-less* por OTP (código de 6 dígitos vía email, Resend, TTL 10 min) está reservada exclusivamente para el administrador, quien accede a través de la URL directa `/admin`; el botón de login no aparece en la navegación pública.

Para acceder a las capas con geometría vectorial, el usuario público completa el pago social siguiendo tres pasos: (1) copia el texto sugerido por la plataforma —que menciona a @crishernandezco y @tremen-tech— y publica un post en LinkedIn; (2) pega la URL del post en el formulario; (3) el backend valida el formato del URL mediante expresión regular sobre dominios `linkedin.com` y crea un token UUID almacenado en la tabla `share_tokens` y en una cookie `httpOnly` con TTL de 1 año, lo que otorga descargas ilimitadas para las 343 comunas disponibles. Si el usuario limpia sus cookies, puede recuperar el acceso ingresando su LinkedIn username: el backend busca el token en `share_tokens.linkedin_username` y restaura la sesión. Las descargas son URLs prefirmadas S3 con expiración de 15 minutos.

7.2.5 Modelo de distribución: pago social

El modelo de acceso de Catastral.cl distingue dos niveles de servicio. Las funcionalidades de consulta, estadísticas, series históricas y descargas tabulares son de acceso libre y sin registro. Para las capas con geometría vectorial (GeoJSON, GeoPackage), el acceso requiere un *pago social*: la publicación de una mención de la plataforma en LinkedIn. Esta decisión de diseño responde a dos objetivos: eliminar la barrera económica para usuarios sin capacidad de pago (investigadores, municipios, emprendedores en etapa temprana) y generar difusión orgánica en la red profesional

donde se concentra la audiencia objetivo.

La hipótesis subyacente es que la demanda por datos catastrales en Chile se segmenta en dos grupos: un segmento profesional (consultoras, desarrolladores GIS, operadores de infraestructura) con disposición a pagar por el dato, y un segmento social (academia, sector público, periodismo de datos) con necesidad legítima pero sin recursos para adquirir bases de datos comerciales. El modelo busca que ambos segmentos accedan al mismo dataset, donde el primero contribuye con visibilidad y el segundo se beneficia de la ausencia de barrera monetaria.

Tabla 7.3: Segmentación de usuarios según modelo de pago social de Catastral.cl

Tipo de usuario	Perfil	Acceso
Empresa de geocoding / GIS	Construye productos comerciales sobre el dato	Pago social (post LinkedIn)
Consultora inmobiliaria	Prospección, due diligence	Pago social (post LinkedIn)
Operador de infraestructura	Localización de activos a escala	Pago social (post LinkedIn)
Investigador academia /	Análisis territorial, tesis	Gratuito (explorador + descarga histórica)
Municipio / planificador	Gestión territorial pública	Gratuito o domain grant
Periodista de datos	Investigación de interés público	Gratuito
Ciudadano	Consulta de su predio	Gratuito

Desde la perspectiva de sostenibilidad, el modelo presenta una propiedad de rendimientos crecientes: a medida que crece el número de usuarios que realizan el pago social, la difusión orgánica reduce el costo de adquisición de nuevos usuarios, lo que potencialmente permite mantener el acceso libre sin comprometer la operación del sistema.

7.2.6 Rendimiento observado

Las consultas centrales de la plataforma responden dentro de umbrales aceptables para uso interactivo. La búsqueda por dirección con índice trigram tarda ≈ 200 ms; la búsqueda espacial por coordenadas con índice GIST, ≈ 50 ms. Los nuevos endpoints de polígonos vectoriales (`/api/geojson/predio` y `/api/geojson/nearby`) responden en $\approx 1,7$ s para 50 polígonos cercanos usando filtro de bounding box GIST más `ST_DWithin`. Las estadísticas agregadas se precalientan al arranque (≈ 10 – 11 segundos) y se sirven desde caché con TTL de 1 hora a ≈ 13 – 14 ms. El endpoint

`/api/health` responde en 15 ms como línea base del stack. La carga inicial de geometrías desde S3 (5,67 millones de polígonos procesados con `ijson` en streaming) tomó ≈ 5 horas en el VPS de la plataforma.

7.3 Evaluación de precisión geométrica

Dado que el dataset construido constituye la base para los análisis presentados en las secciones siguientes, resulta fundamental evaluar su precisión espacial. En particular, se busca cuantificar el error introducido por el proceso de vectorización a partir de imágenes WMS, para determinar si el dataset es suficientemente preciso para los casos de uso propuestos.

7.3.1 Metodología

Para cada predio del dataset coexisten dos representaciones espaciales independientes:

1. **Coordenada API** (`lat`, `lon`): entregada directamente por el endpoint interno del SII (`getPredioNacional`), corresponde a la ubicación oficial registrada para cada predio.
2. **Centroide del polígono**: calculado geoméricamente a partir del polígono vectorizado desde las imágenes WMS del SII.

La distancia entre ambas representaciones constituye una medida directa de la precisión espacial del proceso de vectorización. Se seleccionó una muestra de 1.396 predios de la comuna de Lebu (Biobío, código 8402), correspondiente a un área urbana de tamaño mediano, donde se dispone simultáneamente de coordenada API y polígono vectorizado. Los centroides fueron calculados en proyección EPSG:3857 (métrica) y convertidos a WGS84 para el cálculo de distancias mediante la fórmula de Haversine.

7.3.2 Resultados

La Tabla 7.4 reporta las estadísticas descriptivas del error espacial sobre la muestra de $n = 1.396$ predios de Lebu. La distribución del error es fuertemente asimétrica a la derecha: la mediana es de solo 0,4 metros, mientras que la media se eleva a 4,0

metros por la presencia de casos atípicos en los percentiles superiores. La Tabla 7.5 desagrega estos resultados en umbrales acumulativos, mostrando que el 82,8% de los predios presenta un error inferior a 5 metros y el 95,6% se encuentra dentro de los 20 metros.

Tabla 7.4: Estadísticas de error espacial entre coordenada API y centroide del polígono (comuna de Lebu, $n = 1.396$)

Métrica	Valor
Error promedio	4,0 m
Error mediano	0,4 m
Percentil 75 (p75)	2,7 m
Percentil 90 (p90)	10,8 m
Percentil 95 (p95)	18,8 m
Percentil 99 (p99)	54,9 m

Tabla 7.5: Proporción de predios dentro de umbrales de error espacial

Umbral	Predios dentro del umbral
< 5 m	82,8%
< 10 m	89,1%
< 20 m	95,6%
< 50 m	98,8%

7.3.3 Interpretación

El error mediano de 0,4 metros indica que para la mayoría de los predios la vectorización reproduce con alta fidelidad la ubicación oficial del SII. El error p95 de 18,8 metros establece el límite superior para el 95% de los casos, valor consistente con la resolución espacial del WMS utilizado (zoom nivel 19, $\approx 0,3$ m/píxel) y los efectos de compresión JPEG de los tiles.

El 1,2% de predios con error superior a 50 metros corresponde íntegramente a predios de tipo simple de gran superficie (predios agrícolas o semi-rurales), donde la coordenada API del SII registra el punto de acceso o un vértice del predio en vez del centroide geométrico —comportamiento documentado en la propia fuente.

Estos resultados son suficientes para los casos de uso de analítica urbana y scoring presentados en las secciones siguientes, donde las decisiones operan a escala de manzana (≈ 50 – 200 m). No obstante, el dataset no es adecuado para usos legales o de demarcación formal de límites prediales, que requieren precisión catastral ($< 0,1$ m) sólo obtenible a través del instrumento oficial del Conservador de Bienes Raíces. En

particular, estos resultados refuerzan la validez del dataset para el análisis de suelo subutilizado y el modelo de scoring de localización de estaciones de servicio.

7.4 Casos de uso para la industria inmobiliaria

7.4.1 Análisis de plusvalía y valor de suelo

El campo `valorComercial_clp_m2` permite calcular el valor de mercado estimado de cualquier predio multiplicando su superficie de terreno (`supTerreno`) por el valor unitario del Área Homogénea. Al combinar esto con la geometría vectorial, es posible generar mapas de valor de suelo a escala de manzana para toda una comuna o región metropolitana. Este análisis, que requería horas de trabajo manual con datos dispersos, se convierte en una consulta SQL sobre el dataset:

```
1 SELECT
2     manzana ,
3     COUNT(*)                               AS n_predios ,
4     AVG(valorComercial_clp_m2)             AS
5         valor_uf_m2_promedio ,
6     SUM(supTerreno * valorComercial_clp_m2) AS
7         valor_total_manzana_clp
8 FROM predios
9 WHERE comuna = '13101'
10    AND pol_tipo_predio = 'lote_simple'
11    AND supTerreno > 0
12 GROUP BY manzana
13 ORDER BY valor_uf_m2_promedio DESC;
```

Listing 7.1: Valor de suelo por manzana en Santiago Centro

7.4.2 Prospección de predios por destino y superficie

El campo `destinoDescripcion` permite filtrar predios por uso actual (habitacional, comercio, industria, estacionamiento, etc.). Combinado con la superficie de terreno y el valor unitario de suelo, esto habilita consultas de prospección que antes requerían la intervención de un broker especializado con acceso a bases privadas:

```
1 SELECT
2     nombreComuna ,
```

```
3     rol ,
4     direccion_sii ,
5     supTerreno ,
6     valorComercial_clp_m2 ,
7     pol_area_m2
8 FROM predios
9 WHERE destinoDescripcion LIKE '%INDUSTRIA%'
10    AND supTerreno BETWEEN 2000 AND 10000
11    AND comuna IN ( '13109' , '13110' , '13119' , '13131' )
12 ORDER BY valorComercial_clp_m2 ASC;
```

Listing 7.2: Prospección de predios industriales en comunas de la RM

7.4.3 Identificación de suelo subutilizado

La combinación de `supTerreno` (superficie de terreno) y `supConsMt2` (superficie construida) permite calcular el índice de ocupación de cada predio (superficie construida / superficie de terreno). Predios con índice de ocupación bajo en zonas de alta densidad o alto valor son candidatos a proyectos de densificación. Esta es una capacidad analítica de alto valor para fondos de inversión inmobiliaria (REIT), oficinas de planificación urbana y desarrolladores, y que no existía como consulta ejecutable sobre datos públicos.

7.4.4 Due diligence con datos objetivos

Para operaciones de adquisición inmobiliaria comercial (oficinas, bodegas, locales), el dataset permite verificar de forma independiente el avalúo fiscal, la superficie de terreno, el destino predial oficial y la geometría del lote antes de contratar una tasación. En el contexto de Newmark Chile descrito en el Capítulo 1, esto significa que un broker puede entregar a su cliente, en cuestión de minutos, un informe de due diligence sobre cualquier predio de Chile con datos directamente extraídos del SII, sin depender de bases de datos privadas ni de información de segunda mano.

7.4.5 Caso aplicado: inteligencia de localización para estaciones de servicio

Los cuatro casos de uso anteriores son analíticos: ilustran qué tipo de consultas habilita el dataset. La plataforma **combustible.tremen.tech** es un caso de uso real y operativo que demuestra que el dataset producido por el pipeline de extracción catastral puede ser la capa base de una aplicación comercial de inteligencia geoespacial completa.

El problema que resuelve

La prospección de ubicaciones para nuevas estaciones de servicio (bencineras) en Chile se realiza tradicionalmente mediante *scouts* en terreno que recorren zonas durante 6 a 12 semanas, evaluando visualmente cada sitio. El proceso es lento, subjetivo, incompleto (es imposible cubrir todos los predios disponibles a escala nacional) y no reproducible entre consultores. La plataforma reemplaza este proceso por un pipeline automatizado de aproximadamente 30 minutos que analiza los 9,5 millones de predios del país.

Cómo consume el dataset de la tesis

El dataset del pipeline de extracción catastral es la capa base de la plataforma: sin él, no existiría la capacidad de filtrar masivamente por superficie, destino y localización geográfica a escala nacional. La Tabla 7.6 muestra los campos del dataset que la plataforma utiliza directamente.

Tabla 7.6: Campos del dataset predial consumidos por la plataforma Combustible

Campo (dataset catastral)	Uso en Combustible
lat, lon	Geolocalización del predio candidato en el mapa
supTerreno	Filtro de superficie: 1.200–5.000 m ²
destinoDescripcion	Filtro por destino: ERIAZO o COMERCIO
txt_direccion	Identificación del predio en tabla y popups
rol	Identificador único de cada candidato
valorComercial_clp_m2	Contexto de valor de suelo para evaluación económica

Pipeline de 10 pasos: del catastro al ranking

El pipeline toma como entrada el dataset del pipeline de extracción catastral y lo cruza con cinco fuentes adicionales (OpenStreetMap, panel GPS de movilidad, API de precios CNE, Google Routes API e imágenes satelitales HERE Maps) en diez etapas organizadas en dos fases:

La **Fase A** aplica cinco filtros progresivos que reducen los 9,5 millones de predios iniciales a aproximadamente 3.600 candidatos: filtro de superficie y destino (SII), uso de suelo permitido según el Instrumento de Planificación Territorial, exclusión por proximidad a equipamientos sensibles (colegios, hospitales, cementerios, iglesias a menos de 50 m), compatibilidad con el patrón vial de las 2.017 bencineras existentes, y umbral mínimo de densidad de dispositivos GPS en radio de 500 m.

La **Fase B** enriquece los candidatos con cuatro métricas adicionales: extrapolación censal de población, clasificación satelital automática mediante CLIP ViT-B-32 para descartar predios con estructuras existentes, precios actuales de combustible de la API de la CNE, y conteo vehicular estimado mediante el modelo de tráfico BPR (*Bureau of Public Roads*) con datos de Google Routes API en modo `TRAFFIC_AWARE`.

Modelo de scoring

El score final de cada candidato combina cuatro componentes normalizados intra-regionalmente, cuyos pesos fueron determinados mediante dos criterios complementarios:

$$S = 0,60 \cdot S_{\text{veh}} + 0,20 \cdot S_{\text{precio}} + 0,15 \cdot S_{\text{ruta}} + 0,05 \cdot S_{\text{mov}} \quad (7.1)$$

donde S_{veh} es el flujo vehicular estimado (veh/hora) mediante el modelo BPR, S_{precio} es el precio promedio de combustible en zona de 5 km (mayor precio implica mayor margen potencial), S_{ruta} es el tipo de vía OSM ponderado por el patrón de las bencineras existentes, y S_{mov} es la densidad de dispositivos GPS únicos como *proxy* de actividad humana.

El componente S_{ruta} (15%) se calibró empíricamente a partir del patrón orgánico de localización de las 2.017 estaciones de servicio existentes en Chile: cada bencinera fue matcheada a su segmento OSM más cercano, se contó la distribución por `fclass`, y los pesos de cada categoría vial se normalizaron proporcional a esa distribución real. Los tipos de vía con mayor concentración de estaciones reciben mayor peso;

los tipos sin presencia empírica son excluidos del scoring.

Los pesos de los tres componentes restantes (tráfico vehicular 60%, precio zona 20%, movilidad GPS 5%) constituyen una decisión de diseño basada en la lógica sectorial del negocio de combustibles: el flujo vehicular es el determinante primario del volumen de ventas de una estación de servicio —una estación sin tráfico no es viable independientemente de las demás variables—, el precio de zona captura el margen potencial, y la movilidad GPS opera como indicador complementario de actividad. Los pesos fueron refinados iterativamente a lo largo del desarrollo del sistema, pasando de un modelo inicial con dos variables (tipo de vía y edificación) a la formulación de cuatro componentes presentada aquí. Una calibración estadística formal de estos pesos requeriría datos de ventas reales por estación, que no están disponibles públicamente en Chile.

El componente de mayor peso, el conteo vehicular (60%), se estima invirtiendo la fórmula BPR:

$$\frac{V}{C} = \left(\frac{v_{\text{libre}}/v_{\text{tráfico}} - 1}{0,15} \right)^{0,25} \quad (7.2)$$

donde v_{libre} y $v_{\text{tráfico}}$ son las velocidades sin y con congestión obtenidas de Google Routes API, y C es la capacidad vial HCM según el tipo de vía (motorway: 4.400 veh/h; primary: 1.600; secondary: 800; residential: 300).

Dashboard interactivo

El resultado del pipeline es un dashboard React accesible en `combustible.tremen.tech` (protegido por Cloudflare Access) que presenta los 50 mejores candidatos por región en un mapa Leaflet con tiles satelitales HERE Maps y una tabla ordenable con 20 columnas (scores, métricas de tráfico, precios de combustible por tipo). La exportación de candidatos genera un bundle ZIP con un archivo Excel y un KMZ para Google Earth, con los placemarks coloreados por score.

Evaluación de puntos arbitrarios

Además del análisis masivo de predios catastrados, la plataforma incorpora una funcionalidad de evaluación bajo demanda: el botón **Evaluar Punto** permite al usuario ingresar las coordenadas geográficas de cualquier ubicación (latitud y longitud) o cargar un archivo KML/KMZ proveniente de Google Earth o un GPS




Figura 7.3: Dashboard de `combustible.tremen.tech`: mapa Leaflet con los predios candidatos para la comuna de Arica (37 predios, coloreados por score) y tabla interactiva con métricas de tráfico, superficie, destino y valor de suelo. Disponible en <https://combustible.tremen.tech>.

externo. El sistema ejecuta entonces el pipeline completo de 10 pasos sobre esa ubicación específica, devolviendo en tiempo real —mediante Server-Sent Events— el score compuesto, las métricas de tráfico BPR, el tipo de vía OSM, la densidad de dispositivos GPS y el precio de combustible en zona de influencia de 5 km.

Esta funcionalidad es especialmente relevante para puntos que no están en el catastro del SII —por ejemplo, un terreno en proceso de subdivisión, un predio con rol reciente que no ha sido procesado aún, o una ubicación hipotética que el cliente quiere evaluar antes de iniciar el proceso de compra. El análisis de evaluación individual tarda entre 15 y 45 segundos dependiendo de la latencia de las APIs externas (Google Routes, CNE) y produce el mismo informe exportable en Excel y KMZ que el análisis masivo. Esto convierte la plataforma en una herramienta de soporte a la toma de decisiones tanto para análisis exploratorios a escala nacional como para la validación de oportunidades específicas en negociación.

Conexión directa con los casos de uso de la tesis

La plataforma Combustible es la demostración empírica de los tres casos de uso descritos en las subsecciones anteriores: la prospección por destino y superficie (filtro inicial ERIAZO/COMERCIO, 1.200–5.000 m²) corresponde exactamente a la consulta SQL de la Sección 4.2.2; la identificación de suelo subutilizado (predios eriazos




Figura 7.4: Modal de **Evaluar Punto** en **combustible.tremen.tech**: el usuario ingresa coordenadas o sube un archivo KML/KMZ y recibe el análisis completo del pipeline en tiempo real.

en zonas de alto tráfico) corresponde a la Sección 4.2.3; y el informe exportable en Excel y KMZ con scores cuantitativos es la forma concreta del due diligence con datos objetivos descrito en la Sección 4.2.4. Sin el pipeline de extracción catastral y el dataset predial nacional, esta plataforma simplemente no podría existir.

7.5 Impacto público y democratización de la información

7.5.1 Acceso antes y después de Catastral.cl

La Tabla 7.7 contrasta la situación de distintos actores antes de este trabajo y después de la disponibilidad de la plataforma Catastral.cl.

El impacto es estructuralmente asimétrico: los actores más beneficiados son quienes tenían menor capacidad de pagar por datos privados. Un investigador de una universidad regional o un periodista de datos de un medio independiente pasan de no tener acceso a disponer del mismo dataset que una consultora inmobiliaria de primer nivel, con la diferencia de que ahora lo pueden consultar en un navegador sin escribir una línea de código ([Open Knowledge Foundation, 2023](#); [Biblioteca del Congreso Nacional de Chile, 2008](#)).

Tabla 7.7: Cambio en el acceso a datos prediales según tipo de actor

Actor	Antes	Después (Catastral.cl)
Broker inmobiliario	Bases privadas, costo elevado	Exploración gratuita + descarga enriquecida por comuna
Investigador académico	Sin datos a escala nacional	9,4M predios + 136M filas históricas consultables vía API
PyME / emprendedor	Sin acceso práctico	Dataset descargable en CSV/-GeoJSON/GPKG vía pago social
Periodista de datos	Sin geometría catastral	Mapas verificables con polígonos de 30 cm de precisión
Municipio / planificador	WMS no analizable	Dataset SQL-consultable + descarga GeoPackage lista para QGIS
Ciudadano	Portal predio a predio (manual)	Búsqueda por dirección con mapa, historial de avalúos 7 años
Institución / universidad	Acceso ad hoc, sin escala	Domain grant institucional, acceso para todos los emails del dominio

7.5.2 Observaciones preliminares sobre la recepción

Tras la publicación de la plataforma en redes profesionales, se recibieron comentarios espontáneos de profesionales del sector geoespacial, inmobiliario y de datos públicos en Chile. Si bien estos comentarios no constituyen una evaluación formal —no provienen de una muestra representativa ni de un panel de expertos estructurado—, resultan útiles como evidencia anecdótica de la existencia de demanda insatisfecha por datos catastrales accesibles, y como indicadores exploratorios de los perfiles de potenciales usuarios.

Se identificaron tres categorías recurrentes en los comentarios recibidos. La primera agrupa a profesionales con necesidades técnicas concretas: desarrolladores de productos geoespaciales que reportaron la inestabilidad del WMS del SII y la ausencia de servicios WFS como barreras para integrar datos catastrales en flujos de trabajo SIG, y consultores que necesitaban los datos para construir herramientas de geocodificación y validación de direcciones.

La segunda categoría corresponde a actores del sector público e investigación que expresaron demanda por datos abiertos. Un caso notable es el de un investigador en planificación urbana que declaró haber recurrido al Consejo de la Transparencia

—mecanismo legal de último recurso bajo la Ley 20.285 ([Biblioteca del Congreso Nacional de Chile, 2008](#))— como vía para obtener los polígonos catastrales que esta tesis extrae del WMS.

La tercera categoría agrupa a profesionales del sector privado interesados en aplicaciones comerciales del dataset, desde consultoras inmobiliarias hasta operadores de infraestructura.

Estas observaciones, aunque exploratorias, son consistentes con el diagnóstico de las tres barreras planteado en el Capítulo 1 y sugieren que la demanda abarca perfiles heterogéneos. Una evaluación rigurosa del impacto de la plataforma requeriría un estudio de usuarios con metodología formal (encuestas estructuradas, entrevistas en profundidad o análisis de logs de uso), lo cual queda fuera del alcance de esta tesis pero constituye una línea de trabajo futuro relevante.

7.5.3 Escalabilidad del modelo a América Latina

El método desarrollado no es exclusivo de Chile ni del SII. Varios países de América Latina publican sus catastros prediales en servicios WMS similares (OGC-compatible) con restricciones análogas: el dato existe, es técnicamente público, pero no está disponible en formato analítico. Perú (COFOPRI), Colombia (IGAC) y México (INEGI) cuentan con servicios WMS de catastro que potencialmente son vectorizables con el mismo pipeline, adaptando los parámetros de capa, estilo y valor DN. La arquitectura de 30 túneles WireGuard con rotación automática de IP es igualmente aplicable a cualquier API que imponga *rate limiting* por dirección IP ([Donenfeld, 2017](#)).

La condición técnica necesaria para replicar el método es que el servidor GeoServer (o equivalente) use un valor de píxel distinto para el interior de los predios respecto al fondo del mapa. Esta condición se cumple en todos los servidores WMS evaluados como referencia, dado que es el comportamiento por defecto del estilo SLD de GeoServer al renderizar capas catastrales.

Capítulo 8

Discusión, Limitaciones y Conclusiones

Este capítulo presenta las limitaciones técnicas y metodológicas del trabajo, las conclusiones derivadas de los resultados del Capítulo 4, y las líneas de investigación y desarrollo futuro que se derivan de esta AFE.

8.1 Limitaciones

8.1.1 Dependencia del renderizado WMS del SII

El pipeline completo depende de que el SII mantenga activo su servicio WMS con el mismo estilo cartográfico (`PREDIOS_WMS_V0`) y el mismo valor `DN=182` para los predios. Un cambio en el esquema de colores del servidor invalidaría el filtro de polygonización y requeriría re-descubrir el nuevo valor `DN`. Esta dependencia es inherente al método de vectorización raster y no tiene solución sin acceso a los datos vectoriales originales del SII ([GeoServer Project Steering Committee, 2024](#)).

8.1.2 Predios con colores especiales

Durante el desarrollo se observó que algunos predios aparecen en el WMS con colores distintos al estándar `DN=182`. Los casos documentados incluyen predios en litigio, predios de organismos del Estado y predios con alguna observación administrativa. Estos predios están presentes en el mapa visual pero no son capturados por el filtro `DN=182`, quedando sin geometría en el dataset final. Su fracción es pequeña (esti-

mada en menos del 1% del total), pero puede ser relevante en zonas de alta densidad de predios fiscales.

8.1.3 Ausencia de validación externa

El sistema de QA implementado (Fase 7) verifica la consistencia interna del pipeline: integridad de filas, presencia de columnas esperadas, validez topológica de polígonos y contención dentro de los bounds geográficos de Chile. Sin embargo, no se realizó una validación contra una fuente de verdad externa (*ground truth*). La cifra de 60,3% de cobertura nacional describe el resultado del pipeline, pero no garantiza la corrección geométrica de los polígonos producidos.

Una validación rigurosa requeriría comparar los polígonos vectorizados con geometrías catastrales oficiales del Conservador de Bienes Raíces (CBR) o del MINVU para una muestra de comunas. En Chile, estas fuentes no están disponibles en formato vectorial abierto, lo que dificulta la comparación directa. No obstante, una inspección visual selectiva sobre el WMS del SII muestra que los polígonos vectorizados coinciden con los bordes renderizados del mapa, lo cual es esperable dado que el pipeline extrae exactamente la información visual del WMS. La fuente de error geométrico principal es la resolución de 30 cm/píxel, que introduce una incertidumbre de ± 1 píxel en los bordes de cada polígono.

8.1.4 Sesgo geográfico del 39,7% sin polígono

Es importante advertir que el 39,7% de predios sin polígono vectorial no se distribuye aleatoriamente en el territorio nacional. La fracción sin geometría se concentra en comunas rurales y agrícolas donde el SII no ha realizado levantamiento cartográfico digital: comunas como Guaitecas, Torres del Paine y San Juan de la Costa presentan más del 80% de sus predios sin polígono, mientras que las comunas del Gran Santiago superan el 97% de cobertura. Este sesgo implica que cualquier análisis espacial derivado del dataset —incluyendo los casos de uso presentados en el Capítulo 4— tiene una representatividad significativamente menor en zonas rurales, agrícolas y de baja densidad poblacional. Los resultados y conclusiones de esta tesis no deben extrapolarse a zonas rurales sin considerar esta limitación.

8.1.5 Precisión geométrica de 30 centímetros

La resolución de ≈ 30 cm/px en zoom 19 implica que los polígonos vectorizados tienen una precisión máxima de 1 píxel, equivalente a 30 cm en el terreno. Para análisis a escala de predio esto es más que suficiente: el error es menor que el espesor de un muro. Sin embargo, para aplicaciones que requieren precisión catastral legal (deslindes, subdivisiones, expropiaciones), los polígonos de este dataset no reemplazan a los planos oficiales del Conservador de Bienes Raíces (CBR). Son una aproximación de alta calidad útil para análisis, no un sustituto del instrumento legal.

8.2 Conclusiones

Esta tesis abordó el problema de la inaccesibilidad práctica de los datos catastrales del SII chileno mediante el diseño e implementación de un pipeline de extracción y una plataforma de distribución. Los resultados cuantitativos obtenidos son: 9,55 millones de predios con atributos tabulares completos, 5,67 millones con polígono vectorial de ≈ 30 cm de precisión (60,3% de cobertura nacional), 16 semestres de series históricas de avalúo (136 millones de filas), y 342 comunas disponibles para descarga en formatos analíticos a través de la plataforma Catastral.cl. A partir de estos resultados se derivan las siguientes conclusiones.

Primera conclusión: las barreras de acceso son técnicas, no legales, y son superables mediante ingeniería de datos. La hipótesis planteada en el Capítulo 1 queda confirmada. La Ley de Transparencia ([Biblioteca del Congreso Nacional de Chile, 2008](#)) garantiza formalmente el acceso a los datos catastrales, pero la barrera efectiva reside en los formatos de publicación: texto de ancho fijo sin estructura, API unitaria sin endpoint masivo, y geometría disponible únicamente en formato raster. Superar estas barreras requirió combinar parseo de formato propietario, extracción distribuida con 30 túneles WireGuard y vectorización raster con GDAL. Este resultado indica que la inaccesibilidad del dato catastral chileno es un problema de ingeniería, no de política pública, y que la solución es técnicamente reproducible.

Segunda conclusión: la distribución del dato es condición necesaria para su impacto. La existencia de un dataset almacenado en un sistema de archivos no constituye, por sí sola, democratización del acceso. La plataforma Catastral.cl cumple la función de transformar el resultado técnico del pipeline en un servicio consultable sin requerir conocimientos de programación ni software especializado.

De forma complementaria, la plataforma Combustible (`combustible.tremen.tech`) demuestra que el mismo dataset puede funcionar como capa base de aplicaciones analíticas especializadas, en este caso un sistema de prospección de ubicaciones para estaciones de servicio que reduce el tiempo de análisis de semanas a minutos.

Tercera conclusión: la metodología es potencialmente transferible a otros catastros de la región. Varios países de América Latina publican catastros prediales mediante servicios WMS compatibles con OGC, entre ellos Perú (COFOPRI), Colombia (IGAC) y México (INEGI) ([Open Geospatial Consortium, 2006](#)). La arquitectura técnica desarrollada (túneles WireGuard, polygonización GDAL, spatial join con GeoPandas, API FastAPI, base de datos PostGIS) es independiente del SII chileno y aplicable a cualquier servidor WMS que utilice valores de píxel diferenciados por tipo de elemento cartográfico. La validación de esta transferibilidad requeriría estudios específicos por país, considerando las particularidades de cada infraestructura catastral.

Cuarta conclusión: el trabajo constituye un argumento empírico a favor de la apertura de datos catastrales. Si el Estado chileno publicara los datos catastrales directamente en formato vectorial abierto (GeoJSON, GeoPackage o Parquet georreferenciado), el esfuerzo técnico documentado en esta tesis resultaría innecesario. El costo marginal de publicar un archivo con los polígonos prediales es bajo para una institución que ya dispone de la información en formato vectorial internamente. El beneficio potencial para investigadores, planificadores urbanos, pequeñas empresas y ciudadanos sería significativo ([Janssen et al., 2012](#); [Attard et al., 2015](#)). En este sentido, el pipeline de extracción catastral y la plataforma Catastral.cl pueden interpretarse como evidencia de que existe demanda no satisfecha por datos abiertos catastrales, y como un argumento técnico a favor de que el SII actualice sus estándares de publicación ([Biblioteca del Congreso Nacional de Chile, 2008](#); [Open Knowledge Foundation, 2023](#)).

8.3 Trabajo futuro

8.3.1 Validación muestral con datos catastrales de referencia

Una línea de trabajo futuro relevante sería realizar una validación muestral sobre 5–10 comunas donde existan datos catastrales vectoriales de referencia (por ejemplo, municipalidades que hayan digitalizado sus planos reguladores), cuantificando

métricas como el IoU (*Intersection over Union*) entre los polígonos del pipeline y los polígonos de referencia. Asimismo, un estudio futuro podría cuantificar la correlación entre la cobertura del pipeline y variables socioeconómicas comunales para caracterizar formalmente el sesgo de selección descrito en la sección anterior.

8.3.2 Sat-Catastral: validación del uso de suelo mediante series de tiempo satelitales

Una limitación del dataset actual es que refleja la clasificación de uso de suelo declarada por el SII, sin verificación independiente de si dicha clasificación corresponde al uso real del predio. Esta brecha es especialmente relevante en predios agrícolas, donde la clasificación SII determina la carga tributaria y donde la discrepancia entre el uso declarado y el uso efectivo puede ser significativa.

Una línea de trabajo futuro es **Sat-Catastral**: un sistema que cruza cada predio del dataset con series de tiempo de imágenes satelitales de alta resolución, aplicando modelos de visión computacional para determinar si el uso real del suelo coincide con el destino predial registrado. El enfoque propuesto utiliza **GeoSAM** (*Geospatial Segment Anything Model*), implementado como plugin de QGIS (<https://plugins.qgis.org/plugins/GeoOSAM/>), para segmentar automáticamente los objetos presentes en cada predio (cultivos, construcciones, suelo desnudo, cuerpos de agua) y comparar los resultados con la descripción de destino del SII. La hipótesis es que una fracción no despreciable de los predios clasificados como agrícolas presenta en imagen satelital patrones inconsistentes con uso agropecuario activo (por ejemplo, suelo urbanizado, instalaciones industriales o abandono), lo que podría indicar errores de clasificación con implicancias tributarias.

8.3.3 Valori: impugnación de avalúos ante el SII mediante analítica catastral

El dataset predial nacional que esta AFE produce es también la base de una aplicación comercial de analítica tributaria. La plataforma **Valori** (<https://valori.tremen.tech>) utiliza los atributos de avalúo fiscal, superficie, destino predial y valor comercial de suelo por área homogénea para identificar predios que pagan contribuciones de bienes raíces en exceso respecto de lo que correspondería según los parámetros del propio SII.

El mecanismo es el siguiente: cuando el avalúo fiscal de un predio supera el valor

que resulta de aplicar los coeficientes oficiales del SII a sus características físicas (superficie, destino, área homogénea), el propietario puede impugnar el avalúo ante el organismo y solicitar su rectificación. Si la impugnación prospera, el SII debe devolver las contribuciones pagadas en exceso con efecto retroactivo de hasta tres años. Valori automatiza la detección de estos casos sobre el universo completo de predios del dataset, priorizando aquellos con mayor probabilidad de impugnación exitosa y mayor monto de devolución potencial. Este caso de uso ilustra de forma concreta el impacto económico directo que tiene la disponibilidad del dato catastral en formato analítico: sin el dataset producido por esta AFE, el análisis sería inviable a escala nacional.

8.3.4 Integración futura con el CBR

El Conservador de Bienes Raíces publica escrituras, inscripciones y planos de subdivisión en formato PDF. La integración de esta fuente (extracción de planos técnicos + OCR de datos de inscripción) con el dataset del SII permitiría construir un grafo de propiedad que vincule el predio físico con el historial de transacciones, la cadena de dominio y el propietario actual. Este es el paso natural siguiente para un sistema de inteligencia inmobiliaria completo basado exclusivamente en fuentes públicas chilenas.

Referencias

- Akerlof, G. A. (1970). The market for “lemons”: Quality uncertainty and the market mechanism. *The Quarterly Journal of Economics*, 84(3):488–500.
- Attard, J., Orlandi, F., Scerri, S., and Auer, S. (2015). A systematic review of open government data initiatives. *Government Information Quarterly*, 32(4):399–418.
- Biblioteca del Congreso Nacional de Chile (2008). Ley n° 20.285: Sobre acceso a la información pública. <https://www.bcn.cl/leychile/Navegar?idNorma=276363>. Publicada en el Diario Oficial el 20 de agosto de 2008.
- Broxterman, D. and Zhou, T. (2023). Information frictions in real estate markets: Recent evidence and issues. *Journal of Real Estate Finance and Economics*, 66(2):203–298.
- CEPAL (2022). Datos y hechos sobre la transformación digital: informe sobre los principales indicadores de adopción de tecnologías digitales. Comisión Económica para América Latina y el Caribe. <https://www.cepal.org/es/publicaciones/46766-datos-hechos-la-transformacion-digital-informe-principales-indicadores-adopcion>.
- Cetl, V., Šamanović, S., Bjelotomić Oršulić, O., and Lisec, A. (2023). Building a cadastral map of Europe through the INSPIRE and other related initiatives. *Land*, 12(7):1462.
- Deininger, K. and Feder, G. (2009). Land registration, governance, and development: Evidence and implications for policy. *The World Bank Research Observer*, 24(2):233–266.
- DiPasquale, D. and Wheaton, W. C. (1996). *Urban Economics and Real Estate Markets*. Prentice Hall, Englewood Cliffs, NJ.
- Donenfeld, J. A. (2017). WireGuard: Next generation kernel network tunnel. In

- Proceedings of the Network and Distributed System Security Symposium (NDSS)*. San Diego, CA. Disponible en wireguard.com/papers/wireguard.pdf.
- European Data Portal (2020). The economic impact of open data: Opportunities for value creation in Europe. <https://data.europa.eu/en/doc/economic-impact-open-data-opportunities-value-creation-europe>. Comisión Europea. Accedido: 2026-03-15.
- GDAL/OGR contributors (2024). GDAL: Geospatial data abstraction library. OS-Geo. <https://gdal.org>. Accedido: 2026-01-10.
- GeoServer Project Steering Committee (2024). GeoServer: Open source server for sharing geospatial data. <https://geoserver.org>. Accedido: 2026-01-10.
- Gillies, S. et al. (2024a). Rasterio: Geospatial raster I/O for Python programmers. <https://rasterio.readthedocs.io>. Versión 1.3. Accedido: 2026-01-10.
- Gillies, S. et al. (2024b). Shapely: Manipulation and analysis of geometric objects. PyPI / GitHub. <https://shapely.readthedocs.io>. Accedido: 2026-01-10.
- Janssen, M., Charalabidis, Y., and Zuiderwijk, A. (2012). Benefits, adoption barriers and myths of open data and open government. *Information Systems Management*, 29(4):258–268.
- Jordahl, K., Van den Bossche, J., Fleischmann, M., Wasserman, J., McBride, J., Gerard, J., et al. (2024). GeoPandas v0.14.3. Zenodo. <https://zenodo.org/records/10601680>. DOI: 10.5281/zenodo.10601680.
- Linux man-pages project (2024). `network_namespaces(7)` — Linux manual page. https://man7.org/linux/man-pages/man7/network_namespaces.7.html. Documentación oficial del kernel Linux. Accedido: 2026-01-10.
- McKinsey Global Institute (2013). Open data: Unlocking innovation and performance with liquid information. <https://www.mckinsey.com/business-functions/mckinsey-digital/our-insights/open-data-unlocking-innovation-and-performance-with-liquid-information>. Estimación: USD 3–5 billones anuales en valor potencial global.
- Open Geospatial Consortium (2006). OpenGIS® web map service (WMS) implementation specification, version 1.3.0. <https://www.ogc.org/standards/wms/>. OGC Document 06-042.

- Open Knowledge Foundation (2023). The open data handbook. <https://opendatahandbook.org/>. Accedido: 2026-01-10.
- Redman, T. C. (2008). *Data Driven: Profiting from Your Most Important Business Asset*. Harvard Business School Press, Boston, MA.
- Servicio de Impuestos Internos (2025). Estructura de archivo para rol semestral de contribuciones de bienes raíces. Documento técnico oficial. Disponible en https://www4.sii.cl/sismunInternet6/?caller=DETALLE_CAT_Y_ROL_COBRO (requiere autenticación con RUT y clave SII). Accedido: 2026-03-01.
- Stiglitz, J. E. (2000). The contributions of the economics of information to twentieth century economics. *The Quarterly Journal of Economics*, 115(4):1441–1478.
- Williamson, C. R. and Kerekes, C. B. (2011). Securing private property: Formal versus informal institutions. *The Journal of Law and Economics*, 54(3):537–572.
- World Bank (2021). World development report 2021: Data for better lives. <https://www.worldbank.org/en/publication/wdr2021>. Washington, DC: World Bank. DOI: 10.1596/978-1-4648-1600-0.
- Zuiderwijk, A. and Janssen, M. (2014). Open data policies, their implementation and impact: A framework for comparison. *Government Information Quarterly*, 31(1):17–29.