



UNIVERSIDAD
DE CHILE

UNIVERSIDAD DE CHILE

FACULTAD DE CIENCIAS FÍSICAS Y MATEMÁTICAS

FACULTAD DE ECONOMÍA Y NEGOCIOS

**“Catálogos estructurados de productos para
compras públicas basados en NLP y
modelos de lenguaje. Aplicación a Compra
Ágil y comparación con Convenio Marco”**

**ACTIVIDAD FORMATIVA EQUIVALENTE A TESIS PARA OPTAR AL
GRADO DE MAGÍSTER EN ANALÍTICA DE NEGOCIOS**

Estudiante: Pablo Andrés Quintanilla Medina

Profesor Guía: Marcelo Olivares

Profesora Co-Guía: Cinthya Vergara

Santiago, Agosto 2026

Dedicatoria

A mi familia, por su apoyo incondicional durante todo el proceso de formación, investigación y desarrollo de este trabajo. En especial, a mi esposa Andrea, por su comprensión, paciencia, compañía y constante motivación, fundamentales para alcanzar esta importante etapa.

Agradecimientos

Agradezco sinceramente a todas las personas que me acompañaron durante este proceso académico y profesional. Sus orientaciones, observaciones y experiencias fueron fundamentales para el desarrollo de esta investigación.

También agradezco la disponibilidad de las fuentes de información pública y de la infraestructura de Mercado Público, que hicieron posible este trabajo aplicado.

Finalmente, valoro especialmente la retroalimentación recibida durante el desarrollo de la Actividad Formativa Equivalente a Tesis, ya que permitió fortalecer la metodología, las validaciones y la calidad final de esta investigación.

Tabla de contenido

Dedicatoria.....	2
Agradecimientos.....	3
Índice de ilustraciones y cuadros.....	6
Resumen ejecutivo.....	8
Abstract.....	9
1. Introducción.....	10
2. Planteamiento y formulación del problema.....	13
3. Hipótesis.....	16
4. Objetivos.....	18
4.1 Objetivo general.....	18
4.2 Objetivos específicos.....	18
5. Metodología propuesta.....	20
5.1 Etapas metodológicas.....	23
5.2 Recopilación y preparación de datos.....	23
5.3 Normalización y control de calidad.....	24
5.4 Modelamiento y evaluación.....	25
5.5 Recomendación y validación de decisión.....	26
6. Marco teórico y revisión de la literatura.....	28
6.1 Compras públicas y analítica de decisiones.....	28
6.2 Datos maestros, catálogos y calidad de datos.....	29
6.3 Procesamiento de lenguaje natural aplicado a texto transaccional....	30
6.4 TF-IDF, embeddings y modelos de lenguaje.....	31
6.5 Validación de modelos y selección multicriterio.....	33
6.6 Estadística robusta y precios de referencia.....	34
7. Arquitectura de la solución analítica.....	36
7.1 Visión general y principios de diseño.....	37
7.2 Ingesta y homologación de fuentes.....	38
7.3 Normalización y estandarización semántica.....	39
7.4 Taxonomía y diccionario estructurado.....	40
7.5 Representación semántica y clasificación.....	40
7.6 Calibración de precios y comparación.....	41
7.7 Recomendación y generación de evidencia.....	42
7.8 Validación, indicadores y selección del modelo final.....	43
7.9 Validación de precios y recomendador.....	46

7.10 Propuesta de estructura de información para Compra Ágil.....	47
8. Resultados, análisis y discusión de evidencias.....	49
8.1 Volumen de datos procesados.....	50
8.2 Comparación de modelos de embedding.....	51
8.3 Desempeño de clasificación: datos limpios (CM) frente a datos reales (CA).....	53
8.4 Evaluación de la extracción de atributos con un conjunto de prueba revisado manualmente.....	55
8.5 Calibración y comparación de precios.....	58
8.6 Contraste de hipótesis.....	62
8.7 Discusión.....	62
9. Implementación institucional y gobernanza.....	65
10. Conclusiones.....	67
10.1 Reflexión por objetivo específico.....	69
10.2 Estado de las hipótesis.....	72
10.3 Trabajo futuro.....	74
10.4 Recomendaciones.....	74
10.5 Recomendación principal: rediseño de la estructura de información de Compra Ágil.....	76
11. Bibliografía.....	82
Anexos.....	85
Anexo A. Mapa de variables y campos sugeridos.....	85
Anexo B. Pseudo-código del pipeline.....	85
Anexo C. Conjunto de prueba de extracción de atributos revisado manualmente.....	86
Anexo D. Resultados detallados de la corrida (04/05/2026).....	88

Índice de ilustraciones y cuadros

Figura 1. Flujograma metodológico de la solución propuesta.

Figura 2. Arquitectura conceptual del sistema de catálogo estructurado.

Figura 3. Panel de indicadores clave (KPI) generado por la corrida.

Figura 4. Comparación de los cuatro modelos de embedding en los seis indicadores.

Figura 5. Dashboard de resultados de la corrida.

Figura 6. Calibración de precios de Compra Ágil: métricas evaluadas.

Figura 7. Comparación de precios CM y CA por categoría (precios calibrados).

Figura 8. Caso de prueba del recomendador de precios (tónor).

Figura D1. Procesamiento de Compras Ágiles y auditoría de calidad por dominio.

Figura D2. Procesamiento de Convenios Marco por dominio.

Figura D3. Diccionario estructurado: categorías y precios.

Figura D4. Registro de ejecución del pipeline de clasificación multi-dominio.

Figura D5. Métricas de precio por categoría (extracto de la corrida).

Tabla 1. Relación entre problema de información y consecuencia decisional.

Tabla 2. Etapas del pipeline analítico y su propósito.

Tabla 3. Bibliografía base y tipo de aporte al estudio.

Tabla 4. Indicadores considerados para la evaluación de modelos de embedding.

Tabla 5. Ponderación propuesta para selección del modelo semántico.

Tabla 6. Estructura de datos recomendada para Compra Ágil.

Tabla 7. Volumen de datos cargados por fuente y dominio.

Tabla 8. Indicadores por modelo de embedding.

Tabla 9. Contraste entre validación sobre datos limpios y aplicación sobre datos reales.

Tabla 10. Cierre de hipótesis con evidencia empírica.

Tabla 11. Estructura mínima obligatoria para Compra Ágil.

Tabla C1. Conjunto de prueba de extracción de atributos (45 casos).

Resumen ejecutivo

Esta Actividad Formativa Equivalente a Tesis desarrolla una solución analítica para transformar las descripciones no estructuradas de Compra Ágil en un catálogo de productos comparable y auditable. La modalidad registra las compras como texto libre, con unidades ambiguas, marcas mezcladas con especificaciones y montos difíciles de homologar, lo que limita la comparación de precios. El enfoque integra normalización de texto, una taxonomía basada en Convenio Marco, embeddings multilingües, calibración de precios y un recomendador de modalidad de compra. Los resultados muestran que la principal limitación es informacional: en Convenio Marco la clasificación alcanza un F1 de 0,89, mientras que en Compra Ágil la confianza media desciende a 0,41, no se detectan marcas y el 75 % de los registros no admite dominio. Se concluye que el sistema permite generar recomendaciones basadas en Convenio Marco y se propone una estructura mínima de captura (categoría, unidad, cantidad, marca, atributos técnicos y desglose de costos) para mejorar progresivamente la comparación. El sistema se concibe como apoyo a la decisión, con revisión humana.

Abstract

This Thesis-Equivalent Capstone Project develops an analytical solution to transform unstructured descriptions from Chilean Agile Purchasing into a comparable and auditable product catalog. Purchases under this modality are recorded as free text, with ambiguous units, brands mixed with specifications, and amounts that are difficult to standardize, limiting price comparison. The approach integrates text normalization, a taxonomy based on Framework Agreements, multilingual embeddings, price calibration, and a purchasing-mode recommender. The results show that the main limitation is informational: classification on Framework Agreement data achieves an F1 score of 0.89, whereas mean confidence on Agile Purchasing data decreases to 0.41, no brands are detected, and 75% of the records cannot be assigned to a domain. It is concluded that the system can generate recommendations based on Framework Agreements, and a minimum data-capture structure is proposed (including category, standardized unit and quantity, brand, technical attributes, and cost breakdown) to progressively improve comparison. The system is conceived as a decision-support tool subject to human review.

1. Introducción

Las compras públicas cumplen una función estratégica en el Estado, porque conectan la asignación presupuestaria con la provisión efectiva de bienes y servicios para la ciudadanía. Cuando una institución pública adquiere alimentos, computadores, mobiliario, insumos médicos, artículos de oficina o productos de aseo, la decisión no solo afecta el gasto de una unidad compradora, sino también la eficiencia del uso de recursos públicos, la competencia entre proveedores y la transparencia del proceso.

La digitalización de las compras públicas ha generado grandes volúmenes de datos transaccionales. Sin embargo, la existencia de datos no garantiza automáticamente información útil para decidir. En particular, los registros de productos pueden contener texto libre, abreviaciones, errores ortográficos, unidades implícitas, marcas y modelos mezclados con la descripción, y diferencias importantes en el nivel de detalle. Esta heterogeneidad vuelve difícil responder preguntas operativas simples: qué se compró, si el producto existe en un catálogo, si el precio está dentro de un rango razonable y qué alternativas comparables existen.

Compra Ágil (CA) es una modalidad relevante porque busca simplificar adquisiciones de menor monto y facilitar la participación de proveedores. Con la modernización normativa, el umbral se elevó a 100 UTM, lo que amplía el universo de decisiones donde se requiere rapidez, trazabilidad y comparación suficiente. La simplificación del procedimiento, sin embargo, aumenta la importancia de contar con datos claros: si los productos se describen de manera ambigua, la comparación entre cotizaciones puede depender excesivamente del juicio manual del comprador (ChileCompra, s. f.) (Biblioteca del Congreso Nacional de Chile, 2023; ChileCompra, 2024).

Convenio Marco (CM), por su parte, ofrece una fuente de referencia más estructurada. Sus registros suelen incluir categorías, códigos, marcas, modelos, proveedores y precios de catálogo. Esta mayor estructura no significa que Convenio Marco sea una fuente perfecta ni que todos sus productos sean comparables con Compra Ágil, pero sí permite construir una base semántica y taxonómica más estable que puede ser utilizada como referencia para clasificar productos y calibrar precios.

La presente Actividad Formativa Equivalente a Tesis propone una solución de analítica de negocios que combina procesamiento de lenguaje natural, modelos de lenguaje, reglas de negocio y estadística robusta para

clasificar productos, comparar precios y recomendar decisiones de compra. El sistema toma como entrada las descripciones de Compra Ágil, las normaliza, las clasifica contra una taxonomía construida desde Convenio Marco, recupera productos comparables, calibra precios de referencia y genera alertas y recomendaciones con un nivel de confianza asociado. El informe se organiza como sigue: el capítulo 2 formula el problema; los capítulos 3 y 4 presentan las hipótesis y los objetivos; el capítulo 5 describe la metodología; el 6 desarrolla el marco teórico; el 7 detalla la arquitectura de la solución; el 8 presenta los resultados empíricos; el 9 aborda la implementación y la gobernanza; y el 10 concluye cerrando objetivos e hipótesis.

Tabla 1. Relación entre problema de información y consecuencia decisional.

Problema observado	Consecuencia para la decisión	Respuesta analítica propuesta
Descripción en texto libre	Dificulta identificar productos equivalentes y agrupar compras históricas.	Normalización NLP, embeddings y reglas léxicas.
Unidades de medida ambiguas	Impide comparar precios unitarios y detectar sobrepuestos.	Extracción de cantidad, unidad y unidad comparable.
Marca y modelo mezclados	Reduce precisión semántica y genera falsos comparables.	Extracción de marca y atributos técnicos.
Códigos ONU/UNSPSC faltantes o amplios	Debilita la taxonomía y la trazabilidad.	Uso combinado de código, texto y categoría inferida.
Precios históricos heterogéneos	Puede comparar montos no equivalentes.	Filtro de calidad, percentiles y mediana robusta.

2. Planteamiento y formulación del problema

El problema central de esta AFE es de toma de decisiones basada en datos. Las instituciones que utilizan Compra Ágil deben seleccionar alternativas en plazos acotados y con información limitada. La normativa exige cotizar, comparar y justificar, pero la calidad de esa comparación depende de la estructura de los datos disponibles. Si la información del producto no permite identificar atributos técnicos mínimos, la decisión puede apoyarse en precios totales, descripciones incompletas o experiencia individual, en lugar de evidencia sistemática.

La dificultad se observa especialmente cuando se desea comparar Compra Ágil con Convenio Marco. Un producto descrito como “notebook i5 8gb ssd” puede corresponder a múltiples configuraciones de procesador, generación, almacenamiento, tamaño de pantalla, sistema operativo y garantía. De igual modo, “resma carta” puede variar en gramaje, cantidad de hojas, blancura o formato. La similitud textual es útil, pero no suficiente para afirmar equivalencia técnica. Por ello, el problema no se resuelve únicamente escogiendo un modelo de embeddings más sofisticado.

La tesis sostiene que la comparación confiable requiere tres componentes: una taxonomía de productos, atributos técnicos mínimos y una métrica de confianza. La taxonomía ordena el espacio de productos; los atributos técnicos permiten evaluar comparabilidad; y la confianza permite separar recomendaciones automáticas de casos que deben revisarse manualmente. Esta distinción es crítica para evitar una falsa sensación de precisión algorítmica.

Desde la perspectiva organizacional, el problema impacta en cuatro dimensiones. Primero, afecta la eficiencia, porque los compradores invierten tiempo buscando referencias y corrigiendo información. Segundo, afecta la transparencia, porque una adjudicación puede ser difícil de explicar si no existen comparables estructurados. Tercero, afecta el control de precios, porque las alertas dependen de datos normalizados. Cuarto, afecta el aprendizaje institucional, porque cada proceso de compra queda aislado si no se conecta con un catálogo maestro.

La pregunta de investigación se formula de la siguiente manera: ¿cómo puede construirse un catálogo estructurado de productos, apoyado en NLP, modelos de lenguaje y reglas de negocio, que permita mejorar la clasificación, comparación de precios y recomendación de decisiones en

Compra Ágil utilizando Convenio Marco como referencia semántica y transaccional?

El alcance del problema se acota a bienes y productos de alta recurrencia o con posibilidad de estandarización, tales como alimentos, papelería, computadores, mobiliario, aseo, ferretería e insumos médicos. Quedan fuera del alcance decisiones que dependan principalmente de servicios profesionales altamente personalizados, obras complejas o compras donde el precio no pueda separarse de condiciones técnicas específicas no observadas en los datos.

3. Hipótesis

Hipótesis principal: un pipeline híbrido que combine reglas léxicas, códigos de clasificación, embeddings semánticos, TF-IDF y calibración robusta de precios permite construir un catálogo estructurado más útil para la toma de decisiones en Compra Ágil que un enfoque basado exclusivamente en texto libre o en similitud semántica sin atributos.

- Hipótesis 1 (H1): Convenio Marco puede utilizarse como referencia inicial o ground truth operativo para construir una taxonomía de productos, siempre que se reconozcan sus limitaciones de equivalencia técnica y precio.
- Hipótesis 2 (H2): La normalización de texto, unidades, marcas y códigos aumenta la calidad de clasificación y reduce falsos comparables en productos de Compra Ágil.
- Hipótesis 3 (H3): La selección del modelo semántico debe considerar simultáneamente métricas de desempeño, cohesión, calibración, eficiencia y separación, y no solo accuracy.

- Hipótesis 4 (H4): La comparación de precios requiere estadística robusta, filtros de confiabilidad y revisión humana cuando existen pocos comparables, unidades ambiguas o diferencias técnicas relevantes.
- Hipótesis 5 (H5): Una estructura mínima obligatoria de información para Compra Ágil mejora la trazabilidad, la comparabilidad y la posibilidad de construir sistemas de monitoreo de precios.

Estas hipótesis no anticipan resultados empíricos cerrados. Funcionan como proposiciones de diseño y validación que deben ser contrastadas mediante la ejecución del pipeline, la revisión de casos de prueba y la evaluación de métricas sobre datos actualizados.

4. Objetivos

4.1 Objetivo general

Diseñar y validar conceptualmente una solución analítica para estructurar, clasificar y comparar productos de Compra Ágil mediante técnicas de procesamiento de lenguaje natural, modelos de lenguaje, reglas de negocio y referencias de Convenio Marco, con el fin de mejorar la toma de decisiones en compras públicas.

4.2 Objetivos específicos

- (OE1) Diagnosticar los problemas de información que dificultan la comparación de productos y precios en Compra Ágil.
- (OE2) Construir una taxonomía de productos basada en Convenio Marco y enriquecida con reglas de normalización, códigos ONU/UNSPSC y atributos técnicos.
- (OE3) Documentar la arquitectura de la solución, detallando el fundamento teórico, la lógica computacional y las validaciones de cada componente.

- (OE4) Comparar modelos de representación semántica usando indicadores de clasificación, cohesión, calibración, eficiencia y separación.
- (OE5) Diseñar un esquema de ponderación para seleccionar el modelo final de manera transparente y defendible.
- (OE6) Proponer una estructura de información para Compra Ágil que permita mejores decisiones, monitoreo de precios y revisión de casos de riesgo.
- (OE7) Establecer lineamientos de implementación, gobernanza, revisión humana y mejora continua para el uso institucional del sistema.

5. Metodología propuesta

La metodología corresponde a una investigación aplicada de analítica de negocios. Combina un enfoque cuantitativo-deductivo, porque utiliza métricas para evaluar modelos y comparar resultados, con un enfoque de diseño de sistemas, porque construye un artefacto computacional orientado a resolver un problema organizacional. La solución no se limita a entrenar un modelo; incluye preparación de datos, reglas de negocio, validación, interpretación y propuesta de estructura de información, en línea con trabajos aplicados recientes del programa que comparan técnicas analíticas para apoyar decisiones (Yáñez Cornejo, 2025).

El enfoque de la investigación es aplicado: no busca formular una teoría general de compras públicas ni reemplazar la normativa vigente, sino resolver un problema concreto de toma de decisiones —convertir datos heterogéneos de Compra Ágil en información estructurada que permita clasificar, comparar, alertar y recomendar de manera trazable—. La solución se orienta al soporte de decisiones, no a la adjudicación automática.

En el diseño metodológico, primero se presenta el problema y su relevancia, luego se describe el flujo metodológico, posteriormente se


desarrolla el marco teórico, se explica el enfoque de solución paso a paso, se presentan resultados o plantillas de resultados y finalmente se formulan conclusiones y recomendaciones. En esta versión, la metodología se ordena de manera de seguir el tránsito desde el problema de datos hasta la recomendación de compra.

La unidad de análisis principal es el ítem de producto. Esto es relevante porque una solicitud de compra puede contener varias líneas, cada una con descripción, cantidad, unidad y precio. Evaluar solo la orden completa puede mezclar productos y servicios, impidiendo calcular un precio unitario confiable. Por ello, el pipeline distingue entre datos de solicitud, datos de producto, datos de cotización y referencias de mercado.

El proceso metodológico incorpora validaciones en cada etapa. Las validaciones no se dejan para el final, porque un error temprano en codificación de columnas, parsing de precios o limpieza de texto puede afectar toda la cadena analítica. La estrategia adoptada es de control incremental; verificar carga, columnas, texto, taxonomía, embeddings, clasificación, precios y recomendador.

El protocolo de evaluación es independiente de la herramienta de ejecución. Los datos de Convenio Marco se dividen en un conjunto para construir los centroides de categoría y un conjunto retenido (hold-out) para medir la clasificación; sobre Compra Ágil se reporta cobertura, distribución de confianza y proporción de casos derivados a revisión. Las métricas de clasificación son F1 ponderado y accuracy (Sokolova y Lapalme, 2009); las de estructura semántica, silhouette y separación inter/intra clase (Rousseeuw, 1987); la calibración se mide como la correspondencia entre la confianza reportada y la tasa de acierto (Guo et al., 2017); y la eficiencia, como throughput. Los criterios de aceptación privilegian clasificación y calibración por tratarse de un sistema de apoyo a decisiones públicas con revisión humana.

Figura 1. Flujograma metodológico de la solución propuesta.



5.1 Etapas metodológicas

Tabla 2. Etapas del pipeline analítico y su propósito.

Fase	Nombre	Propósito
1	Instalación y entorno	Garantizar reproducibilidad en el entorno de cómputo y disponibilidad de librerías.
2	Configuración	Centralizar rutas, UTM, modelos y parámetros críticos.
3	Carga de datos	Detectar archivos de Convenio Marco y Compra Ágil desde Drive.
4	Mapeo de columnas	Resolver heterogeneidad de nombres y estructuras de datos.
5	Preprocesamiento NLP	Normalizar texto, unidades, marcas y ruido lingüístico.
6	Procesamiento de datos	Construir campos estándar, categorías y precios efectivos.
7	Diccionario estructurado	Crear taxonomía, palabras clave, ejemplos y estadísticas.
8	Comparación de modelos	Evaluar embeddings con múltiples indicadores.
9	Clasificación híbrida	Combinar reglas, códigos y similitud semántica.
10-19	Recomendación y explotación	Calibrar precios, buscar comparables, alertar y exportar resultados.

5.2 Recopilación y preparación de datos

La recopilación de datos se basa en dos familias de fuentes: Convenios Marco y registros de Compra Ágil. Los Convenios Marco se utilizan como referencia más estructurada de productos y categorías, mientras que Compra Ágil representa el universo de decisiones donde se desea mejorar clasificación, comparación y recomendación.

El sistema detecta archivos por palabras clave asociadas a dominios como alimentos, aseo, ferretería, insumos médicos, mobiliario, escritorio, papelería y computadores. Esta detección es necesaria porque en la práctica los nombres de archivos pueden cambiar, y una solución operativa no puede depender de rutas rígidas o de un único archivo manualmente seleccionado.

La preparación incluye lectura robusta de archivos, transformación de nombres de columnas, preservación de códigos y RUT como texto para evitar pérdida de ceros, y conversión de montos a valores numéricos. La decisión de leer ciertos campos como cadenas responde a un principio de calidad de datos: un identificador no debe tratarse como número aunque contenga dígitos.

5.3 Normalización y control de calidad

La normalización textual se aplica para reducir variación superficial sin destruir información relevante. Se eliminan tildes para comparar textos de manera uniforme, se corrigen problemas de codificación, se transforman abreviaturas comunes y se separan cantidades y unidades. Esta etapa es fundamental en español, donde las diferencias entre “lápiz”, “lapiz”,

“bolígrafo” y “pasta azul” pueden dificultar la recuperación de productos equivalentes.

El control de calidad se materializa mediante reglas de validación: número de registros cargados, columnas mínimas presentes, porcentaje de precios convertidos, cobertura de códigos ONU, proporción de descripciones no vacías, frecuencia de categorías y cantidad de registros por dominio. Estas validaciones permiten anticipar problemas antes de ejecutar modelos costosos.

La normalización no reemplaza la necesidad de atributos técnicos. Por ejemplo, puede hacer comparables las formas “lt” y “litro”, pero no puede inferir de manera confiable si un producto incluye instalación, garantía extendida o accesorios no descritos. Por ello, la metodología combina automatización con alertas de revisión manual.

5.4 Modelamiento y evaluación

El modelamiento se organiza en dos niveles. El primero corresponde a la clasificación del producto en una categoría estructurada. El segundo corresponde a la recuperación de comparables y calibración de precios. Esta

separación evita confundir dos problemas distintos: clasificar correctamente un producto y estimar un precio de referencia confiable.

Para la representación semántica se comparan modelos multilingües y específicos para español. Los embeddings permiten transformar textos en vectores y calcular similitud mediante coseno. Sin embargo, el mejor modelo no se define solo por la similitud promedio, sino por su capacidad de clasificar, separar categorías, calibrar confianza y operar con tiempos razonables.

Para la búsqueda de comparables se incorpora TF-IDF como complemento. Aunque los embeddings capturan relaciones semánticas profundas, TF-IDF ofrece explicabilidad y eficiencia. En compras públicas, la explicabilidad es valiosa porque el usuario debe entender por qué un producto fue sugerido como comparable.

5.5 Recomendación y validación de decisión

La recomendación combina reglas normativas, disponibilidad en Convenio Marco, monto expresado en UTM, diferencia porcentual entre precios y nivel de confianza. El objetivo es apoyar una decisión informada, no emitir una adjudicación automática. Cuando el sistema detecta baja

confianza, pocos comparables o diferencia extrema, la recomendación debe derivarse a revisión humana.

La validación decisonal se basa en casos de prueba representativos: notebook, resma de papel, tóner, detergente, silla, guantes, alimentos y productos de ferretería. Estos casos permiten evaluar si el sistema identifica atributos mínimos y evita comparaciones engañosas. La validación cualitativa complementa las métricas cuantitativas porque algunos falsos positivos solo son evidentes para un experto de dominio.

La métrica de éxito final no es únicamente accuracy. En un sistema de soporte a decisiones públicas, también importan cobertura, trazabilidad, interpretabilidad, tasa de casos revisados y consistencia de precios de referencia. Por ello, la metodología define indicadores técnicos y de gestión.

6. Marco teórico y revisión de la literatura

6.1 Compras públicas y analítica de decisiones

La literatura sobre compras públicas destaca que la eficiencia del gasto no depende solo de obtener precios bajos, sino de equilibrar costo, calidad, oportunidad, competencia, transparencia y cumplimiento normativo. En este sentido, la analítica de negocios aporta herramientas para convertir datos administrativos en evidencia de decisión. La información transaccional puede revelar patrones de precios, proveedores recurrentes, categorías con alta variabilidad y oportunidades de estandarización. Estos principios de eficiencia y valor por dinero en compras públicas son sistematizados por la OECD (2019).

El concepto de valor por dinero es especialmente relevante. Una oferta de menor precio no necesariamente representa mejor valor si el producto no cumple especificaciones, tiene menor durabilidad, incluye menos unidades o excluye servicios esenciales. Por ello, la comparación debe realizarse a nivel de atributos y unidad comparable. La tesis adopta este principio al proponer que la estructura de Compra Ágil debe incluir cantidad, unidad, formato, condiciones comerciales y atributos técnicos mínimos.

La modernización de las compras públicas en Chile refuerza la necesidad de sistemas de información robustos. El aumento del umbral de Compra Ágil a 100 UTM amplía el universo de decisiones que pueden beneficiarse de un catálogo estructurado y de alertas de precio. A mayor relevancia económica de la modalidad, mayor necesidad de trazabilidad y comparación sistemática.

6.2 Datos maestros, catálogos y calidad de datos

Un dato maestro de producto es una representación estable de un bien que permite identificarlo, clasificarlo y compararlo a través de distintos procesos. La descripción textual es solo una parte del dato maestro; también se requieren identificadores, categorías, atributos, unidades, equivalencias, restricciones y relaciones con proveedores o contratos. La gestión de datos maestros y sus principios de gobernanza se apoyan en el marco DAMA-DMBOK (DAMA International, 2017), mientras que las dimensiones de calidad de datos siguen a Wang y Strong (1996).

La calidad de datos suele evaluarse mediante dimensiones como completitud, consistencia, exactitud, unicidad, vigencia y trazabilidad. En Compra Ágil, estas dimensiones se manifiestan de manera concreta: completitud de atributos técnicos, consistencia de unidades, exactitud de

códigos, unicidad de productos equivalentes, vigencia de precios y trazabilidad de cotizaciones. Si una dimensión falla, la comparación puede sesgarse.

Los catálogos electrónicos permiten reducir variabilidad en la descripción, pero requieren gobernanza. Sin reglas de alta, modificación y revisión, un catálogo puede duplicar productos, mezclar marcas con categorías o incorporar atributos irrelevantes. La propuesta de esta AFE considera que el catálogo debe ser dinámico, pero con controles de calidad y revisión manual en categorías críticas.

6.3 Procesamiento de lenguaje natural aplicado a texto transaccional

El procesamiento de lenguaje natural permite transformar texto no estructurado en información usable por algoritmos. En datos transaccionales, el lenguaje suele ser breve, telegráfico y ruidoso. A diferencia de textos extensos, las descripciones de productos contienen abreviaturas, números, unidades y marcas que pueden ser más importantes que la gramática. Por ello, las técnicas de NLP deben adaptarse al dominio. Los fundamentos del procesamiento de lenguaje natural aplicado a texto corto se apoyan en Jurafsky y Martin (2023).

La limpieza textual reduce ruido, pero una limpieza excesiva puede eliminar señales útiles. Por ejemplo, números como 256, 500 o 75 pueden representar almacenamiento, cantidad de hojas o gramaje. De igual modo, siglas como SSD, RAM, N95 o A4 son atributos técnicos y no deben eliminarse como palabras irrelevantes. El sistema considera stopwords generales y personalizadas, pero preserva tokens con valor técnico.

La extracción de cantidades y unidades es una tarea central. En compras públicas, el precio unitario depende de entender si una oferta corresponde a unidad, caja, kilogramo, litro, paquete o resma. El mismo monto total puede ser alto o bajo según el contenido por unidad. La tesis propone registrar tanto la unidad original como una unidad comparable.

6.4 TF-IDF, embeddings y modelos de lenguaje

TF-IDF pondera términos según su frecuencia en un documento y su rareza en el corpus. Aunque es una técnica clásica, sigue siendo útil para recuperación de información porque es transparente y eficiente. En el contexto de esta AFE, TF-IDF permite recuperar productos con términos técnicos específicos, especialmente cuando el usuario busca marcas, modelos o códigos. La ponderación TF-IDF proviene de Spärck Jones (1972), fue

consolidada por Salton y Buckley (1988) y se sistematiza en Manning, Raghavan y Schütze (2008).

Los embeddings semánticos representan textos como vectores densos. Dos descripciones cercanas en significado deberían ubicarse cerca en el espacio vectorial. Esta propiedad permite clasificar productos aunque no compartan exactamente las mismas palabras. Sin embargo, los embeddings pueden fallar cuando la diferencia técnica depende de números o atributos específicos que el modelo no pondera correctamente. Las representaciones vectoriales densas se apoyan en Mikolov et al. (2013), en la arquitectura de transformadores (Vaswani et al., 2017) y en los modelos tipo BERT (Devlin et al., 2019) y en los embeddings de oraciones de Reimers y Gurevych (2019).

La tesis adopta un enfoque híbrido porque ninguna técnica por sí sola resuelve el problema. Las reglas capturan conocimiento explícito y requisitos normativos; los códigos ONU/UNSPSC aportan taxonomía; TF-IDF ayuda a recuperar coincidencias técnicas; y los embeddings capturan similitud semántica. La combinación reduce riesgos y aumenta explicabilidad.

6.5 Validación de modelos y selección multicriterio

La evaluación de modelos en un problema aplicado debe considerar el impacto de los errores. En clasificación de productos, un falso positivo puede sugerir un comparable incorrecto y conducir a una alerta de precio injustificada. Un falso negativo puede impedir aprovechar una referencia útil. Por ello, las métricas deben analizarse junto con ejemplos concretos y reglas de revisión.

Accuracy mide la proporción de casos correctamente clasificados, pero puede ser engañosa si las categorías están desbalanceadas. F1 weighted considera precisión y recall ponderados por soporte de clases, por lo que ofrece una visión más equilibrada en catálogos donde algunas categorías son mucho más frecuentes que otras. Precision es relevante para evitar falsos comparables; recall lo es para no perder productos potencialmente equivalentes. El análisis de métricas de clasificación sigue a Sokolova y Lapalme (2009).

Silhouette evalúa la cohesión y separación de grupos en el espacio vectorial. En esta tesis se utiliza para observar si las categorías forman agrupamientos semánticos distinguibles. La calibración, en cambio, analiza

si la confianza reportada por el sistema se relaciona con la tasa real de aciertos. Un modelo mal calibrado puede entregar confianza alta en casos erróneos, lo que es especialmente riesgoso en sistemas de apoyo a decisiones públicas. El coeficiente de silhouette proviene de Rousseeuw (1987) y la noción de calibración de confianza, de Guo et al. (2017).

6.6 Estadística robusta y precios de referencia

Los precios públicos suelen presentar dispersión por diferencias de producto, región, proveedor, cantidad, flete, urgencia y condiciones comerciales. Por ello, el promedio puede ser sensible a valores extremos. La mediana y los percentiles son medidas robustas que describen mejor el centro y rango típico cuando existen outliers. El uso de medidas robustas frente a valores extremos se apoya en Huber (1981).

La calibración de precios en la tesis se basa en comparar Compra Ágil y Convenio Marco solo cuando existen suficientes comparables y cuando los precios son confiables. Se descartan o etiquetan casos donde la orden está agregada, la moneda no es CLP, la cotización no corresponde a una línea única o la unidad no es comparable. Esta decisión reduce cobertura, pero aumenta validez.

El sistema propuesto entrega alertas por rangos, no juicios definitivos. Una alerta de precio alto indica que el caso merece revisión, pero no implica automáticamente irregularidad. Puede existir una razón válida: urgencia, ubicación, garantía, flete, especificación superior o baja disponibilidad. La interpretación responsable requiere combinar analítica y contexto.


Tabla 3. Bibliografía base y tipo de aporte al estudio.

Fuente	Tipo de aporte	Uso en la tesis
ChileCompra y Ley 21.634	Normativo	Define reglas de Compra Ágil, Convenio Marco y umbral de 100 UTM.
OECD y World Bank	Gestión pública	Fundamenta valor por dinero, transparencia y eficiencia.
DAMA-DMBOK	Datos	Soporta conceptos de datos maestros y calidad de datos.
Manning, Raghavan y Schütze	NLP clásico	Fundamenta recuperación de información y TF-IDF.
Vaswani, Devlin, Reimers	Modelos de lenguaje	Fundamenta transformers, BERT y sentence embeddings.
scikit-learn y sentence-transformers	Implementación	Soporta métricas, TF-IDF y embeddings usados en código.

7. Arquitectura de la solución analítica

Este capítulo describe la arquitectura de la solución analítica: cómo los datos heterogéneos de Compra Ágil y Convenio Marco se transforman, etapa a etapa, en evidencia para decidir. La arquitectura se organiza como un flujo de datos a decisión —ingesta y homologación de fuentes, normalización semántica, construcción de taxonomía, representación y clasificación, calibración de precios y generación de recomendaciones— sobre el que operan, de forma transversal, la validación de indicadores y la selección del modelo. La Figura 2 resume esta arquitectura; las secciones siguientes detallan cada componente, su rol en la cadena y la justificación de sus decisiones de diseño.

Figura 2. Arquitectura conceptual del sistema de catálogo estructurado.



7.1 Visión general y principios de diseño

La solución nació como una exploración de dominio único (principalmente alimentos) y evolucionó hacia un sistema multi-dominio que integra siete familias de productos. Esa transición determinó la arquitectura: en lugar de reglas específicas de un rubro, el sistema incorpora detección automática de dominios, mapeo flexible de columnas y una taxonomía unificada, lo que le permite generalizar a fuentes heterogéneas.

Tres principios de diseño gobiernan la arquitectura. Primero, el enfoque es híbrido: ninguna técnica por sí sola resuelve el problema, de modo que reglas de negocio, códigos de clasificación, recuperación TF-IDF y embeddings semánticos operan de manera complementaria. Segundo, la unidad de análisis es el ítem de producto, no la orden de compra, porque una misma solicitud puede mezclar productos y servicios y distorsionar el precio unitario. Tercero, cada componente debe producir evidencia trazable y auditable (categoría sugerida, comparables, precio de referencia, nivel de confianza y alertas) , de manera que su resultado pueda explicarse al comprador público y revisarse posteriormente.

7.2 Ingesta y homologación de fuentes

La primera etapa incorpora las fuentes oficiales y las lleva a una estructura común. El sistema detecta automáticamente los archivos de Convenio Marco y de Compra Ágil, identifica su dominio y los carga en estructuras uniformes, reduciendo la intervención manual y permitiendo escalar a nuevos catálogos. Como los archivos de ChileCompra pueden variar en nombres y estructura, un mapeo flexible de columnas resuelve la primera columna disponible para cada campo relevante (descripción, precio, proveedor, marca, modelo, código, categoría y región) , lo que hace el flujo robusto frente a la variación de fuentes.

Los parámetros que condicionan la decisión se centralizan en un único punto de configuración: la UTM vigente, el umbral de Compra Ágil (100 UTM) y el monto máximo asociado. Esta centralización es relevante porque la UTM cambia mensualmente y afecta las reglas de recomendación; mantenerla en un solo lugar evita inconsistencias. El entorno de ejecución declara explícitamente sus dependencias, de modo que un evaluador pueda reproducir los resultados desde cero, condición que forma parte de la validez de una solución de analítica aplicada.

7.3 Normalización y estandarización semántica

La segunda etapa convierte texto ruidoso en información comparable. La normalización corrige codificación, homogeneiza mayúsculas y tildes y gestiona palabras vacías, pero preserva deliberadamente los tokens técnicos (siglas como SSD, RAM, N95 o A4 y números como gramaje o capacidad) porque en descripciones de productos esos elementos suelen ser más decisivos que la gramática. Sobre el texto normalizado se extraen cantidad, unidad de medida y marca, y se construye una unidad comparable que permite razonar sobre el precio unitario.

Convenio Marco y Compra Ágil se llevan luego a una estructura común y se enriquecen con categorías internas derivadas del tipo de producto o del código de clasificación; sin esta homologación no es posible comparar, clasificar ni recomendar sobre un mismo espacio. Para el análisis de precios se aplica una normalización más estricta que distingue el precio efectivo de los precios históricos confiables, descartando órdenes agregadas o no comparables. Esta decisión reduce cobertura, pero aumenta la validez de las comparaciones posteriores.

7.4 Taxonomía y diccionario estructurado

A partir de Convenio Marco se construye un diccionario estructurado que asocia a cada categoría sus palabras clave, estadísticas de precio, marcas frecuentes y ejemplos representativos. Este diccionario actúa como puente entre los datos y el conocimiento de negocio: alimenta las reglas de clasificación, sustenta la explicación de por qué un producto pertenece a una categoría y orienta la revisión manual. Su calidad depende de que cada categoría cuente con suficientes ejemplos, palabras clave coherentes y estadísticas no distorsionadas por valores extremos.

7.5 Representación semántica y clasificación

El corazón analítico del sistema representa cada descripción como un vector y la clasifica contra la taxonomía. La elección del modelo de representación se toma con evidencia multicriterio: se comparan varios embeddings multilingües según desempeño de clasificación, cohesión (silhouette), calibración, eficiencia y separación, porque un modelo puede clasificar bien pero calibrar mal, o separar grupos pero resultar lento. La clasificación es híbrida: combina reglas que capturan conocimiento explícito, centroides de categoría y búsqueda de similares, de modo que reduce la dependencia de un

único método y entrega, junto a la categoría sugerida, un puntaje de confianza y la explicación del criterio aplicado.

El sistema se ejecuta de extremo a extremo (ingesta, normalización, diccionario, selección de modelo, clasificación y evaluación) para garantizar reproducibilidad. La calidad de la clasificación se mide con accuracy, precision, recall y F1, con atención especial al F1 ponderado por el desbalance de categorías y al desempeño por clase. De forma complementaria, un buscador basado en TF-IDF ofrece recuperación explicable y rápida cuando la consulta involucra marcas, modelos o códigos específicos, aportando una vía transparente junto a la similitud semántica.

7.6 Calibración de precios y comparación

Sobre los productos clasificados, el sistema calcula precios de referencia robustos por categoría y los compara con Convenio Marco mediante mediana, percentiles y diferencias relativas. La robustez es necesaria porque los precios públicos presentan dispersión por diferencias de producto, cantidad, flete y condiciones comerciales, frente a las cuales el promedio es sensible a valores extremos. La comparación solo se realiza cuando existen suficientes comparables y cuando los precios son confiables (moneda CLP,

orden de una sola línea y unidad comparable) ; de lo contrario, el caso se etiqueta y se deriva a revisión en lugar de forzar una comparación no válida.

7.7 Recomendación y generación de evidencia

La última etapa traduce el análisis en acción posible. Un recomendador aplica reglas de monto, disponibilidad en Convenio Marco y diferencia de precios para sugerir la modalidad de compra o activar revisión; por diseño, un monto superior a 100 UTM no puede recomendarse como Compra Ágil, y una diferencia de precio extrema activa una alerta. La salida no es un juicio definitivo sino evidencia trazable: categoría, comparables, precio de referencia con su nivel de confianza y alertas.

Esta evidencia se comunica en distintos niveles. Un informe ejecutivo resume volúmenes, categorías, modelos y métricas, diferenciando explícitamente resultados reales de plantillas y registrando la fecha de la corrida. Un dashboard y un catálogo exportable permiten revisar los resultados por categoría, fuente y calidad, facilitando la adopción institucional. Finalmente, un conjunto de casos representativos (computadores, papel, tóner, detergente y mobiliario) demuestra el funcionamiento del sistema sobre productos concretos y permite comunicar su valor durante la defensa.

7.8 Validación, indicadores y selección del modelo final

La selección del modelo final no debe depender de una sola métrica. En problemas de clasificación de productos, el costo de error depende del tipo de equivocación. Confundir dos productos de la misma familia puede ser aceptable en una etapa exploratoria, pero confundir un notebook con un accesorio o un insumo médico con un producto de aseo puede conducir a comparaciones inválidas. Por ello, se define una evaluación multicriterio.

La evaluación considera seis dimensiones: F1/accuracy/precision/recall para calidad de clasificación, silhouette para estructura del espacio vectorial, calibración para relación entre confianza y acierto, throughput para costo operativo, y separación inter/intra clase para medir discriminación semántica. La combinación permite escoger un modelo útil para la decisión y no solo para una métrica académica.

La ponderación propuesta asigna mayor peso a la calidad de clasificación porque el primer objetivo es categorizar correctamente. No obstante, se reserva peso relevante para calibración y silhouette porque un sistema de apoyo a decisiones debe saber cuándo confiar en sí mismo. Throughput

recibe menor peso, pero no se elimina, porque en un contexto institucional el tiempo de procesamiento impacta la viabilidad de uso recurrente.

Tabla 4. Indicadores considerados para la evaluación de modelos de embedding.

Indicador	Qué mide	Por qué importa
F1 weighted	Balance entre precision y recall ponderado por soporte de clases.	Reduce sesgo de categorías frecuentes y resume calidad de clasificación.
Accuracy	Porcentaje total de aciertos.	Entrega lectura simple y comparable, aunque puede ser insuficiente si hay desbalance.
Precision	Proporción de predicciones positivas correctas.	Evita falsos comparables y alertas erróneas.
Recall	Capacidad de recuperar elementos de una clase.	Evita perder comparables relevantes.
Silhouette	Cohesión intra-clase y separación inter-clase.	Evalúa estructura del espacio vectorial.
Calibración	Relación entre confianza y acierto.	Permite decidir cuándo automatizar y cuándo revisar manualmente.
Throughput	Velocidad de procesamiento.	Determina viabilidad de uso operativo.
Separación inter/intra	Distancia relativa entre categorías y dentro de categoría.	Indica si el embedding discrimina categorías similares.

Tabla 5. Ponderación propuesta para selección del modelo semántico.

Dimensión	Peso relativo	Justificación
F1 weighted	30%	Principal métrica de clasificación en contexto multiclase y desbalanceado.
Accuracy	15%	Permite mantener control de desempeño global.
Silhouette	15%	Premia modelos que ordenan mejor el espacio semántico.
Calibración	20%	Crítica para sistemas de soporte a decisiones con revisión humana.
Throughput	10%	Asegura factibilidad operativa en el entorno de cómputo o entorno institucional.
Separación inter/intra	10%	Reduce riesgo de categorías demasiado superpuestas.

La fórmula de selección puede expresarse como un score compuesto normalizado entre 0 y 1. Antes de ponderar, cada indicador debe escalarse para que valores mayores representen mejor desempeño. En el caso de throughput, puede utilizarse una transformación relativa respecto del modelo más rápido. En el caso de silhouette y separación, se normaliza por rango observado en la comparación.

El modelo final será aquel que maximice el score compuesto, siempre que no incumpla umbrales mínimos. Esta condición evita seleccionar un modelo por buen desempeño promedio si falla en una dimensión crítica. Por ejemplo, si un modelo presenta excelente accuracy pero mala calibración, puede no ser recomendable para uso decisonal porque entregaría confianza alta en errores.

Los pesos propuestos no deben interpretarse como valores universales. Representan una priorización para esta AFE: decisión pública, trazabilidad, precisión semántica y costo razonable. En una implementación institucional, los pesos podrían ajustarse mediante validación con expertos compradores y revisión de casos históricos.

7.9 Validación de precios y recomendador

La validación de precios se separa de la validación de clasificación porque un producto bien clasificado puede seguir siendo mal comparable en precio. La diferencia puede provenir de cantidad, unidad, flete, garantía, instalación, región o urgencia. Por ello, el recomendador utiliza una lógica de evidencia gradual: primero busca comparables CM, luego complementa con CA histórica confiable, y finalmente asigna un nivel de confianza.

La mediana se utiliza como referencia central porque reduce sensibilidad ante precios extremos. Los percentiles 25 y 75 permiten construir un rango típico. Cuando el precio cotizado cae muy por encima del percentil 75 o supera umbrales definidos, el sistema genera alerta. Sin embargo, la alerta no es una acusación; es una señal para revisar documentación y especificaciones.

El nivel de confianza debe considerar número de comparables, similitud promedio, cobertura de código ONU/UNSPSC, consistencia de unidad, disponibilidad de precio CM y presencia de precios CA históricos confiables. Un caso con pocos comparables y descripción ambigua debe tener baja confianza aunque la similitud textual sea alta.

La recomendación de modalidad integra la regla de monto. Si el monto estimado supera el umbral de Compra Ágil, el sistema no debe recomendar esa modalidad. Si existe producto en Convenio Marco y la diferencia de precio es relevante, el sistema debe sugerir revisar esa alternativa. Si la confianza es baja, debe recomendar revisión manual y mejora de especificaciones.

7.10 Propuesta de estructura de información para Compra Ágil

La propuesta de estructura de información es uno de los aportes centrales de la AFE. El objetivo es pasar de un registro administrativo centrado en la orden de compra a un modelo de datos orientado a decisión. Para comparar productos, no basta con saber el monto total y la descripción; se requiere identificar el ítem, sus atributos, la unidad comparable, las cotizaciones recibidas, las condiciones comerciales y las referencias de mercado.

La estructura se organiza en niveles. El primer nivel corresponde a la solicitud de compra y contiene organismo, unidad compradora, región, fecha, monto estimado, modalidad y justificación. El segundo nivel corresponde al ítem de producto, que incluye descripción original, descripción normalizada, categoría, código ONU, marca, modelo, unidad, cantidad y atributos

técnicos. El tercer nivel corresponde a cotizaciones y proveedor. El cuarto nivel corresponde a referencias de mercado y resultados del modelo.

Este diseño permite que la información se utilice para tres fines simultáneos: operación diaria, control posterior y aprendizaje institucional. En operación, ayuda al comprador a comparar. En control, permite revisar la justificación de decisiones. En aprendizaje, permite construir históricos de precios y mejorar catálogos.

Tabla 6. Estructura de datos recomendada para Compra Ágil.

Nivel	Campos mínimos	Uso decisional
Solicitud	id_solicitud, organismo, unidad, región, fecha, monto estimado, modalidad	Trazabilidad, control normativo y segmentación.
Ítem	id_item, descripción original, descripción normalizada, categoría, código ONU, unidad, cantidad	Clasificación, comparación y cálculo de precio unitario.
Atributos técnicos	marca, modelo, especificaciones, formato, rendimiento, garantía	Evaluación de comparabilidad real.
Cotización	proveedor, RUT, precio unitario, precio total, flete, instalación, plazo, seleccionado	Comparación entre ofertas y justificación.
Referencia de mercado	precio mediana CM, percentiles, similitud, confianza, alerta, recomendación	Soporte analítico de la decisión.

8. Resultados, análisis y discusión de evidencias

La corrida definitiva del código consolidado (versión final) se ejecutó en un entorno de cómputo reproducible el 04/05/2026 sobre fuentes oficiales de ChileCompra, con UTM vigente de \$67.294 (umbral de Compra Ágil = 100 UTM = \$6.729.400). Los resultados se reportan en cuatro bloques (volumen de datos, comparación de modelos de embedding, desempeño de clasificación y calibración de precios) y se cierra cada hipótesis con la evidencia obtenida. La redacción distingue de forma explícita entre lo medido sobre datos limpios de Convenio Marco (CM) y el comportamiento sobre datos reales de Compra Ágil (CA), porque esa distinción es la clave de validez del trabajo.



Figura 3. Panel de indicadores clave (KPI) del sistema generado por la corrida.

8.1 Volumen de datos procesados

El pipeline consolidó 4.912.069 registros: 3.778.844 productos de Convenio Marco distribuidos en 7 dominios y 527 categorías, y 1.133.225 registros de Compra Ágil. Este volumen confirma que la solución opera a escala real y no sobre una muestra de laboratorio.

Fuente / dominio	Registros	% del CM
Aseo y limpieza	1.169.122	30,9%
Ferretería	953.956	25,2%
Alimentos	766.661	20,3%
Escritorio y papelería	726.535	19,2%
Mobiliario	146.790	3,9%
Insumos médicos	14.469	0,4%

Fuente / dominio	Registros	% del CM
Computadores e informática	1.311	0,03%
CM unificado (total)	3.778.844	100%
Compra Ágil (a clasificar)	1.133.225	—

Tabla 7. Volumen de datos cargados por fuente y dominio (corrida 04/05/2026).

La carga evidenció un problema temprano de calidad de datos: la auditoría de la corrida arrojó dos carencias estructurales que condicionan todo el análisis posterior: en Compra Ágil se detectaron marcas en 0,0% de las descripciones, y la cobertura de códigos UNSPSC/ONU fue de 0% en todos los dominios. Además, el dominio "computadores" del CM contiene solo 1.311 productos frente a más de un millón en aseo o ferretería; este desbalance extremo de soporte produce centroides inestables y precios de referencia poco robustos, y explica varios de los artefactos de precio descritos en 8.4.

8.2 Comparación de modelos de embedding

Se evaluaron cuatro modelos multilingües con seis indicadores. La diferencia de F1 entre el mejor y el peor modelo fue de solo 0,092, lo que confirma la hipótesis H3: el desempeño no se decide por F1, sino por el balance entre dimensiones (implementación de métricas con scikit-learn: Pedregosa et al., 2011).

Modelo	F1	Acc	Silh.	Calibr.	Sep.	it/s
distiluse (seleccionado)	0,760	0,771	0,440	0,244	0,802	1651
es-specific	0,736	0,742	0,419	0,326	0,825	759
e5-small	0,729	0,750	0,381	0,392	0,984	2852
mpnet	0,668	0,688	0,417	0,361	0,900	908

Tabla 8. Indicadores por modelo. distiluse-base-multilingual-cased-v1 obtuvo el mayor F1 y la mejor cohesión (Silhouette).




Figura 4. Comparación de los cuatro modelos de embedding en los seis indicadores.

El contraste entre los modelos exige interpretar el trade-off: se seleccionó distiluse por maximizar el score compuesto (F1 + Silhouette). No obstante, conviene declarar abiertamente una tensión: distiluse presenta la peor calibración (0,244) y la peor separación (0,802) del conjunto, mientras que

e5-small ofrece la mejor calibración (0,392), la mejor separación (0,984) y el mayor throughput (2.852 it/s). Dado que la propia metodología pondera la calibración en 20% por ser crítica en sistemas de apoyo a la decisión, la selección debe sostenerse de forma transparente: distiluse prioriza categorizar y ordenar bien el espacio semántico, pero e5-small es preferible si el criterio dominante pasa a ser saber cuándo el sistema debe abstenerse. Se recomienda dejar el modelo como parámetro configurable.

8.3 Desempeño de clasificación: datos limpios (CM) frente a datos reales (CA)

Este punto es central, porque el desempeño cambia radicalmente según la fuente de los datos, como se explica continuación.

En la validación hold-out sobre Convenio Marco, clasificando una muestra retenida de productos CM contra sus propias categorías, el sistema alcanzó $F1 = 0,894$, $accuracy = 0,913$ y 99,1% de asignaciones con confianza alta. Esto demuestra que la metodología de centroides es muy eficaz cuando el texto de entrada está estandarizado.

En la aplicación sobre Compra Ágil real, al ejecutar el mismo modelo sobre los 1.133.225 registros reales de CA, el panorama cambia: se clasificó

el 93,0% (1.053.785 registros), pero la confianza promedio cayó a 0,405 y solo el 0,5% (5.717 casos) alcanzó confianza alta ($\geq 0,70$); un 8,3% quedó en confianza baja para revisión obligatoria.

Indicador	Hold-out (CM)	Aplicación CA real
F1 / Accuracy	0,894 / 0,913	no comparable*
% cobertura (clasificado)	—	93,0%
Confianza promedio	alta	0,405
% confianza alta	99,1% ($>0,5$)	0,5% ($\geq 0,70$)
% confianza baja ($<0,25$)	$\approx 0\%$	8,3%
Marcas detectadas en el texto	—	0,0%
Registros sin dominio asignado	—	75,1%

Tabla 9. Contraste entre validación sobre datos limpios y aplicación sobre datos reales. *El hold-out evalúa CM contra CM; no constituye ground truth de CA.




Figura 5. Dashboard de la corrida. El panel inferior derecho (distribución de confianza en CA) muestra la masa concentrada en torno a 0,4, con apenas ~1% de casos en confianza alta.

La alta cobertura (93%) convive con una confianza media baja (0,405). En coherencia con el criterio metodológico que privilegia la calibración de la confianza por sobre la cobertura (Sección 5.4), el sistema no está en condiciones de automatizar la categorización minimizando intervención humana; sí está en condiciones de apoyar la decisión, proponiendo categoría y derivando a revisión los casos de baja confianza. Los datos más reveladores son dos cifras de carencia: 0,0% de marcas detectadas y 75,1% de registros sin dominio asignable. Ambos confirman la tesis central: el límite no está en el modelo de lenguaje, sino en la estructura de la información de entrada.

8.4 Evaluación de la extracción de atributos con un conjunto de prueba revisado manualmente

Para evaluar la precisión de los algoritmos de extracción de atributos (cantidad, unidad de presentación y marca) se construyó un conjunto de prueba de 45 descripciones revisado manualmente, siguiendo el protocolo estándar: definir para cada descripción la verdad de terreno de los atributos y contrastarla con la salida del código. El conjunto combina 17 descripciones extraídas textualmente de los registros procesados en la corrida y 28 construidas por el autor replicando los patrones observados en los datos

reales (formatos de envase, unidades, marcas del catálogo y casos sin información). El criterio de anotación distingue la presentación comercial (contenido o formato de venta, por ejemplo 6x1 litros o caja de 12 unidades) de las especificaciones técnicas (como 16 GB de RAM), que no constituyen presentación. El detalle completo, caso a caso, se reporta en la Tabla C1 del Anexo C.

Los resultados distinguen con claridad las dos capacidades. La extracción de marca es precisa cuando la marca figura en el texto y pertenece al catálogo: precisión de 93,3% (14 de 15 detecciones correctas), sin ninguna confusión entre marcas, y recall de 70,0% (14 de 20 marcas presentes). Los seis casos no detectados corresponden íntegramente a marcas reales ausentes del catálogo de 139 marcas (por ejemplo, la marca de accesorios computacionales presente en cinco descripciones reales de la corrida), y el único falso positivo detectó la marca de un componente (el procesador) en lugar de la del producto principal. La conclusión es que el desempeño de marca está limitado por la cobertura y la gobernanza del catálogo, no por el algoritmo de detección.

La extracción de presentación es exacta en los formatos frecuentes y frágil fuera de ellos. Sobre los 26 casos con presentación real, el sistema logró 12

aciertos plenos (46,2%) y 3 aciertos de valor con alias de unidad no homologado (litros reconocido como l en lugar de lt; unid reconocido como un), con lo que la coincidencia de valor alcanza 57,7%. Los formatos multiplicativos y de contenido directo (6x1lt, 12x500ml, 3 kg, 170 g, 900 cc, bidón de 20 lt) se resolvieron sin errores. Las fallas se concentran en tres patrones: unidades con separadores o variantes no cubiertas por las expresiones regulares (16 oz, 48 mm, 2 m, decimales con coma como 1,8 m); descripciones donde convive más de una magnitud y el sistema captura la incorrecta para efectos de comparación (la resma de 75 g/m² y 500 hojas, donde se extrae el gramaje y no el contenido); y colisiones de tokens técnicos (el 95 de N95 leído como cantidad; 16GB leído como 16 gramos, único falso positivo entre los 19 casos sin presentación).

Estos resultados precisan el diagnóstico de la tesis en lugar de contradecirlo. Primero, el 0% de marcas reportado sobre Compra Ágil en la Sección 8.3 no se explica por un extractor deficiente: con 93,3% de precisión cuando la información existe, el cero refleja que la marca no figura en el texto libre o no pertenece al catálogo, es decir, ausencia de información en el origen. Segundo, cada patrón de falla de presentación corresponde a un campo de la estructura propuesta en la Sección 10.5: la ambigüedad gramaje/contenido se

elimina capturando contenido por envase; los alias divergentes se eliminan con la unidad base normalizada como campo de selección; y las colisiones con especificaciones técnicas desaparecen cuando los atributos técnicos tienen campos propios. Tercero, el conjunto de prueba queda disponible como base de regresión: cualquier mejora de las expresiones regulares o del catálogo de marcas puede evaluarse contra él de forma reproducible, y el protocolo es extensible a una muestra aleatoria de mayor tamaño mediante la rutina de muestreo incorporada al código (semilla fija, anotación en planilla y cálculo automático de métricas).

8.5 Calibración y comparación de precios

Los precios unitarios de CA presentan dispersión extrema porque mezclan flete, instalación y garantía dentro del monto. Se evaluaron 10 métricas estadísticas contra la mediana de CM en 313 categorías. La métrica con menor error fue el Percentil 25 (cota inferior), que actúa como filtro de sobreprecios.




Figura 6. Calibración de precios CA: de las 10 métricas evaluadas, el Percentil 25 (P25) presentó el menor sesgo y error absoluto medio frente a la referencia CM.

Debe advertirse, sin embargo, que incluso la mejor métrica (P25) conserva un error absoluto medio (MAE) de 5.184% frente a la referencia CM. Es decir, la comparación de precios CA ↔ CM, tal como están hoy los datos, no es confiable en magnitud. El caso "computadores y laptops" lo ilustra: CM aparece con un promedio de ~\$957 frente a \$396.136 en CA (+41.289%), cifra que es un artefacto, porque la categoría CM está contaminada con accesorios y las unidades no son homologables (un notebook no cuesta \$957).




Figura 7. Comparación de precios CM vs CA por categoría (precios calibrados). El Convenio Marco resultó más barato en 11 de 14 categorías.

La dirección del resultado sí es defendible: el Convenio Marco fue más barato en 11 de 14 categorías y CA solo en 3, lo que respalda empíricamente la prioridad de CM del Art. 14 bis de la Ley 21.634 (Biblioteca del Congreso Nacional de Chile, 2023). Sin embargo, el ahorro mensual potencial estimado (~\$202 millones, 3.009 UTM) debe presentarse como una cota indicativa superior y no como un ahorro realizable ni una cifra puntual: está inflado por las mismas incomparabilidades de unidad que producen el MAE de 5.184% y supone, contra la evidencia, que todas las diferencias observadas corresponden a productos equivalentes.

Como caso de prueba, el recomendador se validó sobre casos concretos: Para "Tóner HP LaserJet", el sistema recomendó un precio de referencia de \$7.913 (mediana CM, n=30, confianza media) y, ante una cotización de \$45.000, emitió una alerta fuerte (ratio 5,69×, sobre el percentil 90). El caso ilustra el comportamiento deseado: precio de referencia trazable, nivel de confianza explícito y alerta como señal de revisión, no como sanción.




Figura 8. Caso de prueba del recomendador de precios: Tóner HP LaserJet con alerta de sobreprecio.

8.6 Contraste de hipótesis

La corrida permite cerrar las cinco hipótesis con evidencia empírica.

Hip.	Evidencia de la corrida	Resultado
H1	CM sirvió como referencia operativa (527 categorías, 3,7M productos), pero su comparabilidad técnica y de precio es limitada (categoría computadores contaminada).	Se sostiene con reservas
H2	La normalización clasificó el 93% de CA, pero 0% de marcas y 75% sin dominio muestran que falta estructura en origen, no solo limpieza.	Se sostiene parcialmente
H3	Diferencia de F1 entre modelos = 0,092; la selección dependió de Silhouette y calibración, no de F1.	Se confirma
H4	P25 fue la métrica más robusta, pero su MAE de 5.184% obliga a revisión humana y filtros de confiabilidad.	Se confirma
H5	La ausencia de estructura mínima (unidad, atributos, marca, código) es la causa directa de la baja confianza y del error de precio.	Se confirma

Tabla 10. Cierre de hipótesis con evidencia empírica.

8.7 Discusión

La corrida confirma que el problema de Compra Ágil es informacional antes que algorítmico. El modelo categoriza razonablemente texto estandarizado, pero su confianza disminuye de manera sustantiva frente a descripciones libres reales, y la comparación de precios pierde validez en magnitud por la ausencia de unidades homologadas. Esta evidencia constituye una contribución del trabajo, en cuanto cuantifica dónde y en qué medida la decisión se ve afectada por la falta de estructura, y justifica con datos la propuesta de rediseño de captura que se desarrolla en la Sección 10.5. La evaluación con el conjunto de prueba manual (Sección 8.4) precisa este

diagnóstico: la extracción de atributos es precisa cuando el patrón de información existe (93,3% de precisión de marca, formatos de envase resueltos sin error) y sus fallas corresponden a información ausente, no homologada o mal ubicada en el origen, exactamente lo que la estructura propuesta corrige.

La evidencia por categoría revela que la utilidad del sistema es asimétrica entre fuentes. Sobre Convenio Marco (donde cada producto tiene categoría, marca, unidad y precio de catálogo) el modelo clasifica con alta confianza (F1 de 0,894) y entrega precios de referencia comparables; en ese dominio es una herramienta óptima de análisis y recomendación. Sobre Compra Ágil, la ausencia de estructura impide comparar su precio con Convenio Marco, porque el monto registrado no es un precio unitario sino un total que puede incluir cantidad, flete, instalación o garantía y con frecuencia corresponde a un envase y no a una unidad.

El espectro de categorías lo confirma. Cuando el producto es un ítem único y bien especificado, la comparación funciona: una placa compactadora eléctrica difiere solo -14,5% y el papel higiénico +4,7%. Cuando la compra es a granel o el atributo técnico está ausente, la diferencia se amplifica: papel

y resma difiere +336% porque la cantidad por envase no se captura, crayones +6.983% al comparar un pack contra una unidad y computadores y laptops +41.289% porque la categoría de Convenio Marco está contaminada con accesorios y los atributos técnicos no existen. En categorías con pocos comparables y descripciones poco específicas, como repuesto portamina, la diferencia alcanza seis cifras por un emparejamiento poco confiable. En agregado, incluso la métrica de precio más robusta conserva un error absoluto medio de 5.184%, por lo que la comparación entre Compra Ágil y Convenio Marco no es válida en magnitud.

La consecuencia práctica es que el sistema debe operar como recomendador basado en Convenio Marco (clasificar el requerimiento, entregar una referencia y alertar) y reservar la comparación directa de precios de Compra Ágil para los registros que alcancen una estructura mínima. El caso del tóner lo ilustra: con treinta comparables de Convenio Marco y ninguno confiable de Compra Ágil, el sistema igualmente recomendó un precio de referencia y alertó una cotización con sobreprecio. La comparación de Compra Ágil, en cambio, solo será factible cuando cambie su captura de datos.

9. Implementación institucional y gobernanza

La implementación institucional debería realizarse por etapas. En una primera etapa, el pipeline puede operar como piloto analítico en un entorno de cómputo reproducible, permitiendo validar la metodología con muestras de productos y casos representativos. Esta etapa es adecuada para tesis y prototipos porque reduce infraestructura y facilita iteración.

En una segunda etapa, la solución debería transformarse en un servicio interno o API que reciba descripciones de productos, retorne categoría, comparables, precio de referencia y alertas. Para ello se requiere versionar modelos, controlar fuentes, registrar logs y separar ambientes de desarrollo y producción.

En una tercera etapa, el sistema puede integrarse con formularios de Compra Ágil. La recomendación principal es que el comprador no ingrese únicamente una descripción libre, sino que seleccione categoría, unidad, cantidad y atributos técnicos mínimos. El sistema podría sugerir campos obligatorios según categoría.

La gobernanza debe incluir roles claros: administrador de catálogo, experto de dominio, responsable de datos, usuario comprador y auditor. El

administrador mantiene taxonomía; el experto revisa casos ambiguos; el responsable de datos monitorea calidad; el comprador utiliza la recomendación; y el auditor revisa trazabilidad.

La mejora continua debe apoyarse en retroalimentación. Cada vez que un usuario corrige una categoría o confirma un comparable, esa decisión debería alimentar el catálogo y futuras reglas. Así, el sistema evoluciona desde un modelo estático hacia una plataforma de aprendizaje institucional; estos resguardos responden a los riesgos de deuda técnica documentados para sistemas de aprendizaje automático en producción (Sculley et al., 2015).

10. Conclusiones

La investigación confirma que el problema de Compra Ágil no es únicamente algorítmico, sino informacional. Los modelos de lenguaje ayudan a clasificar texto, pero la toma de decisiones requiere estructura: categorías, atributos, unidades, precios comparables y confianza. Por ello, la contribución central de la AFE es el diseño de un pipeline y una estructura de datos que convierten registros heterogéneos en evidencia para decidir.

La evidencia también precisa el alcance del sistema: es óptimo para analizar y recomendar dentro de Convenio Marco, pero no permite comparar los precios de Compra Ágil mientras esta carezca de estructura. Por ello, su contribución va más allá del pipeline: es el diseño de una estructura de captura (aplicada mediante un núcleo homologado, una unidad funcional de comparación y un puntaje de comparabilidad) que convierte progresivamente a Compra Ágil en una fuente comparable y habilita el benchmarking solo cuando los datos lo permiten.

Convenio Marco puede utilizarse como referencia operativa para construir taxonomía y precios, siempre que se reconozcan sus limitaciones. No todos los productos de Convenio Marco son equivalentes a los de Compra

Ágil, y no todos los precios son comparables sin normalización. La tesis propone usarlo como fuente de aprendizaje y contraste, no como verdad absoluta.

El enfoque híbrido es más adecuado que un enfoque puramente semántico. Las reglas normativas, códigos ONU/UNSPSC, extracción de unidades, marcas, TF-IDF y embeddings cumplen funciones complementarias. Esta arquitectura reduce falsos comparables, aumenta explicabilidad y permite activar revisión manual cuando la evidencia no es suficiente.

La selección del modelo final debe ser multicriterio. F1 weighted, accuracy, silhouette, calibración, throughput y separación inter/intra clase miden dimensiones distintas. El peso relativo propuesto prioriza clasificación y calibración porque la solución se orienta a decisiones públicas trazables. Un modelo rápido pero mal calibrado, o preciso pero opaco, no es suficiente.

La comparación de precios debe apoyarse en estadística robusta. La mediana y los percentiles son más apropiados que el promedio cuando existen valores extremos. Además, los precios históricos de Compra Ágil deben filtrarse por confiabilidad antes de usarse como referencia.

La propuesta de estructura de información para Compra Ágil constituye un aporte práctico. Si se registran atributos mínimos por categoría, unidad comparable, condiciones comerciales y justificación, se facilita la comparación entre cotizaciones, el monitoreo de precios y la evaluación posterior.

El sistema debe implementarse como apoyo a la decisión, no como mecanismo automático de adjudicación. Las alertas deben activar revisión y aprendizaje institucional. Esta condición es esencial para resguardar transparencia, evitar uso punitivo indebido y mantener responsabilidad humana en la compra pública.

10.1 Reflexión por objetivo específico

OE1 (diagnóstico de problemas de información). El diagnóstico se logró con evidencia cuantitativa: la corrida midió la restricción informacional de Compra Ágil (0% de marcas detectadas, 75,1% de registros sin dominio y ausencia de códigos UNSPSC), confirmando empíricamente el mapa de la Tabla 1. Su límite es de alcance: el diagnóstico se basa en dos períodos de datos y en la capacidad de detección del propio pipeline, y no distingue si la

carencia se origina en el formulario o en la práctica de registro, distinción que requeriría trabajo de campo con unidades compradoras.

OE2 (taxonomía basada en Convenio Marco). Se construyó una taxonomía operativa de 527 categorías en 7 dominios a partir de 3,78 millones de productos de Convenio Marco, enriquecida con reglas de normalización y clasificación, y demostró capacidad de ordenar el 93% de Compra Ágil. Como límite, la taxonomía hereda los defectos de su fuente: categorías contaminadas (computadores, con mediana distorsionada por accesorios) y dominios con soporte escaso (1.311 productos), que exigen la depuración continua prevista en la gobernanza del capítulo 9.

OE3 (documentar la arquitectura de la solución). El capítulo 7 documenta la arquitectura completa de datos a decisión (normalización, taxonomía, modelos, precios y recomendación), organizada por componente analítico y con sus decisiones de diseño justificadas. El límite es que lo documentado corresponde al prototipo evaluado: su traducción a una arquitectura productiva (servicios, versionado, ambientes) queda delineada en la hoja de ruta pero no implementada, por estar fuera del alcance de la AFE.

OE4 (comparar modelos con indicadores multicriterio). La comparación se realizó con cuatro modelos multilingües y seis indicadores, y su resultado principal es informativo por sí mismo: la diferencia de F1 entre el mejor y el peor fue de solo 0,092, un empate técnico que ninguna métrica única habría revelado. Sus límites son metodológicos y quedan declarados: el muestreo por categoría fue determinista y la calibración se midió mediante correlación (un proxy del error de calibración esperado), por lo que el resultado debe leerse como un empate con trade-offs y no como un ranking definitivo.

OE5 (esquema de ponderación para seleccionar el modelo). La ponderación multicriterio se propuso, se aplicó y seleccionó distiluse, declarando de forma transparente su desventaja de calibración frente a e5-small y dejando el modelo como parámetro configurable. Su límite es la naturaleza de los pesos: expresan prioridades del decisor y no fueron elicitados formalmente con expertos; con el conjunto etiquetado que la bitácora de revisión generaría, tanto los pesos como los umbrales podrían recalibrarse con base empírica.

OE6 (proponer una estructura de información). Se propuso una estructura mínima para Compra Ágil en la que cada campo se justifica por la falla empírica que corrige (Sección 10.5), junto a un modelo operativo gradual que

preserva la agilidad de la modalidad. El límite es que su efectividad es una proyección fundada en la evidencia, pero aún no medida: validar cuánto se reduce el error de precio con unidad y contenido homologados requiere el piloto de unidad funcional propuesto como trabajo futuro.

OE7 (lineamientos de implementación y gobernanza). El capítulo 9 establece una hoja de ruta por etapas, roles de gobernanza y un ciclo de mejora continua alimentado por la revisión humana, con resguardos frente a los riesgos de operación de sistemas de aprendizaje automático. Como límite, los lineamientos son de diseño institucional: su adopción depende de decisiones de ChileCompra y de las unidades compradoras que exceden el control de este trabajo, por lo que se formulan como condiciones habilitantes y no como resultados.

10.2 Estado de las hipótesis

Hipótesis principal. Se sostiene: el pipeline híbrido (reglas, códigos, embeddings, TF-IDF y calibración robusta) produce un catálogo más útil para decidir que un enfoque de solo texto o solo similitud, aunque su utilidad depende críticamente de la estructura de los datos de entrada.

H1 (Convenio Marco como referencia). Se sostiene con reservas: Convenio Marco sirvió como referencia operativa (527 categorías, 3,78 M de productos), pero su comparabilidad técnica y de precio es limitada, como muestra la contaminación de la categoría computadores.

H2 (la normalización mejora la clasificación). Se sostiene parcialmente: la normalización permitió clasificar el 93% de Compra Ágil, pero el 0% de marcas y el 75% sin dominio muestran que falta estructura en el origen, no solo limpieza.

H3 (selección multicriterio del modelo). Se confirma: la diferencia de F1 entre modelos fue de 0,092 y la selección dependió de la cohesión y la calibración, no del accuracy.

H4 (precios con estadística robusta y revisión). Se confirma: el Percentil 25 fue la métrica más robusta, pero su error absoluto medio residual obliga a revisión humana y filtros de confiabilidad.

H5 (una estructura mínima mejora la comparabilidad). Se confirma: la ausencia de estructura mínima es la causa directa de la baja confianza y del error de precio, lo que fundamenta la propuesta de la Sección 10.5.

10.3 Trabajo futuro

- Incorporar extracción de atributos técnicos mediante modelos de lenguaje con prompts controlados y validación por reglas.
- Construir un módulo de aprendizaje activo donde expertos revisen casos de baja confianza y retroalimenten el catálogo.
- Desarrollar una API para consulta en línea desde sistemas institucionales de compra.
- Evaluar modelos por dominio y considerar ensambles cuando un único embedding no sea óptimo para todas las categorías.
- Integrar series de tiempo de precios para ajustar referencias por fecha, inflación, región y estacionalidad.
- Diseñar un tablero de monitoreo que muestre categorías con mayor dispersión de precios, baja calidad de datos y oportunidades de mejora de catálogo.

10.4 Recomendaciones

Las siguientes recomendaciones se dirigen a la institución compradora (ChileCompra y las unidades de compra) y se derivan de los hallazgos empíricos de la corrida.

- **Operar el sistema como apoyo a la decisión, no como clasificador automático.** Con una confianza promedio de 0,405 sobre CA y solo 0,5% de casos de confianza alta, la categorización automática sin revisión no es defendible. Se recomienda un flujo de dos vías: alta confianza → sugerencia directa; confianza media o baja (la mayoría) → sugerencia con revisión del comprador.
- **Tratar el precio de referencia como rango, no como punto.** Dado el MAE de 5.184% de la mejor métrica, el sistema debe mostrar mediana y percentiles 25/75 con su número de comparables y nivel de confianza, y abstenerse cuando hay pocos comparables o unidades no homologables. El sistema no debe emitir un precio único presentado como valor justo.
- **Comunicar el ahorro como cota indicativa.** La señal "CM más barato en 11/14 categorías" es válida y respalda el Art. 14 bis; la cifra de \$202M/mes no lo es como estimación puntual y debe reportarse con su intervalo y advertencia de comparabilidad.
- **Mantener el modelo como parámetro configurable.** distiluse gana en F1 y cohesión pero pierde en calibración; e5-small es preferible si prima saber cuándo abstenerse. La elección debe poder ajustarse por dominio y revisarse con expertos.

- **Implementar una bitácora de revisión manual.** Cada caso de baja confianza o alerta de precio que el comprador acepte, corrija o rechace debe registrar la razón. Esa bitácora audita decisiones y construye el conjunto de entrenamiento etiquetado de CA que hoy no existe (cuya ausencia explica la brecha entre fuentes medida en la Sección 8.3).
- **Formalizar un ciclo de actualización mensual de precios.** Recalcular referencias con la UTM vigente y la fecha de extracción; un precio de referencia sin fecha pierde validez en un contexto inflacionario.
- **Documentar limitaciones de comparabilidad por categoría.** Marcar las categorías con soporte bajo (ej. computadores, 1.311 productos CM) o con artefactos de unidad como no aptas para comparación automática de precio hasta sanear sus datos.

10.5 Recomendación principal: rediseño de la estructura de información de Compra Ágil

Esta es la recomendación de mayor impacto del trabajo y se desprende directamente de los resultados. La corrida demostró que el cuello de botella no es el modelo: con datos limpios el sistema alcanza F1 0,894, pero sobre Compra Ágil real la confianza cae a 0,405, no detecta marcas (0,0%), deja el

75,1% sin dominio, carece de códigos UNSPSC (0%) y arrastra un error de precio de 5.184%. Todas estas fallas tienen una causa común y corregible en origen: la Compra Ágil se registra como texto libre, sin unidad homologada, sin cantidad por envase, sin atributos técnicos y con la marca mezclada en la descripción. Mientras la captura no cambie, ningún modelo podrá comparar precios de forma confiable.

El principio que ordena la propuesta es estructurar la información en el origen: se propone que el formulario de Compra Ágil capture, al crear la solicitud, un conjunto mínimo de campos estructurados, validados antes de permitir el envío. Bajo este diseño, el rol del componente de NLP cambia de inferir la categoría desde texto libre a asistir el registro: sugiere la categoría, propone atributos según la categoría seleccionada y alerta valores fuera de rango, mientras la estructura queda garantizada por el formulario y no por el modelo.

La siguiente tabla mapea cada campo propuesto con la falla empírica concreta que corrige:

Campo obligatorio	Qué corrige (evidencia de la corrida)	Métrica impactada
Categoría desde taxonomía (selección, no texto libre)	Elimina el 75,1% de registros "sin dominio" al forzar una categoría válida del catálogo.	Cobertura y confianza de clasificación
Unidad de medida normalizada + cantidad por envase	Permite calcular precio unitario homologado; ataca el MAE de 5.184% y los artefactos tipo "computador \$957".	Validez del precio de referencia

Campo obligatorio	Qué corrige (evidencia de la corrida)	Métrica impactada
Marca y modelo en campos separados	Resuelve el 0,0% de marcas detectadas, hoy perdidas dentro del texto libre.	Precisión de comparables
Atributos técnicos mínimos por categoría (formulario dinámico)	Habilita comparación homogénea (notebook: CPU/RAM/SSD/pantalla/garantía; papel: tamaño/gramaje/hojas; tóner: modelo/rendimiento).	Comparabilidad técnica real
Código UNSPSC/ONU sugerido y confirmado	Resuelve el 0% de cobertura de códigos; da taxonomía estable y trazable.	Clasificación y auditoría
Desglose de costos: precio neto vs. flete / instalación / garantía	Remueve el sesgo al alza que infla los precios de CA y distorsiona la comparación con CM.	Calibración de precios

Tabla 11. Estructura mínima obligatoria para Compra Ágil, mapeada a la falla empírica que corrige.

Esta estructura hace eficiente la comparación y la recomendación: con unidad y cantidad homologadas, el precio deja de compararse sobre montos no equivalentes y el MAE debería caer de varios miles por ciento a un rango operable; con categoría y atributos obligatorios, la confianza de clasificación deja de depender de la inferencia sobre texto libre y el recomendador puede operar sobre casos de alta confianza en vez del actual 0,5%. La incorporación de un número acotado de campos en el formulario permite que el sistema transite desde un apoyo condicionado por la calidad de los datos hacia una recomendación con respaldo empírico.

El modelo operativo propuesto es una estructura gradual con unidad funcional y puntaje de comparabilidad. El conjunto completo de campos de la Tabla 11 constituye el perfil objetivo de datos; exigirlo de manera íntegra en cada transacción comprometería el carácter expedito de la modalidad. Por

ello se propone un modelo operativo gradual que llega a ese perfil con la menor fricción posible, sobre cuatro componentes.

- **Núcleo homologado obligatorio:** categoría desde taxonomía, unidad base y cantidad, precio neto por unidad y marca. Con estos cuatro campos, livianos y rápidos, el sistema ya clasifica y calcula un precio unitario, preservando la agilidad.
- **Unidad funcional de comparación por categoría:** el sistema compara en una unidad propia de cada rubro (CLP por hoja A4, por página de tóner, por litro, por kilo o por perfil de atributos), de modo que el tamaño del envase deja de distorsionar la comparación.
- **Ficha técnica progresiva y asistida:** los atributos de la Tabla 11 se exigen solo en las categorías críticas de comparación y se autocompletan desde la descripción para que el comprador los confirme, reduciendo la carga manual.
- **Puntaje de comparabilidad:** cada registro se puntúa según la presencia de unidad normalizada, atributos, confiabilidad del precio y número de comparables; el puntaje habilita el benchmarking pleno solo cuando los datos lo permiten y, en caso contrario, degrada la conducta a

recomendación de referencia, evitando reportar diferencias inválidas como el +41.289% observado en computadores.

De esta forma, la propuesta integra ambos enfoques: la estructura completa opera como meta de calidad de datos, y el modelo gradual permite alcanzarla sin sacrificar la agilidad de la modalidad ni la validez de las comparaciones reportadas.

Implementación gradual y realista:

- Fase 1: Pilotar en categorías estandarizadas de alta recurrencia (papel, tóner, computadores, aseo), donde el Convenio Marco ofrece la referencia más limpia y el beneficio es inmediato.
- Fase 2: Validación en formulario: no permitir el envío de la solicitud sin categoría, unidad y cantidad; atributos según la categoría seleccionada.
- Fase 3: Asistencia del modelo: el sistema sugiere categoría y precio de referencia con su nivel de confianza, y marca para revisión los casos bajo umbral o con pocos comparables.
- Fase 4: Retroalimentación: la bitácora de revisión alimenta un conjunto de validación etiquetado de Compra Ágil que cierra la brecha entre fuentes medida en la Sección 8.3 y mejora cada versión del modelo.

Así, la propuesta de estructura deja de ser una aspiración metodológica y se constituye, con sustento en la evidencia empírica de la corrida, en el mecanismo que transforma datos heterogéneos de Compra Ágil en información apta para comparar precios y recomendar decisiones de forma trazable y eficiente.

11. Bibliografía

Biblioteca del Congreso Nacional de Chile. (2023). *Ley N.º 21.634: Moderniza la Ley N.º 19.886 y otras leyes, para mejorar la calidad del gasto público, aumentar los estándares de probidad y transparencia e introducir principios de economía circular en las compras del Estado*. Ley Chile. <https://nuevo.leychile.cl/navegar?idNorma=1198903>

ChileCompra. (s. f.). *Compra Ágil*. Recuperado el 25 de julio de 2026, de <https://www.chilecompra.cl/compraagil/>

ChileCompra. (2024, 12 de diciembre). *Conoce las principales disposiciones del nuevo Reglamento de Compras Públicas*. <https://www.chilecompra.cl/2024/12/conoce-las-principales-disposiciones-del-nuevo-reglamento-de-compras-publicas/>

DAMA International. (2017). *DAMA-DMBOK: Data management body of knowledge* (2nd ed.). Technics Publications.

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. En J. Burstein, C. Doran, & T. Solorio (Eds.), *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)* (pp. 4171–4186). Association for Computational Linguistics. <https://doi.org/10.18653/v1/N19-1423>

Guo, C., Pleiss, G., Sun, Y., & Weinberger, K. Q. (2017). On calibration of modern neural networks. *Proceedings of Machine Learning Research*, 70, 1321–1330. <https://proceedings.mlr.press/v70/guo17a.html>

Huber, P. J. (1981). *Robust statistics*. John Wiley & Sons.

Jurafsky, D., & Martin, J. H. (2023). *Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition* (3rd ed. draft). https://web.stanford.edu/~jurafsky/slp3/old_jan23/ed3book_jan72023.pdf

Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to information retrieval*. Cambridge University Press. <https://doi.org/10.1017/CBO9780511809071>

Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient estimation of word representations in vector space. *arXiv*. <https://doi.org/10.48550/arXiv.1301.3781>

OECD. (2015). *Recommendation of the Council on Public Procurement*. <https://legalinstruments.oecd.org/en/instruments/OECD-LEGAL-0411>

OECD. (2019). *Productivity in public procurement: A case study of Finland—Measuring the efficiency and effectiveness of public procurement*. <https://www.oecd.org/gov/public-procurement/publications/productivity-public-procurement.pdf>

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830. <https://www.jmlr.org/papers/v12/pedregosa11a.html>

Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. En K. Inui, J. Jiang, V. Ng, & X. Wan (Eds.), *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing* (pp. 3982–3992). Association for Computational Linguistics. <https://doi.org/10.18653/v1/D19-1410>

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65. [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7)

Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5), 513–523. [https://doi.org/10.1016/0306-4573\(88\)90021-0](https://doi.org/10.1016/0306-4573(88)90021-0)

Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., Young, M., Crespo, J.-F., & Dennison, D. (2015). Hidden technical debt in machine learning systems. *Advances in Neural Information Processing Systems*, 28, 2503–2511. <https://proceedings.neurips.cc/paper/5656-hidden-technical-debt-in-machine-learning-systems>

Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4), 427–437. <https://doi.org/10.1016/j.ipm.2009.03.002>

Spärck Jones, K. (1972). A statistical interpretation of term specificity and its application in retrieval. *Journal of Documentation*, 28(1), 11–21. <https://doi.org/10.1108/eb026526>
UNSPSC. (s. f.). *United Nations Standard Products and Services Code*. Recuperado el 25 de julio de 2026, de <https://www.unspsc.org/>

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30, 5998–6008. <https://proceedings.neurips.cc/paper/7181-attention-is-all-you-need>

Wang, R. Y., & Strong, D. M. (1996). Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems*, 12(4), 5–33. <https://doi.org/10.1080/07421222.1996.11518099>

World Bank. (2020). *Enhancing government effectiveness and transparency: The fight against corruption*. <https://openknowledge.worldbank.org/handle/10986/34533>

Yáñez Cornejo, C. (2025). *Modelos predictivos de mortalidad: Comparación de técnicas tradicionales y algoritmos de machine learning* [Actividad Formativa Equivalente a Tesis de magíster, Universidad de Chile].

Anexos

Anexo A. Mapa de variables y campos sugeridos

Este anexo resume los campos recomendados para implementar un catálogo estructurado en Compra Ágil. Los campos deben adaptarse a cada categoría, pero la lógica general se mantiene: identificar producto, unidad, atributos, cotización, proveedor y referencia de mercado.

Tabla A1. Campos mínimos por entidad.

Entidad	Campos sugeridos
Producto	id_producto_estandar, categoria, codigo_onu, descripcion_normalizada, atributos, unidad_comparable
Compra Ágil ítem	id_solicitud, id_item, descripcion_original, cantidad, unidad, precio_unitario, precio_total
Cotización	id_cotizacion, proveedor, rut, precio, plazo, flete, garantia, seleccionado
Referencia	fuelle, precio_mediana, p25, p75, fecha_calculo, n_comparables, confianza

Anexo B. Pseudo-código del pipeline

- Cargar archivos desde Drive y detectar dominio.
- Homologar columnas según mapas flexibles.
- Normalizar descripciones, unidades, marcas y códigos.
- Construir diccionario estructurado desde Convenio Marco.
- Comparar embeddings y seleccionar modelo según score compuesto.
- Clasificar productos CA usando reglas y similitud semántica.
- Buscar comparables CM y CA histórica confiable.
- Calcular precio recomendado y nivel de confianza.
- Emitir alerta, recomendación y exportar evidencia.

Anexo C. Conjunto de prueba de extracción de atributos revisado manualmente

Protocolo. Cada descripción fue anotada manualmente con la presentación esperada (cantidad y unidad canónica del contenido o formato de venta; vacío si no corresponde) y la marca esperada del producto principal (sin marca si no figura). La columna Origen distingue las descripciones extraídas textualmente de la corrida de las construidas replicando patrones observados en los datos. Las columnas Detectado reportan la salida del código sin modificaciones. P y M indican acierto de presentación y de marca, respectivamente. Resumen: presentación 66,7% de acierto global (46,2% pleno y 57,7% de coincidencia de valor sobre los 26 casos con presentación; 1 falso positivo en 19 negativos); marca 84,4% global (precisión 93,3%, recall 70,0%).

N°	Descripción	Origen	Esperado presentación	Esperado marca	Detectado presentación / Detectado marca	P·M
1	ADAPTADOR VGA MAYFIELD MACHOHDMI TIPO A	Corrida	—	mayfield	— / sin marca	✓ X
2	CABLE HDMI MAYFIELD HDMI 1,4 V 1,8 M TIPO A	Corrida	1.8 m	mayfield	— / sin marca	X X
3	CABLE HDMI MAYFIELD HDMI 1,4 V 2 M TIPO A	Corrida	2 m	mayfield	— / sin marca	X X
4	CABLE VGA MAYFIELD 1,8 M MACHOMACHO UNIDAD	Corrida	1.8 m	mayfield	— / sin marca	X X
5	CABLE VGA MAYFIELD 3,0 M MACHOMACHO UNIDAD	Corrida	3 m	mayfield	— / sin marca	X X
6	Notebook	Corrida	—	sin marca	— / sin marca	✓ ✓
7	NOTEBOOKS	Corrida	—	sin marca	— / sin marca	✓ ✓
8	Notebook Laptop	Corrida	—	sin marca	— / sin marca	✓ ✓
9	soporte notebook	Corrida	—	sin marca	— / sin marca	✓ ✓

10	7 COMPUTADORES SEGUN ARCHIVO ADJUNTO	Corrida	7 unid	sin marca	— / sin marca	✗✓
11	Notebook Procesador AMD Ryzen 7 7730U (8C/16T) 16GB RAM 512GB SSD	Corrida	—	sin marca	16 g / amd	✗✗
12	MUEBLE COMPUTADOR REGIÁN DE COQUIMBO	Corrida	—	sin marca	— / sin marca	✓✓
13	Toner HP LaserJet	Corrida	—	hp	— / hp	✓✓
14	Papel higiénico	Corrida	—	sin marca	— / sin marca	✓✓
15	Silla ergonómica de escritorio	Corrida	—	sin marca	— / sin marca	✓✓
16	computador	Corrida	—	sin marca	— / sin marca	✓✓
17	fideos	Corrida	—	sin marca	— / sin marca	✓✓
18	DETERGENTE LIQUIDO 6X1LT	Construido	6 lt	sin marca	6 lt / sin marca	✓✓
19	BEBIDA GASEOSA 12X500ML	Construido	6000 ml	sin marca	6000 ml / sin marca	✓✓
20	LECHE ENTERA COLUN 12X1LT	Construido	12 lt	colun	12 lt / colun	✓✓
21	DETERGENTE OMO EN POLVO 3 KG	Construido	3 kg	omo	3 kg / omo	✓✓
22	COLORO CLOROX TRADICIONAL 2 LT	Construido	2 lt	clorox	2 lt / clorox	✓✓
23	ARROZ TIKI GRADO 1 1 KG	Construido	1 kg	tika	1 kg / tika	✓✓
24	CAFE NESCAFE TRADICION FRASCO 170 G	Construido	170 g	nescafe	170 g / nescafe	✓✓
25	JABON LIQUIDO MANOS 900CC	Construido	900 ml	sin marca	900 ml / sin marca	✓✓
26	ALCOHOL GEL BIDON 5 LITROS	Construido	5 lt	sin marca	5 l / sin marca	✗✓
27	PAPEL HIGIENICO ELITE 30 MTS X 12 ROLLOS	Construido	30 m	elite	12 rol / sin marca	✗✗
28	RESMA PAPEL FOTOCOPIA A4 75 GR 500 HOJAS	Construido	500 hojas	sin marca	75 gr / sin marca	✗✓
29	TONER HP 85A NEGRO ORIGINAL	Construido	—	hp	— / hp	✓✓
30	IMPRESORA EPSON L3250 MULTIFUNCIONAL	Construido	—	epson	— / epson	✓✓
31	NOTEBOOK LENOVO THINKPAD 14 PULGADAS	Construido	—	lenovo	— / lenovo	✓✓
32	MOUSE LOGITECH M170 INALAMBRICO	Construido	—	logitech	— / logitech	✓✓
33	TALADRO PERCUTOR MAKITA 750W	Construido	—	makita	— / makita	✓✓
34	MARTILLO CARPINTERO STANLEY 16 OZ	Construido	16 oz	stanley	— / stanley	✗✓
35	CINTA ADHESIVA SCOTCH 48MM X 40M	Construido	48 mm	scotch	— / scotch	✗✓
36	LAPIZ PASTA BIC AZUL CAJA 12 UNID	Construido	12 unid	bic	12 un / bic	✗✓
37	GUANTES NITRILO TALLA M CAJA 100 UNID	Construido	100 unid	sin marca	100 un / sin marca	✗✓
38	MASCARILLA N95 CAJA 20 UNIDADES	Construido	20 unid	sin marca	95 cja / sin marca	✗✓
39	ALCOHOL DESNATURALIZADO 70% 1 LT	Construido	1 lt	sin marca	1 lt / sin marca	✓✓
40	DETERGENTE EN POLVO BOLSA 800 GR	Construido	800 gr	sin marca	800 gr / sin marca	✓✓
41	ACEITE VEGETAL 900 ML	Construido	900 ml	sin marca	900 ml / sin marca	✓✓
42	AGUA PURIFICADA BIDON 20 LT	Construido	20 lt	sin marca	20 lt / sin marca	✓✓
43	COMPRA INSUMOS DE ASEO SEGUN DETALLE ADJUNTO	Construido	—	sin marca	— / sin marca	✓✓
44	SERVICIO DE MANTENCION AIRE ACONDICIONADO	Construido	—	sin marca	— / sin marca	✓✓
45	PAPEL TERMICO 80MM X 40MTS	Construido	80 mm	sin marca	— / sin marca	✗✓

Tabla C1. Conjunto de prueba de extracción de atributos (45 casos) con verdad de terreno anotada manualmente y salida del código.

Anexo D. Resultados detallados de la corrida (04/05/2026)

Este anexo reúne las salidas de ejecución que respaldan la Sección 8. Las imágenes corresponden a la corrida del código consolidado (versión final) en un entorno de cómputo reproducible.

D.1 Auditoría de calidad de datos. La auditoría sobre el CM unificado (3.778.844 productos, 533 categorías) reporta cobertura de marcas y precios cercana al 100% en CM, pero en Compra Ágil las marcas se detectan en 0% y los códigos UNSPSC en 0% en todos los dominios. Se incluye además una muestra del texto normalizado (NLP) de Compra Ágil.


```

=== PROCESANDO COMPRAS AGILES ===
Extrayendo marcas desde descripcion (CA)...
* CA precio_unitario: fuente=MontoTotal(adj) con fallback MontoTotalDisponble(disp)
CA con precio>0: 562,121/562,190 (100.0%) | mediana=$64,260 | max=$1,939,979
CA filas con precio=0 (no adjudicadas): 69 -> se excluirán del comparador
CA excluidas 69 filas sin precio (ofertas no adjudicadas)
[CA] Estructura A | 562,190 -> 562,112 registros
Extrayendo marcas desde descripcion (CA)...
CA precio_unitario: fuente=MontoTotal(adj) con fallback MontoTotalDisponble(disp)
CA con precio>0: 571,138/571,145 (100.0%) | mediana=$134,589 | max=$6,954,200
CA filas con precio=0 (no adjudicadas): 7 -> se excluirán del comparador
CA excluidas 7 filas sin precio (ofertas no adjudicadas)
[CA] Estructura A | 571,145 -> 571,113 registros

=== AUDITORIA DE CALIDAD ===
CM unificado : 3,778,844 productos | 533 categorias
[escritorio_papeleria ] 726,535 prod | E=B | cats=69 | marcas=100% | precios=99% | modelo=100% | UNSPSC=0%
[aseo ] 1,169,122 prod | E=B | cats=35 | marcas=100% | precios=100% | modelo=100% | UNSPSC=0%
[computadores ] 1,311 prod | E=B | cats=6 | marcas=100% | precios=95% | modelo=100% | UNSPSC=0%
[ferreteria ] 953,956 prod | E=B | cats=130 | marcas=100% | precios=100% | modelo=100% | UNSPSC=0%
[insumos_medicos ] 14,469 prod | E=B | cats=103 | marcas=100% | precios=98% | modelo=100% | UNSPSC=0%
[mobiliario ] 146,790 prod | E=B | cats=63 | marcas=100% | precios=0% | modelo=100% | UNSPSC=0%
[alimentos ] 766,661 prod | E=B | cats=229 | marcas=100% | precios=100% | modelo=100% | UNSPSC=0%
[Compras Agiles ] 1,133,225 prod | long=21 | vocab=7,133 | precios=97% | marcas=0%

Muestra texto NLP (estructura B):
ORIG: ADAPTADOR VGA MAYFIELD MACHOHDMI TIPO A
NLP : adaptador vga adaptador vga mayfield machohdmi region viii

ORIG: CABLE HDMI MAYFIELD HDMI 1.4 V 1,8 M TIP
NLP : cable hdmi cable hdmi mayfield hdmi region viii

ORIG: CABLE HDMI MAYFIELD HDMI 1.4 V 2 M TIPO
NLP : cable hdmi cable hdmi mayfield hdmi region viii

ORIG: CABLE VGA MAYFIELD 1,8 M MACHOMACHO UNID
NLP : cable vga cable vga mayfield machomacho region viii

ORIG: CABLE VGA MAYFIELD 3,0 M MACHOMACHO UNID
NLP : cable vga cable vga mayfield machomacho region viii

Procesamiento completado.

```

Figura D1. Procesamiento de Compras Ágiles y auditoría de calidad por dominio.

D.2 Procesamiento de Convenios Marco y diccionario estructurado.

Detección de dominios, categorías internas y construcción del diccionario (527 categorías, 3.731 palabras clave).

```

=== PROCESANDO CONVENIOS MARCO (todos los dominios) ===

... [escritorio_papeleria]
[CM_escritorio_papeleria] NLP fallback: 407,851 filas (56.1%)
[CM_escritorio_papeleria] Categorías internas asignadas: 69 (de 106 TIPO PRODUCTO únicos)
[CM_escritorio_papeleria] Sin categoría: 0 (0.0%)
[CM_escritorio_papeleria] Top categorías:
marcadores y resaltadores      87,312 (12.0%)
lapices y escritura             64,047 (8.8%)
archivadores y carpetas        53,275 (7.3%)
notas adhesivas y blocs        44,280 (6.1%)
papel y resmas                  41,366 (5.7%)
adhesivos y cintas              39,227 (5.4%)
tijeras reglas y accesorios     39,089 (5.4%)
clips grapas perforadoras      31,245 (4.3%)
[CM_escritorio_papeleria] Estructura B | 726,535 -> 726,535 registros

[aseo]
[CM_aseo] NLP fallback: 591,020 filas (50.6%)
[CM_aseo] Categorías internas asignadas: 36 (de 45 TIPO PRODUCTO únicos)
[CM_aseo] Sin categoría: 2 (0.0%)
[CM_aseo] Top categorías:
papel higienico y toallas       168,117 (14.4%)
bolsas y desechos               158,694 (13.6%)
limpiadores de superficies      157,809 (13.5%)
desinfectantes                  152,979 (13.1%)
detergentes y lavalozas         59,132 (5.1%)
PAÑAL DE ADULTO                 40,537 (3.5%)
ESCOBILLON                      35,490 (3.0%)
PAÑOS                           31,200 (2.7%)
[CM_aseo] Estructura B | 1,169,124 -> 1,169,122 registros

[computadores]
[CM_computadores] NLP fallback: 934 filas (71.2%)
[CM_computadores] Categorías internas asignadas: 6 (de 12 TIPO PRODUCTO únicos)
[CM_computadores] Sin categoría: 0 (0.0%)
[CM_computadores] Top categorías:
computadores y laptops          576 (43.9%)
software y licencias            257 (19.6%)
tablets y celulares             203 (15.5%)
monitores y pantallas           174 (13.3%)
servidores                      52 (4.0%)
cables y accesorios ti          49 (3.7%)
[CM_computadores] Estructura B | 1,311 -> 1,311 registros

[ferreteria]
[CM_ferreteria] NLP fallback: 881,959 filas (92.5%)
[CM_ferreteria] Categorías internas asignadas: 131 (de 192 TIPO PRODUCTO únicos)
[CM_ferreteria] Sin categoría: 1 (0.0%)
[CM_ferreteria] Top categorías:
material electrico              86,939 (9.1%)
seguridad y epp                 86,799 (9.1%)
plomeria                        73,436 (7.7%)
pinturas y recubrimientos       46,006 (4.8%)
adhesivos y cintas              39,577 (4.1%)
guantes y epp medico            38,493 (4.0%)
fijacion y ferreteria menor     38,383 (4.0%)
alimentacion saludable          29,477 (2.1%)

```

Figura D2. Procesamiento de Convenios Marco por dominio (top categorías).

... Diccionario listo: 527 categorías | 3731 keywords | /content/afe_cache/structured_dictionary.json

Figura D3. Diccionario estructurado: 527 categorías con precio promedio por categoría.

```
=====
INICIANDO PIPELINE DE CLASIFICACION MULTI-DOMINIO
=====
CMs disponibles : ['escritorio_papelaria', 'aseo', 'computadores', 'ferreteria', 'insumos_medicos', 'mobiliario', 'alimentos']
CM unificado      : 3,778,844 productos
Compras Agiles    : 1,133,225 registros
=====
Procesador listo | modelo=distilluse-base-multilingual-cased-v1 | device=cuda
Cargando modelo distilluse-base-multilingual-cased-v1...

Loading weights: 100% ██████████ 100/100 [00:00<00:00, 935.22it/s, Materializing param=transformer.layer.5.sa_layer_norm.weight]

[1/3] Embeddings CM unificado (3,778,844 productos)...

Batches: 100% ██████████ 29523/29523 [50:15<00:00, 22.68it/s]

Caché guardado → /content/afe_cache/conv_emb.npy
3,778,844 embeddings en 3067.6s

[2/3] Construyendo centroides (multi-dominio)...
510 centroides de 7 dominios

[3/3] CA: 0 con categoria (TIPO_PRODUCTO_MAP), 1,133,225 para NLP...

Embedding: 1,133,223 productos...
Clasificados: 93.0% (1,053,785/1,133,225) en 596.9s
Por metodo: {'embedding': 1039157, 'sin_clasif': 79440, 'reglas_bajo': 14626, 'reglas': 2}
Por dominio: {'desconocido': 858797, 'aseo': 72449, 'computadores': 69919, 'alimentos': 36296, 'escritorio_papelaria': 32482, 'mobiliario': 29085, 'insumos_medicos': 21899,
Embeddings Compras Agiles (30,000 items)...

Batches: 100% ██████████ 235/235 [00:09<00:00, 43.02it/s]

Embeddings CA listos.

Pipeline completado.
Centroides generados : 510
Dominios representados: 9
```

Figura D4. Log de ejecución del pipeline de clasificación multi-dominio.

D.4 Métricas de calibración de precios. Comparación de las 10 métricas estadísticas de precio CA contra la mediana de CM en 313 categorías; el Percentil 25 minimiza el error absoluto medio.

Categorías evaluadas: 313 Referencia: mediana CM									
Métrica	MAE % Sesgo vs CM								

Media simple	(sesgado por outliers)	27571.0%	sobrepr	27570.2%					
Mediana	(robusto)	13498.4%	sobrepr	13489.5%					
Media truncada 10%	(excluye 5% extremos)	18685.5%	sobrepr	18681.6%					
Media IQR-filtrada	(sin outliers IQR)	17652.7%	sobrepr	17647.1%					
Percentil 25	(cota inferior)	5184.2%	sobrepr	5158.7%	◀ SELECCIONADA				
Media Winsorizada20%		22449.1%	sobrepr	22446.5%					
Bulk (cant>=5) IQR	(precio volumen)	7138.6%	sobrepr	7124.2%					
Mediana unitaria	(cant==1, precio exacto)	46206.4%	sobrepr	46205.1%					
Media pond. cantidad	(vol-weighted)	7165.5%	sobrepr	7132.2%					
Mediana IQR raw	(MontoTotal+cant directo)	12215.0%	sobrepr	12203.2%					
Métrica seleccionada : Percentil 25 (cota inferior) (MAE% = 5184.2%)									
Categoría	CM med	m5_p25	Dif%	n_CA	CV%	%bulk	%unit	cant_med	

pilar	\$ 34,282	\$ 1,218,354	+3453.9%	1,335	68.6%	6.4%	87.2%	1.0	▲
ramita	\$ 716	\$ 1,145,375	+159868.6%	6	100.7%	0.0%	100.0%	1.0	▲
servidores	\$ 2,821	\$ 989,456	+34976.4%	179	82.7%	0.6%	87.2%	1.0	▲
rigati	\$ 964	\$ 815,859	+84532.7%	105	46.4%	4.8%	26.7%	3.0	▲
tiza escolar	\$ 1,023	\$ 747,370	+72956.7%	10	54.2%	0.0%	100.0%	1.0	▲
placa compactadora electrica	\$ 665,630	\$ 569,385	-14.5%	747	96.8%	5.4%	78.3%	1.0	▲
material electrico	\$ 7,349	\$ 475,820	+6374.6%	21	109.5%	0.0%	33.3%	2.0	▲
cja distribucion	\$ 1,072	\$ 465,766	+43348.3%	96	101.2%	2.1%	69.8%	1.0	▲
te	\$ 2,262	\$ 461,810	+20316.0%	7	66.7%	28.6%	71.4%	1.0	▲
pera	\$ 1,585	\$ 444,632	+27952.5%	205	87.0%	13.2%	31.7%	2.0	▲
repuesto portamina escolar	\$ 209	\$ 426,615	+204022.0%	403	107.1%	2.0%	95.8%	1.0	▲
estufa electrica	\$ 42,042	\$ 418,938	+896.5%	560	102.6%	13.0%	70.7%	1.0	▲
kit instalacion wc	\$ 5,402	\$ 416,500	+7610.1%	900	106.8%	11.7%	75.0%	1.0	▲
computadores y laptops	\$ 826	\$ 396,136	+47858.4%	28,144	114.3%	18.5%	50.6%	1.0	▲
equipo de aspiracion continua	\$ 5,849	\$ 344,922	+5797.1%	1,003	122.7%	10.4%	78.6%	1.0	▲
monomando lavaplatos	\$ 19,526	\$ 327,250	+1576.0%	5	73.3%	20.0%	0.0%	2.0	▲
chucrut	\$ 2,578	\$ 295,198	+11350.7%	21	63.1%	0.0%	66.7%	1.0	▲
estufa a parafina	\$ 283,547	\$ 283,058	-0.2%	2,163	125.7%	7.7%	70.8%	1.0	▲
perfil metalcon	\$ 6,168	\$ 282,990	+4488.0%	126	135.6%	31.0%	64.3%	1.0	▲
repollo fresco con rs	\$ 985	\$ 280,589	+28386.2%	80	87.3%	8.8%	68.8%	1.0	▲
trapero reutilizable	\$ 1,053	\$ 279,075	+26402.8%	27	128.5%	0.0%	55.6%	1.0	▲
tortillas	\$ 2,377	\$ 251,349	+10474.2%	306	67.7%	15.7%	54.6%	1.0	▲
longanilla	\$ 2,638	\$ 228,125	+8549.3%	235	73.5%	23.0%	77.0%	1.0	▲
pimenton fresco	\$ 860	\$ 226,100	+26206.0%	189	96.9%	24.3%	67.2%	1.0	▲
durazno	\$ 1,939	\$ 224,000	+11452.3%	1,209	111.1%	30.5%	9.8%	4.0	▲
tablets y celulares	\$ 399	\$ 218,575	+54739.8%	961	126.0%	18.8%	44.5%	2.0	▲
proyectoros	\$ 39,097	\$ 217,298	+455.8%	4,720	133.3%	31.6%	48.8%	2.0	▲
alargador venoso	\$ 25,762	\$ 215,027	+734.7%	9	30.2%	0.0%	100.0%	1.0	▲
sonda foley	\$ 4,795	\$ 205,357	+4182.7%	10	54.4%	60.0%	0.0%	5.0	▲
sacapuntas	\$ 212	\$ 203,030	+95668.9%	5,356	138.5%	28.8%	33.3%	2.0	▲
tabla periodica	\$ 233	\$ 202,062	+86621.9%	224	111.9%	18.3%	30.4%	2.0	▲
aerocamara	\$ 2,499	\$ 201,871	+7978.1%	1,979	110.6%	25.9%	57.3%	1.0	▲
software y licencias	\$ 798	\$ 198,392	+24761.2%	2,802	128.3%	24.4%	53.9%	1.0	▲
monitores y pantallas	\$ 2,250	\$ 196,854	+8649.1%	7,865	138.3%	29.0%	44.0%	2.0	▲

Figura D5. Tabla de métricas de precio por categoría (extracto de la corrida).