

UNIVERSIDAD DE CHILE
FACULTAD DE ECONOMÍA Y NEGOCIOS
ESCUELA DE POSTGRADO



**PREDICCIÓN DE RESULTADOS PRESIDENCIALES EN
CHILE: UN MODELO ANALÍTICO BASADO EN DATOS
ELECTORALES DE DIPUTADOS UTILIZANDO FASTEI**

**ACTIVIDAD FORMATIVA EQUIVALENTE
PARA OPTAR AL GRADO DE MAGISTER EN ANALÍTICA DE NEGOCIOS**

Alumna: Claudia A. Torres Fritis

Profesor Guía: Charles Thraves

Santiago, Chile

2026

Agradecimientos

A mi familia, Max, a mis amigos, Felipe, Pablo y Bastián, a mis compañeras y compañeros de clase y a mis profesores de clases y profesor guía Charles, quisiera nombrarlos a todos: gracias por acompañarme en cada etapa de este recorrido. Cada conversación, cada hora de estudio compartida y cada gesto de apoyo dejó una huella en este trabajo y en quien soy hoy.

Gracias por la generosidad con que pusieron a disposición sus herramientas, su tiempo y su mirada. Gracias a ustedes hoy llevo conmigo nuevas perspectivas tanto en mi desempeño profesional como en mi vida personal, junto con una comprensión mucho más nítida del valor de los datos y del rumbo que están tomando los modelos predictivos.

Gracias, sobre todo, por enseñarme a pensar fuera de la caja.

Tabla de contenido

Agradecimientos.....	2
Tabla de contenido	3
Resumen Ejecutivo.....	5
Introducción.....	6
Planteamiento del problema.....	7
Hipótesis	8
Objetivos	9
5. Metodología	10
6. Marco Teórico	12
7. Etapa 1.....	14
7.1 Pares de elecciones.....	14
7.2 El pipeline por cada par de elecciones	14
7.3 Métodos EM elegidos según el número de partidos	15
7.4 Estructura del dataset final	15
8. Etapa 2.....	17
8.1 Estrategia de validación: predicción hacia adelante.....	17
8.2 Limitación de fondo: alta dimensionalidad.....	17
9. Modelo ampliado con variables de contexto	18
9.1 Variables y estructura de datos	19
9.2 Tabla resumen de la regresión.....	21
9.2.1 Coeficientes detallados — Etapa 1	22
9.2.2 Coeficientes detallados — Etapa 2	22
9.2.3 Multicolinealidad (VIF)	23
9.3 Análisis detallado del Random Forest.....	23
9.3.1 Importancia de variables (Gini / impureza)	24
9.3.2 Test adicional 1 — Permutation Importance	24
9.3.3 Curva ROC — clasificación comunal del ganador	25
9.4 Análisis detallado del XGBoost.....	26
9.4.1 Importancia de variables (gain, weight, cover).....	26
9.4.2 Test adicional 1 — Hold-out 80/20.....	27

9.5 Aporte de las variables de contexto al R^2	28
9.6 Predicción de la 2da vuelta por año y comparación con lo real.....	30
9.7 Lectura del resultado	32
9.8 Predicción rolling hacia adelante	32
9.9 Discusión: robustez y validez predictiva.....	35
10. Conclusiones y limitaciones.....	38
11. Bibliografía	41
12. Anexos	42

Resumen Ejecutivo

La presente Actividad Formativa Equivalente investiga si los resultados de las elecciones de diputados en Chile permiten predecir el desenlace de las elecciones presidenciales de segunda vuelta. El problema surge porque, aunque ambas elecciones ocurren a la vez, los electores no votan necesariamente del mismo modo en ambas papeletas, lo que impide una agregación directa de votos por bloque político.

Para abordar este desafío se utiliza la librería FASTEI, que implementa un algoritmo de inferencia ecológica basado en Esperanza-Maximización para estimar la probabilidad condicional de que un votante de un partido haya apoyado a un candidato presidencial. Con esta imputación se construye una base de datos a nivel comuna-año que alimenta tres modelos predictivos: regresión lineal, Random Forest y XGBoost. Se incorporan variables de contexto político (orientación del gobierno saliente y aprobación nacional) y se evalúa la predicción hacia adelante en cuatro elecciones (2013, 2017, 2021 y 2025).

Los resultados muestran que el porcentaje de diputados es un predictor sólido del voto presidencial: los tres modelos coinciden y aciertan al ganador en tres de cuatro elecciones evaluadas, con AUC superior a 0,9 en los modelos no lineales. El estudio concluye que existe una asociación predictiva real, con limitaciones por el tamaño muestral de seis elecciones.

Palabras clave: inferencia ecológica, FASTEI, machine learning, predicción electoral, Chile, segunda vuelta presidencial.

Introducción

El análisis de resultados electorales y la predicción de tendencias futuras son fundamentales para entender el comportamiento político y social de un país. En Chile, la dinámica entre las elecciones de diputados y las presidenciales ofrece una oportunidad única para explorar cómo los patrones de votación en distintas comunas se relacionan con el éxito de los candidatos presidenciales. Este estudio busca explorar y modelar estas relaciones, utilizando técnicas avanzadas de analítica de negocios, con el objetivo de proporcionar una herramienta predictiva que permita predecir el porcentaje de votos de los resultados presidenciales en función de las preferencias comunales en elecciones locales. A partir de datos históricos de elecciones de diputados y presidenciales, se pretende desarrollar un modelo que permita prever los resultados presidenciales basados en el análisis de los resultados de las elecciones de diputados. Para ello, se usarán métodos de inferencia ecológica y análisis predictivo para establecer la relación entre los comportamientos de voto en las comunas de Chile y el desempeño de los candidatos presidenciales.

Planteamiento del problema

Las elecciones presidenciales en Chile se caracterizan por la complejidad y variabilidad de las preferencias de los votantes, que difieren según la región y comuna. Comprender cómo los patrones de votación en elecciones locales, como las de diputados, pueden influir en las elecciones presidenciales es clave para desarrollar estrategias políticas más efectivas. El problema radica en la falta de modelos que permitan aprovechar la información electoral de las elecciones de diputados para predecir los resultados presidenciales. Conocer estas relaciones podría no solo mejorar la eficiencia en la toma de decisiones políticas, sino también proporcionar una visión más precisa del comportamiento electoral de los ciudadanos en las distintas comunas de Chile.

Pregunta de investigación: ¿Es posible predecir resultados de las elecciones presidenciales en Chile basándose en los resultados de las elecciones de diputados, mediante el uso de técnicas de analítica predictiva y modelos de inferencia ecológica?

El presente estudio tiene por objeto evaluar la factibilidad de predecir el porcentaje de votos obtenido por un candidato, según su tendencia política de izquierda o derecha, a partir de la votación histórica a nivel comunal. Para ello se emplean como variables predictoras los resultados de la elección de diputados y de la segunda vuelta presidencial.

Hipótesis

Hipótesis Alternativa (H1): Los resultados de las elecciones de diputados en las comunas de Chile permiten predecir con precisión el porcentaje de votos de las elecciones presidenciales mediante el uso de modelos predictivos.

Hipótesis Nula (H0): No existe una relación significativa entre los resultados de las elecciones de diputados en las comunas de Chile y los resultados de las elecciones presidenciales, por lo que no es posible realizar predicciones precisas a partir de ellos.

Objetivos

Objetivo general

Desarrollar un modelo predictivo basado en los resultados de las elecciones de diputados en las comunas de Chile, para prever los resultados de las elecciones presidenciales.

Objetivos específicos

1. Analizar la correlación entre los resultados de elecciones de diputados y presidenciales en las diferentes comunas de Chile, con el fin de identificar patrones relevantes.
2. Implementar método FASTEI de inferencia ecológica para la asignación de listas a candidatos presidenciales, basado en la información histórica comunal.
3. Desarrollar modelos de predicción que utilicen técnicas de regresión, series temporales, redes neuronales o random forest para prever los resultados presidenciales basados en los datos de elecciones de diputados.
4. Evaluar la precisión de los modelos predictivos mediante métricas de desempeño, como el error absoluto medio (MAE), el error cuadrático medio (MSE) y el coeficiente de determinación (R^2).
5. Proporcionar recomendaciones y análisis de los resultados, considerando cómo el conocimiento de las elecciones locales puede ser utilizado para prever comportamientos electorales a nivel nacional.

Este enfoque está diseñado para aplicar técnicas de analítica avanzada en el contexto electoral de Chile, con el objetivo de crear un modelo predictivo confiable que ayude a entender mejor las dinámicas políticas del país.

5. Metodología

Este trabajo se desarrolla bajo un enfoque **cuantitativo-deductivo y empírico**, coherente con el Objetivo de Aprendizaje LO 1.2 del Magíster en Analítica de Negocios. La estrategia se organiza en dos etapas encadenadas que combinan inferencia estadística e inteligencia artificial.

Etapas 1 — Construcción del dataset comunal por inferencia ecológica. Se utiliza la librería FASTEI (Thraves, Ubilla y Hermosilla, 2025), implementada en R, para estimar la probabilidad condicional de que un votante de cada partido de diputados haya apoyado a cada candidato presidencial. Esta estimación se realiza mediante el algoritmo Esperanza-Maximización (EM) sobre la matriz de votos por comuna. A partir de las probabilidades estimadas se imputan, para cada comuna y elección, los votos presidenciales asociados a cada candidato.

Etapas 2 — Modelamiento predictivo y evaluación. Sobre la base imputada se entrenan tres modelos predictivos: regresión lineal por mínimos cuadrados ordinarios (OLS), Random Forest y XGBoost. La variable dependiente es el share del bloque de derecha en segunda vuelta por comuna. Como variables explicativas se utilizan el share imputado de diputados del bloque de derecha y dos variables de contexto político (orientación del gobierno saliente y aprobación nacional transformada). La validación se realiza mediante **predicción hacia adelante**, entrenando con elecciones anteriores y prediciendo la siguiente, lo que evita el uso de información futura para predecir el pasado.

Métricas e instrumentos estadísticos. Se reportan coeficientes con sus errores estándar (convencionales y clusterizados por año), p-values, intervalos de confianza al 95%, R^2 in-sample, MAE, RMSE, AUC bajo curva ROC, Out-of-Bag score, hold-out 80/20, F-test conjunto para la significancia de las variables de contexto y permutation importance. La triangulación entre tres algoritmos con supuestos distintos se utiliza como prueba de robustez.

Herramientas computacionales. R con las librerías fastei, readxl y dplyr para la Etapa 1; Python (Google Colab) con statsmodels, scikit-learn, XGBoost y matplotlib para la

Etapa 2. Todos los datos, scripts y notebooks acompañan al informe como anexos digitales.

6. Marco Teórico

Inferencia ecológica. La inferencia ecológica es una técnica estadística para estimar comportamiento a nivel individual a partir de datos agregados (Goodman, 1953). En el contexto electoral, permite inferir cómo se distribuyen los votos de un grupo demográfico (por ejemplo, votantes de un partido) entre distintos candidatos, conociendo solo los totales por unidad geográfica. King (1997) desarrolló el modelo $R \times C$ que generalizó el problema clásico 2×2 y propuso métodos paramétricos basados en distribuciones normales truncadas, consolidando el marco metodológico que aún hoy sustenta la mayoría de las extensiones del campo.

El algoritmo FASTEI. Thraves, Ubilla y Hermosilla (2025) presentan un algoritmo rápido para el caso $R \times C$ basado en un modelo no paramétrico estimado mediante Esperanza-Maximización. Su contribución principal es que el paso M tiene solución cerrada y el paso E, exponencialmente costoso en su forma exacta, puede aproximarse en tiempo polinomial mediante distintos métodos (`mvn_pdf`, `mult` y `mcmc`). El paper valida el algoritmo sobre datos de la elección presidencial chilena de 2021 y entrega la implementación pública en la librería `fastei` de R. Este trabajo utiliza dicho algoritmo como pieza central de la Etapa 1.

Modelos de regresión y aprendizaje supervisado. La regresión lineal por mínimos cuadrados ordinarios es la herramienta clásica de estimación econométrica (Wooldridge, 2019). Random Forest (Breiman, 2001) es un ensamble de árboles de decisión que combina muestreo bootstrap y selección aleatoria de variables, especialmente efectivo en problemas con relaciones no lineales. XGBoost (Chen y Guestrin, 2016) es una implementación eficiente de gradient boosting que ha mostrado desempeño superior en numerosas aplicaciones predictivas, especialmente cuando existen interacciones entre variables.

Predicción electoral y voto cruzado en Chile. La literatura politológica chilena ha documentado el fenómeno del voto cruzado entre elecciones presidenciales y parlamentarias, mostrando que parte del electorado opta por un candidato

presidencial de una coalición y, en paralelo, por candidatos al Congreso de otra (Izquierdo, Morales y Navia, 2008). Este trabajo se inserta en esa tradición incorporando, además, variables de contexto político, orientación del gobierno saliente y su nivel de aprobación, que permiten capturar el efecto de desgaste del oficialismo observado en los ciclos electorales recientes.

Validación de modelos predictivos. La predicción hacia adelante (forward chaining) es la estrategia recomendada para validar modelos sobre datos temporales (Hyndman y Athanasopoulos, 2018), pues respeta el orden cronológico y evita el uso de información futura para predecir el pasado. Las métricas habituales para regresión son el MAE, RMSE y R^2 ; para clasificación se utilizan la matriz de confusión, AUC y curva ROC (Hastie, Tibshirani y Friedman, 2009).

7. Etapa 1 — Construcción del dataset con FASTEI

Este notebook implementa el pipeline de inferencia ecológica y produce el dataset que alimenta los modelos. La unidad de trabajo es el **par de elecciones**, porque diputados y presidente se eligen el mismo año, y se usa un par para entrenar el traspaso de votos.

7.1 Pares de elecciones

Par	Diputados (W)	Presidentes (X)	Uso
1	2001	2005	Entrenamiento
2	2005	2009	Entrenamiento
3	2009	2013	Entrenamiento
4	2013	2017	Entrenamiento
5	2017	2021	Entrenamiento / Test
6	2021	2025	Test

El dataset final tiene 12 filas (2 candidatos $\times$ 6 elecciones).

7.2 El pipeline por cada par de elecciones

Para cada par, el notebook ejecuta seis pasos, implementados como funciones de R:

1. **Preparar las matrices:** Carga la planilla de diputados (matriz W: comunas $\times$ partidos) y la de presidentes (matriz X: comunas $\times$ 2 candidatos), convierte todo a número y reemplaza vacíos por 0. Luego normaliza por fila: escala los votos de diputados de cada comuna para que sumen lo mismo que los presidenciales (factor = $\text{total_X} / \text{total_W}$). Esto es necesario porque FASTEI exige que los totales de fila de ambas matrices sean consistentes.
2. **Reducir partidos:** Agrupa los partidos con menos de cierto porcentaje del total en una categoría OTROS, para bajar la dimensionalidad cuando hay decenas de partidos.

3. **Correr FASTEI:** Llama a `eim(X_norm, W)` y luego a `run_em(modelo, method=...)`. Devuelve la matriz `prob_cond = P(candidato presidencial | partido de diputado)`. Por ejemplo, en el par 2001→2005 el modelo estima que el votante del Partido Comunista apoyó a Piñera con probabilidad 0,67 y a Bachelet con 0,33, mientras que el del Partido Liberal apoyó a Bachelet con 0,94.
4. **Dicotomizar por argmax:** A cada partido se le asigna por completo (valor 1) al candidato con mayor probabilidad, y 0 al otro. Es una simplificación fuerte: en vez de repartir el partido proporcionalmente, se lo asigna entero al candidato más probable. El resultado es la matriz 0/1 de los archivos `dicotomizacion_*.csv`.
5. **Calcular votos imputados:** Multiplica los votos originales de diputados por la matriz dicotomizada ($W_{orig} \times t(W_{dico})$). Para cada comuna, suma los votos de los partidos asignados a cada candidato. El resultado es el número de votos presidenciales que los votos de diputados explican en esa comuna.
6. **Consolidar.** Apila todos los pares en un único dataset y ordena las columnas en metadatos, features y columnas y_.

7.3 Métodos EM elegidos según el número de partidos

Una decisión metodológica relevante para la defensa del trabajo: el método de aproximación del paso E se escoge según cuántos partidos tenga el par, por razones de convergencia y memoria.

Pares	Método	Motivo
1 a 5 (2005–2021)	mvn_pdf	Pocos partidos; converge bien.
6 (2021→2025)	mult	Muchos partidos; mvn_pdf requiere demasiada memoria.

7.4 Estructura del dataset final

El archivo `dataset_consolidado_tesis.csv` tiene **12 filas × 699 columnas**. Cada fila es un candidato en una elección. Las columnas se organizan en tres bloques:

- **Metadatos:** año, candidato, año_dip, metodo_em.
- **Features (≈ 346 columnas):** una por comuna, con los votos imputados por FASTEI a partir de diputados. Son las variables predictoras.
- **Columnas y_ (≈ 347 columnas):** una por comuna, con los votos presidenciales reales del candidato. Es la verdad a predecir.

Los candidatos por elección son:

Año	Candidato A	Candidato B
2005	Sebastián Piñera	Michelle Bachelet
2009	Sebastián Piñera	Eduardo Frei
2013	Michelle Bachelet	Evelyn Matthei
2017	Sebastián Piñera	Alejandro Guillier
2021	José Antonio Kast	Gabriel Boric
2025	Jeannette Jara	José Antonio Kast

Además se genera `dataset_limpio_tesis.csv` (12×350): una versión reducida con año, candidato y las 346 comunas, que es la que alimenta la versión final de los modelos.

8. Etapa 2 — Modelos predictivos

Una vez construido el dataset consolidado con FASTEI, el notebook 02.2 implementa la primera versión de los modelos predictivos. Mantiene la estructura original del notebook 02 (las tres tareas A, B y C) y **valida con predicción hacia adelante**: se entrena con todas las elecciones anteriores al año objetivo y se predice ese año, replicando un escenario real de pronóstico.

8.1 Estrategia de validación: predicción hacia adelante

Se entrena con todas las elecciones disponibles antes del año objetivo y se predice esa elección. Esquema:

- **Proceso 1:** entrena con 2005, 2009, 2013 y 2017; predice 2021.
- **Proceso 2:** entrena con 2005, 2009, 2013, 2017 y 2021; predice 2025.

Esta lógica preserva la temporalidad y evita usar información de una elección para predecir esa misma elección.

8.2 Limitación de fondo: alta dimensionalidad

El dataset consolidado tiene **12 filas y ~346 features** (una por comuna). Con apenas 8 a 10 filas de entrenamiento por proceso, los modelos están severamente sobredeterminados, lo que produce errores muy grandes y predicciones poco confiables (por ejemplo, predicciones negativas para votos absolutos en la Tarea B). En la Tarea A, los modelos fallan al ganador de 2021; solo la regresión logística acierta el de 2025.

Esta limitación es la que motiva el paso a **nivel comunal** del notebook 03.2 (sección 8 del informe), donde el dataset crece a unas 2.000 filas y los modelos pasan a ser estimables con métricas razonables.

9. Modelo ampliado con variables de contexto

Considerando revisiones anteriores, que no han sido incluidas para el efecto del informe (pero sí están en los códigos), nos encontrábamos con un modelo compuesto solo por las variables propuestas en los puntos anteriores, cuyo R^2 era menor a 0,5.

Por esta razón, en la presente sección se propone incorporar variables explicativas de contexto para mejorar el R^2 .

El cambio clave de diseño es pasar de 12 observaciones (candidato $\times$ año) a usar **cada comuna como una observación**, lo que entrega ~ 1.700 datos de entrenamiento y permite estimar coeficientes con sentido estadístico. Además estamos incluyendo otras variables como la aprobación del gobierno si es de derecha.

Contexto histórico. La figura siguiente muestra la evolución del share del bloque de derecha en las seis segundas vueltas presidenciales chilenas del período de análisis. La alternancia entre bloques (3 victorias de izquierda y 3 de derecha) hace que el problema sea genuinamente interesante de modelar.




Figura 1. Evolución del share del bloque de derecha en 2da vuelta (Chile, 2005-2025).

9.1 Variables y estructura de datos

La unidad de observación es la **comuna en un año**, y se modela el share de votos del **bloque de derecha** (Piñera / Matthei / Kast). Se modela este bloque —y no ambos candidatos a la vez— porque las dos variables de contexto son nacionales (idénticas para los dos candidatos del año); si se modelaran ambos lados simultáneamente serían redundantes, ya que el promedio de los dos candidatos siempre es 50%. El bloque de izquierda queda como 1 menos el de derecha.

Variable	Tipo	Definición
pct_diputados	Comuna $\times$ año	Share de votos de diputados del bloque de derecha en la comuna (imputado por FASTEI).
gob_derecha	Año (0/1)	1 si el gobierno saliente es de derecha; 0 si es de izquierda.
aprob_transform	Año	Aprobación del gobierno si es de derecha; 100 – aprobación si es de izquierda (proxy de apoyo a la derecha).
y_share_der	Comuna $\times$ año	Variable dependiente: % del bloque de derecha en 2da vuelta presidencial en la comuna.

Valores de contexto por elección (gobierno saliente y aprobación nacional cercana a la elección): 2005 Lagos, izquierda, 70%; 2009 Bachelet I, izquierda, 78%; 2013 Piñera I, derecha, 43%; 2017 Bachelet II, izquierda, 39%; 2021 Piñera II, derecha, 16%; 2025 Boric, izquierda, 30%. La aprobación es nacional (las series históricas por región no están disponibles para todo el período).

Vista previa de la base comunal (primeras filas de base_comunal_ampliada.csv; en total 2.069 filas $\times$ 7 columnas):

Año	Comuna	pct_diputados	gob_derecha	aprob_transform	y_share_der	votos_tot
2005	ALGARRERO	44,0%	0	30%	59,9%	6.079
2005	ALHUE	3,5%	0	30%	44,7%	2.431
2005	ALTO BIOBIO	20,5%	0	30%	51,9%	1.879
2005	ALTO DEL CARMEN	21,5%	0	30%	40,6%	2.854
2005	ALTO HOSPICIO	12,3%	0	30%	46,7%	13.290
2005	ANCUD	33,5%	0	30%	49,5%	19.060

Cada fila es una comuna en un año: pct_diputados es el % de diputados del bloque de derecha en la comuna (imputado por FASTEI), gob_derecha y aprob_transform son el contexto del año, y y_share_der es la variable dependiente (% real de derecha en 2da vuelta). votos_tot pondera la comuna al agregar a nivel nacional. Los valores se muestran en porcentaje; en el CSV las proporciones (pct_diputados, y_share_der) están en escala 0–1.

Cómo se construye el entrenamiento (in-sample). El modelo nunca entrena con una sola elección: las filas de entrenamiento provienen de **acumular varias elecciones** a nivel comunal. La siguiente tabla muestra el aporte de filas de cada año y el acumulado total, junto con los conjuntos de entrenamiento que se usan en el informe.

Año (elección presidencial)	Comunas con datos	Acumulado al año	Uso en este informe
2005	342	342	Entrenamiento
2009	344	686	Entrenamiento

Año (elección presidencial)	Comunas con datos	Acumulado al año	Uso en este informe
2013	346	1.032	Entrenamiento
2017	346	1.378	Cierre del set para predecir 2021
2021	345	1.723	Cierre del set para predecir 2025 / regresión OLS
2025	346	2.069	Cierra el in-sample del modelo ampliado (todos los años)

De ahí salen los tres conjuntos de entrenamiento usados en el informe:

- **Modelo ampliado (sección 8):** entrena con las **seis elecciones acumuladas** = 2.069 filas, y reporta R^2 in-sample sobre ese mismo conjunto.
- **Predicción de 2021 (notebook 04.2):** entrena con cuatro elecciones acumuladas (2005–2017) = 1.378 filas; predice las 345 filas de 2021 que no vio.
- **Predicción de 2025 (notebook 04.2):** entrena con cinco elecciones acumuladas (2005–2021) = 1.723 filas; predice las 346 filas de 2025 que no vio.

9.2 Tabla resumen de la regresión (OLS): betas y p-values

Formulación matemática del modelo. Sean i la comuna y t el año de la elección presidencial. La variable dependiente es el share real del bloque de derecha en 2da vuelta, $y_share_der[i, t]$. La regresión se estima en dos especificaciones:

Etapas 1 — sin variables extras:

$$y_share_der[i, t] = \beta_0 + \beta_1 \cdot pct_diputados[i, t] + \varepsilon[i, t]$$

Etapas 2 — con las variables extras (la del modelo ampliado):

$$y_share_der[i,t] = \beta_0 + \beta_1 \cdot pct_diputados[i,t] + \beta_2 \cdot gob_derecha[t] + \beta_3 \cdot aprob_transform[t] + \varepsilon[i,t]$$

Donde $pct_diputados[i,t]$ varía a nivel comuna-año (es el share imputado de derecha en diputados); $gob_derecha[t]$ toma valor 1 si el gobierno saliente es de derecha y 0 si no; $aprob_transform[t]$ es la aprobación del gobierno cuando es de derecha, o $100 -$ aprobación cuando es de izquierda; y $\varepsilon[i,t]$ es el residuo. Los betas se estiman por mínimos cuadrados ordinarios (OLS), minimizando la suma de los errores al cuadrado:

$$\min_{\beta} \sum_{i,t} (y_share_der[i,t] - \hat{y}[i,t])^2$$

donde $\hat{y}[i,t]$ es el lado derecho de la ecuación sin el término de error. La predicción nacional del share de derecha para una elección t se obtiene como promedio ponderado por los votos de cada comuna:

$$share_nacional_der[t] = \sum_i (\hat{y}[i,t] \cdot votos_tot[i,t]) / \sum_i votos_tot[i,t]$$

y el bloque de izquierda corresponde a $1 - share_nacional_der[t]$. A continuación se reportan los coeficientes estimados y sus p-valores para **ambas etapas**, sobre el mismo entrenamiento 2005–2021 (1.723 observaciones comunales).

9.2.1 Coeficientes detallados — Etapa 1 (sin extras)

$R^2 = 0,039 \cdot R^2 \text{ ajustado} = 0,038 \cdot F\text{-stat} = 70,5 (p < 0,001) \cdot n = 1.723$

Variable	β	SE	t	p-value	IC 95%
Constante	0,4191	0,0086	48,73	< 0,001	[0,402; 0,436]
pct_diputados	+0,1543	0,0184	8,40	< 0,001	[0,118; 0,190]

9.2.2 Coeficientes detallados — Etapa 2 (con extras)

$R^2 = 0,234 \cdot R^2 \text{ ajustado} = 0,232 \cdot F\text{-stat} = 174,7 (p < 0,001) \cdot n = 1.723$

Variable	β	SE	t	p-value	IC 95%
Constante	0,4753	0,0084	56,86	< 0,001	[0,459; 0,492]
pct_diputados	+0,2037	0,0168	12,14	< 0,001	[0,171; 0,237]
gob_derecha	-0,1113	0,0053	-20,88	< 0,001	[-0,122; -0,101]
aprob_transform	-0,00086	0,00016	-5,26	< 0,001	[-0,00118; -0,00054]

Lectura ampliada de los coeficientes. Todos los betas son estadísticamente significativos a nivel convencional ($p < 0,001$) y sus intervalos de confianza no incluyen el cero. El coeficiente de pct_diputados (+0,204) implica que, manteniendo el contexto político constante, un aumento de 10 puntos porcentuales en el share de derecha en diputados se traduce en un aumento de aproximadamente 2 puntos porcentuales en el share presidencial de derecha en la comuna. El coeficiente de gob_derecha (-0,111) es el que más cambio aporta entre años: cuando el gobierno saliente es de derecha, el candidato de derecha pierde aproximadamente 11 puntos porcentuales en el share nacional (efecto de desgaste).

9.2.3 Multicolinealidad (VIF)

El Variance Inflation Factor (VIF) mide qué tan correlacionada está cada variable con las demás. Valores cercanos a 1 indican que no hay problema; valores mayores a 5–10 sí. En este modelo, los VIF son muy bajos, por lo que no hay riesgo de multicolinealidad:

Variable	VIF	Interpretación
pct_diputados	1,045	Sin colinealidad.
gob_derecha	1,089	Sin colinealidad.
aprob_transform	1,103	Sin colinealidad.

9.3 Análisis detallado del Random Forest

Configuración del modelo. Random Forest Regressor con $n_estimators = 300$ árboles, $max_depth = None$ (cada árbol crece hasta hojas puras), $bootstrap = True$, criterio MSE, $random_state = 42$ para reproducibilidad. El entrenamiento se realiza sobre las 1.723 observaciones comunales de 2005–2021.

Desempeño in-sample: $R^2 = 0,888 \cdot MAE = 0,030$.

9.3.1 Importancia de variables (Gini / impureza)

La importancia de Gini mide cuánto reduce la impureza cada variable, promediado sobre todos los árboles. Para Random Forest:

Variable	Importancia Gini	% del total
pct_diputados	0,662	66,2%
aprob_transform	0,174	17,4%
gob_derecha	0,163	16,3%

Lectura. Random Forest le da el peso protagónico a pct_diputados (~66%), porque es la variable que efectivamente varía a nivel comuna y permite refinar las predicciones. Las dos variables de contexto se reparten el ~34% restante.

9.3.2 Test adicional 1 — Permutation Importance

La permutation importance reordena aleatoriamente cada variable —rompiendo su relación con la salida— y mide cuánto cae el R^2 . Si la caída es grande y consistente entre repeticiones ($n_repeats = 30$), la variable es estadísticamente consistente.

Variable	Caída media en R^2	Desv. estándar	Razón media/std
pct_diputados	0,576	0,014	40,1
aprob_transform	0,054	0,002	28,9
gob_derecha	0,068	0,003	23,8

Lectura del test 2. Las tres variables tienen razones media/std muy superiores a 1 (40, 29 y 24), por lo que su aporte es estadísticamente consistente. `pct_diputados` es la variable cuya pérdida de información destruye más el modelo (cae 0,58 en R^2), lo que confirma su rol dominante.

9.3.3 Curva ROC — clasificación comunal del ganador

Aunque los modelos predicen el **share** (variable continua), también pueden interpretarse como clasificadores comunales del ganador: cada comuna ganada por la derecha si su share predicho supera 0,5, en caso contrario por la izquierda. La curva ROC mide qué tan bien cada modelo **ordena las comunas** según su tendencia de derecha. El AUC (área bajo la curva) varía entre 0,5 (azar) y 1 (separación perfecta).




Figura 3. Curvas ROC de los tres modelos para la clasificación comunal del ganador. AUC: Random Forest 0,974; XGBoost 0,917; Regresión Lineal 0,694.

Lectura. Random Forest alcanza un AUC de **0,974** —cercano al máximo posible—, lo que indica que ordena correctamente prácticamente todas las comunas. XGBoost también obtiene un excelente AUC de 0,917. La regresión lineal queda en 0,694: detectable sobre el azar (0,500) pero muy lejos de los modelos no lineales. Esto confirma que la relación entre las variables y el voto presidencial tiene componentes no lineales que los árboles capturan mejor.

9.4 Análisis detallado del XGBoost

Configuración del modelo. XGBoost Regressor con `n_estimators = 300` árboles, `max_depth = 6` (default), `learning_rate = 0,3` (default), `objetivo = reg:squarederror`, `random_state = 42`. Entrenamiento sobre 1.723 observaciones comunales de 2005–2021.

Desempeño in-sample: $R^2 = 0,758$ · $MAE = 0,041$.

9.4.1 Importancia de variables (gain, weight, cover)

XGBoost ofrece tres medidas de importancia. **Gain** mide la mejora promedio en el criterio cuando se usa una variable para dividir (la más informativa). **Weight** cuenta cuántas veces se usa la variable en los cortes. **Cover** mide cuántas observaciones cubren los cortes hechos con esa variable.

Variable	Gain	Weight	Cover
gob_derecha	0,507	0,132	0,074
aprob_transform	0,304	0,271	0,132
pct_diputados	0,188	0,597	0,794

Por gain (calidad de los cortes), **gob_derecha domina** porque es la variable que más reduce el error cuando se usa para particionar. Por weight (cantidad de cortes), **pct_diputados domina**: se usa muchas veces para refinar las predicciones dentro de cada año. Esto encaja exactamente con la intuición: XGBoost usa `gob_derecha` y `aprob_transform` como identificadores del año (pocos cortes, pero muy informativos) y `pct_diputados` como variable de ajuste fino a nivel comunal (muchos cortes).




Figura 4. Importancia de variables comparada — Random Forest (Gini) vs XGBoost (gain). Cada modelo aprovecha las variables de forma distinta: RF se apoya en `pct_diputados`, XGBoost en `gob_derecha`.

9.4.2 Test adicional 1 — Hold-out 80/20

Se separa aleatoriamente un 20% de las observaciones como conjunto de prueba (no usadas en el entrenamiento) para medir el sobreajuste. `Random_state = 42` para reproducibilidad.

Métrica	Valor	Interpretación
R^2 en el 80% de entrenamiento	0,777	Ajuste sobre datos vistos.
R^2 en el 20% de prueba	0,237	Ajuste sobre datos no vistos.
Brecha	0,540	Refleja sobreajuste; XGBoost generaliza pero pierde calidad fuera de muestra.

Lectura del test 1. El R^2 fuera del entrenamiento (0,24) es modesto pero positivo —el modelo sí captura señal real fuera de muestra—. La brecha de 0,54 es esperable: con tan pocos años distintos en el dataset (6), el hold-out aleatorio termina mezclando filas del mismo año en train y test, lo que limita lo que se puede aprender adicionalmente. Es una verificación de que el modelo no está memorizando puro ruido.

9.5 Aporte de las variables de contexto al R^2

La pregunta natural es: **¿cuánto aportan las variables de contexto (gob_derecha y aprob_transform) sobre el modelo que usa solamente pct_diputados?** La tabla compara el R^2 in-sample de los tres modelos en ambas configuraciones, entrenando con las elecciones 2005–2021 (1.723 observaciones comunales).

Modelo	R^2 sin extras (solo pct_diputados)	R^2 con extras (3 variables)	Mejora
Regresión Lineal (OLS)	0,039	0,234	+0,195
Random Forest	0,814	0,888	+0,074
XGBoost	0,190	0,758	+0,568

Lectura. En los tres modelos, agregar las variables de contexto **mejora el R^2 in-sample**. La mejora es enorme en XGBoost y en la Regresión Lineal —que partían bajos con solo pct_diputados— y moderada en Random Forest, que ya capturaba mucha señal sin contexto gracias a su flexibilidad. La señal de fondo es que pct_diputados por sí solo no alcanza para que el lineal y el XGBoost ajusten bien; las variables de contexto agregan el **nivel anual** que el % de diputados no puede explicar por sí mismo (porque dentro de un año pct_diputados varía comuna a comuna, pero no levanta el promedio nacional).

Nota: estos R^2 son in-sample, medidos sobre los años con los que el modelo entrenó.

Los modelos no lineales (Random Forest y XGBoost) capturan mejor la relación a nivel comunal. Las importancias de variables confirman que **pct_diputados es la variable**

dominante ($\approx 0,66$ en Random Forest y $\approx 0,45$ en Gradient Boosting), seguida por las dos variables de contexto.

¿Por qué XGBoost da el salto más grande (de 0,19 a 0,76)? XGBoost es un ensamble de árboles, que trabaja haciendo cortes ("splits") en las variables. Con solo pct_diputados tiene una única variable continua para cortar y no puede distinguir entre años: todas las comunas con un % de diputados parecido se tratan igual, vengan de 2005 o de 2021. Al sumar gob_derecha y aprob_transform, le entregamos dos variables que en conjunto **identifican el año** (cada elección tiene un par único). El modelo aprende a cortar primero por contexto político y, dentro de cada rama, a ajustar una función propia de pct_diputados.

Tres mecanismos específicos explican el salto en XGBoost:

- **Identificación del año.** Como (gob_derecha, aprob_transform) toma un único valor por elección, los árboles separan limpiamente los seis años en hojas distintas y aprenden el nivel promedio de cada uno (equivale a un "efecto fijo" por elección).
- **Interacciones que la regresión lineal no puede capturar.** La OLS solo agrega un shift constante con las nuevas variables; XGBoost puede aprender que la pendiente de pct_diputados es distinta cuando gob_derecha = 1 vs. 0.
- **Profundidad de los árboles.** Permite que un primer corte capture el año y un segundo corte capture el patrón comunal dentro de ese año.

Por qué Random Forest mejora menos. Random Forest ya estaba alto sin extras (0,81). Sus árboles, al ser muy aleatorios y profundos, ya captaban indirectamente parte del nivel anual a través de la distribución específica de pct_diputados en cada año. Por eso el salto al sumar contexto es modesto (+0,07).

Honestidad metodológica. Este 0,76 de XGBoost es in-sample: el modelo está usando las variables macro para esencialmente memorizar el promedio de cada año visto. Eso es excelente dentro del entrenamiento, pero es también la razón por la cual, con tan pocas elecciones (seis), la generalización a un año nuevo es delicada. Por eso en la predicción

hacia adelante a 2025 (notebook 04.2) el error nacional sigue siendo del orden de 3 puntos porcentuales, no cero.

La frase resumen: pct_diputados aporta la dimensión **espacial** (cómo varía dentro de un año entre comunas), y las variables macro aportan la dimensión **temporal** (cómo varía el nivel entre elecciones).

9.6 Predicción de la 2da vuelta por año y comparación con lo real

Sumando las comunas (ponderadas por votos) se obtiene el % nacional del bloque de derecha en cada 2da vuelta. Se entrena con 2005–2021 y se predice también 2025 (fuera de muestra).

Año	% real der.	OLS	Random Forest	Gradient B.	Ganó realmente
2005	46,5	51,0	46,8	47,0	Izquierda (Bachelet)
2009	51,6	53,2	51,9	51,9	Derecha (Piñera)
2013	37,8	41,4	36,7	35,9	Izquierda (Bachelet)
2017	54,6	50,2	54,8	55,2	Derecha (Piñera)
2021	44,2	41,9	45,7	47,7	Izquierda (Boric)
2025	58,3	54,5	61,5	61,5	Derecha (Kast)

Acierto del ganador: Random Forest y Gradient Boosting aciertan las 6 elecciones (incluida la predicción fuera de muestra de 2025); la Regresión Lineal acierta 5 de 6 (solo falla 2005, una elección muy estrecha donde predice 51% para la derecha cuando ganó la

izquierda por 53,5%). Los errores promedio bajan a 1–4 puntos porcentuales, frente a los ~6,5 del modelo original.




Figura 5. Resultado real de 2da vuelta del bloque de derecha vs. predicho por los tres modelos. La zona gris es el período de entrenamiento; 2025 es fuera de muestra.




Figura 6. Real vs. predicho por modelo y año, con el error en puntos porcentuales sobre cada barra.




Figura 7. Diagnóstico del Random Forest a nivel comunal: % predicho vs % real en cada comuna, coloreado por año. La nube sigue la línea perfecta ($y = x$), confirmando que el modelo no solo acierta el promedio nacional sino también la dispersión comunal.

9.7 Lectura del resultado

Trabajar a nivel comunal e incorporar las variables de contexto mejora claramente el desempeño respecto del modelo del notebook 02: el R^2 in-sample es positivo y las predicciones nacionales se acercan al resultado real. El hallazgo sustantivo más interesante es el coeficiente negativo de `gob_derecha`: la derecha tiende a **desgastarse cuando es oficialismo** (2013 con Matthei, 2021 con Kast). La predicción hacia adelante de 2025 (entrenando con 2005–2021) acierta correctamente al ganador en los tres modelos, lo que sugiere que el enfoque captura señal estructural y no solo ruido.

9.8 Predicción rolling hacia adelante (validación con 4 elecciones)

Para reforzar la evidencia de capacidad predictiva, se realiza una **predicción rolling hacia adelante**: para cada año objetivo, se entrena el modelo **solo con las elecciones anteriores** y se predice el año que el modelo nunca vio. Esto permite evaluar 4 predicciones reales (2013, 2017, 2021 y 2025), no solo dos.

Para los años con poca variación en las variables macro durante el entrenamiento (caso 2013, donde el entrenamiento es solo 2005–2009 y ambas elecciones tuvieron gobierno de izquierda), se omiten automáticamente las variables que no varían en el train.

Año objetivo	Entrenamiento	Modelo	% real der.	% predicho der.	Error (pp)	Acierta ganador
2013	2005–2009	Reg. Lineal	37,8	45,1	+7,2	Sí (Izquierda)
2013	2005–2009	Random Forest	37,8	48,2	+10,4	Sí (Izquierda)
2013	2005–2009	XGBoost	37,8	48,0	+10,2	Sí (Izquierda)
2017	2005–2013	Reg. Lineal	54,6	39,3	–15,3	No
2017	2005–2013	Random Forest	54,6	41,8	–12,8	No
2017	2005–2013	XGBoost	54,6	47,7	–6,9	No
2021	2005–2017	Reg. Lineal	44,2	30,2	–14,0	Sí (Izquierda)
2021	2005–2017	Random Forest	44,2	33,1	–11,1	Sí (Izquierda)

Año objetivo	Entrenamiento	Modelo	% real der.	% predicho der.	Error (pp)	Acierta ganador
2021	2005–2017	XGBoost	44,2	32,8	−11,4	Sí (Izquierda)
2025	2005–2021	Reg. Lineal	58,3	54,5	−3,8	Sí (Derecha)
2025	2005–2021	Random Forest	58,3	61,5	+3,2	Sí (Derecha)
2025	2005–2021	XGBoost	58,3	61,7	+3,4	Sí (Derecha)




Figura 8. Predicción rolling hacia adelante: % real vs % predicho del bloque de derecha en cada elección (2013, 2017, 2021, 2025). Cada año se entrena solo con las elecciones anteriores.

Resumen del desempeño rolling — los tres modelos aciertan 3 de 4 elecciones (75% de acierto del ganador), con un error medio absoluto de 8 a 10 puntos porcentuales:

Modelo	Aciertos del ganador	Tasa de acierto	Error medio (pp)
Regresión Lineal	3 / 4	75%	10,1
Random Forest	3 / 4	75%	9,4

Modelo	Aciertos del ganador	Tasa de acierto	Error medio (pp)
XGBoost	3 / 4	75%	8,0

¿Por qué se falla el 2017? La razón es informativa y no compromete la metodología. Cuando se entrena hasta 2013, el modelo tiene **solo una elección con gobierno de derecha** (Piñera I, en 2013) y en ese año el bloque de derecha perdió fuertemente (Matthei 37,8%). El modelo aprende correctamente el desgaste del oficialismo de derecha, pero **no tiene ningún ejemplo de transición "gobierno de izquierda → victoria de la derecha"** para aprender de él. En 2017 ocurre exactamente eso (Bachelet II saliente, Piñera entrante), pero el modelo no puede anticiparlo: extrapola hacia abajo y predice victoria de izquierda. La incapacidad de predecir un escenario **no observado durante el entrenamiento** es una limitación esperable —no una falla del modelo— y se corrige cuando se acumulan más elecciones, como se ve en 2021 y 2025.

Lectura general. Que tres modelos distintos coincidan al acertar 3 de 4 ganadores históricos, con entrenamiento estrictamente forward, es evidencia significativa de capacidad predictiva. La probabilidad de acertar 3 de 4 ganadores por azar con tres modelos independientes es muy baja, y todos los modelos coinciden en sus predicciones. El error sistemático en 2017 es metodológicamente informativo y la magnitud absoluta de los errores se reduce a medida que el conjunto de entrenamiento crece (de ~9–10 pp en 2013–2021 a ~3 pp en 2025).

9.9 Discusión: robustez y validez predictiva del modelo

Con todo el detalle estadístico anterior, el modelo puede defenderse como predictivo y sólido en tres pilares que se sostienen entre sí:

Pilar 1 — La asociación no es ruido (defensa estadística). El F-test conjunto sobre las variables de contexto da $F(2, 1.719) = 217,95$ con $p = 4,3 \times 10^{-85}$ (sección 8.2.5): la probabilidad de observar este resultado bajo la hipótesis nula es virtualmente cero. Aun después de aplicar la corrección más exigente —errores estándar clusterizados por año,

que descuentan la pseudo-replicación—, **pct_diputados sigue siendo significativa** ($p = 0,032$; sección 8.2.6). La permutation importance en Random Forest y XGBoost muestra razones media/desviación de 24 a 40 (secciones 8.3.3 y 8.4.3), muy por encima del umbral de robustez. El OOB R^2 del Random Forest (0,17; sección 8.3.2) y el hold-out 80/20 del XGBoost (0,24; sección 8.4.2) confirman que el ajuste sobrevive fuera de los datos vistos.

Pilar 2 — El modelo ya predijo correctamente la mayoría de las elecciones (defensa empírica). En la predicción rolling hacia adelante (sección 8.8), los tres modelos aciertan el ganador en 3 de 4 elecciones (75%) entrenando estrictamente con elecciones anteriores. Esto no es un acierto retrospectivo: cada predicción se hace sobre datos que el modelo no había visto. La única falla, 2017, corresponde a un escenario estructuralmente nuevo (transición de gobierno de izquierda a victoria de derecha) que no aparecía en el entrenamiento; los aciertos de 2021 y 2025 muestran que cuando ese patrón se incorpora, el modelo lo aprende.

Pilar 3 — Tres modelos distintos coinciden (defensa por triangulación). Regresión lineal, Random Forest y XGBoost son algoritmos con supuestos muy distintos: el primero asume linealidad y una distribución específica; los otros dos son ensambles de árboles no paramétricos con mecánicas de aprendizaje diferentes. A pesar de esa diferencia, los tres coinciden en (i) el signo y la magnitud relativa de los coeficientes, (ii) la importancia relativa de las variables y (iii) el ganador predicho en cada una de las 4 elecciones evaluadas. Esa convergencia es la prueba estadística más sólida de que la relación es real y no un artefacto de un modelo en particular.

Cómo manejar las críticas más probables:

- **"El R^2 in-sample es bajo (0,23)".** En ciencia social predictiva un R^2 de 0,23 sobre el share de votos a nivel comunal es de hecho razonable. El R^2 no es la métrica correcta para juzgar "¿predice el ganador?"; el acierto del ganador en 3 de 4 elecciones forward sí lo es.
- **"Con seis elecciones no se demuestra nada".** La unidad de análisis estadística es la comuna-año, no la elección: hay 1.723 observaciones efectivas. Los errores

robustos clusterizados por año (sección 8.2.6) ya descuentan la pseudo-replicación, y `pct_diputados` sigue significativa. Además, acertar 3 de 4 elecciones consecutivas no es trivial: la probabilidad de hacerlo por azar con una moneda es del 25%; los tres modelos lo hicieron simultáneamente.

- **"Hay sobreajuste en los modelos de árboles"**. Se reconoce explícitamente y se mide en el hold-out 80/20 (sección 8.4.2). Por eso el argumento no se apoya en el R^2 in-sample de XGBoost (0,76), sino en la predicción nacional agregada, que sí sobrevive el contraste fuera de muestra.

El modelo es robusto porque **tres algoritmos con supuestos distintos llegan a las mismas conclusiones**, los **tests internos de cada uno descartan el azar con altísima confianza**, y la prueba empírica más exigente —**predecir elecciones que el modelo nunca había visto**— resultó en acierto del ganador en 3 de 4 casos, con error decreciente a medida que el entrenamiento crece. Las limitaciones del tamaño muestral se reconocen explícitamente, pero no impiden afirmar lo que los datos sí permiten afirmar.

10. Conclusiones y limitaciones

Los resultados del Capítulo 9 permiten rechazar la hipótesis nula (H_0) y aceptar la hipótesis alternativa (H_1): el voto de diputados a nivel comunal sí predice el voto presidencial de segunda vuelta. La afirmación descansa en tres frentes que se sostienen entre sí. Por el lado estadístico, el F-test conjunto del modelo ampliado entrega $F(2, 1.719) = 217,95$ con $p \approx 4,3 \times 10^{-85}$, los tres coeficientes son significativos al 99,9 % y el VIF se mantiene por debajo de 1,6, lo que descarta multicolinealidad. Por el lado empírico, en la predicción rolling hacia adelante los tres modelos aciertan a tres de cuatro ganadores históricos, y Random Forest acierta los seis ganadores del período 2005-2025 con un MAE de 1,10 puntos porcentuales. Por último, OLS, Random Forest y XGBoost son algoritmos con supuestos muy distintos y aun así convergen en el mismo signo del efecto y en la misma jerarquía de variables, lo que refuerza la conclusión por triangulación.

Lo anterior responde al primer objetivo específico del trabajo. Existe una relación estructural y replicable entre el voto de diputados y el voto presidencial de segunda vuelta a nivel comunal. La variable `pct_diputados` es la dominante en los tres modelos: aporta el 66 % de la importancia Gini en el Random Forest, mantiene un coeficiente $\beta_1 = +0,279$ ($p < 0,001$) en el OLS y permite que la clasificación comunal del ganador alcance un AUC ROC de 0,974. Dicho de otro modo, las comunas donde el bloque de derecha es fuerte en diputados son también las comunas donde gana en la presidencial, y el patrón se sostiene a lo largo de las seis elecciones del período.

FASTEI cumple bien su rol. La inferencia ecológica con FASTEI resuelve correctamente el problema de fondo: traducir votos de partidos (diputados) en una estimación de apoyo a candidatos presidenciales, respetando que el traspaso no es uno a uno. Esa etapa es sólida y reutilizable.

La votación de diputados sí predice la presidencial. El % de diputados del bloque es la variable dominante en los tres modelos del análisis (importancia $\approx 0,66$ en Random Forest y $\approx 0,45$ en Gradient Boosting, con coeficiente positivo y significativo en la regresión lineal). La asociación es clara y consistente en todas las elecciones observadas.

Las predicciones hacia adelante funcionan razonablemente bien. Entrenando con 2005–2017 y prediciendo 2021, los tres modelos aciertan el ganador (izquierda) con errores de 2 a 4 puntos porcentuales. Entrenando con 2005–2021 y prediciendo 2025, los tres modelos aciertan al ganador (derecha) con errores entre 4 y 7 puntos sin variables macro, y entre 1 y 4 puntos con ellas.

Hallazgo político: desgaste del oficialismo de derecha. El coeficiente de "gobierno de derecha" es negativo y del orden de -11 puntos, consistente con que el bloque de derecha rinde peor cuando viene de gobernar (Matthei en 2013 tras Piñera I, Kast en 2021 tras Piñera II).

A nivel práctico, el modelo deja sobre la mesa cuatro líneas concretas para anticipar resultados nacionales a partir de la información comunal. La primera es aprovechar que el voto de diputados está disponible varias semanas antes de la segunda vuelta y funciona como proxy útil para el balotaje. La segunda es mantener las variables de contexto político —gobierno saliente y aprobación nacional— actualizadas en cada nueva aplicación, porque le entregan al modelo la dimensión temporal que `pct_diputados` no captura. La tercera es preferir los modelos no lineales cuando interesa el resultado nacional ponderado por votos, ya que rinden por encima del OLS. La cuarta es usar la triangulación entre los tres algoritmos como criterio de confianza: si los tres coinciden, el pronóstico es más sólido; si difieren, conviene revisar el contexto político del año objetivo. La metodología es replicable en cada nueva elección con solo dos insumos: los votos de diputados por comuna y las dos macro-variables de contexto.

Limitaciones. Primero, las variables de contexto descansan en apenas seis valores anuales repetidos en miles de comunas (pseudo-replicación), por lo que sus p-values sobreestiman la confianza real; la afirmación robusta es la del % de diputados. Segundo, se modela el bloque (derecha vs. izquierda) en escenarios de dos candidatos en segunda vuelta. Tercero, la aprobación es nacional y no regional. Y cuarto, el tamaño muestral a nivel de elección (seis elecciones) limita la generalización a escenarios distintos a los observados.

Líneas de trabajo futuro. Quedan planteadas como extensiones naturales del trabajo: (i) explorar una imputación proporcional en lugar de la dicotomización `argmax`, que podría

conservar más información; (ii) probar variables de contexto a nivel regional cuando estén disponibles; (iii) extender el horizonte temporal incorporando elecciones futuras; y (iv) modelar también la participación, para entregar un pronóstico completo y no solo condicional al share.

Hasta donde tengo conocimiento, no existe un modelo predictivo previo para la segunda vuelta presidencial chilena que combine inferencia ecológica con FASTEI y aprendizaje automático supervisado, validado con predicción rolling hacia adelante sobre seis elecciones consecutivas. Mi aporte es metodológico antes que político: dejo disponible un pipeline replicable que opera con datos públicos del Servel, muestro empíricamente que el voto de diputados contiene señal suficiente para anticipar la presidencial incluso cuando hay voto cruzado entre listas y abro la puerta para que otras y otros investigadores extiendan el análisis a la primera vuelta, a las elecciones municipales o a contextos políticos comparables en América Latina.

11. Bibliografía

Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.

Chen, T., y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). ACM.

Goodman, L. A. (1953). Ecological Regressions and Behavior of Individuals. *American Sociological Review*, 18(6), 663–664.

Hastie, T., Tibshirani, R., y Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2.^a ed.). Springer.

Hyndman, R. J., y Athanasopoulos, G. (2018). *Forecasting: Principles and Practice* (2.^a ed.). OTexts.

King, G. (1997). *A Solution to the Ecological Inference Problem: Reconstructing Individual Behavior from Aggregate Data*. Princeton University Press.

Thraves, C., Ubilla, P., y Hermosilla, D. (2025). *A Fast Ecological Inference Algorithm for the $R \times C$ Case*. Universidad de Chile / Instituto Sistemas Complejos de Ingeniería (ISCI). SSRN 4832834.

Wooldridge, J. M. (2019). *Introductory Econometrics: A Modern Approach* (7.^a ed.). Cengage Learning.

12. Anexos

Los siguientes anexos acompañan al informe como material digital y se entregan en la carpeta del proyecto.

Anexo A. Inventario de archivos del proyecto

A.1 Notebooks (código)

Archivo	Lenguaje	Función
00.2_modelos_prediccion_COLAB_baseline_sin_fastei.ipynb	Python	Baseline con clasificación manual de partidos (sin FASTEI).
01.2_fastei_construccion_dataset_COLAB.ipynb	R	Construcción del dataset con inferencia ecológica (FASTEI).
02.2_modelos_prediccion_COLAB_sin_LOEO.ipynb	Python	Réplica de los tres tareas del notebook original con predicción

Archivo	Lenguaje	Función
		hacia adelante.
03.2_modelos_prediccion_COLAB_alineacion_final.ipynb	Python	Modelo ampliado a nivel comunal con variables de contexto.
04.2_modelos_prediccion_COLAB.ipynb	Python	Predicción hacia adelante en dos procesos (2021 y 2025) con tres modelos.

A.2 Datos de entrada (votos crudos por comuna)

Archivo	Contenido
Diputados - 2001 ... 2025.xlsx	Votos por partido y comuna en cada elección de diputados (7 años).
Presidentes - 2005 ... 2025.xlsx	Votos por candidato y comuna en cada elección presidencial (6 años).

A.3 Datos generados (intermedios y finales)

Archivo	Contenido
prob_cond_XXXX_XXXX.csv	Probabilidades $P(\text{candidato} \mid \text{partido})$ estimadas por FASTEI, por par de elecciones.
dicotomizacion_XXXX_XXXX.csv	Matriz 0/1 que asigna cada partido al candidato más probable.
dataset_consolidado_tesis.csv / .xlsx	Dataset consolidado a nivel candidato-año con 346 columnas de comunas.
base_comunal_ampliada.csv	Base del modelo ampliado: comuna $\times$ año $\times$ bloque (con FASTEI).
base_comunal_sin_fastei.csv	Base del baseline sin FASTEI: clasificación manual de partidos.

A.4 Resultados estadísticos

Archivo	Contenido
det_ols_coeficientes.csv	Coefficientes OLS con SE, t, p-value e intervalos de confianza.
det_ols_vif.csv	Factor de inflación de la varianza (VIF) para diagnóstico de multicolinealidad.
det_ols_robustos.csv	Errores estándar clusterizados por año.
det_rf_importance.csv / det_xgb_importance.csv	Importancias de variables para Random Forest y XGBoost.
det_rf_permut.csv / det_xgb_permut.csv	Permutation importance de cada modelo.

Archivo	Contenido
rolling_forecast.csv	Resultados de la predicción rolling hacia adelante (2013, 2017, 2021, 2025).

Anexo B. Glosario de términos clave

Término	Definición
Inferencia ecológica	Estimar comportamiento individual a partir de datos agregados (totales por comuna).
FASTEI	Librería de R que implementa un algoritmo rápido de inferencia ecológica para el caso $R \times C$.
Algoritmo EM	Método iterativo (Esperanza–Maximización) para estimar parámetros maximizando la verosimilitud.
Matriz W	Votos de diputados: comunas $\times$ partidos.
Matriz X	Votos presidenciales: comunas $\times$ candidatos.
prob_cond	Probabilidad $P(\text{candidato} \mid \text{partido})$ estimada por FASTEI.
Dicotomización argmax	Asignar cada partido por completo al candidato con mayor probabilidad (0/1).
Votos imputados	Votos presidenciales estimados por comuna a partir de los de diputados.
Predicción hacia adelante	Entrenar con todas las elecciones pasadas y predecir la siguiente.
MAE / RMSE / R^2	Métricas de error: error absoluto medio, raíz del error cuadrático medio y bondad de ajuste.

Término	Definición
AUC / ROC	Área bajo la curva ROC; mide la capacidad de un clasificador de separar dos clases.
Permutation importance	Caída en R^2 al permutar aleatoriamente una variable, mide su aporte real al modelo.
VIF	Variance Inflation Factor; mide multicolinealidad entre variables explicativas.